

Chapitre 9

Méthodes de Monte Carlo

Pour une distribution de probabilité μ donnée, il s'agit d'approcher numériquement, par des méthodes de Monte Carlo, l'intégrale ou de manière équivalente l'espérance mathématique

$$\langle \mu, \phi \rangle = \int_E \phi(x) \mu(dx) = \mathbb{E}[\phi(X)] , \quad (9.1)$$

où la variable aléatoire X a pour distribution de probabilité μ , pour toute fonction mesurable bornée ϕ . Dans toute la suite, la notation $S^N(\mu)$ désigne la distribution de probabilité empirique

$$S^N(\mu) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi^i}$$

associée à un N -échantillon $(\xi^1, \dots, \xi^N)$ de variables aléatoires i.i.d., de distribution de probabilité commune μ , c'est-à-dire que

$$\langle S^N(\mu), \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(\xi^i) ,$$

pour toute fonction mesurable bornée ϕ .

Dans les situations où il est facile de simuler des variables aléatoires de distribution de probabilité μ , il est naturel d'introduire l'approximation suivante

$$\langle \mu, \phi \rangle \approx \langle S^N(\mu), \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(\xi^i) ,$$

pour toute fonction mesurable bornée ϕ , c'est-à-dire que

$$\mu \approx S^N(\mu) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi^i} ,$$

où les variables aléatoires $(\xi^1, \dots, \xi^N)$ sont i.i.d., de distribution de probabilité commune μ . On définit par

$$\text{var}(\phi, \mu) = \langle \mu, |\phi - \langle \mu, \phi \rangle|^2 \rangle = \langle \mu, |\phi|^2 \rangle - |\langle \mu, \phi \rangle|^2 \leq \|\phi\|^2 ,$$

la variance de la fonction mesurable bornée ϕ par rapport à la distribution de probabilité μ .

Théorème 9.1 *La variable aléatoire $\langle S^N(\mu), \phi \rangle$ est un estimateur non-biaisé de $\langle \mu, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^2 = \frac{1}{N} \text{var}(\phi, \mu) ,$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{ \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \langle \mu, |\phi - \langle \mu, \phi \rangle|^p \rangle^{1/p} ,$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.2 Compte tenu que

$$|\phi(x) - \langle \mu, \phi \rangle| \leq \text{osc}(\phi) = \sup_{x \in E} \phi(x) - \inf_{x \in E} \phi(x) ,$$

pour tout $x \in E$, on a également la majoration plus grossière suivante

$$\{ \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \text{osc}(\phi) , \quad (9.2)$$

pour toute fonction mesurable bornée ϕ .

PREUVE. En exploitant l'indépendance des différentes variables aléatoires, on remarque que

$$\begin{aligned} \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^2 &= \mathbb{E} \left| \frac{1}{N} \sum_{i=1}^N [\phi(\xi^i) - \langle \mu, \phi \rangle] \right|^2 \\ &= \frac{1}{N^2} \sum_{i=1}^N \mathbb{E} |\phi(\xi^i) - \langle \mu, \phi \rangle|^2 = \frac{1}{N} \langle \mu, |\phi - \langle \mu, \phi \rangle|^2 \rangle , \end{aligned}$$

pour toute fonction mesurable bornée ϕ . Plus généralement, pour tout réel $p \geq 2$

$$\begin{aligned} \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^p &= \mathbb{E} \left| \frac{1}{N} \sum_{i=1}^N [\phi(\xi^i) - \langle \mu, \phi \rangle] \right|^p \\ &\leq \frac{B_p}{N^{p/2}} \frac{1}{N} \sum_{i=1}^N \mathbb{E} |\phi(\xi^i) - \langle \mu, \phi \rangle|^p = \frac{B_p}{N^{p/2}} \langle \mu, |\phi - \langle \mu, \phi \rangle|^p \rangle , \end{aligned}$$

d'après l'inégalité de Marcinkiewicz-Zygmund, c'est-à-dire que

$$\{ \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^p \}^{1/p} \leq \frac{B_p^{1/p}}{\sqrt{N}} \langle \mu, |\phi - \langle \mu, \phi \rangle|^p \rangle^{1/p} ,$$

pour toute fonction mesurable bornée ϕ . □

Le théorème central limite (dans sa version classique, pour des variables indépendantes identiquement distribuées) donne

$$\sqrt{N} \langle S^N(\mu) - \mu, \phi \rangle = \frac{1}{\sqrt{N}} \sum_{i=1}^N [\phi(\xi^i) - \langle \mu, \phi \rangle] \Longrightarrow \mathcal{N}(0, \text{var}(\phi, \mu)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ .

9.1 Échantillonnage pondéré

Une approche traditionnelle pour calculer l'intégrale (9.1) est l'échantillonnage pondéré, ou *importance sampling*, dans laquelle une nouvelle distribution de probabilité $\nu \gg \mu$ est utilisée, qui domine la distribution de probabilité μ , c'est-à-dire qu'il existe une densité (ou dérivée de Radon-Nikodym) $d\mu/d\nu$ telle que

$$\langle \mu, \phi \rangle = \int_E \phi(x) \mu(dx) = \int_E \phi(x) \frac{d\mu}{d\nu}(x) \nu(dx) = \langle \nu, \phi \frac{d\mu}{d\nu} \rangle = \mathbb{E}[\phi(\Xi) \frac{d\mu}{d\nu}(\Xi)] ,$$

où la variable aléatoire Ξ a pour distribution de probabilité ν , pour toute fonction mesurable bornée ϕ . S'il est facile

- d'évaluer la fonction positive $d\mu/d\nu$,
- et de simuler une variable aléatoire de distribution de probabilité ν ,

alors il est facile

- d'approcher la distribution de probabilité μ par la distribution de probabilité empirique pondérée associée à un échantillon de variables aléatoires i.i.d., de distribution de probabilité commune ν et pondéré par la fonction positive $d\mu/d\nu$.

On peut en effet introduire l'approximation suivante

$$\langle \mu, \phi \rangle = \langle \nu, \phi \frac{d\mu}{d\nu} \rangle \approx \langle S^N(\nu), \phi \frac{d\mu}{d\nu} \rangle = \frac{1}{N} \sum_{i=1}^N \phi(x_i) \frac{d\mu}{d\nu}(x_i) ,$$

où les variables aléatoires $(x_1, \dots, x_N)$ sont i.i.d., de distribution de probabilité commune ν , c'est-à-dire que

$$\mu = \frac{d\mu}{d\nu} \nu \approx \mu_N = \frac{d\mu}{d\nu} S^N(\nu) = \frac{1}{N} \sum_{i=1}^N \frac{d\mu}{d\nu}(x_i) \delta_{x_i} .$$

En particulier pour $\phi \equiv 1$, la masse totale

$$\langle \mu_N, 1 \rangle = \frac{1}{N} \sum_{i=1}^N \frac{d\mu}{d\nu}(x_i) ,$$

n'est pas nécessairement égale à 1, de sorte que l'approximation μ_N n'est pas nécessairement normalisée. En revanche, il résulte immédiatement du Théorème 9.1 que la variable aléatoire $\langle \mu_N, \phi \rangle = \langle S^N(\nu), \phi \frac{d\mu}{d\nu} \rangle$ est un estimateur non-biaisé de $\langle \nu, \phi \frac{d\mu}{d\nu} \rangle = \langle \mu, \phi \rangle$, et la variance (non-asymptotique) de cet estimateur est

$$\mathbb{E}|\langle \mu_N - \mu, \phi \rangle|^2 = \mathbb{E}\langle S^N(\nu) - \nu, \phi \frac{d\mu}{d\nu} \rangle^2 = \frac{1}{N} \text{var}(\phi \frac{d\mu}{d\nu}, \nu) .$$

Remarque 9.3 Alternativement, on peut considérer l'approximation auto-normalisée

$$\mu'_N = \frac{\mu_N}{\langle \mu_N, 1 \rangle} = \sum_{i=1}^N \frac{\frac{d\mu}{d\nu}(x_i)}{\sum_{j=1}^N \frac{d\mu}{d\nu}(x_j)} \delta x_i \quad \text{c'est-à-dire que} \quad \langle \mu'_N, \phi \rangle = \frac{\sum_{i=1}^N \phi(x_i) \frac{d\mu}{d\nu}(x_i)}{\sum_{i=1}^N \frac{d\mu}{d\nu}(x_i)} ,$$

pour toute fonction mesurable bornée ϕ , où les variables aléatoires $(x_1, \dots, x_N)$ sont i.i.d., de distribution de probabilité commune ν . Il résulte de la décomposition suivante

$$\mu'_N - \mu = \frac{\mu_N}{\langle \mu_N, 1 \rangle} - \mu = (\mu_N - \mu) - \langle \mu_N - \mu, 1 \rangle \mu'_N ,$$

que

$$\langle \mu'_N - \mu, \phi \rangle = \langle \mu_N - \mu, \phi \rangle - \langle \mu_N - \mu, 1 \rangle \langle \mu'_N, \phi \rangle ,$$

de sorte que

$$\{ \mathbb{E} |\langle \mu'_N - \mu, \phi \rangle|^2 \}^{1/2} \leq \{ \mathbb{E} |\langle \mu_N - \mu, \phi \rangle|^2 \}^{1/2} + \{ \mathbb{E} |\langle \mu_N - \mu, 1 \rangle|^2 \}^{1/2} \|\phi\| ,$$

d'après l'inégalité (triangulaire) de Minkowski, pour toute fonction mesurable bornée ϕ . Ce type d'approximation sera étudié en détail à la Section 9.2.

On remarque que

$$\begin{aligned} \text{var}(\phi \frac{d\mu}{d\nu}, \nu) &= \int_E (\phi(x) \frac{d\mu}{d\nu}(x))^2 \nu(dx) - (\int_E \phi(x) \frac{d\mu}{d\nu}(x) \nu(dx))^2 \\ &= \int_E (\phi(x) \frac{d\mu}{d\nu}(x))^2 \nu(dx) - \langle \mu, \phi \rangle^2 , \end{aligned}$$

et

$$\int_E (\phi(x) \frac{d\mu}{d\nu}(x))^2 \nu(dx) \geq (\int_E |\phi(x)| \frac{d\mu}{d\nu}(x) \nu(dx))^2 = \langle \mu, |\phi| \rangle^2 ,$$

d'après l'inégalité de Jensen, d'où la borne inférieure suivante

$$\text{var}(\phi \frac{d\mu}{d\nu}, \nu) \geq \langle \mu, |\phi| \rangle^2 - \langle \mu, \phi \rangle^2 \geq 0 ,$$

indépendante du choix de la distribution de probabilité d'importance ν . On remarque que si la fonction ϕ garde un signe constant, alors la borne inférieure est nulle.

Parmi tous les choix possibles pour la distribution de probabilité d'importance ν , il existe un choix qui minimise la variance, c'est-à-dire que la borne inférieure est atteinte, même si ce choix est en pratique inaccessible car il nécessite de connaître la constante de normalisation

$$\langle \mu, |\phi| \rangle = \int_E |\phi(x)| \mu(dx) = \mathbb{E} |\phi(X)| ,$$

dont le calcul présente le même degré de difficulté que le calcul de l'intégrale (9.1) elle-même ! En effet, si on introduit

$$\nu_* = |\phi| \cdot \mu = \frac{|\phi| \mu}{\langle \mu, |\phi| \rangle} ,$$

c'est-à-dire que la distribution de probabilité μ domine la distribution de probabilité ν_* mais la réciproque n'est pas nécessairement vraie, par exemple dans le cas où la fonction ϕ peut s'annuler, mais en revanche la distribution de probabilité ν_* domine la distribution de probabilité μ sur le support de la fonction ϕ , avec

$$|\phi| \frac{d\mu}{d\nu_*} = \langle \mu, |\phi| \rangle ,$$

alors on vérifie que

$$\int_E (\phi(x) \frac{d\mu}{d\nu_*}(x))^2 \nu_*(dx) = \langle \mu, |\phi| \rangle^2 ,$$

de sorte que

$$\text{var}(\phi \frac{d\mu}{d\nu_*}, \nu_*) = \int_E (\phi(x) \frac{d\mu}{d\nu_*}(x))^2 \nu_*(dx) - \langle \mu, \phi \rangle^2 = \langle \mu, |\phi| \rangle^2 - \langle \mu, \phi \rangle^2 ,$$

et la borne inférieure est atteinte.

Remarque 9.4 La distribution de probabilité d'importance optimale ν_* et la fonction d'importance optimale $d\mu/d\nu_*$ associée dépendent de la fonction ϕ dont on veut calculer l'intégrale, et ne sont donc pas universelles.

Remarque 9.5 Il est certainement possible de simuler une variable aléatoire distribuée selon ν_* , même si la constante de normalisation $\langle \mu, |\phi| \rangle$ est inconnue, en utilisant l'une ou l'autre des méthodes proposées à la Section 9.2, mais la connaissance explicite de la constante de normalisation est absolument nécessaire pour évaluer la fonction d'importance optimale $d\mu/d\nu_*$. En pratique, le choix optimal n'est donc simplement pas utilisable. Cependant, on peut espérer que des algorithmes adaptatifs, qui apprennent (de manière approchée) la distribution de probabilité d'importance optimale ν_* , produiront des estimateurs dont la variance approchera la variance minimale.

Pour tout autre choix (non-optimal) de la distribution de probabilité d'importance ν et de la fonction d'importance $d\mu/d\nu$, on a

$$\begin{aligned} \text{var}(\phi \frac{d\mu}{d\nu}, \nu) - \text{var}(\phi \frac{d\mu}{d\nu_*}, \nu_*) &= \int_E (\phi(x) \frac{d\mu}{d\nu}(x))^2 \nu(dx) - \langle \mu, |\phi| \rangle^2 \\ &= \int_E (\phi(x) \frac{d\mu}{d\nu_*}(x) \frac{d\nu_*}{d\nu}(x))^2 \nu(dx) - \langle \mu, |\phi| \rangle^2 \\ &= \langle \mu, |\phi| \rangle^2 \int_E (\frac{d\nu_*}{d\nu}(x))^2 \nu(dx) - \langle \mu, |\phi| \rangle^2 \\ &= \langle \mu, |\phi| \rangle^2 \int_E ((\frac{d\nu_*}{d\nu}(x))^2 - 1) \nu(dx) \\ &= \langle \mu, |\phi| \rangle^2 \chi^2(\nu_*, \nu) . \end{aligned}$$

en terme de la divergence du χ^2 entre les distributions de probabilité ν_* et ν , définie par

$$\chi^2(\nu_*, \nu) = \int_E (\frac{d\nu_*}{d\nu}(x) - 1)^2 \nu(dx) = \int_E ((\frac{d\nu_*}{d\nu}(x))^2 - 1) \nu(dx) .$$

pourvu que la distribution de probabilité d'importance ν domine la distribution de probabilité d'importance optimale ν_* . Si λ est une mesure positive, pas nécessairement normalisée, qui domine à la fois ν_* et ν , avec les densités

$$q_* = \frac{d\nu_*}{d\lambda} \quad \text{et} \quad q = \frac{d\nu}{d\lambda} ,$$

respectivement, alors on a les expressions équivalentes suivantes

$$\chi^2(\nu_*, \nu) = \int_E \frac{(q_*(x) - q(x))^2}{q(x)} \lambda(dx) = \int_E \frac{q_*^2(x)}{q(x)} \lambda(dx) - 1 .$$

En conclusion, si au lieu de la distribution de probabilité d'importance optimale ν_* on utilise une distribution de probabilité d'importance ν^M

- qui domine la distribution de probabilité μ , et qui domine donc a fortiori la distribution de probabilité d'importance optimale ν_* , de sorte que la divergence $\chi^2(\nu_*, \nu^M)$ est bien définie,
- et qui approche la distribution de probabilité d'importance optimale ν_* , c'est-à-dire que $\chi^2(\nu_*, \nu^M)$ tend vers zero, quand $M \uparrow \infty$,

et si on construit l'estimateur suivant

$$\langle \mu_N^M, \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(x_i) \frac{d\mu}{d\nu^M}(x_i) ,$$

où les variables aléatoires $(x_1, \dots, x_N)$ sont i.i.d. de distribution de probabilité commune ν^M , alors la variance de cet estimateur est

$$\mathbb{E}|\langle \mu_N^M - \mu, \phi \rangle|^2 = \frac{1}{N} \text{var}(\phi \frac{d\mu}{d\nu^M}, \nu^M) = \frac{1}{N} [\text{var}(\phi \frac{d\mu}{d\nu_*}, \nu_*) + \langle \mu, |\phi|^2 \rangle \chi^2(\nu_*, \nu^M)] ,$$

et si la fonction ϕ garde un signe constant, alors

$$\mathbb{E}|\langle \mu_N^M - \mu, \phi \rangle|^2 = \frac{1}{N} \chi^2(\nu_*, \nu^M) \langle \mu, |\phi|^2 \rangle ,$$

compte tenu que la variance minimale $\text{var}(\phi \frac{d\mu}{d\nu_*}, \nu_*)$ est nulle dans ce cas, c'est-à-dire que l'erreur d'échantillonnage Monte Carlo et l'erreur d'approximation due à l'apprentissage de la distribution de probabilité d'importance optimale ν_* se multiplient au lieu de s'additionner !

9.2 Simulation selon une distribution de Gibbs–Boltzmann

Il peut arriver que la distribution de probabilité d'importance soit seulement connue à une constante multiplicative près, par exemple dans la situation suivante. Si la distribution de probabilité μ est de la forme

$$\mu = g \cdot \eta = \frac{g \eta}{\langle \eta, g \rangle} \quad \text{c'est-à-dire} \quad \langle \mu, \phi \rangle = \frac{\langle \eta, g \phi \rangle}{\langle \eta, g \rangle} ,$$

ou de manière équivalente

$$\langle \gamma, \phi \rangle = \langle \eta, g \phi \rangle = \mathbb{E}[g(\Xi) \phi(\Xi)] \quad \text{et} \quad \langle \mu, \phi \rangle = \frac{\langle \gamma, \phi \rangle}{\langle \gamma, 1 \rangle}, \quad (9.3)$$

où la variable aléatoire Ξ a pour distribution de probabilité η , pour toute fonction mesurable bornée ϕ , et s'il est facile

- d'évaluer la fonction positive g ,
- et de simuler une variable aléatoire de distribution de probabilité η ,

alors il est possible

- de simuler une variable aléatoire de distribution de probabilité μ , avec une méthode d'acceptation / rejet,
- ou bien d'approcher la distribution de probabilité μ par la distribution de probabilité empirique pondérée associée à un échantillon de variables aléatoires i.i.d., de distribution de probabilité commune η et pondéré par la fonction positive g , avec une méthode d'échantillonnage pondéré,

même si la constante de normalisation $\langle \eta, g \rangle$ n'est pas connue explicitement.

► **Acceptation / rejet** La constante de normalisation $\langle \eta, g \rangle$ n'est pas nécessairement connue, et on suppose seulement que $\sup_{x \in E} g(x) \leq M < \infty$.

On simule indépendamment une variable aléatoire Ξ selon la distribution de probabilité η et une variable aléatoire U uniforme sur $[0, 1]$: si $g(\Xi) \geq M U$ alors on pose $X = \Xi$, et sinon on recommence. La variable aléatoire X simulée selon cet algorithme a pour distribution de probabilité $\mu = g \cdot \eta$. En effet

$$\mathbb{E}[\phi(X)] = \mathbb{E}[\phi(\Xi) \mid g(\Xi) \geq M U] = \frac{\mathbb{E}[\phi(\Xi) 1_{(g(\Xi) \geq M U)}]}{\mathbb{P}[g(\Xi) \geq M U]},$$

et

$$\begin{aligned} \mathbb{E}[\phi(\Xi) 1_{(g(\Xi) \geq M U)}] &= \int_E \int_0^1 \phi(x) 1_{(g(x) \geq M u)} du \eta(dx) \\ &= \int_E \phi(x) \frac{g(x)}{M} \eta(dx) = \frac{\langle \eta, g \phi \rangle}{M}, \end{aligned}$$

pour toute fonction mesurable bornée ϕ , et en particulier

$$\mathbb{P}[g(\Xi) \geq M U] = \frac{\langle \eta, g \rangle}{M},$$

pour $\phi \equiv 1$, de sorte que

$$\mathbb{E}[\phi(X)] = \frac{\langle \eta, g \phi \rangle}{\langle \eta, g \rangle} = \langle \mu, \phi \rangle.$$

Soit $(U_k, k \geq 1)$ et $(\Xi_k, k \geq 1)$ deux suites indépendantes, de variables aléatoires i.i.d. uniformes sur $[0, 1]$ et de variables aléatoires i.i.d. de distribution de probabilité commune η respectivement, et on définit le nombre aléatoire

$$T = \inf\{k \geq 1 : g(\Xi_k) \geq M U_k\},$$

qui représente le nombre d'itérations de l'algorithme d'acceptation / rejet nécessaires pour produire une variable aléatoire de distribution de probabilité $\mu = g \cdot \eta$.

Proposition 9.6 *Les variables aléatoires $X = \Xi_T$ et T sont indépendantes*

- de distribution de probabilité $\mu = g \cdot \eta$,
- et de loi géométrique de paramètre $\frac{\langle \eta, g \rangle}{M}$,

respectivement.

PREUVE. Par indépendance

$$\begin{aligned} \mathbb{E}[\phi(X) 1_{(T=n)}] &= \mathbb{E}[\phi(\Xi_n) 1_{(g(\Xi_n) \geq M U_n)} \prod_{k=1}^{n-1} 1_{(g(\Xi_k) < M U_k)}] \\ &= \mathbb{E}[\phi(\Xi_n) 1_{(g(\Xi_n) \geq M U_n)}] \prod_{k=1}^{n-1} \mathbb{P}[g(\Xi_k) < M U_k] \\ &= \frac{\langle \eta, g \phi \rangle}{M} \left(1 - \frac{\langle \eta, g \rangle}{M}\right)^{n-1} \\ &= \langle \mu, \phi \rangle \frac{\langle \eta, g \rangle}{M} \left(1 - \frac{\langle \eta, g \rangle}{M}\right)^{n-1}, \end{aligned}$$

pour tout entier n et pour toute fonction mesurable bornée ϕ , et en particulier pour $\phi \equiv 1$

$$\mathbb{P}[T = n] = \frac{\langle \eta, g \rangle}{M} \left(1 - \frac{\langle \eta, g \rangle}{M}\right)^{n-1},$$

de sorte que

$$\mathbb{E}[\phi(X) 1_{(T=n)}] = \langle \mu, \phi \rangle \frac{\langle \eta, g \rangle}{M} \left(1 - \frac{\langle \eta, g \rangle}{M}\right)^{n-1} = \mathbb{E}[\phi(X)] \mathbb{P}[T = n],$$

ce qui montre l'indépendance des variables aléatoires T et $X = \Xi_T$. $\square$

Soit $(\xi^1, \dots, \xi^N)$ un N -échantillon de distribution de probabilité commune $\mu = g \cdot \eta$ obtenu par l'algorithme d'acceptation / rejet présenté ci-dessus, et soit $(T^1, \dots, T^N)$ les nombres d'itérations nécessaires pour produire respectivement les variables aléatoires $(\xi^1, \dots, \xi^N)$. Pour énoncer un théorème central limite, et utiliser la variance asymptotique comme moyen de comparer les algorithmes entre eux, il est plus raisonnable d'utiliser comme normalisation le nombre

total d'itérations, c'est-à-dire le nombre total de variables aléatoires simulées, qui est une mesure quantitative du temps de calcul de l'algorithme d'acceptation / rejet pour générer un N -échantillon. D'après la loi des grands nombres

$$\frac{1}{N} \sum_{i=1}^N T^i \longrightarrow \mathbb{E}[T] = \frac{M}{\langle \eta, g \rangle} ,$$

en probabilité quand $N \uparrow \infty$, et d'après le lemme de Slutsky

$$\left(\sum_{i=1}^N T^i \right)^{1/2} \langle S^N(\mu) - \mu, \phi \rangle \Longrightarrow \mathcal{N}\left(0, \frac{M}{\langle \eta, g \rangle} \text{var}(\phi, \mu)\right) ,$$

en distribution quand $N \uparrow \infty$.

Remarque 9.7 La variance asymptotique est d'autant plus petite que le rapport

$$\frac{M}{\langle \eta, g \rangle} = \frac{M}{\sup_{x \in E} g(x)} \frac{\sup_{x \in E} g(x)}{\langle \eta, g \rangle} ,$$

est petit (proche de 1). Le premier facteur est d'autant plus petit (proche de 1) que la borne M est proche du supremum, c'est donc une caractéristique de la méthode, tandis que le second facteur est d'autant plus petit (proche de 1) que le recouvrement entre la distribution de probabilité η et la fonction g est grand, c'est-à-dire que la distribution de probabilité η est concentrée autour des points où la fonction g prend ses plus grandes valeurs, c'est donc une caractéristique du modèle lui-même.

► **Échantillonnage pondéré** Le principe consiste à approximer numérateur et dénominateur dans (9.3) à l'aide d'un unique échantillon : on introduit les approximations suivantes

$$\langle \gamma, \phi \rangle = \langle \eta, g \phi \rangle \approx \langle S^N(\eta), g \phi \rangle = \frac{1}{N} \sum_{i=1}^N g(\xi^i) \phi(\xi^i) ,$$

et

$$\langle \mu, \phi \rangle = \langle g \cdot \eta, \phi \rangle \approx \langle g \cdot S^N(\eta), \phi \rangle = \frac{\sum_{i=1}^N g(\xi^i) \phi(\xi^i)}{\sum_{i=1}^N g(\xi^i)} \quad \text{pourvu que} \quad \frac{1}{N} \sum_{i=1}^N g(\xi^i) > 0 ,$$

pour toute fonction mesurable bornée ϕ , c'est-à-dire que

$$\gamma \approx \gamma^N = g S^N(\eta) = \frac{1}{N} \sum_{i=1}^N g(\xi^i) \delta_{\xi^i}$$

et

$$\mu \approx \mu^N = g \cdot S^N(\eta) = \sum_{i=1}^N \frac{g(\xi^i)}{\sum_{j=1}^N g(\xi^j)} \delta_{\xi^i} = \sum_{i=1}^N w^i \delta_{\xi^i} \quad \text{pourvu que} \quad \frac{1}{N} \sum_{i=1}^N g(\xi^i) > 0 ,$$

où les variables aléatoires $(\xi^1, \dots, \xi^N)$ sont i.i.d., de distribution de probabilité commune η , et où les poids positifs $(w^1, \dots, w^N)$ sont définis par

$$w^i = \frac{g(\xi^i)}{\sum_{j=1}^N g(\xi^j)} \quad \text{pour tout } i = 1, \dots, N.$$

Il résulte du Théorème 9.1 que la variable aléatoire $\langle \gamma^N, \phi \rangle = \langle S^N(\eta), g\phi \rangle$ est un estimateur non-biaisé de $\langle \gamma, \phi \rangle = \langle \eta, g\phi \rangle$, pour toute fonction mesurable bornée ϕ , et en particulier pour $\phi \equiv 1$, la variable aléatoire $\langle \gamma^N, 1 \rangle = \langle S^N(\eta), g \rangle$ est un estimateur non-biaisé de $\langle \gamma, 1 \rangle = \langle \eta, g \rangle$. En revanche, en tant que rapport de deux estimateurs non-biaisés, la variable aléatoire $\langle \mu^N, \phi \rangle = \langle \gamma^N, \phi \rangle / \langle \gamma^N, 1 \rangle$ est un estimateur *biaisé* de $\langle \mu, \phi \rangle = \langle \gamma, \phi \rangle / \langle \gamma, 1 \rangle$.

Théorème 9.8 *La variable aléatoire $\langle \gamma^N, \phi \rangle$ est un estimateur non-biaisé de $\langle \gamma, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} |^2 \}^{1/2} = \frac{1}{\sqrt{N}} \left(\frac{\langle \eta, |g\phi - \langle \eta, g\phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2} \right)^{1/2} , \quad (9.4)$$

et pour tout réel $p \geq 2$

$$\{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \left(\frac{\langle \eta, |g\phi - \langle \eta, g\phi \rangle|^p \rangle}{\langle \eta, g \rangle^p} \right)^{1/p} , \quad (9.5)$$

pour toute fonction ϕ mesurable bornée.

PREUVE. On remarque que

$$\frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} = \frac{\langle S^N(\eta) - \eta, g\phi \rangle}{\langle \eta, g \rangle} ,$$

et il résulte du Théorème 9.1 que

$$\{ \mathbb{E} | \frac{\langle S^N(\eta) - \eta, g\phi \rangle}{\langle \eta, g \rangle} |^2 \}^{1/2} = \frac{1}{\sqrt{N}} \left(\frac{\langle \eta, |g\phi - \langle \eta, g\phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2} \right)^{1/2} ,$$

et

$$\{ \mathbb{E} | \frac{\langle S^N(\eta) - \eta, g\phi \rangle}{\langle \eta, g \rangle} |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \left(\frac{\langle \eta, |g\phi - \langle \eta, g\phi \rangle|^p \rangle}{\langle \eta, g \rangle^p} \right)^{1/p} ,$$

pour tout réel $p \geq 2$. □

Remarque 9.9 En particulier pour $\phi \equiv 1$, la variable aléatoire $\langle \gamma^N, 1 \rangle$ est un estimateur non-biaisé de la constante de normalisation $\langle \gamma, 1 \rangle$, et les moments de l'erreur relative d'estimation vérifient

$$\{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^2 \}^{1/2} = \frac{1}{\sqrt{N}} (\frac{\langle \eta, |g - \langle \eta, g \rangle|^2 \rangle}{\langle \eta, g \rangle^2})^{1/2} , \quad (9.6)$$

et

$$\{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} (\frac{\langle \eta, |g - \langle \eta, g \rangle|^p \rangle}{\langle \eta, g \rangle^p})^{1/p} , \quad (9.7)$$

pour tout réel $p \geq 2$. On remarque aussi que

$$g(\phi - \langle \mu, \phi \rangle) - \langle \eta, g(\phi - \langle \mu, \phi \rangle) \rangle = g(\phi - \langle \mu, \phi \rangle) ,$$

compte tenu que

$$\langle \eta, g(\phi - \langle \mu, \phi \rangle) \rangle = \langle \eta, g \rangle \langle \mu, \phi - \langle \mu, \phi \rangle \rangle = 0 ,$$

de sorte que

$$\{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^2 \}^{1/2} = \frac{1}{\sqrt{N}} (\frac{\langle \eta, g^2 |\phi - \langle \mu, \phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2})^{1/2} , \quad (9.8)$$

et

$$\{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} (\frac{\langle \eta, g^p |\phi - \langle \mu, \phi \rangle|^p \rangle}{\langle \eta, g \rangle^p})^{1/p} , \quad (9.9)$$

pour tout réel $p \geq 2$.

Théorème 9.10 La variable aléatoire $\langle \mu^N, \phi \rangle$ est un estimateur biaisé de $\langle \mu, \phi \rangle$, avec

$$\mathbb{E}[\langle \mu^N, \phi \rangle] = \langle \mu, \phi \rangle + O(1/N) , \quad (9.10)$$

et les moments de l'erreur d'estimation vérifient

$$\{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^2 \}^{1/2} = \frac{1}{\sqrt{N}} (\frac{\langle \eta, g^2 |\phi - \langle \mu, \phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2})^{1/2} + O(1/N) , \quad (9.11)$$

et pour tout réel $p \geq 2$

$$\{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} (\frac{\langle \eta, g^p |\phi - \langle \mu, \phi \rangle|^p \rangle}{\langle \eta, g \rangle^p})^{1/p} + O(1/N) ,$$

pour toute fonction mesurable bornée ϕ .

PREUVE. On rappelle la majoration grossière

$$| \langle \mu^N - \mu, \phi \rangle | = | \langle \mu^N, \phi - \langle \mu, \phi \rangle \rangle | \leq \text{osc}(\phi) , \quad (9.12)$$

valable pour toute fonction ϕ mesurable bornée. On remarque aussi que

$$\begin{aligned} \langle \mu^N - \mu, \phi \rangle &= \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} - \langle \mu^N, \phi \rangle \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma, 1 \rangle} \\ &= \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} - \langle \mu, \phi \rangle \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma, 1 \rangle} - \langle \mu^N - \mu, \phi \rangle \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma, 1 \rangle} \\ &= \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} - \langle \mu^N - \mu, \phi \rangle (\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1) , \end{aligned}$$

et en itérant cette relation, on obtient

$$\begin{aligned}
\langle \mu^N - \mu, \phi \rangle &= \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \\
&\quad - \left[\frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} - \langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \right] \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \\
&= \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} - \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \\
&\quad + \langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2 .
\end{aligned}$$

Pour l'étude du biais, on remarque que

$$\mathbb{E} \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} = 0 ,$$

de sorte que

$$\begin{aligned}
\mathbb{E}[\langle \mu^N, \phi \rangle] - \langle \mu, \phi \rangle &= \mathbb{E} \langle \mu^N - \mu, \phi \rangle \\
&= - \mathbb{E} \left[\frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \right] + \mathbb{E}[\langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2] ,
\end{aligned}$$

et en utilisant l'inégalité triangulaire, puis l'inégalité de Hölder et la majoration grossière (9.12), on obtient

$$\begin{aligned}
|\mathbb{E}[\langle \mu^N, \phi \rangle] - \langle \mu, \phi \rangle| &\leq \mathbb{E} \left| \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \right| + \mathbb{E} [|\langle \mu^N - \mu, \phi \rangle| \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2] \\
&\leq \left\{ \mathbb{E} \left| \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \right|^2 \right\}^{1/2} \left\{ \mathbb{E} \left| \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right|^2 \right\}^{1/2} \\
&\quad + \text{osc}(\phi) \mathbb{E} \left| \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right|^2 ,
\end{aligned}$$

où les deux termes dans la majoration sont d'ordre $1/N$ d'après (9.6) et (9.8).

Pour l'étude du moment d'ordre 2, en utilisant l'identité (9.8) et l'inégalité triangulaire, puis l'inégalité de Hölder et la majoration grossière (9.12), on obtient

$$\begin{aligned}
& | \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^2 \}^{1/2} - \frac{1}{\sqrt{N}} \left(\frac{\langle \eta, g^2 | \phi - \langle \mu, \phi \rangle |^2 \rangle}{\langle \eta, g \rangle^2} \right)^{1/2} | \\
&= | \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^2 \}^{1/2} - \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^2 \}^{1/2} | \\
&\leq \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle - \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^2 \}^{1/2} \\
&\leq \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) |^2 \}^{1/2} + \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2 |^2 \}^{1/2} \\
&\leq \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^4 \}^{1/4} \{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^4 \}^{1/4} + \text{osc}(\phi) \{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^4 \}^{1/2} ,
\end{aligned}$$

où les deux termes dans la majoration sont d'ordre $1/N$ d'après (9.7) et (9.9).

Pour l'étude du moment d'ordre p , en utilisant l'inégalité triangulaire et la majoration (9.9), puis l'inégalité de Hölder et la majoration grossière (9.12), on obtient

$$\begin{aligned}
\{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^p \}^{1/p} &\leq \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^p \}^{1/p} \\
&\quad + \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) |^p \}^{1/p} \\
&\quad + \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2 |^p \}^{1/p} \\
&\leq \frac{c_p}{\sqrt{N}} \left(\frac{\langle \eta, g^p | \phi - \langle \mu, \phi \rangle |^p \rangle}{\langle \eta, g \rangle^p} \right)^{1/p} \\
&\quad + \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^{2p} \}^{1/2p} \{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^{2p} \}^{1/2p} \\
&\quad + \text{osc}(\phi) \{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^{2p} \}^{1/p} ,
\end{aligned}$$

où les deux derniers termes dans la majoration sont d'ordre $1/N$ d'après (9.7) et (9.9). $\square$

Théorème 9.11

$$\sqrt{N} \left[\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right] \Longrightarrow \mathcal{N}(0, V) \quad \text{et} \quad \sqrt{N} \langle \mu^N - \mu, \phi \rangle \Longrightarrow \mathcal{N}(0, v(\phi)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$V = \frac{\langle \eta, g^2 \rangle}{\langle \eta, g \rangle^2} - 1 \quad \text{et} \quad v(\phi) = \frac{\langle \eta, g^2 | \phi - \langle \mu, \phi \rangle |^2 \rangle}{\langle \eta, g \rangle^2} ,$$

respectivement.

Remarque 9.12 On vérifie que la variance asymptotique V coïncide avec la variance non-asymptotique donnée en (9.6), et que la variance asymptotique $v(\phi)$ coïncide avec le terme dominant de l'erreur quadratique moyenne non-asymptotique donnée en (9.11) ou de manière équivalente avec le terme dominant de la variance non-asymptotique, compte tenu que le biais donné en (9.10) est asymptotiquement négligeable.

PREUVE. Il résulte du théorème central limite (dans sa version classique, pour des variables indépendantes identiquement distribuées), que

$$\sqrt{N} \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} = \sqrt{N} \frac{\langle S^N(\eta) - \eta, g \phi \rangle}{\langle \eta, g \rangle} \implies \mathcal{N}(0, \frac{\text{var}(g \phi, \eta)}{\langle \eta, g \rangle^2}) ,$$

en distribution quand $N \uparrow \infty$, et en particulier pour $\phi \equiv 1$

$$\sqrt{N} \left[\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right] = \sqrt{N} \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma, 1 \rangle} \implies \mathcal{N}(0, \frac{\text{var}(g, \eta)}{\langle \eta, g \rangle^2}) ,$$

en distribution quand $N \uparrow \infty$. On remarque aussi que

$$\langle \mu^N - \mu, \phi \rangle = \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma^N, 1 \rangle} - \langle \mu, \phi \rangle \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma^N, 1 \rangle} = \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \frac{\langle \gamma, 1 \rangle}{\langle \gamma^N, 1 \rangle} .$$

D'après la loi des grands nombres

$$\langle \gamma^N, 1 \rangle = \frac{1}{N} \sum_{i=1}^N g(\xi^i) \longrightarrow \langle \eta, g \rangle = \langle \gamma, 1 \rangle ,$$

en probabilité quand $N \uparrow \infty$, et d'après le lemme de Slutsky

$$\sqrt{N} \langle \mu^N - \mu, \phi \rangle = \frac{\langle \gamma, 1 \rangle}{\langle \gamma^N, 1 \rangle} \sqrt{N} \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \implies \mathcal{N}(0, \frac{\text{var}(g(\phi - \langle \mu, \phi \rangle), \eta)}{\langle \eta, g \rangle^2}) ,$$

en distribution quand $N \uparrow \infty$. On remarque que

$$\langle \eta, g(\phi - \langle \mu, \phi \rangle) \rangle = \langle \eta, g \rangle \langle \mu, \phi - \langle \mu, \phi \rangle \rangle = 0 ,$$

de sorte que

$$\text{var}(g(\phi - \langle \mu, \phi \rangle), \eta) = \langle \eta, g^2 |\phi - \langle \mu, \phi \rangle|^2 \rangle . \quad \square$$

Remarque 9.13 Le principe de l'échantillonnage pondéré est illustré sur la Figure 9.2. On constate en particulier que l'approximation sera d'autant meilleure que la distribution d'importance η (densité a priori) et la fonction d'importance g (vraisemblance) se recouvrent mutuellement, de telle sorte que la fonction d'importance prend des valeurs significatives sur l'échantillon généré. La décomposition d'importance sera au contraire mal-posée si les valeurs significatives de la fonction d'importance sont obtenues dans les queues de la distribution d'importance, auquel cas la fonction d'importance prend des valeurs négligeables sur l'échantillon généré. Un

critère quantitatif pour mesurer le recouvrement mutuel entre la distribution d'importance η et la fonction d'importance g est donné par l'intégrale normalisée (compte tenu que la fonction d'importance est définie à une constante multiplicative près)

$$\int_E \frac{g(x')}{\sup_{x \in E} g(x)} \eta(dx') \quad \text{ou par le rapport inverse} \quad r = \frac{\sup_{x \in E} g(x)}{\langle \eta, g \rangle} .$$




FIGURE 9.1 – Densité a priori, échantillon (en haut) et histogramme associé à l'échantillon (en bas)




FIGURE 9.2 – Densité a priori, fonction de vraisemblance, densité a posteriori, échantillon pondéré (en haut) et histogramme associé à l'échantillon pondéré (en bas)

Pour une décomposition $\mu = g \cdot \eta$ donnée, la variance asymptotique de l'algorithme d'échantillonnage pondéré est inférieure à la variance asymptotique, convenablement normalisée par le nombre total de variable aléatoires simulées, de l'algorithme d'acceptation / rejet. En effet

$$\frac{\langle \eta, g^2 |\phi - \langle \mu, \phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2} \leq \frac{M}{\langle \eta, g \rangle} \frac{\langle \eta, g |\phi - \langle \mu, \phi \rangle|^2 \rangle}{\langle \eta, g \rangle} = \frac{M}{\langle \eta, g \rangle} \text{var}(\phi, \mu) ,$$

où on suppose que $\sup_{x \in E} g(x) \leq M < \infty$.

Aucun de ces deux algorithmes ne nécessite la connaissance de la constante de normalisation $\langle \eta, g \rangle$, mais l'algorithme d'acceptation / rejet utilise quand même de façon explicite une borne supérieure M de la fonction positive g , alors que l'algorithme d'échantillonnage pondéré ne nécessite pas la connaissance d'une telle borne. En revanche, l'algorithme d'acceptation / rejet produit un échantillon de distribution de probabilité μ exactement, alors que l'algorithme d'échantillonnage pondéré produit seulement un échantillon de distribution de probabilité η , pondéré par la fonction positive g et normalisé.

9.3 Échantillonnage et approximation d'un mélange fini

Si la distribution de probabilité η est définie comme un mélange fini de distributions de probabilité $(m_1, \dots, m_M)$ avec les poids positifs $(w_1, \dots, w_M)$, c'est-à-dire si

$$\eta = \sum_{i=1}^M w_i m_i \quad \text{avec} \quad \sum_{i=1}^M w_i = 1 ,$$

et s'il est facile

- de simuler pour tout $i = 1, \dots, M$ une variable aléatoire distribuée selon m_i ,

alors il est facile, en principe, de simuler une variable aléatoire selon la distribution de probabilité η . Il suffit en effet de simuler d'abord une variable aléatoire I à valeurs dans l'ensemble fini $\{1, \dots, M\}$ et distribuée selon les poids $(w_1, \dots, w_M)$, c'est-à-dire $\mathbb{P}[I = i] = w_i$ pour tout $i = 1, \dots, M$, puis de générer une variable aléatoire distribuée selon m_I . La probabilité de sélectionner une composante du mélange sera d'autant plus grande que le poids de cette composante est grand. La question qui reste, et qui sera traitée à la Section 9.4, est donc de savoir simuler une variable aléatoire à valeurs dans l'ensemble fini $\{1, \dots, M\}$.

► **Échantillonnage multinomial** S'il s'agit d'approcher la distribution de probabilité η par un mélange fini de masses de Dirac, ou particules, plusieurs approches sont possibles. On peut simuler un N -échantillon $(\xi_1, \dots, \xi_N)$ distribué selon η , où N n'est pas nécessairement égal au nombre M de composantes du mélange, et

$$S^N(\eta) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_i} . \quad (9.13)$$

Les poids sont ici exploités pour sélectionner (avec remise) les composantes du mélange les mieux loties, avec l'effet attendu que les composantes de plus forts poids seront sélectionnées plusieurs fois, tandis que les composantes de moins forts poids pourront même être éliminées et ne plus être représentées du tout dans l'approximation. Le nombre de fois que la i -ème composante du mélange est sélectionnée, ou de manière équivalente son nombre N_i de représentants dans l'approximation, sera d'autant grand que le poids w_i de cette composante est grand, et on peut montrer que le vecteur aléatoire $(N_1, \dots, N_M)$ suit une loi multinomiale. La question qui reste, et qui sera traitée à la Section 9.4, est donc de savoir simuler un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$, plus efficacement qu'en répétant N fois la simulation d'une seule variable aléatoire.

Intuitivement, si tous les poids sont égaux à (ou proches de) $1/M$, c'est-à-dire si la répartition des poids de mélange est proche de l'équidistribution, alors il est inutile voire même contre-productif de sélectionner les composantes du mélange, avec le risque de favoriser certaines composantes au détriment des autres composantes, alors qu'en principe toutes les composantes ont la même importance.

Théorème 9.14 *La variable aléatoire $\langle S^N(\eta), \phi \rangle$ est un estimateur non-biaisé de $\langle \eta, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\mathbb{E} |\langle S^N(\eta) - \eta, \phi \rangle|^2 = \frac{1}{N} \text{var}(\phi, \eta)$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{\mathbb{E} |\langle S^N(\eta) - \eta, \phi \rangle|^p\}^{1/p} \leq \frac{c_p}{\sqrt{N}} \langle \eta, |\phi - \langle \eta, \phi \rangle|^p \rangle^{1/p},$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.15 Compte tenu que

$$|\phi(x) - \langle \eta, \phi \rangle| \leq \text{osc}(\phi),$$

pour tout $x \in E$, on a également la majoration plus grossière suivante

$$\{\mathbb{E} |\langle S^N(\eta) - \eta, \phi \rangle|^p\}^{1/p} \leq \frac{c_p}{\sqrt{N}} \text{osc}(\phi),$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.16 On remarque que

$$\begin{aligned} \text{var}(\phi, \eta) &= \sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \\ &= \sum_{i=1}^M w_i \text{var}(\phi, m_i) + \underbrace{\left[\sum_{i=1}^M w_i |\langle m_i, \phi \rangle|^2 - \left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \right]}_{W_M}, \end{aligned}$$

où le terme W_M représente la variance des moyennes intra-composantes affectées du poids de chaque composante.

► **Conservation des poids** A l'opposé, on peut décider de conserver les poids et de simuler un représentant pour chaque composante du mélange (ce qui impose que N est nécessairement égal au nombre M de composantes du mélange initial), et poser

$$\eta_M = \sum_{i=1}^M w_i \delta_{\xi_i} , \quad (9.14)$$

où indépendamment pour tout $i = 1, \dots, M$ la variable aléatoire ξ_i est distribuée selon m_i .

Intuitivement, cette seconde approche est certainement pertinente dans le cas où la répartition des poids de mélange est proche de l'équidistribution, mais en revanche peu appropriée dans le cas extrême où presque tous les poids sont nuls sauf quelques uns, c'est-à-dire dans le cas où quelques composantes seulement, voire même une seule composante, sont effectivement présentes dans le mélange.

Théorème 9.17 *La variable aléatoire $\langle \eta_M, \phi \rangle$ est un estimateur non-biaisé de $\langle \eta, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^2 = \left(\sum_{i=1}^M w_i^2 \right) \left[\sum_{i=1}^M w_i^\square \text{var}(\phi, m_i) \right] ,$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{ \mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^p \}^{1/p} \leq c_p \left(\sum_{i=1}^M w_i^2 \right)^{1/2} \left\{ \sum_{i=1}^M w_i^\square \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle \right\}^{1/p} ,$$

pour toute fonction mesurable bornée ϕ , où le vecteur de probabilité $(w_1^\square, \dots, w_M^\square)$ est défini par

$$w_i^\square = w_i^2 / \left[\sum_{j=1}^M w_j^2 \right] \quad \text{pour tout } i = 1, \dots, M.$$

Remarque 9.18 Compte tenu que

$$| \phi(x) - \langle m_i, \phi \rangle | \leq \text{osc}(\phi) ,$$

pour tout $x \in E$ et pour tout $i = 0, 1, \dots, M$, on a également la majoration plus grossière suivante

$$\{ \mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^p \}^{1/p} \leq c_p \left(\sum_{i=1}^M w_i^2 \right)^{1/2} \text{osc}(\phi) ,$$

pour toute fonction mesurable bornée ϕ .

PREUVE. En exploitant l'indépendance des différentes variables aléatoires, on remarque que

$$\begin{aligned} \mathbb{E} |\langle \eta_M - \eta, \phi \rangle|^2 &= \mathbb{E} \left| \sum_{i=1}^M w_i [\phi(\xi^i) - \langle m_i, \phi \rangle] \right|^2 \\ &= \sum_{i=1}^M w_i^2 \mathbb{E} |\phi(\xi^i) - \langle m_i, \phi \rangle|^2 \\ &= \left(\sum_{i=1}^M w_i^2 \right) \left[\sum_{i=1}^M w_i^\square \text{var}(\phi, m_i) \right], \end{aligned}$$

pour toute fonction mesurable bornée ϕ . Plus généralement, pour tout réel $p \geq 2$, il résulte de l'inégalité de Marcinkiewicz–Zygmund (B.2) que

$$\begin{aligned} \mathbb{E} |\langle \eta_M - \eta, \phi \rangle|^p &= \mathbb{E} \left| \sum_{i=1}^M w_i [\phi(\xi^i) - \langle m_i, \phi \rangle] \right|^p \\ &\leq B_p \left(\sum_{i=1}^M w_i^2 \right)^{p/2} \left[\sum_{i=1}^M w_i^\square \mathbb{E} |\phi(\xi^i) - \langle m_i, \phi \rangle|^p \right] \\ &= B_p \left(\sum_{i=1}^M w_i^2 \right)^{p/2} \left[\sum_{i=1}^M w_i^\square \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle \right], \end{aligned}$$

pour toute fonction mesurable bornée ϕ . □

Remarque 9.19 La variance de l'estimateur (9.13) vérifie

$$V_{\text{red}} = \frac{1}{N} \left[\sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \right] \geq \frac{1}{N} \sum_{i=1}^M w_i \text{var}(\phi, m_i),$$

compte tenu que

$$\left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \leq \sum_{i=1}^M w_i |\langle m_i, \phi \rangle|^2,$$

d'après l'inégalité de Jensen, à comparer avec la variance

$$V_{\text{nored}} = \sum_{i=1}^M w_i^2 \text{var}(\phi, m_i),$$

de l'estimateur (9.14). A l'équidistribution, c'est-à-dire si tous les poids sont égaux entre eux (et égaux à $1/M$), alors

$$V_{\text{red}} \geq \frac{1}{M^2} \sum_{i=1}^M \text{var}(\phi, m_i) = V_{\text{nored}},$$

ce qui confirme l'intuition que redistribuer est contre-productif dans ce cas extrême. A l'inverse, si la distribution des poids est complètement dégénérée, c'est-à-dire si tous les poids sont nuls sauf le poids $w_a = 1$ pour la composante a du mélange, alors

$$V_{\text{red}} = \frac{1}{N} [\langle m_a, |\phi|^2 \rangle - |\langle m_a, \phi \rangle|^2] = \frac{1}{N} \text{var}(\phi, m_a) \leq \text{var}(\phi, m_a) = V_{\text{nored}} ,$$

ce qui confirme l'intuition que redistribuer est certainement pertinent dans cet autre cas extrême.

► **Stratification et échantillonnage résiduel multinomial** Sélectionner les composantes du mélange en échantillonnant selon les poids respectifs n'est donc approprié que dans les cas où la répartition des poids de mélange est éloigné de l'équidistribution, mais introduit de toute manière un aléa supplémentaire. Pour limiter cette source d'aléa, on peut par exemple affecter de manière déterministe à chaque composante du mélange un nombre de représentants égal au nombre de fois que le poids $1/N$ est contenu dans le poids w_i de la composante (le poids $1/N$ est celui qui sera affecté à chaque particule dans l'approximation finale). Il reste ensuite à compléter la population de particules de manière à assurer un effectif de taille N , par exemple en simulant un échantillon selon la distribution résiduelle des poids non encore affectés. Concrètement, pour toute composante $i = 1, \dots, M$ le nombre de représentants affectés à l'issue de la première passe est $N_i = \lfloor N w_i \rfloor$, c'est-à-dire que

$$N w_i = N_i + q_i \quad \text{avec} \quad 0 \leq q_i < 1 .$$

Compte tenu des identités

$$N = \sum_{i=1}^M N w_i = \sum_{i=1}^M (N_i + q_i) = \sum_{i=1}^M N_i + N_0 \quad \text{avec} \quad N_0 = \sum_{i=1}^M q_i ,$$

et

$$\eta = \sum_{i=1}^M w_i m_i = \sum_{i=1}^M \frac{N_i}{N} m_i + \sum_{i=1}^M \frac{q_i}{N} m_i = \sum_{i=1}^M \frac{N_i}{N} m_i + \frac{N_0}{N} m_0 ,$$

avec

$$m_0 = \sum_{i=1}^M \frac{q_i}{N_0} m_i ,$$

on déduit que $(N - N_0)$ représentants ont déjà été affectés à l'issue de cette première passe, et il reste donc N_0 représentants à affecter de manière à approcher la distribution de probabilité résiduelle convenablement renormalisée m_0 . L'approximation proposée consiste

- à simuler indépendamment pour tout $i = 1, \dots, M$ un N_i -échantillon $(\xi^{i,1}, \dots, \xi^{i,N_i})$ distribué selon m_i ,
- à simuler un N_0 -échantillon $(\xi^{0,1}, \dots, \xi^{0,N_0})$ distribué selon le mélange fini m_0 ,

toutes les variables aléatoires étant simulées de manière indépendantes, et à poser

$$\eta_N = \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} \delta_{\xi^{i,j}} + \frac{1}{N} \sum_{j=1}^{N_0} \delta_{\xi^{0,j}} , \quad (9.15)$$

c'est-à-dire que

$$\langle \eta_N, \phi \rangle = \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} \phi(\xi^{i,j}) + \frac{1}{N} \sum_{j=1}^{N_0} \phi(\xi^{0,j}) ,$$

et par différence

$$\langle \eta_N - \eta, \phi \rangle = \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} [\phi(\xi^{i,j}) - \langle m_i, \phi \rangle] + \frac{1}{N} \sum_{j=1}^{N_0} [\phi(\xi^{0,j}) - \langle m_0, \phi \rangle] ,$$

pour toute fonction mesurable bornée ϕ .

Théorème 9.20 *La variable aléatoire $\langle \eta_N, \phi \rangle$ est un estimateur non-biaisé de $\langle \eta, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\mathbb{E} |\langle \eta_N - \eta, \phi \rangle|^2 = \frac{1}{N} \left[\sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) \right] ,$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{ \mathbb{E} |\langle \eta_N - \eta, \phi \rangle|^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \left[\sum_{i=1}^M \frac{N_i}{N} \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle + \frac{N_0}{N} \langle m_0, |\phi - \langle m_0, \phi \rangle|^p \rangle \right]^{1/p} ,$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.21 Compte tenu que

$$|\phi(x) - \langle m_i, \phi \rangle| \leq \text{osc}(\phi) ,$$

pour tout $x \in E$ et pour tout $i = 0, 1, \dots, M$, on a également la majoration plus grossière suivante

$$\{ \mathbb{E} |\langle \eta_N - \eta, \phi \rangle|^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \left[\sum_{i=1}^M \frac{N_i}{N} + \frac{N_0}{N} \right]^{1/p} \text{osc}(\phi) \leq \frac{c_p}{\sqrt{N}} \text{osc}(\phi) ,$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.22 On remarque que

$$\text{var}(\phi, m_0) = \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 ,$$

et on rappelle que $N_i = N w_i - q_i$ pour tout $i = 1, \dots, M$, de sorte que

$$\begin{aligned}
& \sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) = \\
&= \sum_{i=1}^M w_i \text{var}(\phi, m_i) - \frac{N_0}{N} \sum_{i=1}^M \frac{q_i}{N_0} [\langle m_i, |\phi|^2 \rangle - |\langle m_i, \phi \rangle|^2] \\
&\quad + \frac{N_0}{N} \left[\sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \right] \\
&= \sum_{i=1}^M w_i \text{var}(\phi, m_i) + \underbrace{\frac{N_0}{N} \left[\sum_{i=1}^M \frac{q_i}{N_0} |\langle m_i, \phi \rangle|^2 - \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \right]}_{W_M},
\end{aligned}$$

où le terme W_M représente la variance des moyennes intra-composantes affectées du poids résiduel de chaque composante.

Remarque 9.23 En regroupant les termes différemment, et compte tenu que $N_i + q_i = N w_i$ pour tout $i = 1, \dots, M$, il vient

$$\begin{aligned}
& \sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) \\
&= \sum_{i=1}^M \frac{N_i}{N} \langle m_i, |\phi|^2 \rangle - \sum_{i=1}^M \frac{N_i}{N} |\langle m_i, \phi \rangle|^2 \\
&\quad + \frac{N_0}{N} \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, |\phi|^2 \rangle - \frac{N_0}{N} \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \\
&= \sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left[\sum_{i=1}^M \frac{N_i}{N} |\langle m_i, \phi \rangle|^2 + \frac{N_0}{N} \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \right],
\end{aligned}$$

tandis que

$$\begin{aligned}
\text{var}(\phi, \eta) &= \sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \\
&= \sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M \frac{N_i}{N} \langle m_i, \phi \rangle + \frac{N_0}{N} \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2.
\end{aligned}$$

D'après l'inégalité de Jensen, on a

$$\left| \sum_{i=1}^M \frac{N_i}{N} \langle m_i, \phi \rangle + \frac{N_0}{N} \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \leq \sum_{i=1}^M \frac{N_i}{N} |\langle m_i, \phi \rangle|^2 + \frac{N_0}{N} \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2,$$

d'où on déduit que

$$\text{var}(\phi, \eta) \geq \sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) ,$$

c'est-à-dire que la variance de l'estimateur (9.15) est inférieure à la variance de l'estimateur (9.13). En d'autres termes, la variance de l'erreur d'estimation pour l'algorithme d'échantillonnage résiduel multinomial est inférieure à la variance de l'erreur d'estimation pour l'algorithme d'échantillonnage multinomial.

PREUVE DU THÉORÈME 9.20. En exploitant l'indépendance des différentes variables aléatoires, on remarque que

$$\begin{aligned} \mathbb{E} | \langle \eta_N - \eta, \phi \rangle |^2 &= \mathbb{E} \left| \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} [\phi(\xi^{i,j}) - \langle m_i, \phi \rangle] + \frac{1}{N} \sum_{j=1}^{N_0} [\phi(\xi^{0,j}) - \langle m_0, \phi \rangle] \right|^2 \\ &= \frac{1}{N^2} \sum_{i=1}^M \sum_{j=1}^{N_i} \mathbb{E} |\phi(\xi^{i,j}) - \langle m_i, \phi \rangle|^2 + \frac{1}{N^2} \sum_{j=1}^{N_0} \mathbb{E} |\phi(\xi^{0,j}) - \langle m_0, \phi \rangle|^2 \\ &= \frac{1}{N} \left[\sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) \right] , \end{aligned}$$

pour toute fonction mesurable bornée ϕ . Plus généralement, pour tout réel $p \geq 2$, il résulte de l'inégalité Marcinkiewicz–Zygmund (B.1) que

$$\begin{aligned} \mathbb{E} | \langle \eta_N - \eta, \phi \rangle |^p &= \mathbb{E} \left| \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} [\phi(\xi^{i,j}) - \langle m_i, \phi \rangle] + \frac{1}{N} \sum_{j=1}^{N_0} [\phi(\xi^{0,j}) - \langle m_0, \phi \rangle] \right|^p \\ &\leq \frac{B_p}{N^{p/2}} \frac{1}{N} \left[\sum_{i=1}^M \sum_{j=1}^{N_i} \mathbb{E} |\phi(\xi^{i,j}) - \langle m_i, \phi \rangle|^p + \sum_{j=1}^{N_0} \mathbb{E} |\phi(\xi^{0,j}) - \langle m_0, \phi \rangle|^p \right] \\ &= \frac{B_p}{N^{p/2}} \left[\sum_{i=1}^M \frac{N_i}{N} \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle + \frac{N_0}{N} \langle m_0, |\phi - \langle m_0, \phi \rangle|^p \rangle \right] , \end{aligned}$$

pour toute fonction mesurable bornée ϕ . □

► **Échantillonnage adaptatif** Étant donné la distribution de probabilité η définie comme un mélange fini

$$\eta = \sum_{i=1}^M w_i m_i \quad \text{avec} \quad \sum_{i=1}^M w_i = 1 ,$$

il n'est véritablement intéressant de sélectionner les composantes du mélange que si les poids $(w_1, \dots, w_M)$ sont très déséquilibrés. Plusieurs critères ont été proposés pour mesurer l'écart à l'équidistribution, et pour décider de conserver les poids ou de les utiliser pour échantillonner selon l'une ou l'autre des implémentations proposées ci-dessus, par exemple la distance du

χ^2 ou la distance de Kullback–Leibler entre deux vecteurs de probabilité $p = (p_1, \dots, p_M)$ et $q = (q_1, \dots, q_M)$, définies par

$$\chi^2(p, q) = \sum_{i=1}^M q_i \left(\frac{p_i}{q_i} - 1 \right)^2 \quad \text{et} \quad K(p, q) = \sum_{i=1}^M p_i \log \frac{p_i}{q_i} ,$$

respectivement.

Distance du χ^2 et taille effective de l'échantillon Un premier critère pour mesurer l'écart entre les poids $(w_1, \dots, w_M)$ et la distribution uniforme, est la distance du χ^2

$$0 \leq \frac{1}{M} \sum_{i=1}^M (M w_i - 1)^2 = \frac{1}{M} \sum_{i=1}^M (M w_i)^2 - 1 = M \sum_{i=1}^M w_i^2 - 1 = \frac{M}{M_{\text{eff}}} - 1 ,$$

où M_{eff} est la taille *effective* de l'échantillon, définie par

$$1 \leq M_{\text{eff}} = 1 / \left[\sum_{i=1}^M w_i^2 \right] \leq M ,$$

et où l'égalité est atteinte à l'équidistribution, ce qui suggère de redistribuer si

$$\frac{M}{M_{\text{eff}}} - 1 \geq \chi_{\text{red}}^2 > 0 \quad \text{c'est-à-dire si} \quad M_{\text{eff}} \leq c_{\text{red}} M ,$$

où le seuil $c_{\text{red}} = 1/(1 + \chi_{\text{red}}^2) < 1$ reste à déterminer.

Distance de Kullback–Leibler et entropie de l'échantillon Un second critère pour mesurer l'écart entre les poids $(w_1, \dots, w_M)$ et la distribution uniforme, est la distance de Kullback–Leibler

$$0 \leq \sum_{i=1}^M w_i \log(M w_i) = \sum_{i=1}^M w_i \log w_i + \log M = -\text{Ent} + \log M ,$$

où Ent est l'entropie de l'échantillon, définie par

$$\text{Ent} = - \sum_{i=1}^M w_i \log w_i \leq \log M ,$$

et où l'égalité est atteinte à l'équidistribution, ce qui suggère de redistribuer si

$$-\text{Ent} + \log M \geq c_{\text{red}} ,$$

où le seuil $c_{\text{red}} > 0$ reste à déterminer.

Remarque 9.24 Les résultats obtenus au Théorème 9.17 pour l'estimateur (9.14) peuvent être ré-interprétés en terme de la taille effective de l'échantillon. En effet

$$\mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^2 = \frac{1}{M_{\text{eff}}} \sum_{i=1}^M w_i^{\square} \text{var}(\phi, m_i) ,$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{\mathbb{E}|\langle \eta_M - \eta, \phi \rangle|^p\}^{1/p} \leq \frac{c_p}{\sqrt{M_{\text{eff}}}} \left\{ \sum_{i=1}^M w_i^\square \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle \right\}^{1/p},$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.25 On peut aussi introduire l'approximation particulière adaptative définie par

$$\eta_M = \begin{cases} \sum_{i=1}^M w_i \delta_{\xi_i} & \text{avec } \xi_i \sim m_i \text{ pour tout } i = 1 \dots M \\ & \text{si } M_{\text{eff}} > c_{\text{red}} M, \\ \frac{1}{M} \sum_{i=1}^M \delta_{\xi_i} & \text{avec } \xi_i \sim \eta \text{ pour tout } i = 1 \dots M \\ & \text{si } M_{\text{eff}} \leq c_{\text{red}} M, \end{cases}$$

avec l'expression suivante pour la variance de l'erreur d'estimation

$$\mathbb{E}|\langle \eta_M - \eta, \phi \rangle|^2 = \begin{cases} \frac{1}{M_{\text{eff}}} \sum_{i=1}^M w_i^\square \text{var}(\phi, m_i) & \text{si } M_{\text{eff}} > c_{\text{red}} M, \\ \frac{1}{M} \text{var}(\phi, \eta) & \text{si } M_{\text{eff}} \leq c_{\text{red}} M. \end{cases}$$

9.4 Échantillonnage selon une distribution à support fini

La question qui reste est donc de savoir simuler une variable aléatoire I à valeurs dans l'ensemble fini $\{1, \dots, M\}$, ou bien de savoir simuler un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$, et on commence par introduire un découpage de l'intervalle $[0, 1]$ en M segments adjacents de longueurs respectives $w_1, \dots, w_M$. Ces M segments sont délimités par les probabilités cumulées

$$s_0 = 0 \quad \text{et} \quad s_i = w_1 + \dots + w_i,$$

pour tout $i = 1, \dots, M$ et on vérifie que $s_M = 1$.

La méthode la plus directe est la méthode d'inversion, qui consiste à générer une variable aléatoire U uniforme sur $[0, 1]$: si U appartient au j -ème segment, i.e. si

$$s_{j-1} < U \leq s_j,$$

alors on pose $I = j$. Une recherche binaire en $O(\log_2 M)$ opérations permet d'obtenir ce résultat, et il suffit donc de $NO(\log_2 M)$ opérations pour générer un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$ et distribué selon les poids $(w_1, \dots, w_M)$.

Au lieu de répéter N fois l'opération de


- générer une variable aléatoire uniforme sur $[0, 1]$,
- puis effectuer une recherche binaire,

on peut penser à générer un N -échantillon $(U_1, \dots, U_N)$ de variables aléatoires uniformes sur $[0, 1]$, puis à ordonner cet échantillon, ce qui nécessite $O(N \log_2 N)$ opérations. On peut alors appliquer la méthode d'inversion à l'échantillon ré-ordonné $U_{(1)} \leq \dots \leq U_{(N)}$: si $U_{(i)}$ appartient au j -ème segment, i.e. si

$$s_{j-1} < U_{(i)} \leq s_j ,$$

alors on pose $I_i = j$. L'avantage de travailler avec un échantillon ordonné est que pour générer I_{i+1} il suffit de tester l'appartenance de $U_{(i+1)}$ aux segments situés au-delà du j -ème segment, et il suffit donc de $M + N$ comparaisons au plus pour affecter les N variables ré-ordonnées aux M différents segments, c'est-à-dire pour interclasser les deux suites ordonnées

$$0 \leq U_{(1)} \leq \dots \leq U_{(N)} \leq 1 \quad \text{et} \quad 0 = s_0 \leq s_1 \leq \dots \leq s_M = 1 .$$



Avec cette méthode, il suffit donc de $O(N \log_2 N) + O(M + N)$ opérations pour générer un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$ et distribué selon les poids $(w_1, \dots, w_M)$.

Une méthode plus efficace, qui évite l'étape préalable de ré-ordonner les variables aléatoires uniformes, consiste à générer directement une N -statistique d'ordre uniforme, c'est-à-dire un vecteur aléatoire $(V_1, \dots, V_N)$ distribué comme le vecteur aléatoire $(U_{(1)}, \dots, U_{(N)})$ obtenu en ré-ordonnant un N -échantillon $(U_1, \dots, U_N)$ de variables aléatoires uniformes sur $[0, 1]$. L'un ou l'autre des deux résultats suivants permet d'effectuer cette tâche en $O(N)$ opérations, et il suffit donc de $O(N) + O(M + N)$ opérations pour générer un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$ et distribué selon les poids $(w_1, \dots, w_M)$.

Proposition 9.26 Soit $(U_1, \dots, U_N)$ un N -échantillon de variables aléatoires uniformes sur $[0, 1]$. On définit

$$V_i = U_N^{1/N} \dots U_i^{1/i} \quad \text{pour tout } i = N, \dots, 1,$$

ou bien par récurrence : $V_N = U_N^{1/N}$ et

$$V_i = V_{i+1} U_i^{1/i} \quad \text{pour tout } i = N - 1, \dots, 1.$$

Le vecteur aléatoire $(V_1, \dots, V_N)$ est distribué comme le vecteur aléatoire $(U_{(1)}, \dots, U_{(N)})$ obtenu en ré-ordonnant $(U_1, \dots, U_N)$.

PREUVE. Clairement, $V_i \leq V_{i+1}$ pour tout $i = 1, \dots, N-1$, c'est-à-dire que la suite

$$V_1 \leq \dots \leq V_i \leq V_{i+1} \leq \dots \leq V_N ,$$

est croissante. On remarque que

$$\mathbb{E}[\phi(V_N)] = \mathbb{E}[\phi(U_N^{1/N})] = \int_0^1 \phi(x^{1/N}) dx = \int_0^1 \phi(v) N v^{N-1} dv ,$$

pour toute fonction mesurable bornée ϕ définie sur l'intervalle $[0, 1]$, de sorte que

$$\mathbb{P}[V_N \in dv] = 1_{(0 \leq v \leq 1)} N v^{N-1} dv .$$

Compte tenu que la variable aléatoire uniforme U_i est indépendante de $(V_{i+1}, \dots, V_N)$, on a

$$\begin{aligned} \mathbb{E}[\phi(V_i) \mid V_{i+1}, \dots, V_N] &= \mathbb{E}[\phi(V_{i+1} U_i^{1/i}) \mid V_{i+1}, \dots, V_N] \\ &= \int_0^1 \phi(V_{i+1} x^{1/i}) \mathbb{P}[U_i \in dx \mid V_{i+1}, \dots, V_N] \\ &= \int_0^1 \phi(V_{i+1} x^{1/i}) dx \\ &= \int_0^1 \phi(v) 1_{(0 \leq v \leq V_{i+1})} \frac{i v^{i-1}}{V_{i+1}^i} dv , \end{aligned}$$

pour toute fonction mesurable bornée ϕ définie sur l'intervalle $[0, 1]$, de sorte que

$$\mathbb{P}[V_i \in dv \mid V_{i+1}, \dots, V_N] = 1_{(0 \leq v \leq V_{i+1})} \frac{i v^{i-1}}{V_{i+1}^i} dv ,$$

pour tout $i = N-1, \dots, 1$. On en déduit que

$$\begin{aligned} \mathbb{P}[V_1 \in dv_1, \dots, V_N \in dv_N] &= \mathbb{P}[V_N \in dv_N] \prod_{i=1}^{N-1} \mathbb{P}[V_i \in dv_i \mid V_{i+1} = v_{i+1}, \dots, V_N = v_N] \\ &= 1_{(0 \leq v_N \leq 1)} N v_N^{N-1} dv_N \prod_{i=1}^{N-1} 1_{(0 \leq v_i \leq v_{i+1})} \frac{i v_i^{i-1}}{v_{i+1}^i} dv_i \\ &= N! 1_{(0 \leq v_1 \leq \dots \leq v_N \leq 1)} dv_1 \dots dv_N . \quad \square \end{aligned}$$

Proposition 9.27 Soit $(E_1, \dots, E_{N+1})$ un $(N+1)$ -échantillon de variables aléatoires exponentielles de paramètre 1 sur $[0, \infty)$. On définit $S_{N+1} = E_1 + \dots + E_{N+1}$ et

$$S_i = E_1 + \dots + E_i \quad \text{et} \quad V_i = \frac{S_i}{S_{N+1}} \quad \text{pour tout } i = 1, \dots, N,$$

ou bien par récurrence : $V_1 = \frac{E_1}{S_{N+1}}$ et

$$V_i = V_{i-1} + \frac{E_i}{S_{N+1}} \quad \text{pour tout } i = 2, \dots, N.$$

Le vecteur aléatoire $(V_1, \dots, V_N)$ est distribué comme le vecteur aléatoire $(U_{(1)}, \dots, U_{(N)})$ obtenu en ré-ordonnant un N -échantillon $(U_1, \dots, U_N)$ de variables aléatoires uniformes sur $[0, 1]$.

PREUVE. Clairement, $V_i \geq V_{i-1}$ pour tout $i = 2, \dots, N$, c'est-à-dire que la suite

$$V_1 \leq \dots \leq V_i \leq V_{i+1} \leq \dots \leq V_N,$$

est croissante. On remarque que $S_1 = E_1$, de sorte que

$$\mathbb{P}[S_1 \in ds] = 1_{(s \geq 0)} e^{-s} ds.$$

Compte tenu que $(S_1, \dots, S_i)$ contient exactement la même information que $(E_1, \dots, E_i)$, et que la variable aléatoire E_{i+1} est indépendante de $(E_1, \dots, E_i)$, on a

$$\begin{aligned} \mathbb{E}[\phi(S_{i+1}) \mid S_1, \dots, S_i] &= \mathbb{E}[\phi(S_i + E_{i+1}) \mid E_1, \dots, E_i] \\ &= \int_0^\infty \phi(S_i + x) \mathbb{P}[E_{i+1} \in dx \mid E_1, \dots, E_i] \\ &= \int_0^\infty \phi(S_i + x) e^{-x} dx \\ &= \int_0^\infty \phi(s) 1_{(s \geq S_i)} e^{-(s-S_i)} ds, \end{aligned}$$

pour toute fonction ϕ mesurable bornée définie sur l'intervalle $[0, \infty)$, de sorte que

$$\mathbb{P}[S_{i+1} \in ds \mid S_1, \dots, S_i] = 1_{(s \geq S_i)} e^{-(s-S_i)} ds,$$

pour tout $i = 1, \dots, N$. On en déduit que

$$\begin{aligned} \mathbb{P}[S_1 \in ds_1, \dots, S_{N+1} \in ds_{N+1}] &= \mathbb{P}[S_1 \in ds_1] \prod_{i=1}^N \mathbb{P}[S_{i+1} \in ds_i \mid S_1 = s_1, \dots, S_i = s_i] \\ &= 1_{(s \geq 0)} e^{-s_1} ds_1 \prod_{i=1}^N 1_{(s_{i+1} \geq s_i)} e^{-(s_{i+1}-s_i)} ds_i \\ &= 1_{(0 \leq s_1 \leq \dots \leq s_{N+1})} e^{-s_{N+1}} ds_1 \dots ds_{N+1}, \end{aligned}$$

et

$$\begin{aligned}
\mathbb{E}[f(V_1, \dots, V_N)] &= \mathbb{E}\left[f\left(\frac{S_1}{S_{N+1}}, \dots, \frac{S_N}{S_{N+1}}\right)\right] \\
&= \int_0^\infty \dots \int_0^\infty f\left(\frac{s_1}{s_{N+1}}, \dots, \frac{s_N}{s_{N+1}}\right) \mathbb{P}[S_1 \in ds_1, \dots, S_{N+1} \in ds_{N+1}] \\
&= \int_0^\infty \dots \int_0^\infty f\left(\frac{s_1}{s_{N+1}}, \dots, \frac{s_N}{s_{N+1}}\right) 1_{(0 \leq s_1 \leq \dots \leq s_N \leq s_{N+1})} e^{-s_{N+1}} ds_1 \dots ds_N ds_{N+1} \\
&= \int_0^\infty \dots \int_0^\infty f(v_1, \dots, v_N) 1_{(0 \leq v_1 \leq \dots \leq v_N \leq 1)} s_{N+1}^N e^{-s_{N+1}} dv_1 \dots dv_N ds_{N+1} \\
&= \int_0^\infty \dots \int_0^\infty f(v_1, \dots, v_N) 1_{(0 \leq v_1 \leq \dots \leq v_N \leq 1)} dv_1 \dots dv_N \int_0^\infty s_{N+1}^N e^{-s_{N+1}} ds_{N+1} \\
&= \int_0^\infty \dots \int_0^\infty f(v_1, \dots, v_N) N! 1_{(0 \leq v_1 \leq \dots \leq v_N \leq 1)} dv_1 \dots dv_N,
\end{aligned}$$

pour toute fonction f mesurable bornée définie sur l'ensemble produit $[0, \infty)^N$, compte tenu que

$$\int_0^\infty s^N e^{-s} ds = N!.$$

On en déduit que

$$\mathbb{P}[V_1 \in dv_1, \dots, V_N \in dv_N] = N! 1_{(0 \leq v_1 \leq \dots \leq v_N)} dv_1 \dots dv_N. \quad \square$$

