

École Nationale Supérieure de Techniques Avancées
Domaine : Mathématiques et leurs Applications

cours SOD333
Filtrage Bayésien
et Approximation Particulaire

version provisoire du 16 septembre 2021

François Le Gland
INRIA Rennes et IRMAR

http://people.rennes.inria.fr/Francois.Le_Gland/ensta/

Objectif du cours

Le filtrage consiste à estimer de façon récursive un état caché au vu d'observations. Le domaine d'application principal est la localisation, la navigation et la poursuite de mobiles, dans le domaine militaire, mais aussi en robotique mobile, en vision par ordinateur, où il s'agit de combiner : un modèle a priori de déplacement du mobile, des mesures issues de capteurs, et éventuellement une base de mesures de références, disponibles par exemples sous la forme d'une carte numérique (modèle numérique de terrain, carte de couverture, etc.).

Le problème de filtrage possède une solution explicite, appelée filtre de Kalman, dans le cas particulier des systèmes linéaires gaussiens. Dans le cas plus général des modèles de Markov cachés, des méthodes de simulations efficaces sont apparues récemment, sous le nom de filtrage particulaire. L'objectif de ce cours est de présenter différents algorithmes de filtrage particulaire, de les mettre en œuvre dans le cadre de travaux pratiques, et de démontrer quelques résultats de convergence en utilisant le cadre très général de l'approximation particulaire des distributions de Feynman–Kac.

Table des matières

1	Introduction	1
1.1	Importance de l'information a priori	1
1.2	Estimation bayésienne	4
1.3	Cadre gaussien	9
2	Exemples	15
2.1	Recalage altimétrique de navigation inertielle	15
2.2	Suivi visuel par histogramme de couleur	19
2.3	Poursuite d'une cible furtive (track-before-detect)	22
2.4	Navigation en environnement intérieur	24
3	Filtrage de Kalman	29
3.1	Systèmes linéaires gaussiens	29
3.2	Filtre de Kalman	31
3.3	Lisseur de Kalman	36
4	Extensions aux systèmes non-linéaires	45
4.1	Filtre de Kalman linéarisé, filtre de Kalman étendu	46
4.2	Filtre de Kalman <i>unscented</i>	48
5	Au-delà des systèmes linéaires gaussiens	55
5.1	Systèmes non-linéaires à bruits non-gaussiens	55
5.2	Modèles de Markov cachés	58
5.3	Chaînes de Markov à paramètres markoviens	60
5.4	Chaînes de Markov partiellement observées	62
6	Borne de Cramér-Rao a posteriori	67

7 Filtrage bayésien	75
7.1 Modèles de Markov cachés	75
7.2 Chaînes de Markov partiellement observées	80
8 Généralisation : distributions de Feynman–Kac	87
8.1 Modèle de base	87
8.2 Modèle (apparamment) plus général	90
8.3 Modèle à valeurs transitions ou trajectoires	95
9 Méthodes de Monte Carlo	103
9.1 Échantillonnage pondéré	105
9.2 Simulation selon une distribution de Gibbs–Boltzmann	108
9.3 Échantillonnage et approximation d’un mélange fini	120
9.4 Échantillonnage selon une loi discrète	129
10 Approximations particulières	135
10.1 Échantillonnage pondéré (SIS)	135
10.2 Échantillonnage / ré-échantillonnage (SIR)	139
11 Estimation d’erreur	155
11.1 Probabilité d’extinction	157
11.2 Estimation d’erreur dans $\mathbb{L}^p$	162
12 TCL pour les approximations particulières	165
12.1 Échantillonnage pondéré (SIS)	165
12.2 Échantillonnage / ré-échantillonnage (SIR)	166
A Inversion matricielle	177
B Inégalités	181
C Théorème central limite conditionnel	187
C.1 Variables aléatoires indépendantes identiquement distribuées	191
C.2 Suites triangulaires de variables aléatoires indépendantes	192
C.3 Version conditionnelle	195

Chapitre 1

Introduction

En toute généralité, le filtrage consiste à estimer l'état d'un système dynamique, c'est-à-dire évoluant au cours du temps, à partir d'observations partielles, généralement bruitées.

Typiquement, on dispose d'une suite $Y_0, Y_1, \dots, Y_n$ d'observations, par exemple obtenues après traitement préalable du signal recueilli au niveau des capteurs. Chaque observation Y_n est reliée à l'état inconnu X_n par une relation du type

$$Y_n = h_n(X_n) + V_n, \quad (1.1)$$

où V_n est un *bruit*, qui modélise l'erreur d'observation. On précisera plus loin dans ce cours la notion de *bruit*, en terme de variables aléatoires le plus souvent centrées (de moyenne nulle).

1.1 Importance de l'information a priori

Une hypothèse assez commune est de supposer que les variables aléatoires $V_0, V_1, \dots, V_n$ sont indépendantes entre elles. A cause de cette hypothèse d'indépendance mutuelle des bruits d'observation, et a fortiori en absence de bruit, seule l'observation Y_n participe à l'estimation de l'état caché X_n , c'est-à-dire qu'on se trouve confronté à une succession de problèmes d'estimation découplés : dans la relation (1.1), l'observation Y_n est disponible (par définition) tandis que ni l'état caché X_n ni le bruit V_n ne sont disponibles, et il faut arriver à retrouver (estimer) l'état caché X_n au vu de l'observation Y_n et malgré la présence du bruit V_n .

Tel qu'il est formulé, le problème de l'estimation de l'état caché X_n à partir des observations $Y_0, Y_1, \dots, Y_n$ est en général mal-posé :

- en général, la dimension m de la variable cachée est plus grande que la dimension d de l'observation : même en absence de bruit, on ne peut pas inverser la relation (1.1) qui possède plus d'inconnues que d'équations,
- dans le cas favorable où $m = d$, et même en absence de bruit, il n'est pas toujours possible d'inverser la relation (1.1) qui peut très bien posséder plusieurs solutions distinctes,

- la situation est évidemment encore plus compliquée en présence de bruit : à cause du phénomène de découplage cité plus haut, la suite $X_0, X_1, \dots, X_n$ reconstituée peut ne pas être pertinente en tant que trajectoire, même si chacune des estimations est pertinente séparément.

Pour lever l'indétermination, c'est-à-dire pour garantir l'existence d'une solution unique, et pour résoudre le problème de cohérence temporelle, la solution classique consiste à utiliser des informations supplémentaires sur la suite cachée, par exemple sous la forme de fonctions de coût portant sur l'état initial ou sur les transitions entre deux états successifs. Par exemple, on cherchera à minimiser le critère

$$J(x_{0:n}) = c_0(x_0) + \sum_{k=1}^n c_k(x_{k-1}, x_k) + \sum_{k=0}^n d_k(x_k) ,$$

par rapport à la suite $x_{0:n} = (x_0, x_1, \dots, x_n)$, qui combine des fonctions de coût représentant l'information *a priori* sur la solution avec des fonctions de coût d'une autre nature, qui peuvent représenter par exemple un terme d'*attache aux données*, de la forme

$$h_k(x) = \frac{1}{2} |Y_k - h_k(x)|^2 \quad \text{ou bien} \quad h_k(x) = \frac{1}{2} (Y_k - h_k(x))^* I_k (Y_k - h_k(x)) ,$$

pour tout $k = 0, 1, \dots, n$, avec l'interprétation que la suite recherchée doit également vérifier à chaque instant l'équation d'observation en un sens approché. Plus généralement, ces fonctions de coût peuvent juste représenter une contrainte (ou une propriété) que la suite recherchée devrait vérifier (ou posséder). En absence d'information *a priori*, le critère se réduit simplement à

$$J(x_{0:n}) = \frac{1}{2} \sum_{k=0}^n |Y_k - h_k(x_k)|^2 \quad \text{ou bien} \quad J(x_{0:n}) = \frac{1}{2} \sum_{k=0}^n (Y_k - h_k(x_k))^* I_k (Y_k - h_k(x_k)) ,$$

ce qui revient en absence de couplage à minimiser séparément le critère

$$\frac{1}{2} |Y_k - h_k(x_k)|^2 \quad \text{ou bien} \quad \frac{1}{2} (Y_k - h_k(x_k))^* R_k^{-1} (Y_k - h_k(x_k)) ,$$

par rapport à l'état x_k , pour tout $k = 0, 1, \dots, n$, avec les conséquences déjà évoquées en terme d'indétermination et de possible incohérence temporelle. Un exemple classique de fonctions de coût représentant l'information *a priori* est

$$c_0(x) = \frac{1}{2} |x - \mu|^2 \quad \text{ou bien} \quad c_0(x) = \frac{1}{2} (x - \mu)^* \Sigma_0^{-1} (x - \mu) ,$$

avec l'interprétation que l'état initial x_0 recherché doit être proche de μ , et

$$c_k(x, x') = \frac{1}{2} |x' - f_k(x)|^2 \quad \text{ou bien} \quad c_k(x, x') = \frac{1}{2} (x' - f_k(x))^* Q_k^{-1} (x' - f_k(x)) ,$$

avec l'interprétation que l'état x_k recherché doit être proche de $f_k(x_{k-1})$, ou de manière équivalente que la transition (x_{k-1}, x_k) recherchée doit vérifier l'équation $x_k = f_k(x_{k-1})$ dans un sens approché, pour tout $k = 1, \dots, n$. On remarque que ces fonctions de coût sont (à une constante additive près) de la forme

$$c_0(x) = -\log p_0(x) \quad \text{et} \quad c_k(x, x') = -\log p_k(x' | x) , \quad (1.2)$$

pour tout $k = 1, \dots, n$, où $p_0(x)$ est la densité de probabilité initiale, et où $p_k(x' | x)$ est la densité de probabilité de transition, dans le modèle non-linéaire suivant avec bruits gaussiens additifs

$$X_k = f_k(X_{k-1}) + W_k \quad \text{avec} \quad W_k \sim \mathcal{N}(0, Q_k) ,$$

et avec condition initiale $X_0 \sim \mathcal{N}(\mu, \Sigma)$. En effet (à une constante mutiplicative de normalisation près)

$$\mathbb{P}[X_0 \in dx] \propto \exp\{-\frac{1}{2} (x - \mu)^* \Sigma_0^{-1} (x - \mu)\} dx \propto p_0(x) dx ,$$

et

$$\mathbb{P}[X_k \in dx' | X_{k-1} = x] \propto \exp\{-\frac{1}{2} (x' - f_k(x))^* Q_k^{-1} (x' - f_k(x))\} dx' \propto p_k(x' | x) dx' ,$$

pour tout $k = 1, \dots, n$. En toute généralité, si les relations (1.2) sont vérifiées pour une densité de probabilité $p_0(x)$ et pour des densités de probabilité de transition $p_k(x' | x)$, pour tout $k = 1, \dots, n$, alors le critère à minimiser peut s'écrire

$$J(x_{0:n}) = -\log p_0(x_0) - \sum_{k=1}^n \log p_k(x_k | x_{k-1}) + \sum_{k=0}^n d_k(x_k) ,$$

ce qui revient à maximiser

$$\exp\{-J(x_{0:n})\} = \underbrace{p_0(x_0) \prod_{k=1}^n p_k(x_k | x_{k-1})}_{p_{0:n}(x_{0:n})} \exp\{-\sum_{k=0}^n d_k(x_k)\} ,$$

par rapport à la suite $x_{0:n} = (x_0, x_1, \dots, x_n)$. On remarque que $p_{0:n}(x_{0:n})$ représente la densité de probabilité conjointe des états successifs $(X_0, X_1, \dots, X_n)$ de la chaîne de Markov caractérisée par

- la densité de probabilité initiale $p_0(x_0)$,
- et les densités de probabilité de transition $p_k(x' | x)$, pour tout $k = 1, \dots, n$.

Comme alternative au point de vue de l'optimisation déterministe développé jusqu'ici, on adoptera dans ce cours un point de vue d'estimation bayésienne, c'est-à-dire qu'on remplacera le problème de minimisation déterministe, avec prise en compte de l'information *a priori* en terme de fonctions de coût, par le problème du calcul de la distribution de Gibbs-Boltzmann définie (à une constante multiplicative près) sur l'espace des trajectoires $E_n = E \times \dots \times E$ par

$$\exp\{-J(x_{0:n})\} dx_{0:n} = \underbrace{p_0(x_0) \prod_{k=1}^n p_k(x_k | x_{k-1})}_{p_{0:n}(x_{0:n})} \exp\{-\sum_{k=0}^n d_k(x_k)\} dx_{0:n} . \quad (1.3)$$

En d'autres termes, on remplacera le problème de calculer le mode, c'est-à-dire la trajectoire $x_{0:n} = (x_0, x_1, \dots, x_n)$ de plus forte densité, par le problème de calculer des espérances (ou des

intégrales) du type

$$\begin{aligned} \int_E \cdots \int_E f(x_{0:n}) \exp\{-J(x_{0:n})\} dx_{0:n} &= \int_E \cdots \int_E f(x_{0:n}) \exp\left\{-\sum_{k=0}^n d_k(x_k)\right\} p_{0:n}(x_{0:n}) dx_{0:n} \\ &= \mathbb{E}[f(X_{0:n}) \exp\left\{-\sum_{k=0}^n d_k(X_k)\right\}] , \end{aligned}$$

pour des fonctions-test f définies sur l'espace des trajectoires $E_n = E \times \cdots \times E$. Dans la pratique, on verra comment résoudre ce problème de manière approchée, en simulant des échantillons de variables aléatoires distribuées (approximativement) selon la distribution de Gibbs–Boltzmann trajectorielle définie (à une constante multiplicative près) par (1.3).

1.2 Estimation bayésienne

Dans de nombreux cas, la prise en compte de l'information a priori peut se ramener au problème statique suivant : étant donnés deux vecteurs aléatoires X et Y , qu'apporte le fait d'observer la réalisation $Y = y$ sur la connaissance que l'on a de X ?

Soit X et Y deux variables aléatoires à valeurs dans E et dans F respectivement, et soit ϕ une application mesurable définie sur E à valeurs dans $\mathbb{R}^p$. Par définition, un *estimateur* de $\phi(X)$ à partir de l'observation de Y est un vecteur aléatoire $\psi(Y)$, où ψ est une application mesurable définie sur F à valeurs dans $\mathbb{R}^p$ (par abus de notation, la variable aléatoire $\psi(Y)$ sera également notée ψ).

► **Estimateur MMSE** Soit ψ un estimateur de $\phi(X)$ sachant Y . Naturellement $\psi = \psi(Y)$ n'est pas égal à $\phi(X)$: une mesure de l'écart entre l'estimateur et la vraie valeur est fournie par la matrice (de dimension $p \times p$) de corrélation d'erreur

$$\mathbb{E}[(\psi(Y) - \phi(X))(\psi(Y) - \phi(X))^*] , \quad (1.4)$$

dont la trace

$$\text{trace } \mathbb{E}[(\psi(Y) - \phi(X))(\psi(Y) - \phi(X))^*] = \mathbb{E}|\psi(Y) - \phi(X)|^2 ,$$

est l'erreur quadratique moyenne. L'estimateur du minimum d'erreur quadratique moyenne (MMSE, pour *minimum mean-square error*) de $\phi(X)$ sachant Y est un estimateur $\hat{\phi}$ tel que

$$\mathbb{E}[(\hat{\phi}(Y) - \phi(X))(\hat{\phi}(Y) - \phi(X))^*] \leq \mathbb{E}[(\psi(Y) - \phi(X))(\psi(Y) - \phi(X))^*] ,$$

au sens des matrices symétriques, pour tout autre estimateur ψ .

La Proposition 1.1 ci-dessous montre que cet estimateur est obtenu à l'aide de la distribution de probabilité conditionnelle de X sachant $Y = y$, définie à partir de la distribution de probabilité jointe de (X, Y) par la décomposition

$$\mathbb{P}[X \in dx, Y \in dy] = \mathbb{P}[X \in dx | Y = y] \mathbb{P}[Y \in dy] . \quad (1.5)$$

Proposition 1.1 *Soit X et Y deux variables aléatoires à valeurs dans E et F respectivement, et soit ϕ une application mesurable définie sur E à valeurs dans $\mathbb{R}^p$. L'estimateur MMSE de $\phi(X)$ sachant Y est la moyenne conditionnelle de $\phi(X)$ sachant Y , i.e.*

$$\widehat{\phi}(y) = \mathbb{E}[\phi(X) \mid Y = y] = \int_E \phi(x) \mathbb{P}[X \in dx \mid Y = y] .$$

PREUVE. Pour tout estimateur ψ , la décomposition

$$\psi(Y) - \phi(X) = \widehat{\phi}(Y) - \phi(X) + \psi(Y) - \widehat{\phi}(Y) ,$$

entraîne

$$\begin{aligned} \mathbb{E}[(\psi(Y) - \phi(X))(\psi(Y) - \phi(X))^*] &= \\ &= \mathbb{E}[(\widehat{\phi}(Y) - \phi(X))(\widehat{\phi}(Y) - \phi(X))^*] + \mathbb{E}[(\psi(Y) - \widehat{\phi}(Y))(\psi(Y) - \widehat{\phi}(Y))^*] \\ &\quad + \mathbb{E}[(\psi(Y) - \widehat{\phi}(Y))(\widehat{\phi}(Y) - \phi(X))^*] + \mathbb{E}[(\widehat{\phi}(Y) - \phi(X))(\psi(Y) - \widehat{\phi}(Y))^*] , \end{aligned}$$

et on remarque que

$$\begin{aligned} \mathbb{E}[(\psi(Y) - \widehat{\phi}(Y))(\widehat{\phi}(Y) - \phi(X))^*] &= \\ &= \int_E \int_F (\psi(y) - \widehat{\phi}(y))(\widehat{\phi}(y) - \phi(x))^* \mathbb{P}[X \in dx, Y \in dy] \\ &= \int_E \int_F (\psi(y) - \widehat{\phi}(y))(\widehat{\phi}(y) - \phi(x))^* \mathbb{P}[X \in dx \mid Y = y] \mathbb{P}[Y \in dy] \\ &= \int_F (\psi(y) - \widehat{\phi}(y))^* \left\{ \int_E (\widehat{\phi}(y) - \phi(x)) \mathbb{P}[X \in dx \mid Y = y] \right\} \mathbb{P}[Y \in dy] = 0 , \end{aligned}$$

par définition de $\widehat{\phi}(y)$. On a donc

$$\begin{aligned} \mathbb{E}[(\psi(Y) - \phi(X))(\psi(Y) - \phi(X))^*] &= \\ &= \mathbb{E}[(\widehat{\phi}(Y) - \phi(X))(\widehat{\phi}(Y) - \phi(X))^*] + \mathbb{E}[(\psi(Y) - \widehat{\phi}(Y))(\psi(Y) - \widehat{\phi}(Y))^*] \\ &\geq \mathbb{E}[(\widehat{\phi}(Y) - \phi(X))(\widehat{\phi}(Y) - \phi(X))^*] , \end{aligned}$$

au sens des matrices symétriques, avec égalité pour $\psi = \widehat{\phi}$. □

Remarque 1.2 Compte tenu que le vecteur aléatoire $(\widehat{\phi}(Y) - \phi(X))$ est centré, la matrice de corrélation d'erreur est aussi la matrice de covariance d'erreur, dans le cas particulier de l'estimateur $\widehat{\phi}$.

► **Borne de Cramér–Rao a posteriori** On suppose à présent que $E = \mathbb{R}^m$, c'est-à-dire que X et Y sont des variables aléatoires à valeurs dans $\mathbb{R}^m$ et F respectivement, et soit ϕ une application mesurable définie sur $\mathbb{R}^m$ à valeurs dans $\mathbb{R}^p$. Le biais de l'estimateur ψ de $\phi(X)$ sachant Y est défini par

$$b(\psi, x) = \mathbb{E}[\psi(Y) \mid X = x] - \phi(x) .$$

On suppose que la distribution de probabilité jointe des vecteurs aléatoires X et Y possède une densité

$$\mathbb{P}[X \in dx, Y \in dy] = p(x, y) \, dx \, \lambda(dy) ,$$

sur $\mathbb{R}^m \times F$, suffisamment régulière par rapport à la variable $x \in \mathbb{R}^m$, avec les deux factorisations alternatives

$$p(x, y) = p(x \mid y) p(y) = p(y \mid x) p(x) ,$$

en termes de distributions de probabilités conditionnelles et marginales, et en particulier

$$\mathbb{P}[X \in dx] = p(x) \, dx \quad \text{avec} \quad p(x) = \int_F p(x, y) \, \lambda(dy) .$$

On suppose que

$$\int_{\mathbb{R}^m} \int_F \frac{\partial^2}{\partial x^2} p(x, y) \, \lambda(dy) \, dx = \int_{\mathbb{R}^m} \left\{ \frac{\partial^2}{\partial x^2} \int_F p(x, y) \, \lambda(dy) \right\} \, dx = \int_{\mathbb{R}^m} p''(x) \, dx = 0 . \quad (1.6)$$

Remarque 1.3 En utilisant l'identité

$$\frac{\partial^2}{\partial x^2} \log p(x, y) = \frac{1}{p(x, y)} \frac{\partial^2}{\partial x^2} p(x, y) - \left(\frac{\partial}{\partial x} \log p(x, y) \right)^* \frac{\partial}{\partial x} \log p(x, y) ,$$

entre matrices de dimension $m \times m$, et en intégrant membre à membre par rapport à la distribution de probabilité jointe $p(x, y) \, dx \, \lambda(dy)$ du couple (X, Y) , il vient

$$\mathbb{E} \left[\left(\frac{\partial}{\partial x} \log p(X, Y) \right)^* \frac{\partial}{\partial x} \log p(X, Y) \right] = \int_{\mathbb{R}^m} \int_F \frac{\partial^2}{\partial x^2} p(x, y) \, \lambda(dy) \, dx - \mathbb{E} \left[\frac{\partial^2}{\partial x^2} \log p(X, Y) \right] ,$$

et sous l'hypothèse (1.6) on a donc

$$-\mathbb{E} \left[\frac{\partial^2}{\partial x^2} \log p(X, Y) \right] = \mathbb{E} \left[\left(\frac{\partial}{\partial x} \log p(X, Y) \right)^* \frac{\partial}{\partial x} \log p(X, Y) \right] .$$

On en déduit que la matrice symétrique qui apparait dans le membre de gauche est semi-définie positive.

Proposition 1.4 Si la matrice d'information de Fisher (de dimension $m \times m$) définie par

$$J = -\mathbb{E} \left[\frac{\partial^2}{\partial x^2} \log p(X, Y) \right] ,$$

est inversible, alors la matrice de corrélation de l'erreur d'estimation est minorée (au sens des matrices symétriques) par la relation suivante

$$C = \mathbb{E} [(\psi(Y) - \phi(X)) (\psi(Y) - \phi(X))^*] \geq M J^{-1} M^* .$$

avec la matrice de sensibilité (de dimension $p \times m$) définie par

$$M = \mathbb{E}[\phi'(X)] ,$$

pour tout estimateur ψ de $\phi(X)$ sachant Y tel que

$$\int_{\mathbb{R}^m} (b(\psi, x) p(x))' dx = 0 . \quad (1.7)$$

Remarque 1.5 La matrice d'information de Fisher J et la matrice de sensibilité M qui interviennent dans l'expression de la borne ne dépendent pas de l'estimateur ψ .

PREUVE. Par définition

$$b(\psi, x) p(x) = \int_F (\psi(y) - \phi(x)) p(y | x) p(x) \lambda(dy) = \int_F (\psi(y) - \phi(x)) p(x, y) \lambda(dy) ,$$

et la matrice jacobienne (de dimension $p \times m$) associée vérifie

$$\begin{aligned} (b(\psi, x) p(x))' &= -\phi'(x) \int_F p(x, y) \lambda(dy) + \int_F (\psi(y) - \phi(x)) \frac{\partial}{\partial x} p(x, y) \lambda(dy) \\ &= -\phi'(x) p(x) + \int_F (\psi(y) - \phi(x)) \frac{\partial}{\partial x} \log p(x, y) p(x, y) \lambda(dy) . \end{aligned}$$

En intégrant par rapport à la variable $x \in \mathbb{R}^m$, il vient

$$\begin{aligned} &\int_{\mathbb{R}^m} (b(\psi, x) p(x))' dx \\ &= - \int_{\mathbb{R}^m} \phi'(x) p(x) dx + \int_{\mathbb{R}^m} \int_F (\psi(y) - \phi(x)) \frac{\partial}{\partial x} \log p(x, y) p(x, y) \lambda(dy) dx \\ &= -\mathbb{E}[\phi'(X)] + \mathbb{E}[(\psi(Y) - \phi(X)) \frac{\partial}{\partial x} \log p(X, Y)] , \end{aligned}$$

et si la condition (1.7) est vérifiée, alors

$$\mathbb{E}[(\psi(Y) - \phi(X)) \frac{\partial}{\partial x} \log p(X, Y)] = M ,$$

où la matrice de sensibilité M ne dépend pas de ψ . D'autre part, il résulte de la Remarque 1.3 que

$$J = -\mathbb{E}[\frac{\partial^2}{\partial x^2} \log p(X, Y)] = \mathbb{E}[(\frac{\partial}{\partial x} \log p(X, Y))^* \frac{\partial}{\partial x} \log p(X, Y)] .$$

On introduit ensuite le vecteur aléatoire (de dimension $p + m$)

$$\begin{pmatrix} \psi(Y) - \phi(X) \\ (\frac{\partial}{\partial x} \log p(X, Y))^* \end{pmatrix} \quad \text{et sa matrice de corrélation} \quad \begin{pmatrix} C & M \\ M^* & J \end{pmatrix} .$$

Compte tenu que cette matrice est symétrique semi-définie positive, il résulte du Lemme A.3 d'inversion matricielle que le complément de Schur $\Delta = C - M J^{-1} M^*$ est également une matrice semi-définie positive, c'est-à-dire que

$$C \geq M J^{-1} M^* . \quad \square$$

Remarque 1.6 Par définition de l'estimateur MMSE, on a nécessairement

$$\mathbb{E}[(\psi(Y) - \phi(X))(\psi(Y) - \phi(X))^*] \geq \mathbb{E}[(\hat{\phi}(Y) - \phi(X))(\hat{\phi}(Y) - \phi(X))^*] \geq M J^{-1} M^* ,$$

pour tout estimateur ψ , et la borne la plus à gauche est atteinte pour $\psi = \hat{\phi}$. La borne donnée par l'estimateur MMSE est donc plus fine que la borne de Cramér-Rao a posteriori, mais aussi plus difficile à calculer : le plus souvent en effet on ne dispose pas de l'expression de l'estimateur MMSE, mais l'expression des matrices J et M est assez facile à obtenir. La borne de Cramér-Rao a posteriori peut même être assez grossière et atteinte par aucun estimateur, et on déduit de l'encadrement ci-dessus que si la borne de Cramér-Rao a posteriori est atteinte, alors elle est nécessairement atteinte pour l'estimateur MMSE $\psi = \hat{\phi}$.

Exemple 1.7 Soit X et V deux vecteurs aléatoires gaussiens indépendants, de moyenne $\bar{X}$ et 0, et de matrice de covariance Q_X et Q_V , respectivement, et on pose $Y = h(X) + V$. Si les matrices de covariance Q_X et Q_V sont inversibles, alors on a

$$p(y | x) \propto \exp\{-\frac{1}{2}(y - h(x))^* Q_V^{-1}(y - h(x))\} ,$$

et

$$p(x) \propto \exp\{-\frac{1}{2}(x - \bar{X})^* Q_X^{-1}(x - \bar{X})\} ,$$

de sorte que

$$\begin{aligned} -\log p(x, y) &= -\log p(y | x) - \log p(x) \\ &= \frac{1}{2}(y - h(x))^* Q_V^{-1}(y - h(x)) + \frac{1}{2}(x - \bar{X})^* Q_X^{-1}(x - \bar{X}) + \text{cste} , \end{aligned}$$

et

$$-\frac{\partial^2}{\partial x^2} \log p(x, y) = (h'(x))^* Q_V^{-1} h'(x) - (y - h(x))^* Q_V^{-1} h''(x) + Q_X^{-1} ,$$

d'où l'expression de la matrice d'information de Fisher

$$\begin{aligned} J &= -\mathbb{E}\left[\frac{\partial^2}{\partial x^2} \log p(X, Y)\right] = \mathbb{E}[(h'(X))^* Q_V^{-1} h'(X)] - \mathbb{E}[V^* Q_V^{-1} h''(X)] + Q_X^{-1} \\ &= \mathbb{E}[(h'(X))^* Q_V^{-1} h'(X)] + Q_X^{-1} , \end{aligned}$$

compte tenu que

$$\mathbb{E}[V^* Q_V^{-1} h''(X)] = 0 .$$

Dans le cas particulier où l'application $h(x) = H x$ est linéaire, on obtient

$$J = H^* Q_V^{-1} H + Q_X^{-1} \quad \text{et} \quad J^{-1} = Q_X - Q_X H^* (H Q_X H^* + Q_V)^{-1} H Q_X ,$$

d'après le Lemme A.1 d'inversion matricielle.

1.3 Cadre gaussien

Dans le cas particulier des vecteurs aléatoires gaussiens, le résultat général obtenu ci-dessus peut être précisé de la façon suivante.

Proposition 1.8 *Soit $Z = (X, Y)$ un vecteur aléatoire gaussien de dimension $m + d$, de moyenne et de matrice de covariance*

$$\bar{Z} = \begin{pmatrix} \bar{X} \\ \bar{Y} \end{pmatrix} \quad \text{et} \quad Q_Z = \begin{pmatrix} Q_X & Q_{XY} \\ Q_{YX} & Q_Y \end{pmatrix},$$

respectivement. Si la matrice Q_Y est inversible, alors la distribution de probabilité conditionnelle du vecteur aléatoire X sachant $Y = y$, est une distribution de probabilité gaussienne de moyenne

$$\hat{X}(y) = \bar{X} + Q_{XY} Q_Y^{-1} (y - \bar{Y}),$$

et de matrice de covariance

$$R = Q_X - Q_{XY} Q_Y^{-1} Q_{YX},$$

complément de Schur de la matrice Q_Y dans la matrice-bloc Q_Z .

Remarque 1.9 Pour simuler un vecteur aléatoire gaussien de dimension m , de moyenne $\hat{X}(y)$ et de matrice de covariance R , il suffit de simuler un vecteur aléatoire gaussien $Z' = (X', Y')$ de dimension $m + d$, de même moyenne et de même matrice de covariance que $Z = (X, Y)$, et de poser

$$\xi(y) = X' + Q_{XY} Q_Y^{-1} (y - Y').$$

On vérifie en effet que le vecteur aléatoire $\xi(y)$ ainsi défini est gaussien, comme transformation affine du vecteur aléatoire gaussien Z' , de moyenne

$$\mathbb{E}[\xi(y)] = \mathbb{E}[X'] + Q_{XY} Q_Y^{-1} (y - \mathbb{E}[Y']) = \bar{X} + Q_{XY} Q_Y^{-1} (y - \bar{Y}) = \hat{X}(y),$$

et de matrice de covariance

$$\begin{aligned} & \mathbb{E}[(\xi(y) - \hat{X}(y)) (\xi(y) - \hat{X}(y))^*] \\ &= \mathbb{E}[(X' - \bar{X}) - Q_{XY} Q_Y^{-1} (Y' - \bar{Y}) ((X' - \bar{X}) - Q_{XY} Q_Y^{-1} (Y' - \bar{Y}))^*] \\ &= \mathbb{E}[(X' - \bar{X}) (X' - \bar{X})^*] - \mathbb{E}[(X' - \bar{X}) (Y' - \bar{Y})^*] Q_Y^{-1} Q_{YX} \\ & \quad - Q_{XY} Q_Y^{-1} \mathbb{E}[(Y' - \bar{Y}) (X' - \bar{X})^*] + Q_{XY} Q_Y^{-1} \mathbb{E}[(Y' - \bar{Y}) (Y' - \bar{Y})^*] Q_Y^{-1} Q_{YX} \\ &= Q_X - Q_{XY} Q_Y^{-1} Q_{YX} - Q_{XY} Q_Y^{-1} Q_{YX} + Q_{XY} Q_Y^{-1} Q_Y Q_Y^{-1} Q_{YX} \\ &= Q_X - Q_{XY} Q_Y^{-1} Q_{YX} = R, \end{aligned}$$

compte tenu que

$$\begin{aligned}\xi(y) - \widehat{X}(y) &= X' + Q_{XY} Q_Y^{-1} (y - Y') - (\bar{X} + Q_{XY} Q_Y^{-1} (y - \bar{Y})) \\ &= (X' - \bar{X}) - Q_{XY} Q_Y^{-1} (Y' - \bar{Y}) ,\end{aligned}$$

par différence.

Remarque 1.10 On vérifie aisément que

$$0 \leq R \leq Q_X ,$$

au sens des matrices symétriques (la majoration est immédiate et la minoration résulte du Lemme A.3), c'est-à-dire que l'utilisation de l'information supplémentaire $Y = y$, ne peut que réduire l'incertitude que l'on a sur le vecteur aléatoire X . En outre, la matrice R ne dépend pas de y , et peut donc être calculée avant même de disposer de la valeur prise par l'observation Y .

Remarque 1.11 Soit $\widehat{X} = \widehat{X}(Y)$ l'estimateur du minimum de variance de X sachant Y . Compte tenu que

$$\widehat{X} = \bar{X} + Q_{XY} Q_Y^{-1} (Y - \bar{Y}) ,$$

dépend de façon affine du vecteur aléatoire Y , on en déduit que $(X, \widehat{X}, Y)$ est un vecteur aléatoire gaussien, comme transformation affine du vecteur aléatoire gaussien $Z = (X, Y)$.

Remarque 1.12 Si $Y = (Y', Y'')$ où les composantes Y' et Y'' sont indépendantes, alors

$$\bar{Z} = \begin{pmatrix} \bar{X} \\ \bar{Y}' \\ \bar{Y}'' \end{pmatrix} \quad \text{et} \quad Q_Z = \begin{pmatrix} Q_X & Q_{XY'} & Q_{XY''} \\ Q_{Y'X} & Q_{Y'} & 0 \\ Q_{Y''X} & 0 & Q_{Y''} \end{pmatrix} ,$$

et si les matrices $Q_{Y'}$ et $Q_{Y''}$ sont inversibles, alors la distribution de probabilité conditionnelle du vecteur aléatoire X sachant $Y = y$, avec $y = (y', y'')$, est une distribution de probabilité gaussienne de moyenne

$$\begin{aligned}\widehat{X}(y) &= \bar{X} + Q_{XY} Q_Y^{-1} (y - \bar{Y}) \\ &= \bar{X} + \begin{pmatrix} Q_{XY'} & Q_{XY''} \end{pmatrix} \begin{pmatrix} Q_{Y'}^{-1} & 0 \\ 0 & Q_{Y''}^{-1} \end{pmatrix} \begin{pmatrix} y' - \bar{Y}' \\ y'' - \bar{Y}'' \end{pmatrix} \\ &= \bar{X} + Q_{XY'} Q_{Y'}^{-1} (y' - \bar{Y}') + Q_{XY''} Q_{Y''}^{-1} (y'' - \bar{Y}'') ,\end{aligned}$$

et de matrice de covariance

$$\begin{aligned}
 R &= Q_X - Q_{XY} Q_Y^{-1} Q_{YX} \\
 &= Q_X - \begin{pmatrix} Q_{XY'} & Q_{XY''} \end{pmatrix} \begin{pmatrix} Q_{Y'}^{-1} & 0 \\ 0 & Q_{Y''}^{-1} \end{pmatrix} \begin{pmatrix} Q_{Y'X} \\ Q_{Y''X} \end{pmatrix} \\
 &= Q_X - Q_{XY'} Q_{Y'}^{-1} Q_{Y'X} - Q_{XY''} Q_{Y''}^{-1} Q_{Y''X} .
 \end{aligned}$$

Exemple 1.13 Soit X et V deux vecteurs aléatoires gaussiens indépendants, de moyenne $\bar{X}$ et 0, et de matrice de covariance Q_X et Q_V , respectivement, et on pose $Y = H X + V$. Le vecteur aléatoire $Z = (X, Y)$ est alors gaussien, de moyenne et de matrice de covariance

$$\bar{Z} = \begin{pmatrix} \bar{X} \\ H \bar{X} \end{pmatrix} \quad \text{et} \quad Q_Z = \begin{pmatrix} Q_X & Q_X H^* \\ H Q_X & H Q_X H^* + Q_V \end{pmatrix} ,$$

respectivement. En effet, par différence

$$Y - H \bar{X} = H (X - \bar{X}) + V ,$$

de sorte que

$$\begin{aligned}
 Q_{XY} &= \mathbb{E}[(X - \bar{X})(H(X - \bar{X}) + V)^*] \\
 &= \mathbb{E}[(X - \bar{X})(X - \bar{X})^*] H^* + \mathbb{E}[(X - \bar{X}) V^*] \\
 &= Q_X H^* ,
 \end{aligned}$$

et

$$\begin{aligned}
 Q_Y &= \mathbb{E}[(H(X - \bar{X}) + V)(H(X - \bar{X}) + V)^*] \\
 &= H \mathbb{E}[(X - \bar{X})(X - \bar{X})^*] H^* + \mathbb{E}[V V^*] \\
 &\quad + H \mathbb{E}[(X - \bar{X}) V^*] + \mathbb{E}[V (X - \bar{X})^*] H^* \\
 &= H Q_X H^* + Q_V .
 \end{aligned}$$

Pour établir ces deux identités, on a utilisé dans la dernière égalité le fait que $(X - \bar{X})$ est indépendant de V , donc $\mathbb{E}[(X - \bar{X}) V^*] = 0$. Si la matrice Q_V est inversible, alors a fortiori la matrice $Q_Y = H Q_X H^* + Q_V$ est inversible, et il découle de la Proposition 1.8 que la distribution

de probabilité conditionnelle du vecteur aléatoire X sachant Y , est une distribution de probabilité gaussienne de moyenne

$$\widehat{X}(Y) = \bar{X} + Q_X H^* (H Q_X H^* + Q_V)^{-1} (Y - H \bar{X}) ,$$

et de matrice de covariance déterministe

$$R = Q_X - Q_X H^* (H Q_X H^* + Q_V)^{-1} H Q_X ,$$

complément de Schur de la matrice $Q_Y = H Q_X H^* + Q_V$ dans la matrice-bloc Q_Z . Pour simuler un vecteur aléatoire gaussien de dimension m , de moyenne $\widehat{X}(Y)$ et de matrice de covariance R , il découle de la Remarque 1.9 qu'il suffit de simuler deux vecteurs aléatoires gaussiens indépendants X' et V' , de moyenne $\bar{X}$ et 0, et de matrice de covariance Q_X et Q_V , respectivement, c'est-à-dire de même moyenne et de même matrice de covariance que X et V respectivement, et de poser

$$\xi(Y) = X' + Q_X H^* (H Q_X H^* + Q_V)^{-1} (Y - (H X' + V')) .$$

Si en outre la matrice Q_X est inversible, alors il découle du Lemme A.1 d'inversion matricielle que la matrice R est inversible, et

$$R^{-1} = H^* Q_V^{-1} H + Q_X^{-1} = J ,$$

d'après l'expression obtenue dans l'Exemple 1.7 pour la matrice d'information de Fisher. Dans ce cas particulier, la borne de Cramér–Rao a posteriori est donc atteinte, puisque

$$\mathbb{E}[(\widehat{X}(Y) - X)(\widehat{X}(Y) - X)^*] = R = J^{-1} .$$

Pour finir, on peut montrer directement la relation $J = R^{-1}$ sans utiliser l'expression obtenue dans l'Exemple 1.7. En effet, si la matrice R est inversible, ce qui est garanti dès que les matrices Q_X et Q_V sont inversibles, alors on a

$$p(x | y) \propto \exp\{-\frac{1}{2} (x - \widehat{X}(y))^* R^{-1} (x - \widehat{X}(y))\} ,$$

de sorte que

$$-\log p(x | y) = \frac{1}{2} (x - \widehat{X}(y))^* R^{-1} (x - \widehat{X}(y)) + \text{cste} ,$$

et

$$-\frac{\partial^2}{\partial x^2} \log p(x | y) = R^{-1} ,$$

et on retrouve bien l'expression de la matrice d'information de Fisher

$$J = -\mathbb{E}\left[\frac{\partial^2}{\partial x^2} \log p(X | Y)\right] = R^{-1} .$$

PREUVE DE LA PROPOSITION 1.8. On pose $\Xi = X - Q_{XY} Q_Y^{-1} Y$, et on vérifie que le vecteur aléatoire (Ξ, Y) est gaussien, comme transformation affine du vecteur aléatoire gaussien $Z = (X, Y)$. On calcule facilement la moyenne

$$\bar{\Xi} = \mathbb{E}[\Xi] = \bar{X} - Q_{XY} Q_Y^{-1} \bar{Y} ,$$

et par différence

$$\Xi - \bar{\Xi} = (X - \bar{X}) - Q_{XY} Q_Y^{-1} (Y - \bar{Y}) ,$$

et on calcule facilement la matrice de covariance

$$\begin{aligned} Q_{\Xi} &= \mathbb{E}[(\Xi - \bar{\Xi}) (\Xi - \bar{\Xi})^*] \\ &= \mathbb{E}[((X - \bar{X}) - Q_{XY} Q_Y^{-1} (Y - \bar{Y})) ((X - \bar{X}) - Q_{XY} Q_Y^{-1} (Y - \bar{Y}))^*] \\ &= \mathbb{E}[(X - \bar{X}) (X - \bar{X})^*] - \mathbb{E}[(X - \bar{X}) (Y - \bar{Y})^*] Q_Y^{-1} Q_{YX} \\ &\quad - Q_{XY} Q_Y^{-1} \mathbb{E}[(Y - \bar{Y}) (X - \bar{X})^*] + Q_{XY} Q_Y^{-1} \mathbb{E}[(Y - \bar{Y}) (Y - \bar{Y})^*] Q_Y^{-1} Q_{YX} \\ &= Q_X - Q_{XY} Q_Y^{-1} Q_{YX} = R , \end{aligned}$$

et la matrice de corrélation

$$\begin{aligned} Q_{\Xi Y} &= \mathbb{E}[(\Xi - \bar{\Xi}) (Y - \bar{Y})^*] \\ &= \mathbb{E}[(X - \bar{X}) - Q_{XY} Q_Y^{-1} (Y - \bar{Y})] (Y - \bar{Y})^* \\ &= \mathbb{E}[(X - \bar{X}) (Y - \bar{Y})^*] - Q_{XY} Q_Y^{-1} \mathbb{E}[(Y - \bar{Y}) (Y - \bar{Y})^*] = 0 . \end{aligned}$$

En particulier, les vecteurs aléatoires gaussiens Ξ et Y sont décorrélés, donc indépendants, de sorte que

$$\mathbb{E}[\Xi | Y] = \mathbb{E}[\Xi] = \bar{\Xi} \quad \text{et} \quad \mathbb{E}[(\Xi - \bar{\Xi}) (\Xi - \bar{\Xi})^* | Y] = \mathbb{E}[(\Xi - \bar{\Xi}) (\Xi - \bar{\Xi})^*] = R .$$

On en déduit la moyenne conditionnelle du vecteur aléatoire $X = \Xi + Q_{XY} Q_Y^{-1} Y$ sachant Y

$$\hat{X}(Y) = \mathbb{E}[X | Y] = \bar{\Xi} + Q_{XY} Q_Y^{-1} Y = \bar{X} + Q_{XY} Q_Y^{-1} (Y - \bar{Y}) ,$$

et la matrice de covariance de l'erreur d'estimation

$$\mathbb{E}[(X - \hat{X}(Y)) (X - \hat{X}(Y))^*] = \mathbb{E}[(\Xi - \bar{\Xi}) (\Xi - \bar{\Xi})^*] = R ,$$

compte tenu que $X - \hat{X}(Y) = \Xi - \bar{\Xi}$ par différence, mais aussi

$$\mathbb{E}[(X - \hat{X}(Y)) (X - \hat{X}(Y))^* | Y] = \mathbb{E}[(\Xi - \bar{\Xi}) (\Xi - \bar{\Xi})^* | Y] = R ,$$

c'est-à-dire que la matrice de covariance de l'erreur d'estimation coïncide avec la matrice de covariance de la distribution de probabilité conditionnelle du vecteur aléatoire X sachant Y . Enfin, pour montrer que cette distribution de probabilité conditionnelle est gaussienne, il suffit

d'exprimer sa fonction caractéristique

$$\begin{aligned}
\mathbb{E}[\exp\{i u^* X\} \mid Y] &= \mathbb{E}[\exp\{i u^* (\Xi + Q_{XY} Q_Y^{-1} Y)\} \mid Y] \\
&= \exp\{i u^* Q_{XY} Q_Y^{-1} Y\} \mathbb{E}[\exp\{i u^* \Xi\}] \\
&= \exp\{i u^* Q_{XY} Q_Y^{-1} Y\} \exp\{i u^* (\bar{X} - Q_{XY} Q_Y^{-1} \bar{Y}) - \frac{1}{2} u^* R u\} \\
&= \exp\{i u^* \hat{X}(Y) - \frac{1}{2} u^* R u\} .
\end{aligned}$$

On reconnaît la fonction caractéristique d'un vecteur aléatoire gaussien de moyenne $\hat{X}(Y)$ et de matrice de covariance R . $\square$

Conclusion On voit qu'il est important de disposer d'une information *a priori* sur l'état inconnu X_n , par exemple de disposer d'une équation d'état décrivant l'évolution de X_n quand n varie. On peut considérer deux types de modèles :

- les systèmes linéaires gaussiens,
- les chaînes de Markov à espace d'état fini,

et dans chacun de ces deux cas, il est possible de résoudre exactement le problème de filtrage de façon optimale, par la mise en œuvre :

- du filtre de Kalman, dans le cas des systèmes linéaires gaussiens,
- des équations forward–backward de Baum, ou de l'algorithme de Viterbi, dans le cas des chaînes de Markov à état fini.

Ces deux cas peuvent être vus comme des cas particuliers de modèles beaucoup plus généraux :

- les chaînes de Markov à espace d'état quelconque (fini, dénombrable, continu, hybride, etc.),

et dans ce cas il ne sera pas possible de résoudre exactement le problème de filtrage de façon optimale, qui s'exprime pourtant très simplement en termes de distributions de Feynman–Kac, et il faudra avoir recours à la mise en œuvre de méthodes de résolution approchées, en l'occurrence :

- de filtres particuliers, c'est-à-dire de méthodes de Monte Carlo avec interaction.

Chapitre 2

Exemples

2.1 Recalage altimétrique de navigation inertielle

Un avion survole une zone dont le relief est connu : la hauteur $h(r)$ du relief en chaque point de coordonnée horizontale r est connue, et enregistrée dans une carte numérique.

Dans la suite, la position horizontale de l'avion est notée r , la position verticale, ou altitude, est notée z , et la vitesse horizontale est notée v . A l'instant 0, la position horizontale initiale de l'avion est r_0 , son altitude initiale est z_0 et sa vitesse horizontale initiale est v_0 . En réalité, l'avion se déplace à l'altitude $z = z_0$ constante et à la vitesse horizontale constante $v = v_0$.




FIGURE 2.1 : Modèle numérique de terrain, et trajectoire réelle

Pour effectuer la navigation, c'est-à-dire pour permettre à l'avion d'estimer sa propre position horizontale r_k et sa propre vitesse horizontale v_k à chaque instant t_k , on recueille (au

moyen d'accéléromètres et de gyroscopes installés à bord) avec un pas de temps $\Delta = t_k - t_{k-1}$ et jusqu'à l'instant final T , l'accélération horizontale de l'avion avec une erreur additive modélisée par un bruit blanc gaussien centré de matrice de covariance $\sigma_{\text{INS}}^2 I_2$ (on dénote par I_2 la matrice identité de dimension 2×2). L'écart-type σ_{INS} est une caractéristique supposée connue de la centrale de navigation inertielle utilisée.

En respectant les caractéristiques statistiques données ci-dessus, la suite a_k^{INS} d'accélération bruitées vérifie

$$a_k^{\text{INS}} = a_k + w_k^{\text{INS}} ,$$

où a_k dénote l'accélération réelle de l'avion, ici $a_k \equiv 0$ compte que l'avion se déplace en réalité à vitesse constante, et où la suite w_k^{INS} est un bruit blanc gaussien centré de matrice de covariance $\sigma_{\text{INS}}^2 I_2$.

L'estimation r_k^{INS} de la position horizontale exacte r_k est obtenue simplement en intégrant les mesures d'accélération horizontale, à l'aide du modèle d'état suivant

$$\begin{pmatrix} r_k^{\text{INS}} \\ v_k^{\text{INS}} \end{pmatrix} = \begin{pmatrix} I_2 & \Delta I_2 \\ 0 & I_2 \end{pmatrix} \begin{pmatrix} r_{k-1}^{\text{INS}} \\ v_{k-1}^{\text{INS}} \end{pmatrix} + \Delta \begin{pmatrix} 0 \\ a_k^{\text{INS}} \end{pmatrix} \quad \text{avec} \quad \begin{pmatrix} r_0^{\text{INS}} \\ v_0^{\text{INS}} \end{pmatrix} = \begin{pmatrix} r_0 \\ v_0 \end{pmatrix} .$$

Si on représente sur le même graphique la position horizontale exacte r_k de l'avion et l'estimation inertielle r_k^{INS} , pour chaque instant entre 0 et T , on remarque que la trajectoire estimée s'écarte de la trajectoire réelle, juste parce que les erreurs sur l'estimation de l'accélération s'accumulent au cours du temps.




FIGURE 2.2 : Modèle numérique de terrain, trajectoire réelle et trajectoire inertielle

On introduit comme nouvelles variables d'état les erreurs d'estimation inertielle en position horizontale $\delta r_k = r_k^{\text{INS}} - r_k$ et en vitesse horizontale $\delta v_k = v_k^{\text{INS}} - v_k$, et le modèle d'état

correspondant est donc donné par

$$\begin{pmatrix} \delta r_k \\ \delta v_k \end{pmatrix} = \begin{pmatrix} I_2 & \Delta I_2 \\ 0 & I_2 \end{pmatrix} \begin{pmatrix} \delta r_{k-1} \\ \delta v_{k-1} \end{pmatrix} + \Delta \begin{pmatrix} 0 \\ w_k^{\text{INS}} \end{pmatrix} \quad \text{avec} \quad \begin{pmatrix} \delta r_0 \\ \delta v_0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

où la suite w_k^{INS} est un bruit blanc gaussien centré de matrice de covariance $\sigma_{\text{INS}}^2 I_2$.

On se propose dans la suite d'estimer ces nouvelles variables d'état, en exploitant d'autres mesures, de manière à corriger les estimations inertielles obtenues lors de cette première phase.

Pour corriger la dérive de l'estimation inertielle en position horizontale r_k^{INS} par rapport à la position horizontale exacte r_k , on recueille séparément (au moyen d'un radar altimétrique, ou radio-altimètre, installé à bord) avec le même pas de temps Δ une mesure d_k^{ALT} de la hauteur de l'avion au-dessus du relief situé à la verticale, avec une erreur additive modélisée par un bruit blanc gaussien centré de variance σ_{ALT}^2 . L'écart-type σ_{ALT} est une caractéristique supposée connue du radio-altimètre utilisé.

On recueille également (au moyen d'un baromètre altimétrique, ou baro-altimètre, installé à bord) avec le même pas de temps Δ une mesure z_k^{BAR} de l'altitude de l'avion, avec une erreur additive modélisée par un bruit blanc gaussien centré de variance σ_{BAR}^2 . L'écart-type σ_{BAR} est une caractéristique supposée connue du baro-altimètre utilisé.




FIGURE 2.3 : Principe du recalage altimétrique

A chaque instant t_k , le radio-altimètre fournit une mesure bruitée d_k^{ALT} de la distance entre l'avion et le relief, c'est-à-dire

$$d_k^{\text{ALT}} = (z_k - h(r_k)) + w_k^{\text{ALT}},$$

où r_k dénote la position horizontale réelle de l'avion, où z_k dénote l'altitude réelle de l'avion, où $h(r_k)$ dénote la hauteur du relief au point de coordonnée horizontale r_k , et où la suite w_k^{ALT} est

un bruit blanc gaussien centré de variance σ_{ALT}^2 . Au même instant t_k , le baro-altimètre fournit une mesure bruitée z_k^{BAR} de l'altitude de l'avion, c'est-à-dire

$$z_k^{\text{BAR}} = z_k + w_k^{\text{BAR}} ,$$

où z_k dénote l'altitude réelle de l'avion, et où la suite w_k^{BAR} est un bruit blanc gaussien centré de variance σ_{BAR}^2 . La hauteur du relief survolé à l'instant t_k déduite à partir des mesures fournies par le radio-altimètre et par le baro-altimètre est donc

$$h_k^{\text{ALT}} = z_k^{\text{BAR}} - d_k^{\text{ALT}} = h(r_k) + w_k^{\text{BAR}} - w_k^{\text{ALT}} ,$$

et peut être reliée à l'erreur de position inertielle horizontale δr_k par

$$h_k^{\text{ALT}} = h(r_k^{\text{INS}} - \delta r_k) + w_k^{\text{BAR}} - w_k^{\text{ALT}} .$$




FIGURE 2.4 : Profil réel du terrain survolé et mesures altimétriques

En résumé, le modèle d'état utilisé pour le recalage altimétrique de navigation inertielle comprend :

- l'équation d'état

$$\begin{pmatrix} \delta r_k \\ \delta v_k \end{pmatrix} = \begin{pmatrix} I_2 & \Delta I_2 \\ 0 & I_2 \end{pmatrix} \begin{pmatrix} \delta r_{k-1} \\ \delta v_{k-1} \end{pmatrix} + \Delta \begin{pmatrix} 0 \\ w_k^{\text{INS}} \end{pmatrix} ,$$

où la suite w_k^{INS} est un bruit blanc gaussien centré de variance $\sigma_{\text{INS}}^2 I_2$,

- la condition initiale

$$\begin{pmatrix} \delta r_0 \\ \delta v_0 \end{pmatrix} \text{ gaussienne, centrée, de matrice de covariance } \begin{pmatrix} \sigma_{r_0}^2 I_2 & 0 \\ 0 & \sigma_{v_0}^2 I_2 \end{pmatrix} ,$$

- et l'équation d'observation

$$h_k^{\text{ALT}} = h(r_k^{\text{INS}} - \delta r_k) + w_k^{\text{BAR}} - w_k^{\text{ALT}} .$$

où la suite w_k^{ALT} est un bruit blanc gaussien centré de variance σ_{ALT}^2 , et où la suite w_k^{BAR} est un bruit blanc gaussien centré de variance σ_{BAR}^2 .

L'estimation inertielle horizontale r_k^{INS} fournie par la centrale inertielle, et la mesure h_k^{ALT} de la hauteur du relief fournie par le radio-altimètre et par le baro-altimètre sont disponibles. La fonction $r \mapsto h(r)$ n'est pas connue de façon analytique, mais définie *point-par-point* en allant lire la carte numérique.

2.2 Suivi visuel par histogramme de couleur

On souhaite réaliser un algorithme de suivi dans une séquence d'images numériques couleur. A la lecture de la première image de la séquence, l'utilisateur sélectionne une zone de l'image, et le suivi s'effectue de façon séquentielle sur l'ensemble de la séquence, voir Figure 2.5.




FIGURE 2.5 : Suivi d'un visage dans une séquence de 10 images

La méthode est construite sur l'algorithme SIR (souvent appelé algorithme CONDENSATION, pour *conditional density propagation*, en vision par ordinateur). Elle repose sur l'hypothèse que l'histogramme de couleur de la zone à suivre est constant le long de la séquence. Pour avoir plus d'informations sur cette méthode de suivi visuel, on pourra lire [21].

Introduction aux images numériques

On désigne sous le terme d'image numérique toute image (dessin, icône, photographie, etc.) acquise, créée, traitée ou stockée sous forme binaire. On distingue généralement deux grandes catégories d'images :

- les images vectorielles, dont la description informatique est composée d'objets géométriques individuels (segments de droite, polygones, arcs de cercle, etc.), chacun définis par divers attributs de forme, de position, de couleur, etc.
- les images matricielles, représentées par un tableau à deux dimensions dont chaque case est un pixel (mot dérivé de l'anglais *picture element*, élément d'image). A chaque pixel est associée une ou plusieurs valeurs décrivant son niveau de gris ou sa couleur.

Les images vectorielles sont utilisées essentiellement pour du graphisme ou en CAO. Lorsque l'on s'intéresse au traitement d'images et à la vision par ordinateur, la représentation utilisée est la forme matricielle. Il existe plusieurs standards de codage de la couleur :

bitmap noir et blanc : en stockant un bit dans chaque case, il est possible de définir deux couleurs (noir ou blanc).

bitmap 256 niveaux de gris : en stockant un octet dans chaque case, il est possible de définir 256 dégradés de gris allant du noir au blanc

palette de couleurs (colormap) : grâce à cette méthode, il est possible de définir une palette, ou table des couleurs, contenant l'ensemble des couleurs pouvant être contenues dans l'image, à chacune desquelles est associé un indice. Le nombre de bits réservé au codage de chaque indice de la palette détermine le nombre de couleurs pouvant être utilisées. On appelle ainsi image en couleurs indexées une image dont les couleurs sont codées selon cette technique.

couleurs vraies (true color) : le codage de la couleur est réalisé sur trois octets, chaque octet représentant la valeur d'une composante couleur par un entier de 0 à 255. Ces trois valeurs codent généralement la couleur dans l'espace RVB (rouge, vert, bleu), mais d'autres espaces de couleurs peuvent être utilisés. Le nombre de couleurs différentes pouvant être ainsi représentées est de $256 \times 256 \times 256$ possibilités, soit près de 16 millions de couleurs.

Une image numérique est avant tout un signal 2D. D'un point de vue mathématique, on considère l'image comme une fonction de $\mathbb{R} \times \mathbb{R}$ dans Ω où le couplet d'entrée est une position spatiale sur la grille des pixels, et où Ω est l'espace des valeurs de codage de la couleur (ou du niveau de gris). Par extension, on parlera d'images en dimension 2D+t (t pour le temps) pour désigner une séquence d'images numériques (ou vidéo numérique).

Remarque 2.1 Etant donné que l'écran effectue un balayage de gauche à droite et de haut en bas, on désigne généralement par les coordonnées $(0, 0)$ le pixel situé en haut à gauche de l'image, ce qui signifie que les axes de l'image sont orientés de la façon suivante : l'axe X est orienté de gauche à droite, l'axe Y est orienté de haut en bas, contrairement aux notations conventionnelles en mathématiques, où l'axe Y est orienté vers le haut.

Principe de l'algorithme de suivi visuel

Le but de cet algorithme est de suivre une région d'intérêt dans une séquence d'images. Cette région est initialisée par l'utilisateur et sa forme est fixée a priori. On considérera ici un rectangle, paramétré par la position, en pixel, du centre du rectangle $d = (x, y)$ et un paramètre d'échelle s . Au pas de temps k (i.e. à l'image k), l'état du système à estimer sera donc $X_k = (d_k, s_k)$. Le paramètre d'échelle permet de suivre un objet même si celui-ci avance ou s'éloigne dans l'axe de la caméra (effet de zoom). À l'initialisation, l'utilisateur clique 4 points dans l'image, qui vont définir le rectangle initial. Celui-ci est décrit par les coordonnées du point haut/gauche, une largeur et une hauteur.

Équation d'état On s'intéresse à la situation où aucune information a priori n'est disponible sur la nature de l'objet suivi. Dans ce cas, l'équation dynamique du système doit être peu informative. On supposera donc un modèle à position constante

$$X_k = X_{k-1} + W_k ,$$

où W_k est un bruit blanc gaussien, centré en 0 et de matrice de covariance C , matrice 3×3 diagonale. Les valeurs sur la diagonale sont c_1 , c_2 et c_3 . Notons que si la nature de l'objet suivi est connu, il est plus intéressant d'utiliser un modèle dynamique approprié. Par exemple, on pourrait imaginer utiliser un modèle à vitesse constante pour le suivi d'une voiture dans une vidéo acquise par une caméra sur autoroute.

Modèle de couleur La zone initiale à suivre est caractérisée par un histogramme de couleur. Cet histogramme de référence est construit sur les Nb couleurs les plus représentatives de cette zone, comme montré sur la Figure 2.6. Cet histogramme de référence est noté $q^* = \{q^*(n), n = 1, \dots, Nb\}$, où $q^*(n)$ représente le nombre normalisé de pixels de la zone initiale dont la couleur la plus proche est la couleur n . On a $\sum_{n=1}^{Nb} q^*(n) = 1$. Pour plus d'informations sur les différents espaces de couleur, on pourra se reporter à la page *color space* sous Wikipedia.




FIGURE 2.6 : Zone de l'image à suivre et histogramme de couleur associé pour $Nb = 64$

Comme décrit précédemment, le but est de suivre une zone de l'image le long de la séquence, sous l'hypothèse que son histogramme de couleur est invariant dans le temps. Au temps k , l'histogramme de couleur $q_k(x)$ d'un état hypothèse x sera comparé au modèle de couleur de référence q^* , et on définit la mesure de distance D entre ces deux histogrammes de couleur normalisés

$$D(q^*, q_k(x)) = (1 - \sum_{n=1}^{Nb} \sqrt{q^*(n) q_k(x, n)})^{1/2} ,$$

Pour favoriser les états hypothèses dont l'histogramme de couleur associé est proche de l'histogramme de référence, on introduit la fonction de pondération

$$g_k(x) \propto \exp\{-\lambda D^2(q^*, q_k(x))\} .$$

2.3 Poursuite d'une cible furtive (track-before-detect)

Une image radar est constituée par un tableau rectangulaire de $p \times p$ pixels, où l'intensité de l'écho recueilli en un point est codée par un niveau de gris allant du plus foncé (écho de faible intensité) au plus clair (écho de forte intensité). La même situation se rencontre avec un dispositif opto-électronique, comme une caméra matricielle, où chaque pixel reçoit et affiche une intensité lumineuse différente. En principe, si une cible est présente dans la scène 3D visée, elle apparaîtra dans le plan-image sous la forme d'un pixel plus clair (ou d'un groupe de pixels adjacents plus clairs) que les autres pixels de l'image, lesquels correspondent à l'écho d'objets secondaires de moindre intensité et/ou à un bruit spatial, indépendant ou bien spatialement corrélé d'un pixel à l'autre. Pour détecter (et localiser) la cible, il suffit en principe de rechercher dans l'image le pixel (ou le groupe de pixels adjacents) le plus clair, c'est-à-dire de plus forte intensité. Au lieu d'une recherche exhaustive, on utilise souvent une méthode de seuillage : rechercher les pixels d'intensité supérieure à un seuil bien choisi, permet souvent d'obtenir directement le pixel de plus forte intensité. En répétant cette opération pour chaque image successivement on peut ainsi détecter d'abord, puis suivre, la cible dans une séquence d'images.




FIGURE 2.7 : Image observée, position réelle, histogramme, détection (cible visible)

On s'intéresse ici au cas d'une cible furtive, caractérisée par un écho de très faible intensité, c'est-à-dire d'une intensité du même ordre de grandeur que l'intensité caractéristique du bruit présent dans l'image, voire même d'un ordre de grandeur inférieur. Dans ce cas, une méthode de seuillage est inefficace : quel que soit le seuil choisi, rechercher les pixels d'intensité supérieure au seuil ne permet plus d'isoler la cible au milieu du bruit. Même un opérateur humain est incapable, sur une image isolée, de détecter la présence et la position de la cible. En revanche, un opérateur

humain est capable dans certains cas de suivre la cible dans une séquence d'images, comme une succession de pixels (un dans chaque image de la séquence) animés d'un mouvement cohérent au milieu de l'agitation incoordonnée des autres pixels. En quelque sorte, l'œil humain suit la cible sans jamais la détecter vraiment : c'est ce genre de performance qu'il s'agit de reproduire ici de manière algorithmique, connue sous le terme de *track-before-detect*, en s'appuyant sur un modèle a priori pour le déplacement de la cible, qui favorise le mouvement cohérent de pixels entre des images successives.




FIGURE 2.8 : Image observée, position réelle, histogramme, détection (cible furtive)

Chaque image peut se représenter comme un champ aléatoire $(Y_k(s), s \in S)$ où l'indice $s \in S$ désigne le pixel ou de manière équivalente le site d'un réseau bi-dimensionnel. Par hypothèse, l'intensité observée au pixel $s \in S$ se décompose comme

$$Y_k(s) = I(r_k, s) + B_k(s) ,$$

c'est-à-dire comme la somme de l'intensité due à la présence de la cible à la position (inconnue) r_k et de l'intensité due au bruit seulement. L'intensité au point $s \in S$ due à la présence de la cible à la position r est modélisée par une fonction d'étalement ponctuelle (ou *point spread function*, PSF)

$$I(r, s) = I_0 \frac{\delta^2}{2\pi\sigma_{\text{PSF}}^2} \exp\left\{-\frac{|r(s) - r|^2}{2\sigma_{\text{PSF}}^2}\right\} 1_{(s \in C(r))} ,$$

où $r(s)$ désigne la position dans l'espace physique du centre du pixel s , où $\delta > 0$ désigne la taille du pixel dans l'espace physique, et où l'ensemble $C(r)$ désigne le voisinage à 9 points dans l'espace-image autour du pixel contenant le point de position r dans l'espace physique.

L'intensité due au bruit seulement est modélisée comme un champ aléatoire gaussien $(B_k(s), s \in S)$ centré, de variance σ_B^2 en tout pixel $s \in S$ et décorrélié spatialement, c'est-à-dire

$$\mathbb{E}[B_k(s)] = 0 \quad \text{et} \quad \mathbb{E}[B_k(s) B_k(s')] = \sigma_B^2 \mathbf{1}_{(s = s')} .$$

On définit le rapport signal à bruit (ou *signal to noise ratio*, SNR) en decibel, comme

$$\text{SNR} = 20 \log_{10} \frac{I_0}{\sigma_B} .$$

On pose ici (par convention) $I_0 = 1$ de sorte qu'un rapport signal à bruit de 20 dB correspond à $\sigma_B = 0.1$ tandis qu'un rapport signal à bruit de 0 dB correspond à $\sigma_B = 1$.

La fonction de vraisemblance est donnée à une constante multiplicative près par l'expression, en fonction de la variable r , de la densité du champ aléatoire observé $(Y_k(s), s \in S)$ quand la cible occupe la position r dans l'espace physique. On a donc par définition

$$g_k(r) = \exp\left\{-\frac{1}{2\sigma_B^2} \sum_{s \in S} |Y_k(s) - I(r, s)|^2\right\} ,$$

et on remarque que

$$g_k(r) = \exp\left\{\frac{1}{\sigma_B^2} \sum_{s \in C(r)} I(r, s) Y_k(s) - \frac{1}{2\sigma_B^2} \sum_{s \in C(r)} |I(r, s)|^2\right\} ,$$

à une constante multiplicative près, de sorte que le calcul porte seulement sur les 9 pixels du voisinage $C(r)$, et pas sur l'ensemble S de tous les pixels.

Le modèle a priori pour l'évolution de la cible est donné par le modèle d'état suivant

$$\begin{pmatrix} r_k \\ v_k \end{pmatrix} = \begin{pmatrix} I_2 & \Delta I_2 \\ 0 & I_2 \end{pmatrix} \begin{pmatrix} r_{k-1} \\ v_{k-1} \end{pmatrix} + \sigma \sqrt{\Delta} \begin{pmatrix} 0 \\ w_k \end{pmatrix} ,$$

où w_k est un vecteur aléatoire gaussien centré de matrice de covariance I_2 , où la position initiale r_0 est distribuée uniformément dans l'espace physique défini ci-dessus, et où la vitesse initiale v_0 est distribuée uniformément dans le domaine délimité en module par $v_{\min} \leq |v_0| \leq v_{\max}$ et en orientation par $[0, 2\pi)$.

Sur chaque image, on peut rechercher le pixel de plus forte intensité observée, ou bien mettre en œuvre une méthode de seuillage pour détecter les pixels d'intensité supérieure au seuil choisi. On peut aussi extraire l'histogramme des intensités observées aux différents pixels de l'image. Si le rapport signal à bruit est trop faible, alors une simple détection image par image s'avère inefficace. On peut en revanche considérer les images successives comme des observations (matricielles), et mettre en œuvre un algorithme de filtrage pour effectuer directement le suivi.

2.4 Navigation en environnement intérieur

Un utilisateur se déplace à l'intérieur d'un bâtiment dont le plan est disponible sous la forme d'une carte numérique. L'utilisateur est caractérisé à l'instant t_k

- une mesure $\hat{\alpha}_k$ de la rotation effectuée par l'utilisateur à l'instant t_k , avec une incertitude caractérisée par un bruit gaussien additif de moyenne nulle et de variance σ_{turn}^2 ,
- et une mesure $\hat{d}_k$ de la distance parcourue par l'utilisateur entre les instants t_k et t_{k+1} , avec une incertitude caractérisée par un bruit gaussien additif de moyenne nulle et de variance σ_{walk}^2 .

En d'autres termes

$$\hat{\alpha}_k = \alpha_k + w_k^{\text{turn}} \quad (\text{modulo } 2\pi) \quad \text{et} \quad \hat{d}_k = d_k + w_k^{\text{walk}}, \quad (2.1)$$

où w_k^{walk} et w_k^{turn} sont deux variables aléatoires gaussiennes indépendantes, de moyenne nulle et de variance σ_{walk}^2 et σ_{turn}^2 , respectivement.

Les mesures bruitées $\hat{d}_1, \dots, \hat{d}_{n_{\text{max}}-1}$ et $\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_{n_{\text{max}}-1}$ (avec la convention $\hat{\alpha}_1 = 0$) sont recueillies par l'utilisateur le long de la trajectoire. À partir de ces mesures PNS incrémentales bruitées, et à partir d'estimations de la position initiale r_1 et de l'orientation initiale θ_1 inconnues, on peut essayer de reconstruire la position et l'orientation de l'utilisateur à chaque instant, par intégration

$$\theta_k^{\text{PNS}} = \theta_{k-1}^{\text{PNS}} + \hat{\alpha}_k \quad (\text{modulo } 2\pi) \quad \text{et} \quad r_{k+1}^{\text{PNS}} = r_k^{\text{PNS}} + \hat{d}_k u(\theta_k^{\text{PNS}}),$$

où $u(\theta) = (\cos \theta, \sin \theta)$ désigne le vecteur unitaire associé à l'angle θ . La trajectoire estimée à partir des mesures PNS seulement est représentée sur la Figure 2.10.




FIGURE 2.10 : Trajectoire estimée à partir des mesures PNS seulement

On remarque que la trajectoire estimée s'écarte de la trajectoire réelle, juste parce que les erreurs sur les mesures PNS incrémentales s'accumulent au cours du temps.

Pour corriger la dérive de la trajectoire estimée à partir des mesures PNS seulement, l'idée consiste à recueillir séparément des mesures fournies par d'autres capteurs. Dans la solution proposée ici, à l'intérieur du bâtiment sont disposées des balises de *ranging* identiques, dont les positions sont connues. Chaque balise est caractérisée par sa portée R , de sorte que

- tout utilisateur se trouvant à une distance inférieure à R par rapport à une balise est détecté par cette balise,
- et symétriquement, tout utilisateur se trouvant à une distance supérieure à R par rapport à une balise n'est pas détecté par cette balise.





FIGURE 2.11 : Balises de *ranging* à portée limitée

En outre, si une balise détecte un utilisateur alors une mesure de la distance entre l'utilisateur et cette balise est également disponible, avec une incertitude caractérisée par un bruit gaussien additif de moyenne nulle et de variance σ_{range}^2 . Les éventuelles détections et mesures de distance bruitées sont recueillies par l'utilisateur le long de la trajectoire, et sont disponibles pour le recalage de navigation.

FIGURE 2.12 : Détection par une balise de *ranging*

Pour réaliser le recalage de navigation, on dispose des informations suivantes

- un modèle *a priori* pour l'évolution de la position et de l'orientation de l'utilisateur, utilisant les mesures PNS incrémentales bruitées définies en (2.1),
- une fonction de vraisemblance associée à chaque balise active, c'est-à-dire à chaque balise déclenchée par l'utilisateur,

et on peut également prendre en compte

- la détection (ou la non-détection) de l'utilisateur par une balise,
- et les contraintes sur l'évolution de l'utilisateur dues à la présence d'obstacles, typiquement les murs et cloisons intérieures du bâtiment, information disponible à partir de la carte numérique.

Chapitre 3

Filtrage de Kalman

Le problème de filtrage (en temps discret) se présente en général de la manière suivante : on considère $\{X_k\}$, un processus (dont les caractéristiques statistiques sont connues) représentant l'état d'un système non observé. A l'instant k , on recueille une observation Y_k qui est formée d'un signal (i.e. une fonction $h(X_k)$ de l'état X_k) et d'un bruit additif

$$Y_k = h(X_k) + V_k .$$

Les caractéristiques statistiques du bruit de mesure $\{V_k\}$ sont également supposées connues. A l'instant k , on dispose de l'information $Y_{0:k} = (Y_0, \dots, Y_k)$ et le but est d'obtenir *le plus d'information possible* sur l'état du système X_k (on veut, par exemple, pouvoir calculer un estimateur $\hat{X}_k$ de X_k). On a vu à la Section 1.2 que la solution consiste à calculer la distribution de probabilité conditionnelle de la variable aléatoire X_k sachant $Y_{0:k}$.

Dans le cas des systèmes décrits à la Section 3.1, le cadre est gaussien et l'évolution de cette distribution de probabilité conditionnelle (déterminée par sa moyenne et sa matrice de covariance) est régie par les équations du filtre de Kalman, présentées à la Section 3.2 et très simples à mettre en œuvre. Dans tous les autres cas, par exemple dans le cas des systèmes non-linéaires avec des bruits non gaussiens, ou dans le cas de modèles encore plus généraux qui seront introduits au Chapitre 5, l'évolution de cette distribution de probabilité conditionnelle est déterminée par un tout autre type d'équations, qui seront décrites au Chapitre 7 et dont la mise-en-œuvre pratique sera présentée au Chapitre 10. Les techniques développées dans le cas linéaire peuvent parfois s'étendre au cas non linéaire par des méthodes de linéarisation, présentées à la Section 4.1. Les filtres ainsi obtenus sont très souvent utilisés en pratique mais ont parfois des performances peu satisfaisantes.

3.1 Systèmes linéaires gaussiens

On considère une suite d'états cachés $\{X_k\}$ à valeurs dans $\mathbb{R}^m$, vérifiant

$$X_k = F_k X_{k-1} + f_k + W_k , \tag{3.1}$$

et une suite d'observations $\{Y_k\}$ à valeurs dans $\mathbb{R}^d$, vérifiant

$$Y_k = H_k X_k + h_k + V_k , \tag{3.2}$$

et on suppose que

- la condition initiale X_0 est gaussienne, de moyenne $\bar{X}_0$ et de matrice de covariance Q_0^X ,
- la suite $\{W_k\}$ est un bruit blanc gaussien, de matrice de covariance Q_k^W ,
- la suite $\{V_k\}$ est un bruit blanc gaussien, de matrice de covariance Q_k^V ,
- les suites $\{W_k\}$ et $\{V_k\}$ et la condition initiale X_0 sont mutuellement indépendants.

La signification du modèle (3.1) est la suivante

- même si l'état $X_{k-1} = x$ est connu exactement à l'instant $(k-1)$, on peut seulement dire que l'état X_k à l'instant k est incertain, et distribué comme un vecteur aléatoire gaussien, de moyenne $F_k x + f_k$ et de matrice de covariance Q_k^W ,
- si l'état X_{k-1} est incertain à l'instant $(k-1)$, et distribué comme un vecteur aléatoire gaussien, de moyenne $\bar{X}_{k-1}$ et de matrice de covariance Q_{k-1}^X , alors cette incertitude se propage à l'instant k : même en absence de bruit, c'est-à-dire même si $G_k = 0$, l'état X_k à l'instant k est incertain, et distribué comme un vecteur aléatoire gaussien, de moyenne $F_k \bar{X}_{k-1} + f_k$ et de matrice de covariance $F_k Q_{k-1}^X F_k^*$.

Proposition 3.1 *La suite $\{Z_k = (X_k, Y_k)\}$ est une suite gaussienne à valeurs dans $\mathbb{R}^{m+d}$.*

PREUVE. Comme sortie d'un système linéaire à entrées gaussiennes, la suite $\{Z_k\}$ est un processus aléatoire gaussien. En effet, pour tout instant n , le vecteur aléatoire $(Z_0, Z_1, \dots, Z_n)$ peut s'exprimer comme transformation affine du vecteur aléatoire $(X_0, W_1, \dots, W_n, V_0, V_1, \dots, V_n)$ qui par hypothèse est un vecteur aléatoire gaussien, donc le vecteur aléatoire $(Z_0, Z_1, \dots, Z_n)$ est gaussien, comme transformation affine d'un vecteur aléatoire gaussien. $\square$

Remarque 3.2 Si les coefficients dépendent des observations passées, on parle de système *conditionnellement* linéaire gaussien : on considère ainsi une suite d'états cachés $\{X_k\}$ à valeurs dans $\mathbb{R}^m$, vérifiant

$$X_k = F_k(Y_{0:k-1}) X_{k-1} + f_k(Y_{0:k-1}) + G_k(Y_{0:k-1}) W_k ,$$

où la suite $\{W_k\}$ prend ses valeurs dans $\mathbb{R}^p$, et une suite d'observations $\{Y_k\}$ à valeurs dans $\mathbb{R}^d$, vérifiant

$$Y_k = H_k(Y_{0:k-1}) X_k + h_k(Y_{0:k-1}) + V_k ,$$

et on suppose que

- la condition initiale X_0 est gaussienne, de moyenne $\bar{X}_0$ et de matrice de covariance Q_0^X ,
- la suite $\{W_k\}$ est un bruit blanc gaussien, de matrice de covariance identité,
- la suite $\{V_k\}$ est un bruit blanc gaussien, de matrice de covariance Q_k^V ,

- les suites $\{W_k\}$ et $\{V_k\}$ et la condition initiale X_0 sont mutuellement indépendants.

Dans ce cas, la suite $\{Z_k = (X_k, Y_k)\}$ n'est en général pas une suite gaussienne, mais on peut vérifier que conditionnellement à $Y_{0:k-1}$

- le vecteur aléatoire $W_k^{\text{CLG}} = G_k(Y_{0:k-1}) W_k$ est gaussien centré, de matrice de covariance conditionnelle $Q_k^W(Y_{0:k-1}) = G_k(Y_{0:k-1}) G_k^*(Y_{0:k-1})$,
- le couple (X_k, Y_k) forme conjointement un vecteur aléatoire gaussien.

3.2 Filtre de Kalman

On considère un système linéaire du type (3.1) (3.2), c'est-à-dire

$$X_k = F_k X_{k-1} + f_k + W_k , \quad (3.3)$$

$$Y_k = H_k X_k + h_k + V_k , \quad (3.4)$$

avec les hypothèses faites à la Section 3.1. A l'instant k , on dispose de l'information

$$Y_{0:k} = (Y_0, Y_1, \dots, Y_k) .$$

L'objectif est d'estimer de façon optimale et récursive le vecteur aléatoire X_k à partir de $Y_{0:k}$. Si on adopte le critère du minimum de variance, il s'agit d'après la Section 1.2 de calculer la distribution de probabilité conditionnelle du vecteur aléatoire X_k sachant $Y_{0:k}$. Comme le cadre est gaussien, il suffit de calculer la moyenne et la matrice de covariance

$$\hat{X}_k = \mathbb{E}[X_k \mid Y_{0:k}] \quad \text{et} \quad P_k = \mathbb{E}[(X_k - \hat{X}_k)(X_k - \hat{X}_k)^* \mid Y_{0:k}] .$$

On définit également les quantités suivantes

$$\hat{X}_k^- = \mathbb{E}[X_k \mid Y_{0:k-1}] \quad \text{et} \quad P_k^- = \mathbb{E}[(X_k - \hat{X}_k^-)(X_k - \hat{X}_k^-)^* \mid Y_{0:k-1}] .$$

D'après la Remarque 1.10, les matrices de covariances conditionnelles P_k et P_k^- ne dépendent pas des observations, c'est-à-dire que

$$P_k = \mathbb{E}[(X_k - \hat{X}_k)(X_k - \hat{X}_k)^*] \quad \text{et} \quad P_k^- = \mathbb{E}[(X_k - \hat{X}_k^-)(X_k - \hat{X}_k^-)^*] .$$

Supposons connue la distribution de probabilité conditionnelle du vecteur aléatoire X_{k-1} sachant $Y_{0:k-1}$. Pour calculer la distribution de probabilité conditionnelle du vecteur aléatoire X_k sachant $Y_{0:k}$, on procède en deux étapes :

- dans l'étape de *prédiction*, on calcule la distribution de probabilité conditionnelle du vecteur aléatoire X_k sachant les observations passées $Y_{0:k-1}$, ce qui est facile à partir de (3.3),

- dans l'étape de *correction*, on utilise la nouvelle observation Y_k , et en particulier, on considère la composante de l'observation Y_k qui apporte une information nouvelle par rapport aux observations passées $Y_{0:k-1}$, c'est-à-dire

$$I_k = Y_k - \mathbb{E}[Y_k \mid Y_{0:k-1}] ,$$

et d'après (3.4), on a

$$I_k = Y_k - (H_k \mathbb{E}[X_k \mid Y_{0:k-1}] + h_k + \mathbb{E}[V_k \mid Y_{0:k-1}]) = Y_k - (H_k \hat{X}_k^- + h_k) ,$$

compte tenu que V_k et $Y_{0:k-1}$ sont indépendants.

Remarque 3.3 Par définition, toute fonction des variables $(Y_0, \dots, Y_{k-1}, Y_k)$ peut s'exprimer en fonction des variables $(Y_0, \dots, Y_{k-1}, I_k)$, et réciproquement. On en déduit que $(Y_{0:k-1}, I_k)$ contient exactement la même information que $Y_{0:k}$.

Lemme 3.4 Le processus $\{I_k\}$ est un processus gaussien à valeurs dans $\mathbb{R}^d$, appelé processus d'innovation. En particulier, le vecteur aléatoire I_k est gaussien, de moyenne nulle et de matrice de covariance

$$Q_k^I = H_k P_k^- H_k^* + Q_k^V ,$$

et indépendant de $Y_{0:k-1}$. Plus généralement, le vecteur aléatoire $(X_k - \hat{X}_k^-, I_k)$ est gaussien, de moyenne nulle et de matrice de covariance

$$\begin{pmatrix} P_k^- & P_k^- H_k^* \\ H_k P_k^- & H_k P_k^- H_k^* + Q_k^V \end{pmatrix} ,$$

et indépendant de $Y_{0:k-1}$.

PREUVE. D'après la Remarque 1.11, l'observation prédite $\mathbb{E}[Y_k \mid Y_{0:k-1}]$ dépend de façon affine des observations passées $(Y_0, Y_1, \dots, Y_{k-1})$, de sorte que l'innovation I_k dépend de façon affine des observations $(Y_0, Y_1, \dots, Y_k)$. On en déduit que le vecteur aléatoire $(I_0, I_1, \dots, I_k)$ est gaussien, comme transformation affine d'un vecteur aléatoire gaussien.

Toujours d'après la Remarque 1.11, l'état prédit $\hat{X}_k^- = \mathbb{E}[X_k \mid Y_{0:k-1}]$ dépend de façon affine des observations passées $(Y_0, \dots, Y_{k-1})$, de sorte que le vecteur aléatoire $(Y_0, \dots, Y_{k-1}, X_k - \hat{X}_k^-, I_k)$ dépend de façon affine du vecteur $(Y_0, Y_1, \dots, Y_k, X_k)$ formé de l'état courant X_k et des observations $(Y_0, Y_1, \dots, Y_k)$. On en déduit que le vecteur aléatoire $(Y_0, \dots, Y_{k-1}, X_k - \hat{X}_k^-, I_k)$ est gaussien, et donc a fortiori le vecteur aléatoire $(X_k - \hat{X}_k^-, I_k)$ est gaussien, comme transformation affine d'un vecteur aléatoire gaussien. Compte tenu que

$$\mathbb{E}[X_k - \hat{X}_k^- \mid Y_{0:k-1}] = 0 \quad \text{et} \quad \mathbb{E}[I_k \mid Y_{0:k-1}] = 0 ,$$

par définition, on en déduit que le vecteur aléatoire $(X_k - \hat{X}_k^-, I_k)$ est indépendant de $Y_{0:k-1}$. D'après l'équation (3.4), on a

$$I_k = Y_k - (H_k \hat{X}_k^- + h_k) = H_k (X_k - \hat{X}_k^-) + V_k , \tag{3.5}$$

et on en déduit que

$$\begin{aligned}
Q_k^I &= \mathbb{E}[I_k I_k^*] \\
&= \mathbb{E}[(H_k (X_k - \hat{X}_k^-) + V_k) (H_k (X_k - \hat{X}_k^-) + V_k)^*] \\
&= H_k \mathbb{E}[(X_k - \hat{X}_k^-) (X_k - \hat{X}_k^-)^*] H_k^* + \mathbb{E}[V_k V_k^*] \\
&\quad + \mathbb{E}[V_k (X_k - \hat{X}_k^-)^*] H_k^* + H_k \mathbb{E}[(X_k - \hat{X}_k^-) V_k^*] \\
&= H_k P_k^- H_k^* + Q_k^V .
\end{aligned}$$

Dans cette dernière égalité, on a utilisé le fait que $(X_k - \hat{X}_k^-)$ est indépendant de V_k , donc $\mathbb{E}[(X_k - \hat{X}_k^-) V_k^*] = 0$. On déduit également de (3.5) que

$$\begin{aligned}
\mathbb{E}[(X_k - \hat{X}_k^-) I_k^*] &= \mathbb{E}[(X_k - \hat{X}_k^-) (H_k (X_k - \hat{X}_k^-) + V_k)^*] \\
&= \mathbb{E}[(X_k - \hat{X}_k^-) (X_k - \hat{X}_k^-)^*] H_k^* + \mathbb{E}[(X_k - \hat{X}_k^-) V_k^*] \\
&= P_k^- H_k^* .
\end{aligned}$$

Dans cette dernière égalité, on a de nouveau utilisé le fait que $(X_k - \hat{X}_k^-)$ est indépendant de V_k , donc $\mathbb{E}[(X_k - \hat{X}_k^-) V_k^*] = 0$. $\square$

Remarque 3.5 Si la matrice de covariance Q_k^V est inversible, alors a fortiori la matrice de covariance $Q_k^I = H_k P_k^- H_k^* + Q_k^V$ est inversible, pour tout instant k .

Remarque 3.6 Compte tenu que la distribution de probabilité conditionnelle du vecteur aléatoire Y_k sachant $Y_{0:k-1}$ est gaussienne, de moyenne $H_k \hat{X}_k^- + h_k$ et de matrice de covariance Q_k^I , et pourvu que la matrice Q_k^I soit inversible, on obtient l'expression suivante

$$\begin{aligned}
L_n &= \prod_{k=0}^n \exp\left\{-\frac{1}{2} (Y_k - (H_k \hat{X}_k^- + h_k))^* (Q_k^I)^{-1} (Y_k - (H_k \hat{X}_k^- + h_k))\right\} \\
&= \prod_{k=0}^n \exp\left\{-\frac{1}{2} I_k^* (Q_k^I)^{-1} I_k\right\} ,
\end{aligned}$$

pour la vraisemblance du modèle, à une constante multiplicative près.

Théorème 3.7 (Filtre de Kalman) *On suppose que la matrice de covariance Q_k^V est inversible, pour tout instant k . Alors les suites $\{\hat{X}_k\}$ et $\{P_k\}$ vérifient les équations récurrentes suivantes*

$$\begin{aligned}
\hat{X}_k^- &= F_k \hat{X}_{k-1} + f_k , \\
P_k^- &= F_k P_{k-1} F_k^* + Q_k^W ,
\end{aligned}$$

et

$$\hat{X}_k = \hat{X}_k^- + K_k (Y_k - (H_k \hat{X}_k^- + h_k)) ,$$

$$P_k = (I - K_k H_k) P_k^- ,$$

où la matrice

$$K_k = P_k^- H_k^* [H_k P_k^- H_k^* + Q_k^V]^{-1} ,$$

est appelée gain de Kalman, et avec les initialisations

$$\hat{X}_0^- = \bar{X}_0 = \mathbb{E}[X_0] \quad \text{et} \quad P_0^- = Q_0^X = \text{cov}(X_0) .$$

Remarque 3.8 Au vu de l'expression développée

$$P_k = P_k^- - P_k^- H_k^* [H_k P_k^- H_k^* + Q_k^V]^{-1} H_k P_k^- ,$$

on vérifie aisément que $P_k \leq P_k^-$, c'est-à-dire que la matrice de covariance de l'erreur de filtrage est plus petite (au sens des matrices symétriques) que la matrice de covariance de l'erreur de prédiction, pour tout instant k .

Remarque 3.9 On vérifie que la suite $\{P_k\}$ ne dépend pas des observations : elle peut donc être pré-calculée, en particulier dans le cas simple où les coefficients $F_k = F$, $H_k = H$, $Q_k^W = Q_W$ et $Q_k^V = Q_V$ sont constants.

Remarque 3.10 Si les coefficients F_k , f_k et Q_k^W , et les coefficients H_k et h_k dépendent des observations passées $Y_{0:k-1}$, on a indiqué à la Remarque 3.2 que conditionnellement à $Y_{0:k-1}$ le couple (X_k, Y_k) forme conjointement un vecteur aléatoire gaussien, et on peut vérifier que la distribution de probabilité conditionnelle du vecteur aléatoire X_k sachant $Y_{0:k}$ est gaussienne, de moyenne $\hat{X}_k$ et de matrice de covariance P_k données par les équations du Théorème 3.7 avec des coefficients dépendant des observations.

PREUVE. On procède en plusieurs étapes. Le point central est la Proposition 1.8 qui sera constamment utilisée.

Expression de $\hat{X}_0$ et P_0 en fonction de $\hat{X}_0^-$ et P_0^- :

Le vecteur aléatoire (X_0, Y_0) est gaussien, de moyenne et de matrice de covariance données par

$$\begin{pmatrix} \hat{X}_0^- \\ H_0 \hat{X}_0^- + h_0 \end{pmatrix} \quad \text{et} \quad \begin{pmatrix} P_0^- & P_0^- H_0^* \\ H_0 P_0^- & H_0 P_0^- H_0^* + Q_0^V \end{pmatrix} ,$$

respectivement. D'après la Proposition 1.8, la distribution de probabilité conditionnelle du vecteur aléatoire X_0 sachant Y_0 est gaussienne, de moyenne

$$\hat{X}_0 = \hat{X}_0^- + P_0^- H_0^* [H_0 P_0^- H_0^* + Q_0^V]^{-1} (Y_0 - (H_0 \hat{X}_0^- + h_0)) ,$$

et de matrice de covariance

$$P_0 = P_0^- - P_0^- H_0^* [H_0 P_0^- H_0^* + Q_0^V]^{-1} H_0 P_0^- .$$

Expression de $\hat{X}_k^-$ et P_k^- en fonction de $\hat{X}_{k-1}$ et P_{k-1} :

Le vecteur aléatoire $(X_k, Y_0, \dots, Y_{k-1})$ est gaussien, et d'après la Proposition 1.8, la distribution de probabilité conditionnelle du vecteur aléatoire X_k sachant $Y_{0:k-1}$ est gaussienne, de moyenne $\hat{X}_k^-$ et de matrice de covariance P_k^- . D'après l'équation (3.3), c'est-à-dire

$$X_k = F_k X_{k-1} + f_k + W_k ,$$

on a

$$\hat{X}_k^- = \mathbb{E}[X_k | Y_{0:k-1}] = F_k \mathbb{E}[X_{k-1} | Y_{0:k-1}] + f_k + \mathbb{E}[W_k | Y_{0:k-1}] = F_k \hat{X}_{k-1} + f_k ,$$

compte tenu que W_k et Y_{k-1} sont indépendants. Par différence

$$X_k - \hat{X}_k^- = F_k (X_{k-1} - \hat{X}_{k-1}) + W_k ,$$

de sorte que

$$\begin{aligned} P_k^- &= \mathbb{E}[(X_k - \hat{X}_k^-) (X_k - \hat{X}_k^-)^*] \\ &= \mathbb{E}[(F_k (X_{k-1} - \hat{X}_{k-1}) + W_k) (F_k (X_{k-1} - \hat{X}_{k-1}) + W_k)^*] \\ &= F_k \mathbb{E}[(X_{k-1} - \hat{X}_{k-1}) (X_{k-1} - \hat{X}_{k-1})^*] F_k^* + \mathbb{E}[W_k W_k^*] \\ &\quad + \mathbb{E}[W_k (X_{k-1} - \hat{X}_{k-1})^*] F_k^* + F_k \mathbb{E}[(X_{k-1} - \hat{X}_{k-1}) W_k^*] \\ &= F_k P_{k-1} F_k^* + Q_k^W . \end{aligned}$$

Dans cette dernière égalité, on a utilisé le fait que $(X_{k-1} - \hat{X}_{k-1})$ est indépendant de W_k , donc $\mathbb{E}[(X_{k-1} - \hat{X}_{k-1}) W_k^*] = 0$.

Expression de $\hat{X}_k$ et P_k en fonction de $\hat{X}_k^-$ et P_k^- :

Le vecteur aléatoire $(X_k, Y_0, \dots, Y_k)$ est gaussien, et d'après la Proposition 1.8, la distribution de probabilité conditionnelle du vecteur aléatoire X_k sachant $Y_{0:k}$ est gaussienne, de moyenne $\hat{X}_k$ et de matrice de covariance déterministe P_k . D'après la Remarque 3.3, on a

$$\begin{aligned} \hat{X}_k &= \mathbb{E}[X_k | Y_{0:k}] \\ &= \hat{X}_k^- + \mathbb{E}[X_k - \hat{X}_k^- | Y_{0:k}] \\ &= \hat{X}_k^- + \mathbb{E}[X_k - \hat{X}_k^- | Y_{0:k-1}, I_k] \\ &= \hat{X}_k^- + \mathbb{E}[X_k - \hat{X}_k^- | I_k] , \end{aligned}$$

compte tenu que les vecteurs aléatoires $(X_k - \hat{X}_k^-)$ et I_k sont indépendants de $Y_{0:k-1}$, d'après le Lemme 3.4. Par différence

$$X_k - \hat{X}_k = (X_k - \hat{X}_k^-) - (\hat{X}_k - \hat{X}_k^-) = (X_k - \hat{X}_k^-) - \mathbb{E}[X_k - \hat{X}_k^- | I_k] ,$$

de sorte que

$$\begin{aligned} P_k &= \mathbb{E}[(X_k - \hat{X}_k)(X_k - \hat{X}_k)^*] \\ &= \mathbb{E}[(X_k - \hat{X}_k^-) - \mathbb{E}[X_k - \hat{X}_k^- | I_k]]((X_k - \hat{X}_k^-) - \mathbb{E}[X_k - \hat{X}_k^- | I_k])^*] . \end{aligned}$$

Pour calculer la moyenne conditionnelle et la matrice de covariance conditionnelle du vecteur aléatoire X_k sachant $Y_{0:k}$, il suffit donc de calculer la moyenne conditionnelle et la matrice de covariance conditionnelle du vecteur aléatoire $(X_k - \hat{X}_k^-)$ sachant I_k . En d'autres termes, pour estimer l'état caché X_k au vu des observations $Y_{0:k}$ il suffit d'estimer de quelle quantité, exprimée en fonction de l'écart I_k constaté entre la nouvelle observation et l'observation prédite, corriger l'estimation prédite $\hat{X}_k^-$. C'est de cette propriété que découle la forme récursive du filtre de Kalman. D'après le Lemme 3.4, le vecteur aléatoire $(X_k - \hat{X}_k^-, I_k)$ est gaussien, de moyenne nulle et de matrice de covariance

$$\begin{pmatrix} P_k^- & P_k^- H_k^* \\ H_k P_k^- & H_k P_k^- H_k^* + Q_k^V \end{pmatrix} .$$

Si la matrice Q_k^V est inversible, alors a fortiori la matrice $Q_k^I = H_k P_k^- H_k^* + Q_k^V$ est inversible, et d'après la Proposition 1.8 on a immédiatement

$$\hat{X}_k = \hat{X}_k^- + P_k^- H_k^* [H_k P_k^- H_k^* + Q_k^V]^{-1} I_k ,$$

et

$$P_k = P_k^- - P_k^- H_k^* [H_k P_k^- H_k^* + Q_k^V]^{-1} H_k P_k^- ,$$

ce qui termine la démonstration. $\square$

3.3 Lisseur de Kalman

On dispose désormais de l'information

$$Y_{0:n} = (Y_0, Y_1, \dots, Y_n) ,$$

et l'objectif est d'estimer de façon optimale le vecteur aléatoire X_k à partir de $Y_{0:n}$, pour un instant k intermédiaire entre l'instant initial 0 et l'instant final n . Si on adopte le critère du minimum de variance, il s'agit d'après la Section 1.2 de calculer la distribution de probabilité conditionnelle du vecteur aléatoire X_k sachant $Y_{0:n}$. Comme le cadre est gaussien, il suffit de calculer la moyenne et la matrice de covariance

$$\hat{X}_k^n = \mathbb{E}[X_k | Y_{0:n}] \quad \text{et} \quad P_k^n = \mathbb{E}[(X_k - \hat{X}_k^n)(X_k - \hat{X}_k^n)^* | Y_{0:n}] ,$$

et clairement, $\hat{X}_n^n = \hat{X}_n$ et $P_n^n = P_n$ pour $k = n$. D'après la Remarque 1.10, la matrice de covariance conditionnelle P_k^n ne dépend pas des observations, c'est-à-dire que

$$P_k^n = \mathbb{E}[(X_k - \hat{X}_k^n)(X_k - \hat{X}_k^n)^*] .$$

Théorème 3.11 (Lisseur de Kalman (formulation de Rauch–Tung–Striebel)) *On suppose que les matrices de covariance Q_k^W et Q_k^V sont inversibles, pour tout instant k . Alors les suites $\{\hat{X}_k^n\}$ et $\{P_k^n\}$ vérifient les équations récurrentes rétrogrades suivantes*

$$\hat{X}_{k-1}^n = \hat{X}_{k-1} + L_k (\hat{X}_k^n - \hat{X}_k^-) ,$$

$$P_{k-1}^n = P_{k-1} + L_k (P_k^n - P_k^-) L_k^* ,$$

avec la matrice de gain

$$L_k = P_{k-1} F_k^* (P_k^-)^{-1} ,$$

et avec les initialisations

$$\hat{X}_n^n = \hat{X}_n \quad \text{et} \quad P_n^n = P_n .$$

Remarque 3.12 Au vu de l'expression développée

$$P_{k-1} - L_k P_k^- L_k^* = P_{k-1} - P_{k-1} F_k^* [F_k P_{k-1} F_k^* + Q_k^W]^{-1} F_k P_{k-1} ,$$

on vérifie que la matrice $P_{k-1} - L_k P_k^- L_k^*$ est semi-définie positive, pour tout instant k . On en déduit par récurrence arrière que la matrice P_k^n (telle qu'elle est définie par l'équation rétrograde de l'énoncé) est semi-définie positive, pour tout instant k . Par définition, $P_n^n = P_n$, c'est-à-dire que la relation est vraie au rang $k = n$. Si la relation est vraie au rang k , c'est-à-dire si la matrice P_k^n est semi-définie positive, alors nécessairement la matrice

$$P_{k-1}^n = P_{k-1} + L_k (P_k^n - P_k^-) L_k^* = (P_{k-1} - L_k P_k^- L_k^*) + L_k P_k^n L_k^* ,$$

aussi est semi-définie positive, c'est-à-dire que la relation est vraie au rang $(k-1)$.

Remarque 3.13 On vérifie par récurrence arrière que $P_k^n \leq P_k$, c'est-à-dire que la matrice de covariance de l'erreur de lissage est plus petite (au sens des matrices symétriques) que la matrice de covariance de l'erreur de filtrage, pour tout instant k . Par définition $P_n^n = P_n$, c'est-à-dire que la relation est vraie au rang $k = n$. Si la relation est vraie au rang k , c'est-à-dire si $P_k^n \leq P_k$, alors nécessairement $P_k^n \leq P_k^-$ compte tenu que $P_k \leq P_k^-$ d'après la Remarque 3.8. En d'autres termes, la différence $(P_k^n - P_k^-)$ est semi-définie négative, de sorte que la différence

$$P_{k-1}^n - P_{k-1} = L_k (P_k^n - P_k^-) L_k^* ,$$

aussi est semi-définie négative. En d'autres termes, $P_{k-1}^n \leq P_{k-1}$, c'est-à-dire que la relation est vraie au rang $(k-1)$.

PREUVE. On remarque que le vecteur aléatoire Y_k peut s'exprimer comme transformation affine du vecteur aléatoire (X_k, V_k) , et donc a fortiori comme transformation affine du vecteur aléatoire $(Y_{0:k-1}, X_k - \hat{X}_k^-, V_k)$. De même, le vecteur aléatoire Y_{k+p} peut s'exprimer comme transformation affine du vecteur aléatoire (X_{k+p}, V_{k+p}) , et par transitivité comme transformation affine du vecteur aléatoire $(X_k, W_{k+1}, \dots, W_{k+p}, V_{k+p})$, et donc a fortiori comme transformation affine du vecteur aléatoire $(Y_{0:k-1}, X_k - \hat{X}_k^-, W_{k+1}, \dots, W_{k+p}, V_{k+p})$. On en déduit que le vecteur aléatoire $Y_{0:n} = (Y_{0:k-1}, Y_k, \dots, Y_n)$ peut s'exprimer comme transformation affine du vecteur

aléatoire $(Y_{0:k-1}, X_k - \hat{X}_k^-, Z_{k+1:n})$ où $Z_{k+1:n} = (W_{k+1}, \dots, W_n, V_k, V_{k+1}, \dots, V_n)$ par définition. Les vecteurs aléatoires $Y_{0:k-1}$, $X_k - \hat{X}_k^-$ et $Z_{k+1:n}$ sont mutuellement indépendants, et il résulte de la Remarque 1.12 que

$$\begin{aligned}
U_{k-1}^n &= \mathbb{E}[X_{k-1} \mid Y_{0:k-1}, X_k - \hat{X}_k^-, Z_{k+1:n}] \\
&= \hat{X}_{k-1} + \mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid Y_{0:k-1}, X_k - \hat{X}_k^-, Z_{k+1:n}] \\
&= \hat{X}_{k-1} + \mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid Y_{0:k-1}] + \mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid X_k - \hat{X}_k^-] \\
&\quad + \mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid Z_{k+1:n}] \\
&= \hat{X}_{k-1} + \mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid X_k - \hat{X}_k^-] ,
\end{aligned}$$

compte tenu que $\mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid Y_{0:k-1}] = 0$ par définition, et où on a utilisé dans la dernière égalité le fait que $(X_{k-1} - \hat{X}_{k-1})$ est indépendant de $Z_{k+1:n}$, donc $\mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid Z_{k+1:n}] = 0$. Par différence

$$\begin{aligned}
X_{k-1} - U_{k-1}^n &= (X_{k-1} - \hat{X}_{k-1}) - (U_{k-1}^n - \hat{X}_{k-1}) \\
&= (X_{k-1} - \hat{X}_{k-1}) - \mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid X_k - \hat{X}_k^-] ,
\end{aligned}$$

de sorte que

$$\begin{aligned}
&\mathbb{E}[(X_{k-1} - U_{k-1}^n)(X_{k-1} - U_{k-1}^n)^*] \\
&= \mathbb{E}[(X_{k-1} - \hat{X}_{k-1}) - \mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid X_k - \hat{X}_k^-]) \\
&\quad ((X_{k-1} - \hat{X}_{k-1}) - \mathbb{E}[X_{k-1} - \hat{X}_{k-1} \mid X_k - \hat{X}_k^-])^*] .
\end{aligned}$$

Pour calculer la moyenne conditionnelle et la matrice de covariance conditionnelle du vecteur aléatoire X_{k-1} sachant $(Y_{0:k-1}, X_k - \hat{X}_k^-, Z_{k+1:n})$, il suffit donc de calculer la moyenne conditionnelle et la matrice de covariance conditionnelle du vecteur aléatoire $(X_{k-1} - \hat{X}_{k-1})$ sachant $(X_k - \hat{X}_k^-)$. D'après la Remarque 1.11, l'état estimé $\hat{X}_{k-1} = \mathbb{E}[X_{k-1} \mid Y_{0:k-1}]$ et l'état prédit $\hat{X}_k^- = \mathbb{E}[X_k \mid Y_{0:k-1}]$ dépendent de façon affine des observations passées $(Y_0, \dots, Y_{k-1})$, de sorte que le vecteur aléatoire $(X_{k-1} - \hat{X}_{k-1}, X_k - \hat{X}_k^-)$ dépend de façon affine du vecteur aléatoire $(Y_0, \dots, Y_{k-1}, X_{k-1}, X_k)$. On en déduit que le vecteur aléatoire $(X_{k-1} - \hat{X}_{k-1}, X_k - \hat{X}_k^-)$ est gaussien, comme transformation affine d'un vecteur aléatoire gaussien. Par différence

$$X_k - \hat{X}_k^- = F_k(X_{k-1} - \hat{X}_{k-1}) + W_k ,$$

de sorte que

$$\begin{aligned}
& \mathbb{E}[(X_{k-1} - \hat{X}_{k-1})(X_k - \hat{X}_k)^*] \\
&= \mathbb{E}[(X_{k-1} - \hat{X}_{k-1})(F_k(X_{k-1} - \hat{X}_{k-1}) + W_k)^*] \\
&= \mathbb{E}[(X_{k-1} - \hat{X}_{k-1})(X_{k-1} - \hat{X}_{k-1})^*] F_k^* + \mathbb{E}[(X_{k-1} - \hat{X}_{k-1}) W_k^*] \\
&= P_{k-1} F_k^* .
\end{aligned}$$

Dans cette dernière égalité, on a utilisé le fait que $(X_{k-1} - \hat{X}_{k-1})$ et W_k sont indépendants, donc $\mathbb{E}[(X_{k-1} - \hat{X}_{k-1}) W_k^*] = 0$. On en déduit que le vecteur aléatoire gaussien $(X_{k-1} - \hat{X}_{k-1}, X_k - \hat{X}_k^-)$ est de moyenne nulle et de matrice de covariance

$$\begin{pmatrix} P_{k-1} & P_{k-1} F_k^* \\ F_k P_{k-1} & P_k^- \end{pmatrix} .$$

Par hypothèse la matrice P_k^- est inversible, et d'après la Proposition 1.8 on a immédiatement

$$U_{k-1}^n = \hat{X}_{k-1} + P_{k-1} F_k^* (P_k^-)^{-1} (X_k - \hat{X}_k^-) = \hat{X}_{k-1} + L_k (X_k - \hat{X}_k^-) ,$$

et

$$\mathbb{E}[(X_{k-1} - U_{k-1}^n)(X_{k-1} - U_{k-1}^n)^*] = P_{k-1} - P_{k-1} F_k^* (P_k^-)^{-1} F_k P_{k-1} = P_{k-1} - L_k P_k^- L_k^* .$$

On rappelle que $(Y_{0:k-1}, X_k - \hat{X}_k^-, Z_{k+1:n})$ contient davantage d'information que $Y_{0:n}$, de sorte que

$$\hat{X}_{k-1}^n = \mathbb{E}[X_{k-1} | Y_{0:n}] = \mathbb{E}[U_{k-1}^n | Y_{0:n}] = \hat{X}_{k-1} + L_k (\hat{X}_k^n - \hat{X}_k^-) .$$

Par différence

$$X_{k-1} - \hat{X}_{k-1}^n = (X_{k-1} - U_{k-1}^n) + (U_{k-1}^n - \hat{X}_{k-1}^n) \quad \text{et} \quad U_{k-1}^n - \hat{X}_{k-1}^n = L_k (X_k - \hat{X}_k^n) ,$$

de sorte que

$$\begin{aligned}
P_{k-1}^n &= \mathbb{E}[(X_{k-1} - \hat{X}_{k-1}^n)(X_{k-1} - \hat{X}_{k-1}^n)^*] \\
&= \mathbb{E}[(X_{k-1} - U_{k-1}^n + U_{k-1}^n - \hat{X}_{k-1}^n)((X_{k-1} - U_{k-1}^n) + (U_{k-1}^n - \hat{X}_{k-1}^n))^*] \\
&= \mathbb{E}[(X_{k-1} - U_{k-1}^n)(X_{k-1} - U_{k-1}^n)^*] + \mathbb{E}[(U_{k-1}^n - \hat{X}_{k-1}^n)(U_{k-1}^n - \hat{X}_{k-1}^n)^*] \\
&\quad + \mathbb{E}[(U_{k-1}^n - \hat{X}_{k-1}^n)(X_{k-1} - U_{k-1}^n)^*] + \mathbb{E}[(X_{k-1} - U_{k-1}^n)(U_{k-1}^n - \hat{X}_{k-1}^n)^*] \\
&= (P_{k-1} - L_k P_k^- L_k^*) + L_k P_k^n L_k^* .
\end{aligned}$$

Dans cette dernière égalité, on a utilisé le fait que

- $(U_{k-1}^n - \hat{X}_{k-1}^n)$ dépend de $(Y_{0:k-1}, X_k - \hat{X}_k^-, Z_{k+1:n})$,
- et $\mathbb{E}[X_{k-1} - U_{k-1}^n \mid Y_{0:k-1}, X_k - \hat{X}_k^-, Z_{k+1:n}] = 0$ par définition,

donc $\mathbb{E}[(X_{k-1} - U_{k-1}^n)(U_{k-1}^n - \hat{X}_{k-1}^n)^*] = 0$. □

Proposition 3.14 *La matrice de corrélation C_k^n entre les erreurs de lissage $(X_{k-1} - \hat{X}_{k-1}^n)$ et $(X_k - \hat{X}_k^n)$ à deux instants successifs vérifie la relation suivante*

$$C_k^n = \mathbb{E}[(X_{k-1} - \hat{X}_{k-1}^n)(X_k - \hat{X}_k^n)^*] = L_k P_k^n.$$

PREUVE. On rappelle que

$$X_{k-1} - \hat{X}_{k-1}^n = (X_{k-1} - U_{k-1}^n) + L_k (X_k - \hat{X}_k^n),$$

de sorte que

$$\begin{aligned} C_k^n &= \mathbb{E}[(X_{k-1} - \hat{X}_{k-1}^n)(X_k - \hat{X}_k^n)^*] \\ &= \mathbb{E}[(X_{k-1} - U_{k-1}^n)(X_k - \hat{X}_k^n)^*] + L_k \mathbb{E}[(X_k - \hat{X}_k^n)(X_k - \hat{X}_k^n)^*] \\ &= L_k P_k^n. \end{aligned}$$

Dans cette dernière égalité, on a utilisé le fait que

- $(X_k - \hat{X}_k^n) = (X_k - \hat{X}_k^-) + (\hat{X}_k^- - \hat{X}_{k-1}^n)$ dépend de $(Y_{0:k-1}, X_k - \hat{X}_k^-, Z_{k+1:n})$,
- et $\mathbb{E}[X_{k-1} - U_{k-1}^n \mid Y_{0:k-1}, X_k - \hat{X}_k^-, Z_{k+1:n}] = 0$ par définition,

donc $\mathbb{E}[(X_{k-1} - U_{k-1}^n)(X_k - \hat{X}_k^n)^*] = 0$. □

Il existe plusieurs formulations équivalentes pour le lissage de Kalman, et on présente ci-dessous une formulation alternative, qui ne fait pas l'hypothèse que la matrice de covariance Q_k^W est inversible, et qui n'utilise pas l'inverse de la matrice de covariance P_k^- .

Pour tout $k = 1, \dots, n$, on introduit les variables

$$r_{k-1} = F_k^* (P_k^-)^{-1} (\hat{X}_k^n - \hat{X}_k^-) \quad \text{et} \quad \Pi_{k-1} = -F_k^* (P_k^-)^{-1} (P_k^n - P_k^-) (P_k^-)^{-1} F_k,$$

et on pose $r_n = 0$ et $\Pi_n = 0$ par convention. On rappelle que la différence $(P_k^n - P_k^-)$ est semi-définie négative, de sorte que la matrice Π_{k-1} est semi-définie positive. Clairement

$$\begin{aligned} \hat{X}_k^n &= \hat{X}_k + L_{k+1} (\hat{X}_{k+1}^n - \hat{X}_{k+1}^-) \\ &= \hat{X}_k + P_k F_{k+1}^* (P_{k+1}^-)^{-1} (\hat{X}_{k+1}^n - \hat{X}_{k+1}^-) \\ &= \hat{X}_k + P_k r_k, \end{aligned}$$

et de même

$$\begin{aligned}
P_k^n &= P_k + L_{k+1} (P_{k+1}^n - P_{k+1}^-) L_{k+1}^* \\
&= P_k + P_k F_{k+1}^* (P_{k+1}^-)^{-1} (P_{k+1}^n - P_{k+1}^-) (P_{k+1}^-)^{-1} F_{k+1} P_k \\
&= P_k - P_k \Pi_k P_k ,
\end{aligned}$$

de sorte que le lisseur de Kalman $\hat{X}_k^n$ et la matrice de covariance d'erreur de lissage P_k^n s'expriment comme

$$\hat{X}_k^n = \hat{X}_k + P_k r_k \quad \text{et} \quad P_k^n = P_k - P_k \Pi_k P_k , \quad (3.6)$$

en fonction du filtre de Kalman $\hat{X}_k$, de la matrice de covariance d'erreur de filtrage P_k , et des variables r_k et Π_k , respectivement. On pose

$$\Xi_k = [H_k P_k^- H_k^* + Q_k^V]^{-1} \quad \text{de sorte que} \quad K_k = P_k^- H_k^* \Xi_k ,$$

pour tout $k = 0, 1, \dots, n$.

Théorème 3.15 (Lisseur de Kalman (formulation de Fraser–Potter)) *On suppose que la matrice de covariance Q_k^V est inversible, pour tout instant k . Alors les suites $\{\hat{X}_k^n\}$ et $\{P_k^n\}$ sont données par les expressions suivantes*

$$\hat{X}_k^n = \hat{X}_k + P_k r_k \quad \text{et} \quad P_k^n = P_k - P_k \Pi_k P_k ,$$

où les suites $\{r_k\}$ et $\{\Pi_k\}$ vérifient les équations récurrentes rétrogrades suivantes

$$r_k^- = (I - K_k H_k)^* r_k + H_k^* \Xi_k (Y_k - (H_k \hat{X}_k^- + h_k)) ,$$

$$\Pi_k^- = (I - K_k H_k)^* \Pi_k (I - K_k H_k) + H_k^* \Xi_k H_k ,$$

et

$$r_{k-1} = F_k^* r_k^- \quad \text{et} \quad \Pi_{k-1}^n = F_k^* \Pi_k^- F_k ,$$

avec les initialisations

$$r_n = 0 \quad \text{et} \quad \Pi_n = 0 .$$

PREUVE. On rappelle que

$$P_k = (I - K_k H_k) P_k^- = P_k^- (I - K_k H_k)^* ,$$

de sorte que

$$P_k (P_k^-)^{-1} = I - K_k H_k \quad \text{et} \quad (P_k^-)^{-1} P_k = (I - K_k H_k)^* , \quad (3.7)$$

et par définition

$$K_k = P_k^- H_k^* \Xi_k ,$$

de sorte que

$$(P_k^-)^{-1} K_k = H_k^* \Xi_k . \quad (3.8)$$

D'après l'étape de correction du filtre de Kalman, on a

$$\hat{X}_k = \hat{X}_k^- + K_k (Y_k - (H_k \hat{X}_k^- + h_k)) ,$$

de sorte que

$$\hat{X}_k^n - \hat{X}_k^- = \hat{X}_k - \hat{X}_k^- + P_k r_k = K_k (Y_k - (H_k \hat{X}_k^- + h_k)) + P_k r_k ,$$

et en reportant cette expression dans la définition de la variable r_{k-1} , on obtient

$$\begin{aligned} r_{k-1} &= F_k^* (P_k^-)^{-1} (\hat{X}_k^n - \hat{X}_k^-) \\ &= F_k^* (P_k^-)^{-1} [P_k r_k + K_k (Y_k - (H_k \hat{X}_k^- + h_k))] \\ &= F_k^* [(I - K_k H_k)^* r_k + H_k^* \Xi_k (Y_k - (H_k \hat{X}_k^- + h_k))] , \end{aligned}$$

compte tenu des identités (3.7) et (3.8). D'après l'étape de correction du filtre de Kalman, on a

$$P_k = P_k^- - P_k^- H_k^* \Xi_k H_k P_k^- ,$$

de sorte que

$$P_k^n - P_k^- = P_k - P_k^- - P_k \Pi_k P_k = -P_k^- H_k^* \Xi_k H_k P_k^- - P_k \Pi_k P_k ,$$

et en reportant cette expression dans la définition de la variable Π_{k-1} , on obtient

$$\begin{aligned} \Pi_{k-1} &= -F_k^* (P_k^-)^{-1} (P_k^n - P_k^-) (P_k^-)^{-1} F_k \\ &= F_k^* (P_k^-)^{-1} [P_k \Pi_k P_k + P_k^- H_k^* \Xi_k H_k P_k^-] (P_k^-)^{-1} F_k \\ &= F_k^* [(I - K_k H_k)^* \Pi_k (I - K_k H_k) + H_k^* \Xi_k H_k] F_k , \end{aligned}$$

compte tenu de l'identité (3.8). □

Les deux formulations partagent la même phase aller, qui comprend le calcul du filtre de Kalman $\hat{X}_k$ et de la matrice de covariance d'erreur de filtrage P_k . Une condition nécessaire pour cette phase aller est l'inversibilité de la matrice de covariance $Q_k^I = H_k P_k^- H_k^* + Q_k^V$ de dimension $d \times d$, et une condition suffisante est l'inversibilité de la matrice de covariance Q_k^V , une donnée du problème. Le calcul de la matrice inverse n'est pas nécessaire, mais la résolution de systèmes linéaires de dimension d de la forme $Q_k^I y = b$ est requise, et passe par exemple par la décomposition de Cholesky de la matrice Q_k^I .

Dans la formulation de Rauch–Tung–Striebel, qui fait l'objet du Théorème 3.11, une condition nécessaire pour la phase retour est l'inversibilité de la matrice de covariance $P_k^- = F_k P_{k-1} F_k^* + Q_k^W$ de dimension $m \times m$, et une condition suffisante est l'inversibilité de la matrice de covariance Q_k^W , une donnée du problème. Le calcul de la matrice inverse n'est pas nécessaire, mais la

résolution de systèmes linéaires de dimension m de la forme $P_k^- x = b$ est requise, et passe par exemple par la décomposition de Cholesky de la matrice P_k^- . L'équation récurrente rétrograde pour le calcul du lisseur $\hat{X}_{k-1}^n$ utilise les valeurs numériques du filtre $\hat{X}_{k-1}$ et de la matrice de covariance d'erreur de filtrage P_{k-1} (à partir desquelles il est facile de reconstruire les valeurs numériques du prédicteur $\hat{X}_k^-$ et de la matrice de covariance d'erreur de prédiction P_k^-). Ces valeurs numériques sont calculées dans la phase aller, et doivent donc être conservées en mémoire pour être utilisées dans la phase retour. En revanche, cette équation récurrente rétrograde pour le calcul du lisseur $\hat{X}_{k-1}^n$ n'utilise ni la valeur numérique de l'observation Y_k ni celle de l'innovation $I_k = Y_k - (H_k \hat{X}_k^- + h_k)$.

Dans la formulation de Fraser–Potter, qui fait l'objet du Théorème 3.15, il n'y a pas de condition nécessaire d'inversibilité pour la phase retour qui ne soit pas déjà nécessaire pour la phase aller. Les expressions (3.6) pour le lisseur $\hat{X}_k^n$ et pour la matrice de covariance d'erreur de lissage P_k^n utilisent les valeurs numériques du filtre $\hat{X}_k$ et de la matrice de covariance d'erreur de filtrage P_k . Ces valeurs numériques sont calculées dans la phase aller, et doivent donc être conservées en mémoire pour être utilisées dans la phase retour. L'équation récurrente rétrograde pour le calcul de la variable r_k utilise la valeur numérique de l'observation Y_k ou de manière équivalente celle de l'innovation $I_k = Y_k - (H_k \hat{X}_k^- + h_k)$. Ces valeurs numériques sont calculées dans la phase aller, et doivent donc être conservées en mémoire pour être utilisées dans la phase retour.

En conclusion :

- les deux formulations requièrent dans la phase aller une même condition d'inversibilité et l'inversion de systèmes linéaires de dimension d ,
- la formulation de Rauch–Tung–Striebel requiert dans la phase retour une condition d'inversibilité supplémentaire et l'inversion de systèmes linéaires de dimension m , tandis que la formulation de Fraser–Potter ne requiert aucune condition d'inversibilité supplémentaire,
- les deux formulations utilisent dans la phase retour les valeurs numériques du filtre et de la matrice de covariance d'erreur de filtrage — ces valeurs numériques sont calculées dans la phase aller, et doivent donc être conservées en mémoire pour être utilisées dans la phase retour,
- la formulation de Fraser–Potter utilise dans la phase retour la valeur numérique de l'observation ou de manière équivalente celle de l'innovation, tandis que la formulation de Rauch–Tung–Striebel n'utilise aucune de ces valeurs numériques — ces valeurs numériques sont calculées dans la phase aller, et doivent donc être conservées en mémoire pour être utilisées dans la phase retour.

Remarque 3.16 Il est également possible d'obtenir une équation récurrente pour le lisseur, dans le sens direct (et pas dans le sens rétrograde) et autonome (ne faisant pas intervenir ni le filtre ni la matrice de covariance de l'erreur de filtrage). Par différence, on obtient

$$\begin{aligned} \hat{X}_k^n - F_k \hat{X}_{k-1}^n &= \hat{X}_k + P_k r_k - F_k (\hat{X}_{k-1} + P_{k-1} r_{k-1}) \\ &= (\hat{X}_k - F_k \hat{X}_{k-1}) + (P_k r_k - F_k P_{k-1} r_{k-1}) . \end{aligned}$$

D'après l'étape de correction du filtre de Kalman, on a

$$\widehat{X}_k - F_k \widehat{X}_{k-1} = \widehat{X}_k - \widehat{X}_k^- = K_k (Y_k - (H_k \widehat{X}_k^- + h_k)) ,$$

et on remarque que

$$\begin{aligned} P_k^- r_k^- &= P_k^- [(I - K_k H_k)^* r_k + H_k^* \Xi_k (Y_k - (H_k \widehat{X}_k^- + h_k))] \\ &= P_k r_k + K_k (Y_k - (H_k \widehat{X}_k^- + h_k)) , \end{aligned}$$

compte tenu des identités

$$P_k^- (I - K_k H_k)^* = P_k \quad \text{et} \quad P_k^- H_k^* \Xi_k = K_k ,$$

de sorte que

$$(\widehat{X}_k - F_k \widehat{X}_{k-1}) + (P_k r_k - P_k^- r_k^-) = 0 .$$

D'autre part

$$\begin{aligned} P_k r_k - F_k P_{k-1} r_{k-1} &= P_k r_k - F_k P_{k-1} F_k^* r_k^- \\ &= P_k r_k - (P_k^- - Q_k^W) r_k^- \\ &= (P_k r_k - P_k^- r_k^-) + Q_k^W r_k^- . \end{aligned}$$

On en déduit que

$$\begin{aligned} \widehat{X}_k^n &= F_k \widehat{X}_{k-1}^n + (\widehat{X}_k - F_k \widehat{X}_{k-1}) + (P_k r_k - F_k P_{k-1} r_{k-1}) \\ &= F_k \widehat{X}_{k-1}^n + (\widehat{X}_k - F_k \widehat{X}_{k-1}) + (P_k r_k - P_k^- r_k^-) + Q_k^W r_k^- \\ &= F_k \widehat{X}_{k-1}^n + Q_k^W r_k^- , \end{aligned}$$

c'est-à-dire qu'on obtient une équation récurrente, dans le sens direct, et faisant seulement intervenir la variable r_k^- .

Chapitre 4

Extensions aux systèmes non-linéaires

On considère une suite d'états cachés $\{X_k\}$ à valeurs dans $\mathbb{R}^m$, vérifiant

$$X_k = b_k(X_{k-1}) + \sigma_k(X_{k-1}) W_k , \quad (4.1)$$

où $\{W_k\}$ prend ses valeurs dans $\mathbb{R}^p$, et une suite d'observations $\{Y_k\}$ à valeurs dans $\mathbb{R}^d$, vérifiant

$$Y_k = h_k(X_k) + V_k , \quad (4.2)$$

et on suppose que

- la condition initiale X_0 est gaussienne, de moyenne $\bar{X}_0$ et de matrice de covariance Q_0^X ,
- la suite $\{W_k\}$ est un bruit blanc gaussien, de matrice de covariance identité,
- la suite $\{V_k\}$ est un bruit blanc gaussien, de matrice de covariance Q_k^V inversible,
- les suites $\{W_k\}$ et $\{V_k\}$ et la condition initiale X_0 sont mutuellement indépendants.

La signification du modèle (4.1) est la suivante

- même si l'état $X_{k-1} = x$ est connu exactement à l'instant $(k-1)$, on peut seulement dire que l'état X_k à l'instant k est incertain, et distribué comme un vecteur aléatoire gaussien, de moyenne $b_k(x)$ et de matrice de covariance $\sigma_k(x) \sigma_k^*(x)$.

La plupart des propriétés obtenues à la Section 3.1 ne sont pas vraies pour le système décrit par les équations (4.1) et (4.2). En particulier, le processus $\{Z_k = (X_k, Y_k)\}$ n'est pas gaussien (ni même conditionnellement gaussien), et les moments conditionnels de X_k sachant $Y_{0:k}$ ne peuvent pas être calculés de manière simple. Deux approches pragmatiques sont présentées dans ce chapitre, qui permettent d'obtenir des estimateurs sous-optimaux, c'est-à-dire qui n'atteignent pas nécessairement le minimum de l'erreur quadratique moyenne, mais qui sont néanmoins très largement utilisés en pratique. La première approche présentée à la Section 4.1 repose sur des

techniques de linéarisation, et donne lieu au filtre de Kalman linéarisé et au filtre de Kalman étendu. La deuxième approche présentée à la Section 4.2 repose sur des techniques d'approximation gaussienne et de quadrature numérique, et donne lieu au filtre de Kalman dit *unscented*. Dans les chapitres suivants, on abandonnera ce point de vue de linéarisation ou d'approximation gaussienne, et on s'attachera d'abord à caractériser la distribution de probabilité conditionnelle de l'état caché sachant les observations, soit par une représentation probabiliste, soit par une équation récurrente dans l'espace des distributions de probabilité, et on proposera ensuite des approximations numériques reposant sur méthodes de simulation de type Monte Carlo.

4.1 Filtre de Kalman linéarisé, filtre de Kalman étendu

On considère le système non linéaire

$$\begin{aligned} X_k &= b_k(X_{k-1}) + \sigma_k(X_{k-1}) W_k , \\ Y_k &= h_k(X_k) + V_k , \end{aligned} \tag{4.3}$$

et on suppose que les fonctions b_k et h_k sont dérivables. En linéarisant le système (4.3) autour d'une suite déterministe donnée, ou bien autour de l'estimateur courant, on peut obtenir des algorithmes sous-optimaux, qui sont décrits ci-dessous.

Filtre de Kalman linéarisé

On se donne une suite (déterministe) $\{\bar{x}_k\}$ à valeurs dans $\mathbb{R}^m$, appelée *trajectoire nominale* (on peut prendre par exemple $\bar{x}_k$ comme une approximation de la moyenne de X_k). La méthode consiste à linéariser les fonctions b_k et σ_k autour de $\bar{x}_{k-1}$, c'est-à-dire

$$b_k(x) \simeq b_k(\bar{x}_{k-1}) + b'_k(\bar{x}_{k-1})(x - \bar{x}_{k-1}) \quad \text{et} \quad \sigma_k(x) \simeq \sigma_k(\bar{x}_{k-1}) ,$$

et la fonction h_k autour de $\bar{x}_k$, c'est-à-dire

$$h_k(x) \simeq h_k(\bar{x}_k) + h'_k(\bar{x}_k)(x - \bar{x}_k) .$$

Le système non-linéaire (4.3) est alors remplacé par le système linéaire gaussien

$$X_k = F_k^L X_{k-1} + f_k^L + W_k^L ,$$

$$Y_k = H_k^L X_k + h_k^L + V_k ,$$

avec

$$F_k^L = b'_k(\bar{x}_{k-1}) \quad \text{et} \quad f_k^L = -b'_k(\bar{x}_{k-1}) \bar{x}_{k-1} + b_k(\bar{x}_{k-1}) ,$$

et avec

$$H_k^L = h'_k(\bar{x}_k) \quad \text{et} \quad h_k^L = -h'_k(\bar{x}_k) \bar{x}_k + h_k(\bar{x}_k) .$$

Ici, le vecteur aléatoire $W_k^L = \sigma_k(\bar{x}_{k-1}) W_k$ est gaussien, centré et de matrice de covariance $Q_k^L = \sigma_k(\bar{x}_{k-1}) \sigma_k^*(\bar{x}_{k-1})$. On applique alors exactement le filtre de Kalman à ce nouveau système, et on obtient l'algorithme sous-optimal suivant

$$\hat{X}_k^- = b_k(\bar{x}_{k-1}) + b'_k(\bar{x}_{k-1}) (\hat{X}_{k-1} - \bar{x}_{k-1}) ,$$

$$P_k^- = b'_k(\bar{x}_{k-1}) P_{k-1} (b'_k(\bar{x}_{k-1}))^* + \sigma_k(\bar{x}_{k-1}) \sigma_k^*(\bar{x}_{k-1}) ,$$

et

$$\hat{X}_k = \hat{X}_k^- + K_k (Y_k - (h_k(\bar{x}_k) + h'_k(\bar{x}_k) (\hat{X}_k^- - \bar{x}_k))) ,$$

$$P_k = (I - K_k h'_k(\bar{x}_k)) P_k^- ,$$

avec la matrice de gain

$$K_k = P_k^- (h'_k(\bar{x}_k))^* [h'_k(\bar{x}_k) P_k^- (h'_k(\bar{x}_k))^* + Q_k^V]^{-1} .$$

A la place de la première et la troisième de ces équations, on peut utiliser

$$\hat{X}_k^- = b_k(\hat{X}_{k-1}) ,$$

$$\hat{X}_k = \hat{X}_k^- + K_k (Y_k - h_k(\hat{X}_k^-)) .$$

On choisit l'initialisation $\hat{X}_0^-$ et P_0^- de telle sorte que $\mathcal{N}(\hat{X}_0^-, P_0^-)$ soit une bonne approximation de la distribution de probabilité du vecteur aléatoire X_0 .

Filtre de Kalman étendu

Au lieu de linéariser autour d'une trajectoire nominale déterministe $\{\bar{x}_k\}$, on peut utiliser l'estimateur courant. La méthode consiste à linéariser les fonctions b_k et σ_k autour de $\hat{X}_{k-1}$, c'est-à-dire

$$b_k(x) \simeq b_k(\hat{X}_{k-1}) + b'_k(\hat{X}_{k-1}) (x - \hat{X}_{k-1}) \quad \text{et} \quad \sigma_k(x) \simeq \sigma_k(\hat{X}_{k-1}) ,$$

et à linéariser la fonction h_k autour de $\hat{X}_k^-$, c'est-à-dire

$$h_k(x) \simeq h_k(\hat{X}_k^-) + h'_k(\hat{X}_k^-) (x - \hat{X}_k^-) .$$

Le système non-linéaire (4.3) est alors remplacé par le système *conditionnellement* linéaire gaussien

$$X_k = F_k^L X_{k-1} + f_k^L + W_k^L ,$$

$$Y_k = H_k^L X_k + h_k^L + V_k ,$$

avec

$$F_k^L = b'_k(\hat{X}_{k-1}) \quad \text{et} \quad f_k^L = -b'_k(\hat{X}_{k-1}) \hat{X}_{k-1} + b_k(\hat{X}_{k-1}) ,$$

et avec

$$H_k^L = h'_k(\hat{X}_k^-) \quad \text{et} \quad h_k^L = -h'_k(\hat{X}_k^-) \hat{X}_k^- + h_k(\hat{X}_k^-) ,$$

et on remarque que

$$F_k^L \hat{X}_{k-1} + f_k^L = b_k(\hat{X}_{k-1}) \quad \text{et} \quad H_k^L \hat{X}_k^- + h_k^L = h_k(\hat{X}_k^-) .$$

Conditionnellement à $Y_{0:k-1}$, le vecteur aléatoire $W_k^L = \sigma_k(\hat{X}_{k-1}) W_k$ est gaussien, centré et de matrice de covariance conditionnelle $Q_k^L = \sigma_k(\hat{X}_{k-1}) \sigma_k^*(\hat{X}_{k-1})$. On remarque que les coefficients F_k^L , f_k^L et Q_k^L , et les coefficients H_k^L et h_k^L dépendent des observations passées $Y_{0:k-1}$. On applique alors exactement le filtre de Kalman à ce nouveau système, et au vu de la Remarque 3.10 on obtient l'algorithme sous-optimal suivant

$$\hat{X}_k^- = b_k(\hat{X}_{k-1}) ,$$

$$P_k^- = b'_k(\hat{X}_{k-1}) P_{k-1} (b'_k(\hat{X}_{k-1}))^* + \sigma_k(\hat{X}_{k-1}) \sigma_k^*(\hat{X}_{k-1}) ,$$

et

$$\hat{X}_k = \hat{X}_k^- + K_k (Y_k - h_k(\hat{X}_k^-)) ,$$

$$P_k = (I - K_k h'_k(\hat{X}_k^-)) P_k^- ,$$

avec la matrice de gain

$$K_k = P_k^- (h'_k(\hat{X}_k^-))^* [h'_k(\hat{X}_k^-) P_k^- (h'_k(\hat{X}_k^-))^* + Q_k^V]^{-1} .$$

On choisit l'initialisation $\hat{X}_0^-$ et P_0^- de telle sorte que $\mathcal{N}(\hat{X}_0^-, P_0^-)$ soit une bonne approximation de la distribution de probabilité du vecteur aléatoire X_0 .

Remarque 4.1 Dans cet algorithme, la suite $\{P_k\}$ dépend des observations, et ne peut donc pas être pré-calculée.

4.2 Filtre de Kalman *unscented*

On considère à nouveau le système non linéaire (4.3), c'est-à-dire

$$X_k = b_k(X_{k-1}) + \sigma_k(X_{k-1}) W_k ,$$

$$Y_k = h_k(X_k) + V_k ,$$

et on ne suppose plus que les fonctions b_k et h_k sont dérivables, mais on suppose que les fonctions b_k , h_k et σ_k et certaines fonctions associées, peuvent être intégrées par rapport à certaines distributions de probabilité gaussiennes.

Au lieu de s'appuyer sur une linéarisation des fonctions autour de l'estimateur courant, on se propose ici

- de remplacer les différentes distributions de probabilité conditionnelles par des distributions de probabilité gaussiennes ayant même moyenne et même matrice de covariance,
- d'utiliser des formules de quadrature, développées initialement pour le calcul numérique d'intégrales, pour approcher ces moyennes et ces matrices de covariance conditionnelles.

Le premier point peut s'interpréter comme une projection, au sens de la distance de Kullback–Leibler, sur la famille des distributions de probabilité gaussiennes.

► Le calcul des deux premiers moments (moyenne et matrice de covariance) de la distribution de probabilité conditionnelle $\mu_k^-(dx) = \mathbb{P}[X_k \in dx \mid Y_{0:k-1}]$, c'est-à-dire le calcul de la moyenne conditionnelle et de la matrice de covariance conditionnelle du vecteur aléatoire X_k sachant $Y_{0:k-1}$, est facile. Par définition

$$\begin{aligned}\widehat{X}_k^- &= \mathbb{E}[X_k \mid Y_{0:k-1}] \\ &= \mathbb{E}[b_k(X_{k-1}) \mid Y_{0:k-1}] + \mathbb{E}[\sigma_k(X_{k-1}) W_k \mid Y_{0:k-1}] \\ &= \int_{\mathbb{R}^m} b_k(x) \mu_{k-1}(dx) ,\end{aligned}$$

compte tenu que

$$\begin{aligned}\mathbb{E}[\sigma_k(X_{k-1}) W_k \mid Y_{0:k-1}] &= \mathbb{E}[\mathbb{E}[\sigma_k(X_{k-1}) W_k \mid X_{k-1}, Y_{0:k-1}] \mid Y_{0:k-1}] \\ &= \mathbb{E}[\sigma_k(X_{k-1}) \mathbb{E}[W_k \mid X_{k-1}, Y_{0:k-1}] \mid Y_{0:k-1}] = 0 ,\end{aligned}$$

où on a utilisé dans la dernière égalité l'indépendance de $(Y_0, \dots, Y_{k-1}, X_{k-1})$ et de W_k , donc $\mathbb{E}[W_k \mid X_{k-1}, Y_{0:k-1}] = 0$. Par différence

$$X_k - \widehat{X}_k^- = (b_k(X_{k-1}) - \widehat{X}_k^-) + \sigma_k(X_{k-1}) W_k ,$$

de sorte que

$$\begin{aligned}P_k^- &= \mathbb{E}[(X_k - \widehat{X}_k^-) (X_k - \widehat{X}_k^-)^* \mid Y_{0:k-1}] \\ &= \mathbb{E}[(b_k(X_{k-1}) - \widehat{X}_k^-) + \sigma_k(X_{k-1}) W_k] ((b_k(X_{k-1}) - \widehat{X}_k^-) + \sigma_k(X_{k-1}) W_k)^* \mid Y_{0:k-1}] \\ &= \mathbb{E}[(b_k(X_{k-1}) - \widehat{X}_k^-) (b_k(X_{k-1}) - \widehat{X}_k^-)^* \mid Y_{0:k-1}] \\ &\quad + \mathbb{E}[\sigma_k(X_{k-1}) W_k (b_k(X_{k-1}) - \widehat{X}_k^-)^* \mid Y_{0:k-1}] \\ &\quad + \mathbb{E}[(b_k(X_{k-1}) - \widehat{X}_k^-) W_k^* \sigma_k^*(X_{k-1}) \mid Y_{0:k-1}] \\ &\quad + \mathbb{E}[\sigma_k(X_{k-1}) W_k W_k^* \sigma_k^*(X_{k-1}) \mid Y_{0:k-1}] \\ &= \int_{\mathbb{R}^m} (b_k(x) - \widehat{X}_k^-) (b_k(x) - \widehat{X}_k^-)^* \mu_{k-1}(dx) + \int_{\mathbb{R}^m} \sigma_k(x) \sigma_k^*(x) \mu_{k-1}(dx) ,\end{aligned}$$

compte tenu que

$$\begin{aligned}
& \mathbb{E}[\sigma_k(X_{k-1}) W_k W_k^* \sigma_k^*(X_{k-1}) \mid Y_{0:k-1}] \\
&= \mathbb{E}[\mathbb{E}[\sigma_k(X_{k-1}) W_k W_k^* \sigma_k^*(X_{k-1}) \mid X_{k-1}, Y_{0:k-1}] \mid Y_{0:k-1}] \\
&= \mathbb{E}[\sigma_k(X_{k-1}) \mathbb{E}[W_k W_k^* \mid X_{k-1}, Y_{0:k-1}] \sigma_k^*(X_{k-1}) \mid Y_{0:k-1}] \\
&= \mathbb{E}[\sigma_k(X_{k-1}) \sigma_k^*(X_{k-1}) \mid Y_{0:k-1}] ,
\end{aligned}$$

où on a utilisé dans la dernière égalité l'indépendance de $(Y_0, \dots, Y_{k-1}, X_{k-1})$ et de W_k , donc $\mathbb{E}[W_k W_k^* \mid X_{k-1}, Y_{0:k-1}] = I$, et compte tenu que

$$\begin{aligned}
& \mathbb{E}[\sigma_k(X_{k-1}) W_k (b_k(X_{k-1}) - \widehat{X}_k^-)^* \mid Y_{0:k-1}] \\
&= \mathbb{E}[\mathbb{E}[\sigma_k(X_{k-1}) W_k (b_k(X_{k-1}) - \widehat{X}_k^-)^* \mid X_{k-1}, Y_{0:k-1}] \mid Y_{0:k-1}] \\
&= \mathbb{E}[\sigma_k(X_{k-1}) \mathbb{E}[W_k \mid X_{k-1}, Y_{0:k-1}] (b_k(X_{k-1}) - \widehat{X}_k^-)^* \mid Y_{0:k-1}] = 0 ,
\end{aligned}$$

où on a encore utilisé dans la dernière égalité l'indépendance de $(Y_0, \dots, Y_{k-1}, X_{k-1})$ et de W_k , donc $\mathbb{E}[W_k \mid X_{k-1}, Y_{0:k-1}] = 0$.

► En revanche, le calcul des deux premiers moments (moyenne et matrice de covariance) de la distribution de probabilité conditionnelle $\mu_k(dx) = \mathbb{P}[X_k \in dx \mid Y_{0:k}]$, c'est-à-dire le calcul de la moyenne conditionnelle et de la matrice de covariance conditionnelle du vecteur aléatoire X_k sachant $Y_{0:k}$, n'est pas immédiat, et on commence par le calcul des deux premiers moments (moyenne et matrice de covariance) de la distribution de probabilité conditionnelle jointe du vecteur aléatoire (X_k, Y_k) sachant $Y_{0:k-1}$, qui est plus facile. On rappelle que

$$\widehat{X}_k^- = \int_{\mathbb{R}^m} b_k(x) \mu_{k-1}(dx) ,$$

a déjà été obtenu plus haut, et par définition

$$\begin{aligned}
\widehat{Y}_k^- &= \mathbb{E}[Y_k \mid Y_{0:k-1}] \\
&= \mathbb{E}[h_k(X_k) \mid Y_{0:k-1}] + \mathbb{E}[V_k \mid Y_{0:k-1}] \\
&= \int_{\mathbb{R}^m} h_k(x) \mu_k^-(dx) .
\end{aligned}$$

On rappelle que

$$P_k^- = \int (b_k(x) - \widehat{X}_k^-) (b_k(x) - \widehat{X}_k^-)^* \mu_{k-1}(dx) + \int_{\mathbb{R}^m} \sigma_k(x) \sigma_k^*(x) \mu_{k-1}(dx) ,$$

a déjà été obtenu plus haut, et par différence

$$Y_k - \widehat{Y}_k^- = (h_k(X_k) - \widehat{Y}_k^-) + V_k ,$$

de sorte que

$$\begin{aligned}
\Xi_k &= \mathbb{E}[(Y_k - \hat{Y}_k^-)(Y_k - \hat{Y}_k^-)^* | Y_{0:k-1}] \\
&= \mathbb{E}[(h_k(X_k) - \hat{Y}_k^- + V_k)(h_k(X_k) - \hat{Y}_k^- + V_k)^* | Y_{0:k-1}] \\
&= \mathbb{E}[(h_k(X_k) - \hat{Y}_k^-)(h_k(X_k) - \hat{Y}_k^-)^* | Y_{0:k-1}] + \mathbb{E}[V_k V_k^* | Y_{0:k-1}] \\
&\quad + \mathbb{E}[(h_k(X_k) - \hat{Y}_k^-) V_k^* | Y_{0:k-1}] \\
&\quad + \mathbb{E}[V_k (h_k(X_k) - \hat{Y}_k^-)^* | Y_{0:k-1}] \\
&= \int_{\mathbb{R}^m} (h_k(x) - \hat{Y}_k^-)(h_k(x) - \hat{Y}_k^-)^* \mu_k^-(dx) + Q_k^V,
\end{aligned}$$

compte tenu que

$$\begin{aligned}
&\mathbb{E}[V_k (h_k(X_k) - \hat{Y}_k^-)^* | Y_{0:k-1}] \\
&= \mathbb{E}[\mathbb{E}[V_k (h_k(X_k) - \hat{Y}_k^-)^* | X_k, Y_{0:k-1}] | Y_{0:k-1}] \\
&= \mathbb{E}[\mathbb{E}[V_k | X_k, Y_{0:k-1}] (h_k(X_k) - \hat{Y}_k^-)^* | Y_{0:k-1}] = 0.
\end{aligned}$$

où on a utilisé dans la dernière égalité l'indépendance de $(Y_0, \dots, Y_{k-1}, X_k)$ et de V_k , donc $\mathbb{E}[V_k | X_k, Y_{0:k-1}] = 0$, et

$$\begin{aligned}
C_k &= \mathbb{E}[(X_k - \hat{X}_k^-)(Y_k - \hat{Y}_k^-)^* | Y_{0:k-1}] \\
&= \mathbb{E}[(X_k - \hat{X}_k^-)(h_k(X_k) - \hat{Y}_k^-)^* | Y_{0:k-1}] + \mathbb{E}[(X_k - \hat{X}_k^-) V_k^* | Y_{0:k-1}] \\
&= \int_{\mathbb{R}^m} (x - \hat{X}_k^-)(h_k(x) - \hat{Y}_k^-)^* \mu_k^-(dx).
\end{aligned}$$

On remplace la distribution de probabilité conditionnelle jointe du vecteur aléatoire (X_k, Y_k) sachant $Y_{0:k-1}$ par la distribution de probabilité gaussienne de moyenne et de matrice de covariance

$$\begin{pmatrix} \hat{X}_k^- \\ \hat{Y}_k^- \end{pmatrix} \quad \text{et} \quad \begin{pmatrix} P_k^- & C_k \\ C_k^* & \Xi_k \end{pmatrix},$$

respectivement. Si la matrice Q_k^V est inversible, alors a fortiori la matrice Ξ_k est inversible, et d'après la Proposition 1.8 on obtient immédiatement les approximations suivantes

$$\hat{X}_k = \hat{X}_k^- + C_k \Xi_k^{-1} (Y_k - \hat{Y}_k^-) \quad \text{et} \quad P_k = P_k^- - C_k \Xi_k^{-1} C_k^*,$$

pour les deux premiers moments de la distribution de probabilité conditionnelle μ_k , c'est-à-dire pour la moyenne conditionnelle et de la matrice de covariance conditionnelle du vecteur aléatoire X_k sachant $Y_{0:k}$.

Ces équations ne sont pas fermées, c'est-à-dire que les moments $\hat{X}_k^-$ et P_k^- ne s'expriment pas en fonction des moments $\hat{X}_{k-1}$ et P_{k-1} seulement, mais en fonction de toute la distribution de probabilité conditionnelle μ_{k-1} , et de même, les moments $\hat{X}_k$ et P_k ne s'expriment pas en fonction des moments $\hat{X}_k^-$ et P_k^- seulement, mais en fonction de toute la distribution de probabilité conditionnelle μ_k^- . Pour fermer ces équations, on adopte le principe de projection énoncé plus haut.

► On remplace la distribution de probabilité conditionnelle μ_{k-1} par la distribution de probabilité gaussienne de moyenne $\hat{X}_{k-1}$ et de matrice de covariance $P_{k-1} = S_{k-1} S_{k-1}^*$, et en effectuant le changement de variable $x = \hat{X}_{k-1} + S_{k-1} u$, on obtient les approximations

$$\hat{X}_k^- \approx \int \hat{b}_k(u) \exp\{-\frac{1}{2}|u|^2\} \frac{du}{(2\pi)^{m/2}},$$

et

$$\begin{aligned} P_k^- &\approx \int (\hat{b}_k(u) - \hat{X}_k^-) (\hat{b}_k(u) - \hat{X}_k^-)^* \exp\{-\frac{1}{2}|u|^2\} \frac{du}{(2\pi)^{m/2}} \\ &\quad + \int \hat{\sigma}_k(u) \hat{\sigma}_k^*(u) \exp\{-\frac{1}{2}|u|^2\} \frac{du}{(2\pi)^{m/2}} \end{aligned}$$

où par définition

$$\hat{b}_k(u) = b_k(\hat{X}_{k-1} + S_{k-1} u) \quad \text{et} \quad \hat{\sigma}_k(u) = \sigma_k(\hat{X}_{k-1} + S_{k-1} u).$$

► De même, on remplace la distribution de probabilité conditionnelle μ_k^- par la distribution de probabilité gaussienne de moyenne $\hat{X}_k^-$ et de matrice de covariance $P_k^- = S_k^- (S_k^-)^*$, et en effectuant le changement de variable $x = \hat{X}_k^- + S_k^- u$, on obtient les approximations

$$\hat{Y}_k^- \approx \int_{\mathbb{R}^m} \hat{h}_k(u) \exp\{-\frac{1}{2}|u|^2\} \frac{du}{(2\pi)^{m/2}},$$

et

$$\Xi_k \approx \int_{\mathbb{R}^m} (\hat{h}_k(u) - \hat{Y}_k^-) (\hat{h}_k(u) - \hat{Y}_k^-)^* \exp\{-\frac{1}{2}|u|^2\} \frac{du}{(2\pi)^{m/2}} + Q_k^V,$$

et

$$C_k \approx S_k^- \int_{\mathbb{R}^m} u (\hat{h}_k(u) - \hat{Y}_k^-)^* \exp\{-\frac{1}{2}|u|^2\} \frac{du}{(2\pi)^{m/2}},$$

où par définition

$$\hat{h}_k(u) = h_k(\hat{X}_k^- + S_k^- u).$$

Il reste donc à calculer les intégrales des fonctions non-linéaires

$$\hat{b}_k(u), \hat{b}_k(u) \hat{b}_k^*(u), \hat{\sigma}_k(u) \hat{\sigma}_k^*(u), \hat{h}_k(u), u \hat{h}_k^*(u) \text{ et } \hat{h}_k(u) \hat{h}_k^*(u),$$

par rapport à la densité gaussienne réduite centrée.

Remarque 4.2 Si on suppose que les fonctions b_k et h_k sont dérivables, et qu'on utilise un développement limité au premier ordre au voisinage de $u = 0$ dans les intégrales ci-dessus, on retrouve les équations du filtre de Kalman étendu. L'idée ici est de *ne pas linéariser*, et de calculer les intégrales en utilisant des formules de quadrature numérique.

On introduit les formules de quadrature suivantes, reposant sur la notion de σ -points. En dimension m , la densité de probabilité gaussienne centrée réduite (de matrice de covariance identité) est représentée par $2m + 1$ points de quadrature $(u_{-m}, \dots, u_m)$ appelés σ -points, et définis par

$$u_0 = 0, \quad u_i = e_i \sqrt{m + \kappa} \quad \text{et} \quad u_{-i} = -u_i,$$

où e_i désigne le i -ème vecteur de base, affectés des poids

$$w_0 = \frac{\kappa}{m + \kappa} \quad \text{et} \quad w_{-i} = w_i = \frac{1}{2(m + \kappa)}, \quad (4.4)$$

pour tout $i = 1, \dots, m$ (d'autres choix de σ -points sont possibles). On vérifie que

$$\sum_{i=-m}^{+m} w_i = 1, \quad \sum_{i=-m}^{+m} w_i u_i = 0 \quad \text{et} \quad \sum_{i=-m}^{+m} w_i u_i u_i^* = \sum_{i=1}^m e_i e_i^* = I,$$

c'est-à-dire que les deux premiers moments sont pris en compte exactement. Plus généralement

$$\int_{\mathbb{R}^m} \phi(u) \exp\{-\tfrac{1}{2}|u|^2\} \frac{du}{(2\pi)^{m/2}} \approx \sum_{i=-m}^{+m} w_i \phi(u_i),$$

et un changement de variable évident donne aussitôt

$$\int_{\mathbb{R}^m} \phi(\mu + \Sigma^{1/2} u) \exp\{-\tfrac{1}{2}|u|^2\} \frac{du}{(2\pi)^{m/2}} \approx \sum_{i=-m}^{+m} w_i \phi(\mu + \Sigma^{1/2} u_i),$$

pour toute fonction ϕ définie sur $\mathbb{R}^m$, c'est-à-dire que les σ -points $(x_{-m}, \dots, x_m)$ associés à la distribution de probabilité gaussienne de vecteur moyenne μ et de matrice de covariance Σ , sont définis par la relation $x_i = \mu + \Sigma^{1/2} u_i$, soit

$$x_0 = \mu, \quad x_i = \mu + \Sigma^{1/2} e_i \sqrt{m + \kappa} \quad \text{et} \quad x_{-i} = \mu - \Sigma^{1/2} e_i \sqrt{m + \kappa},$$

pour tout $i = 1, \dots, m$. On vérifie que

$$\sum_{i=-m}^{+m} w_i x_i = \mu \quad \text{et} \quad \sum_{i=-m}^{+m} w_i (x_i - \mu) (x_i - \mu)^* = \sum_{i=1}^m \Sigma^{1/2} e_i (\Sigma^{1/2} e_i)^* = \Sigma,$$

c'est-à-dire que les deux premiers moments sont pris en compte exactement. Plus généralement encore, soit X un vecteur aléatoire gaussien de vecteur moyenne μ et de matrice de covariance Σ , et soit T une transformation non-linéaire définie sur $\mathbb{R}^m$. Clairement

$$\int \phi(T(\mu + \Sigma^{1/2} u)) \exp\{-\tfrac{1}{2}|u|^2\} \frac{du}{(2\pi)^{m/2}} \approx \sum_{i=-m}^{+m} w_i \phi(T(x_i)),$$

pour toute fonction ϕ définie sur $\mathbb{R}^m$, c'est-à-dire que les σ -points $(x'_{-m}, \dots, x'_m)$ associés au vecteur aléatoire transformé $X' = T(X)$, sont simplement obtenus par la relation $x'_i = T(x_i)$ à partir des σ -points $(x_{-m}, \dots, x_m)$ associés au vecteur aléatoire X , soit

$$x'_0 = T(\mu), \quad x'_i = T(\mu + \Sigma^{1/2} e_i \sqrt{m + \kappa}) \quad \text{et} \quad x'_{-i} = T(\mu - \Sigma^{1/2} e_i \sqrt{m + \kappa}),$$

pour tout $i = 1, \dots, m$.

Avec ces formules de quadrature, on obtient l'algorithme de filtrage sous-optimal suivant.

Expression de $\hat{X}_k^-$ et P_k^- en fonction de $\hat{X}_{k-1}$ et $P_{k-1} = S_{k-1} S_{k-1}^*$:

On introduit les σ -points

$$x_0 = \hat{X}_{k-1}, \quad x_i = \hat{X}_{k-1} + S_{k-1} e_i \sqrt{m + \kappa} \quad \text{et} \quad x_{-i} = \hat{X}_{k-1} - S_{k-1} e_i \sqrt{m + \kappa},$$

affectés des poids (4.4) pour tout $i = 1, \dots, m$, et on définit le vecteur moyenne

$$\hat{X}_k^- = \sum_{i=-m}^{+m} w_i b_k(x_i),$$

et la matrice de covariance

$$P_k^- = \sum_{i=-m}^{+m} w_i (b_k(x_i) - \hat{X}_k^-) (b_k(x_i) - \hat{X}_k^-)^* + \sum_{i=-m}^{+m} w_i \sigma_k(x_i) \sigma_k^*(x_i) = S_k^- (S_k^-)^*.$$

Expression de $\hat{X}_k$ et P_k en fonction de $\hat{X}_k^-$ et $P_k^- = S_k^- (S_k^-)^*$:

On introduit les σ -points

$$x_0 = \hat{X}_k^-, \quad x_i = \hat{X}_k^- + S_k^- e_i \sqrt{m + \kappa} \quad \text{et} \quad x_{-i} = \hat{X}_k^- - S_k^- e_i \sqrt{m + \kappa},$$

affectés des poids (4.4) pour tout $i = 1, \dots, m$, on définit le vecteur moyenne

$$\hat{Y}_k^- = \sum_{i=-m}^{+m} w_i h_k(x_i),$$

la matrice de covariance

$$\Xi_k = \sum_{i=-m}^{+m} w_i (h_k(x_i) - \hat{Y}_k^-) (h_k(x_i) - \hat{Y}_k^-)^* + Q_k^V,$$

et la matrice de corrélation

$$C_k = \sum_{i=-m}^{+m} w_i (x_i - \hat{X}_k^-) (h_k(x_i) - \hat{Y}_k^-)^*,$$

et on pose

$$\hat{X}_k = \hat{X}_k^- + C_k \Xi_k^{-1} (Y_k - \hat{Y}_k^-) \quad \text{et} \quad P_k = P_k^- - C_k \Xi_k^{-1} C_k^* = S_k S_k^*.$$

Chapitre 5

Au-delà des systèmes linéaires gaussiens

5.1 Systèmes non-linéaires à bruits non-gaussiens

Il s'agit de la classe la plus générale de modèles d'état, et c'est aussi un cas particulier de la classe plus générale des modèles de Markov cachés (pour lesquels l'espace d'état peut être très général). On considère donc une suite d'états cachés $\{X_k\}$ à valeurs dans $\mathbb{R}^m$, vérifiant

$$X_k = f_k(X_{k-1}, W_k) \quad \text{avec} \quad W_k \sim p_k^W(dw), \quad (5.1)$$

avec des entrées bruitées $\{W_k\}$ à valeurs dans $\mathbb{R}^p$, pas nécessairement gaussiennes, et une condition initiale $X_0 \sim \eta_0(dx)$ pas nécessairement gaussienne, et une suite d'observations $\{Y_k\}$ à valeurs dans $\mathbb{R}^d$, vérifiant

$$Y_k = h_k(X_k) + V_k \quad \text{avec} \quad V_k \sim q_k^V(v) dv, \quad (5.2)$$

avec des bruits d'observation $\{V_k\}$ additifs, à valeurs dans $\mathbb{R}^d$, pas nécessairement gaussiens, mais de distribution de probabilité $q_k^V(v) dv$ absolument continue par rapport à la mesure de Lebesgue dv . Les bruits blancs $\{W_k\}$ et $\{V_k\}$ sont indépendants entre eux et indépendants de la condition initiale X_0 . On ne suppose pas que les fonctions f_k et h_k sont dérivables. Pour la suite, il sera suffisant de faire l'hypothèse suivante : pour tout instant k

- il est facile de *simuler* un vecteur aléatoire selon la distribution de probabilité $p_k^W(dw)$ du vecteur aléatoire W_k ,
- la distribution de probabilité du vecteur aléatoire V_k admet une densité $q_k^V(v)$ qu'il est facile d'*évaluer* pour tout $v \in \mathbb{R}^d$.

Proposition 5.1 *La suite $\{X_k\}$ est une chaîne de Markov à valeurs dans $\mathbb{R}^m$, c'est-à-dire que la distribution de probabilité conditionnelle par rapport au passé*

$$\mathbb{P}[X_k \in dx' \mid X_{0:k-1}] = \mathbb{P}[X_k \in dx' \mid X_{k-1}],$$

ne dépend que du passé immédiat, avec les probabilités de transition

$$\mathbb{P}[X_k \in dx' \mid X_{k-1} = x] = Q_k(x, dx') ,$$

défini par

$$Q_k \phi(x) = \mathbb{E}[\phi(X_k) \mid X_{k-1} = x] = \int_{\mathbb{R}^p} \phi(f_k(x, w)) p_k^W(dw) ,$$

pour toute fonction test ϕ mesurable bornée, définie sur $\mathbb{R}^m$.

PREUVE. Compte tenu que W_k est indépendant de $X_{0:k-1}$, on a

$$\begin{aligned} \mathbb{E}[\phi(X_k) \mid X_{0:k-1}] &= \mathbb{E}[\phi(f_k(X_{k-1}, W_k)) \mid X_{0:k-1}] \\ &= \int_{\mathbb{R}^p} \phi(f_k(X_{k-1}, w)) p_k^W(dw) , \end{aligned}$$

pour toute fonction ϕ mesurable bornée définie sur $\mathbb{R}^m$. Clairement, le résultat ne dépend que de X_{k-1} , c'est-à-dire que

$$\mathbb{E}[\phi(X_k) \mid X_{0:k-1}] = \mathbb{E}[\phi(X_k) \mid X_{k-1}] ,$$

et

$$\mathbb{E}[\phi(X_k) \mid X_{k-1} = x] = \int_{\mathbb{R}^p} \phi(f_k(x, w)) p_k^W(dw) . \quad \square$$

Remarque 5.2 Si $f_k(x, w) = b_k(x) + w$, et si la distribution de probabilité $p_k^W(dw)$ de la variable aléatoire W_k admet une densité encore notée $p_k^W(w)$, c'est-à-dire si $p_k^W(dw) = p_k^W(w) dw$, alors

$$Q_k(x, dx') = p_k^W(x' - b_k(x)) dx' ,$$

c'est-à-dire que le noyau $Q_k(x, dx')$ admet une densité. En effet, le changement de variable $x' = b_k(x) + w$ donne immédiatement

$$Q_k \phi(x) = \int_{\mathbb{R}^m} \phi(b_k(x) + w) p_k^W(w) dw = \int_{\mathbb{R}^m} \phi(x') p_k^W(x' - b_k(x)) dx' ,$$

pour toute fonction test ϕ mesurable bornée, définie sur $\mathbb{R}^m$.

Remarque 5.3 En général, le noyau $Q_k(x, dx')$ n'admet pas de densité par rapport à la mesure de Lebesgue sur $\mathbb{R}^m$. En effet, conditionnellement à $X_{k-1} = x$, le vecteur aléatoire X_k appartient nécessairement au sous-ensemble

$$\mathcal{M}(x) = \{x' \in \mathbb{R}^m : \text{il existe } w \in \mathbb{R}^p \text{ tel que } x' = f_k(x, w)\} ,$$

et dans le cas où $p < m$ ce sous-ensemble $\mathcal{M}(x)$ est généralement, sous certaines hypothèses de régularité, une sous-variété différentielle de dimension p dans l'espace $\mathbb{R}^m$, c'est-à-dire un sous-ensemble de mesure de Lebesgue nulle. La distribution de probabilité conditionnelle du vecteur aléatoire X_k sachant $X_{k-1} = x$ ne peut donc pas avoir de densité par rapport à la mesure de Lebesgue sur $\mathbb{R}^m$.

Proposition 5.4 *La suite $\{Y_k\}$ vérifie l'hypothèse de canal sans mémoire, c'est-à-dire que pour tout instant n*

- *conditionnellement aux états cachés $X_{0:n}$ les observations $Y_{0:n}$ sont mutuellement indépendantes, ce qui se traduit par*

$$\mathbb{P}[Y_{0:n} \in dy_{0:n} \mid X_{0:n}] = \prod_{k=0}^n \mathbb{P}[Y_k \in dy_k \mid X_{0:n}] ,$$

- *pour tout $k = 0, \dots, n$, la distribution de probabilité conditionnelle de la variable aléatoire Y_k sachant $X_{0:n}$ ne dépend que de X_k , ce qui se traduit par*

$$\mathbb{P}[Y_k \in dy_k \mid X_{0:n}] = \mathbb{P}[Y_k \in dy_k \mid X_k] ,$$

avec les probabilités d'émission

$$\mathbb{P}[Y_k \in dy \mid X_k = x] = q_k^V(y - h_k(x)) dy ,$$

et on définit la fonction de vraisemblance

$$g_k(x) = q_k^V(Y_k - h_k(x)) ,$$

qui mesure l'adéquation d'un état quelconque $x \in \mathbb{R}^m$ avec l'observation Y_k .

En d'autres termes, la distribution de probabilité conditionnelle jointe des observations $Y_{0:n}$ sachant les états cachés $X_{0:n}$ vérifie

$$\mathbb{P}[Y_{0:n} \in dy_{0:n} \mid X_{0:n} = x_{0:n}] = \prod_{k=0}^n q_k^V(y_k - h_k(x_k)) dy_0 \cdots dy_n .$$

Exemple 5.5 Dans le cas particulier où le bruit additif V_k est un vecteur aléatoire gaussien centré et de matrice de covariance identité, alors la probabilité d'émission

$$\mathbb{P}[Y_k \in dy \mid X_k = x] = \frac{1}{(2\pi)^{d/2}} \exp\{-\frac{1}{2}|y - h_k(x)|^2\} dy ,$$

est absolument continue, et la fonction de vraisemblance, définie à une constante multiplicative près, est donnée par

$$g_k(x) = \exp\{-\frac{1}{2}|Y_k - h_k(x)|^2\} .$$

PREUVE. Pour toute famille $\phi_0, \dots, \phi_n$ de fonctions mesurables bornées définies sur $\mathbb{R}^d$, et compte tenu que les vecteurs aléatoires $V_0, \dots, V_n$ sont mutuellement indépendants et indépendants du vecteur aléatoire $X_{0:n}$, on a

$$\begin{aligned}
& \mathbb{E}[\phi_0(Y_0) \cdots \phi_n(Y_n) \mid X_{0:n}] \\
&= \mathbb{E}[\phi_0(h_0(X_0) + V_0) \cdots \phi_n(h_n(X_n) + V_n) \mid X_{0:n}] \\
&= \int_{\mathbb{R}^d} \cdots \int_{\mathbb{R}^d} \phi_0(h_0(X_0) + v_0) \cdots \phi_n(h_n(X_n) + v_n) \mathbb{P}[V_{0:n} \in dv_{0:n}] \\
&= \prod_{k=0}^n \int_{\mathbb{R}^d} \phi_k(h_k(X_k) + v_k) \mathbb{P}[V_k \in dv_k] \\
&= \prod_{k=0}^n \int_{\mathbb{R}^d} \phi_k(h_k(X_k) + v_k) q_k^V(v_k) dv_k \\
&= \prod_{k=0}^n \int_{\mathbb{R}^d} \phi_k(y_k) \underbrace{q_k^V(y_k - h_k(X_k)) dy_k}_{\mathbb{P}[Y_k \in dy_k \mid X_k]} = \prod_{k=0}^n \mathbb{E}[\phi_k(Y_k) \mid X_k] . \quad \square
\end{aligned}$$

On voudrait également pouvoir prendre en compte un certain nombre de systèmes plus généraux, qui correspondent à des situations d'intérêt pratique, par exemple les systèmes hybrides à saut markovien

$$X_k = f_k(r_{k-1}, X_{k-1}, W_k) ,$$

$$Y_k = h_k(r_k, X_k) + V_k ,$$

où la suite $\{r_k\}$ forme une chaîne de Markov à valeurs dans un espace fini, correspondant à différents *régimes* ou *modes* de fonctionnement.

5.2 Modèles de Markov cachés

Plus généralement, on peut aussi considérer un modèle de Markov caché où les états cachés $\{X_k\}$ forment une chaîne de Markov à valeurs dans un espace E qui peut être très général, par exemple un espace hybride continu / discret, un sous-ensemble défini par des contraintes, une variété différentielle, un graphe, etc., de noyaux de transition

$$\mathbb{P}[X_k \in dx' \mid X_{k-1} = x] = Q_k(x, dx') ,$$

et de distribution de probabilité initiale

$$\mathbb{P}[X_0 \in dx] = \eta_0(dx) ,$$

et où les observations $\{Y_k\}$ vérifient l'hypothèse de *canal sans mémoire*, c'est-à-dire que pour tout instant n

- conditionnellement aux états cachés $X_{0:n}$ les observations $Y_{0:n}$ sont mutuellement indépendantes, ce qui se traduit par

$$\mathbb{P}[Y_{0:n} \in dy_{0:n} \mid X_{0:n}] = \prod_{k=0}^n \mathbb{P}[Y_k \in dy_k \mid X_{0:n}] ,$$

- pour tout $k = 0, \dots, n$, la distribution de probabilité conditionnelle de la variable aléatoire Y_k sachant $X_{0:n}$ ne dépend que de X_k , ce qui se traduit par

$$\mathbb{P}[Y_k \in dy \mid X_{0:n}] = \mathbb{P}[Y_k \in dy \mid X_k] ,$$

avec la probabilité d'émission


$$\mathbb{P}[Y_k \in dy \mid X_k = x] = g_k(x, y) \lambda_k^F(dy) ,$$

où la mesure positive $\lambda_k^F(dy)$ définie sur F ne dépend pas de l'état caché $x \in E$, et par abus de notation on définit la *fonction de vraisemblance*

$$g_k(x) = g_k(x, Y_k) ,$$

qui mesure l'adéquation d'un état quelconque $x \in E$ avec l'observation Y_k .

La situation est complètement décrite par le diagramme suivant



où les flèches représentent la dépendance entre variables aléatoires. En d'autres termes, la distribution de probabilité conditionnelle jointe des observations $Y_{0:n}$ sachant les états cachés $X_{0:n}$ vérifie

$$\mathbb{P}[Y_{0:n} \in dy_{0:n} \mid X_{0:n} = x_{0:n}] = \prod_{k=0}^n g_k(x_k, y_k) \lambda_0^F(dy_0) \cdots \lambda_n^F(dy_n) .$$

Ce modèle peut paraître très abstrait à première vue, mais pour la suite il suffira que l'hypothèse suivante soit vérifiée : pour tout instant $k = 1, \dots, n$

- il est facile de *simuler* pour tout $x \in E$, un vecteur aléatoire selon la distribution de probabilité $Q_k(x, dx')$,
- il est facile d'*évaluer* pour tout $x' \in E$, la fonction de vraisemblance $g_k(x')$.

Malgré leur grande généralité, les modèles de Markov cachés ne permettent pas de prendre en compte un certain nombre de systèmes non-linéaires à bruits non-gaussiens, qui correspondent

à des situations d'intérêt pratique, par exemple les cas où les observations dépendent de la transition de la chaîne de Markov cachée

$$X_k = f_k(X_{k-1}, W_k) ,$$

$$Y_k = h_k(X_{k-1}, X_k) + V_k ,$$

les modèles de Markov à variables latentes

$$X_k = f_k(X_{k-1}, W_k) ,$$

$$Y_k = h_k(Y_{k-1}, X_k) + V_k ,$$

où conditionnellement aux états cachés, les observations forment une chaîne de Markov, ou bien les systèmes d'état à bruits corrélés

$$X_k = f_k(X_{k-1}, V_{k-1}, W_k) ,$$

$$Y_k = h_k(X_k) + V_k ,$$

où clairement le bruit $U_{k-1} = (V_{k-1}, W_k)$ dans l'équation d'état est corrélé au bruit d'observation V_{k-1} . Dans ce dernier exemple, une solution pragmatique consiste à reporter dans l'équation d'état l'expression pour V_{k-1} tirée de l'équation d'observation, de sorte que

$$X_k = f_k(X_{k-1}, Y_{k-1} - h_{k-1}(X_{k-1}), W_k) ,$$

$$Y_k = h_k(X_k) + V_k .$$

Les classes de modèles de plus en plus généraux présentés dans les deux prochaines sections, permettent de prendre en compte ces situations.

5.3 Chaînes de Markov à paramètres markoviens

Certains problèmes sont décrits par une chaîne de Markov $\{Y_k\}$, et pour disposer d'une plus grande possibilité de modélisation on propose de faire dépendre les noyaux de transitions d'une suite de variables aléatoires latentes $\{X_k\}$, formant elle-même une chaîne de Markov. Cette situation se rencontre par exemple dans les modèles à volatilité stochastique, et à la différence de la situation précédente, l'estimation de la suite latente n'est pas un objectif en soi.

Dans ces modèles, les états cachés $\{X_k\}$ forment une chaîne de Markov à valeurs dans un espace E , de noyaux de transition

$$\mathbb{P}[X_k \in dx' \mid X_{k-1} = x] = Q_k(x, dx') ,$$

et de distribution de probabilité initiale

$$\mathbb{P}[X_0 \in dx] = \eta_0(dx) ,$$

et conditionnellement aux états cachés, les observations $\{Y_k\}$ forment une chaîne de Markov à valeurs dans F , c'est-à-dire que pour tout instant n

- conditionnellement aux états cachés $X_{0:n}$ les observations $Y_{0:n}$ forment une chaîne de Markov, ce qui se traduit pour tout $k = 1, \dots, n$, par

$$\mathbb{P}[Y_k \in dy \mid Y_{0:k-1}, X_{0:n}] = \mathbb{P}[Y_k \in dy \mid Y_{k-1}, X_{0:n}] ,$$

- pour $k = 0$, la distribution de probabilité conditionnelle de la variable aléatoire Y_0 sachant $X_{0:n}$ ne dépend que de X_0 , ce qui se traduit par

$$\mathbb{P}[Y_0 \in dy \mid X_{0:n}] = \mathbb{P}[Y_0 \in dy \mid X_0] ,$$

avec la probabilité initiale

$$\mathbb{P}[Y_0 \in dy \mid X_0 = x] = g_0(x, y) \lambda_0^F(dy) ,$$

où la mesure positive $\lambda_0^F(dy)$ définie sur F ne dépend pas de l'état caché $x \in E$, et par abus de notation on définit la *fonction de vraisemblance*

$$g_0(x) = g_0(x, Y_0) ,$$

qui mesure l'adéquation d'un état quelconque $x' \in E$ avec l'observation initiale Y_0 ,

- pour tout $k = 1, \dots, n$, la distribution de probabilité conditionnelle de la variable aléatoire Y_k sachant Y_{k-1} et $X_{0:n}$ ne dépend que de Y_{k-1} et de X_k , ce qui se traduit par

$$\mathbb{P}[Y_k \in dy_k \mid Y_{k-1}, X_{0:n}] = \mathbb{P}[Y_k \in dy_k \mid Y_{k-1}, X_k] ,$$

avec la probabilité d'émission


$$\mathbb{P}[Y_k \in dy' \mid Y_{k-1} = y, X_k = x'] = g_k(x', y, y') \lambda_k^F(y, dy') ,$$

où la mesure positive $\lambda_k^F(y, dy')$ définie sur F ne dépend pas de l'état caché $x' \in E$, et par abus de notation on définit la *fonction de vraisemblance*

$$g_k(x') = g_k(x', Y_{k-1}, Y_k) ,$$

qui mesure l'adéquation d'un état quelconque $x' \in E$ avec les observations successives Y_{k-1} et Y_k .

La situation est complètement décrite par le diagramme suivant



où les flèches représentent la dépendance entre variables aléatoires. En d'autres termes, la distribution de probabilité conditionnelle jointe des observations $Y_{0:n}$ sachant les états cachés $X_{0:n}$ vérifie

$$\begin{aligned}
 & \mathbb{P}[Y_{0:n} \in dy_{0:n} \mid X_{0:n} = x_{0:n}] \\
 &= g_0(x_0, y_0) \lambda_0^F(dy_0) \prod_{k=1}^n g_k(x_k, y_{k-1}, y_k) \lambda_k^F(y_{k-1}, dy_k) \\
 &= [g_0(x_0, y_0) \prod_{k=1}^n g_k(x_k, y_{k-1}, y_k)] \lambda_0^F(dy_0) \prod_{k=1}^n \lambda_k^F(y_{k-1}, dy_k) .
 \end{aligned}$$

5.4 Chaînes de Markov partiellement observées

Encore plus généralement, on peut considérer un modèle où les états cachés $\{X_k\}$ ne forment plus nécessairement une chaîne de Markov, mais où conjointement états cachés et observations $\{Z_k\}$ avec $Z_k = (X_k, Y_k)$ pour tout instant $k = 0, 1, \dots, n$, forment une chaîne de Markov à valeurs dans $E \times F$, de distribution de probabilité initiale

$$\mathbb{P}[X_0 \in dx, Y_0 \in dy] = \gamma_0(y, dx) \lambda_0^F(dy) , \quad (5.3)$$

où la mesure positive $\lambda_0^F(dy)$ définie sur F , ne dépend pas de l'état caché $x \in E$, et de probabilités de *transition*

$$\mathbb{P}[X_k \in dx', Y_k \in dy' \mid X_{k-1} = x, Y_{k-1} = y] = R_k(y, y', x, dx') \lambda_k^F(y, dy') , \quad (5.4)$$

où la mesure positive $\lambda_k^F(y, dy')$ définie sur F , dépend de l'observation précédente $y \in F$ mais ne dépend pas de la transition cachée $(x, x') \in E$. En d'autres termes, la distribution de probabilité jointe des états cachés $X_{0:n}$ et des observations $Y_{0:n}$ vérifie

$$\begin{aligned} \mathbb{P}[X_{0:n} \in dx_{0:n}, Y_{0:n} \in dy_{0:n}] \\ &= \gamma_0(y_0, dx_0) \lambda_0^F(dy_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k) \lambda_k^F(y_{k-1}, dy_k) \\ &= [\gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k)] \lambda_0^F(dy_0) \prod_{k=1}^n \lambda_k^F(y_{k-1}, dy_k) . \end{aligned}$$

Ce modèle général inclut comme cas particulier

- les modèles de Markov cachés, avec

$$\gamma_0(y, dx) = \eta_0(dx) g_0(x, y) \quad \text{et} \quad R_k(y', x, dx') = Q_k(x, dx') g_k(x', y') ,$$

- les modèles auto-régressifs à paramètres markoviens, avec

$$\gamma_0(y, dx) = \eta_0(dx) g_0(x, y) \quad \text{et} \quad R_k(y, y', x, dx') = Q_k(x, dx') g_k(x', y, y') .$$

En toute généralité, les mesures positives $\gamma_0(y, dx)$ et les noyaux positifs $R_k(y, y', x, dx')$ peuvent être factorisés comme

$$\gamma_0(y, dx) = g_0^{\text{imp}}(y, x) \eta_0^{\text{imp}}(y, dx) \quad \text{et} \quad R_k(y, y', x, dx') = g_k^{\text{imp}}(y, y', x, x') Q_k^{\text{imp}}(y, y', x, dx') ,$$

respectivement, c'est-à-dire comme le produit

- d'une fonction de pondération positive $g_0^{\text{imp}}(y, x)$ ou $g_k^{\text{imp}}(y, y', x, x')$,
- et d'une distribution de probabilité $\eta_0^{\text{imp}}(y, dx)$ ou d'un noyau markovien $Q_k^{\text{imp}}(y, y', x, dx')$.

Une telle factorisation n'est évidemment pas unique, mais il existe toujours au moins la factorisation donnée par

$$\gamma_0(y, dx) = \underbrace{\gamma_0(y, E)}_{\hat{g}_0(y)} \underbrace{\frac{\gamma_0(y, dx)}{\gamma_0(y, E)}}_{\hat{\eta}_0(y, dx)},$$

et

$$R_k(y, y', x, dx') = \underbrace{R_k(y, y', x, E)}_{\hat{g}_k(x, y, y')} \underbrace{\frac{R_k(y, y', x, dx')}{R_k(y, y', x, E)}}_{\hat{Q}_k(y, y', x, dx')},$$

avec l'interprétation suivante : en intégrant (5.3) par rapport à $x \in E$, on obtient

$$\mathbb{P}[Y_0 \in dy] = \hat{g}_0(y) \lambda_0^F(dy),$$

d'où on déduit que

$$\mathbb{P}[X_0 \in dx \mid Y_0 = y] = \hat{\eta}_0(y, dx),$$

et en intégrant (5.4) par rapport à $x' \in E$, on obtient

$$\mathbb{P}[Y_k \in dy' \mid X_{k-1} = x, Y_{k-1} = y] = \hat{g}_k(x, y, y') \lambda_k^F(dy'),$$

d'où on déduit que

$$\mathbb{P}[X_k \in dx' \mid X_{k-1} = x, Y_{k-1} = y, Y_k = y'] = \hat{Q}_k(y, y', x, dx').$$

Dans le cas particulier des modèles de Markov cachés, cette décomposition fait intervenir

- la probabilité d'émission

$$\mathbb{P}[Y_k \in dy' \mid X_{k-1} = x] = \hat{g}_k(x, y') \lambda_k^F(dy'),$$

où la fonction positive

$$\hat{g}_k(x, y') = \int_E Q_k(x, dx') g_k(x', y'),$$


peut être interprétée pour tout état $x \in E$ et pour toute observation $y' \in F$ comme une mesure quantitative du recouvrement entre l'application $x' \mapsto g_k(x', y')$ et la distribution de probabilité $Q_k(x, dx')$,

- et la transition de probabilité

$$\mathbb{P}[X_k \in dx' \mid X_{k-1} = x, Y_k = y'] = \hat{Q}_k(y', x, dx'),$$

où le noyau markovien $\hat{Q}_k(y', x, dx')$ dépend de l'observation $y' \in F$,

et la situation est complètement décrite par le diagramme suivant



où les flèches représentent la dépendance entre variables aléatoires.

Exemple 5.6 On considère un système non-linéaire avec des bruits gaussiens additifs et une fonction d'observation linéaire

$$X_k = f_k(X_{k-1}) + \sigma_k(X_{k-1}) W_k ,$$

$$Y_k = H_k X_k + h_k + V_k ,$$

où la condition initiale X_0 est un vecteur aléatoire gaussien de moyenne $\bar{X}_0$ et de matrice de covariance Q_0^X , et où les suites $\{W_k\}$ et $\{V_k\}$ sont des bruits blancs gaussiens indépendants, indépendants de la condition initiale X_0 , de matrices de covariance identité et Q_k^V respectivement, avec Q_k^V inversible. Il résulte de la Proposition 1.8 que

- conditionnellement à $Y_0 = y$, le vecteur aléatoire X_0 est gaussien, de moyenne

$$m_0(y) = \bar{X}_0 + Q_0^X H_0^* [H_0 Q_0^X H_0^* + Q_0^V]^{-1} (y - (H_0 \bar{X}_0 + h_0)) ,$$

et de matrice de covariance (pas nécessairement inversible)

$$P_0 = Q_0^X - Q_0^X H_0^* [H_0 Q_0^X H_0^* + Q_0^V]^{-1} H_0 Q_0^X ,$$

et il est facile de simuler un vecteur aléatoire X' selon la distribution de probabilité gaussienne

$$\hat{\eta}_0(y, dx) = \Gamma(dx, m_0(y), P_0) ,$$

de moyenne $m_0(y)$ et de matrice de covariance P_0 pour tout $y \in F$: il suffit en effet, d'après la Remarque 1.9, de simuler deux vecteurs aléatoires gaussiens indépendants X et V , de moyenne $\bar{X}_0$ et 0 et de matrice de covariance Q_0^X et Q_0^V respectivement, et de poser

$$X' = X + Q_0^X H_0^* [H_0 Q_0^X H_0^* + Q_0^V]^{-1} (Y_0 - (H_0 X + h_0 + V)) .$$

Grâce à la linéarité de la fonction d'observation, on a

$$X_k = f_k(X_{k-1}) + \sigma_k(X_{k-1}) W_k ,$$

$$Y_k = H_k f_k(X_{k-1}) + h_k + H_k \sigma_k(X_{k-1}) W_k + V_k ,$$

d'où on déduit que conditionnellement à $X_{k-1} = x$, le vecteur aléatoire (X_k, Y_k) est gaussien, de moyenne et de matrice de covariance

$$\begin{pmatrix} f_k(x) \\ H_k f_k(x) + h_k \end{pmatrix} \quad \text{et} \quad \begin{pmatrix} \Sigma_k(x) & \Sigma_k(x) H_k^* \\ H_k \Sigma_k(x) & H_k \Sigma_k(x) H_k^* + Q_k^V \end{pmatrix} ,$$

respectivement, avec $\Sigma_k(x) = \sigma_k(x) \sigma_k^*(x)$. Compte tenu que la matrice Q_k^V est inversible, la matrice $H_k \Sigma_k(x) H_k^* + Q_k^V$ est inversible a fortiori, et il résulte de la Proposition 1.8 que

- conditionnellement à $X_{k-1} = x$, le vecteur aléatoire Y_k est gaussien, de moyenne $H_k f_k(x) + h_k$ et de matrice de covariance inversible $H_k \Sigma_k(x) H_k^* + Q_k^V$, et il est facile d'évaluer la densité de probabilité gaussienne

$$\hat{g}_k(x, y') = q(y' - (H_k f_k(x) + h_k), H_k \Sigma_k(x) H_k^* + Q_k^V) ,$$

de moyenne $H_k f_k(x) + h_k$ et de matrice de covariance inversible $H_k \Sigma_k(x) H_k^* + Q_k^V$, pour tout $x \in E$ et tout $y' \in F$,

- conditionnellement à $(X_{k-1} = x, Y_k = y')$ le vecteur aléatoire X_k est gaussien, de moyenne

$$m_k(y', x) = f_k(x) + \Sigma_k(x) H_k^* [H_k \Sigma_k(x) H_k^* + Q_k^V]^{-1} (y' - (H_k f_k(x) + h_k)) ,$$

et de matrice de covariance (pas nécessairement inversible)

$$P_k(x) = \Sigma_k(x) - \Sigma_k(x) H_k^* [H_k \Sigma_k(x) H_k^* + Q_k^V]^{-1} H_k \Sigma_k(x) ,$$

et il est facile de simuler un vecteur aléatoire X' selon la distribution de probabilité gaussienne

$$\hat{Q}_k(y', x, dx') = \Gamma(dx', m_k(y', x), P_k(x)) ,$$

de moyenne $m_k(y', x)$ et de matrice de covariance $P_k(x)$ pour tout $x \in E$ et tout $y' \in F$: il suffit en effet, d'après la Remarque 1.9, de simuler deux vecteurs aléatoires gaussiens indépendants W et V , centrés et de matrice de covariance identité et Q_k^V respectivement, et de poser

$$X = f_k(x) + \sigma_k(x) W ,$$

et

$$X' = X + \Sigma_k(x) H_k^* [H_k \Sigma_k(x) H_k^* + Q_k^V]^{-1} (y' - (H_k X + h_k + V)) .$$

Chapitre 6

Borne de Cramér–Rao a posteriori

Pour évaluer la performance des algorithmes numériques de filtrage non-linéaire, y compris les nombreuses variantes du filtrage particulaire, il est utile de disposer d'une borne inférieure sur l'erreur commise par un estimateur quelconque de l'état caché. S'il s'agit d'estimer un paramètre fixe, il est bien connu que la matrice d'information de Fisher associée au modèle statistique permet d'obtenir une telle borne inférieure, sous le nom de borne de Cramér–Rao. Dans le cas du filtrage bayésien, il s'agit d'estimer un paramètre aléatoire (et dynamique), à savoir la suite des états cachés, pour lequel on dispose d'un modèle a priori : dans ce cadre bayésien, on peut utiliser la notion de borne de Cramér–Rao a posteriori, pour laquelle des algorithmes de calcul récurrents efficaces ont été obtenus.

On considère le cas général d'un modèle de Markov caché, et on suppose qu'il existe

- pour $k = 0$, une densité initiale

$$\mathbb{P}[X_0 \in dx] = p_0(x, y) dx ,$$

- pour tout $k = 1, \dots, n$, des densités de transition

$$\mathbb{P}[X_k \in dx' \mid X_{k-1} = x] = p_k(x' \mid x) dx' ,$$

- pour tout $k = 0, 1, \dots, n$, des densités d'émission

$$\mathbb{P}[Y_k \in dy \mid X_k = x] = q_k(y \mid x) dy .$$

On peut poser dans ce cas

$$X_{0:n} = (X_0, \dots, X_n) \quad \text{et} \quad Y_{0:n} = (Y_0, \dots, Y_n) ,$$

et se ramener au problème statique considéré dans la Proposition 1.4 ci-dessus pour l'estimation du vecteur aléatoire

$$\phi(X_{0:n}) = X_n ,$$

sachant $Y_{0:n}$.

On introduit les matrices symétriques suivantes : premièrement

$$D_k = \begin{pmatrix} D_k^{11} & D_k^{12} \\ D_k^{21} & D_k^{22} \end{pmatrix} = -\mathbb{E}\left[\frac{\partial^2}{\partial x_{k-1:k}^2} \log p_k(X_k | X_{k-1})\right],$$

où les blocs sont définis comme

$$\begin{aligned} D_k^{11} &= -\mathbb{E}\left[\frac{\partial^2}{\partial x_{k-1}^2} \log p_k(X_k | X_{k-1})\right], \\ D_k^{12} &= -\mathbb{E}\left[\frac{\partial^2}{\partial x_{k-1} \partial x_k} \log p_k(X_k | X_{k-1})\right], \\ D_k^{22} &= -\mathbb{E}\left[\frac{\partial^2}{\partial x_k^2} \log p_k(X_k | X_{k-1})\right], \end{aligned}$$

pour tout $k = 1, \dots, n$, deuxièmement

$$D_0^{22} = -\mathbb{E}\left[\frac{\partial^2}{\partial x_0^2} \log p_0(X_0)\right],$$

et troisièmement

$$E_k = -\mathbb{E}\left[\frac{\partial^2}{\partial x_k^2} \log q_k(Y_k | X_k)\right],$$

pour tout $k = 0, 1, \dots, n$.

Théorème 6.1 *Si la matrice D_k^{22} est inversible pour tout $k = 0, 1, \dots, n$, alors la matrice d'information de Fisher J_n (de dimension $m \times m$) définie de la façon récursive suivante*

$$J_k^- = D_k^{22} - D_k^{21} (J_{k-1} + D_k^{11})^{-1} D_k^{12} \quad \text{et} \quad J_k = J_k^- + E_k,$$

pour tout $k = 1, \dots, n$, et avec l'initialisation

$$J_0^- = D_0^{22} \quad \text{et} \quad J_0 = J_0^- + E_0,$$

est inversible, et la matrice de corrélation de l'erreur d'estimation est minorée par la relation suivante

$$\mathbb{E}[(\psi(Y_{0:n}) - \phi(X_n)) (\psi(Y_{0:n}) - \phi(X_n))^*] \geq M_n J_n^{-1} M_n^*,$$

avec la matrice de sensibilité (de dimension $p \times m$) définie par

$$M_n = \mathbb{E}[\phi'(X_n)].$$

PREUVE. On se propose d'utiliser la Proposition 1.4, formulée dans le cas statique, et de l'appliquer aux variables trajectorielles $X_{0:n} = (X_0, X_1, \dots, X_n)$ et $Y_{0:n} = (Y_0, Y_1, \dots, Y_n)$, et à une statistique $\phi_{0:n}(x_{0:n}) = \phi(x_n)$ ne dépendant que de l'état final x_n , de sorte que la matrice jacobienne

$$\phi'_{0:n}(x_{0:n}) = \begin{pmatrix} 0 & \phi'(x_n) \end{pmatrix},$$

ne dépend aussi que de l'état final x_n . On obtient ainsi la borne

$$\mathbb{E}[(\psi(Y_{0:n}) - \phi(X_n))(\psi(Y_{0:n}) - \phi(X_n))^*] \geq M_{0:n} J_{0:n}^{-1} M_{0:n}^* ,$$

avec la matrice d'information de Fisher (de dimension $(n+1)m \times (n+1)m$)

$$J_{0:n} = -\mathbb{E}\left[\frac{\partial^2}{\partial x_{0:n}^2} \log p_{0:n}(X_{0:n}, Y_{0:n})\right] ,$$

supposée inversible, et avec la matrice de sensibilité (de dimension $p \times (n+1)m$)

$$M_{0:n} = \mathbb{E}[\phi'_{0:n}(X_{0:n})] = \begin{pmatrix} 0 & \mathbb{E}[\phi'(X_n)] \end{pmatrix} = \begin{pmatrix} 0 & M_n \end{pmatrix} .$$

La densité jointe des vecteurs aléatoires $X_{0:n}$ et $Y_{0:n}$ est donnée par

$$\begin{aligned} p_{0:k}(x_{0:k}, y_{0:k}) &= p_0(x_0) \prod_{k=1}^n p_k(x_k | x_{k-1}) \prod_{k=0}^n q_k(y_k | x_k) \\ &= p_{0:n-1}(x_{0:n-1}, y_{0:n-1}) p_n(x_n | x_{n-1}) q_n(y_n | x_n) , \end{aligned}$$

d'où l'expression récurrente de la log-densité

$$\log p_{0:k}(x_{0:k}, y_{0:k}) = \log p_{0:k-1}(x_{0:k-1}, y_{0:k-1}) + \log p_k(x_k | x_{k-1}) + \log q_k(y_k | x_k) ,$$

et on commence par expliciter les trois matrices hessiennes associées aux trois termes figurant dans le membre de droite. Premièrement

$$\begin{aligned} \frac{\partial^2}{\partial x_{0:k}^2} \log p_{0:k-1}(x_{0:k-1}, y_{0:k-1}) &= \begin{pmatrix} \frac{\partial^2}{\partial x_{0:k-1}^2} & \frac{\partial^2}{\partial x_{0:k-1} \partial x_k} \\ \star & \frac{\partial^2}{\partial x_k^2} \end{pmatrix} \log p_{0:k-1}(x_{0:k-1}, y_{0:k-1}) \\ &= \begin{pmatrix} \frac{\partial^2}{\partial x_{0:k-1}^2} \log p_{0:k-1}(x_{0:k-1}, y_{0:k-1}) & 0 \\ 0 & 0 \end{pmatrix} , \end{aligned}$$

de sorte que

$$-\mathbb{E}\left[\frac{\partial^2}{\partial x_{0:k}^2} \log p_{0:k-1}(X_{0:k-1}, Y_{0:k-1})\right] = \begin{pmatrix} J_{0:k-1} & 0 \\ 0 & 0 \end{pmatrix} .$$

Deuxièmement

$$\begin{aligned} \frac{\partial^2}{\partial x_{0:k}^2} \log p_k(x_k | x_{k-1}) &= \begin{pmatrix} \frac{\partial^2}{\partial x_{0:k-2}^2} & \frac{\partial^2}{\partial x_{0:k-2} \partial x_{k-1:k}} \\ \star & \frac{\partial^2}{\partial x_{k-1:k}^2} \end{pmatrix} \log p_k(x_k | x_{k-1}) \\ &= \begin{pmatrix} 0 & 0 \\ 0 & \frac{\partial^2}{\partial x_{k-1:k}^2} \log p_k(x_k | x_{k-1}) \end{pmatrix} , \end{aligned}$$

de sorte que

$$-\mathbb{E}\left[\frac{\partial^2}{\partial x_{0:k}^2} \log p_k(X_k | X_{k-1})\right] = \begin{pmatrix} 0 & 0 \\ 0 & D_k \end{pmatrix}.$$

Troisièmement et dernièrement

$$\begin{aligned} \frac{\partial^2}{\partial x_{0:k}^2} \log q_k(y_k | x_k) &= \begin{pmatrix} \frac{\partial^2}{\partial x_{0:k-1}^2} & \frac{\partial^2}{\partial x_{0:k-1} \partial x_k} \\ \star & \frac{\partial^2}{\partial x_k^2} \end{pmatrix} \log q_k(y_k | x_k) \\ &= \begin{pmatrix} 0 & 0 \\ 0 & \frac{\partial^2}{\partial x_k^2} \log q_k(y_k | x_k) \end{pmatrix}, \end{aligned}$$

de sorte que

$$-\mathbb{E}\left[\frac{\partial^2}{\partial x_{0:k}^2} \log q_k(Y_k | X_k)\right] = \begin{pmatrix} 0 & 0 \\ 0 & E_k \end{pmatrix}.$$

En regroupant ces identités, on obtient donc

$$\begin{aligned} J_{0:k} &= -\mathbb{E}\left[\frac{\partial^2}{\partial x_{0:k}^2} \log p_{0:k}(X_{0:k}, Y_{0:k})\right] \\ &= -\mathbb{E}\left[\frac{\partial^2}{\partial x_{0:k}^2} \log p_{0:k-1}(X_{0:k-1}, Y_{0:k-1})\right] \\ &\quad -\mathbb{E}\left[\frac{\partial^2}{\partial x_{0:k}^2} \log p_k(X_k | X_{k-1})\right] - \mathbb{E}\left[\frac{\partial^2}{\partial x_{0:k}^2} \log q_k(Y_k | X_k)\right] \\ &= \begin{pmatrix} J_{0:k-1} & 0 \\ 0 & E_k \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & D_k \end{pmatrix}, \end{aligned}$$

et on se propose d'utiliser cette relation de récurrence pour montrer la propriété suivante

La matrice $J_{0:k}$ est inversible, pour tout $k = 0, 1, \dots, n$.

Attention cependant : les dimensions des différents blocs figurant dans le membre de droite ne sont pas constantes ! On vérifie en effet que $J_{0:k}$ est une matrice $(k+1)m \times (k+1)m$, que les blocs diagonaux $J_{0:k-1}$ et E_k sont des matrices $km \times km$ et $m \times m$ respectivement, tandis que le bloc diagonal D_k est une matrice $2m \times 2m$.

On suppose que la propriété est vérifiée au rang $(k-1)$, c'est-à-dire que la matrice $J_{0:k-1}$ est inversible. Soit u , v , et w trois vecteurs quelconques de dimension $(k-1)m$, m et m respectivement, de sorte que les trois vecteurs notés

$$[uvw] = \begin{pmatrix} u \\ v \\ w \end{pmatrix}, \quad [uv] = \begin{pmatrix} u \\ v \end{pmatrix} \quad \text{et} \quad [vw] = \begin{pmatrix} v \\ w \end{pmatrix},$$

sont des vecteurs de dimension $(k+1)m$, km et $2m$ respectivement. On remarque que l'expression

$$\begin{aligned} & [uvw]^* J_{0:k} [uvw] \\ &= \begin{pmatrix} [uv]^* & w^* \end{pmatrix} \begin{pmatrix} J_{0:k-1} & 0 \\ 0 & E_k \end{pmatrix} \begin{pmatrix} [uv] \\ w \end{pmatrix} + \begin{pmatrix} u^* & [vw]^* \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 0 & D_k \end{pmatrix} \begin{pmatrix} u \\ [vw] \end{pmatrix} \\ &= [uv]^* J_{0:k-1} [uv] + w^* E_k w + [vw]^* D_k [vw] , \end{aligned}$$

se décompose comme la somme de trois expressions positives ou nulles. Clairement, si l'expression $[uvw]^* J_{0:k} [uvw]$ s'annule, alors nécessairement chacune des trois expressions

$$[uv]^* J_{0:k-1} [uv] , \quad w^* E_k w \quad \text{et} \quad [vw]^* D_k [vw] ,$$

s'annule. Si la première expression $[uv]^* J_{0:k-1} [uv]$ s'annule, alors nécessairement $[uv] = 0$ car la matrice $J_{0:k-1}$ est définie positive d'après l'hypothèse de récurrence. Si $[uv] = 0$, alors la troisième expression $[vw]^* D_k [vw]$ se réduit à $w^* D_k^{22} w$ et si cette expression s'annule, alors nécessairement $w = 0$ car la matrice D_k^{22} est inversible. Finalement, si l'expression $[uvw]^* J_{0:k} [uvw]$ s'annule, alors nécessairement $[uvw] = 0$ et on en déduit que la matrice $J_{0:k}$ est définie positive, donc inversible, c'est-à-dire que la propriété est vérifiée au rang k .

En introduisant la décomposition sous forme de matrice-bloc

$$J_{0:k} = -\mathbb{E} \left[\frac{\partial^2}{\partial x_{0:k}^2} \log p_{0:k}(X_{0:k}, Y_{0:k}) \right] = \begin{pmatrix} A_k & B_k \\ B_k^* & C_k \end{pmatrix} ,$$

on obtient

$$\begin{aligned} J_{0:k} &= \begin{pmatrix} J_{0:k-1} & 0 \\ 0 & E_k \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & D_k \end{pmatrix} \\ &= \begin{pmatrix} A_{k-1} & B_{k-1} & 0 \\ B_{k-1}^* & C_{k-1} & 0 \\ 0 & 0 & E_k \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 \\ 0 & D_k^{11} & D_k^{12} \\ 0 & D_k^{21} & D_k^{22} \end{pmatrix} \\ &= \begin{pmatrix} A_{k-1} & B_{k-1} & 0 \\ B_{k-1}^* & C_{k-1} + D_k^{11} & D_k^{12} \\ 0 & D_k^{21} & E_k + D_k^{22} \end{pmatrix} . \end{aligned}$$

Par comparaison des deux décompositions de $J_{0:k}$ sous forme de matrice-bloc, on obtient les identifications

$$A_k = \begin{pmatrix} A_{k-1} & B_{k-1} \\ B_{k-1}^* & C_{k-1} + D_k^{11} \end{pmatrix} , \quad B_k = \begin{pmatrix} 0 \\ D_k^{12} \end{pmatrix} \quad \text{et} \quad C_k = E_k + D_k^{22} ,$$

et on se propose d'utiliser cette relation de récurrence pour montrer la propriété suivante

La matrice A_k est inversible, pour tout $k = 0, 1, \dots, n$.

On suppose que la propriété est vérifiée au rang $(k-1)$, c'est-à-dire que la matrice A_{k-1} est inversible. Puisque la matrice A_{k-1} est inversible, on peut définir son complément de Schur

$$J_{k-1} = C_{k-1} - B_{k-1}^* A_{k-1}^{-1} B_{k-1} ,$$

dans la matrice-bloc

$$J_{0:k-1} = \begin{pmatrix} A_{k-1} & B_{k-1} \\ B_{k-1}^* & C_{k-1} \end{pmatrix} .$$

Puisque la matrice A_{k-1} et la matrice-bloc $J_{0:k-1}$ sont inversibles, alors le complément de Schur J_{k-1} est inversible d'après la Remarque A.4. Puisque la matrice A_{k-1} est inversible, on peut aussi définir son complément de Schur

$$\Delta_{k-1} = C_{k-1} + D_k^{11} - B_{k-1}^* A_{k-1}^{-1} B_{k-1} = J_{k-1} + D_k^{11} ,$$

dans la matrice-bloc

$$A_k = \begin{pmatrix} A_{k-1} & B_{k-1} \\ B_{k-1}^* & C_{k-1} + D_k^{11} \end{pmatrix} .$$

Puisque la matrice J_{k-1} est inversible, et donc définie positive, alors a fortiori la matrice Δ_{k-1} est définie positive, donc inversible. Puisque la matrice A_{k-1} et le complément de Schur Δ_{k-1} sont inversibles, alors la matrice-bloc A_k est inversible d'après la Remarque A.4, c'est-à-dire que la propriété est vérifiée au rang k .

En utilisant la Remarque A.4, il vient

$$A_k^{-1} = \begin{pmatrix} A_{k-1} & B_{k-1} \\ B_{k-1}^* & C_{k-1} + D_k^{11} \end{pmatrix}^{-1} = \begin{pmatrix} \star & \star \\ \star & \Delta_{k-1}^{-1} \end{pmatrix} ,$$

et par ailleurs

$$J_{0:k}^{-1} = \begin{pmatrix} A_k & B_k \\ B_k^* & C_k \end{pmatrix}^{-1} = \begin{pmatrix} \star & \star \\ \star & J_k^{-1} \end{pmatrix} ,$$

avec

$$J_k = C_k - B_k^* A_k^{-1} B_k ,$$

complément de Schur de la matrice A_k dans la matrice-bloc $J_{0:k}$. On en déduit que

$$\begin{aligned} M_{0:n} J_{0:n}^{-1} M_{0:n}^* &= \begin{pmatrix} 0 & M_n \end{pmatrix} \begin{pmatrix} \star & \star \\ \star & J_n^{-1} \end{pmatrix} \begin{pmatrix} 0 \\ M_n^* \end{pmatrix} \\ &= M_n J_n^{-1} M_n^* , \end{aligned}$$

et

$$\begin{aligned} J_k &= C_k - B_k^* A_k^{-1} B_k \\ &= E_k + D_k^{22} - \begin{pmatrix} 0 & D_k^{21} \end{pmatrix} \begin{pmatrix} \star & \star \\ \star & \Delta_{k-1}^{-1} \end{pmatrix} \begin{pmatrix} 0 \\ D_k^{12} \end{pmatrix} \\ &= E_k + D_k^{22} - D_k^{21} (J_{k-1} + D_k^{11})^{-1} D_k^{12} . \quad \square \end{aligned}$$

Exemple 6.2 Dans le cas particulier d'un système non-linéaire avec des bruits gaussiens additifs, où

$$X_k = f_k(X_{k-1}) + W_k \quad \text{avec} \quad W_k \sim \mathcal{N}(0, Q_k^W),$$

et où

$$Y_k = h_k(X_k) + V_k \quad \text{avec} \quad V_k \sim \mathcal{N}(0, Q_k^V),$$

avec des matrices de covariance Q_k^W et Q_k^V inversibles, on obtient les expressions suivantes

$$D_k^{11} = \mathbb{E} [[f'_k(X_{k-1})]^* (Q_k^W)^{-1} f'_k(X_{k-1})],$$

$$D_k^{12} = -\mathbb{E} [[f'_k(X_{k-1})]^*] (Q_k^W)^{-1},$$

$$D_k^{22} = (Q_k^W)^{-1},$$

et

$$E_k = \mathbb{E} [[h'_k(X_k)]^* (Q_k^V)^{-1} h'_k(X_k)].$$

Clairement, la matrice D_k^{22} est inversible, de sorte que l'hypothèse du Théorème 6.1 est vérifiée. Par ailleurs, la matrice E_k est semi-définie positive, et on vérifie que la matrice

$$D_k = \begin{pmatrix} D_k^{11} & D_k^{12} \\ D_k^{21} & D_k^{22} \end{pmatrix},$$

est semi-définie positive. En effet

$$\begin{aligned} \begin{pmatrix} u^* & v^* \end{pmatrix} \begin{pmatrix} D_k^{11} & D_k^{12} \\ D_k^{21} & D_k^{22} \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} &= u^* \mathbb{E} [[f'_k(X_{k-1})]^* (Q_k^W)^{-1} f'_k(X_{k-1})] u \\ &\quad - u^* \mathbb{E} [[f'_k(X_{k-1})]^*] (Q_k^W)^{-1} v - v^* (Q_k^W)^{-1} \mathbb{E} [f'_k(X_{k-1})] u \\ &\quad + v^* (Q_k^W)^{-1} v \\ &= \mathbb{E} [[f'_k(X_{k-1}) u - v]^* (Q_k^W)^{-1} [f'_k(X_{k-1}) u - v]] \geq 0, \end{aligned}$$

pour tout $u, v \in \mathbb{R}^m$.

Chapitre 7

Filtrage bayésien

L'objectif de ce chapitre est d'établir les équations du filtre non-linéaire, pour les systèmes non-linéaires et non-gaussiens, ou plus généralement les équations du filtre bayésien, pour les modèles de Markov cachés et les chaînes de Markov partiellement observées. Il s'agit donc de calculer la distribution de probabilité conditionnelle de la variable aléatoire X_k sachant $Y_{0:k}$, et la distribution de probabilité conditionnelle de la variable aléatoire X_k sachant $Y_{0:k-1}$, définies par

$$\mu_k(dx) = \mathbb{P}[X_k \in dx \mid Y_{0:k}] \quad \text{et} \quad \mu_k^-(dx) = \mathbb{P}[X_k \in dx \mid Y_{0:k-1}] ,$$

respectivement.

7.1 Modèles de Markov cachés

D'après la formule de Bayes, et d'après la propriété de canal sans mémoire, la distribution de probabilité jointe des états cachés $X_{0:n}$ et des observations $Y_{0:n}$ vérifie

$$\begin{aligned} \mathbb{P}[X_{0:n} \in dx_{0:n}, Y_{0:n} \in dy_{0:n}] &= \mathbb{P}[Y_{0:n} \in dy_{0:n} \mid X_{0:n} = x_{0:n}] \mathbb{P}[X_{0:n} \in dx_{0:n}] \\ &= \mathbb{P}[X_{0:n} \in dx_{0:n}] \prod_{k=0}^n g_k(x_k, y_k) \lambda_0^F(dy_0) \cdots \lambda_n^F(dy_n) . \end{aligned}$$

En intégrant par rapport aux variables $x_{0:n}$, on obtient la distribution de probabilité jointe des observations $Y_{0:n}$, c'est-à-dire

$$\begin{aligned} \mathbb{P}[Y_{0:n} \in dy_{0:n}] &= \int_E \cdots \int_E \prod_{k=0}^n g_k(x_k, y_k) \mathbb{P}[X_{0:n} \in dx_{0:n}] \lambda_0^F(dy_0) \cdots \lambda_n^F(dy_n) \\ &= \mathbb{E}[\prod_{k=0}^n g_k(X_k, y_k)] \lambda_0^F(dy_0) \cdots \lambda_n^F(dy_n) . \end{aligned}$$

D'après la formule de Bayes, il vient

$$\begin{aligned}
& \mathbb{P}[X_{0:n} \in dx_{0:n}, Y_{0:n} \in dy_{0:n}] \\
&= \mathbb{P}[X_{0:n} \in dx_{0:n}] \prod_{k=0}^n g_k(x_k, y_k) \lambda_0^F(dy_0) \cdots \lambda_n^F(dy_n) \\
&= \mathbb{P}[X_{0:n} \in dx_{0:n} \mid Y_{0:n} = y_{0:n}] \mathbb{P}[Y_{0:n} \in dy_{0:n}] \\
&= \mathbb{P}[X_{0:n} \in dx_{0:n} \mid Y_{0:n} = y_{0:n}] \mathbb{E}\left[\prod_{k=0}^n g_k(X_k, y_k)\right] \lambda_0^F(dy_0) \cdots \lambda_n^F(dy_n),
\end{aligned}$$

et on obtient

$$\mathbb{P}[X_{0:n} \in dx_{0:n} \mid Y_{0:n} = y_{0:n}] = \frac{\prod_{k=0}^n g_k(x_k, y_k) \mathbb{P}[X_{0:n} \in dx_{0:n}]}{\mathbb{E}\left[\prod_{k=0}^n g_k(X_k, y_k)\right]},$$

pour toute suite $y_{0:n}$ d'observations. Pour toute fonction test f définie sur l'espace produit $E^{n+1} = E \times \cdots \times E$, on a

$$\begin{aligned}
\mathbb{E}[f(X_{0:n}) \mid Y_{0:n} = y_{0:n}] &= \frac{\int_E \cdots \int_E f(x_{0:n}) \prod_{k=0}^n g_k(x_k, y_k) \mathbb{P}[X_{0:n} \in dx_{0:n}]}{\mathbb{E}\left[\prod_{k=0}^n g_k(X_k, y_k)\right]} \\
&= \frac{\mathbb{E}\left[f(X_{0:n}) \prod_{k=0}^n g_k(X_k, y_k)\right]}{\mathbb{E}\left[\prod_{k=0}^n g_k(X_k, y_k)\right]},
\end{aligned}$$

et on rappelle que

$$\mathbb{P}[Y_{0:n} \in dy_{0:n}] = \mathbb{E}\left[\prod_{k=0}^n g_k(X_k, y_k)\right] \lambda_0^F(dy_0) \cdots \lambda_n^F(dy_n),$$

et comme ces identités sont vérifiées pour toute suite $y_{0:n}$ d'observations, on en déduit que la distribution de probabilité conditionnelle jointe des états cachés $X_{0:n}$ sachant $Y_{0:n}$ est donnée par

$$\mathbb{E}[f(X_{0:n}) \mid Y_{0:n}] = \frac{\mathbb{E}\left[f(X_{0:n}) \prod_{k=0}^n g_k(X_k)\right]}{\mathbb{E}\left[\prod_{k=0}^n g_k(X_k)\right]}, \quad (7.1)$$

et la fonction de vraisemblance du modèle est donnée par

$$L_n = \mathbb{E} \left[\prod_{k=0}^n g_k(X_k) \right] ,$$

où l'espérance porte seulement sur la suite des états cachés $X_{0:n}$: les fonctions de vraisemblance $g_0(x), \dots, g_n(x)$ sont définies par abus de notation comme

$$g_k(x) = g_k(x, Y_k) ,$$

pour tout $k = 0, 1, \dots, n$, et dépendent implicitement des observations $Y_{0:n}$, mais celles-ci sont considérées comme fixées dans les expressions ci-dessus. En particulier, la distribution de probabilité conditionnelle de l'état caché X_n sachant $Y_{0:n}$ est donnée par

$$\langle \mu_n, \phi \rangle = \mathbb{E}[\phi(X_n) \mid Y_{0:n}] = \frac{\mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_k)]}{\mathbb{E}[\prod_{k=0}^n g_k(X_k)]} = \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} ,$$

où la mesure positive (non-normalisée) $\gamma_n(dx)$ est définie par

$$\langle \gamma_n, \phi \rangle = \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_k)] ,$$

et pour $\phi \equiv 1$, on a

$$\langle \gamma_n, 1 \rangle = \mathbb{E}[\prod_{k=0}^n g_k(X_k)] = L_n .$$

De la même manière, la distribution de probabilité conditionnelle de l'état caché X_n sachant $Y_{0:n-1}$ est donnée par

$$\langle \mu_n^-, \phi \rangle = \mathbb{E}[\phi(X_n) \mid Y_{0:n-1}] = \frac{\mathbb{E}[\phi(X_n) \prod_{k=0}^{n-1} g_k(X_k)]}{\mathbb{E}[\prod_{k=0}^{n-1} g_k(X_k)]} = \frac{\langle \gamma_n^-, \phi \rangle}{\langle \gamma_n^-, 1 \rangle} ,$$

où la mesure positive (non-normalisée) $\gamma_n^-(dx)$ est définie par

$$\langle \gamma_n^-, \phi \rangle = \mathbb{E}[\phi(X_n) \prod_{k=0}^{n-1} g_k(X_k)] ,$$

et pour $\phi \equiv 1$, on a

$$\langle \gamma_n^-, 1 \rangle = \mathbb{E}[\prod_{k=0}^{n-1} g_k(X_k)] = \langle \gamma_{n-1}, 1 \rangle .$$

Pour obtenir une équation récurrente permettant d'exprimer μ_k en fonction de μ_{k-1} , il suffit donc d'une équation récurrente permettant d'exprimer γ_k en fonction de γ_{k-1} , puis de normaliser.

Théorème 7.1 (Filtre bayésien) *La suite $\{\mu_k\}$ vérifie l'équation récurrente suivante*

$$\mu_{k-1} \xrightarrow{\text{prédiction}} \mu_k^- = \mu_{k-1} Q_k \xrightarrow{\text{correction}} \mu_k = g_k \cdot \mu_k^- ,$$

et la suite $\{L_k\}$ vérifie l'équation récurrente suivante

$$L_k = \langle \mu_k^-, g_k \rangle L_{k-1} \quad \text{soit en itérant} \quad L_n = \prod_{k=1}^n \langle \mu_k^-, g_k \rangle \langle \eta_0, g_0 \rangle .$$

Remarque 7.2 Dans l'énoncé du théorème, la notation

$$\mu_{k-1} Q_k(dx') = \int_E \mu_{k-1}(dx) Q_k(x, dx')$$

désigne l'action du noyau markovien $Q_k(x, dx')$ sur la distribution de probabilité $\mu_{k-1}(dx)$, et la notation

$$g_k \cdot \mu_k^- = \frac{g_k \mu_k^-}{\langle \mu_k^-, g_k \rangle} ,$$

désigne le produit projectif de la distribution de probabilité a priori $\mu_k^-(dx')$ et de la fonction de vraisemblance $g_k(x')$. De manière équivalente

$$\langle \mu_{k-1} Q_k, \phi \rangle = \langle \mu_{k-1}, Q_k \phi \rangle = \int_E \mu_{k-1}(dx) \mathbb{E}[\phi(X_k) \mid X_{k-1} = x] ,$$

et

$$\langle g_k \cdot \mu_k^-, \phi \rangle = \frac{\langle \mu_k^-, g_k \phi \rangle}{\langle \mu_k^-, g_k \rangle} = \frac{\int_E \phi(x) g_k(x) \mu_k^-(dx)}{\int_E g_k(x) \mu_k^-(dx)} ,$$

pour toute fonction mesurable bornée ϕ .

Remarque 7.3 De manière équivalente

$$\mu_k = \frac{\mu_{k-1} R_k}{\langle \mu_{k-1} R_k, 1 \rangle} ,$$

en une seule étape, avec le noyau positif (non-normalisé) $R_k(x, dx') = Q_k(x, dx') g_k(x')$. En effet, pour toute fonction mesurable bornée ϕ

$$\begin{aligned} \langle \mu_{k-1} R_k, \phi \rangle &= \int_E \mu_{k-1} R_k(dx') \phi(x') \\ &= \int_E \left[\int_E \mu_{k-1}(dx) R_k(x, dx') \right] \phi(x') \\ &= \int_E \int_E \mu_{k-1}(dx) Q_k(x, dx') g_k(x') \phi(x') \\ &= \int_E \left[\int_E \mu_{k-1}(dx) Q_k(x, dx') \right] g_k(x') \phi(x') \\ &= \int_E \mu_k^-(dx') g_k(x') \phi(x') = \langle \mu_k^-, g_k \phi \rangle , \end{aligned}$$

et en particulier pour $\phi \equiv 1$

$$\langle \mu_{k-1} R_k, 1 \rangle = \langle \mu_k^-, g_k \rangle ,$$

et en normalisant, on vérifie que

$$\frac{\langle \mu_{k-1} R_k, \phi \rangle}{\langle \mu_{k-1} R_k, 1 \rangle} = \frac{\langle \mu_k^-, g_k \phi \rangle}{\langle \mu_k^-, g_k \rangle} = \langle \mu_k, \phi \rangle .$$

PREUVE DU THÉORÈME 7.1. On procède en deux étapes, correspondant respectivement aux étapes de prédiction et de correction, et en raisonnant d'abord sur les versions non normalisées.

Expression de μ_n^- en fonction de μ_{n-1} :

On remarque immédiatement que

$$\langle \gamma_n^-, 1 \rangle = \mathbb{E} \left[\prod_{k=0}^{n-1} g_k(X_k) \right] = \langle \gamma_{n-1}, 1 \rangle ,$$

c'est-à-dire que la constante de normalisation est conservée. En utilisant la propriété de Markov, on a

$$\begin{aligned} \langle \gamma_n^-, \phi \rangle &= \mathbb{E} [\phi(X_n) \prod_{k=0}^{n-1} g_k(X_k)] \\ &= \mathbb{E} [\mathbb{E} [\phi(X_n) \mid X_{0:n-1}] \prod_{k=0}^{n-1} g_k(X_k)] \\ &= \mathbb{E} [\mathbb{E} [\phi(X_n) \mid X_{n-1}] \prod_{k=0}^{n-1} g_k(X_k)] \\ &= \mathbb{E} [Q_n \phi(X_{n-1}) \prod_{k=0}^{n-1} g_k(X_k)] = \langle \gamma_{n-1}, Q_n \phi \rangle = \langle \gamma_{n-1} Q_n, \phi \rangle , \end{aligned}$$

pour toute fonction test ϕ définie sur E , où la dernière égalité exprime simplement que

$$\begin{aligned} \langle \gamma_{n-1}, Q_n \phi \rangle &= \int_E \gamma_{n-1}(dx) Q_n \phi(x) \\ &= \int_E \gamma_{n-1}(dx) \left[\int_E Q_n(x, dx') \phi(x') \right] = \int_E \left[\int_E \gamma_{n-1}(dx) Q_n(x, dx') \right] \phi(x') \\ &= \int_E \gamma_{n-1} Q_n(dx') \phi(x') = \langle \gamma_{n-1} Q_n, \phi \rangle . \end{aligned}$$

Comme la fonction test ϕ est quelconque, on en déduit que

$$\gamma_n^- = \gamma_{n-1} Q_n ,$$

et en normalisant, on obtient

$$\mu_n^- = \frac{\gamma_n^-}{\langle \gamma_n^-, 1 \rangle} = \frac{\gamma_{n-1} Q_n}{\langle \gamma_{n-1}, 1 \rangle} = \mu_{n-1} Q_n .$$

Expression de μ_n en fonction de μ_n^- :

On a simplement

$$\begin{aligned}\langle \gamma_n, \phi \rangle &= \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_k)] \\ &= \mathbb{E}[\phi(X_n) g_n(X_n) \prod_{k=0}^{n-1} g_k(X_k)] = \langle \gamma_n^-, g_n \phi \rangle = \langle g_n \gamma_n^-, \phi \rangle ,\end{aligned}$$

pour toute fonction test ϕ définie sur E , où la dernière égalité exprime simplement que

$$\langle \gamma_n^-, g_n \phi \rangle = \int_E [g_n(x) \phi(x)] \gamma_n^-(dx) = \int_E \phi(x) [g_n(x) \gamma_n^-(dx)] = \langle g_n \gamma_n^-, \phi \rangle .$$

Comme la fonction test ϕ est quelconque, on en déduit que

$$\gamma_n = g_n \gamma_n^- ,$$

et en normalisant, on obtient

$$\mu_n = \frac{\gamma_n}{\langle \gamma_n, 1 \rangle} = \frac{g_n \gamma_n^-}{\langle \gamma_n^-, g_n \rangle} = \frac{g_n \mu_n^-}{\langle \mu_n^-, g_n \rangle} ,$$

où la dernière égalité est obtenue en divisant numérateur et dénominateur par la constante de normalisation $\langle \gamma_n^-, 1 \rangle$. $\square$

7.2 Chaînes de Markov partiellement observées

D'après la propriété de Markov, la distribution de probabilité jointe des états cachés $X_{0:n}$ et des observations $Y_{0:n}$ vérifie

$$\begin{aligned}\mathbb{P}[X_{0:n} \in dx_{0:n}, Y_{0:n} \in dy_{0:n}] \\ = [\gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k)] \lambda_0^F(dy_0) \prod_{k=1}^n \lambda_k^F(y_{k-1}, dy_k) .\end{aligned}$$

En intégrant par rapport aux variables $x_{0:n}$, on obtient la distribution de probabilité jointe des observations $Y_{0:n}$, c'est-à-dire

$$\begin{aligned}\mathbb{P}[Y_{0:n} \in dy_{0:n}] \\ = [\int_E \cdots \int_E \gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k)] \lambda_0^F(dy_0) \prod_{k=1}^n \lambda_k^F(y_{k-1}, dy_k) .\end{aligned}$$

D'après la formule de Bayes, il vient

$$\begin{aligned}
& \mathbb{P}[X_{0:n} \in dx_{0:n}, Y_{0:n} \in dy_{0:n}] \\
&= [\gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k)] \lambda_0^F(dy_0) \prod_{k=1}^n \lambda_k^F(y_{k-1}, dy_k) \\
&= \mathbb{P}[X_{0:n} \in dx_{0:n} \mid Y_{0:n} = y_{0:n}] \mathbb{P}[Y_{0:n} \in dy_{0:n}] \\
&= \mathbb{P}[X_{0:n} \in dx_{0:n} \mid Y_{0:n} = y_{0:n}] \\
&\quad \left[\int_E \cdots \int_E \gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k) \right] \lambda_0^F(dy_0) \prod_{k=1}^n \lambda_k^F(y_{k-1}, dy_k) ,
\end{aligned}$$

et on obtient

$$\mathbb{P}[X_{0:n} \in dx_{0:n} \mid Y_{0:n} = y_{0:n}] = \frac{\gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k)}{\int_E \cdots \int_E \gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k)} ,$$

pour toute suite $y_{0:n}$ d'observations. Pour toute fonction test f définie sur l'espace produit $E^{n+1} = E \times \cdots \times E$, on a

$$\mathbb{E}[f(X_{0:n}) \mid Y_{0:n} = y_{0:n}] = \frac{\int_E \cdots \int_E \gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k) f(x_{0:n})}{\int_E \cdots \int_E \gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k)} ,$$

et on rappelle que

$$\begin{aligned}
& \mathbb{P}[Y_{0:n} \in dy_{0:n}] \\
&= \left[\int_E \cdots \int_E \gamma_0(y_0, dx_0) \prod_{k=1}^n R_k(y_{k-1}, y_k, x_{k-1}, dx_k) \right] \lambda_0^F(dy_0) \prod_{k=1}^n \lambda_k^F(y_{k-1}, dy_k) .
\end{aligned}$$

et comme ces identités sont vérifiées pour toute suite $y_{0:n}$ d'observations, on en déduit que la distribution de probabilité conditionnelle jointe des états cachés $X_{0:n}$ sachant $Y_{0:n}$ est donnée par

$$\mathbb{E}[f(X_{0:n}) \mid Y_{0:n}] = \frac{\int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k) f(x_{0:n})}{\int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k)} , \quad (7.2)$$

et la fonction de vraisemblance du modèle est donnée par

$$L_n = \int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k) ,$$

où la mesure positive $\gamma_0(dx)$ et les noyaux positifs (non-normalisés) $R_k(x, dx')$ sont définis par abus de notation comme

$$\gamma_0(dx) = \gamma_0(Y_0, dx) \quad \text{et} \quad R_k(x, dx') = R_k(Y_{k-1}, Y_k, x, dx') ,$$

pour tout $k = 1, \dots, n$, et dépendent implicitement des observations $Y_{0:n}$, mais celles-ci sont considérées comme fixées dans les expressions ci-dessus. En particulier, la distribution de probabilité conditionnelle de l'état caché X_n sachant $Y_{0:n}$ est donnée par

$$\langle \mu_n, \phi \rangle = \mathbb{E}[\phi(X_n) \mid Y_{0:n}] = \frac{\int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k) \phi(x_n)}{\int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k)} = \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} ,$$

où la mesure positive (non-normalisée) $\gamma_n(dx)$ est définie par

$$\langle \gamma_n, \phi \rangle = \int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k) \phi(x_n) ,$$

et pour $\phi \equiv 1$, on a

$$\langle \gamma_n, 1 \rangle = \int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k) = L_n .$$

Pour obtenir une équation récurrente permettant d'exprimer μ_k en fonction de μ_{k-1} , il suffit donc d'une équation récurrente permettant d'exprimer γ_k en fonction de γ_{k-1} , puis de normaliser.

Théorème 7.4 (Filtre bayésien) *La suite $\{\mu_k\}$ vérifie l'équation récurrente suivante*

$$\mu_k = \frac{\mu_{k-1} R_k}{\langle \mu_{k-1} R_k, 1 \rangle} ,$$

et la suite $\{L_k\}$ vérifie l'équation récurrente suivante

$$L_k = \langle \mu_{k-1} R_k, 1 \rangle L_{k-1} \quad \text{soit en itérant} \quad L_n = \prod_{k=1}^n \langle \mu_{k-1} R_k, 1 \rangle \langle \gamma_0, 1 \rangle .$$

PREUVE. On a

$$\begin{aligned}
\langle \gamma_n, \phi \rangle &= \int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k) \phi(x_n) \\
&= \int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^{n-1} R_k(x_{k-1}, dx_k) \int_E R_n(x_{n-1}, dx_n) \phi(x_n) \\
&= \int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^{n-1} R_k(x_{k-1}, dx_k) R_n \phi(x_{n-1}) \\
&= \langle \gamma_{n-1}, R_n \phi \rangle = \langle \gamma_{n-1} R_n, \phi \rangle .
\end{aligned}$$

Comme la fonction test ϕ est quelconque, on en déduit que

$$\gamma_n = \gamma_{n-1} R_n ,$$

et en normalisant, on obtient

$$\mu_n = \frac{\gamma_n}{\langle \gamma_n, 1 \rangle} = \frac{\gamma_{n-1} R_n}{\langle \gamma_{n-1} R_n, 1 \rangle} = \frac{\mu_{n-1} R_n}{\langle \mu_{n-1} R_n, 1 \rangle} ,$$

où la dernière égalité est obtenue en divisant numérateur et dénominateur par la constante de normalisation $\langle \gamma_{n-1}, 1 \rangle$. $\square$

On a déjà vu à la Section 5.4 que les mesures positives $\gamma_0(y, dx)$ et les noyaux positifs $R_k(y, y', x, dx')$ peuvent être factorisés comme

$$\gamma_0(y, dx) = g_0^{\text{imp}}(y, x) \eta_0^{\text{imp}}(y, dx) \quad \text{et} \quad R_k(y, y', x, dx') = g_k^{\text{imp}}(y, y', x, x') Q_k^{\text{imp}}(y, y', x, dx') ,$$

respectivement, c'est-à-dire comme le produit

- d'une fonction de pondération positive $g_0^{\text{imp}}(y, x)$ ou $g_k^{\text{imp}}(y, y', x, x')$,
- et d'une distribution de probabilité $\eta_0^{\text{imp}}(y, dx)$ ou d'un noyau markovien $Q_k^{\text{imp}}(y, y', x, dx')$,

et avec les abus de notation habituels, une telle décomposition implique que la mesure positive $\gamma_0(dx)$ et le noyau positif $R_k(x, dx')$ peuvent être factorisés comme

$$\gamma_0(dx) = g_0^{\text{imp}}(x) \eta_0^{\text{imp}}(dx) \quad \text{et} \quad R_k(x, dx') = g_k^{\text{imp}}(x, x') Q_k^{\text{imp}}(x, dx') , \quad (7.3)$$

respectivement, c'est-à-dire comme le produit

- d'une fonction de pondération positive, éventuellement aléatoire, $g_0^{\text{imp}}(x) = g_0^{\text{imp}}(Y_0, x)$ ou $g_k^{\text{imp}}(x, x') = g_k^{\text{imp}}(Y_{k-1}, Y_k, x, x')$,
- et d'une distribution de probabilité, éventuellement aléatoire, $\eta_0^{\text{imp}}(dx) = \eta_0^{\text{imp}}(Y_0, dx)$ ou d'un noyau markovien, éventuellement aléatoire, $Q_k^{\text{imp}}(x, dx') = Q_k^{\text{imp}}(Y_{k-1}, Y_k, x, dx')$.

Cette décomposition est évidemment non unique : dans le cas particulier des modèles de Markov cachés, le premier exemple d'une telle décomposition est donné naturellement par la définition

$$\gamma_0(dx) = g_0(x) \eta_0(dx) \quad \text{et} \quad R_k(x, dx') = Q_k(x, dx') g_k(x') ,$$

avec le même abus de notation, et un autre exemple de décomposition est

$$\gamma_0(dx) = \gamma_0(E) \underbrace{\frac{\gamma_0(dx)}{\gamma_0(E)}}_{\widehat{\eta}_0(dx)} \quad \text{et} \quad R_k(x, dx') = \underbrace{R_k(x, E)}_{\widehat{g}_k(x)} \underbrace{\frac{R_k(x, dx')}{R_k(x, E)}}_{\widehat{Q}_k(x, dx')} ,$$

où la fonction de pondération

$$\widehat{g}_k(x) = R_k(x, E) = \int_E Q_k(x, dx') g_k(x') ,$$

peut être interprétée pour tout état $x \in E$ comme une mesure quantitative du recouvrement entre l'application $x' \mapsto g_k(x')$ et la distribution de probabilité $Q_k(x, dx')$. En pratique, la décomposition d'importance doit être telle que

- il est facile de *simuler* une variable aléatoire selon la distribution de probabilité $\eta_0^{\text{imp}}(dx)$,
- il est facile d'*évaluer* pour tout $x \in E$ la fonction d'importance $g_0^{\text{imp}}(x)$,

et pour tout instant $k = 1, \dots, n$

- il est facile de *simuler* pour tout $x \in E$ une variable aléatoire selon la distribution de probabilité $Q_k^{\text{imp}}(x, dx')$,
- il est facile d'*évaluer* pour tout $x, x' \in E$ la fonction d'importance $g_k^{\text{imp}}(x, x')$,

quand bien même l'expression analytique du noyau positif $R_k(x, dx')$ serait inconnue, ou tellement compliquée qu'il serait impossible en pratique de calculer des intégrales telles que

$$R_k \phi(x) = \int_E R_k(x, dx') \phi(x') \quad \text{ou} \quad \mu R_k(dx') = \int_E \mu(dx) R_k(x, dx') .$$

Exemple 7.5 Cette situation favorable se rencontre par exemple pour le système non-linéaire, présenté dans l'Exemple 5.6, avec des bruits gaussiens additifs et une fonction d'observation linéaire

$$\begin{aligned} X_k &= f_k(X_{k-1}) + \sigma_k(X_{k-1}) W_k , \\ Y_k &= H_k X_k + h_k + V_k , \end{aligned} \tag{7.4}$$

où les suites $\{W_k\}$ et $\{V_k\}$ sont des bruits blancs gaussiens indépendants, indépendants de la condition initiale X_0 , de matrices de covariance identité et Q_k^V respectivement (avec Q_k^V inversible) à l'instant k . Dans ce cas en effet

- il est facile de simuler un vecteur aléatoire X' selon la distribution de probabilité $\hat{\eta}_0(dx)$: il suffit de simuler deux vecteurs aléatoires gaussiens indépendants X et V , de moyenne $\bar{X}_0$ et 0 et de matrice de covariance Q_0^X et Q_0^V respectivement, et de poser

$$X' = X + Q_0^X H_0^* [H_0 Q_0^X H_0^* + Q_0^V]^{-1} (Y_0 - (H_0 X + h_0 + V)) ,$$

et pour tout instant $k = 1, \dots, n$

- il est facile d'évaluer pour tout $x \in E$ la densité de probabilité gaussienne

$$\hat{g}_k(x) = q(Y_k - (H_k f_k(x) + h_k), H_k \Sigma_k(x) H_k^* + Q_k^V) ,$$

de moyenne $H_k f_k(x) + h_k$ et de matrice de covariance inversible $H_k \Sigma_k(x) H_k^* + Q_k^V$ avec $\Sigma_k(x) = \sigma_k(x) \sigma_k^*(x)$,

- et il est facile de simuler pour tout $x \in E$ un vecteur aléatoire X' selon la distribution de probabilité $\hat{Q}_k(x, dx')$: il suffit de simuler deux vecteurs aléatoires gaussiens indépendants W et V , centrés et de matrice de covariance identité et Q_k^V respectivement, et de poser

$$X = f_k(x) + \sigma_k(x) W ,$$

et

$$X' = X + \Sigma_k(x) H_k^* [H_k \Sigma_k(x) H_k^* + Q_k^V]^{-1} (Y_k - (H_k X + h_k + V)) .$$

L'équation du filtre bayésien a été obtenue très simplement, mais il est en général impossible de la résoudre, sauf dans le cas particulier des systèmes linéaires gaussiens, où elle se ramène aux équations du filtre de Kalman, présentées au Chapitre 3. Il faut donc avoir recours à une approximation numérique, et on présente ci-dessous une approximation de type Monte Carlo, appelée filtre particulaire, qui a connu un développement spectaculaire au cours des dernières années, et qui est maintenant largement répandu, en particulier dans les applications en localisation, navigation ou poursuite de mobiles, aussi bien dans le domaine militaire (aéronef, sous-marin, bâtiment de surface, missile, drone, etc.), que dans le domaine civil, avec des applications en robotique mobile ou en communications sans-fil.

Chapitre 8

Généralisation : distributions de Feynman–Kac

8.1 Modèle de base

Plus généralement, on peut s'intéresser aux distributions non-normalisées et aux distributions normalisées associées, définies par

$$\langle \gamma_n, \phi \rangle = \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_k)] \quad \text{et} \quad \langle \mu_n, \phi \rangle = \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle}, \quad (8.1)$$

et par

$$\langle \gamma_n^-, \phi \rangle = \mathbb{E}[\phi(X_n) \prod_{k=0}^{n-1} g_k(X_k)] \quad \text{et} \quad \langle \mu_n^-, \phi \rangle = \frac{\langle \gamma_n^-, \phi \rangle}{\langle \gamma_n^-, 1 \rangle},$$

pour toute fonction mesurable bornée ϕ , où $\{X_k, k = 0, 1, \dots, n\}$ est une chaîne de Markov caractérisée par

- la distribution de probabilité initiale $\eta_0(dx)$,
- et les noyaux de probabilités de transition $Q_k(x, dx')$, pour tout $k = 1, \dots, n$,

et où $g_k(x)$ sont des fonctions mesurables bornées (strictement positives) données, appelées fonctions de sélection ou fonctions de *fitness*, pour tout $k = 0, 1, \dots, n$. L'hypothèse minimale, faute de quoi le problème n'est pas bien posé, est que $\langle \gamma_n, 1 \rangle > 0$, ce qui est assuré par exemple si les fonctions de sélection sont strictement positives.

► **Équation récurrente** En procédant comme dans la preuve du Théorème 7.1, on obtient

$$\begin{aligned} \langle \gamma_k, \phi \rangle &= \mathbb{E}[\phi(X_k) \prod_{p=0}^k g_p(X_p)] \\ &= \mathbb{E}[\phi(X_k) g_k(X_k) \prod_{p=0}^{k-1} g_p(X_p)] = \langle \gamma_k^-, g_k \phi \rangle = \langle g_k \gamma_k^-, \phi \rangle, \end{aligned}$$

et en utilisant la propriété de Markov, on obtient

$$\begin{aligned}
\langle \gamma_k^-, \phi \rangle &= \mathbb{E}[\phi(X_k) \prod_{p=0}^{k-1} g_p(X_p)] \\
&= \mathbb{E}[\mathbb{E}[\phi(X_k) \mid X_{0:k-1}] \prod_{p=0}^{k-1} g_p(X_p)] \\
&= \mathbb{E}[\mathbb{E}[\phi(X_k) \mid X_{k-1}] \prod_{p=0}^{k-1} g_p(X_p)] \\
&= \mathbb{E}[Q_k \phi(X_{k-1}) \prod_{p=0}^{k-1} g_p(X_p)] = \langle \gamma_{k-1}, Q_k \phi \rangle = \langle \gamma_{k-1} Q_k, \phi \rangle ,
\end{aligned}$$

pour toute fonction mesurable bornée ϕ , de sorte que la distribution non-normalisée vérifie la relation de récurrence linéaire

$$\gamma_k = g_k (\gamma_{k-1} Q_k) = g_k \eta_k \langle \gamma_{k-1}, 1 \rangle \quad \text{et} \quad \gamma_0 = g_0 \eta_0 , \quad (8.2)$$

en posant $\eta_k = \mu_{k-1} Q_k$, ou de manière équivalente $\gamma_k = \gamma_{k-1} R_k$ où le noyau positif (non normalisé) R_k est défini par $R_k(x, dx') = Q_k(x, dx') g_k(x')$. La constante de normalisation vérifie la relation de récurrence

$$\langle \gamma_k, 1 \rangle = \langle \eta_k, g_k \rangle \langle \gamma_{k-1}, 1 \rangle \quad \text{et} \quad \langle \gamma_0, 1 \rangle = \langle \eta_0, g_0 \rangle , \quad (8.3)$$

de sorte que la distribution normalisée vérifie la relation de récurrence non-linéaire décrite par le schéma suivant

$$\mu_{k-1} \xrightarrow{\text{mutation}} \eta_k = \mu_{k-1} Q_k \xrightarrow{\text{pondération}} \mu_k = g_k \cdot \eta_k ,$$

avec la condition initiale $\mu_0 = g_0 \cdot \eta_0$, où la notation $\cdot$ désigne le produit projectif. Il résulte de la relation de récurrence (8.3) et de la définition (8.1) que

$$\langle \gamma_n, 1 \rangle = \mathbb{E}[\prod_{k=0}^n g_k(X_k)] = \prod_{k=0}^n \langle \eta_k, g_k \rangle ,$$

c'est-à-dire que l'espérance d'un produit est remplacée par un produit d'espérances.

On remarque que la distribution non-normalisée vérifie aussi la relation de récurrence linéaire

$$\gamma_k^- = (g_{k-1} \gamma_{k-1}^-) Q_k \quad \text{et} \quad \gamma_0^- = \eta_0 , \quad (8.4)$$

ou de manière équivalente $\gamma_k^- = \gamma_{k-1}^- R_k^-$ où le noyau positif (non normalisé) R_k^- est défini par $R_k^-(x, dx') = g_{k-1}(x) Q_k(x, dx')$. On montre par récurrence arrière l'identité suivante entre noyaux positifs (non-normalisés)

$$g_k (R_{k+1:n-1} Q_n) = R_{k+1:n}^- , \quad (8.5)$$

valide pour tout $k = (n - 1), \dots, 1, 0$. Par définition, on a immédiatement

$$g_{n-1}(x) Q_n(x, dx') = R_n^-(x, dx') ,$$

c'est-à-dire que l'identité (8.5) est vérifiée pour $k = (n - 1)$. D'autre part, si l'identité (8.5) est vérifiée à l'étape k , alors

$$\begin{aligned} g_{k-1}(x) (R_{k:n-1} Q_n)(x, dx') &= g_{k-1}(x) (R_k (R_{k+1:n-1} Q_n))(x, dx') \\ &= g_{k-1}(x) \int_E R_k(x, dx'') (R_{k+1:n-1} Q_n)(x'', dx') \\ &= g_{k-1}(x) \int_E Q_k(x, dx'') g_k(x'') (R_{k+1:n-1} Q_n)(x'', dx') \\ &= g_{k-1}(x) \int_E Q_k(x, dx'') R_{k+1:n}^-(x'', dx') \\ &= \int_E R_k^-(x, dx'') R_{k+1:n}^-(x'', dx') \\ &= R_{k:n}^-(x, dx') , \end{aligned}$$

c'est-à-dire que l'identité (8.5) est vérifiée à l'étape $(k - 1)$. En particulier, il résulte de (8.5) que

$$g_k R_{k+1:n-1} 1 = g_k R_{k+1:n-1} Q_n 1 = R_{k+1:n}^- 1 , \quad (8.6)$$

pour tout $k = 0, 1, \dots, (n - 1)$.

► **Changement de modèle** Si la distribution de probabilité initiale $\eta_0(dx)$ est absolument continue par rapport à une autre distribution de probabilité $\eta_0^0(dx)$, avec la densité $r_0(x)$, et si le noyau de transition $Q_k(x, dx')$ est absolument continu par rapport à un autre noyau de transition $Q_k^0(x, dx')$, avec la densité $r_k(x, x')$, c'est-à-dire que

$$\eta_0(dx) = r_0(x) \eta_0^0(dx) \quad \text{et} \quad Q_k(x, dx') = r_k(x, x') Q_k^0(x, dx') , \quad (8.7)$$

pour tout $k = 1, \dots, n$, alors

$$\begin{aligned} \langle \gamma_n, \phi \rangle &= \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_k)] \\ &= \int_E \cdots \int_E \phi(x_n) \prod_{k=0}^n g_k(x_k) \eta_0(dx_0) \prod_{k=1}^n Q_k(x_{k-1}, dx_k) \\ &= \int_E \cdots \int_E \phi(x_n) \prod_{k=0}^n g_k(x_k) r_0(x_0) \prod_{k=1}^n r_k(x_{k-1}, dx_k) \eta_0^0(dx_0) \prod_{k=1}^n Q_k^0(x_{k-1}, dx_k) \\ &= \mathbb{E}[\phi(X_n^0) \prod_{k=0}^n g_k^0(X_{k-1}^0, X_k^0)] , \end{aligned}$$

pour toute fonction mesurable bornée ϕ , où la suite $\{X_k^0, k = 0, 1, \dots, n\}$ est une chaîne de Markov, caractérisée par

- la distribution de probabilité initiale $\eta_0^0(dx)$,
- et les noyaux de probabilités de transition $Q_k^0(x, dx')$, pour tout $k = 1, \dots, n$,

et où les fonctions de sélection sont définies par

$$g_0^0(x, x') = g_0(x') r_0(x') \quad \text{et} \quad g_k^0(x, x') = g_k(x') r_k(x, x') ,$$

pour tout $k = 1, \dots, n$.

A première vue, cette expression paraît plus générale compte tenu que chaque fonction de sélection dépend maintenant de la transition courante (et plus seulement de l'état courant) de la chaîne de Markov.

8.2 Modèle (apparamment) plus général

Plus généralement encore, on peut aussi s'intéresser à la distribution non-normalisée et à la distribution normalisée associée, définies par

$$\langle \gamma_n, \phi \rangle = \int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k) \phi(x_n) \quad \text{et} \quad \langle \mu_n, \phi \rangle = \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} , \quad (8.8)$$

pour toute fonction mesurable bornée ϕ , où γ_0 est une mesure positive donnée et où $\{R_k, k = 1, \dots, n\}$ sont des noyaux positifs (non-normalisés) donnés. Ce modèle général inclut comme cas particulier le modèle (8.1), avec

$$\gamma_0(dx) = \eta_0(dx) g_0(x) \quad \text{et} \quad R_k(x, dx') = Q_k(x, dx') g_k(x') .$$

► **Équation récurrente** En procédant comme dans la preuve du Théorème 7.4, on obtient

$$\begin{aligned} \langle \gamma_k, \phi \rangle &= \int_E \cdots \int_E \gamma_0(dx_0) \prod_{p=1}^k R_p(x_{p-1}, dx_p) \phi(x_k) \\ &= \int_E \cdots \int_E \gamma_0(dx_0) \prod_{p=1}^{k-1} R_p(x_{p-1}, dx_p) \int_E R_k(x_{k-1}, dx_k) \phi(x_k) \\ &= \int_E \cdots \int_E \gamma_0(dx_0) \prod_{p=1}^{k-1} R_p(x_{p-1}, dx_p) R_k \phi(x_{k-1}) \\ &= \langle \gamma_{k-1}, R_k \phi \rangle = \langle \gamma_{k-1} R_k, \phi \rangle , \end{aligned}$$

pour toute fonction mesurable bornée ϕ , de sorte que la distribution non-normalisée vérifie la relation de récurrence linéaire

$$\gamma_k = \gamma_{k-1} R_k = \mu_{k-1} R_k \langle \gamma_{k-1}, 1 \rangle . \quad (8.9)$$

La constante de normalisation vérifie la relation de récurrence

$$\langle \gamma_k, 1 \rangle = \langle \gamma_{k-1} R_k, 1 \rangle = \langle \mu_{k-1} R_k, 1 \rangle \langle \gamma_{k-1}, 1 \rangle . \quad (8.10)$$

de sorte que la distribution normalisée vérifie la relation de récurrence non-linéaire décrite par le schéma suivant

$$\mu_{k-1} \longrightarrow \mu_k = \frac{\mu_{k-1} R_k}{\langle \mu_{k-1} R_k, 1 \rangle} ,$$

avec la condition initiale $\mu_0 = \gamma_0 / \langle \gamma_0, 1 \rangle$. Il résulte de la relation de récurrence (8.10) et de la définition (8.8) que

$$\langle \gamma_n, 1 \rangle = \int_E \cdots \int_E \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k) = \langle \gamma_0, 1 \rangle \prod_{k=1}^n \langle \mu_{k-1} R_k, 1 \rangle ,$$

c'est-à-dire qu'une intégrale multiple est remplacée par un produit d'intégrales doubles.

► **Décomposition d'importance** En toute généralité, les mesures positives $\gamma_0(dx)$ et les noyaux positifs $R_k(x, dx')$ peuvent être factorisés comme

$$\gamma_0(dx) = g_0^{\text{imp}}(x) \eta_0^{\text{imp}}(dx) \quad \text{et} \quad R_k(x, dx') = g_k^{\text{imp}}(x, x') Q_k^{\text{imp}}(x, dx') , \quad (8.11)$$

respectivement, c'est-à-dire comme le produit

- d'une fonction de pondération positive $g_0^{\text{imp}}(x)$ ou $g_k^{\text{imp}}(x, x')$,
- et d'une distribution de probabilité $\eta_0^{\text{imp}}(dx)$ ou d'un noyau de probabilités de transition $Q_k^{\text{imp}}(x, dx')$,

pour tout $k = 1, \dots, n$, d'où on déduit l'expression équivalente suivante

$$\langle \gamma_n, \phi \rangle = \int_E \cdots \int_E \eta_0^{\text{imp}}(dx_0) \prod_{k=1}^n Q_k^{\text{imp}}(x_{k-1}, dx_k) g_0^{\text{imp}}(x_0) \prod_{k=1}^n g_k^{\text{imp}}(x_{k-1}, x_k) \phi(x_n) ,$$

et la représentation probabiliste

$$\langle \gamma_n, \phi \rangle = \mathbb{E}[\phi(X_n^{\text{imp}}) \prod_{k=0}^n g_k^{\text{imp}}(X_{k-1}^{\text{imp}}, X_k^{\text{imp}})] , \quad (8.12)$$

pour toute fonction mesurable bornée ϕ , où la suite $\{X_k^{\text{imp}}, k = 0, 1, \dots, n\}$ est une chaîne de Markov caractérisée par

- la distribution de probabilité initiale $\eta_0^{\text{imp}}(dx)$,
- et les noyaux de probabilités de transition $Q_k^{\text{imp}}(x, dx')$, pour tout $k = 1, \dots, n$,

avec la convention $g_0^{\text{imp}}(x, x') = g_0^{\text{imp}}(x')$ pour $k = 0$. On remarque que chaque fonction de sélection dépend de la transition courante (et pas seulement de l'état courant) de la chaîne de Markov.

La décomposition (8.11) est évidemment non unique : dans le cas particulier du modèle considéré à la Section 8.1, le premier exemple d'une telle décomposition est donné naturellement par la définition

$$\gamma_0(dx) = g_0(x) \eta_0(dx) \quad \text{et} \quad R_k(x, dx') = Q_k(x, dx') g_k(x') ,$$

où la fonction de sélection dépend seulement de l'état d'arrivée de la transition courante, et un autre exemple de décomposition est

$$\gamma_0(dx) = \underbrace{\gamma_0(E) \frac{\gamma_0(dx)}{\gamma_0(E)}}_{\hat{\eta}_0(dx)} \quad \text{et} \quad R_k(x, dx') = \underbrace{R_k(x, E)}_{\hat{g}_k(x)} \underbrace{\frac{R_k(x, dx')}{R_k(x, E)}}_{\hat{Q}_k(x, dx')} ,$$

où la fonction de sélection

$$\gamma_0(E) = \int_E g_0(x) \eta_0(dx) ,$$

est juste une constante, et où la fonction de sélection

$$\hat{g}_k(x) = R_k(x, E) = \int_E Q_k(x, dx') g_k(x') ,$$

dépend seulement de l'état de départ de la transition courante, et peut être interprétée pour tout état $x \in E$ comme une mesure quantitative du recouvrement entre l'application $x' \mapsto g_k(x')$ et la distribution de probabilité $Q_k(x, dx')$, pour tout $k = 1, \dots, n$, et plus généralement, il existe une décomposition

$$\gamma_0(dx) = \underbrace{g_0(x) r_0(x)}_{g_0^0(x)} \eta_0^0(dx) \quad \text{et} \quad R_k(x, dx') = \underbrace{g_k(x') r_k(x, x')}_{g_k^0(x, x')} Q_k^0(x, dx') ,$$

pour chaque changement de modèle du type considéré en (8.7).

Autant que possible, une distinction claire devra être faite entre les résultats et les estimations qui dépendent seulement du noyau positif $R_k(x, dx')$, et les résultats et les estimations qui dépendent spécifiquement de la décomposition d'importance (8.11) utilisée, c'est-à-dire qui dépendent explicitement du noyau markovien $Q_k^{\text{imp}}(x, dx')$ et de la fonction positive $g_k^{\text{imp}}(x, x')$. En pratique, la décomposition d'importance doit être telle que

- il est facile de *simuler* une variable aléatoire selon la distribution de probabilité $\eta_0^{\text{imp}}(dx)$,
- il est facile d'*évaluer* pour tout $x \in E$ la fonction d'importance $g_0^{\text{imp}}(x)$,

et pour tout instant $k = 1, \dots, n$

- il est facile de *simuler* pour tout $x \in E$ une variable aléatoire selon la distribution de probabilité $Q_k^{\text{imp}}(x, dx')$,

- il est facile d'évaluer pour tout $x, x' \in E$ la fonction d'importance $g_k^{\text{imp}}(x, x')$,

quand bien même l'expression analytique du noyau positif $R_k(x, dx')$ serait inconnue, ou tellement compliquée qu'il serait impossible en pratique de calculer des intégrales telles que

$$R_k \phi(x) = \int_E R_k(x, dx') \phi(x') \quad \text{où} \quad \mu R_k(dx') = \int_E \mu(dx) R_k(x, dx') .$$

► **Décomposition d'importance dite optimale** En exploitant la décomposition

$$g_0(x) \eta_0(dx) = \langle \eta_0, g_0 \rangle \hat{\eta}_0(dx) , \quad (8.13)$$

et

$$g_k(x, x') Q_k(x, dx') = \underbrace{\int_E g_k(x, x'') Q_k(x, dx'')}_{\hat{g}_k(x)} \underbrace{\frac{g_k(x, x') Q_k(x, dx')}{\int_E g_k(x, x'') Q_k(x, dx'')}}_{\hat{Q}_k(x, dx')} , \quad (8.14)$$

pour tout $k = 1, \dots, n$, décomposition qui devient triviale dans le cas particulier où la fonction de sélection $g_0(x) = \text{cste}$ est constante, et où la fonction de sélection $g_k(x, x') = g_k(x)$ ne dépend que de l'état de départ de la transition courante, pour tout $k = 1, \dots, n$, on obtient la représentation probabiliste équivalente

$$\begin{aligned} \langle \gamma_n, \phi \rangle &= \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_{k-1}, X_k)] \\ &= \int_E \cdots \int_E g_0(x_0) \eta_0(dx_0) \prod_{k=1}^n g_k(x_{k-1}, x_k) \prod_{k=1}^n Q_k(x_{k-1}, dx_k) \phi(x_n) \\ &= \langle \eta_0, g_0 \rangle \int_E \cdots \int_E \hat{\eta}_0(dx_0) \prod_{k=1}^n \hat{g}_k(x_{k-1}) \prod_{k=1}^n \hat{Q}_k(x_{k-1}, dx_k) \phi(x_n) \\ &= \langle \eta_0, g_0 \rangle \int_E \cdots \int_E \hat{\eta}_0(dx_0) \prod_{k=0}^{n-1} \hat{g}_{k+1}(x_k) \prod_{k=1}^n \hat{Q}_k(x_{k-1}, dx_k) \phi(x_n) \\ &= \langle \eta_0, g_0 \rangle \int_E \cdots \int_E \eta_0^{\text{opt}}(dx_0) \prod_{k=0}^{n-1} g_k^{\text{opt}}(x_k) \prod_{k=1}^n Q_k^{\text{opt}}(x_{k-1}, dx_k) \phi(x_n) \\ &= \langle \eta_0, g_0 \rangle \mathbb{E}[\phi(X_n^{\text{opt}}) \prod_{k=0}^{n-1} g_k^{\text{opt}}(X_k^{\text{opt}})] \\ &= \langle \eta_0, g_0 \rangle \langle \gamma_n^{\text{opt-}}, \phi \rangle , \end{aligned}$$

où la suite $\{X_k^{\text{opt}}, k = 0, 1, \dots, n\}$ est une chaîne de Markov, caractérisée par

- la distribution de probabilité $\eta_0^{\text{opt}}(dx)$ définie par (8.13), c'est-à-dire

$$\eta_0^{\text{opt}}(dx) = \hat{\eta}_0(dx) = \frac{g_0(x) \eta_0(dx)}{\int_E g_0(dx') \eta_0(dx')} , \quad (8.15)$$

- et les noyaux de probabilités de transition $Q_k^{\text{opt}}(x, dx')$ définis par (8.14), c'est-à-dire

$$Q_k^{\text{opt}}(x, dx') = \widehat{Q}_k(x, dx') = \frac{g_k(x, x') Q_k(x, dx')}{\int_E g_k(x, x'') Q_k(x, dx'')} , \quad (8.16)$$

pour tout $k = 1, \dots, n$,

et où les fonctions de sélection $g_k^{\text{opt}}(x')$ sont définies par (8.14), c'est-à-dire

$$g_k^{\text{opt}}(x') = \widehat{g}_{k+1}(x') = \int_E g_{k+1}(x', x'') Q_{k+1}(x', dx'') , \quad (8.17)$$

pour tout $k = 0, 1, \dots, (n-1)$. En pratique, cette décomposition n'est vraiment utile que si

- il est facile de *simuler* une variable aléatoire selon la distribution de probabilité $\widehat{\eta}_0(dx)$,
- il est facile d'*évaluer* la constante $\langle \eta_0, g_0 \rangle$,

et pour tout instant $k = 1, \dots, n$

- il est facile de *simuler* pour tout $x \in E$ une variable aléatoire selon la distribution de probabilité $\widehat{Q}_k(x, dx')$,
- il est facile d'*évaluer* pour tout $x \in E$ la fonction d'importance $\widehat{g}_k(x)$.

On introduit les distributions non-normalisées et les distributions normalisées associées, définies par

$$\langle \gamma_n^{\text{opt}}, \phi \rangle = \mathbb{E}[\phi(X_n^{\text{opt}}) \prod_{k=0}^n g_k^{\text{opt}}(X_k^{\text{opt}})] \quad \text{et} \quad \langle \mu_n^{\text{opt}}, \phi \rangle = \frac{\langle \gamma_n^{\text{opt}}, \phi \rangle}{\langle \gamma_n^{\text{opt}}, 1 \rangle} , \quad (8.18)$$

et

$$\langle \gamma_n^{\text{opt-}}, \phi \rangle = \mathbb{E}[\phi(X_n^{\text{opt}}) \prod_{k=0}^{n-1} g_k^{\text{opt}}(X_k^{\text{opt}})] \quad \text{et} \quad \langle \eta_n^{\text{opt}}, \phi \rangle = \frac{\langle \gamma_n^{\text{opt-}}, \phi \rangle}{\langle \gamma_n^{\text{opt-}}, 1 \rangle} ,$$

pour toute fonction mesurable bornée ϕ , et on remarque que

$$\langle \mu_n, \phi \rangle = \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} = \frac{\langle \gamma_n^{\text{opt-}}, \phi \rangle}{\langle \gamma_n^{\text{opt-}}, 1 \rangle} = \langle \eta_n^{\text{opt}}, \phi \rangle ,$$

c'est-à-dire que la distribution normalisée μ_n (c'est-à-dire le filtre, dans le contexte du filtrage bayésien) pour le modèle d'origine peut s'interpréter comme la distribution normalisée η_n^{opt} (c'est-à-dire le prédictor, dans le contexte du filtrage bayésien) pour le modèle dit optimal, et

$$\langle \gamma_n, 1 \rangle = \langle \eta_0, g_0 \rangle \langle \gamma_n^{\text{opt-}}, 1 \rangle = \langle \eta_0, g_0 \rangle \langle \gamma_{n-1}^{\text{opt}}, 1 \rangle ,$$

c'est-à-dire que la constante de normalisation $\langle \gamma_n, 1 \rangle$ pour le modèle d'origine peut s'interpréter en terme de la constante de normalisation $\langle \gamma_{n-1}^{\text{opt}}, 1 \rangle$ à l'instant précédent pour le modèle dit

optimal. On déduit de (8.4) que la distribution non-normalisée vérifie la relation de récurrence linéaire

$$\gamma_k^{\text{opt-}} = (g_{k-1}^{\text{opt}} \gamma_{k-1}^{\text{opt-}}) Q_k^{\text{opt}} = \gamma_{k-1}^{\text{opt-}} R_k^{\text{opt-}} ,$$

ou de manière équivalente $\gamma_k^{\text{opt-}} = \gamma_{k-1}^{\text{opt-}} R_k^{\text{opt-}}$ où le noyau positif (non-normalisé) $R_k^{\text{opt-}}$ est défini par

$$R_k^{\text{opt-}}(x, dx') = g_{k-1}^{\text{opt}}(x) Q_k^{\text{opt}}(x, dx') = \widehat{g}_k(x) \widehat{Q}_k(x, dx') = R_k(x, dx') , \quad (8.19)$$

pour tout $k = 1, \dots, n$, et on déduit de (8.5) l'identité suivante entre noyaux positifs (non-normalisés)

$$g_k^{\text{opt}}(R_{k+1:n-1}^{\text{opt}} Q_n^{\text{opt}}) = R_{k+1:n}^{\text{opt-}} = R_{k+1:n} , \quad (8.20)$$

valide pour tout $k = (n-1), \dots, 1, 0$.

Remarque 8.1 A titre de vérification, et sans repasser par l'identité (8.5), on peut montrer de manière directe l'identité (8.20) par récurrence arrière. D'après (8.19) on a immédiatement

$$g_{n-1}^{\text{opt}}(x) Q_n^{\text{opt}}(x, dx') = R_n(x, dx') ,$$

c'est-à-dire que l'identité (8.20) est vérifiée pour $k = (n-1)$. D'autre part, si l'identité (8.20) est vérifiée à l'étape k , alors d'après (8.19) on a

$$\begin{aligned} g_{k-1}^{\text{opt}}(x) (R_{k:n-1}^{\text{opt}} Q_n^{\text{opt}})(x, dx') &= g_{k-1}^{\text{opt}}(x) (R_k^{\text{opt}} (R_{k+1:n-1}^{\text{opt}} Q_n^{\text{opt}}))(x, dx') \\ &= g_{k-1}^{\text{opt}}(x) \int_E R_k^{\text{opt}}(x, dx'') (R_{k+1:n-1}^{\text{opt}} Q_n^{\text{opt}})(x'', dx') \\ &= g_{k-1}^{\text{opt}}(x) \int_E Q_k^{\text{opt}}(x, dx'') g_k^{\text{opt}}(x'') (R_{k+1:n-1}^{\text{opt}} Q_n^{\text{opt}})(x'', dx') \\ &= g_{k-1}^{\text{opt}}(x) \int_E Q_k^{\text{opt}}(x, dx'') R_{k+1:n}(x'', dx') \\ &= \int_E R_k(x, dx'') R_{k+1:n}(x'', dx') \\ &= R_{k:n}(x, dx') , \end{aligned}$$

c'est-à-dire que l'identité (8.20) est vérifiée à l'étape $(k-1)$. En particulier, il résulte de (8.20) que

$$g_k^{\text{opt}} R_{k+1:n-1}^{\text{opt}} 1 = g_k^{\text{opt}} R_{k+1:n-1}^{\text{opt}} Q_n^{\text{opt}} 1 = R_{k+1:n} 1 , \quad (8.21)$$

pour tout $k = (n-1), \dots, 1, 0$.

8.3 Modèle à valeurs transitions ou trajectoires

Tous les modèles présentés jusqu'ici semblent pouvoir être vus comme des cas particuliers du modèle

$$\langle \gamma_n, \phi \rangle = \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_{k-1}, X_k)] \quad \text{et} \quad \langle \mu_n, \phi \rangle = \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle}, \quad (8.22)$$

pour toute fonction mesurable bornée ϕ , où $\{X_k, k = 0, 1, \dots, n\}$ est une chaîne de Markov caractérisée par

- la distribution de probabilité initiale $\eta_0(dx)$,
- les noyaux de probabilités de transition $Q_k(x, dx')$, pour tout $k = 1, \dots, n$,

et où $g_k(x, x')$ sont des fonctions mesurables bornées (strictement positives) données, appelées fonctions de sélection ou fonctions de *fitness*, pour tout $k = 0, 1, \dots, n$, avec la convention $g_0(x, x') = g_0(x')$ pour $k = 0$.

On remarque que chaque fonction de sélection dépend de la transition courante de la chaîne de Markov, ce qui inclus comme cas particuliers le cas où chaque fonction de sélection dépend seulement de l'état d'arrivée de la transition courante, comme dans le modèle (8.1), et le cas où chaque fonction de sélection dépend seulement de l'état de départ de la transition courante.

Le modèle (8.22) peut être vu comme un cas particulier du modèle (8.8), avec

$$\gamma_0(dx) = g_0(x) \eta_0(dx) \quad \text{et} \quad R_k(x, dx') = g_k(x, x') Q_k(x, dx'),$$

pour tout $k = 1, \dots, n$. En effet

$$\begin{aligned} \langle \gamma_n, \phi \rangle &= \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_{k-1}, X_k)] \\ &= \int_E \cdots \int_E \phi(x_n) \prod_{k=0}^n g_k(x_{k-1}, x_k) \eta_0(dx_0) \prod_{k=1}^n Q_k(x_{k-1}, dx_k) \\ &= \int_E \cdots \int_E \phi(x_n) \gamma_0(dx_0) \prod_{k=1}^n R_k(x_{k-1}, dx_k), \end{aligned}$$

pour toute fonction mesurable bornée ϕ , et on déduit de (8.9) que la distribution non-normalisée vérifie la relation de récurrence linéaire

$$\gamma_k = \gamma_{k-1} R_k = \mu_{k-1} R_k \langle \gamma_{k-1}, 1 \rangle. \quad (8.23)$$

► **Équation récurrente** On remarque que

$$\mu R_k(dx') = \int_E \mu(dx) R_k(x, dx') = \int_E g_k(x, x') \mu(dx) Q_k(x, dx'),$$

de sorte que

$$\begin{aligned}
 \langle \mu R_k, \phi \rangle &= \int_E \left[\int_E g_k(x, x') \mu(dx) Q_k(x, dx') \right] \phi(x') \\
 &= \int_E \int_E \phi(x') g_k(x, x') \mu(dx) Q_k(x, dx') \\
 &= \langle \mu \otimes Q_k, g_k \phi \circ \pi \rangle ,
 \end{aligned}$$

pour toute fonction mesurable bornée ϕ , et en particulier pour $\phi \equiv 1$

$$\langle \mu R_k, 1 \rangle = \int_E \int_E g_k(x, x') \mu(dx) Q_k(x, dx') = \langle \mu \otimes Q_k, g_k \rangle ,$$

où $\pi : (x, x') \in E \times E \mapsto x' \in E$ désigne la projection sur la deuxième composante de l'espace produit $E \times E$, c'est-à-dire que l'application π pointe sur l'état final de la transition, et où $\mu \otimes Q_k$ désigne la distribution de probabilité jointe

$$(\mu \otimes Q_k)(dx, dx') = \mu(dx) Q_k(x, dx') ,$$

sur l'espace produit $E \times E$, c'est-à-dire que

$$\mu R_k = (g_k (\mu \otimes Q_k)) \circ \pi^{-1} .$$

En utilisant cette expression dans (8.23), on obtient

$$\gamma_k = (g_k (\gamma_{k-1} \otimes Q_k)) \circ \pi^{-1} \quad \text{et} \quad \gamma_0 = g_0 \eta_0 , \quad (8.24)$$

et la constante de normalisation vérifie

$$\langle \gamma_k, 1 \rangle = \langle \mu_{k-1} \otimes Q_k, g_k \rangle \langle \gamma_{k-1}, 1 \rangle \quad \text{et} \quad \langle \gamma_0, 1 \rangle = \langle \eta_0, g_0 \rangle . \quad (8.25)$$

Il résulte de la relation de récurrence (8.25) et de la définition (8.22) que

$$\langle \gamma_n, 1 \rangle = \mathbb{E} \left[\prod_{k=0}^n g_k(X_{k-1}, X_k) \right] = \langle \eta_0, g_0 \rangle \prod_{k=1}^n \langle \mu_{k-1} \otimes Q_k, g_k \rangle ,$$

c'est-à-dire que l'espérance d'un produit est remplacée par un produit d'espérances.

Remarque 8.2 Pour générer une variable aléatoire (X, X') distribuée selon $(\mu \otimes Q_k)(dx, dx')$, il suffit de générer d'abord une variable aléatoire X distribuée selon $\mu(dx)$, et de générer ensuite une variable aléatoire X' distribuée selon $Q_k(X, dx')$.

► **Représentation intégrale et distribution de Gibbs-Boltzmann trajectorielle** On remarque que

$$\begin{aligned}
\langle \gamma_n, \phi \rangle &= \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_{k-1}, X_k)] \\
&= \int_E \cdots \int_E \phi(x_n) \prod_{k=0}^n g_k(x_{k-1}, x_k) \eta_0(dx_0) \prod_{k=1}^n Q_k(x_{k-1}, dx_k) \\
&= \int_E \cdots \int_E \phi \circ \pi(x_{0:n}) g_{0:n}(x_{0:n}) \eta_{0:n}(dx_{0:n}) \\
&= \langle \eta_{0:n}, g_{0:n} \phi \circ \pi \rangle \\
&= \mathbb{E}[\phi \circ \pi(X_{0:n}) g_{0:n}(X_{0:n})] ,
\end{aligned}$$

pour toute fonction mesurable bornée ϕ , où $\pi : (x_0, \dots, x_n) \in E \times \cdots \times E \mapsto x_n \in E$ désigne la projection sur la dernière composante de l'espace produit $E^{n+1} = E \times \cdots \times E$, c'est-à-dire que l'application π pointe sur l'état final de la trajectoire, où

$$\eta_{0:n}(dx_{0:n}) = \eta_0(dx_0) \prod_{k=1}^n Q_k(x_{k-1}, dx_k) = \mathbb{P}[X_{0:n} \in dx_{0:n}] ,$$

dénote la distribution de probabilité conjointe des états successifs de la chaîne de Markov, ou de manière équivalente la distribution de probabilité de la trajectoire $X_{0:n} = (X_0, \dots, X_n)$, et où

$$g_{0:n}(x_{0:n}) = \prod_{k=0}^n g_k(x_{k-1}, x_k) .$$

On remarque que

$$\langle \mu_n, \phi \rangle = \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} = \frac{\langle \eta_{0:n}, g_{0:n} \phi \circ \pi \rangle}{\langle \eta_{0:n}, g_{0:n} \rangle} ,$$

pour toute fonction mesurable bornée ϕ , de sorte que la distribution normalisée μ_n s'exprime en terme de la distribution de Gibbs-Boltzmann

$$\mu_{0:n} = g_{0:n} \cdot \eta_{0:n} = \frac{g_{0:n} \eta_{0:n}}{\langle \eta_{0:n}, g_{0:n} \rangle} ,$$

définie sur l'espace trajectorielle $E^{n+1} = E \times \cdots \times E$, comme $\mu_n = \mu_{0:n} \circ \pi^{-1}$.

► **Chaîne de Markov à valeurs transitions** En fait, contrairement aux apparences, le modèle (8.22) où chaque fonction de sélection dépend de la transition courante de la chaîne de Markov, n'est pas plus général que le modèle (8.1) où chaque fonction de sélection dépend seulement de l'état courant de la chaîne de Markov, pourvu qu'on change de point de vue, comme le montre le raisonnement suivant. On définit la variable aléatoire $X_k^{\text{tr}} = (X_{k-1}, X_k)$ à valeurs dans l'ensemble produit $E^{\text{tr}} = E \times E$, pour tout $k = 1, \dots, n$ et la variable aléatoire $X_0^{\text{tr}} = X_0$ à valeurs dans E , pour $k = 0$. Clairement, la suite $\{X_k^{\text{tr}}, k = 0, 1, \dots, n\}$ est une chaîne de Markov, caractérisée par

- la distribution de probabilité initiale $\eta_0^{\text{tr}}(dx) = \eta_0(dx)$,
- et les noyaux de probabilités de transition $Q_k^{\text{tr}}(x_1, x_2, dx'_1, dx'_2)$ définis par

$$Q_k^{\text{tr}}(x_1, x_2, dx'_1, dx'_2) = \delta_{x_2}(dx'_1) Q_k(x'_1, dx'_2) , \quad (8.26)$$

pour tout $k = 1, \dots, n$,

c'est-à-dire que l'état de départ de la nouvelle transition coïncide avec l'état d'arrivée de la transition précédente et l'état d'arrivée de la nouvelle transition est distribué à partir de l'état de départ selon le noyau de transition du modèle (8.22), et on considère la distribution non-normalisée et la distribution normalisée associée, définies par

$$\langle \gamma_n^{\text{tr}}, f \rangle = \mathbb{E}[f(X_n^{\text{tr}}) \prod_{k=0}^n g_k(X_k^{\text{tr}})] \quad \text{et} \quad \langle \mu_n^{\text{tr}}, f \rangle = \frac{\langle \gamma_n^{\text{tr}}, f \rangle}{\langle \gamma_n^{\text{tr}}, 1 \rangle} , \quad (8.27)$$

pour toute fonction mesurable bornée f définie sur l'ensemble produit $E^{\text{tr}} = E \times E$. On vérifie que

$$\langle \gamma_n, \phi \rangle = \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_{k-1}, X_k)] = \mathbb{E}[\phi \circ \pi(X_n^{\text{tr}}) \prod_{k=0}^n g_k(X_k^{\text{tr}})] = \langle \gamma_n^{\text{tr}}, \phi \circ \pi \rangle ,$$

pour toute fonction mesurable bornée ϕ , où $\pi : (x, x') \in E \times E \mapsto x' \in E$ désigne la projection sur la dernière composante de l'espace produit $E \times E$, c'est-à-dire que l'application π pointe sur l'état d'arrivée de la transition, de sorte que $\gamma_n = \gamma_n^{\text{tr}} \circ \pi^{-1}$. En d'autres termes, la distribution non-normalisée pour le modèle apparemment plus général (8.22) où chaque fonction de sélection dépend de la transition courante de la chaîne de Markov, s'exprime aussi en terme de la distribution non-normalisée pour le modèle plus simple (8.27) où chaque fonction de sélection dépend seulement de l'état courant de la chaîne de Markov, pourvu qu'on change de point de vue.

On en déduit en particulier que la distribution non-normalisée vérifie la relation de récurrence linéaire

$$\gamma_k^{\text{tr}} = g_k(\gamma_{k-1}^{\text{tr}} Q_k^{\text{tr}}) = g_k \eta_k^{\text{tr}} \langle \gamma_{k-1}^{\text{tr}}, 1 \rangle \quad \text{et} \quad \gamma_0^{\text{tr}} = g_0 \eta_0 , \quad (8.28)$$

en posant $\eta_k^{\text{tr}} = \mu_{k-1}^{\text{tr}} Q_k^{\text{tr}}$, et la constante de normalisation vérifie la relation de récurrence

$$\langle \gamma_k^{\text{tr}}, 1 \rangle = \langle \eta_k^{\text{tr}}, g_k \rangle \langle \gamma_{k-1}^{\text{tr}}, 1 \rangle \quad \text{et} \quad \langle \gamma_0^{\text{tr}}, 1 \rangle = \langle \eta_0, g_0 \rangle . \quad (8.29)$$

Il résulte de la relation de récurrence (8.29) et de la définition (8.27) que

$$\langle \gamma_n, 1 \rangle = \langle \gamma_n^{\text{tr}}, 1 \rangle = \mathbb{E}[\prod_{k=0}^n g_k(X_k^{\text{tr}})] = \prod_{k=0}^n \langle \eta_k^{\text{tr}}, g_k \rangle ,$$

c'est-à-dire que l'espérance d'un produit est remplacée par un produit d'espérances.

Remarque 8.3 A titre de vérification et sans repasser par les représentations probabilistes associées (8.22) et (8.27), on peut montrer de manière directe la consistance des deux suites définies par les relations de récurrence (8.24) et (8.28) respectivement, c'est-à-dire vérifier par récurrence

que $\gamma_k^{\text{tr}} \circ \pi^{-1} = \gamma_k$, pour tout $k = 1, \dots, n$. On suppose que l'hypothèse de récurrence est vraie au rang $(k-1)$, c'est-à-dire que la distribution marginale (non-normalisée) de γ_{k-1}^{tr} coïncide avec la distribution non-normalisée γ_{k-1} , ou en d'autres termes $\gamma_{k-1}^{\text{tr}}(E, dx_2) = \gamma_{k-1}(dx_2)$, et en utilisant la relation de récurrence (8.28) on remarque que

$$\begin{aligned}
\langle \gamma_k^{\text{tr}}, \phi \circ \pi \rangle &= \langle \gamma_{k-1}^{\text{tr}} Q_k^{\text{tr}}, \phi \circ \pi g_k \rangle \\
&= \int_E \int_E \gamma_{k-1}^{\text{tr}}(dx_1, dx_2) \int_E \int_E \delta_{x_2}(dx'_1) Q_k(x'_1, dx'_2) \phi(x'_2) g_k(x'_1, x'_2) \\
&= \int_E \int_E \gamma_{k-1}^{\text{tr}}(dx_1, dx_2) \int_E Q_k(x_2, dx'_2) \phi(x'_2) g_k(x_2, x'_2) \\
&= \int_E \gamma_{k-1}^{\text{tr}}(E, dx_2) \int_E Q_k(x_2, dx'_2) \phi(x'_2) g_k(x_2, x'_2) \\
&= \int_E \gamma_{k-1}(dx_2) \int_E Q_k(x_2, dx'_2) \phi(x'_2) g_k(x_2, x'_2) \\
&= \int_E \int_E \gamma_{k-1}(dx_2) Q_k(x_2, dx'_2) \phi(x'_2) g_k(x_2, x'_2) \\
&= \int_E \int_E (\gamma_{k-1} \otimes Q_k)(dx_2, dx'_2) \phi(x'_2) g_k(x_2, x'_2) \\
&= \langle \gamma_{k-1} \otimes Q_k, g_k \phi \circ \pi \rangle
\end{aligned}$$

pour toute fonction mesurable bornée ϕ , de sorte que

$$\gamma_k^{\text{tr}} \circ \pi^{-1} = (g_k (\gamma_{k-1} \otimes Q_k)) \circ \pi^{-1} = \gamma_k ,$$

en utilisant la relation de récurrence (8.24), c'est-à-dire que l'hypothèse de récurrence est vraie au rang k .

► **Chaîne de Markov à valeurs trajectoires** Plus généralement encore, tous les modèles présentés jusqu'ici peuvent être vus comme des cas particuliers du modèle trajectorien suivant. On définit la variable aléatoire $X_k^\bullet = X_{0:k} = (X_0, \dots, X_k)$ à valeurs dans l'espace produit $E^{k+1} = E \times \dots \times E$ dépendant du temps, pour tout $k = 0, 1, \dots, n$. Clairement la suite $\{X_k^\bullet, k = 0, 1, \dots, n\}$ est une chaîne de Markov, caractérisée par

- la distribution de probabilité initiale $\eta_0^\bullet(dx_{0:0}) = \eta_0(dx_0)$,
- et les noyaux de probabilités de transition $Q_k^\bullet(x_{0:k-1}, dx'_{0:k})$ définis par

$$Q_k^\bullet(x_0, \dots, x_{k-1}, dx'_0, \dots, dx'_k) = \delta_{x_0}(dx'_0) \cdots \delta_{x_{k-1}}(dx'_{k-1}) Q_k(x_{k-1}, dx'_k) ,$$

pour tout $k = 1, \dots, n$,

et on considère la distribution non-normalisée et à la distribution normalisée associée, définies par

$$\langle \gamma_n^\bullet, f \rangle = \mathbb{E}[f(X_n^\bullet) \prod_{k=0}^n g_k^\bullet(X_k^\bullet)] \quad \text{et} \quad \langle \mu_n^\bullet, f \rangle = \frac{\langle \gamma_n^\bullet, f \rangle}{\langle \gamma_n^\bullet, 1 \rangle}, \quad (8.30)$$

pour toute fonction mesurable bornée f définie sur l'ensemble produit $E^{n+1} = E \times \cdots \times E$, où les fonctions de sélection $g_k^\bullet(x_{0:k})$ sont définies par

$$g_k^\bullet(x_0, \dots, x_k) = g_k(x_{k-1}, x_k),$$

pour tout $k = 0, 1, \dots, n$, avec la convention $g_0(x, x') = g_0(x')$ pour $k = 0$. On vérifie que

$$\langle \gamma_n, \phi \rangle = \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_{k-1}, X_k)] = \mathbb{E}[\phi \circ \pi(X_n^\bullet) \prod_{k=0}^n g_k^\bullet(X_k^\bullet)] = \langle \gamma_n^\bullet, \phi \circ \pi \rangle,$$

pour toute fonction mesurable bornée ϕ , où $\pi : (x_0, \dots, x_n) \in E \times \cdots \times E \mapsto x_n \in E$ désigne la projection sur la dernière composante de l'espace produit $E^{n+1} = E \times \cdots \times E$, c'est-à-dire que l'application π pointe sur l'état final de la trajectoire, de sorte que $\gamma_n = \gamma_n^\bullet \circ \pi^{-1}$. En d'autres termes, la distribution non-normalisée pour le modèle apparamment plus général (8.22) où chaque fonction de sélection dépend de la transition courante de la chaîne de Markov, s'exprime aussi en terme de la distribution non-normalisée pour le modèle plus simple (8.30) où chaque fonction de sélection dépend seulement de l'état courant de la chaîne de Markov, pourvu qu'on adopte un point de vue trajectorien.

Chapitre 9

Méthodes de Monte Carlo

Pour une distribution de probabilité μ donnée, il s'agit d'approcher numériquement, par des méthodes de Monte Carlo, l'intégrale ou de manière équivalente l'espérance mathématique

$$\langle \mu, \phi \rangle = \int_E \phi(x) \mu(dx) = \mathbb{E}[\phi(X)] , \quad (9.1)$$

où la variable aléatoire X a pour distribution de probabilité μ , pour toute fonction mesurable bornée ϕ . Dans toute la suite, la notation $S^N(\mu)$ désigne la distribution de probabilité empirique

$$S^N(\mu) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi^i}$$

associée à un N -échantillon $(\xi^1, \dots, \xi^N)$ de variables aléatoires i.i.d., de distribution de probabilité commune μ , c'est-à-dire que

$$\langle S^N(\mu), \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(\xi^i) ,$$

pour toute fonction mesurable bornée ϕ .

Dans les situations où il est facile de simuler des variables aléatoires de distribution de probabilité μ , il est naturel d'introduire l'approximation suivante

$$\langle \mu, \phi \rangle \approx \langle S^N(\mu), \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(\xi^i) ,$$

pour toute fonction mesurable bornée ϕ , c'est-à-dire que

$$\mu \approx S^N(\mu) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi^i} ,$$

où les variables aléatoires $(\xi^1, \dots, \xi^N)$ sont i.i.d., de distribution de probabilité commune μ . On définit par

$$\text{var}(\phi, \mu) = \langle \mu, |\phi - \langle \mu, \phi \rangle|^2 \rangle = \langle \mu, |\phi|^2 \rangle - |\langle \mu, \phi \rangle|^2 \leq \|\phi\|^2 ,$$

la variance de la fonction mesurable bornée ϕ par rapport à la distribution de probabilité μ .

Théorème 9.1 *La variable aléatoire $\langle S^N(\mu), \phi \rangle$ est un estimateur non-biaisé de $\langle \mu, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^2 = \frac{1}{N} \text{var}(\phi, \mu) ,$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{ \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \langle \mu, |\phi - \langle \mu, \phi \rangle|^p \rangle^{1/p} ,$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.2 Compte tenu que

$$|\phi(x) - \langle \mu, \phi \rangle| \leq \text{osc}(\phi) = \sup_{x \in E} \phi(x) - \inf_{x \in E} \phi(x) ,$$

pour tout $x \in E$, on a également la majoration plus grossière suivante

$$\{ \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \text{osc}(\phi) , \quad (9.2)$$

pour toute fonction mesurable bornée ϕ .

PREUVE. En exploitant l'indépendance des différentes variables aléatoires, on remarque que

$$\begin{aligned} \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^2 &= \mathbb{E} \left| \frac{1}{N} \sum_{i=1}^N [\phi(\xi^i) - \langle \mu, \phi \rangle] \right|^2 \\ &= \frac{1}{N^2} \sum_{i=1}^N \mathbb{E} |\phi(\xi^i) - \langle \mu, \phi \rangle|^2 = \frac{1}{N} \langle \mu, |\phi - \langle \mu, \phi \rangle|^2 \rangle , \end{aligned}$$

pour toute fonction mesurable bornée ϕ . Plus généralement, pour tout réel $p \geq 2$

$$\begin{aligned} \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^p &= \mathbb{E} \left| \frac{1}{N} \sum_{i=1}^N [\phi(\xi^i) - \langle \mu, \phi \rangle] \right|^p \\ &\leq \frac{B_p}{N^{p/2}} \frac{1}{N} \sum_{i=1}^N \mathbb{E} |\phi(\xi^i) - \langle \mu, \phi \rangle|^p = \frac{B_p}{N^{p/2}} \langle \mu, |\phi - \langle \mu, \phi \rangle|^p \rangle , \end{aligned}$$

d'après l'inégalité de Marcinkiewicz-Zygmund, c'est-à-dire que

$$\{ \mathbb{E} | \langle S^N(\mu) - \mu, \phi \rangle |^p \}^{1/p} \leq \frac{B_p^{1/p}}{\sqrt{N}} \langle \mu, |\phi - \langle \mu, \phi \rangle|^p \rangle^{1/p} ,$$

pour toute fonction mesurable bornée ϕ . □

Le théorème central limite (dans sa version classique, pour des variables indépendantes identiquement distribuées) donne

$$\sqrt{N} \langle S^N(\mu) - \mu, \phi \rangle = \frac{1}{\sqrt{N}} \sum_{i=1}^N [\phi(\xi^i) - \langle \mu, \phi \rangle] \Longrightarrow \mathcal{N}(0, \text{var}(\phi, \mu)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ .

9.1 Échantillonnage pondéré

Une approche traditionnelle pour calculer l'intégrale (9.1) est l'échantillonnage pondéré, ou *importance sampling*, dans laquelle une nouvelle distribution de probabilité $\nu \gg \mu$ est utilisée, qui domine la distribution de probabilité μ , c'est-à-dire qu'il existe une densité (ou dérivée de Radon-Nikodym) $d\mu/d\nu$ telle que

$$\langle \mu, \phi \rangle = \int_E \phi(x) \mu(dx) = \int_E \phi(x) \frac{d\mu}{d\nu}(x) \nu(dx) = \langle \nu, \phi \frac{d\mu}{d\nu} \rangle = \mathbb{E}[\phi(\Xi) \frac{d\mu}{d\nu}(\Xi)] ,$$

où la variable aléatoire Ξ a pour distribution de probabilité ν , pour toute fonction mesurable bornée ϕ . S'il est facile

- d'évaluer la fonction positive $d\mu/d\nu$,
- et de simuler une variable aléatoire de distribution de probabilité ν ,

alors il est facile

- d'approcher la distribution de probabilité μ par la distribution de probabilité empirique pondérée associée à un échantillon de variables aléatoires i.i.d., de distribution de probabilité commune ν et pondéré par la fonction positive $d\mu/d\nu$.

On peut en effet introduire l'approximation suivante

$$\langle \mu, \phi \rangle = \langle \nu, \phi \frac{d\mu}{d\nu} \rangle \approx \langle S^N(\nu), \phi \frac{d\mu}{d\nu} \rangle = \frac{1}{N} \sum_{i=1}^N \phi(x_i) \frac{d\mu}{d\nu}(x_i) ,$$

où les variables aléatoires $(x_1, \dots, x_N)$ sont i.i.d., de distribution de probabilité commune ν , c'est-à-dire que

$$\mu = \frac{d\mu}{d\nu} \nu \approx \mu_N = \frac{d\mu}{d\nu} S^N(\nu) = \frac{1}{N} \sum_{i=1}^N \frac{d\mu}{d\nu}(x_i) \delta_{x_i} .$$

En particulier pour $\phi \equiv 1$, la masse totale

$$\langle \mu_N, 1 \rangle = \frac{1}{N} \sum_{i=1}^N \frac{d\mu}{d\nu}(x_i) ,$$

n'est pas nécessairement égale à 1, de sorte que l'approximation μ_N n'est pas nécessairement normalisée. En revanche, il résulte immédiatement du Théorème 9.1 que la variable aléatoire $\langle \mu_N, \phi \rangle = \langle S^N(\nu), \phi \frac{d\mu}{d\nu} \rangle$ est un estimateur non-biaisé de $\langle \nu, \phi \frac{d\mu}{d\nu} \rangle = \langle \mu, \phi \rangle$, et la variance (non-asymptotique) de cet estimateur est

$$\mathbb{E}|\langle \mu_N - \mu, \phi \rangle|^2 = \mathbb{E}\langle S^N(\nu) - \nu, \phi \frac{d\mu}{d\nu} \rangle^2 = \frac{1}{N} \text{var}(\phi \frac{d\mu}{d\nu}, \nu) .$$

Remarque 9.3 Alternativement, on peut considérer l'approximation auto-normalisée

$$\mu'_N = \frac{\mu_N}{\langle \mu_N, 1 \rangle} = \sum_{i=1}^N \frac{\frac{d\mu}{d\nu}(x_i)}{\sum_{j=1}^N \frac{d\mu}{d\nu}(x_j)} \delta x_i \quad \text{c'est-à-dire que} \quad \langle \mu'_N, \phi \rangle = \frac{\sum_{i=1}^N \phi(x_i) \frac{d\mu}{d\nu}(x_i)}{\sum_{i=1}^N \frac{d\mu}{d\nu}(x_i)},$$

pour toute fonction mesurable bornée ϕ , où les variables aléatoires $(x_1, \dots, x_N)$ sont i.i.d., de distribution de probabilité commune ν . Il résulte de la décomposition suivante

$$\mu'_N - \mu = \frac{\mu_N}{\langle \mu_N, 1 \rangle} - \mu = (\mu_N - \mu) - \langle \mu_N - \mu, 1 \rangle \mu'_N,$$

que

$$\langle \mu'_N - \mu, \phi \rangle = \langle \mu_N - \mu, \phi \rangle - \langle \mu_N - \mu, 1 \rangle \langle \mu'_N, \phi \rangle,$$

de sorte que

$$\{\mathbb{E}|\langle \mu'_N - \mu, \phi \rangle|^2\}^{1/2} \leq \{\mathbb{E}|\langle \mu_N - \mu, \phi \rangle|^2\}^{1/2} + \{\mathbb{E}|\langle \mu_N - \mu, 1 \rangle|^2\}^{1/2} \|\phi\|,$$

d'après l'inégalité (triangulaire) de Minkowski, pour toute fonction mesurable bornée ϕ . Ce type d'approximation sera étudié en détail à la Section 9.2.

On remarque que

$$\begin{aligned} \text{var}(\phi \frac{d\mu}{d\nu}, \nu) &= \int_E (\phi(x) \frac{d\mu}{d\nu}(x))^2 \nu(dx) - (\int_E \phi(x) \frac{d\mu}{d\nu}(x) \nu(dx))^2 \\ &= \int_E (\phi(x) \frac{d\mu}{d\nu}(x))^2 \nu(dx) - \langle \mu, \phi \rangle^2, \end{aligned}$$

et

$$\int_E (\phi(x) \frac{d\mu}{d\nu}(x))^2 \nu(dx) \geq (\int_E |\phi(x)| \frac{d\mu}{d\nu}(x) \nu(dx))^2 = \langle \mu, |\phi| \rangle^2,$$

d'après l'inégalité de Cauchy-Schwartz, d'où la borne inférieure suivante

$$\text{var}(\phi \frac{d\mu}{d\nu}, \nu) \geq \langle \mu, |\phi| \rangle^2 - \langle \mu, \phi \rangle^2 \geq 0,$$

indépendante du choix de la distribution de probabilité d'importance ν . On remarque que si la fonction ϕ garde un signe constant, alors la borne inférieure est nulle.

Parmi tous les choix possibles pour la distribution de probabilité d'importance ν , il existe un choix qui minimise la variance, c'est-à-dire que la borne inférieure est atteinte, même si ce choix est en pratique inaccessible car il nécessite de connaître la constante de normalisation

$$\langle \mu, |\phi| \rangle = \int_E |\phi(x)| \mu(dx) = \mathbb{E}|\phi(X)|,$$

dont le calcul présente le même degré de difficulté que le calcul de l'intégrale (9.1) elle-même ! En effet, si on introduit

$$\nu_* = |\phi| \cdot \mu = \frac{|\phi| \mu}{\langle \mu, |\phi| \rangle},$$

c'est-à-dire que la distribution de probabilité μ domine la distribution de probabilité ν_* mais la réciproque n'est pas nécessairement vraie, par exemple dans le cas où la fonction ϕ peut s'annuler, mais en revanche la distribution de probabilité ν_* domine la distribution de probabilité μ sur le support de la fonction ϕ , avec

$$|\phi| \frac{d\mu}{d\nu_*} = \langle \mu, |\phi| \rangle ,$$

alors on vérifie que

$$\int_E (\phi(x) \frac{d\mu}{d\nu_*}(x))^2 \nu_*(dx) = \langle \mu, |\phi| \rangle^2 ,$$

de sorte que

$$\text{var}(\phi \frac{d\mu}{d\nu_*}, \nu_*) = \int_E (\phi(x) \frac{d\mu}{d\nu_*}(x))^2 \nu_*(dx) - \langle \mu, \phi \rangle^2 = \langle \mu, |\phi| \rangle^2 - \langle \mu, \phi \rangle^2 ,$$

et la borne inférieure est atteinte.

Remarque 9.4 La distribution de probabilité d'importance optimale ν_* et la fonction d'importance optimale $d\mu/d\nu_*$ associée dépendent de la fonction ϕ dont on veut calculer l'intégrale, et ne sont donc pas universelles.

Remarque 9.5 Il est certainement possible de simuler une variable aléatoire distribuée selon ν_* , même si la constante de normalisation $\langle \mu, |\phi| \rangle$ est inconnue, en utilisant l'une ou l'autre des méthodes proposées à la Section 9.2, mais la connaissance explicite de la constante de normalisation est absolument nécessaire pour évaluer la fonction d'importance optimale $d\mu/d\nu_*$. En pratique, le choix optimal n'est donc simplement pas utilisable. Cependant, on peut espérer que des algorithmes adaptatifs, qui apprennent (de manière approchée) la distribution de probabilité d'importance optimale ν_* , produiront des estimateurs dont la variance approchera la variance minimale.

Pour tout autre choix (non-optimal) de la distribution de probabilité d'importance ν et de la fonction d'importance $d\mu/d\nu$, on a

$$\begin{aligned} \text{var}(\phi \frac{d\mu}{d\nu}, \nu) - \text{var}(\phi \frac{d\mu}{d\nu_*}, \nu_*) &= \int_E (\phi(x) \frac{d\mu}{d\nu}(x))^2 \nu(dx) - \langle \mu, |\phi| \rangle^2 \\ &= \int_E (\phi(x) \frac{d\mu}{d\nu_*}(x) \frac{d\nu_*}{d\nu}(x))^2 \nu(dx) - \langle \mu, |\phi| \rangle^2 \\ &= \langle \mu, |\phi| \rangle^2 \int_E (\frac{d\nu_*}{d\nu}(x))^2 \nu(dx) - \langle \mu, |\phi| \rangle^2 \\ &= \langle \mu, |\phi| \rangle^2 \int_E ((\frac{d\nu_*}{d\nu}(x))^2 - 1) \nu(dx) \\ &= \langle \mu, |\phi| \rangle^2 \chi^2(\nu_*, \nu) . \end{aligned}$$

en terme de la divergence du χ^2 entre les distributions de probabilité ν_* et ν , définie par

$$\chi^2(\nu_*, \nu) = \int_E (\frac{d\nu_*}{d\nu}(x) - 1)^2 \nu(dx) = \int_E ((\frac{d\nu_*}{d\nu}(x))^2 - 1) \nu(dx) .$$

pourvu que la distribution de probabilité d'importance ν domine la distribution de probabilité d'importance optimale ν_* . Si λ est une mesure positive, pas nécessairement normalisée, qui domine à la fois ν_* et ν , avec les densités

$$q_* = \frac{d\nu_*}{d\lambda} \quad \text{et} \quad q = \frac{d\nu}{d\lambda} ,$$

respectivement, alors on a les expressions équivalentes suivantes

$$\chi^2(\nu_*, \nu) = \int_E \frac{(q_*(x) - q(x))^2}{q(x)} \lambda(dx) = \int_E \frac{q_*^2(x)}{q(x)} \lambda(dx) - 1 .$$

En conclusion, si au lieu de la distribution de probabilité d'importance optimale ν_* on utilise une distribution de probabilité d'importance ν^M

- qui domine la distribution de probabilité μ , et qui domine donc a fortiori la distribution de probabilité d'importance optimale ν_* , de sorte que la divergence $\chi^2(\nu_*, \nu^M)$ est bien définie,
- et qui approche la distribution de probabilité d'importance optimale ν_* , c'est-à-dire que $\chi^2(\nu_*, \nu^M)$ tend vers zero, quand $M \uparrow \infty$,

et si on construit l'estimateur suivant

$$\langle \mu_N^M, \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(x_i) \frac{d\mu}{d\nu^M}(x_i) ,$$

où les variables aléatoires $(x_1, \dots, x_N)$ sont i.i.d. de distribution de probabilité commune ν^M , alors la variance de cet estimateur est

$$\mathbb{E}|\langle \mu_N^M - \mu, \phi \rangle|^2 = \frac{1}{N} \text{var}(\phi \frac{d\mu}{d\nu^M}, \nu^M) = \frac{1}{N} [\text{var}(\phi \frac{d\mu}{d\nu_*}, \nu_*) + \langle \mu, |\phi|^2 \rangle \chi^2(\nu_*, \nu^M)] ,$$

et si la fonction ϕ garde un signe constant, alors

$$\mathbb{E}|\langle \mu_N^M - \mu, \phi \rangle|^2 = \frac{1}{N} \chi^2(\nu_*, \nu^M) \langle \mu, |\phi|^2 \rangle ,$$

compte tenu que la variance minimale $\text{var}(\phi \frac{d\mu}{d\nu_*}, \nu_*)$ est nulle dans ce cas, c'est-à-dire que l'erreur d'échantillonnage Monte Carlo et l'erreur d'approximation due à l'apprentissage de la distribution de probabilité d'importance optimale ν_* se multiplient au lieu de s'additionner !

9.2 Simulation selon une distribution de Gibbs–Boltzmann

Il peut arriver que la distribution de probabilité d'importance soit seulement connue à une constante multiplicative près, par exemple dans la situation suivante. Si la distribution de probabilité μ est de la forme

$$\mu = g \cdot \eta = \frac{g \eta}{\langle \eta, g \rangle} \quad \text{c'est-à-dire} \quad \langle \mu, \phi \rangle = \frac{\langle \eta, g \phi \rangle}{\langle \eta, g \rangle} ,$$

ou de manière équivalente

$$\langle \gamma, \phi \rangle = \langle \eta, g \phi \rangle = \mathbb{E}[g(\Xi) \phi(\Xi)] \quad \text{et} \quad \langle \mu, \phi \rangle = \frac{\langle \gamma, \phi \rangle}{\langle \gamma, 1 \rangle}, \quad (9.3)$$

où la variable aléatoire Ξ a pour distribution de probabilité η , pour toute fonction mesurable bornée ϕ , et s'il est facile

- d'évaluer la fonction positive g ,
- et de simuler une variable aléatoire de distribution de probabilité η ,

alors il est possible

- de simuler une variable aléatoire de distribution de probabilité μ , avec une méthode d'acceptation / rejet,
- ou bien d'approcher la distribution de probabilité μ par la distribution de probabilité empirique pondérée associée à un échantillon de variables aléatoires i.i.d., de distribution de probabilité commune η et pondéré par la fonction positive g , avec une méthode d'échantillonnage pondéré,

même si la constante de normalisation $\langle \eta, g \rangle$ n'est pas connue explicitement.

► **Acceptation / rejet** La constante de normalisation $\langle \eta, g \rangle$ n'est pas nécessairement connue, et on suppose seulement que $\sup_{x \in E} g(x) \leq M < \infty$.

On simule indépendamment une variable aléatoire Ξ selon la distribution de probabilité η et une variable aléatoire U uniforme sur $[0, 1]$: si $g(\Xi) \geq M U$ alors on pose $X = \Xi$, et sinon on recommence. La variable aléatoire X simulée selon cet algorithme a pour distribution de probabilité $\mu = g \cdot \eta$. En effet

$$\mathbb{E}[\phi(X)] = \mathbb{E}[\phi(\Xi) \mid g(\Xi) \geq M U] = \frac{\mathbb{E}[\phi(\Xi) 1_{(g(\Xi) \geq M U)}]}{\mathbb{P}[g(\Xi) \geq M U]},$$

et

$$\begin{aligned} \mathbb{E}[\phi(\Xi) 1_{(g(\Xi) \geq M U)}] &= \int_E \int_0^1 \phi(x) 1_{(g(x) \geq M u)} du \eta(dx) \\ &= \int_E \phi(x) \frac{g(x)}{M} \eta(dx) = \frac{\langle \eta, g \phi \rangle}{M}, \end{aligned}$$

pour toute fonction mesurable bornée ϕ , et en particulier

$$\mathbb{P}[g(\Xi) \geq M U] = \frac{\langle \eta, g \rangle}{M},$$

pour $\phi \equiv 1$, de sorte que

$$\mathbb{E}[\phi(X)] = \frac{\langle \eta, g \phi \rangle}{\langle \eta, g \rangle} = \langle \mu, \phi \rangle.$$

Soit $(U_k, k \geq 1)$ et $(\Xi_k, k \geq 1)$ deux suites indépendantes, de variables aléatoires i.i.d. uniformes sur $[0, 1]$ et de variables aléatoires i.i.d. de distribution de probabilité commune η respectivement, et on définit le nombre aléatoire

$$T = \inf\{k \geq 1 : g(\Xi_k) \geq M U_k\},$$

qui représente le nombre d'itérations de l'algorithme d'acceptation / rejet nécessaires pour produire une variable aléatoire de distribution de probabilité $\mu = g \cdot \eta$.

Proposition 9.6 *Les variables aléatoires $X = \Xi_T$ et T sont indépendantes*

- de distribution de probabilité $\mu = g \cdot \eta$,
- et de loi géométrique de paramètre $\frac{\langle \eta, g \rangle}{M}$,

respectivement.

PREUVE. Par indépendance

$$\begin{aligned} \mathbb{E}[\phi(X) 1_{(T=n)}] &= \mathbb{E}[\phi(\Xi_n) 1_{(g(\Xi_n) \geq M U_n)} \prod_{k=1}^{n-1} 1_{(g(\Xi_k) < M U_k)}] \\ &= \mathbb{E}[\phi(\Xi_n) 1_{(g(\Xi_n) \geq M U_n)}] \prod_{k=1}^{n-1} \mathbb{P}[g(\Xi_k) < M U_k] \\ &= \frac{\langle \eta, g \phi \rangle}{M} \left(1 - \frac{\langle \eta, g \rangle}{M}\right)^{n-1} \\ &= \langle \mu, \phi \rangle \frac{\langle \eta, g \rangle}{M} \left(1 - \frac{\langle \eta, g \rangle}{M}\right)^{n-1}, \end{aligned}$$

pour tout entier n et pour toute fonction mesurable bornée ϕ , et en particulier pour $\phi \equiv 1$

$$\mathbb{P}[T = n] = \frac{\langle \eta, g \rangle}{M} \left(1 - \frac{\langle \eta, g \rangle}{M}\right)^{n-1},$$

de sorte que

$$\mathbb{E}[\phi(X) 1_{(T=n)}] = \langle \mu, \phi \rangle \frac{\langle \eta, g \rangle}{M} \left(1 - \frac{\langle \eta, g \rangle}{M}\right)^{n-1} = \mathbb{E}[\phi(X)] \mathbb{P}[T = n],$$

ce qui montre l'indépendance des variables aléatoires T et $X = \Xi_T$. $\square$

Soit $(\xi^1, \dots, \xi^N)$ un N -échantillon de distribution de probabilité commune $\mu = g \cdot \eta$ obtenu par l'algorithme d'acceptation / rejet présenté ci-dessus, et soit $(T^1, \dots, T^N)$ les nombres d'itérations nécessaires pour produire respectivement les variables aléatoires $(\xi^1, \dots, \xi^N)$. Pour énoncer un théorème central limite, et utiliser la variance asymptotique comme moyen de comparer les algorithmes entre eux, il est plus raisonnable d'utiliser comme normalisation le nombre

total d'itérations, c'est-à-dire le nombre total de variables aléatoires simulées, qui est une mesure quantitative du temps de calcul de l'algorithme d'acceptation / rejet pour générer un N -échantillon. D'après la loi des grands nombres

$$\frac{1}{N} \sum_{i=1}^N T^i \longrightarrow \mathbb{E}[T] = \frac{M}{\langle \eta, g \rangle} ,$$

en probabilité quand $N \uparrow \infty$, et d'après le lemme de Slutsky

$$\left(\sum_{i=1}^N T^i \right)^{1/2} \langle S^N(\mu) - \mu, \phi \rangle \Longrightarrow \mathcal{N}\left(0, \frac{M}{\langle \eta, g \rangle} \text{var}(\phi, \mu)\right) ,$$

en distribution quand $N \uparrow \infty$.

Remarque 9.7 La variance asymptotique est d'autant plus petite que le rapport

$$\frac{M}{\langle \eta, g \rangle} = \frac{M}{\sup_{x \in E} g(x)} \frac{\sup_{x \in E} g(x)}{\langle \eta, g \rangle} ,$$

est petit (proche de 1). Le premier facteur est d'autant plus petit (proche de 1) que la borne M est proche du supremum, c'est donc une caractéristique de la méthode, tandis que le second facteur est d'autant plus petit (proche de 1) que le recouvrement entre la distribution de probabilité η et la fonction g est grand, c'est-à-dire que la distribution de probabilité η est concentrée autour des points où la fonction g prend ses plus grandes valeurs, c'est donc une caractéristique du modèle lui-même.

► **Échantillonnage pondéré** Le principe consiste à approximer numérateur et dénominateur dans (9.3) à l'aide d'un unique échantillon : on introduit les approximations suivantes

$$\langle \gamma, \phi \rangle = \langle \eta, g \phi \rangle \approx \langle S^N(\eta), g \phi \rangle = \frac{1}{N} \sum_{i=1}^N g(\xi^i) \phi(\xi^i) ,$$

et

$$\langle \mu, \phi \rangle = \langle g \cdot \eta, \phi \rangle \approx \langle g \cdot S^N(\eta), \phi \rangle = \frac{\sum_{i=1}^N g(\xi^i) \phi(\xi^i)}{\sum_{i=1}^N g(\xi^i)} \quad \text{pourvu que} \quad \frac{1}{N} \sum_{i=1}^N g(\xi^i) > 0 ,$$

pour toute fonction mesurable bornée ϕ , c'est-à-dire que

$$\gamma \approx \gamma^N = g S^N(\eta) = \frac{1}{N} \sum_{i=1}^N g(\xi^i) \delta_{\xi^i}$$

et

$$\mu \approx \mu^N = g \cdot S^N(\eta) = \sum_{i=1}^N \frac{g(\xi^i)}{\sum_{j=1}^N g(\xi^j)} \delta_{\xi^i} = \sum_{i=1}^N w^i \delta_{\xi^i} \quad \text{pourvu que} \quad \frac{1}{N} \sum_{i=1}^N g(\xi^i) > 0 ,$$

où les variables aléatoires $(\xi^1, \dots, \xi^N)$ sont i.i.d., de distribution de probabilité commune η , et où les poids positifs $(w^1, \dots, w^N)$ sont définis par

$$w^i = \frac{g(\xi^i)}{\sum_{j=1}^N g(\xi^j)} \quad \text{pour tout } i = 1, \dots, N.$$

Il résulte du Théorème 9.1 que la variable aléatoire $\langle \gamma^N, \phi \rangle = \langle S^N(\eta), g\phi \rangle$ est un estimateur non-biaisé de $\langle \gamma, \phi \rangle = \langle \eta, g\phi \rangle$, pour toute fonction mesurable bornée ϕ , et en particulier pour $\phi \equiv 1$, la variable aléatoire $\langle \gamma^N, 1 \rangle = \langle S^N(\eta), g \rangle$ est un estimateur non-biaisé de $\langle \gamma, 1 \rangle = \langle \eta, g \rangle$. En revanche, en tant que rapport de deux estimateurs non-biaisés, la variable aléatoire $\langle \mu^N, \phi \rangle = \langle \gamma^N, \phi \rangle / \langle \gamma^N, 1 \rangle$ est un estimateur *biaisé* de $\langle \mu, \phi \rangle = \langle \gamma, \phi \rangle / \langle \gamma, 1 \rangle$.

Théorème 9.8 *La variable aléatoire $\langle \gamma^N, \phi \rangle$ est un estimateur non-biaisé de $\langle \gamma, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} |^2 \}^{1/2} = \frac{1}{\sqrt{N}} \left(\frac{\langle \eta, |g\phi - \langle \eta, g\phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2} \right)^{1/2} , \quad (9.4)$$

et pour tout réel $p \geq 2$

$$\{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \left(\frac{\langle \eta, |g\phi - \langle \eta, g\phi \rangle|^p \rangle}{\langle \eta, g \rangle^p} \right)^{1/p} , \quad (9.5)$$

pour toute fonction ϕ mesurable bornée.

PREUVE. On remarque que

$$\frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} = \frac{\langle S^N(\eta) - \eta, g\phi \rangle}{\langle \eta, g \rangle} ,$$

et il résulte du Théorème 9.1 que

$$\{ \mathbb{E} | \frac{\langle S^N(\eta) - \eta, g\phi \rangle}{\langle \eta, g \rangle} |^2 \}^{1/2} = \frac{1}{\sqrt{N}} \left(\frac{\langle \eta, |g\phi - \langle \eta, g\phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2} \right)^{1/2} ,$$

et

$$\{ \mathbb{E} | \frac{\langle S^N(\eta) - \eta, g\phi \rangle}{\langle \eta, g \rangle} |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \left(\frac{\langle \eta, |g\phi - \langle \eta, g\phi \rangle|^p \rangle}{\langle \eta, g \rangle^p} \right)^{1/p} ,$$

pour tout réel $p \geq 2$. □

Remarque 9.9 En particulier pour $\phi \equiv 1$, la variable aléatoire $\langle \gamma^N, 1 \rangle$ est un estimateur non-biaisé de la constante de normalisation $\langle \gamma, 1 \rangle$, et les moments de l'erreur relative d'estimation vérifient

$$\{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^2 \}^{1/2} = \frac{1}{\sqrt{N}} (\frac{\langle \eta, |g - \langle \eta, g \rangle|^2 \rangle}{\langle \eta, g \rangle^2})^{1/2} , \quad (9.6)$$

et

$$\{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} (\frac{\langle \eta, |g - \langle \eta, g \rangle|^p \rangle}{\langle \eta, g \rangle^p})^{1/p} , \quad (9.7)$$

pour tout réel $p \geq 2$. On remarque aussi que

$$g(\phi - \langle \mu, \phi \rangle) - \langle \eta, g(\phi - \langle \mu, \phi \rangle) \rangle = g(\phi - \langle \mu, \phi \rangle) ,$$

compte tenu que

$$\langle \eta, g(\phi - \langle \mu, \phi \rangle) \rangle = \langle \eta, g \rangle \langle \mu, \phi - \langle \mu, \phi \rangle \rangle = 0 ,$$

de sorte que

$$\{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^2 \}^{1/2} = \frac{1}{\sqrt{N}} (\frac{\langle \eta, g^2 |\phi - \langle \mu, \phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2})^{1/2} , \quad (9.8)$$

et

$$\{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} (\frac{\langle \eta, g^p |\phi - \langle \mu, \phi \rangle|^p \rangle}{\langle \eta, g \rangle^p})^{1/p} , \quad (9.9)$$

pour tout réel $p \geq 2$.

Théorème 9.10 La variable aléatoire $\langle \mu^N, \phi \rangle$ est un estimateur biaisé de $\langle \mu, \phi \rangle$, avec

$$\mathbb{E}[\langle \mu^N, \phi \rangle] = \langle \mu, \phi \rangle + O(1/N) , \quad (9.10)$$

et les moments de l'erreur d'estimation vérifient

$$\{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^2 \}^{1/2} = \frac{1}{\sqrt{N}} (\frac{\langle \eta, g^2 |\phi - \langle \mu, \phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2})^{1/2} + O(1/N) , \quad (9.11)$$

et pour tout réel $p \geq 2$

$$\{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} (\frac{\langle \eta, g^p |\phi - \langle \mu, \phi \rangle|^p \rangle}{\langle \eta, g \rangle^p})^{1/p} + O(1/N) ,$$

pour toute fonction mesurable bornée ϕ .

PREUVE. On rappelle la majoration grossière

$$| \langle \mu^N - \mu, \phi \rangle | = | \langle \mu^N, \phi - \langle \mu, \phi \rangle \rangle | \leq \text{osc}(\phi) , \quad (9.12)$$

valable pour toute fonction ϕ mesurable bornée. On remarque aussi que

$$\begin{aligned} \langle \mu^N - \mu, \phi \rangle &= \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} - \langle \mu^N, \phi \rangle \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma, 1 \rangle} \\ &= \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} - \langle \mu, \phi \rangle \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma, 1 \rangle} - \langle \mu^N - \mu, \phi \rangle \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma, 1 \rangle} \\ &= \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} - \langle \mu^N - \mu, \phi \rangle (\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1) , \end{aligned}$$

et en itérant cette relation, on obtient

$$\begin{aligned}
\langle \mu^N - \mu, \phi \rangle &= \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \\
&\quad - \left[\frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} - \langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \right] \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \\
&= \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} - \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \\
&\quad + \langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2 .
\end{aligned}$$

Pour l'étude du biais, on remarque que

$$\mathbb{E} \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} = 0 ,$$

de sorte que

$$\begin{aligned}
\mathbb{E}[\langle \mu^N, \phi \rangle] - \langle \mu, \phi \rangle &= \mathbb{E} \langle \mu^N - \mu, \phi \rangle \\
&= - \mathbb{E} \left[\frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \right] + \mathbb{E}[\langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2] ,
\end{aligned}$$

et en utilisant l'inégalité triangulaire, puis l'inégalité de Hölder et la majoration grossière (9.12), on obtient

$$\begin{aligned}
|\mathbb{E}[\langle \mu^N, \phi \rangle] - \langle \mu, \phi \rangle| &\leq \mathbb{E} \left| \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) \right| + \mathbb{E} [|\langle \mu^N - \mu, \phi \rangle| \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2] \\
&\leq \left\{ \mathbb{E} \left| \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \right|^2 \right\}^{1/2} \left\{ \mathbb{E} \left| \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right|^2 \right\}^{1/2} \\
&\quad + \text{osc}(\phi) \mathbb{E} \left| \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right|^2 ,
\end{aligned}$$

où les deux termes dans la majoration sont d'ordre $1/N$ d'après (9.6) et (9.8).

Pour l'étude du moment d'ordre 2, en utilisant l'identité (9.8) et l'inégalité triangulaire, puis l'inégalité de Hölder et la majoration grossière (9.12), on obtient

$$\begin{aligned}
& | \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^2 \}^{1/2} - \frac{1}{\sqrt{N}} \left(\frac{\langle \eta, g^2 | \phi - \langle \mu, \phi \rangle |^2 \rangle}{\langle \eta, g \rangle^2} \right)^{1/2} | \\
&= | \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^2 \}^{1/2} - \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^2 \}^{1/2} | \\
&\leq \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle - \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^2 \}^{1/2} \\
&\leq \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) |^2 \}^{1/2} + \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2 |^2 \}^{1/2} \\
&\leq \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^4 \}^{1/4} \{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^4 \}^{1/4} + \text{osc}(\phi) \{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^4 \}^{1/2} ,
\end{aligned}$$

où les deux termes dans la majoration sont d'ordre $1/N$ d'après (9.7) et (9.9).

Pour l'étude du moment d'ordre p , en utilisant l'inégalité triangulaire et la majoration (9.9), puis l'inégalité de Hölder et la majoration grossière (9.12), on obtient

$$\begin{aligned}
\{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle |^p \}^{1/p} &\leq \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^p \}^{1/p} \\
&\quad + \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right) |^p \}^{1/p} \\
&\quad + \{ \mathbb{E} | \langle \mu^N - \mu, \phi \rangle \left(\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right)^2 |^p \}^{1/p} \\
&\leq \frac{c_p}{\sqrt{N}} \left(\frac{\langle \eta, g^p | \phi - \langle \mu, \phi \rangle |^p \rangle}{\langle \eta, g \rangle^p} \right)^{1/p} \\
&\quad + \{ \mathbb{E} | \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} |^{2p} \}^{1/2p} \{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^{2p} \}^{1/2p} \\
&\quad + \text{osc}(\phi) \{ \mathbb{E} | \frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 |^{2p} \}^{1/p} ,
\end{aligned}$$

où les deux derniers termes dans la majoration sont d'ordre $1/N$ d'après (9.7) et (9.9). $\square$

Théorème 9.11

$$\sqrt{N} \left[\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right] \Longrightarrow \mathcal{N}(0, V) \quad \text{et} \quad \sqrt{N} \langle \mu^N - \mu, \phi \rangle \Longrightarrow \mathcal{N}(0, v(\phi)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$V = \frac{\langle \eta, g^2 \rangle}{\langle \eta, g \rangle^2} - 1 \quad \text{et} \quad v(\phi) = \frac{\langle \eta, g^2 | \phi - \langle \mu, \phi \rangle |^2 \rangle}{\langle \eta, g \rangle^2} ,$$

respectivement.

Remarque 9.12 On vérifie que la variance asymptotique V coïncide avec la variance non-asymptotique donnée en (9.6), et que la variance asymptotique $v(\phi)$ coïncide avec le terme dominant de l'erreur quadratique moyenne non-asymptotique donnée en (9.11) ou de manière équivalente avec le terme dominant de la variance non-asymptotique, compte tenu que le biais donné en (9.10) est asymptotiquement négligeable.

PREUVE. Il résulte du théorème central limite (dans sa version classique, pour des variables indépendantes identiquement distribuées), que

$$\sqrt{N} \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma, 1 \rangle} = \sqrt{N} \frac{\langle S^N(\eta) - \eta, g \phi \rangle}{\langle \eta, g \rangle} \implies \mathcal{N}(0, \frac{\text{var}(g \phi, \eta)}{\langle \eta, g \rangle^2}) ,$$

en distribution quand $N \uparrow \infty$, et en particulier pour $\phi \equiv 1$

$$\sqrt{N} \left[\frac{\langle \gamma^N, 1 \rangle}{\langle \gamma, 1 \rangle} - 1 \right] = \sqrt{N} \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma, 1 \rangle} \implies \mathcal{N}(0, \frac{\text{var}(g, \eta)}{\langle \eta, g \rangle^2}) ,$$

en distribution quand $N \uparrow \infty$. On remarque aussi que

$$\langle \mu^N - \mu, \phi \rangle = \frac{\langle \gamma^N - \gamma, \phi \rangle}{\langle \gamma^N, 1 \rangle} - \langle \mu, \phi \rangle \frac{\langle \gamma^N - \gamma, 1 \rangle}{\langle \gamma^N, 1 \rangle} = \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \frac{\langle \gamma, 1 \rangle}{\langle \gamma^N, 1 \rangle} .$$

D'après la loi des grands nombres

$$\langle \gamma^N, 1 \rangle = \frac{1}{N} \sum_{i=1}^N g(\xi^i) \longrightarrow \langle \eta, g \rangle = \langle \gamma, 1 \rangle ,$$

en probabilité quand $N \uparrow \infty$, et d'après le lemme de Slutsky

$$\sqrt{N} \langle \mu^N - \mu, \phi \rangle = \frac{\langle \gamma, 1 \rangle}{\langle \gamma^N, 1 \rangle} \sqrt{N} \frac{\langle \gamma^N - \gamma, \phi - \langle \mu, \phi \rangle \rangle}{\langle \gamma, 1 \rangle} \implies \mathcal{N}(0, \frac{\text{var}(g(\phi - \langle \mu, \phi \rangle), \eta)}{\langle \eta, g \rangle^2}) ,$$

en distribution quand $N \uparrow \infty$. On remarque que

$$\langle \eta, g(\phi - \langle \mu, \phi \rangle) \rangle = \langle \eta, g \rangle \langle \mu, \phi - \langle \mu, \phi \rangle \rangle = 0 ,$$

de sorte que

$$\text{var}(g(\phi - \langle \mu, \phi \rangle), \eta) = \langle \eta, g^2 |\phi - \langle \mu, \phi \rangle|^2 \rangle . \quad \square$$

Remarque 9.13 Le principe de l'échantillonnage pondéré est illustré sur la Figure 9.2. On constate en particulier que l'approximation sera d'autant meilleure que la distribution d'importance η (densité a priori) et la fonction d'importance g (vraisemblance) se recouvrent mutuellement, de telle sorte que la fonction d'importance prend des valeurs significatives sur l'échantillon généré. La décomposition d'importance sera au contraire mal-posée si les valeurs significatives de la fonction d'importance sont obtenues dans les queues de la distribution d'importance, auquel cas la fonction d'importance prend des valeurs négligeables sur l'échantillon généré. Un

critère quantitatif pour mesurer le recouvrement mutuel entre la distribution d'importance η et la fonction d'importance g est donné par l'intégrale normalisée (compte tenu que la fonction d'importance est définie à une constante multiplicative près)

$$\int_E \frac{g(x')}{\sup_{x \in E} g(x)} \eta(dx') \quad \text{ou par le rapport inverse} \quad r = \frac{\sup_{x \in E} g(x)}{\langle \eta, g \rangle} .$$




FIGURE 9.1 : Densité a priori, échantillon (en haut) et histogramme associé à l'échantillon (en bas)




FIGURE 9.2 : Densité a priori, fonction de vraisemblance, densité a posteriori, échantillon pondéré (en haut) et histogramme associé à l'échantillon pondéré (en bas)

Pour une décomposition $\mu = g \cdot \eta$ donnée, la variance asymptotique de l'algorithme d'échantillonnage pondéré est inférieure à la variance asymptotique, convenablement normalisée par le nombre total de variable aléatoires simulées, de l'algorithme d'acceptation / rejet. En effet

$$\frac{\langle \eta, g^2 |\phi - \langle \mu, \phi \rangle|^2 \rangle}{\langle \eta, g \rangle^2} \leq \frac{M}{\langle \eta, g \rangle} \frac{\langle \eta, g |\phi - \langle \mu, \phi \rangle|^2 \rangle}{\langle \eta, g \rangle} = \frac{M}{\langle \eta, g \rangle} \text{var}(\phi, \mu) ,$$

où on suppose que $\sup_{x \in E} g(x) \leq M < \infty$.

Aucun de ces deux algorithmes ne nécessite la connaissance de la constante de normalisation $\langle \eta, g \rangle$, mais l'algorithme d'acceptation / rejet utilise quand même de façon explicite une borne supérieure M de la fonction positive g , alors que l'algorithme d'échantillonnage pondéré ne nécessite pas la connaissance d'une telle borne. En revanche, l'algorithme d'acceptation / rejet produit un échantillon de distribution de probabilité μ exactement, alors que l'algorithme d'échantillonnage pondéré produit seulement un échantillon de distribution de probabilité η , pondéré par la fonction positive g et normalisé.

9.3 Échantillonnage et approximation d'un mélange fini

Si la distribution de probabilité η est définie comme un mélange fini de distributions de probabilité $(m_1, \dots, m_M)$ avec les poids positifs $(w_1, \dots, w_M)$, c'est-à-dire si

$$\eta = \sum_{i=1}^M w_i m_i \quad \text{avec} \quad \sum_{i=1}^M w_i = 1 ,$$

et s'il est facile

- de simuler pour tout $i = 1, \dots, M$ une variable aléatoire distribuée selon m_i ,

alors il est facile, en principe, de simuler une variable aléatoire selon la distribution de probabilité η . Il suffit en effet de simuler d'abord une variable aléatoire I à valeurs dans l'ensemble fini $\{1, \dots, M\}$ et distribuée selon les poids $(w_1, \dots, w_M)$, c'est-à-dire $\mathbb{P}[I = i] = w_i$ pour tout $i = 1, \dots, M$, puis de générer une variable aléatoire distribuée selon m_I . La probabilité de sélectionner une composante du mélange sera d'autant plus grande que le poids de cette composante est grand. La question qui reste, et qui sera traitée à la Section 9.4, est donc de savoir simuler une variable aléatoire à valeurs dans l'ensemble fini $\{1, \dots, M\}$.

► **Échantillonnage multinomial** S'il s'agit d'approcher la distribution de probabilité η par un mélange fini de masses de Dirac, ou particules, plusieurs approches sont possibles. On peut simuler un N -échantillon $(\xi_1, \dots, \xi_N)$ distribué selon η , où N n'est pas nécessairement égal au nombre M de composantes du mélange, et

$$S^N(\eta) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_i} . \quad (9.13)$$

Les poids sont ici exploités pour sélectionner (avec remise) les composantes du mélange les mieux loties, avec l'effet attendu que les composantes de plus forts poids seront sélectionnées plusieurs fois, tandis que les composantes de moins forts poids pourront même être éliminées et ne plus être représentées du tout dans l'approximation. Le nombre de fois que la i -ème composante du mélange est sélectionnée, ou de manière équivalente son nombre N_i de représentants dans l'approximation, sera d'autant grand que le poids w_i de cette composante est grand, et on peut montrer que le vecteur aléatoire $(N_1, \dots, N_M)$ suit une loi multinomiale. La question qui reste, et qui sera traitée à la Section 9.4, est donc de savoir simuler un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$, plus efficacement qu'en répétant N fois la simulation d'une seule variable aléatoire.

Intuitivement, si tous les poids sont égaux à (ou proches de) $1/M$, c'est-à-dire si la répartition des poids de mélange est proche de l'équidistribution, alors il est inutile voire même contre-productif de sélectionner les composantes du mélange, avec le risque de favoriser certaines composantes au détriment des autres composantes, alors qu'en principe toutes les composantes ont la même importance.

Théorème 9.14 *La variable aléatoire $\langle S^N(\eta), \phi \rangle$ est un estimateur non-biaisé de $\langle \eta, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\mathbb{E} |\langle S^N(\eta) - \eta, \phi \rangle|^2 = \frac{1}{N} \text{var}(\phi, \eta)$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{\mathbb{E} |\langle S^N(\eta) - \eta, \phi \rangle|^p\}^{1/p} \leq \frac{c_p}{\sqrt{N}} \langle \eta, |\phi - \langle \eta, \phi \rangle|^p \rangle^{1/p},$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.15 Compte tenu que

$$|\phi(x) - \langle \eta, \phi \rangle| \leq \text{osc}(\phi),$$

pour tout $x \in E$, on a également la majoration plus grossière suivante

$$\{\mathbb{E} |\langle S^N(\eta) - \eta, \phi \rangle|^p\}^{1/p} \leq \frac{c_p}{\sqrt{N}} \text{osc}(\phi),$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.16 On remarque que

$$\begin{aligned} \text{var}(\phi, \eta) &= \sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \\ &= \sum_{i=1}^M w_i \text{var}(\phi, m_i) + \underbrace{\left[\sum_{i=1}^M w_i |\langle m_i, \phi \rangle|^2 - \left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \right]}_{W_M}, \end{aligned}$$

où le terme W_M représente la variance des moyennes intra-composantes affectées du poids de chaque composante.

► **Conservation des poids** A l'opposé, on peut décider de conserver les poids et de simuler un représentant pour chaque composante du mélange (ce qui impose que N est nécessairement égal au nombre M de composantes du mélange initial), et poser

$$\eta_M = \sum_{i=1}^M w_i \delta_{\xi_i} , \quad (9.14)$$

où indépendamment pour tout $i = 1, \dots, M$ la variable aléatoire ξ_i est distribuée selon m_i .

Intuitivement, cette seconde approche est certainement pertinente dans le cas où la répartition des poids de mélange est proche de l'équidistribution, mais en revanche peu appropriée dans le cas extrême où presque tous les poids sont nuls sauf quelques uns, c'est-à-dire dans le cas où quelques composantes seulement, voire même une seule composante, sont effectivement présentes dans le mélange.

Théorème 9.17 *La variable aléatoire $\langle \eta_M, \phi \rangle$ est un estimateur non-biaisé de $\langle \eta, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^2 = \left(\sum_{i=1}^M w_i^2 \right) \left[\sum_{i=1}^M w_i^\square \text{var}(\phi, m_i) \right] ,$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{ \mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^p \}^{1/p} \leq c_p \left(\sum_{i=1}^M w_i^2 \right)^{1/2} \{ \sum_{i=1}^M w_i^\square \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle \}^{1/p} ,$$

pour toute fonction mesurable bornée ϕ , où le vecteur de probabilité $(w_1^\square, \dots, w_M^\square)$ est défini par

$$w_i^\square = w_i^2 / \left[\sum_{j=1}^M w_j^2 \right] \quad \text{pour tout } i = 1, \dots, M.$$

Remarque 9.18 Compte tenu que

$$| \phi(x) - \langle m_i, \phi \rangle | \leq \text{osc}(\phi) ,$$

pour tout $x \in E$ et pour tout $i = 0, 1, \dots, M$, on a également la majoration plus grossière suivante

$$\{ \mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^p \}^{1/p} \leq c_p \left(\sum_{i=1}^M w_i^2 \right)^{1/2} \text{osc}(\phi) ,$$

pour toute fonction mesurable bornée ϕ .

PREUVE. En exploitant l'indépendance des différentes variables aléatoires, on remarque que

$$\begin{aligned} \mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^2 &= \mathbb{E} \left| \sum_{i=1}^M w_i [\phi(\xi^i) - \langle m_i, \phi \rangle] \right|^2 \\ &= \sum_{i=1}^M w_i^2 \mathbb{E} |\phi(\xi^i) - \langle m_i, \phi \rangle|^2 \\ &= \left(\sum_{i=1}^M w_i^2 \right) \left[\sum_{i=1}^M w_i^\square \text{var}(\phi, m_i) \right], \end{aligned}$$

pour toute fonction mesurable bornée ϕ . Plus généralement, pour tout réel $p \geq 2$, il résulte de l'inégalité de Marcinkiewicz–Zygmund (B.2) que

$$\begin{aligned} \mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^p &= \mathbb{E} \left| \sum_{i=1}^M w_i [\phi(\xi^i) - \langle m_i, \phi \rangle] \right|^p \\ &\leq B_p \left(\sum_{i=1}^M w_i^2 \right)^{p/2} \left[\sum_{i=1}^M w_i^\square \mathbb{E} |\phi(\xi^i) - \langle m_i, \phi \rangle|^p \right] \\ &= B_p \left(\sum_{i=1}^M w_i^2 \right)^{p/2} \left[\sum_{i=1}^M w_i^\square \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle \right], \end{aligned}$$

pour toute fonction mesurable bornée ϕ . □

Remarque 9.19 La variance de l'estimateur (9.13) vérifie

$$V_{\text{red}} = \frac{1}{N} \left[\sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \right] \geq \frac{1}{N} \sum_{i=1}^M w_i \text{var}(\phi, m_i),$$

compte tenu que

$$\left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \leq \sum_{i=1}^M w_i |\langle m_i, \phi \rangle|^2,$$

d'après l'inégalité de Cauchy–Schwartz, à comparer avec la variance

$$V_{\text{nored}} = \sum_{i=1}^M w_i^2 \text{var}(\phi, m_i),$$

de l'estimateur (9.14). A l'équidistribution, c'est-à-dire si tous les poids sont égaux entre eux (et égaux à $1/M$), alors

$$V_{\text{red}} \geq \frac{1}{M^2} \sum_{i=1}^M \text{var}(\phi, m_i) = V_{\text{nored}},$$

ce qui confirme l'intuition que redistribuer est contre-productif dans ce cas extrême. A l'inverse, si la distribution des poids est complètement dégénérée, c'est-à-dire si tous les poids sont nuls sauf le poids $w_a = 1$ pour la composante a du mélange, alors

$$V_{\text{red}} = \frac{1}{N} [\langle m_a, |\phi|^2 \rangle - |\langle m_a, \phi \rangle|^2] = \frac{1}{N} \text{var}(\phi, m_a) \leq \text{var}(\phi, m_a) = V_{\text{nored}} ,$$

ce qui confirme l'intuition que redistribuer est certainement pertinent dans cet autre cas extrême.

► **Stratification et échantillonnage résiduel multinomial** Sélectionner les composantes du mélange en échantillonnant selon les poids respectifs n'est donc approprié que dans les cas où la répartition des poids de mélange est éloigné de l'équidistribution, mais introduit de toute manière un aléa supplémentaire. Pour limiter cette source d'aléa, on peut par exemple affecter de manière déterministe à chaque composante du mélange un nombre de représentants égal au nombre de fois que le poids $1/N$ est contenu dans le poids w_i de la composante (le poids $1/N$ est celui qui sera affecté à chaque particule dans l'approximation finale). Il reste ensuite à compléter la population de particules de manière à assurer un effectif de taille N , par exemple en simulant un échantillon selon la distribution résiduelle des poids non encore affectés. Concrètement, pour toute composante $i = 1, \dots, M$ le nombre de représentants affectés à l'issue de la première passe est $N_i = \lfloor N w_i \rfloor$, c'est-à-dire que

$$N w_i = N_i + q_i \quad \text{avec} \quad 0 \leq q_i < 1 .$$

Compte tenu des identités

$$N = \sum_{i=1}^M N w_i = \sum_{i=1}^M (N_i + q_i) = \sum_{i=1}^M N_i + N_0 \quad \text{avec} \quad N_0 = \sum_{i=1}^M q_i ,$$

et

$$\eta = \sum_{i=1}^M w_i m_i = \sum_{i=1}^M \frac{N_i}{N} m_i + \sum_{i=1}^M \frac{q_i}{N} m_i = \sum_{i=1}^M \frac{N_i}{N} m_i + \frac{N_0}{N} m_0 ,$$

avec

$$m_0 = \sum_{i=1}^M \frac{q_i}{N_0} m_i ,$$

on déduit que $(N - N_0)$ représentants ont déjà été affectés à l'issue de cette première passe, et il reste donc N_0 représentants à affecter de manière à approcher la distribution de probabilité résiduelle convenablement renormalisée m_0 . L'approximation proposée consiste

- à simuler indépendamment pour tout $i = 1, \dots, M$ un N_i -échantillon $(\xi^{i,1}, \dots, \xi^{i,N_i})$ distribué selon m_i ,
- à simuler un N_0 -échantillon $(\xi^{0,1}, \dots, \xi^{0,N_0})$ distribué selon le mélange fini m_0 ,

toutes les variables aléatoires étant simulées de manière indépendantes, et à poser

$$\eta_N = \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} \delta_{\xi^{i,j}} + \frac{1}{N} \sum_{j=1}^{N_0} \delta_{\xi^{0,j}} , \quad (9.15)$$

c'est-à-dire que

$$\langle \eta_N, \phi \rangle = \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} \phi(\xi^{i,j}) + \frac{1}{N} \sum_{j=1}^{N_0} \phi(\xi^{0,j}) ,$$

et par différence

$$\langle \eta_N - \eta, \phi \rangle = \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} [\phi(\xi^{i,j}) - \langle m_i, \phi \rangle] + \frac{1}{N} \sum_{j=1}^{N_0} [\phi(\xi^{0,j}) - \langle m_0, \phi \rangle] ,$$

pour toute fonction mesurable bornée ϕ .

Théorème 9.20 *La variable aléatoire $\langle \eta_N, \phi \rangle$ est un estimateur non-biaisé de $\langle \eta, \phi \rangle$, et les moments de l'erreur d'estimation vérifient*

$$\mathbb{E} |\langle \eta_N - \eta, \phi \rangle|^2 = \frac{1}{N} \left[\sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) \right] ,$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{ \mathbb{E} |\langle \eta_N - \eta, \phi \rangle|^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \left[\sum_{i=1}^M \frac{N_i}{N} \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle + \frac{N_0}{N} \langle m_0, |\phi - \langle m_0, \phi \rangle|^p \rangle \right]^{1/p} ,$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.21 Compte tenu que

$$|\phi(x) - \langle m_i, \phi \rangle| \leq \text{osc}(\phi) ,$$

pour tout $x \in E$ et pour tout $i = 0, 1, \dots, M$, on a également la majoration plus grossière suivante

$$\{ \mathbb{E} |\langle \eta_N - \eta, \phi \rangle|^p \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \left[\sum_{i=1}^M \frac{N_i}{N} + \frac{N_0}{N} \right]^{1/p} \text{osc}(\phi) \leq \frac{c_p}{\sqrt{N}} \text{osc}(\phi) ,$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.22 On remarque que

$$\text{var}(\phi, m_0) = \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 ,$$

et on rappelle que $N_i = N w_i - q_i$ pour tout $i = 1, \dots, M$, de sorte que

$$\begin{aligned}
& \sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) = \\
&= \sum_{i=1}^M w_i \text{var}(\phi, m_i) - \frac{N_0}{N} \sum_{i=1}^M \frac{q_i}{N_0} [\langle m_i, |\phi|^2 \rangle - |\langle m_i, \phi \rangle|^2] \\
&\quad + \frac{N_0}{N} \left[\sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \right] \\
&= \sum_{i=1}^M w_i \text{var}(\phi, m_i) + \underbrace{\frac{N_0}{N} \left[\sum_{i=1}^M \frac{q_i}{N_0} |\langle m_i, \phi \rangle|^2 - \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \right]}_{W_M},
\end{aligned}$$

où le terme W_M représente la variance des moyennes intra-composantes affectées du poids résiduel de chaque composante.

Remarque 9.23 En regroupant les termes différemment, et compte tenu que $N_i + q_i = N w_i$ pour tout $i = 1, \dots, M$, il vient

$$\begin{aligned}
& \sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) \\
&= \sum_{i=1}^M \frac{N_i}{N} \langle m_i, |\phi|^2 \rangle - \sum_{i=1}^M \frac{N_i}{N} |\langle m_i, \phi \rangle|^2 \\
&\quad + \frac{N_0}{N} \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, |\phi|^2 \rangle - \frac{N_0}{N} \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \\
&= \sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left[\sum_{i=1}^M \frac{N_i}{N} |\langle m_i, \phi \rangle|^2 + \frac{N_0}{N} \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \right],
\end{aligned}$$

tandis que

$$\begin{aligned}
\text{var}(\phi, \eta) &= \sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M w_i \langle m_i, \phi \rangle \right|^2 \\
&= \sum_{i=1}^M w_i \langle m_i, |\phi|^2 \rangle - \left| \sum_{i=1}^M \frac{N_i}{N} \langle m_i, \phi \rangle + \frac{N_0}{N} \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2.
\end{aligned}$$

D'après l'inégalité de Cauchy-Schwartz, on a

$$\left| \sum_{i=1}^M \frac{N_i}{N} \langle m_i, \phi \rangle + \frac{N_0}{N} \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2 \leq \sum_{i=1}^M \frac{N_i}{N} |\langle m_i, \phi \rangle|^2 + \frac{N_0}{N} \left| \sum_{i=1}^M \frac{q_i}{N_0} \langle m_i, \phi \rangle \right|^2,$$

d'où on déduit que

$$\text{var}(\phi, \eta) \geq \sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) ,$$

c'est-à-dire que la variance de l'estimateur (9.15) est inférieure à la variance de l'estimateur (9.13). En d'autres termes, la variance de l'erreur d'estimation pour l'algorithme d'échantillonnage résiduel multinomial est inférieure à la variance de l'erreur d'estimation pour l'algorithme d'échantillonnage multinomial.

PREUVE DU THÉORÈME 9.20. En exploitant l'indépendance des différentes variables aléatoires, on remarque que

$$\begin{aligned} \mathbb{E} | \langle \eta_N - \eta, \phi \rangle |^2 &= \mathbb{E} \left| \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} [\phi(\xi^{i,j}) - \langle m_i, \phi \rangle] + \frac{1}{N} \sum_{j=1}^{N_0} [\phi(\xi^{0,j}) - \langle m_0, \phi \rangle] \right|^2 \\ &= \frac{1}{N^2} \sum_{i=1}^M \sum_{j=1}^{N_i} \mathbb{E} |\phi(\xi^{i,j}) - \langle m_i, \phi \rangle|^2 + \frac{1}{N^2} \sum_{j=1}^{N_0} \mathbb{E} |\phi(\xi^{0,j}) - \langle m_0, \phi \rangle|^2 \\ &= \frac{1}{N} \left[\sum_{i=1}^M \frac{N_i}{N} \text{var}(\phi, m_i) + \frac{N_0}{N} \text{var}(\phi, m_0) \right] , \end{aligned}$$

pour toute fonction mesurable bornée ϕ . Plus généralement, pour tout réel $p \geq 2$, il résulte de l'inégalité Marcinkiewicz–Zygmund (B.1) que

$$\begin{aligned} \mathbb{E} | \langle \eta_N - \eta, \phi \rangle |^p &= \mathbb{E} \left| \frac{1}{N} \sum_{i=1}^M \sum_{j=1}^{N_i} [\phi(\xi^{i,j}) - \langle m_i, \phi \rangle] + \frac{1}{N} \sum_{j=1}^{N_0} [\phi(\xi^{0,j}) - \langle m_0, \phi \rangle] \right|^p \\ &\leq \frac{B_p}{N^{p/2}} \frac{1}{N} \left[\sum_{i=1}^M \sum_{j=1}^{N_i} \mathbb{E} |\phi(\xi^{i,j}) - \langle m_i, \phi \rangle|^p + \sum_{j=1}^{N_0} \mathbb{E} |\phi(\xi^{0,j}) - \langle m_0, \phi \rangle|^p \right] \\ &= \frac{B_p}{N^{p/2}} \left[\sum_{i=1}^M \frac{N_i}{N} \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle + \frac{N_0}{N} \langle m_0, |\phi - \langle m_0, \phi \rangle|^p \rangle \right] , \end{aligned}$$

pour toute fonction mesurable bornée ϕ . □

► **Échantillonnage adaptatif** Étant donné la distribution de probabilité η définie comme un mélange fini

$$\eta = \sum_{i=1}^M w_i m_i \quad \text{avec} \quad \sum_{i=1}^M w_i = 1 ,$$

il n'est véritablement intéressant de sélectionner les composantes du mélange que si les poids $(w_1, \dots, w_M)$ sont très déséquilibrés. Plusieurs critères ont été proposés pour mesurer l'écart à l'équidistribution, et pour décider de conserver les poids ou de les utiliser pour échantillonner selon l'une ou l'autre des implémentations proposées ci-dessus, par exemple la distance du

χ^2 ou la distance de Kullback–Leibler entre deux vecteurs de probabilité $p = (p_1, \dots, p_M)$ et $q = (q_1, \dots, q_M)$, définies par

$$\chi^2(p, q) = \sum_{i=1}^M q_i \left(\frac{p_i}{q_i} - 1 \right)^2 \quad \text{et} \quad K(p, q) = \sum_{i=1}^M p_i \log \frac{p_i}{q_i} ,$$

respectivement.

Distance du χ^2 et taille effective de l'échantillon Un premier critère pour mesurer l'écart entre les poids $(w_1, \dots, w_M)$ et la distribution uniforme, est la distance du χ^2

$$0 \leq \frac{1}{M} \sum_{i=1}^M (M w_i - 1)^2 = \frac{1}{M} \sum_{i=1}^M (M w_i)^2 - 1 = M \sum_{i=1}^M w_i^2 - 1 = \frac{M}{M_{\text{eff}}} - 1 ,$$

où M_{eff} est la taille *effective* de l'échantillon, définie par

$$1 \leq M_{\text{eff}} = 1 / \left[\sum_{i=1}^M w_i^2 \right] \leq M ,$$

et où l'égalité est atteinte à l'équidistribution, ce qui suggère de redistribuer si

$$\frac{M}{M_{\text{eff}}} - 1 \geq \chi_{\text{red}}^2 > 0 \quad \text{c'est-à-dire si} \quad M_{\text{eff}} \leq c_{\text{red}} M ,$$

où le seuil $c_{\text{red}} = 1/(1 + \chi_{\text{red}}^2) < 1$ reste à déterminer.

Distance de Kullback–Leibler et entropie de l'échantillon Un second critère pour mesurer l'écart entre les poids $(w_1, \dots, w_M)$ et la distribution uniforme, est la distance de Kullback–Leibler

$$0 \leq \sum_{i=1}^M w_i \log(M w_i) = \sum_{i=1}^M w_i \log w_i + \log M = -\text{Ent} + \log M ,$$

où Ent est l'entropie de l'échantillon, définie par

$$\text{Ent} = - \sum_{i=1}^M w_i \log w_i \leq \log M ,$$

et où l'égalité est atteinte à l'équidistribution, ce qui suggère de redistribuer si

$$-\text{Ent} + \log M \geq c_{\text{red}} ,$$

où le seuil $c_{\text{red}} > 0$ reste à déterminer.

Remarque 9.24 Les résultats obtenus au Théorème 9.17 pour l'estimateur (9.14) peuvent être ré-interprétés en terme de la taille effective de l'échantillon. En effet

$$\mathbb{E} | \langle \eta_M - \eta, \phi \rangle |^2 = \frac{1}{M_{\text{eff}}} \sum_{i=1}^M w_i^{\square} \text{var}(\phi, m_i) ,$$

et pour tout réel $p \geq 2$, il existe une constante positive $c_p > 0$ telle que

$$\{\mathbb{E}|\langle \eta_M - \eta, \phi \rangle|^p\}^{1/p} \leq \frac{c_p}{\sqrt{M_{\text{eff}}}} \left\{ \sum_{i=1}^M w_i^\square \langle m_i, |\phi - \langle m_i, \phi \rangle|^p \rangle \right\}^{1/p},$$

pour toute fonction mesurable bornée ϕ .

Remarque 9.25 On peut aussi introduire l'approximation particulière adaptative définie par

$$\eta_M = \begin{cases} \sum_{i=1}^M w_i \delta_{\xi_i} & \text{avec } \xi_i \sim m_i \text{ pour tout } i = 1 \cdots M \\ & \text{si } M_{\text{eff}} > c_{\text{red}} M, \\ \frac{1}{M} \sum_{i=1}^M \delta_{\xi_i} & \text{avec } \xi_i \sim \eta \text{ pour tout } i = 1 \cdots M \\ & \text{si } M_{\text{eff}} \leq c_{\text{red}} M, \end{cases}$$

avec l'expression suivante pour la variance de l'erreur d'estimation

$$\mathbb{E}|\langle \eta_M - \eta, \phi \rangle|^2 = \begin{cases} \frac{1}{M_{\text{eff}}} \sum_{i=1}^M w_i^\square \text{var}(\phi, m_i) & \text{si } M_{\text{eff}} > c_{\text{red}} M, \\ \frac{1}{M} \text{var}(\phi, \eta) & \text{si } M_{\text{eff}} \leq c_{\text{red}} M. \end{cases}$$

9.4 Échantillonnage selon une loi discrète

La question qui reste est donc de savoir simuler une variable aléatoire I à valeurs dans l'ensemble fini $\{1, \dots, M\}$, ou bien de savoir simuler un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$, et on commence par introduire un découpage de l'intervalle $[0, 1]$ en M segments adjacents de longueurs respectives $w_1, \dots, w_M$. Ces M segments sont délimités par les probabilités cumulées

$$s_0 = 0 \quad \text{et} \quad s_i = w_1 + \dots + w_i,$$

pour tout $i = 1, \dots, M$ et on vérifie que $s_M = 1$.

La méthode la plus directe est la méthode d'inversion, qui consiste à générer une variable aléatoire U uniforme sur $[0, 1]$: si U appartient au j -ème segment, i.e. si

$$s_{j-1} < U \leq s_j,$$

alors on pose $I = j$. Une recherche binaire en $O(\log_2 M)$ opérations permet d'obtenir ce résultat, et il suffit donc de $NO(\log_2 M)$ opérations pour générer un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$ et distribué selon les poids $(w_1, \dots, w_M)$.

Au lieu de répéter N fois l'opération de


- générer une variable aléatoire uniforme sur $[0, 1]$,
- puis effectuer une recherche binaire,

on peut penser à générer un N -échantillon $(U_1, \dots, U_N)$ de variables aléatoires uniformes sur $[0, 1]$, puis à ordonner cet échantillon, ce qui nécessite $O(N \log_2 N)$ opérations. On peut alors appliquer la méthode d'inversion à l'échantillon ré-ordonné $U_{(1)} \leq \dots \leq U_{(N)}$: si $U_{(i)}$ appartient au j -ème segment, i.e. si

$$s_{j-1} < U_{(i)} \leq s_j ,$$

alors on pose $I_i = j$. L'avantage de travailler avec un échantillon ordonné est que pour générer I_{i+1} il suffit de tester l'appartenance de $U_{(i+1)}$ aux segments situés au-delà du j -ème segment, et il suffit donc de $M + N$ comparaisons au plus pour affecter les N variables ré-ordonnées aux M différents segments, c'est-à-dire pour interclasser les deux suites ordonnées

$$0 \leq U_{(1)} \leq \dots \leq U_{(N)} \leq 1 \quad \text{et} \quad 0 = s_0 \leq s_1 \leq \dots \leq s_M = 1 .$$



Avec cette méthode, il suffit donc de $O(N \log_2 N) + O(M + N)$ opérations pour générer un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$ et distribué selon les poids $(w_1, \dots, w_M)$.

Une méthode plus efficace, qui évite l'étape préalable de ré-ordonner les variables aléatoires uniformes, consiste à générer directement une N -statistique d'ordre uniforme, c'est-à-dire un vecteur aléatoire $(V_1, \dots, V_N)$ distribué comme le vecteur aléatoire $(U_{(1)}, \dots, U_{(N)})$ obtenu en ré-ordonnant un N -échantillon $(U_1, \dots, U_N)$ de variables aléatoires uniformes sur $[0, 1]$. L'un ou l'autre des deux résultats suivants permet d'effectuer cette tâche en $O(N)$ opérations, et il suffit donc de $O(N) + O(M + N)$ opérations pour générer un N -échantillon à valeurs dans l'ensemble fini $\{1, \dots, M\}$ et distribué selon les poids $(w_1, \dots, w_M)$.

Proposition 9.26 Soit $(U_1, \dots, U_N)$ un N -échantillon de variables aléatoires uniformes sur $[0, 1]$. On définit

$$V_i = U_N^{1/N} \dots U_i^{1/i} \quad \text{pour tout } i = N, \dots, 1,$$

ou bien par récurrence : $V_N = U_N^{1/N}$ et

$$V_i = V_{i+1} U_i^{1/i} \quad \text{pour tout } i = N - 1, \dots, 1.$$

Le vecteur aléatoire $(V_1, \dots, V_N)$ est distribué comme le vecteur aléatoire $(U_{(1)}, \dots, U_{(N)})$ obtenu en ré-ordonnant $(U_1, \dots, U_N)$.

PREUVE. Clairement, $V_i \leq V_{i+1}$ pour tout $i = 1, \dots, N-1$, c'est-à-dire que la suite

$$V_1 \leq \dots \leq V_i \leq V_{i+1} \leq \dots \leq V_N ,$$

est croissante. On remarque que

$$\mathbb{E}[\phi(V_N)] = \mathbb{E}[\phi(U_N^{1/N})] = \int_0^1 \phi(x^{1/N}) dx = \int_0^1 \phi(v) N v^{N-1} dv ,$$

pour toute fonction mesurable bornée ϕ définie sur l'intervalle $[0, 1]$, de sorte que

$$\mathbb{P}[V_N \in dv] = 1_{(0 \leq v \leq 1)} N v^{N-1} dv .$$

Compte tenu que la variable aléatoire uniforme U_i est indépendante de $(V_{i+1}, \dots, V_N)$, on a

$$\begin{aligned} \mathbb{E}[\phi(V_i) \mid V_{i+1}, \dots, V_N] &= \mathbb{E}[\phi(V_{i+1} U_i^{1/i}) \mid V_{i+1}, \dots, V_N] \\ &= \int_0^1 \phi(V_{i+1} x^{1/i}) \mathbb{P}[U_i \in dx \mid V_{i+1}, \dots, V_N] \\ &= \int_0^1 \phi(V_{i+1} x^{1/i}) dx \\ &= \int_0^1 \phi(v) 1_{(0 \leq v \leq V_{i+1})} \frac{i v^{i-1}}{V_{i+1}^i} dv , \end{aligned}$$

pour toute fonction mesurable bornée ϕ définie sur l'intervalle $[0, 1]$, de sorte que

$$\mathbb{P}[V_i \in dv \mid V_{i+1}, \dots, V_N] = 1_{(0 \leq v \leq V_{i+1})} \frac{i v^{i-1}}{V_{i+1}^i} dv ,$$

pour tout $i = N-1, \dots, 1$. On en déduit que

$$\begin{aligned} \mathbb{P}[V_1 \in dv_1, \dots, V_N \in dv_N] &= \mathbb{P}[V_N \in dv_N] \prod_{i=1}^{N-1} \mathbb{P}[V_i \in dv_i \mid V_{i+1} = v_{i+1}, \dots, V_N = v_N] \\ &= 1_{(0 \leq v_N \leq 1)} N v_N^{N-1} dv_N \prod_{i=1}^{N-1} 1_{(0 \leq v_i \leq v_{i+1})} \frac{i v_i^{i-1}}{v_{i+1}^i} dv_i \\ &= N! 1_{(0 \leq v_1 \leq \dots \leq v_N \leq 1)} dv_1 \dots dv_N . \quad \square \end{aligned}$$

Proposition 9.27 Soit $(E_1, \dots, E_{N+1})$ un $(N+1)$ -échantillon de variables aléatoires exponentielles de paramètre 1 sur $[0, \infty)$. On définit $S_{N+1} = E_1 + \dots + E_{N+1}$ et

$$S_i = E_1 + \dots + E_i \quad \text{et} \quad V_i = \frac{S_i}{S_{N+1}} \quad \text{pour tout } i = 1, \dots, N,$$

ou bien par récurrence : $V_1 = \frac{E_1}{S_{N+1}}$ et

$$V_i = V_{i-1} + \frac{E_i}{S_{N+1}} \quad \text{pour tout } i = 2, \dots, N.$$

Le vecteur aléatoire $(V_1, \dots, V_N)$ est distribué comme le vecteur aléatoire $(U_{(1)}, \dots, U_{(N)})$ obtenu en ré-ordonnant un N -échantillon $(U_1, \dots, U_N)$ de variables aléatoires uniformes sur $[0, 1]$.

PREUVE. Clairement, $V_i \geq V_{i-1}$ pour tout $i = 2, \dots, N$, c'est-à-dire que la suite

$$V_1 \leq \dots \leq V_i \leq V_{i+1} \leq \dots \leq V_N,$$

est croissante. On remarque que $S_1 = E_1$, de sorte que

$$\mathbb{P}[S_1 \in ds] = 1_{(s \geq 0)} e^{-s} ds.$$

Compte tenu que $(S_1, \dots, S_i)$ contient exactement la même information que $(E_1, \dots, E_i)$, et que la variable aléatoire E_{i+1} est indépendante de $(E_1, \dots, E_i)$, on a

$$\begin{aligned} \mathbb{E}[\phi(S_{i+1}) \mid S_1, \dots, S_i] &= \mathbb{E}[\phi(S_i + E_{i+1}) \mid E_1, \dots, E_i] \\ &= \int_0^\infty \phi(S_i + x) \mathbb{P}[E_{i+1} \in dx \mid E_1, \dots, E_i] \\ &= \int_0^\infty \phi(S_i + x) e^{-x} dx \\ &= \int_0^\infty \phi(s) 1_{(s \geq S_i)} e^{-(s-S_i)} ds, \end{aligned}$$

pour toute fonction ϕ mesurable bornée définie sur l'intervalle $[0, \infty)$, de sorte que

$$\mathbb{P}[S_{i+1} \in ds \mid S_1, \dots, S_i] = 1_{(s \geq S_i)} e^{-(s-S_i)} ds,$$

pour tout $i = 1, \dots, N$. On en déduit que

$$\begin{aligned} \mathbb{P}[S_1 \in ds_1, \dots, S_{N+1} \in ds_{N+1}] &= \mathbb{P}[S_1 \in ds_1] \prod_{i=1}^N \mathbb{P}[S_{i+1} \in ds_i \mid S_1 = s_1, \dots, S_i = s_i] \\ &= 1_{(s \geq 0)} e^{-s_1} ds_1 \prod_{i=1}^N 1_{(s_{i+1} \geq s_i)} e^{-(s_{i+1}-s_i)} ds_i \\ &= 1_{(0 \leq s_1 \leq \dots \leq s_{N+1})} e^{-s_{N+1}} ds_1 \dots ds_{N+1}, \end{aligned}$$

et

$$\begin{aligned}
\mathbb{E}[f(V_1, \dots, V_N)] &= \mathbb{E}\left[f\left(\frac{S_1}{S_{N+1}}, \dots, \frac{S_N}{S_{N+1}}\right)\right] \\
&= \int_0^\infty \dots \int_0^\infty f\left(\frac{s_1}{s_{N+1}}, \dots, \frac{s_N}{s_{N+1}}\right) \mathbb{P}[S_1 \in ds_1, \dots, S_{N+1} \in ds_{N+1}] \\
&= \int_0^\infty \dots \int_0^\infty f\left(\frac{s_1}{s_{N+1}}, \dots, \frac{s_N}{s_{N+1}}\right) 1_{(0 \leq s_1 \leq \dots \leq s_N \leq s_{N+1})} e^{-s_{N+1}} ds_1 \dots ds_N ds_{N+1} \\
&= \int_0^\infty \dots \int_0^\infty f(v_1, \dots, v_N) 1_{(0 \leq v_1 \leq \dots \leq v_N \leq 1)} s_{N+1}^N e^{-s_{N+1}} dv_1 \dots dv_N ds_{N+1} \\
&= \int_0^\infty \dots \int_0^\infty f(v_1, \dots, v_N) 1_{(0 \leq v_1 \leq \dots \leq v_N \leq 1)} dv_1 \dots dv_N \int_0^\infty s_{N+1}^N e^{-s_{N+1}} ds_{N+1} \\
&= \int_0^\infty \dots \int_0^\infty f(v_1, \dots, v_N) N! 1_{(0 \leq v_1 \leq \dots \leq v_N \leq 1)} dv_1 \dots dv_N,
\end{aligned}$$

pour toute fonction f mesurable bornée définie sur l'ensemble produit $[0, \infty)^N$, compte tenu que

$$\int_0^\infty s^N e^{-s} ds = N!.$$

On en déduit que

$$\mathbb{P}[V_1 \in dv_1, \dots, V_N \in dv_N] = N! 1_{(0 \leq v_1 \leq \dots \leq v_N)} dv_1 \dots dv_N. \quad \square$$

Chapitre 10

Approximations particulières

On se place dans le cadre général décrit au Chapitre 8, où différents modèles ont été considérés, avec différents points de vue. Il ressort de la discussion que le modèle (8.22), où chaque fonction de sélection dépend de la transition courante de la chaîne de Markov, semble suffisamment général pour inclure comme cas particuliers la plupart des modèles présentés jusqu'ici, mais il ressort aussi de la discussion que le modèle (8.1) apparemment plus simple, où chaque fonction de sélection dépend seulement de l'état courant (c'est-à-dire de l'état d'arrivée de la transition courante) de la chaîne de Markov, contient en fait le modèle (8.22) comme cas particulier, pourvu qu'on change de point de vue et qu'on adopte le modèle (8.27) à valeurs transitions. Cette remarque sera abondamment exploitée dans ce chapitre et dans les chapitres suivants, et on considérera indifféremment ces deux modèles et les différents points de vue associés.

Il s'agit ici d'approcher numériquement, par des méthodes de Monte Carlo, la distribution non-normalisée et la distribution normalisée associée, définis

- soit par une représentation probabiliste comme (8.1), (8.22) ou (8.27),
- soit par une relation de récurrence comme (8.2), (8.24) ou (8.28),

respectivement, selon le modèle utilisé. Le premier point de vue conduit aux algorithmes d'échantillonnage pondéré (SIS, pour *sequential importance sampling*) qui sont des algorithmes de Monte Carlo classiques (sans interaction), assez inefficaces, et le second point de vue conduit aux algorithmes d'échantillonnage / ré-échantillonnage (SIR, pour *sampling with importance resampling*) qui sont des algorithmes de Monte Carlo avec interaction, beaucoup plus efficaces.

10.1 Échantillonnage pondéré (SIS)

Il n'y a aucune difficulté particulière à considérer directement le modèle (8.22) apparemment plus général, où chaque fonction de sélection dépend de la transition courante de la chaîne de Markov, et à considérer ensuite comme un cas particulier le modèle (8.1) apparemment plus simple, où chaque fonction de sélection dépend seulement de l'état courant (c'est-à-dire de l'état d'arrivée de la transition courante) de la chaîne de Markov.

Si on introduit la variable aléatoire $X_{0:n} = (X_0, X_1, \dots, X_n)$ à valeurs trajectorielles, dont la distribution de probabilité est

$$\eta_{0:n}(dx_{0:n}) = \mathbb{P}[X_{0:n} \in dx_{0:n}] = \eta_0(dx_0) Q_1(x_0, dx_1) \cdots Q_n(x_{n-1}, dx_n) ,$$

et la fonction de poids

$$g_{0:n}(x_{0:n}) = \prod_{k=0}^n g_k(x_{k-1}, x_k) ,$$

et si on définit

$$\langle \eta_{0:n}, g_{0:n} f \rangle = \mathbb{E}[f(X_{0:n}) g_{0:n}(X_{0:n})] = \int_E \cdots \int_E f(x_{0:n}) g_{0:n}(x_{0:n}) \eta_{0:n}(dx_{0:n}) ,$$

pour toute fonction mesurable bornée f définie sur l'espace produit $E \times \cdots \times E = E^{n+1}$, alors on a

$$\langle \gamma_n, \phi \rangle = \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_k)] = \mathbb{E}[\phi \circ \pi(X_{0:n}) g_{0:n}(X_{0:n})] = \langle \eta_{0:n}, g_{0:n} \phi \circ \pi \rangle ,$$

où $\pi : (x_0, x_1, \dots, x_n) \in E \times \cdots \times E \mapsto x_n \in E$ désigne la projection sur la dernière composante de l'espace produit $E^{n+1} = E \times \cdots \times E$, c'est-à-dire que l'application π pointe sur l'état final de la trajectoire, de sorte que

$$\langle \mu_n, \phi \rangle = \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} = \frac{\langle \eta_{0:n}, g_{0:n} \phi \circ \pi \rangle}{\langle \eta_{0:n}, g_{0:n} \rangle} ,$$

et la distribution normalisée μ_n s'exprime en terme de la distribution de Gibbs-Boltzmann trajectorielle

$$\mu_{0:n} = g_{0:n} \cdot \eta_{0:n} = \frac{g_{0:n} \eta_{0:n}}{\langle \eta_{0:n}, g_{0:n} \rangle} ,$$

comme $\mu_n = \mu_{0:n} \circ \pi^{-1}$. On se retrouve donc dans le cas statique considéré au Chapitre 9, et on peut appliquer la méthode d'échantillonnage pondéré décrite à la Section 9.2, d'où l'approximation

$$\mu_{0:n} \approx \mu_{0:n}^N = g_{0:n} \cdot S^N(\eta_{0:n}) = \sum_{i=1}^N w_n^i \delta_{\xi_{0:n}^i} ,$$

où les variables aléatoires $(\xi_{0:n}^1, \dots, \xi_{0:n}^N)$ à valeurs trajectorielles sont i.i.d. de distribution de probabilité commune $\eta_{0:n}$, c'est-à-dire que indépendamment pour tout $i = 1, \dots, N$, la trajectoire $\xi_{0:n}^i$ s'exprime comme $\xi_{0:n}^i = (\xi_0^i, \xi_1^i, \dots, \xi_n^i)$ où

- la variable aléatoire ξ_0^i est distribuée selon η_0 ,
- pour tout $k = 1, \dots, n$, la variable aléatoire ξ_k^i est distribuée selon $m_k^i = Q_k(\xi_{k-1}^i, \cdot)$,

et où les poids positifs $(w_n^1, \dots, w_n^N)$ sont définis par

$$w_n^i = \frac{g_{0:n}(\xi_{0:n}^i)}{\sum_{j=1}^N g_{0:n}(\xi_{0:n}^j)} \quad \text{pour tout } i = 1, \dots, N.$$

Compte tenu de la relation $\mu_n = \mu_{0:n} \circ \pi^{-1}$, on a également l'approximation

$$\mu_n \approx \mu_n^N = \mu_{0:n}^N \circ \pi^{-1} = \sum_{i=1}^N w_n^i \delta_{\xi_n^i} .$$

La simulation des trajectoires et le calcul des poids peuvent être décrits de la façon récursive suivante

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est simulée selon la distribution de probabilité η_0 , et on pose

$$w_0^i = \frac{g_0(\xi_0^i)}{\sum_{j=1}^N g_0(\xi_0^j)} ,$$

- pour tout $k = 1, \dots, n$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_k^i est simulée selon la distribution de probabilité $Q_k(\xi_{k-1}^i, dx')$, et on pose

$$w_k^i = \frac{w_{k-1}^i g_k(\xi_{k-1}^i, \xi_k^i)}{\sum_{j=1}^N w_{k-1}^j g_k(\xi_{k-1}^j, \xi_k^j)} .$$

Les performances de cet algorithme, en termes de variance asymptotique de l'erreur d'approximation, quand le nombre N de particules tend vers l'infini, sont présentées au Théorème 12.1.

Exemple 10.1 Dans le cas particulier du système non-linéaire à bruits non-gaussiens décrit par (5.1) et (5.2), simuler une variable aléatoire X selon la distribution de probabilité $Q_k(x, dx')$ signifie simplement simuler une variable aléatoire W selon la distribution de probabilité $p_k^W(dw)$, et poser $X = f_k(x, W)$, et évaluer la fonction de vraisemblance $g_k(x')$ signifie simplement évaluer $q_k^V(Y_k - h_k(x'))$, d'où l'algorithme suivant

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est simulée selon la distribution de probabilité η_0 , et on pose

$$w_0^i = \frac{q_0^V(Y_0 - h_0(\xi_0^i))}{\sum_{j=1}^N q_0^V(Y_0 - h_0(\xi_0^j))} .$$

- pour tout $k = 1, \dots, n$, indépendamment pour tout $i = 1, \dots, N$
 - la variable aléatoire W_k^i est simulée selon la distribution de probabilité $p_k^W(dw)$,
 - on pose $\xi_k^i = f_k(\xi_{k-1}^i, W_k^i)$,

Algorithm 10.1.1 Algorithme SIS (modèle général)

required distribution de probabilité initiale $\eta_0(dx)$
required probabilités de transition $Q_k(x, dx')$ pour $k = 1 \cdots n$
required fonction de sélection $g_k(x, x')$ pour $k = 0, 1 \cdots n$
 $k = 0$ [initialisation]

[simulation]

for $i = 1 \cdots N$ (indépendemment) **do**
 $\xi_0^i \sim \eta_0(dx)$
end for

[calcul des poids normalisés]

for $i = 1 \cdots N$ **do**
 $w_0^i \propto g_0(\xi_0^i)$
end for
loop
 $k \leftarrow k + 1$ [itération]

[propagation]

for $i = 1 \cdots N$ (indépendemment) **do**
 $\xi_k^i \sim Q_k(\xi_{k-1}^i, dx')$
end for

[mise-à-jour des poids normalisés]

for $i = 1 \cdots N$ **do**
 $w_k^i \propto w_{k-1}^i g_k(\xi_{k-1}^i, \xi_k^i)$
end for
end loop

et on pose

$$w_k^i = \frac{w_{k-1}^i q_k^V(Y_k - h_k(\xi_k^i))}{\sum_{j=1}^N w_{k-1}^j q_k^V(Y_k - h_k(\xi_k^j))} .$$

On remarque que les poids dépendent des trajectoires simulées, et sont en effet d'autant plus élevés pour les trajectoires en adéquation avec les observations, mais en revanche ces poids ne sont pas utilisés pour simuler les trajectoires : en poussant les choses à l'extrême, on peut donc dire que les trajectoires sont simulées en aveugle, et l'algorithme se contente de pondérer différemment les différentes trajectoires.

Comme ces différentes trajectoires sont en nombre fini, il est de moins en moins raisonnable, au fur et à mesure que le temps passe, d'espérer qu'un nombre suffisant d'entre ces trajectoires puisse être assez proche de la vraie trajectoire. Comme les poids s'accumulent au cours du temps le long de chaque trajectoire, la situation typique est de voir une seule trajectoire recueillir un poids beaucoup plus fort que toutes les autres, et ceci juste parce qu'au cours de son histoire passée elle s'est trouvée plus souvent proche de la vraie trajectoire, quand bien même elle s'en trouverait très éloignée à l'instant présent.

Ces phénomènes de dégénérescence des poids et d'importance excessive du passé sont bien connus, et diverses solutions ont été proposées pour y remédier

- simuler les trajectoires selon un mécanisme qui prenne mieux en compte les observations, au lieu de simuler les trajectoires en aveugle,
- multiplier les trajectoires de poids le plus fort, et éliminer les trajectoires de poids le plus faible, en introduisant une étape de ré-échantillonnage,

et il est également possible de combiner ces solutions, ce qui fait l'objet des algorithmes présentés ci-dessous.

10.2 Échantillonnage / ré-échantillonnage (SIR)

Il est plus facile ici de considérer d'abord le modèle (8.1) apparemment plus simple, où chaque fonction de sélection dépend seulement de l'état courant (c'est-à-dire de l'état d'arrivée de la transition courante) de la chaîne de Markov, et de considérer ensuite comme un cas particulier le modèle (8.22) apparemment plus général, où chaque fonction de sélection dépend de la transition courante de la chaîne de Markov, ce qui est possible pourvu qu'on change de point de vue et qu'on adopte le modèle (8.27) à valeurs transitions.

Au lieu de simuler d'abord N trajectoires indépendantes de la chaîne de Markov et d'évaluer séparément les poids associés à chaque trajectoire simulée, le principe consiste à rechercher une approximation

$$\eta_k \approx \eta_k^N = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_k^i} \quad \text{et} \quad \mu_k \approx \mu_k^N = \sum_{i=1}^N w_k^i \delta_{\xi_k^i} \quad \text{avec} \quad \sum_{i=1}^N w_k^i = 1 , \quad (10.1)$$

des distributions normalisées, sous la forme de distributions de probabilité empiriques pondérées associées à un système de particules caractérisé par les positions $(\xi_k^i, i = 1, \dots, N)$ et par les poids positifs $(w_k^i, i = 1, \dots, N)$. En toute généralité, le nombre de particules pourrait être aléatoire ou varier d'une génération à l'autre, mais on se limite ici au cas simple où le nombre N de particules est constant à chaque génération. Les poids et les positions des particules sont choisis de telle sorte que l'évolution de la suite approchée reproduise aussi fidèlement que possible l'évolution de la distribution normalisée décrite par le diagramme suivant

$$\mu_{k-1} \xrightarrow{\text{mutation}} \eta_k = \mu_{k-1} Q_k \xrightarrow{\text{pondération}} \mu_k = g_k \cdot \eta_k, \quad (10.2)$$

avec la condition initiale $\mu_0 = g_0 \cdot \eta_0$, où la notation $\cdot$ désigne le produit projectif.

On introduit d'abord l'approximation

$$\eta_0^N = S^N(\eta_0) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_0^i},$$

où indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est distribuée selon η_0 .

Pour tout $k = 0, 1, \dots, n$, il est immédiat à partir de la définition (10.1) que

$$\mu_k^N = g_k \cdot \eta_k^N = \sum_{i=1}^N \frac{g_k(\xi_k^i)}{\sum_{j=1}^N g_k(\xi_k^j)} \delta_{\xi_k^i} = \sum_{i=1}^N w_k^i \delta_{\xi_k^i},$$

possède automatiquement la forme recherchée, avec les poids définis par

$$w_k^i = \frac{g_k(\xi_k^i)}{\sum_{j=1}^N g_k(\xi_k^j)} \quad \text{pour tout } i = 1, \dots, N, \quad (10.3)$$

et

$$\langle \eta_k^N, g_k \rangle = \frac{1}{N} \sum_{i=1}^N g_k(\xi_k^i),$$

fournit l'approximation correspondante pour la constante de normalisation $\langle \eta_k, g_k \rangle$.

Pour tout $k = 1, \dots, n$, il est immédiat à partir de la définition (10.1) que

$$\mu_{k-1}^N Q_k = \sum_{i=1}^N w_{k-1}^i m_k^i \quad \text{où} \quad m_k^i(dx') = Q_k(\xi_{k-1}^i, dx'),$$

pour tout $i = 1, \dots, N$, et il s'agit donc d'approcher une distribution de probabilité définie comme un mélange fini, selon l'une ou l'autre des approches proposées à la Section 9.3. La définition précise de l'approximation η_k^N dépend de l'implémentation choisie.

► **Ré-échantillonnage multinomial** Dans cette implémentation, à chaque génération $k = 1, \dots, n$, on simule un N -échantillon distribué selon le mélange fini $\mu_{k-1}^N Q_k$, d'où l'approximation

$$\mu_{k-1}^N Q_k = \sum_{i=1}^N w_{k-1}^i m_k^i \approx \eta_k^N = S^N(\mu_{k-1}^N Q_k) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_k^i},$$

sous la forme désirée, et où indépendamment pour tout $i = 1, \dots, N$ la variable aléatoire ξ_k^i est distribuée selon le mélange fini $\mu_{k-1}^N Q_k$. On en déduit l'expression suivante pour l'erreur d'approximation

$$\langle \eta_k^N - \mu_{k-1}^N Q_k, \phi \rangle = \frac{1}{N} \sum_{i=1}^N [\phi(\xi_k^i) - \langle \mu_{k-1}^N Q_k, \phi \rangle],$$

et il résulte du Théorème 9.14 et de la Remarque 9.15 que

$$\mathbb{E}[|\langle \eta_k^N - \mu_{k-1}^N Q_k, \phi \rangle|^2 \mid \mathcal{F}_{k-1}^N] = \frac{1}{N} \text{var}(\phi, \mu_{k-1}^N Q_k),$$

et pour tout réel $p \geq 2$

$$\{\mathbb{E}[|\langle \eta_k^N - \mu_{k-1}^N Q_k, \phi \rangle|^p \mid \mathcal{F}_{k-1}^N]\}^{1/p} \leq \frac{c_p}{\sqrt{N}} \text{osc}(\phi), \quad (10.4)$$

pour toute fonction mesurable bornée ϕ , où $\mathcal{F}_{k-1}^N$ désigne la tribu engendrée par le système de particules jusqu'à la $(k-1)$ -ème génération.

► **Stratification et ré-échantillonnage résiduel multinomial** Dans cette implémentation, à chaque génération $k = 1, \dots, n$, chaque composante $i = 1, \dots, N$ du mélange fini $\mu_{k-1}^N Q_k$ reçoit dans une première allocation un nombre de représentants égal au nombre de fois que le poids $1/N$ est contenu dans le poids w_{k-1}^i de la composante (le poids $1/N$ est celui qui sera affecté à chaque particule dans l'approximation η_k^N). Il reste ensuite à compléter la population de particules de manière à assurer un effectif de taille N , en simulant un échantillon selon la distribution résiduelle des poids non encore affectés. Concrètement, pour toute composante $i = 1, \dots, N$ le nombre de représentants affectés à l'issue de la première passe est $N_k^i = \lfloor N w_{k-1}^i \rfloor$, c'est-à-dire que

$$N w_k^i = N_k^i + q_k^i \quad \text{avec} \quad 0 \leq q_k^i < 1.$$

Compte tenu des identités

$$N = \sum_{i=1}^N N w_{k-1}^i = \sum_{i=1}^N (N_k^i + q_k^i) = \sum_{i=1}^N N_k^i + N_k^0 \quad \text{avec} \quad N_k^0 = \sum_{i=1}^N q_k^i,$$

et

$$\mu_{k-1}^N Q_k = \sum_{i=1}^N w_{k-1}^i m_k^i = \sum_{i=1}^N \frac{N_k^i}{N} m_k^i + \sum_{i=1}^N \frac{q_k^i}{N} m_k^i = \sum_{i=1}^N \frac{N_k^i}{N} m_k^i + \frac{N_k^0}{N} m_k^0,$$

avec

$$m_k^0 = \sum_{i=1}^N \frac{q_k^i}{N_k^0} m_k^i,$$

on déduit que $(N - N_k^0)$ descendants ont déjà été affectés à l'issue de cette première passe, et il reste donc N_k^0 descendants à affecter de manière à approcher la distribution de probabilité résiduelle convenablement renormalisée m_k^0 . L'approche proposée consiste

- à simuler un N_k^0 -échantillon $(\xi_k^{0,1}, \dots, \xi_k^{0,N_k^0})$ distribué selon le mélange fini m_k^0 ,
- à simuler indépendamment pour tout $i = 1, \dots, N$ un N_k^i -échantillon $(\xi_k^{i,1}, \dots, \xi_k^{i,N_k^i})$ distribué selon m_k^i ,

toutes les variables aléatoires étant simulées de manière indépendantes, d'où l'approximation

$$\mu_{k-1}^N Q_k = \sum_{i=1}^N w_{k-1}^i m_k^i \approx \eta_k^N = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^{N_k^i} \delta_{\xi_k^{i,j}} + \frac{1}{N} \sum_{j=1}^{N_k^0} \delta_{\xi_k^{0,j}} = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_k^i}, \quad (10.5)$$

sous la forme désirée, c'est-à-dire que

$$\langle \eta_k^N, \phi \rangle = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^{N_k^i} \phi(\xi_k^{i,j}) + \frac{1}{N} \sum_{j=1}^{N_k^0} \phi(\xi_k^{0,j}),$$

et par différence

$$\langle \eta_k^N - \mu_{k-1}^N Q_k, \phi \rangle = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^{N_k^i} [\phi(\xi_k^{i,j}) - \langle m_k^i, \phi \rangle] + \frac{1}{N} \sum_{j=1}^{N_k^0} [\phi(\xi_k^{0,j}) - \langle m_k^0, \phi \rangle],$$

pour toute fonction mesurable bornée ϕ . Il résulte du Théorème 9.20 et de la Remarque 9.21 que

$$\mathbb{E}[|\langle \eta_k^N - \mu_{k-1}^N Q_k, \phi \rangle|^2 \mid \mathcal{F}_{k-1}^N] = \frac{1}{N} \left[\sum_{i=1}^N \frac{N_k^i}{N} \text{var}(\phi, m_k^i) + \frac{N_k^0}{N} \text{var}(\phi, m_k^0) \right],$$

et pour tout réel $p \geq 2$

$$\{ \mathbb{E}[|\langle \eta_k^N - \mu_{k-1}^N Q_k, \phi \rangle|^p \mid \mathcal{F}_{k-1}^N] \}^{1/p} \leq \frac{c_p}{\sqrt{N}} \text{osc}(\phi), \quad (10.6)$$

pour toute fonction mesurable bornée ϕ , où $\mathcal{F}_{k-1}^N$ désigne la tribu engendrée par le système de particules jusqu'à la $(k-1)$ -ème génération.

Résumé Dans toute cette classe d'algorithmes d'approximation particulière, et quelle que soit l'implémentation retenue pour mettre en œuvre l'étape de sélection, l'évolution de la population de particules et la mise-à-jour des poids sont ici couplées et peuvent être décrites de la façon récursive suivante

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est simulée selon la distribution de probabilité η_0 , et on pose

$$w_0^i = \frac{g_0(\xi_0^i)}{\sum_{j=1}^N g_0(\xi_0^j)}.$$

- pour tout $k = 1, \dots, n$, indépendamment pour tout $i = 1, \dots, N$
 - un individu $\hat{\xi}_{k-1}^i$ est sélectionné au sein de la population de particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids $(w_{k-1}^1, \dots, w_{k-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,
 - la variable aléatoire ξ_k^i est simulée selon la distribution de probabilité $Q_k(\hat{\xi}_{k-1}^i, dx')$,

et on pose

$$w_k^i = \frac{g_k(\xi_k^i)}{\sum_{j=1}^N g_k(\xi_k^j)} .$$

Les performances de ces algorithmes, en termes de variance asymptotique de l'erreur d'approximation, quand le nombre N de particules tend vers l'infini, sont présentées au Théorème 12.2.

En résumé, les particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$

- sont sélectionnées selon leurs poids respectifs $(w_{k-1}^1, \dots, w_{k-1}^N)$ (étape de sélection),
- évoluent selon le noyau de Markov Q_k (étape de mutation),
- et sont pondérées en évaluant la fonction de *fitness* g_k (étape de pondération).

Au lieu de s'accumuler le long de chaque trajectoire comme dans le cas de l'algorithme SIS, les poids sont ici utilisés pour redistribuer les particules, c'est-à-dire multiplier les particules de plus fort poids et éliminer les particules de plus faible poids. Le gain escompté en ne conservant à chaque pas de temps que les particules les plus pertinentes, est de concentrer ainsi les particules, c'est-à-dire la puissance de calcul disponible, dans les régions d'intérêt de l'ensemble E .

Exemple 10.2 Dans le cas particulier du système non-linéaire à bruits non-gaussiens décrit par (5.1) et (5.2), simuler une variable aléatoire X selon la distribution de probabilité $Q_k(x, dx')$ signifie simplement simuler une variable aléatoire W selon la distribution de probabilité $p_k^W(dw)$, et poser $X = f_k(x, W)$, et évaluer la fonction de vraisemblance $g_k(x')$ signifie simplement évaluer $q_k^V(Y_k - h_k(x'))$, d'où l'algorithme suivant

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est simulée selon la distribution de probabilité η_0 , et on pose

$$w_0^i = \frac{q_0^V(Y_0 - h_0(\xi_0^i))}{\sum_{j=1}^N q_0^V(Y_0 - h_0(\xi_0^j))} .$$

- pour tout $k = 1, \dots, n$, indépendamment pour tout $i = 1, \dots, N$
 - un individu $\hat{\xi}_{k-1}^i$ est sélectionné au sein de la population de particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids $(w_{k-1}^1, \dots, w_{k-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,

Algorithm 10.2.1 Algorithme SIR (modèle de base (8.1))

required distribution de probabilité initiale $\eta_0(dx)$
required probabilités de transition $Q_k(x, dx')$ pour $k = 1 \dots n$
required fonction de sélection $g_k(x')$ pour $k = 0, 1 \dots n$
 $k = 0$ [initialisation]
[simulation]
for $i = 1 \dots N$ (indépendemment) **do**
 $\xi_0^i \sim \eta_0(dx)$
end for
[calcul des poids normalisés]
for $i = 1 \dots N$ **do**
 $w_0^i \propto g_0(\xi_0^i)$
end for
loop
 $k \leftarrow k + 1$ [itération]
[sélection]
for $i = 1 \dots N$ (indépendemment) **do**
choisir $\hat{\xi}_{k-1}^i$ au sein de la population $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids respectifs
 $(w_{k-1}^1, \dots, w_{k-1}^N)$
end for
[propagation]
for $i = 1 \dots N$ (indépendemment) **do**
 $\xi_k^i \sim Q_k(\hat{\xi}_{k-1}^i, dx')$
end for
[calcul des poids normalisés]
for $i = 1 \dots N$ **do**
 $w_k^i \propto g_k(\xi_k^i)$
end for
end loop

- la variable aléatoire W_k^i est simulée selon la distribution de probabilité $p_k^W(dw)$,
- on pose $\xi_k^i = f_k(\hat{\xi}_{k-1}^i, W_k^i)$,

et on pose

$$w_k^i = \frac{q_k^V(Y_k - h_k(\xi_k^i))}{\sum_{j=1}^N q_k^V(Y_k - h_k(\xi_k^j))} .$$

Dans le cas plus général du modèle (8.8) et pour une décomposition d'importance (8.11) donnée, avec la représentation probabiliste (8.12) associée, ou bien pour le modèle (8.22) où la décomposition d'importance est donnée de manière explicite dans la représentation probabiliste, chaque fonction de sélection dépend de la transition courante de la chaîne de Markov, mais il suffit de changer de point de vue et d'adopter le modèle (8.27) à valeurs transitions, où chaque fonction de sélection dépend seulement de l'état courant, puis de ré-exprimer dans ce cadre les algorithmes proposés ci-dessus pour le modèle (8.1) apparemment plus simple.

Le principe consiste donc à rechercher une approximation

$$\eta_k^{\text{tr}} \approx \eta_k^{N,\text{tr}} = \frac{1}{N} \sum_{i=1}^N \delta_{(\xi_k^{i,1}, \xi_k^{i,2})} \quad \text{et} \quad \mu_k^{\text{tr}} \approx \mu_k^{N,\text{tr}} = \sum_{i=1}^N w_k^i \delta_{(\xi_k^{i,1}, \xi_k^{i,2})} , \quad (10.7)$$

des distributions normalisées, sous la forme de distributions de probabilité empiriques pondérées associées à un système de particules à valeurs transitions caractérisé par les positions-transitions $((\xi_k^{i,1}, \xi_k^{i,2}), i = 1, \dots, N)$ et par les poids positifs normalisés $(w_k^i, i = 1, \dots, N)$. Les poids et les positions des particules sont choisis de telle sorte que l'évolution de la suite approchée reproduise aussi fidèlement que possible l'évolution de la distribution normalisée décrite par le diagramme suivant

$$\mu_{k-1}^{\text{tr}} \xrightarrow{\text{mutation}} \eta_k^{\text{tr}} = \mu_{k-1}^{\text{tr}} Q_k^{\text{tr}} \xrightarrow{\text{pondération}} \mu_k^{\text{tr}} = g_k \cdot \eta_k^{\text{tr}} , \quad (10.8)$$

avec la condition initiale $\mu_0^{\text{tr}} = g_0 \cdot \eta_0$, où la notation $\cdot$ désigne le produit projectif. Ici, les noyaux markoviens $Q_k^{\text{tr}}(x, dx')$ sont définis en (8.26).

On introduit d'abord l'approximation

$$\eta_0^N = S^N(\eta_0) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_0^i} ,$$

où indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est distribuée selon η_0 .

Pour tout $k = 0, 1, \dots, n$, il est immédiat à partir de la définition (10.1) que

$$\mu_k^{N,\text{tr}} = g_k \cdot \eta_k^{N,\text{tr}} = \sum_{i=1}^N \frac{g_k(\xi_k^{i,1}, \xi_k^{i,2})}{\sum_{j=1}^N g_k(\xi_k^{j,1}, \xi_k^{j,2})} \delta_{(\xi_k^{i,1}, \xi_k^{i,2})} = \sum_{i=1}^N w_k^i \delta_{(\xi_k^{i,1}, \xi_k^{i,2})} ,$$

possède automatiquement la forme recherchée, avec les poids définis par

$$w_k^i = \frac{g_k(\xi_k^{i,1}, \xi_k^{i,2})}{\sum_{j=1}^N g_k(\xi_k^{j,1}, \xi_k^{j,2})} \quad \text{pour tout } i = 1, \dots, N, \quad (10.9)$$

et

$$\langle \eta_k^{N,\text{tr}}, g_k \rangle = \frac{1}{N} \sum_{i=1}^N g_k(\xi_k^{i,1}, \xi_k^{i,2}),$$

fournit l'approximation correspondante pour la constante de normalisation $\langle \eta_k^{\text{tr}}, g_k \rangle$.

Pour tout $k = 1, \dots, n$, il est immédiat à partir de la définition (10.1) également que

$$\mu_{k-1}^{N,\text{tr}} Q_k^{\text{tr}} = \sum_{i=1}^N w_{k-1}^i m_k^i \quad \text{où} \quad m_k^i(dx'_1, dx'_2) = \delta_{\xi_{k-1}^{i,2}}(dx'_1) Q_k(x'_1, dx'_2),$$

pour tout $i = 1, \dots, N$, et il s'agit donc d'approcher une distribution de probabilité définie comme un mélange fini, selon l'une ou l'autre des approches proposées à la Section 9.3. La définition précise de l'approximation $\eta_k^{N,\text{tr}}$ dépend de l'implémentation choisie.

Quelle que soit l'implémentation choisie, pour simuler une variable aléatoire à valeur transition (X'_1, X'_2) selon m_k^i , il suffit de poser $X'_1 = \xi_{k-1}^{i,2}$ et de simuler X'_2 selon $Q_k(\xi_{k-1}^{i,2}, dx')$, c'est-à-dire que l'état de départ de la nouvelle transition coïncide avec l'état d'arrivée de la transition précédente et l'état d'arrivée de la nouvelle transition est distribué à partir de l'état de départ selon le noyau de transition du modèle (8.22). En revanche, l'état de départ de la transition précédente n'est pas utilisé.

L'évolution de la population de particules-transitions et la mise-à-jour des poids peuvent être décrites de la façon récursive suivante

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire $\xi_0^{i,2}$ est simulée selon la distribution de probabilité η_0 , et on pose

$$w_0^i = \frac{g_0(\xi_0^{i,2})}{\sum_{j=1}^N g_0(\xi_0^{j,2})}.$$

- pour tout $k = 1, \dots, n$, indépendamment pour tout $i = 1, \dots, N$
 - un individu $(\hat{\xi}_{k-1}^{i,1}, \hat{\xi}_{k-1}^{i,2})$ est sélectionné au sein de la population de particules-transitions $((\xi_{k-1}^{1,1}, \xi_{k-1}^{1,2}), \dots, (\xi_{k-1}^{N,1}, \xi_{k-1}^{N,2}))$ en fonction des poids $(w_{k-1}^1, \dots, w_{k-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,
 - la variable aléatoire à valeur transition $(\xi_k^{i,1}, \xi_k^{i,2})$ est simulée selon la distribution de probabilité $Q_k^{\text{tr}}(\hat{\xi}_{k-1}^{i,1}, \hat{\xi}_{k-1}^{i,2}, dx'_1, dx'_2)$, c'est-à-dire que $\xi_k^{i,1} = \hat{\xi}_{k-1}^{i,2}$ et que la variable aléatoire $\xi_k^{i,2}$ est simulée selon la distribution de probabilité $Q_k(\hat{\xi}_{k-1}^{i,2}, dx'_2)$,

et on pose

$$w_k^i = \frac{g_k(\xi_k^{i,1}, \xi_k^{i,2})}{\sum_{j=1}^N g_k(\xi_k^{j,1}, \xi_k^{j,2})} \quad \text{c'est-à-dire} \quad w_k^i = \frac{g_k(\hat{\xi}_{k-1}^{i,2}, \xi_k^{i,2})}{\sum_{j=1}^N g_k(\hat{\xi}_{k-1}^{j,2}, \xi_k^{j,2})} .$$

Finalement, l'approximation particulière pour le modèle (8.22) est donnée sous la forme

$$\mu_k \approx \mu_k^N = \mu_k^{N,\text{tr}} \circ \pi^{-1} = \sum_{i=1}^N w_k^i \delta_{\xi_k^{i,2}} ,$$

compte tenu de la relation $\mu_k = \mu_k^{\text{tr}} \circ \pi^{-1}$. On remarque aussitôt que toutes les étapes de cette classe d'algorithmes d'approximation particulière peuvent s'exprimer en terme de l'état d'arrivée seulement des particules-transitions, ce qui donne

$$\mu_k \approx \mu_k^N = \sum_{i=1}^N w_k^i \delta_{\xi_k^i} ,$$

où l'évolution de la population de particules et la mise-à-jour des poids peuvent être décrites de la façon récursive suivante

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est simulée selon la distribution de probabilité η_0 , et on pose

$$w_0^i = \frac{g_0(\xi_0^i)}{\sum_{j=1}^N g_0(\xi_0^j)} .$$

- pour tout $k = 1, \dots, n$, indépendamment pour tout $i = 1, \dots, N$
 - un individu $\hat{\xi}_{k-1}^i$ est sélectionné au sein de la population de particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids $(w_{k-1}^1, \dots, w_{k-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,
 - la variable aléatoire ξ_k^i est simulée selon la distribution de probabilité $Q_k(\hat{\xi}_{k-1}, dx')$,

et on pose

$$w_k^i = \frac{g_k(\hat{\xi}_{k-1}^i, \xi_k^i)}{\sum_{j=1}^N g_k(\hat{\xi}_{k-1}^j, \xi_k^j)} .$$

En résumé, les particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$

- sont sélectionnées selon leurs poids respectifs $(w_{k-1}^1, \dots, w_{k-1}^N)$ (étape de sélection),

Algorithm 10.2.2 Algorithme SIR (modèle général)

required distribution de probabilité initiale $\eta_0(dx)$
required probabilités de transition $Q_k(x, dx')$ pour $k = 1 \dots n$
required fonction de sélection $g_k(x, x')$ pour $k = 0, 1 \dots n$
 $k = 0$ [initialisation]
 [simulation]
for $i = 1 \dots N$ (indépendemment) **do**
 $\xi_0^i \sim \eta_0(dx)$
end for
 [calcul des poids normalisés]
for $i = 1 \dots N$ **do**
 $w_0^i \propto g_0(\xi_0^i)$
end for
loop
 $k \leftarrow k + 1$ [itération]
 [sélection]
for $i = 1 \dots N$ (indépendemment) **do**
 choisir $\hat{\xi}_{k-1}^i$ au sein de la population $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids respectifs
 $(w_{k-1}^1, \dots, w_{k-1}^N)$
end for
 [propagation]
for $i = 1 \dots N$ (indépendemment) **do**
 $\xi_k^i \sim Q_k(\hat{\xi}_{k-1}^i, dx')$
end for
 [calcul des poids normalisés]
for $i = 1 \dots N$ **do**
 $w_k^i \propto g_k(\hat{\xi}_{k-1}^i, \xi_k^i)$
end for
end loop

- évoluent selon le noyau de Markov Q_k (étape de mutation),
- et sont pondérées en évaluant la fonction de *fitness* g_k (étape de pondération).

Remarque 10.3 Dans le cas où les fonctions de sélection $g_k(x, x') = g_k(x')$ ne dépendent que de l'état d'arrivée de la transition, pour tout $k = 0, 1, \dots, n$, on retrouve évidemment comme cas particulier le schéma d'approximation déjà décrit plus haut.

Dans le cas de la décomposition d'importance optimale (8.13) et (8.14) où la fonction de sélection $g_0(x) = \text{cste}$ est constante et où les fonctions de sélection $g_k(x, x') = \hat{g}_k(x)$ ne dépendent au contraire que de l'état de départ de la transition pour tout $k = 1, \dots, n$, on obtient en principe comme cas particulier un schéma d'approximation où l'évolution de la population de particules et la mise-à-jour des poids peuvent être décrites de la façon récursive suivante

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est simulée selon la distribution de probabilité $\hat{\eta}_0$, et on pose

$$w_0^i = 1/N .$$

- pour tout $k = 1, \dots, n$, indépendamment pour tout $i = 1, \dots, N$
 - un individu $\hat{\xi}_{k-1}^i$ est sélectionné au sein de la population de particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids $(w_{k-1}^1, \dots, w_{k-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,
 - la variable aléatoire ξ_k^i est simulée selon la distribution de probabilité $\hat{Q}_k(\hat{\xi}_{k-1}^i, dx')$,

et on pose

$$w_k^i = \frac{\hat{g}_k(\hat{\xi}_{k-1}^i)}{\sum_{j=1}^N \hat{g}_k(\hat{\xi}_{k-1}^j)} .$$

On constate néanmoins que les poids $(w_k^1, \dots, w_k^N)$ qui servent à sélectionner les individus au sein de la nouvelle population $(\xi_k^1, \dots, \xi_k^N)$ ne dépendent en fait que de la population $(\hat{\xi}_{k-1}^1, \dots, \hat{\xi}_{k-1}^N)$ et sont donc disponibles avant même que la nouvelle population ne soit générée. Il est plus efficace dans ce cas d'effectuer la sélection plus tôt, et il suffit ici d'adopter le modèle (8.18).

Le principe consiste donc à rechercher une approximation

$$\eta_k^{\text{opt}} \approx \eta_k^{N, \text{opt}} = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_k^i} \quad \text{et} \quad \mu_k^{\text{opt}} \approx \mu_k^{N, \text{opt}} = \sum_{i=1}^N w_k^i \delta_{\xi_k^i} \quad \text{avec} \quad \sum_{i=1}^N w_k^i = 1 ,$$

pour tout $k = 0, 1, \dots, (n-1)$, et

$$\eta_n^{\text{opt}} \approx \eta_n^{N, \text{opt}} = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_n^i} ,$$

pour $k = n$, sous la forme de distributions de probabilité empiriques pondérées associées à un système de particules caractérisé par les positions $(\xi_k^i, i = 1, \dots, N)$ et par les poids positifs normalisés $(w_k^i, i = 1, \dots, N)$. Les poids et les positions des particules sont choisis de telle sorte que l'évolution de la suite approchée reproduise aussi fidèlement que possible l'évolution de la distribution normalisée décrite par le diagramme suivant

$$\mu_{k-1}^{\text{opt}} \xrightarrow{\text{mutation}} \eta_k^{\text{opt}} = \mu_{k-1}^{\text{opt}} Q_k^{\text{opt}} \xrightarrow{\text{pondération}} \mu_k^{\text{opt}} = g_k^{\text{opt}} \cdot \eta_k^{\text{opt}}, \quad (10.10)$$

avec la condition initiale $\mu_0^{\text{opt}} = g_0^{\text{opt}} \cdot \eta_0^{\text{opt}}$, où la notation $\cdot$ désigne le produit projectif. Ici, la distribution initiale $\eta_0^{\text{opt}}(dx)$ est définie en (8.15), les noyaux markoviens $Q_k^{\text{opt}}(x, dx')$ sont définis en (8.16) pour $k = 1, \dots, n$, et les fonctions de sélection $g_k^{\text{opt}}(x')$ sont définis en (8.17) pour $k = 0, \dots, (n-1)$.

L'évolution de la population de particules et la mise-à-jour des poids peuvent être décrites de la façon récursive suivante

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est simulée selon la distribution de probabilité η_0^{opt} , et on pose

$$w_0^i = \frac{g_0^{\text{opt}}(\xi_0^i)}{\sum_{j=1}^N g_0^{\text{opt}}(\xi_0^j)}.$$

- pour tout $k = 1, \dots, (n-1)$, indépendamment pour tout $i = 1, \dots, N$
 - un individu $\hat{\xi}_{k-1}^i$ est sélectionné au sein de la population de particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids $(w_{k-1}^1, \dots, w_{k-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,
 - la variable aléatoire ξ_k^i est simulée selon la distribution de probabilité $Q_k^{\text{opt}}(\hat{\xi}_{k-1}^i, dx')$,

et on pose

$$w_k^i = \frac{g_k^{\text{opt}}(\xi_k^i)}{\sum_{j=1}^N g_k^{\text{opt}}(\xi_k^j)}.$$

- pour $k = n$, indépendamment pour tout $i = 1, \dots, N$
 - un individu $\hat{\xi}_{n-1}^i$ est sélectionné au sein de la population de particules $(\xi_{n-1}^1, \dots, \xi_{n-1}^N)$ en fonction des poids $(w_{n-1}^1, \dots, w_{n-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,
 - la variable aléatoire ξ_n^i est simulée selon la distribution de probabilité $Q_n^{\text{opt}}(\hat{\xi}_{n-1}^i, dx')$.

En ré-organisant différemment les calculs, et en utilisant les définitions (8.15), (8.16) et (8.17), on voit que l'évolution de la population de particules et la mise-à-jour des poids peuvent être aussi décrites de la façon récursive suivante

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est simulée selon la distribution de probabilité $\hat{\eta}_0$.
- pour tout $k = 1, \dots, n$, indépendamment pour tout $i = 1, \dots, N$

– on pose

$$w_{k-1}^i = \frac{\hat{g}_k(\xi_{k-1}^i)}{\sum_{j=1}^N \hat{g}_k(\xi_{k-1}^j)},$$

- un individu $\hat{\xi}_{k-1}^i$ est sélectionné au sein de la population de particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids $(w_{k-1}^1, \dots, w_{k-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,
- la variable aléatoire ξ_k^i est simulée selon la distribution de probabilité $\hat{Q}_k(\hat{\xi}_{k-1}^i, dx')$.

Algorithm 10.2.3 Algorithme SIR (modèle optimal (8.18))

required distribution de probabilité initiale $\hat{\eta}_0(dx)$

required probabilités de transition $\hat{Q}_k(x, dx')$ pour $k = 1 \dots n$

required fonction de sélection $\hat{g}_k(x)$ pour $k = 1 \dots n$

$k = 0$ [initialisation]

[simulation]

for $i = 1 \dots N$ (indépendemment) **do**

$\xi_0^i \sim \hat{\eta}_0(dx)$

end for

loop

$k \leftarrow k + 1$ [itération]

[calcul des poids normalisés]

for $i = 1 \dots N$ **do**

$w_{k-1}^i \propto \hat{g}_k(\xi_{k-1}^i)$

end for

[sélection]

for $i = 1 \dots N$ (indépendemment) **do**

choisir $\hat{\xi}_{k-1}^i$ au sein de la population $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids respectifs $(w_{k-1}^1, \dots, w_{k-1}^N)$

end for

[propagation]

for $i = 1 \dots N$ (indépendemment) **do**

$\xi_k^i \sim \hat{Q}_k(\hat{\xi}_{k-1}^i, dx')$

end for

end loop

Exemple 10.4 Dans le cas particulier du système non-linéaire avec des bruits gaussiens additifs et une fonction d'observation linéaire décrit par (7.4), on obtient l'algorithme suivant

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$

- on simule deux vecteurs aléatoires gaussiens indépendants $\xi_{0|-1}^i$ et V_0^i , de moyenne $\bar{X}_0$ et 0 et de matrice de covariance Q_0^X et Q_0^V respectivement,
- on pose

$$\xi_0^i = \xi_{0|-1}^i + Q_0^X H_0^* [H_0 Q_0^X H_0^* + Q_0^V]^{-1} (Y_0 - (H_0 \xi_{0|-1}^i + h_0 + V_0^i)) ,$$

- pour tout $k = 1, \dots, n$, indépendamment pour tout $i = 1, \dots, N$

- on pose

$$w_{k-1}^i = \frac{q(Y_k - H_k f_k(\xi_{k-1}^i) - h_k, H_k \Sigma_k(\xi_{k-1}^i) H_k^* + Q_k^V)}{\sum_{j=1}^N q(Y_k - H_k f_k(\xi_{k-1}^j) - h_k, H_k \Sigma_k(\xi_{k-1}^j) H_k^* + Q_k^V)} ,$$

où par définition $\Sigma_k(x) = \sigma_k(x) Q_k^W \sigma_k^*(x)$ pour tout $x \in E$,

- on sélectionne un individu $\hat{\xi}_{k-1}^i$ au sein de la population de particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids $(w_{k-1}^1, \dots, w_{k-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,
- on simule deux vecteurs aléatoires gaussiens indépendants W_k^i et V_k^i , centrés et de matrice de covariance Q_k^W et Q_k^V respectivement,
- on pose

$$\xi_{k|k-1}^i = f_k(\hat{\xi}_{k-1}^i) + W_k^i ,$$

et

$$\xi_k^i = \xi_{k|k-1}^i + \Sigma_k(\hat{\xi}_{k-1}^i) H_k^* [H_k \Sigma_k(\hat{\xi}_{k-1}^i) H_k^* + Q_k^V]^{-1} (Y_k - (H_k \xi_{k|k-1}^i + h_k + V_k^i)) .$$

► **Ré-échantillonnage adaptatif** L'algorithme adaptatif suivant combine les propriétés de l'algorithme SIS, sans ré-échantillonnage, et celles de l'algorithme SIR, avec ré-échantillonnage à chaque pas de temps.

L'évolution de la population de particules et la mise-à-jour des poids sont ici couplées et peuvent être décrites de la façon récursive suivante

- pour $k = 0$, indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_0^i est simulée selon la distribution de probabilité η_0 , et on pose

$$w_0^i = \frac{g_0(\xi_0^i)}{\sum_{j=1}^N g_0(\xi_0^j)} .$$

- pour tout $k = 1, \dots, n$, on évalue la taille effective

$$N_{\text{eff}} = 1 / \left[\sum_{i=1}^N (w_{k-1}^i)^2 \right],$$

si $N_{\text{eff}} \leq c_{\text{red}} N$, alors indépendamment pour tout $i = 1, \dots, N$

- on sélectionne un individu $\hat{\xi}_{k-1}^i$ au sein de la population de particules $(\xi_{k-1}^1, \dots, \xi_{k-1}^N)$ en fonction des poids $(w_{k-1}^1, \dots, w_{k-1}^N)$ et à l'aide de l'un des mécanismes de sélection proposés,
- la variable aléatoire ξ_k^i est simulée selon la distribution de probabilité $Q_k(\hat{\xi}_{k-1}^i, dx')$,

et on pose

$$w_k^i = \frac{g_k(\hat{\xi}_{k-1}^i, \xi_k^i)}{\sum_{j=1}^N g_k(\hat{\xi}_{k-1}^j, \xi_k^j)},$$

sinon, si $N_{\text{eff}} > c_{\text{red}} N$, alors indépendamment pour tout $i = 1, \dots, N$, la variable aléatoire ξ_k^i est simulée selon la distribution de probabilité $Q_k(\xi_{k-1}^i, dx')$, et on pose

$$w_k^i = \frac{w_{k-1}^i g_k(\xi_{k-1}^i, \xi_k^i)}{\sum_{j=1}^N w_{k-1}^j g_k(\xi_{k-1}^j, \xi_k^j)}.$$

Chapitre 11

Estimation d'erreur

On rappelle que la distribution non-normalisée vérifie la relation de récurrence linéaire

$$\gamma_k = g_k (\gamma_{k-1} Q_k) = g_k \eta_k \langle \gamma_{k-1}, 1 \rangle \quad \text{et} \quad \gamma_0 = g_0 \eta_0 , \quad (8.2)$$

en posant $\eta_k = \mu_{k-1} Q_k$, ou de manière équivalente $\gamma_k = \gamma_{k-1} R_k$ où le noyau positif (non normalisé) R_k est défini par $R_k(x, dx') = Q_k(x, dx') g_k(x')$, et la constante de normalisation vérifie la relation de récurrence

$$\langle \gamma_k, 1 \rangle = \langle \eta_k, g_k \rangle \langle \gamma_{k-1}, 1 \rangle \quad \text{et} \quad \langle \gamma_0, 1 \rangle = \langle \eta_0, g_0 \rangle . \quad (8.3)$$

En partant de la relation de récurrence linéaire (8.2) et en introduisant l'approximation particulière

$$\gamma_k^N = g_k \eta_k^N \langle \gamma_{k-1}^N, 1 \rangle \quad \text{et} \quad \gamma_0^N = g_0 \eta_0^N ,$$

pour la distribution non-normalisée, où la définition précise de l'approximation η_k^N dépend de l'implémentation choisie, on voit aisément que

$$\langle \gamma_k^N, 1 \rangle = \langle \eta_k^N, g_k \rangle \langle \gamma_{k-1}^N, 1 \rangle \quad \text{et} \quad \langle \gamma_0^N, 1 \rangle = \langle \eta_0^N, g_0 \rangle , \quad (11.1)$$

de sorte que

$$\frac{\gamma_k^N}{\langle \gamma_k^N, 1 \rangle} = g_k \cdot \eta_k^N = \mu_k^N \quad \text{et} \quad \frac{\gamma_0^N}{\langle \gamma_0^N, 1 \rangle} = g_0 \cdot \eta_0^N = \mu_0^N .$$

Pour $k = 0$, on a par différence

$$\gamma_0^N - \gamma_0 = g_0 (\eta_0^N - \eta_0) ,$$

de sorte que

$$\langle \gamma_0^N - \gamma_0, \phi \rangle = \langle \eta_0^N - \eta_0, g_0 \phi \rangle , \quad (11.2)$$

pour toute fonction ϕ mesurable bornée. Pour tout $k = 1, \dots, n$, on a par différence

$$\begin{aligned} \gamma_k^N - \gamma_k &= g_k \eta_k^N \langle \gamma_{k-1}^N, 1 \rangle - g_k (\gamma_{k-1} Q_k) \\ &= g_k (\gamma_{k-1}^N Q_k - \gamma_{k-1} Q_k) + g_k (\eta_k^N - \mu_{k-1}^N Q_k) \langle \gamma_{k-1}^N, 1 \rangle , \end{aligned}$$

de sorte que

$$\langle \gamma_k^N - \gamma_k, \phi \rangle = \langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle + \langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle \langle \gamma_{k-1}^N, 1 \rangle, \quad (11.3)$$

pour toute fonction ϕ mesurable bornée. On constate que l'erreur d'approximation au rang k évaluée pour la fonction ϕ , peut s'exprimer à l'aide

- de l'erreur d'approximation au rang $(k-1)$ évaluée pour la fonction $R_k \phi = Q_k(g_k \phi)$,
- et de l'erreur locale d'approximation Monte Carlo évaluée pour la fonction $g_k \phi$.

La décomposition (11.3) est à la base des démonstrations par récurrence de la convergence dans $\mathbb{L}^p$ et de la normalité asymptotique des approximations particulières.

Au vu de la relation de récurrence (8.3), l'hypothèse minimale $\langle \gamma_n, 1 \rangle > 0$ est équivalente à supposer que $\langle \eta_k, g_k \rangle > 0$ pour tout $k = 0, 1, \dots, n$. Cette condition est trivialement vérifiée si les fonctions g_k sont strictement positives et ne s'annulent donc en aucun point, pour tout $k = 0, 1, \dots, n$. En revanche, si la fonction g_k peut s'annuler en certains points, et même si $\langle \eta_k, g_k \rangle > 0$, il peut quand même arriver que $g_k(\xi_k^i) = 0$ pour tout $i = 1, \dots, N$, c'est-à-dire que toutes les particules sont affectées d'un poids nul, auquel cas $\langle \eta_k^N, g_k \rangle = 0$ et $\langle \gamma_k^N, 1 \rangle = 0$, de sorte que l'approximation μ_k^N n'est pas définie. Soit τ^N le temps d'extinction du système de particules, c'est-à-dire le premier instant

$$\begin{aligned} \tau^N &= \inf\{k \geq 1 : \langle \gamma_k^N, 1 \rangle = 0\} \\ &= \inf\{k \geq 1 : \langle \eta_k^N, g_k \rangle = \frac{1}{N} \sum_{i=1}^N g_k(\xi_k^i) = 0\} \\ &= \inf\{k \geq 1 : g_k(\xi_k^i) = 0 \text{ pour tout } i = 1, \dots, N\}, \end{aligned}$$

auquel toutes les particules sont affectées d'un poids nul.

Pour $k = 0$, les distributions $\eta_0^N = S^N(\eta_0)$ et $\gamma_0^N = g_0 \eta_0^N$ sont bien définies, mais rien n'empêche que la constante de normalisation $\langle \eta_0^N, g_0 \rangle$ soit nulle, de sorte que la distribution $\mu_0^N = g_0 \cdot \eta_0^N$ n'est pas nécessairement définie. Sur l'ensemble $\{\tau^N > 0\}$ en revanche, la constante de normalisation $\langle \eta_0^N, g_0 \rangle$ est strictement positive, et la distribution $\mu_0^N = g_0 \cdot \eta_0^N$ est bien définie. Pour tout $k = 1, \dots, n$, sur l'ensemble $\{\tau^N > k-1\}$, les distributions γ_{k-1}^N et μ_{k-1}^N sont bien définies, donc les distributions $\eta_k^N = S^N(\mu_{k-1}^N Q_k)$ et $\gamma_k^N = g_k \eta_k^N \langle \gamma_{k-1}^N, 1 \rangle$ aussi sont bien définies, mais rien n'empêche que la constante de normalisation $\langle \eta_k^N, g_k \rangle$ soit nulle, de sorte que la distribution $\mu_k^N = g_k \cdot \eta_k^N$ n'est pas nécessairement définie. Sur l'ensemble $\{\tau^N > k\}$ en revanche, la constante de normalisation $\langle \eta_k^N, g_k \rangle$ est strictement positive, et la distribution $\mu_k^N = g_k \cdot \eta_k^N$ est bien définie.

Le temps d'extinction est bien sûr infini dans le cas où les fonctions g_k sont strictement positives et ne s'annulent en aucun point, pour tout $k = 0, 1, \dots, n$.

Les résultats suivants seront démontrés dans ce chapitre et dans le chapitre suivant : une borne non-asymptotique

$$\sup_{\phi : \|\phi\|=1} \{\mathbb{E} |\mu_n^N - \mu_n, \phi|^p\}^{1/p} \leq \frac{c_{n,p}}{\sqrt{N}},$$

dans le cas où le temps d'extinction est infini, et

$$\sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{(\tau^N > n)} | \langle \mu_n^N - \mu_n, \phi \rangle|^p] \}^{1/p} \leq \frac{c_{n,p}}{\sqrt{N}},$$

dans le cas général, et un théorème central limite

$$\sqrt{N} \langle \mu_n^N - \mu_n, \phi \rangle \Longrightarrow \mathcal{N}(0, v_n(\phi)),$$

dans le cas où le temps d'extinction est infini, et

$$\sqrt{N} 1_{(\tau^N > n)} \langle \mu_n^N - \mu_n, \phi \rangle \Longrightarrow \mathcal{N}(0, v_n(\phi)),$$

dans le cas général, en distribution quand $N \uparrow \infty$, avec une expression explicite pour la variance asymptotique $v_n(\phi)$, pour toute fonction mesurable bornée ϕ .

11.1 Probabilité d'extinction

On donne d'abord une majoration exponentielle de la probabilité d'extinction $\mathbb{P}[\tau^N \leq n]$. Cette partie peut donc être sautée dans le cas où les fonctions g_k sont strictement positives et ne s'annulent en aucun point, pour tout $k = 0, 1, \dots, n$, puisque le temps d'extinction est infini dans ce cas.

Proposition 11.1 *Il existe des constantes positives $a_n > 0$ et $b_n > 0$ telles que*

$$\mathbb{P}[\tau^N \leq n] \leq a_n \exp\{-b_n N\},$$

pour tout entier N .

PREUVE. Pour $k = 0$, on pose

$$E_0^N(c) = \sup_{\phi \geq 0: \|\phi\|=1} \mathbb{P}\left[\left|\frac{\langle \gamma_0^N - \gamma_0, \phi \rangle}{\langle \gamma_0, 1 \rangle}\right| > c\right] \quad \text{et} \quad F_0^N = \mathbb{P}\left[\left|\frac{\langle \gamma_0^N - \gamma_0, 1 \rangle}{\langle \gamma_0, 1 \rangle}\right| > \frac{1}{2}\right],$$

et pour tout $k = 1, \dots, n$, on pose

$$E_k^N(c) = \sup_{\phi \geq 0: \|\phi\|=1} \mathbb{P}\left[\left|\frac{\langle \gamma_k^N - \gamma_k, \phi \rangle}{\langle \gamma_k, 1 \rangle}\right| > c \text{ et } \tau^N > k-1\right],$$

et

$$F_k^N = \mathbb{P}\left[\left|\frac{\langle \gamma_k^N - \gamma_k, 1 \rangle}{\langle \gamma_k, 1 \rangle}\right| > \frac{1}{2} \text{ et } \tau^N > k-1\right].$$

Clairement, pour tout $k = 0, 1, \dots, n$, l'application $c \mapsto E_k^N(c)$ est décroissante et $F_k^N \leq E_k^N(\frac{1}{2})$.

Pour $k = 0$, si $\langle \gamma_0^N, 1 \rangle = 0$ alors nécessairement $\left|\frac{\langle \gamma_0^N - \gamma_0, 1 \rangle}{\langle \gamma_0, 1 \rangle}\right| > \frac{1}{2}$, de sorte que

$$\mathbb{P}[\tau^N = 0] = \mathbb{P}[\langle \gamma_0^N, 1 \rangle = 0] \leq \mathbb{P}\left[\left|\frac{\langle \gamma_0^N - \gamma_0, 1 \rangle}{\langle \gamma_0, 1 \rangle}\right| > \frac{1}{2}\right] = F_0^N.$$

Pour tout $k = 1, \dots, n$, les *bons ensembles* $\{\tau^N > k\} \subseteq \{\tau^N > k-1\}$ sont emboîtés, et sur l'ensemble $\{\tau^N > k-1\}$, si $\langle \gamma_k^N, 1 \rangle = 0$ alors nécessairement $|\frac{\langle \gamma_k^N - \gamma_k, 1 \rangle}{\langle \gamma_k, 1 \rangle}| > \frac{1}{2}$, de sorte que

$$\mathbb{P}[\tau^N = k] = \mathbb{P}[\langle \gamma_k^N, 1 \rangle = 0 \text{ et } \tau^N > k-1] \leq \mathbb{P}[|\frac{\langle \gamma_k^N - \gamma_k, 1 \rangle}{\langle \gamma_k, 1 \rangle}| > \frac{1}{2} \text{ et } \tau^N > k-1] = F_k^N .$$

On en déduit que

$$\mathbb{P}[\tau^N \leq n] = \sum_{k=0}^n \mathbb{P}[\tau^N = k] \leq \sum_{k=0}^n F_k^N .$$

Pour $k = 0$, on rappelle l'expression

$$\langle \gamma_0^N - \gamma_0, \phi \rangle = \langle \eta_0^N - \eta_0, g_0 \phi \rangle , \quad (11.2)$$

pour toute fonction ϕ mesurable bornée, et on en déduit que

$$\mathbb{P}[|\frac{\langle \gamma_0^N - \gamma_0, \phi \rangle}{\langle \gamma_0, 1 \rangle}| > c] = \mathbb{P}[|\langle \eta_0^N - \eta_0, g_0 \phi \rangle| > c \langle \eta_0, g_0 \rangle] .$$

Pour toute fonction mesurable positive ϕ telle que $\|\phi\| = 1$, on définit

$$0 \leq X_i = g_0(\xi_0^i) \phi(\xi_0^i) \leq \sup_{x \in E} g_0(x) \quad \text{pour tout } i = 1, \dots, N$$

où les v.a. $(\xi_0^i, \dots, \xi_0^N)$ sont indépendantes de distribution commune η_0 , et on vérifie que

$$\mathbb{E}(X_i) = \mathbb{E}[g_0(\xi_0^i) \phi(\xi_0^i)] = \langle \eta_0, g_0 \phi \rangle ,$$

et

$$\langle \eta_0^N - \eta_0, g_0 \phi \rangle = \frac{1}{N} \sum_{i=1}^N [g_0(\xi_0^i) \phi(\xi_0^i) - \langle \eta_0, g_0 \phi \rangle] = \frac{1}{N} \sum_{i=1}^N (X_i - \mathbb{E}(X_i)) .$$

D'après l'inégalité de Hoeffding

$$\begin{aligned} \mathbb{P}[|\langle \eta_0^N - \eta_0, g_0 \phi \rangle| > c \langle \eta_0, g_0 \rangle] &\leq 2 \exp\{-2 (\frac{c \langle \eta_0, g_0 \rangle}{\sup_{x \in E} g_0(x)})^2 N\} \\ &\leq 2 \exp\{-\frac{2 c^2}{r_0^2} N\} . \end{aligned}$$

Il en résulte que

$$\mathbb{P}[|\frac{\langle \gamma_0^N - \gamma_0, \phi \rangle}{\langle \gamma_0, 1 \rangle}| > c] \leq 2 \exp\{-\frac{2 c^2}{r_0^2} N\} ,$$

et en prenant le supremum par rapport aux fonctions mesurables positives ϕ telles que $\|\phi\| = 1$, on obtient

$$E_0^N(c) \leq 2 \exp\{-\frac{2 c^2}{r_0^2} N\} .$$

Pour tout $k = 1, \dots, n$, on rappelle la décomposition

$$\langle \gamma_k^N - \gamma_k, \phi \rangle = \langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle + \langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle \langle \gamma_{k-1}^N, 1 \rangle, \quad (11.3)$$

valide sur l'ensemble $\{\tau^N > k-1\}$ pour toute fonction ϕ mesurable bornée, et on en déduit que

$$\begin{aligned} \left| \frac{\langle \gamma_k^N - \gamma_k, \phi \rangle}{\langle \gamma_k, 1 \rangle} \right| &\leq \left| \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_{k-1}, 1 \rangle \langle \eta_k, g_k \rangle} \right| + \left| \frac{\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle}{\langle \eta_k, g_k \rangle} \right| \frac{\langle \gamma_{k-1}^N, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} \\ &\leq \left| \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_{k-1}, 1 \rangle \langle \eta_k, g_k \rangle} \right| + \left| \frac{\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle}{\langle \eta_k, g_k \rangle} \right| \left(1 + \left| \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} \right| \right). \end{aligned}$$

Si sur l'ensemble $\{\tau^N > k-1\}$ (et a fortiori sur l'ensemble $\{\tau^N > k\}$)

$$\left| \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_{k-1}, 1 \rangle} \right| \leq \frac{1}{2} c \langle \eta_k, g_k \rangle \quad \text{et} \quad \left| \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} \right| \leq \frac{1}{2},$$

et

$$\left| \langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle \right| \leq \frac{1}{3} c \langle \eta_k, g_k \rangle,$$

alors nécessairement sur l'ensemble $\{\tau^N > k\}$

$$\left| \frac{\langle \gamma_k^N - \gamma_k, \phi \rangle}{\langle \gamma_k, 1 \rangle} \right| \leq c.$$

On en déduit que

$$\begin{aligned} E_k^N(c) &= \sup_{\phi \geq 0: \|\phi\|=1} \mathbb{P} \left[\left| \frac{\langle \gamma_k^N - \gamma_k, \phi \rangle}{\langle \gamma_k, 1 \rangle} \right| > c \text{ et } \tau^N > k \right] \\ &\leq \sup_{\phi \geq 0: \|\phi\|=1} \mathbb{P} \left[\left| \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_{k-1}, 1 \rangle} \right| > \frac{1}{2} c \langle \eta_k, g_k \rangle \text{ et } \tau^N > k-1 \right] \\ &\quad + \mathbb{P} \left[\left| \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} \right| > \frac{1}{2} \text{ et } \tau^N > k-1 \right] \\ &\quad + \sup_{\phi \geq 0: \|\phi\|=1} \mathbb{P} \left[\left| \langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle \right| > \frac{1}{3} c \langle \eta_k, g_k \rangle \text{ et } \tau^N > k-1 \right]. \end{aligned} \quad (11.6)$$

Dans le second membre de (11.6), le deuxième terme s'interprète immédiatement comme F_{k-1}^N , et on se propose d'étudier successivement le premier et le troisième terme.

Pour toute fonction mesurable positive ϕ telle que $\|\phi\| = 1$, on a

$$0 \leq Q_k(g_k \phi)(x) = \int_E Q_k(x, dx') g_k(x') \phi(x') \leq \sup_{x \in E} g_k(x),$$

pour tout $x \in E$, et on en déduit que $\sup_{x \in E} Q_k(g_k \phi)(x) \leq \sup_{x \in E} g_k(x)$ et

$$\begin{aligned}
& \mathbb{P}\left[\left|\frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_{k-1}, 1 \rangle}\right| > \frac{1}{2} c \langle \eta_k, g_k \rangle \text{ et } \tau^N > k-1\right] \\
&= \mathbb{P}\left[\left|\frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_{k-1}, 1 \rangle \sup_{x \in E} Q_k(g_k \phi)(x)}\right| > \frac{1}{2} c \frac{\langle \eta_k, g_k \rangle}{\sup_{x \in E} Q_k(g_k \phi)(x)} \text{ et } \tau^N > k-1\right] \\
&\leq \mathbb{P}\left[\left|\frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_{k-1}, 1 \rangle \sup_{x \in E} Q_k(g_k \phi)(x)}\right| > \frac{1}{2} c \frac{\langle \eta_k, g_k \rangle}{\sup_{x \in E} g_k(x)} \text{ et } \tau^N > k-1\right] \\
&\leq \sup_{\phi \geq 0: \|\phi\|=1} \mathbb{P}\left[\left|\frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, \phi \rangle}{\langle \gamma_{k-1}, 1 \rangle}\right| > \frac{1}{2} \frac{c}{r_k} \text{ et } \tau^N > k-1\right] = E_{k-1}^N\left(\frac{1}{2} \frac{c}{r_k}\right),
\end{aligned}$$

de sorte que

$$\sup_{\phi \geq 0: \|\phi\|=1} \mathbb{P}\left[\left|\frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_{k-1}, 1 \rangle}\right| > \frac{1}{2} c \langle \eta_k, g_k \rangle \text{ et } \tau^N > k-1\right] \leq E_{k-1}^N\left(\frac{1}{2} \frac{c}{r_k}\right),$$

ce qui fournit une majoration du premier terme figurant dans le second membre de (11.6).

Pour toute fonction mesurable positive ϕ telle que $\|\phi\| = 1$, on définit

$$0 \leq X_i = g_k(\xi_k^i) \phi(\xi_k^i) \leq \sup_{x \in E} g_k(x) \quad \text{pour tout } i = 1, \dots, N$$

où conditionnellement par rapport à $\mathcal{F}_{k-1}^N$ les v.a. $(\xi_k^i, \dots, \xi_k^N)$ sont indépendantes de distribution commune $\mu_{k-1}^N Q_k$, et on vérifie que sur l'ensemble $\{\tau^N > k-1\}$

$$\mathbb{E}(X_i \mid \mathcal{F}_{k-1}^N) = \langle \mu_{k-1}^N Q_k, g_k \phi \rangle,$$

et

$$\begin{aligned}
\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle &= \frac{1}{N} \sum_{i=1}^N [g_k(\xi_k^i) \phi(\xi_k^i) - \langle \mu_{k-1}^N Q_k, g_k \phi \rangle] \\
&= \frac{1}{N} \sum_{i=1}^N (X_i - \mathbb{E}(X_i \mid \mathcal{F}_{k-1}^N)).
\end{aligned}$$

D'après l'inégalité de Hoeffding, sur l'ensemble $\{\tau^N > k-1\}$

$$\begin{aligned}
\mathbb{P}\left[\left|\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle\right| > \frac{1}{3} c \langle \eta_k, g_k \rangle \mid \mathcal{F}_{k-1}^N\right] &\leq 2 \exp\left\{-2 \left(\frac{\frac{1}{3} c \langle \eta_k, g_k \rangle}{\sup_{x \in E} g_k(x)}\right)^2 N\right\} \\
&\leq 2 \exp\left\{-\frac{2}{9} \frac{c^2}{r_k^2} N\right\}.
\end{aligned}$$

On en déduit que

$$\begin{aligned} & \mathbb{P}[|\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle| > \tfrac{1}{3} c \langle \eta_k, g_k \rangle \text{ et } \tau^N > k-1 \mid \mathcal{F}_{k-1}^N] \\ &= 1_{(\tau^N > k-1)} \mathbb{P}[|\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle| > \tfrac{1}{3} c \langle \eta_k, g_k \rangle \mid \mathcal{F}_{k-1}^N] \\ &\leq 2 \exp\{-\tfrac{2}{9} \frac{c^2}{r_k^2} N\} , \end{aligned}$$

de sorte que, en prenant l'espérance

$$\mathbb{P}[|\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle| > \tfrac{1}{3} c \langle \eta_k, g_k \rangle \text{ et } \tau^N > k-1] \leq 2 \exp\{-\tfrac{2}{9} \frac{c^2}{r_k^2} N\} ,$$

et finalement, en prenant le supremum par rapport aux fonctions mesurables positives ϕ telles que $\|\phi\| = 1$, on obtient

$$\sup_{\phi \geq 0 : \|\phi\|=1} \mathbb{P}[|\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle| > \tfrac{1}{3} c \langle \eta_k, g_k \rangle \text{ et } \tau^N > k-1] \leq 2 \exp\{-\tfrac{2}{9} \frac{c^2}{r_k^2} N\} ,$$

ce qui fournit une majoration du troisième terme figurant dans le second membre de (11.6).

En reportant ces majorations dans le second membre de (11.6), on obtient

$$E_k^N(c) \leq E_{k-1}^N(\tfrac{1}{2} \frac{c}{r_k}) + F_{k-1}^N + 2 \exp\{-\tfrac{2}{9} \frac{c^2}{r_k^2} N\} ,$$

pour tout $k = 1, \dots, n$, avec la condition initiale

$$E_0^N(c) \leq 2 \exp\{-\tfrac{2}{9} \frac{c^2}{r_0^2} N\} .$$

On peut montrer par récurrence que

$$E_k^N(c) \leq e_k \max(\exp\{-d_k c^2 N\}, \exp\{-f_k N\}) = e_k \exp\{-\min(d_k c^2, f_k) N\} ,$$

où $e_k > 0$, $d_k > 0$ et $f_k > 0$ sont des réels positifs. En particulier pour $c = \frac{1}{2}$, on a

$$F_k^N \leq E_k^N(\tfrac{1}{2}) \leq e_k \exp\{-\min(\tfrac{1}{4} d_k, f_k) N\} ,$$

pour tout $k = 0, 1, \dots, n$, de sorte que

$$\begin{aligned} \mathbb{P}[\tau^N \leq n] &\leq \sum_{k=0}^n F_k^N \leq \sum_{k=0}^n e_k \exp\{-\min(\tfrac{1}{4} d_k, f_k) N\} \\ &\leq (\sum_{k=0}^n e_k) \exp\{-\min_{k=0,1,\dots,n} \min(\tfrac{1}{4} d_k, f_k) N\} , \end{aligned}$$

c'est-à-dire que la majoration annoncée est vérifiée avec

$$a_n = \sum_{k=0}^n e_k \quad \text{et} \quad b_n = \min_{k=0,1,\dots,n} \min(\tfrac{1}{4} d_k, f_k) . \quad \square$$

11.2 Estimation d'erreur dans $\mathbb{L}^p$

On remarque que le rapport

$$r_k = \frac{\sup_{x \in E} g_k(x)}{\langle \eta_k, g_k \rangle}$$

toujours supérieur à 1, peut s'interpréter comme un indicateur de la difficulté d'un problème donné : en effet, une grande valeur numérique de r_k indique que les régions où la fonction de sélection g_k prend une valeur numérique significative ont en fait une faible probabilité sous η_k .

Pour l'algorithme SIR avec ré-échantillonnage multinomial et pour l'algorithme SIR avec stratification et ré-échantillonnage résiduel multinomial, on a les estimations suivantes pour l'approximation de la distribution normalisée et pour l'approximation de la constante de normalisation.

Théorème 11.2 *Pour tout réel $p \geq 2$, on a*

$$\{ \mathbb{E}[1_{(\tau^N > n)} \mid \frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1]^p] \}^{1/p} \leq z_n^{N,p}, \quad (11.7)$$

et

$$\sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{(\tau^N > n)} \mid \langle \mu_n^N - \mu_n, \phi \rangle]^p] \}^{1/p} \leq 2 z_n^{N,p}, \quad (11.8)$$

où la suite $\{z_k^{N,p}, k = 0, 1, \dots, n\}$ vérifie la relation de récurrence linéaire

$$z_k^{N,p} \leq r_k \left(1 + \frac{2c_p}{\sqrt{N}}\right) z_{k-1}^{N,p} + \frac{2c_p}{\sqrt{N}} \quad \text{et} \quad z_0^{N,p} \leq \frac{2c_p}{\sqrt{N}}. \quad (11.9)$$

Remarque 11.3 Sur le bon ensemble $\{\tau^N > n\}$

$$\langle \mu_n^N - \mu_n, \phi \rangle = \frac{\langle \gamma_n^N, \phi \rangle}{\langle \gamma_n^N, 1 \rangle} - \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} = \frac{\langle \gamma_n^N - \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} - \langle \mu_n^N, \phi \rangle \left[\frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1 \right],$$

de sorte que

$$1_{(\tau^N > n)} \mid \langle \mu_n^N - \mu_n, \phi \rangle \mid \leq 1_{(\tau^N > n)} \left[\left| \frac{\langle \gamma_n^N - \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} \right| + \|\phi\| \left| \frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1 \right| \right],$$

pour toute fonction ϕ mesurable bornée. Clairement

$$\{ \mathbb{E}[1_{(\tau^N > n)} \mid \frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1]^p] \}^{1/p} \leq \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{(\tau^N > n)} \mid \frac{\langle \gamma_n^N - \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle}]^p] \}^{1/p},$$

et

$$\sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{(\tau^N > n)} \mid \langle \mu_n^N - \mu_n, \phi \rangle]^p] \}^{1/p} \leq 2 \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{(\tau^N > n)} \mid \frac{\langle \gamma_n^N - \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle}]^p] \}^{1/p},$$

d'après l'inégalité (triangulaire) de Minkovski. Pour démontrer le Théorème 11.2 il suffit donc de prouver que la suite définie par

$$z_k^{N,p} = \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_k^N} | \frac{\langle \gamma_k^N - \gamma_k, \phi \rangle}{\langle \gamma_k, 1 \rangle} |^p] \}^{1/p} \quad \text{avec} \quad A_k^N = \{\tau^N > k\} ,$$

pour tout $k = 0, 1, \dots, n$ vérifie la relation de récurrence linéaire (11.9).

PREUVE DU THÉORÈME 11.2. Pour $k = 0$, on rappelle l'expression

$$\langle \gamma_0^N - \gamma_0, \phi \rangle = \langle \eta_0^N - \eta_0, g_0 \phi \rangle , \quad (11.2)$$

pour toute fonction ϕ mesurable bornée. On en déduit que

$$\{ \mathbb{E}[1_{A_0^N} | \langle \gamma_0^N - \gamma_0, \phi \rangle |^p] \}^{1/p} \leq \{ \mathbb{E}[\langle \eta_0^N - \eta_0, g_0 \phi \rangle |^p] \}^{1/p} \leq \frac{2c_p}{\sqrt{N}} \sup_{x \in E} g_0(x) \|\phi\| ,$$

pour toute fonction ϕ mesurable bornée, en utilisant la majoration (9.2), et en divisant par $\langle \gamma_0, 1 \rangle = \langle \eta_0, g_0 \rangle$, on obtient

$$\sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_0^N} | \frac{\langle \gamma_0^N - \gamma_0, \phi \rangle}{\langle \gamma_0, 1 \rangle} |^p] \}^{1/p} \leq \frac{2c_p}{\sqrt{N}} \frac{\sup_{x \in E} g_0(x)}{\langle \eta_0, g_0 \rangle} ,$$

de sorte que

$$z_0^{N,p} \leq \frac{2c_p}{\sqrt{N}} r_0 .$$

Pour tout $k = 1, \dots, n$, on rappelle la décomposition

$$\langle \gamma_k^N - \gamma_k, \phi \rangle = \langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle + \langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle \langle \gamma_{k-1}^N, 1 \rangle , \quad (11.3)$$

pour toute fonction ϕ mesurable bornée. On en déduit que

$$\begin{aligned} & \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_k^N} | \frac{\langle \gamma_k^N - \gamma_k, \phi \rangle}{\langle \gamma_k, 1 \rangle} |^p] \}^{1/p} \\ & \leq \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_{k-1}^N} | \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_k, 1 \rangle} |^p] \}^{1/p} \\ & \quad + \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_{k-1}^N} | \frac{\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle \langle \gamma_{k-1}^N, 1 \rangle}{\langle \gamma_k, 1 \rangle} |^p] \}^{1/p} , \end{aligned}$$

d'après l'inégalité (triangulaire) de Minkowski. On remarque que

$$\begin{aligned} & \{ \mathbb{E}[1_{A_{k-1}^N} | \langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle |^p] \}^{1/p} \\ & \leq \sup_{x \in E} |Q_k(g_k \phi)(x)| \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_{k-1}^N} | \langle \gamma_{k-1}^N - \gamma_{k-1}, \phi \rangle |^p] \}^{1/p} \\ & \leq \sup_{x \in E} g_k(x) \|\phi\| \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_{k-1}^N} | \langle \gamma_{k-1}^N - \gamma_{k-1}, \phi \rangle |^p] \}^{1/p} , \end{aligned}$$

compte tenu que

$$|Q_k(g_k \phi)(x)| \leq \int_E Q_k(x, dx') g_k(x') |\phi(x')| \leq \sup_{x \in E} g_k(x) \|\phi\| ,$$

pour tout $x \in E$ et pour toute fonction mesurable bornée ϕ , et en divisant par $\langle \gamma_k, 1 \rangle = \langle \eta_k, g_k \rangle \langle \gamma_{k-1}, 1 \rangle$ on obtient

$$\begin{aligned} & \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_{k-1}^N} | \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, Q_k(g_k \phi) \rangle}{\langle \gamma_k, 1 \rangle} |^p] \}^{1/p} \\ & \leq \frac{\sup_{x \in E} g_k(x)}{\langle \eta_k, g_k \rangle} \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_{k-1}^N} | \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, \phi \rangle}{\langle \gamma_{k-1}, 1 \rangle} |^p] \}^{1/p} . \end{aligned}$$

D'autre part

$$\{ \mathbb{E}[| \langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle |^p | \mathcal{F}_{k-1}^N] \}^{1/p} \leq \frac{2c_p}{\sqrt{N}} \sup_{x \in E} g_k(x) \|\phi\| ,$$

en utilisant la majoration (10.4) ou (10.6) selon l'implémentation choisie, et où $\mathcal{F}_{k-1}^N$ désigne la tribu engendrée par le système de particules jusqu'à la $(k-1)$ -ème génération, de sorte que

$$\begin{aligned} & \{ \mathbb{E}[1_{A_{k-1}^N} | \langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle \langle \gamma_{k-1}^N, 1 \rangle |^p] \}^{1/p} \\ & \leq \frac{2c_p}{\sqrt{N}} \sup_{x \in E} g_k(x) \|\phi\| \{ \mathbb{E}[1_{A_{k-1}^N} \langle \gamma_{k-1}^N, 1 \rangle^p] \}^{1/p} , \end{aligned}$$

pour toute fonction mesurable bornée ϕ , et en divisant par $\langle \gamma_k, 1 \rangle = \langle \eta_k, g_k \rangle \langle \gamma_{k-1}, 1 \rangle$ on obtient

$$\begin{aligned} & \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_{k-1}^N} | \frac{\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle \langle \gamma_{k-1}^N, 1 \rangle}{\langle \gamma_k, 1 \rangle} |^p] \}^{1/p} \\ & \leq \frac{2c_p}{\sqrt{N}} \frac{\sup_{x \in E} g_k(x)}{\langle \eta_k, g_k \rangle} \{ \mathbb{E}[1_{A_{k-1}^N} | \frac{\langle \gamma_{k-1}^N, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} |^p] \}^{1/p} , \end{aligned}$$

et on remarque que

$$\begin{aligned} \{ \mathbb{E}[1_{A_{k-1}^N} | \frac{\langle \gamma_{k-1}^N, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} |^p] \}^{1/p} & \leq 1 + \{ \mathbb{E}[1_{A_{k-1}^N} | \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} |^p] \}^{1/p} \\ & \leq 1 + \sup_{\phi: \|\phi\|=1} \{ \mathbb{E}[1_{A_{k-1}^N} | \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, \phi \rangle}{\langle \gamma_{k-1}, 1 \rangle} |^p] \}^{1/p} , \end{aligned}$$

d'après l'inégalité (triangulaire) de Minkowski. Finalement

$$z_{k,p}^N \leq r_k z_{k-1,p}^N + \frac{2c_p}{\sqrt{N}} r_k (1 + z_{k-1,p}^N) \leq r_k (1 + \frac{2c_p}{\sqrt{N}}) z_{k-1,p}^N + \frac{2c_p}{\sqrt{N}} r_k ,$$

en combinant les estimations obtenues ci-dessus. $\square$

Chapitre 12

TCL pour les approximations particulières

12.1 Échantillonnage pondéré (SIS)

Pour analyser les performances de l'algorithme en termes de variance asymptotique de l'erreur d'approximation quand le nombre N de trajectoires simulées tend vers l'infini, on peut se placer dans le cadre statique étudié au Chapitre 9. Si on introduit la variable aléatoire $X_{0:n} = (X_0, X_1, \dots, X_n)$ à valeurs trajectorielles, dont la distribution de probabilité est

$$\eta_{0:n}(dx_{0:n}) = \mathbb{P}[X_{0:n} \in dx_{0:n}] = \eta_0(dx_0) Q_1(x_0, dx_1) \cdots Q_n(x_{n-1}, dx_n) ,$$

et la fonction de poids

$$g_{0:n}(x_{0:n}) = \prod_{k=0}^n g_k(x_{k-1}, x_k) ,$$

et si on définit

$$\langle \eta_{0:n}, g_{0:n} f \rangle = \mathbb{E}[f(X_{0:n}) g_{0:n}(X_{0:n})] = \int_E \cdots \int_E f(x_{0:n}) g_{0:n}(x_{0:n}) \eta_{0:n}(dx_{0:n}) ,$$

pour toute fonction mesurable bornée f définie sur l'espace produit $E \times \cdots \times E = E^{n+1}$, alors on peut réécrire le flot linéaire comme une intégrale et appliquer la méthode d'échantillonnage pondéré vu à la Section 9.2. En effet, dans le cas particulier $f = \phi \circ \pi$ où la fonction f ne dépend que de la dernière variable, c'est-à-dire prend la forme suivante

$$f(x_{0:n}) = f(x_0, x_1, \dots, x_n) = \phi(x_n) , \quad (12.1)$$

on a

$$\langle \gamma_n, \phi \rangle = \mathbb{E}[\phi(X_n) \prod_{k=0}^n g_k(X_k)] = \mathbb{E}[\phi \circ \pi(X_{0:n}) g_{0:n}(X_{0:n})] = \langle \eta_{0:n}, g_{0:n} \phi \circ \pi \rangle ,$$

où $\pi : (x_0, x_1, \dots, x_n) \in E^{n+1} \mapsto x_n \in E$ désigne la projection sur la dernière composante de l'espace produit E^{n+1} , de sorte que

$$\langle \mu_{0:n}, \phi \circ \pi \rangle = \frac{\langle \eta_{0:n}, g_{0:n} \phi \circ \pi \rangle}{\langle \eta_{0:n}, g_{0:n} \rangle} = \frac{\langle \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} = \langle \mu_n, \phi \rangle ,$$

et on remarque que l'approximation introduite à la Section 10.1 vérifie

$$\langle \gamma_n^N, \phi \rangle = \langle S^N(\eta_{0:n}), g_{0:n} \phi \circ \pi \rangle = \frac{1}{N} \sum_{i=1}^N g_{0:n}(\xi_{0:n}^i) \phi \circ \pi(\xi_{0:n}^i) ,$$

de sorte que

$$\frac{\langle \gamma_n^N - \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} = \frac{\langle S^N(\eta_{0:n}) - \eta_{0:n}, g_{0:n} \phi \circ \pi \rangle}{\langle \eta_{0:n}, g_{0:n} \rangle} ,$$

pour toute fonction mesurable bornée ϕ définie sur E , et il suffit d'appliquer le Théorème 9.11.

Théorème 12.1

$$\sqrt{N} \left[\frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1 \right] \Longrightarrow \mathcal{N}(0, V_n) \quad \text{et} \quad \sqrt{N} \langle \mu_n^N - \mu_n, \phi \rangle \Longrightarrow \mathcal{N}(0, v_n(\phi)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$V_n = \frac{\langle \eta_{0:n}, g_{0:n}^2 \rangle}{\langle \eta_{0:n}, g_{0:n} \rangle^2} - 1 \quad \text{et} \quad v_n(\phi) = \frac{\langle \eta_{0:n}, g_{0:n}^2 |\phi \circ \pi - \langle \mu_n, \phi \rangle|^2 \rangle}{\langle \eta_{0:n}, g_{0:n} \rangle^2} ,$$

respectivement.

12.2 Échantillonnage / ré-échantillonnage (SIR)

Si en s'inspirant de (8.2), on définit récursivement l'approximation particulière

$$\begin{aligned} \gamma_k^N &= g_k S^N(\mu_{k-1}^N Q_k) \langle \gamma_{k-1}^N, 1 \rangle = g_k \eta_k^N \langle \gamma_{k-1}^N, 1 \rangle \\ \text{et} \quad \gamma_0^N &= g_0 S^N(\eta_0) = g_0 \eta_0^N , \end{aligned} \tag{12.2}$$

pour la distribution non-normalisée, alors il est facile de voir que

$$\langle \gamma_k^N, 1 \rangle = \langle \eta_k^N, g_k \rangle \langle \gamma_{k-1}^N, 1 \rangle \quad \text{et} \quad \langle \gamma_0^N, 1 \rangle = \langle \eta_0^N, g_0 \rangle , \tag{12.3}$$

de sorte que

$$\frac{\gamma_k^N}{\langle \gamma_k^N, 1 \rangle} = g_k \cdot \eta_k^N = \mu_k^N \quad \text{et} \quad \frac{\gamma_0^N}{\langle \gamma_0^N, 1 \rangle} = g_0 \cdot \eta_0^N = \mu_0^N ,$$

c'est-à-dire que (12.2) correspond exactement à l'algorithme SIR avec ré-échantillonnage multinomial, et en itérant (12.3)

$$\langle \gamma_n^N, 1 \rangle = \prod_{k=0}^n \langle \eta_k^N, g_k \rangle .$$

Théorème 12.2 *Pour l'approximation particulière du modèle (8.1), avec redistribution multinomiale*

$$\sqrt{N} \left[\frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1 \right] \Longrightarrow \mathcal{N}(0, V_n) \quad \text{et} \quad \sqrt{N} \langle \mu_n^N - \mu_n, \phi \rangle \Longrightarrow \mathcal{N}(0, v_n(\phi)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$V_n = \sum_{k=0}^n \left[\frac{\langle \eta_k, (g_k R_{k+1:n} 1)^2 \rangle}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2} - 1 \right] \quad \text{et} \quad v_n(\phi) = \sum_{k=0}^n \frac{\langle \eta_k, |g_k R_{k+1:n} (\phi - \langle \mu_n, \phi \rangle)|^2 \rangle}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2} ,$$

respectivement, où

$$R_{k+1:n} \phi(x) = R_{k+1} \cdots R_n \phi(x) = \mathbb{E}[\phi(X_n) \prod_{p=k+1}^n g_p(X_p) \mid X_k = x] ,$$

pour tout $k = 0, 1, \dots, n$, avec la convention $R_{n+1:n} \phi(x) = \phi(x)$.

Corollaire 12.3 *Pour l'approximation particulière du modèle (8.1), avec redistribution multinomiale*

$$\sqrt{N} \langle \eta_n^N - \eta_n, \phi \rangle \Longrightarrow \mathcal{N}(0, v_n^-(\phi)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$v_n^-(\phi) = \sum_{k=0}^n \frac{\langle \eta_k, |R_{k+1:n}^-(\phi - \langle \eta_n, \phi \rangle)|^2 \rangle}{\langle \eta_k, R_{k+1:n}^- 1 \rangle^2} ,$$

respectivement, où

$$R_{k+1:n}^- \phi(x) = R_{k+1}^- \cdots R_n^- \phi(x) = \mathbb{E}[\phi(X_n) \prod_{p=k}^{n-1} g_p(X_p) \mid X_k = x] ,$$

pour tout $k = 0, 1, \dots, n$, avec la convention $R_{n+1:n}^- \phi(x) = \phi(x)$.

PREUVE DU COROLLAIRE 12.3. On remarque que

$$\sqrt{N} \langle \eta_n^N - \eta_n, \phi \rangle = \sqrt{N} \langle \mu_{n-1}^N - \mu_{n-1}, Q_n \phi \rangle + \sqrt{N} \langle \eta_n^N - \mu_{n-1}^N, Q_n \phi \rangle = Z_N'' + Z_N' ,$$

pour toute fonction ϕ mesurable bornée. On vérifie que la v.a. Z_N'' est mesurable par rapport à la tribu $\mathcal{F}_{n-1}^N$ engendrée par le système de particules jusqu'à la $(n-1)$ -ème génération, et d'après le Théorème 12.2

$$Z_N'' \Longrightarrow \mathcal{N}(0, v_{n-1}(Q_n \phi)) ,$$

en distribution quand $N \uparrow \infty$. En suivant les lignes de la preuve du Théorème 12.2, on vérifie que

$$\mathbb{E}[\exp\{j u Z_N'\} \mid \mathcal{F}_{n-1}^N] \longrightarrow \exp\{-\frac{1}{2} u^2 \text{var}(\phi, \eta_n)\} ,$$

en probabilité quand $N \uparrow \infty$. Il résulte du Lemme C.1 que

$$\sqrt{N} \langle \eta_n^N - \eta_n, \phi \rangle \implies \mathcal{N}(0, v_n^-(\phi)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$v_n^-(\phi) = v_{n-1}(Q_n \phi) + \text{var}(\phi, \eta_n) .$$

Il résulte de l'expression de la variance asymptotique donnée au Théorème 12.2, et des identités (8.5) et (8.6), que

$$\begin{aligned} v_{n-1}(Q_n \phi) &= \sum_{k=0}^{n-1} \frac{\langle \eta_k, |g_k R_{k+1:n-1} (Q_n \phi - \langle \mu_{n-1}, Q_n \phi \rangle)|^2 \rangle}{\langle \eta_k, g_k R_{k+1:n-1} 1 \rangle^2} \\ &= \sum_{k=0}^{n-1} \frac{\langle \eta_k, |R_{k+1:n}^-(\phi - \langle \eta_n, \phi \rangle)|^2 \rangle}{\langle \eta_k, R_{k+1:n}^- 1 \rangle^2} , \end{aligned}$$

et

$$\begin{aligned} v_n^-(\phi) &= v_{n-1}(Q_n \phi) + \text{var}(\phi, \eta_n) \\ &= \sum_{k=0}^{n-1} \frac{\langle \eta_k, |R_{k+1:n}^-(\phi - \langle \eta_n, \phi \rangle)|^2 \rangle}{\langle \eta_k, R_{k+1:n}^- 1 \rangle^2} + \langle \eta_n, |\phi - \langle \eta_n, \phi \rangle|^2 \rangle \\ &= \sum_{k=0}^n \frac{\langle \eta_k, |R_{k+1:n}^-(\phi - \langle \eta_n, \phi \rangle)|^2 \rangle}{\langle \eta_k, R_{k+1:n}^- 1 \rangle^2} . \quad \square \end{aligned}$$

Remarque 12.4 Pour démontrer le Théorème 12.2, il suffit de démontrer que

$$\sqrt{N} \frac{\langle \gamma_n^N - \gamma_n, \phi \rangle}{\langle \gamma_n, 1 \rangle} \implies \mathcal{N}(0, V_n(\phi)) , \quad (12.4)$$

pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$V_n(\phi) = \sum_{k=0}^n \frac{\text{var}(g_k R_{k+1:n} \phi, \eta_k)}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2} , \quad (12.5)$$

pour tout $k = 1, \dots, n$. Clairement, le Théorème 12.2 pour la constante de normalisation découle de (12.4) avec

$$V_n = V_n(1) = \sum_{k=0}^n \frac{\text{var}(g_k R_{k+1:n} 1, \eta_k)}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2} = \sum_{k=0}^n \left[\frac{\langle \eta_k, (g_k R_{k+1:n} 1)^2 \rangle}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2} - 1 \right] .$$

On remarque aussi que

$$\langle \mu_n^N - \mu_n, \phi \rangle = \frac{\langle \gamma_n^N, \phi - \langle \mu_n, \phi \rangle \rangle}{\langle \gamma_n^N, 1 \rangle} = \frac{\langle \gamma_n, 1 \rangle}{\langle \gamma_n^N, 1 \rangle} \frac{\langle \gamma_n^N - \gamma_n, \phi - \langle \mu_n, \phi \rangle \rangle}{\langle \gamma_n, 1 \rangle} ,$$

pour toute fonction mesurable bornée ϕ , et compte tenu que $\langle \gamma_n^N, 1 \rangle \longrightarrow \langle \gamma_n, 1 \rangle$ en probabilité quand $N \uparrow \infty$, le Théorème 12.2 pour la distribution normalisée découle de (12.4) et du lemme de Slutsky, avec

$$v_n(\phi) = V_n(\phi - \langle \mu_n, \phi \rangle) = \sum_{k=0}^n \frac{\text{var}(g_k R_{k+1:n}(\phi - \langle \mu_n, \phi \rangle), \eta_k)}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2},$$

et on vérifie que

$$\begin{aligned} \langle \eta_k, g_k R_{k+1:n}(\phi - \langle \mu_n, \phi \rangle) \rangle &= \langle \eta_k, g_k \rangle \langle \mu_k R_{k+1:n}, \phi - \langle \mu_n, \phi \rangle \rangle \\ &= \langle \eta_k, g_k \rangle \frac{\langle \gamma_k R_{k+1:n}, \phi - \langle \mu_n, \phi \rangle \rangle}{\langle \gamma_k, 1 \rangle} \\ &= \langle \eta_k, g_k \rangle \frac{\langle \gamma_n, \phi - \langle \mu_n, \phi \rangle \rangle}{\langle \gamma_k, 1 \rangle} \\ &= \langle \eta_k, g_k \rangle \frac{\langle \gamma_n, 1 \rangle}{\langle \gamma_k, 1 \rangle} \langle \mu_n, \phi - \langle \mu_n, \phi \rangle \rangle = 0, \end{aligned}$$

de sorte que

$$\text{var}(g_k R_{k+1:n}(\phi - \langle \mu_n, \phi \rangle), \eta_k) = \langle \eta_k, |g_k R_{k+1:n}(\phi - \langle \mu_n, \phi \rangle)|^2 \rangle,$$

pour tout $k = 0, 1, \dots, n$.

Remarque 12.5 On remarque que

$$\langle \eta_p, g_p R_{p+1:k} 1 \rangle = \langle \eta_p, g_p \rangle \langle \mu_p R_{p+1:k}, 1 \rangle = \langle \eta_p, g_p \rangle \frac{\langle \gamma_p R_{p+1:k}, 1 \rangle}{\langle \gamma_p, 1 \rangle} = \langle \eta_p, g_p \rangle \frac{\langle \gamma_k, 1 \rangle}{\langle \gamma_p, 1 \rangle},$$

pour tout $p = 0, 1, \dots, (k-1)$, de sorte que le rapport

$$\frac{\langle \eta_p, g_p R_{p+1:k} 1 \rangle}{\langle \eta_p, g_p R_{p+1:k-1} 1 \rangle} = \frac{\langle \gamma_k, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} = \langle \eta_k, g_k \rangle,$$

ne dépend pas de $p = 0, 1, \dots, (k-1)$, et

$$V_k(\phi) = \sum_{p=0}^k \frac{\text{var}(g_p R_{p+1:k} \phi, \eta_p)}{\langle \eta_p, g_p R_{p+1:k} 1 \rangle^2} = \sum_{p=0}^{k-1} \frac{\text{var}(g_p R_{p+1:k-1} R_k \phi, \eta_p)}{\langle \eta_p, g_p R_{p+1:k-1} 1 \rangle^2 \langle \eta_k, g_k \rangle^2} + \frac{\text{var}(g_k \phi, \eta_k)}{\langle \eta_k, g_k \rangle^2},$$

d'où la relation de récurrence

$$V_k(\phi) = \frac{V_{k-1}(R_k \phi)}{\langle \eta_k, g_k \rangle^2} + \frac{\text{var}(g_k \phi, \eta_k)}{\langle \eta_k, g_k \rangle^2}, \quad (12.6)$$

pour tout $k = 1, \dots, n$.

Remarque 12.6 Si la propriété (12.4) est vérifiée, alors le vecteur aléatoire

$$(\sqrt{N} [\frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1], \sqrt{N} \langle \mu_n^N - \mu_n, \phi_1 \rangle, \dots, \sqrt{N} \langle \mu_n^N - \mu_n, \phi_d \rangle) ,$$

converge conjointement en distribution quand $N \uparrow \infty$ vers une limite gaussienne, pour toutes fonctions mesurables bornées $\phi_1, \dots, \phi_d$, en utilisant le procédé de Cramér–Wold.

PREUVE DU THÉORÈME 12.2 (PAR RÉCURRENCE). Pour $k = 0$, on rappelle l'expression

$$\langle \gamma_0^N - \gamma_0, \phi \rangle = \langle \eta_0^N - \eta_0, g_0 \phi \rangle , \quad (11.2)$$

pour toute fonction ϕ mesurable bornée. On remarque que

$$\sqrt{N} \langle \eta_0^N - \eta_0, g_0 \phi \rangle = \frac{1}{\sqrt{N}} \sum_{i=1}^N [g_0(\xi_0^i) \phi(\xi_0^i) - \langle \eta_0, g_0 \phi \rangle] ,$$

où $\xi_0^1, \dots, \xi_0^N$ sont des variables aléatoires i.i.d. de distribution de probabilité commune η_0 . On en déduit que

$$\sqrt{N} \langle \eta_0^N - \eta_0, g_0 \phi \rangle \implies \mathcal{N}(0, \text{var}(g_0 \phi, \eta_0)) ,$$

en distribution quand $N \uparrow \infty$, et en divisant par $\langle \gamma_0, 1 \rangle = \langle \eta_0, g_0 \rangle$ on obtient

$$\sqrt{N} \frac{\langle \gamma_0^N - \gamma_0, \phi \rangle}{\langle \gamma_0, 1 \rangle} \implies \mathcal{N}(0, \frac{\text{var}(g_0 \phi, \eta_0)}{\langle \eta_0, g_0 \rangle^2}) ,$$

en distribution quand $N \uparrow \infty$, c'est-à-dire que l'hypothèse de récurrence (12.6) est vérifiée pour $k = 0$, avec

$$V_0(\phi) = \frac{\text{var}(g_0 \phi, \eta_0)}{\langle \eta_0, g_0 \rangle^2} .$$

Pour tout $k = 1, \dots, n$, on rappelle la décomposition

$$\langle \gamma_k^N - \gamma_k, \phi \rangle = \langle \gamma_{k-1}^N - \gamma_{k-1}, R_k \phi \rangle + \langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle \langle \gamma_{k-1}^N, 1 \rangle , \quad (11.3)$$

et en divisant par $\langle \gamma_k, 1 \rangle = \langle \gamma_{k-1}, 1 \rangle \langle \eta_k, g_k \rangle$ on obtient

$$\begin{aligned} Z_N &= \sqrt{N} \frac{\langle \gamma_k^N - \gamma_k, \phi \rangle}{\langle \gamma_k, 1 \rangle} \\ &= \sqrt{N} \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, R_k \phi \rangle}{\langle \eta_k, g_k \rangle \langle \gamma_{k-1}, 1 \rangle} + \sqrt{N} \frac{\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle}{\langle \eta_k, g_k \rangle} \frac{\langle \gamma_{k-1}^N, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} \\ &= Z_N'' + c_N' Z_N' , \end{aligned}$$

pour toute fonction ϕ mesurable bornée. D'après l'hypothèse de récurrence

$$\sqrt{N} \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, R_k \phi \rangle}{\langle \gamma_{k-1}, 1 \rangle} \implies \mathcal{N}(0, V_{k-1}(R_k \phi)) ,$$

en distribution quand $N \uparrow \infty$, et en divisant par $\langle \eta_k, g_k \rangle$ on obtient

$$Z_N'' = \sqrt{N} \frac{\langle \gamma_{k-1}^N - \gamma_{k-1}, R_k \phi \rangle}{\langle \eta_k, g_k \rangle \langle \gamma_{k-1}, 1 \rangle} \Longrightarrow \mathcal{N}(0, \frac{V_{k-1}(R_k \phi)}{\langle \eta_k, g_k \rangle^2}) ,$$

en distribution quand $N \uparrow \infty$. D'autre part, on remarque que

$$c_N' = \frac{\langle \gamma_{k-1}^N, 1 \rangle}{\langle \gamma_{k-1}, 1 \rangle} \longrightarrow 1 ,$$

en probabilité quand $N \uparrow \infty$, et

$$Z_N' = \sqrt{N} \frac{\langle \eta_k^N - \mu_{k-1}^N Q_k, g_k \phi \rangle}{\langle \eta_k, g_k \rangle} = \frac{1}{\sqrt{N}} \sum_{i=1}^N \frac{g_k(\xi_k^i) \phi(\xi_k^i) - \langle \mu_{k-1}^N Q_k, g_k \phi \rangle}{\langle \eta_k, g_k \rangle} ,$$

où conditionnellement par rapport à la tribu $\mathcal{F}_{k-1}^N$ engendrée par le système de particules jusqu'à la $(k-1)$ -ème génération, les variables aléatoires $\xi_k^1, \dots, \xi_k^N$ sont i.i.d. de distribution de probabilité commune $\mu_{k-1}^N Q_k$. On vérifie que la variable aléatoire

$$X_{N,i} = \frac{g_k(\xi_k^i) \phi(\xi_k^i) - \langle \mu_{k-1}^N Q_k, g_k \phi \rangle}{\langle \eta_k, g_k \rangle} ,$$

est centrée, de variance

$$s_{N,i}^2 = \mathbb{E}[|X_{N,i}|^2 \mid \mathcal{F}_{k-1}^N] = \frac{\text{var}(g_k \phi, \mu_{k-1}^N Q_k)}{\langle \eta_k, g_k \rangle^2} ,$$

et bornée

$$|X_{N,i}| \leq 2 \frac{\sup_{x \in E} g_k(x)}{\langle \eta_k, g_k \rangle} \|\phi\| ,$$

pour tout $i = 1, \dots, N$. Clairement

$$s_N^2 = \frac{1}{N} \sum_{i=1}^N s_{N,i}^2 = \frac{\text{var}(g_k \phi, \mu_{k-1}^N Q_k)}{\langle \eta_k, g_k \rangle^2} \longrightarrow \frac{\text{var}(g_k \phi, \eta_k)}{\langle \eta_k, g_k \rangle^2} ,$$

en probabilité quand $N \uparrow \infty$, et il résulte du Théorème C.12 que

$$\mathbb{E}[\exp\{j u Z_N'\} \mid \mathcal{F}_{k-1}^N] \longrightarrow \exp\{-\frac{1}{2} u^2 \frac{\text{var}(g_k \phi, \eta_k)}{\langle \eta_k, g_k \rangle^2}\} ,$$

en probabilité quand $N \uparrow \infty$. Finalement, il résulte du Lemme C.1 et de la Remarque C.2 que

$$Z_N'' + c_N' Z_N' = \sqrt{N} \frac{\langle \gamma_k^N - \gamma_k, \phi \rangle}{\langle \gamma_k, 1 \rangle} \Longrightarrow \mathcal{N}(0, V_k(\phi)) ,$$

en distribution quand $N \uparrow \infty$, avec

$$V_k(\phi) = \frac{V_{k-1}(R_k \phi)}{\langle \eta_k, g_k \rangle^2} + \frac{\text{var}(g_k \phi, \eta_k)}{\langle \eta_k, g_k \rangle^2} ,$$

c'est-à-dire que l'hypothèse de récurrence (12.6) est vérifiée. $\square$

Théorème 12.7 *Pour l'approximation particulière du modèle (8.1), utilisant la distribution d'importance optimale et avec redistribution multinomiale*

$$\sqrt{N} \left[\frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1 \right] \Longrightarrow \mathcal{N}(0, V_{n-1}^{\text{opt}}) \quad \text{et} \quad \sqrt{N} \langle \mu_n^N - \mu_n, \phi \rangle \Longrightarrow \mathcal{N}(0, v_n^{\text{opt}-}(\phi)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$V_{n-1}^{\text{opt}} = \sum_{k=0}^n \left[\frac{\langle \mu_k, (R_{k+1:n} 1)^2 \rangle}{\langle \mu_k, R_{k+1:n} 1 \rangle^2} - 1 \right] ,$$

et

$$v_n^{\text{opt}-}(\phi) = \sum_{k=0}^n \frac{\langle \mu_k, |R_{k+1:n} (\phi - \langle \mu_n, \phi \rangle)|^2 \rangle}{\langle \mu_k, R_{k+1:n} 1 \rangle^2} ,$$

respectivement, où

$$R_{k+1:n} \phi(x) = R_{k+1} \cdots R_n \phi(x) = \mathbb{E}[\phi(X_n) \prod_{p=k+1}^n g_p(X_p) \mid X_k = x] ,$$

pour tout $k = 0, 1 \cdots n$, avec la convention $R_{n+1:n} \phi(x) = \phi(x)$.

PREUVE. On rappelle que l'approximation particulière des distributions γ_n et μ_n utilisant la distribution d'importance optimale définie par (8.13) et (8.14), coïncide avec l'approximation particulière des distributions $\gamma_n^{\text{opt}-}$ et η_n^{opt} pour le modèle dit optimal (8.18). En particulier, l'approximation particulière de la constante de normalisation $\langle \gamma_n, 1 \rangle$ coïncide avec l'approximation particulière de la constante de normalisation $\langle \gamma_n^{\text{opt}-}, 1 \rangle = \langle \gamma_{n-1}^{\text{opt}}, 1 \rangle$. Il résulte immédiatement du Théorème 12.2 et du Corollaire 12.3 que

$$\sqrt{N} \left[\frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1 \right] = \sqrt{N} \left[\frac{\langle \gamma_{n-1}^{\text{opt},N}, 1 \rangle}{\langle \gamma_{n-1}^{\text{opt}}, 1 \rangle} - 1 \right] \Longrightarrow \mathcal{N}(0, V_{n-1}^{\text{opt}})$$

et

$$\sqrt{N} \langle \mu_n^N - \mu_n, \phi \rangle = \sqrt{N} \langle \eta_n^{\text{opt},N} - \eta_n^{\text{opt}}, \phi \rangle \Longrightarrow \mathcal{N}(0, v_n^{\text{opt}-}(\phi))$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$V_{n-1}^{\text{opt}} = \sum_{k=0}^{n-1} \left[\frac{\langle \eta_k^{\text{opt}}, (g_k^{\text{opt}} R_{k+1:n-1}^{\text{opt}} 1)^2 \rangle}{\langle \eta_k^{\text{opt}}, g_k^{\text{opt}} R_{k+1:n-1}^{\text{opt}} 1 \rangle^2} - 1 \right] = \sum_{k=0}^n \left[\frac{\langle \mu_k, (R_{k+1:n} 1)^2 \rangle}{\langle \mu_k, R_{k+1:n} 1 \rangle^2} - 1 \right] ,$$

et

$$v_n^{\text{opt}-}(\phi) = \sum_{k=0}^n \frac{\langle \eta_k^{\text{opt}}, |R_{k+1:n}^{\text{opt}-} (\phi - \langle \eta_n^{\text{opt}}, \phi \rangle)|^2 \rangle}{\langle \eta_k^{\text{opt}}, R_{k+1:n}^{\text{opt}-} 1 \rangle^2} = \sum_{k=0}^n \frac{\langle \mu_k, |R_{k+1:n} (\phi - \langle \mu_n, \phi \rangle)|^2 \rangle}{\langle \mu_k, R_{k+1:n} 1 \rangle^2} ,$$

d'après (8.21) et (8.20), respectivement. □

Remarque 12.8 La comparaison des variances asymptotiques donne

$$V_{n-1}^{\text{opt}} = \sum_{k=0}^n \left[\frac{\langle \mu_k, (R_{k+1:n} 1)^2 \rangle}{\langle \mu_k, R_{k+1:n} 1 \rangle^2} - 1 \right] = \sum_{k=0}^n \left[\frac{\langle \eta_k, g_k \rangle \langle \eta_k, g_k (R_{k+1:n} 1)^2 \rangle}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2} - 1 \right],$$

à comparer avec

$$V_n = \sum_{k=0}^n \left[\frac{\langle \eta_k, (g_k R_{k+1:n} 1)^2 \rangle}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2} - 1 \right],$$

pour les constantes de normalisation, et

$$v_n^{\text{opt-}}(\phi) = \sum_{k=0}^n \frac{\langle \mu_k, |R_{k+1:n}(\phi - \langle \mu_n, \phi \rangle)|^2 \rangle}{\langle \mu_k, R_{k+1:n} 1 \rangle^2} = \sum_{k=0}^n \frac{\langle \eta_k, g_k \rangle \langle \eta_k, g_k |R_{k+1:n}(\phi - \langle \mu_n, \phi \rangle)|^2 \rangle}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2},$$

à comparer avec

$$v_n(\phi) = \sum_{k=0}^n \frac{\langle \eta_k, |g_k R_{k+1:n}(\phi - \langle \mu_n, \phi \rangle)|^2 \rangle}{\langle \eta_k, g_k R_{k+1:n} 1 \rangle^2},$$

pour les distributions normalisées.

Dans le cas plus général du modèle (8.8) et pour une décomposition d'importance (8.11) donnée, avec la représentation probabiliste (8.12) associée, ou bien pour le modèle (8.22) où la décomposition d'importance est donnée de manière explicite dans la représentation probabiliste, chaque fonction de sélection dépend de la transition courante de la chaîne de Markov, mais il suffit de changer de point de vue et d'adopter le modèle (8.27) à valeurs transitions, où chaque fonction de sélection dépend seulement de l'état courant, puis de ré-exprimer dans ce cadre le Théorème 12.2 établi ci-dessus pour le modèle (8.1) apparemment plus simple. On obtient ainsi un premier résultat intermédiaire, qu'il suffit ensuite de ré-interpréter en terme de la décomposition d'importance donnée. On introduit le noyau positif

$$R_k^\square(x, dx') = Q_k(x, dx') |g_k(x, x')|^2,$$

pour tout $k = 1, \dots, n$.

Théorème 12.9 *Pour l'approximation particulière du modèle (8.22), avec redistribution multinomiale*

$$\sqrt{N} \left[\frac{\langle \gamma_n^N, 1 \rangle}{\langle \gamma_n, 1 \rangle} - 1 \right] \Rightarrow \mathcal{N}(0, V_n) \quad \text{et} \quad \sqrt{N} \langle \mu_n^N - \mu_n, \phi \rangle \Rightarrow \mathcal{N}(0, v_n(\phi)),$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée ϕ , avec l'expression suivante pour la variance asymptotique

$$V_n = \sum_{k=0}^n \left[\frac{\langle \mu_{k-1} R_k^\square, |R_{k+1:n} 1|^2 \rangle}{\langle \mu_{k-1} R_k, R_{k+1:n} 1 \rangle^2} - 1 \right] \quad \text{et} \quad v_n(\phi) = \sum_{k=0}^n \frac{\langle \mu_{k-1} R_k^\square, |R_{k+1:n}(\phi - \langle \mu_n, \phi \rangle)|^2 \rangle}{\langle \mu_{k-1} R_k, R_{k+1:n} 1 \rangle^2},$$

respectivement, où

$$R_{k+1:n} \phi(x) = R_{k+1} \cdots R_n \phi(x) = \mathbb{E}[\phi(X_n) \prod_{p=k+1}^n g_p(X_{p-1}, X_p) \mid X_k = x],$$

pour tout $k = 0, 1, \dots, n$, avec la convention $R_{n+1:n} \phi(x) = \phi(x)$.

PREUVE. En particulier pour l'approximation particulière du modèle (8.27) à valeurs transitions, avec redistribution multinomiale, il résulte du Théorème 12.2 que

$$\sqrt{N} \left[\frac{\langle \gamma_n^{N, \text{tr}}, 1 \rangle}{\langle \gamma_n^{\text{tr}}, 1 \rangle} - 1 \right] \Longrightarrow \mathcal{N}(0, V_n^{\text{tr}}) \quad \text{et} \quad \sqrt{N} \langle \mu_n^{N, \text{tr}} - \mu_n^{\text{tr}}, F \rangle \Longrightarrow \mathcal{N}(0, v_n^{\text{tr}}(F)) ,$$

en distribution quand $N \uparrow \infty$, pour toute fonction mesurable bornée F définie sur l'ensemble produit $E \times E$, avec l'expression suivante pour la variance asymptotique

$$V_n^{\text{tr}} = \sum_{k=0}^n \left[\frac{\langle \eta_k^{\text{tr}}, (g_k R_{k+1:n}^{\text{tr}} 1)^2 \rangle}{\langle \eta_k^{\text{tr}}, g_k R_{k+1:n}^{\text{tr}} 1 \rangle^2} - 1 \right] \quad \text{et} \quad v_n^{\text{tr}}(F) = \sum_{k=0}^n \frac{\langle \eta_k^{\text{tr}}, |g_k R_{k+1:n}^{\text{tr}} (F - \langle \mu_n^{\text{tr}}, F \rangle)|^2 \rangle}{\langle \eta_k^{\text{tr}}, g_k R_{k+1:n}^{\text{tr}} 1 \rangle^2} ,$$

respectivement, où

$$R_{k+1:n}^{\text{tr}} F(x_1, x_2) = \mathbb{E}[F(X_n^{\text{tr}}) \prod_{p=k+1}^n g_p(X_p^{\text{tr}}) \mid X_k^{\text{tr}} = (x_1, x_2)] ,$$

pour tout $k = 0, 1, \dots, n$, avec la convention $R_{n+1:n}^{\text{tr}} F(x_1, x_2) = F(x_1, x_2)$. Il suffit ensuite de ré-interpréter ce résultat en terme du modèle (8.22), avec une fonction de la forme $F = \phi \circ \pi$, où $\pi : (x, x') \in E \times E \mapsto x' \in E$ désigne la projection sur la dernière composante de l'espace produit $E \times E$.

Par définition $\eta_k^{\text{tr}} = \mu_{k-1}^{\text{tr}} Q_k^{\text{tr}}$, où le noyau markovien Q_k^{tr} est défini en (8.26), de sorte que

$$\begin{aligned} \langle \eta_k^{\text{tr}}, F \rangle &= \int_E \int_E F(x'_1, x'_2) \int_E \int_E \mu_{k-1}^{\text{tr}}(dx_1, dx_2) Q_k^{\text{tr}}(x_1, x_2, dx'_1, dx'_2) \\ &= \int_E \int_E F(x'_1, x'_2) \int_E \int_E \mu_{k-1}^{\text{tr}}(dx_1, dx_2) \delta_{x_2}(dx'_1) Q_k(x'_1, dx'_2) \\ &= \int_E \int_E \int_E \mu_{k-1}^{\text{tr}}(dx_1, dx_2) F(x_2, x'_2) Q_k(x_2, dx'_2) \\ &= \int_E \int_E \mu_{k-1}^{\text{tr}}(E, dx_2) F(x_2, x'_2) Q_k(x_2, dx'_2) \\ &= \int_E \int_E \mu_{k-1}(dx_2) F(x_2, x'_2) Q_k(x_2, dx'_2) , \end{aligned}$$

toute pour toute fonction mesurable bornée F définie sur l'ensemble produit $E \times E$, et compte tenu que $\mu_{k-1}^{\text{tr}}(E, dx_2) = \mu_{k-1}(dx_2)$, c'est-à-dire que

$$\eta_k^{\text{tr}} = \mu_{k-1} \otimes Q_k .$$

D'après la propriété de Markov

$$\begin{aligned} R_{k+1:n}^{\text{tr}} (\phi \circ \pi)(x_1, x_2) &= \mathbb{E}[\phi(X_n) \prod_{p=k+1}^n g_p(X_{p-1}, X_p) \mid X_{k-1} = x_1, X_k = x_2] \\ &= \mathbb{E}[\phi(X_n) \prod_{p=k+1}^n g_p(X_{p-1}, X_p) \mid X_k = x_2] \\ &= R_{k+1:n} \phi(x_2) , \end{aligned}$$

pour toute fonction de la forme $F = \phi \circ \pi$, de sorte que

$$R_{k+1:n}^{\text{tr}}(\phi \circ \pi) = (R_{k+1:n} \phi) \circ \pi ,$$

compte tenu que le résultat ne dépend que de x_2 . On rappelle que $\mu_n^{\text{tr}} \circ \pi^{-1} = \mu_n$, de sorte que $\langle \mu_n^{\text{tr}}, \phi \circ \pi \rangle = \langle \mu_n, \phi \rangle$ pour toute fonction de la forme $F = \phi \circ \pi$. On en déduit alors que

$$\begin{aligned} \langle \eta_k^{\text{tr}}, |g_k R_{k+1:n}^{\text{tr}}(\phi \circ \pi - \langle \mu_n^{\text{tr}}, \phi \circ \pi \rangle)|^2 \rangle &= \\ &= \int_E \int_E \mu_{k-1}(dx) Q_k(x, dx') |g_k(x, x')|^2 |R_{k+1:n} \phi(x') - R_{k+1:n} 1(x') \langle \mu_n, \phi \rangle|^2 \\ &= \int_E \int_E \mu_{k-1}(dx) R_k^\square(x, dx') |R_{k+1:n} \phi(x') - R_{k+1:n} 1(x') \langle \mu_n, \phi \rangle|^2 \\ &= \langle \mu_{k-1} R_k^\square, |R_{k+1:n}(\phi - \langle \mu_n, \phi \rangle)|^2 \rangle , \end{aligned}$$

et

$$\begin{aligned} \langle \eta_k^{\text{tr}}, (g_k R_{k+1:n}^{\text{tr}} 1)^2 \rangle &= \int_E \int_E \mu_{k-1}(dx) Q_k(x, dx') |g_k(x, x')|^2 |R_{k+1:n} 1(x')|^2 \\ &= \int_E \int_E \mu_{k-1}(dx) R_k^\square(x, dx') |R_{k+1:n} 1(x')|^2 \\ &= \langle \mu_{k-1} R_k^\square, |R_{k+1:n} 1|^2 \rangle , \end{aligned}$$

et finalement

$$\begin{aligned} \langle \eta_k^{\text{tr}}, g_k R_{k+1:n}^{\text{tr}} 1 \rangle &= \int_E \int_E \mu_{k-1}(dx) Q_k(x, dx') g_k(x, x') R_{k+1:n} 1(x') \\ &= \int_E \int_E \mu_{k-1}(dx) R_k(x, dx') R_{k+1:n} 1(x') \\ &= \langle \mu_{k-1} R_k, R_{k+1:n} 1 \rangle , \end{aligned}$$

et il suffit d'utiliser ces identités dans l'expression des variances asymptotiques. $\square$

Annexe A

Inversion matricielle

Lemme A.1 Soit Q et R deux matrices symétriques définies positives, de dimension m et d respectivement, et soit H une matrice $d \times m$. Alors

$$(H^* R^{-1} H + Q^{-1})^{-1} = Q - Q H^* (H Q H^* + R)^{-1} H Q ,$$

où toutes les matrices inverses sont bien définies, et de plus

$$(H^* R^{-1} H + Q^{-1})^{-1} H^* = Q H^* (H Q H^* + R)^{-1} R .$$

PREUVE. On remarque d'abord que

$$H Q H^* + R \geq R \quad \text{et} \quad H^* R^{-1} H + Q^{-1} \geq Q^{-1}$$

au sens des matrices symétriques, ce qui prouve que les matrices

$$H Q H^* + R \quad \text{et} \quad H^* R^{-1} H + Q^{-1}$$

sont inversibles. En développant, on vérifie que

$$\begin{aligned} & [Q - Q H^* (H Q H^* + R)^{-1} H Q] [H^* R^{-1} H + Q^{-1}] \\ &= Q H^* R^{-1} H + I - Q H^* (H Q H^* + R)^{-1} (H Q H^* + R - R) R^{-1} H \\ & \quad - Q H^* (H Q H^* + R)^{-1} H \\ &= I , \end{aligned}$$

et d'autre part, en multipliant à droite par H^* , on obtient

$$\begin{aligned} (H^* R^{-1} H + Q^{-1})^{-1} H^* &= Q H^* - Q H^* (H Q H^* + R)^{-1} (H Q H^* + R - R) \\ &= Q H^* (H Q H^* + R)^{-1} R . \quad \square \end{aligned}$$

Remarque A.2 Cette formule permet de remplacer l'inversion de la matrice $(H^* R^{-1} H + Q^{-1})$ de dimension m , par l'inversion de la matrice $(H Q H^* + R)$ de dimension d , avec $d \leq m$ en général. En particulier, dans le cas où $d = 1$, la matrice $H = h^*$ est un vecteur ligne, la matrice $R = r$ est un scalaire, et la formule devient

$$\left(\frac{h h^*}{r} + Q^{-1}\right)^{-1} = Q - \frac{Q h h^* Q}{r + h^* Q h}.$$

Lemme A.3 Si la matrice D est inversible, alors

$$M = \begin{pmatrix} A & B \\ C & D \end{pmatrix} = \begin{pmatrix} I & B D^{-1} \\ 0 & I \end{pmatrix} \begin{pmatrix} \Delta & 0 \\ 0 & D \end{pmatrix} \begin{pmatrix} I & 0 \\ D^{-1} C & I \end{pmatrix},$$

où la matrice $\Delta = A - B D^{-1} C$ est appelée complément de Schur de la matrice D dans la matrice-bloc M . En particulier, $\det M = \det \Delta \cdot \det D$ de sorte que la matrice M est inversible si et seulement si la matrice Δ est inversible, et

$$M^{-1} = \begin{pmatrix} \Delta^{-1} & \star \\ \star & \star \end{pmatrix}.$$

Si la matrice M est symétrique, ce qui implique en particulier que $A = A^*$, $C = B^*$ et $D = D^*$, alors le complément de Schur $\Delta = A - B D^{-1} B^*$ est également symétrique, et si en outre la matrice M est semi-définie positive, respectivement définie positive, alors la matrice Δ est également semi-définie positive, respectivement définie positive.

Remarque A.4 Si la matrice A est inversible, alors la matrice $\Delta = D - C A^{-1} B$ est appelée complément de Schur de la matrice A dans la matrice-bloc M , la matrice M est inversible si et seulement si la matrice Δ est inversible, et

$$M^{-1} = \begin{pmatrix} \star & \star \\ \star & \Delta^{-1} \end{pmatrix}.$$

PREUVE. En développant, on vérifie que

$$\begin{aligned} \begin{pmatrix} I & B D^{-1} \\ 0 & I \end{pmatrix} \begin{pmatrix} \Delta & 0 \\ 0 & D \end{pmatrix} \begin{pmatrix} I & 0 \\ D^{-1} C & I \end{pmatrix} &= \begin{pmatrix} \Delta & B \\ 0 & D \end{pmatrix} \begin{pmatrix} I & 0 \\ D^{-1} C & I \end{pmatrix} \\ &= \begin{pmatrix} \Delta + B D^{-1} C & B \\ C & D \end{pmatrix} = M, \end{aligned}$$

ce qui montre l'identité annoncée. On en déduit que $\det M = \det \Delta \cdot \det D$ de sorte que la matrice M est inversible si et seulement si la matrice Δ est inversible, et

$$M^{-1} = \begin{pmatrix} I & 0 \\ -D^{-1} C & I \end{pmatrix} \begin{pmatrix} \Delta^{-1} & 0 \\ 0 & D^{-1} \end{pmatrix} \begin{pmatrix} I & -B D^{-1} \\ 0 & I \end{pmatrix},$$

et on remarque que

$$\begin{pmatrix} I & 0 \\ \star & I \end{pmatrix} \begin{pmatrix} \Delta^{-1} & 0 \\ 0 & \star \end{pmatrix} \begin{pmatrix} I & \star \\ 0 & I \end{pmatrix} = \begin{pmatrix} \Delta^{-1} & 0 \\ \star & \star \end{pmatrix} \begin{pmatrix} I & \star \\ 0 & I \end{pmatrix} = \begin{pmatrix} \Delta^{-1} & \star \\ \star & \star \end{pmatrix} .$$

Si la matrice M est symétrique, on remarque que

$$\begin{pmatrix} I & -B D^{-1} \end{pmatrix} \begin{pmatrix} A & B \\ B^* & D \end{pmatrix} \begin{pmatrix} I \\ -D^{-1} B^* \end{pmatrix} = \begin{pmatrix} A - B D^{-1} B^* & 0 \end{pmatrix} \begin{pmatrix} I \\ -D^{-1} B^* \end{pmatrix} = \Delta ,$$

de sorte que

$$\begin{pmatrix} u^* & -u^* B D^{-1} \end{pmatrix} \begin{pmatrix} A & B \\ B^* & D \end{pmatrix} \begin{pmatrix} u \\ -D^{-1} B^* u \end{pmatrix} = u^* \Delta u ,$$

pour tout vecteur u , ce qui permet de conclure. □

Annexe B

Inégalités

On regroupe dans cette annexe plusieurs résultats non-asymptotiques sur les sommes de variables aléatoires indépendantes mais pas nécessairement identiquement distribuées : inégalité de Khintchine, inégalité de Marcinkiewicz–Zygmund pour les moments d'ordre $p \geq 1$, inégalité exponentielle de Hoeffding pour les probabilités de déviation.

On appelle suite de Rademacher une suite de variables aléatoires indépendantes prenant les valeurs -1 ou $+1$ avec probabilité $\frac{1}{2}$.

Proposition B.1 (Inégalité de Khintchine) *Pour tout réel $p \geq 0$, il existe une constante positive $A_p > 0$ telle que*

$$\mathbb{E} \left| \sum_{i=1}^N \varepsilon_i c_i \right|^p \leq A_p \left(\sum_{i=1}^N c_i^2 \right)^{p/2} ,$$

pour toute suite $(c_1, \dots, c_N)$ de réels et pour toute suite de Rademacher $(\varepsilon_1, \dots, \varepsilon_N)$.

Par homogénéité, on peut supposer que $\sum_{i=1}^N c_i^2 = 1$ sans perte de généralité.

Si l'inégalité est vraie pour un entier $p \geq 0$, alors pour tout réel $0 \leq q \leq p$

$$\mathbb{E} \left| \sum_{i=1}^N \varepsilon_i c_i \right|^q \leq \left\{ \mathbb{E} \left| \sum_{i=1}^N \varepsilon_i c_i \right|^p \right\}^{q/p} \leq A_p^{q/p} ,$$

d'après l'inégalité de Jensen, compte tenu que l'application $x \mapsto |x|^{q/p}$ est concave, et il suffit de montrer l'inégalité pour tout entier $p \geq 1$, le cas $p = 0$ étant trivial.

PREUVE. On remarque que

$$e^x \geq e^{|x|} 1_{(x \geq 0)} \geq \frac{1}{p!} |x|^p 1_{(x \geq 0)} ,$$

pour tout entier $p \geq 1$, de sorte que

$$\frac{1}{p!} |x|^p = \frac{1}{p!} |x|^p 1_{(x \geq 0)} + \frac{1}{p!} |x|^p 1_{(x \leq 0)} \leq e^x + e^{-x} ,$$

pour tout réel x . Il en résulte que

$$\frac{1}{p!} \mathbb{E} \left| \sum_{i=1}^N \varepsilon_i c_i \right|^p \leq \mathbb{E} \exp \left\{ \sum_{i=1}^N \varepsilon_i c_i \right\} + \mathbb{E} \exp \left\{ - \sum_{i=1}^N \varepsilon_i c_i \right\} = 2 \mathbb{E} \exp \left\{ \sum_{i=1}^N \varepsilon_i c_i \right\}.$$

Finalement

$$\mathbb{E} \exp \left\{ \sum_{i=1}^N \varepsilon_i c_i \right\} = \prod_{i=1}^N \left(\frac{1}{2} e^{c_i} + \frac{1}{2} e^{-c_i} \right) \leq \exp \left\{ \frac{1}{2} \sum_{i=1}^N c_i^2 \right\} = \sqrt{e},$$

compte tenu de l'inégalité $\frac{1}{2}(e^x + e^{-x}) \leq e^{\frac{1}{2}x^2}$, valide pour tout réel x , et l'inégalité de Khintchine est démontrée avec $A_p = 2\sqrt{e} p!$. $\square$

Proposition B.2 (Inégalité de Marcinkiewicz–Zygmund) *Pour tout réel $p \geq 1$, il existe une constante positive $B_p > 0$ telle que*

$$\mathbb{E} \left| \sum_{i=1}^N X_i \right|^p \leq B_p \mathbb{E} \left(\sum_{i=1}^N X_i^2 \right)^{p/2},$$

pour toute suite $(X_1, \dots, X_N)$ de variables aléatoires indépendantes centrées et de puissance p -ème intégrable.

Remarque B.3 En divisant par N^p , on obtient

$$\mathbb{E} \left| \frac{1}{N} \sum_{i=1}^N X_i \right|^p \leq \frac{B_p}{N^{p/2}} \mathbb{E} \left(\frac{1}{N} \sum_{i=1}^N X_i^2 \right)^{p/2},$$

et pour tout réel $p \geq 2$, il résulte de l'inégalité de Jensen que

$$\left(\frac{1}{N} \sum_{i=1}^N X_i^2 \right)^{p/2} \leq \frac{1}{N} \sum_{i=1}^N |X_i|^p,$$

compte tenu que l'application $x \mapsto |x|^{p/2}$ est convexe, de sorte que

$$\mathbb{E} \left| \frac{1}{N} \sum_{i=1}^N X_i \right|^p \leq \frac{B_p}{N^{p/2}} \left(\frac{1}{N} \sum_{i=1}^N \mathbb{E} |X_i|^p \right). \quad (\text{B.1})$$

Remarque B.4 Plus généralement, pour tout vecteur de probabilité $(w_1, \dots, w_N)$, et quitte à remplacer X_i par $w_i X_i$ pour tout $i = 1, \dots, N$, on obtient

$$\mathbb{E} \left| \sum_{i=1}^N w_i X_i \right|^p \leq B_p \mathbb{E} \left(\sum_{i=1}^N w_i^2 X_i^2 \right)^{p/2} = B_p \left(\sum_{i=1}^N w_i^2 \right)^{p/2} \mathbb{E} \left(\sum_{i=1}^N w_i^\square X_i^2 \right)^{p/2},$$

en introduisant le vecteur de probabilité $(w_1^\square, \dots, w_N^\square)$ défini par

$$w_i^\square = \frac{w_i^2}{\sum_{j=1}^N w_j^2},$$

pour tout $i = 1, \dots, N$, et pour tout réel $p \geq 2$, il résulte de l'inégalité de Jensen que

$$\left(\sum_{i=1}^N w_i^{\square} X_i^2 \right)^{p/2} \leq \sum_{i=1}^N w_i^{\square} |X_i|^p ,$$

compte tenu que l'application $x \mapsto |x|^{p/2}$ est convexe, de sorte que

$$\mathbb{E} \left| \sum_{i=1}^N w_i X_i \right|^p \leq B_p \left(\sum_{i=1}^N w_i^2 \right)^{p/2} \left(\sum_{i=1}^N w_i^{\square} \mathbb{E} |X_i|^p \right) . \quad (\text{B.2})$$

PREUVE DE LA PROPOSITION B.2. On pose

$$S_N = \sum_{i=1}^N X_i \quad \text{et} \quad R_N = \sum_{i=1}^N \varepsilon_i X_i ,$$

et on considère les versions symétrisées

$$S_N^{\text{sym}} = \sum_{i=1}^N (X_i - X'_i) \quad \text{et} \quad R_N^{\text{sym}} = \sum_{i=1}^N \varepsilon_i (X_i - X'_i) ,$$

où $(\varepsilon_1, \dots, \varepsilon_N)$ est une suite de Rademacher, où la suite $(X'_1, \dots, X'_N)$ a la même distribution que la suite $(X_1, \dots, X_N)$, et où les suites $(X_1, \dots, X_N)$, $(X'_1, \dots, X'_N)$ et $(\varepsilon_1, \dots, \varepsilon_N)$ sont mutuellement indépendantes. Pour tout $i = 1, \dots, N$ et compte tenu que les variables aléatoires $(X_i - X'_i)$ et $(X'_i - X_i)$ ont la même distribution, on vérifie que

$$\begin{aligned} \mathbb{E}[\phi(\varepsilon_i (X_i - X'_i))] &= \mathbb{E}(\mathbb{E}[\phi(\varepsilon_i (X_i - X'_i)) \mid X_i, X'_i]) \\ &= \mathbb{E}[\tfrac{1}{2} \phi(X_i - X'_i) + \tfrac{1}{2} \phi(X'_i - X_i)] = \mathbb{E}[\phi(X_i - X'_i)] , \end{aligned}$$

pour toute fonction test ϕ , de sorte que les variables aléatoires $\varepsilon_i (X_i - X'_i)$ et $(X_i - X'_i)$ ont la même distribution, et il en résulte que les variables aléatoires S_N^{sym} et R_N^{sym} ont la même distribution. On remarque que

$$\mathbb{E}[S_N^{\text{sym}} \mid X_1, \dots, X_N] = S_N ,$$

et il résulte de l'inégalité de Jensen que

$$\Phi(S_N) = \Phi(\mathbb{E}[S_N^{\text{sym}} \mid X_1, \dots, X_N]) \leq \mathbb{E}[\Phi(S_N^{\text{sym}}) \mid X_1, \dots, X_N] ,$$

pour toute fonction convexe Φ , de sorte que

$$\mathbb{E}[\Phi(S_N)] \leq \mathbb{E}[\Phi(S_N^{\text{sym}})] .$$

On remarque aussi que

$$\begin{aligned} \mathbb{E}|R_N^{\text{sym}}|^p &= \mathbb{E} \left| \sum_{i=1}^N \varepsilon_i X_i - \sum_{i=1}^N \varepsilon_i X'_i \right|^p \\ &\leq 2^{p-1} \left(\mathbb{E} \left| \sum_{i=1}^N \varepsilon_i X_i \right|^p + \mathbb{E} \left| \sum_{i=1}^N \varepsilon_i X'_i \right|^p \right) = 2^p \mathbb{E} \left| \sum_{i=1}^N \varepsilon_i X_i \right|^p , \end{aligned}$$

et

$$\mathbb{E} \left| \sum_{i=1}^N \varepsilon_i X_i \right|^p = \mathbb{E} \left(\mathbb{E} \left[\left| \sum_{i=1}^N \varepsilon_i X_i \right|^p \mid X_1, \dots, X_N \right] \right) \leq A_p \mathbb{E} \left(\sum_{i=1}^N X_i^2 \right)^{p/2} ,$$

d'après l'inégalité de Khintchine. Finalement, pour tout réel $p \geq 1$

$$\mathbb{E} \left| \sum_{i=1}^N X_i \right|^p = \mathbb{E} |S_N|^p \leq \mathbb{E} |S_N^{\text{sym}}|^p = \mathbb{E} |R_N^{\text{sym}}|^p = 2^p A_p \mathbb{E} \left(\sum_{i=1}^N X_i^2 \right)^{p/2} ,$$

compte tenu que l'application $x \mapsto |x|^p$ est convexe, et l'inégalité de Marcinkiewicz–Zygmund est démontrée avec $B_p = 2^p A_p = 2^{p+1} \sqrt{e} p!$. $\square$

Lemme B.5 *Soit X une variable aléatoire réelle, de moyenne nulle et à valeurs bornées, c'est-à-dire que $a \leq X \leq b$. Alors*

$$\mathbb{E}[\exp\{s X\}] \leq \exp\left\{\frac{1}{8} s^2 (b-a)^2\right\} ,$$

pour tout réel s .

PREUVE. Nécessairement $a \leq 0 \leq b$, et il résulte de l'identité

$$x = \frac{x-a}{b-a} b + \frac{b-x}{b-a} a ,$$

et de la convexité de la fonction exponentielle que

$$\exp\{s x\} \leq \frac{x-a}{b-a} \exp\{s b\} + \frac{b-x}{b-a} \exp\{s a\} ,$$

pour tout $a \leq x \leq b$, de sorte que

$$\mathbb{E}[\exp\{s X\}] \leq \frac{-a}{b-a} \exp\{s b\} + \frac{b}{b-a} \exp\{s a\} ,$$

compte tenu que $\mathbb{E}(X) = 0$. On pose

$$p = \frac{-a}{b-a} \quad \text{de sorte que} \quad 1-p = \frac{b}{b-a} ,$$

et il vient

$$s a = -s p (b-a) = -p u \quad \text{et} \quad s b = s (1-p) (b-a) = (1-p) u ,$$

avec $u = s(b-a)$. On en déduit que

$$\mathbb{E}[\exp\{s X\}] \leq p \exp\{(1-p) u\} + (1-p) \exp\{-p u\} = \exp\{\phi(u)\} ,$$

ce qui définit

$$\phi(u) = -p u + \log(p \exp\{u\} + 1-p) .$$

On calcule facilement l'expression des dérivées

$$\phi'(u) = -p + \frac{p \exp\{u\}}{p \exp\{u\} + 1 - p},$$

et

$$\phi''(u) = \frac{p \exp\{u\}}{p \exp\{u\} + 1 - p} - \left(\frac{p \exp\{u\}}{p \exp\{u\} + 1 - p} \right)^2 = \frac{p(1-p) \exp\{u\}}{(p \exp\{u\} + 1 - p)^2},$$

et on vérifie que $\phi(0) = \phi'(0) = 0$ et que $\phi''(u) \leq \frac{1}{4}$, de sorte que

$$\phi(u) = \phi(0) + \phi'(0)u + \frac{1}{2} \phi''(\theta) u^2 \leq \frac{1}{8} u^2 = \frac{1}{8} s^2 (b-a)^2. \quad \square$$

Proposition B.6 (Inégalité exponentielle de Hoeffding) Soit $(X_1, \dots, X_N)$ des variables aléatoires réelles indépendantes (mais pas nécessairement identiquement distribuées, ni centrées) et à valeurs bornées, c'est-à-dire que $a_i \leq X_i \leq b_i$, pour tout $i = 1, \dots, N$. Alors

$$\mathbb{P}\left[\left|\sum_{i=1}^N (X_i - \mathbb{E}(X_i))\right| \geq c\right] \leq 2 \exp\left\{-\frac{2c^2}{\sum_{i=1}^N (b_i - a_i)^2}\right\},$$

pour tout réel positif $c \geq 0$.

Remarque B.7 En utilisant cN en lieu et place de c , on obtient

$$\mathbb{P}\left[\left|\frac{1}{N} \sum_{i=1}^N (X_i - \mathbb{E}(X_i))\right| \geq c\right] \leq 2 \exp\left\{-\frac{2Nc^2}{\frac{1}{N} \sum_{i=1}^N (b_i - a_i)^2}\right\},$$

pour tout réel positif $c \geq 0$.

PREUVE. On utilise la méthode de majoration de Chernoff : pour tout réel positif $\lambda > 0$, il résulte de l'inégalité de Markov, de l'indépendance des variables aléatoires $(X_1, \dots, X_N)$ et du Lemme B.5, que

$$\begin{aligned} \mathbb{P}\left[\sum_{i=1}^N (X_i - \mathbb{E}(X_i)) \geq c\right] &= \mathbb{P}\left[\exp\left\{\lambda \sum_{i=1}^N (X_i - \mathbb{E}(X_i))\right\} \geq \exp\{\lambda c\}\right] \\ &\leq \exp\{-\lambda c\} \mathbb{E}\left[\exp\left\{\lambda \sum_{i=1}^N (X_i - \mathbb{E}(X_i))\right\}\right] \\ &\leq \exp\{-\lambda c\} \prod_{i=1}^N \mathbb{E}\left[\exp\{\lambda (X_i - \mathbb{E}(X_i))\}\right] \\ &\leq \exp\{-\lambda c\} \prod_{i=1}^N \exp\left\{\frac{1}{8} \lambda^2 (b_i - a_i)^2\right\} \\ &\leq \exp\left\{-\lambda c + \frac{1}{8} \lambda^2 \sum_{i=1}^N (b_i - a_i)^2\right\}, \end{aligned}$$

compte tenu que

$$a_i - \mathbb{E}(X_i) \leq X_i - \mathbb{E}(X_i) \leq b_i - \mathbb{E}(X_i) ,$$

pour tout $i = 1, \dots, N$ (de sorte que l'oscillation est invariante par translation). Comme $\lambda > 0$ est arbitraire, la majoration reste encore valide avec la borne minimale, c'est-à-dire

$$\mathbb{P}\left[\sum_{i=1}^N (X_i - \mathbb{E}(X_i)) \geq c\right] \leq \min_{\lambda > 0} \exp\left\{-\lambda c + \frac{1}{8} \lambda^2 \sum_{i=1}^N (b_i - a_i)^2\right\} = \exp\left\{-\frac{2c^2}{\sum_{i=1}^N (b_i - a_i)^2}\right\} ,$$

obtenue pour la valeur $\lambda = \frac{4c}{\sum_{i=1}^N (b_i - a_i)^2}$. En posant $X'_i = -X_i$ et compte tenu que

$$-b_i + \mathbb{E}(X_i) \leq X'_i - \mathbb{E}(X'_i) = -(X_i - \mathbb{E}(X_i)) \leq -a_i + \mathbb{E}(X_i) ,$$

pour tout $i = 1, \dots, N$ (de sorte que l'oscillation est invariante par changement de signe), il vient

$$\mathbb{P}\left[\sum_{i=1}^N (X_i - \mathbb{E}(X_i)) \leq -c\right] = \mathbb{P}\left[\sum_{i=1}^N (X'_i - \mathbb{E}(X'_i)) \geq c\right] \leq \exp\left\{-\frac{2c^2}{\sum_{i=1}^N (b_i - a_i)^2}\right\} ,$$

et en combinant les deux majorations, on obtient

$$\begin{aligned} \mathbb{P}\left[\left|\sum_{i=1}^N (X_i - \mathbb{E}(X_i))\right| \geq c\right] &= \mathbb{P}\left[\sum_{i=1}^N (X_i - \mathbb{E}(X_i)) \geq c \text{ ou } \sum_{i=1}^N (X_i - \mathbb{E}(X_i)) \leq -c\right] \\ &= \mathbb{P}\left[\sum_{i=1}^N (X_i - \mathbb{E}(X_i)) \geq c\right] + \mathbb{P}\left[\sum_{i=1}^N (X_i - \mathbb{E}(X_i)) \leq -c\right] \\ &\leq 2 \exp\left\{-\frac{2c^2}{\sum_{i=1}^N (b_i - a_i)^2}\right\} . \quad \square \end{aligned}$$

Annexe C

Théorème central limite conditionnel

On regroupe dans cette annexe quelques versions du théorème central limite, en particulier une version conditionnelle formulée au Théorème C.9 qui sera typiquement utilisée dans le cas de variables aléatoires décomposées comme dans le résultat ci-dessous.

Lemme C.1 *Si conditionnellement par rapport à $\mathcal{F}_N$, la variable aléatoire Z'_N converge en distribution vers une variable aléatoire gaussienne centrée, de variance V' , au sens où pour tout réel u fixé*

$$\mathbb{E}[\exp\{j u Z'_N\} \mid \mathcal{F}_N] \longrightarrow \exp\{-\tfrac{1}{2} u^2 V'\} ,$$

en probabilité (et dans $\mathbb{L}^1$, par le théorème de convergence dominée de Lebesgue) quand $N \uparrow \infty$, et si la variable aléatoire Z''_N est mesurable par rapport à $\mathcal{F}_N$, et converge en distribution vers une variable aléatoire gaussienne centrée, de variance V'' , i.e. si pour tout réel w fixé

$$\mathbb{E}[\exp\{j w Z''_N\}] \longrightarrow \exp\{-\tfrac{1}{2} w^2 V''\} ,$$

quand $N \uparrow \infty$, alors le vecteur aléatoire (Z'_N, Z''_N) converge en distribution vers un vecteur aléatoire gaussien centré, de matrice de covariance bloc-diagonale

$$\begin{pmatrix} V' & 0 \\ 0 & V'' \end{pmatrix} ,$$

quand $N \uparrow \infty$. En particulier, la variable aléatoire $Z_N = Z'_N + Z''_N$ converge en distribution vers une variable aléatoire gaussienne centrée et de variance $V = V' + V''$, quand $N \uparrow \infty$.

PREUVE. Il suffit d'exploiter la décomposition suivante

$$\begin{aligned} & \mathbb{E}[\exp\{j (u Z'_N + w Z''_N)\}] - \exp\{-\tfrac{1}{2} (u^2 V' + w^2 V'')\} \\ &= \mathbb{E}[\mathbb{E}[\exp\{j u Z'_N\} \mid \mathcal{F}_N] \exp\{j w Z''_N\}] - \exp\{-\tfrac{1}{2} u^2 V'\} \exp\{-\tfrac{1}{2} w^2 V''\} \\ &= \mathbb{E}[(\mathbb{E}[\exp\{j u Z'_N\} \mid \mathcal{F}_N] - \exp\{-\tfrac{1}{2} u^2 V'\}) \exp\{j w Z''_N\}] \\ & \quad + \exp\{-\tfrac{1}{2} u^2 V'\} [\mathbb{E}[\exp\{j w Z''_N\}] - \exp\{-\tfrac{1}{2} w^2 V''\}] , \end{aligned}$$

et l'inégalité triangulaire entraîne aussitôt que

$$\begin{aligned} & | \mathbb{E}[\exp\{j(u Z'_N + w Z''_N)\}] - \exp\{-\frac{1}{2}(u^2 V' + w^2 V'')\} | \\ & \leq \mathbb{E} | \mathbb{E}[\exp\{j u Z'_N\} | \mathcal{F}_N] - \exp\{-\frac{1}{2} u^2 V'\} | \\ & \quad + | \mathbb{E}[\exp\{j w Z''_N\}] - \exp\{-\frac{1}{2} w^2 V''\} | , \end{aligned}$$

qui converge vers zéro quand $N \uparrow \infty$. □

Remarque C.2 Sous les hypothèses du Lemme A, et si la variable aléatoire c'_N converge en probabilité vers 1 quand $N \uparrow \infty$, alors la variable aléatoire $c'_N Z'_N + Z''_N$ converge en distribution vers une variable aléatoire gaussienne centrée et de variance $V = V' + V''$, quand $N \uparrow \infty$. Il suffit en effet de vérifier que

$$c'_N Z'_N + Z''_N = \begin{pmatrix} c'_N & 1 \end{pmatrix} \begin{pmatrix} Z'_N \\ Z''_N \end{pmatrix} ,$$

et d'appliquer le lemme de Slutsky.

On commence par rappeler des majorations bien connues.

Lemme C.3 *On a*

$$(i) \text{ pour tout réel positif } x \geq 0 \quad 0 \leq e^{-x} - (1 - x) \leq \frac{1}{2} x^2 ,$$

$$(ii) \text{ pour tous réels } x, x' \quad |e^{jx} - e^{jx'}| \leq |x - x'| ,$$

$$(iii) \text{ pour tous réels positifs } x, x' \geq 0 \quad |e^{-x} - e^{-x'}| \leq |x - x'| .$$

PREUVE. On définit

$$G_1(x) = e^{-x} - (1 - x) ,$$

pour tout $x \geq 0$, et on vérifie que

$$G'_1(x) = -e^{-x} + 1 \geq 0 ,$$

pour tout $x \geq 0$, de sorte que la fonction G_1 est croissante sur $[0, \infty)$ et $G_1(x) \geq G_1(0) = 0$, ce qui prouve la minoration. On définit ensuite

$$G_2(x) = e^{-x} - (1 - x) - \frac{1}{2} x^2 ,$$

pour tout $x \geq 0$, et on vérifie que

$$G'_2(x) = -e^{-x} + 1 - x = -G_1(x) \leq 0 ,$$

pour tout $x \geq 0$, de sorte que la fonction G_2 est décroissante sur $[0, \infty)$ et $G_2(x) \leq G_2(0) = 0$, ce qui prouve la majoration.

On définit

$$F(\lambda) = e^{j(\lambda x + (1-\lambda)x')} ,$$

pour tout $0 \leq \lambda \leq 1$, où x et x' sont fixés. On vérifie que

$$F'(\lambda) = j(x - x') e^{j(\lambda x + (1-\lambda)x')} ,$$

et on en déduit que

$$e^{jx} - e^{jx'} = F(1) - F(0) = \int_0^1 F'(\lambda) d\lambda = j(x - x') \int_0^1 e^{j(\lambda x' + (1-\lambda)x)} d\lambda ,$$

de sorte que

$$|e^{jx} - e^{jx'}| = |x - x'| \left| \int_0^1 e^{j(\lambda x' + (1-\lambda)x)} d\lambda \right| \leq |x - x'| .$$

On définit de même

$$F(\lambda) = e^{-(\lambda x + (1-\lambda)x')} ,$$

pour tout $0 \leq \lambda \leq 1$, où $x, x' \geq 0$ sont fixés. On vérifie que $\lambda x + (1 - \lambda) x' \geq 0$ et

$$F'(\lambda) = -(x - x') e^{-(\lambda x + (1-\lambda)x')} ,$$

et on en déduit que

$$e^{-x} - e^{-x'} = F(1) - F(0) = \int_0^1 F'(\lambda) d\lambda = -(x - x') \int_0^1 e^{-(\lambda x + (1-\lambda)x')} d\lambda ,$$

de sorte que

$$|e^{-x} - e^{-x'}| = |x - x'| \left| \int_0^1 e^{-(\lambda x + (1-\lambda)x')} d\lambda \right| \leq |x - x'| . \quad \square$$

Lemme C.4 *Soit X une variable aléatoire centrée, de variance s^2 . Alors*

$$R(u) = \frac{1}{u^2} |\mathbb{E}[\exp\{j u X\}] - (1 - \frac{1}{2} u^2 s^2)| \longrightarrow 0 ,$$

quand $u \rightarrow 0$.

PREUVE. D'après la formule de Taylor avec reste intégral

$$e^{jx} = 1 + jx - \int_0^1 (1 - \lambda) x^2 e^{j\lambda x} d\lambda = 1 + jx - \frac{1}{2} x^2 - \int_0^1 (1 - \lambda) x^2 [e^{j\lambda x} - 1] d\lambda ,$$

il vient

$$\mathbb{E}[\exp\{j u X\}] = 1 - \frac{1}{2} u^2 s^2 - u^2 \int_0^1 (1 - \lambda) \mathbb{E}[|X|^2 [\exp\{j \lambda u X\} - 1]] d\lambda ,$$

de sorte que

$$\frac{1}{u^2} |\mathbb{E}[\exp\{j u X\}] - (1 - \frac{1}{2} u^2 s^2)| \leq \int_0^1 (1 - \lambda) \mathbb{E}[|X|^2 | \exp\{j \lambda u X\} - 1|] d\lambda .$$

On définit

$$Z(u) = |X|^2 \int_0^1 (1 - \lambda) | \exp\{j \lambda u X\} - 1| d\lambda \leq |X|^2 ,$$

pour tout réel u , de sorte que la famille $(Z(u), u \in \mathbb{R})$ est uniformément intégrable, et on vérifie que $Z(u)$ converge vers 0 presque sûrement quand $u \rightarrow 0$. Il suffit alors d'appliquer le théorème de convergence dominée de Lebesgue pour conclure. $\square$

Lemme C.5 *Soit X une variable aléatoire centrée, de variance s^2 . Pour tout réel positif $c > 0$ et pour tout réel u*

$$\begin{aligned} |\mathbb{E}[\exp\{j u X\}] - (1 - \frac{1}{2} u^2 s^2)| &\leq \mathbb{E}[|X|^2 \min(\frac{1}{6} |u X|, 1)] u^2 \\ &\leq \frac{1}{6} c s^2 |u|^3 + \mathbb{E}[1_{(|X| > c)} |X|^2] u^2 . \end{aligned}$$

PREUVE. D'après la majoration classique rappelée dans le Lemme C.3–(ii), on a

$$\int_0^1 (1 - \lambda) |e^{j \lambda x} - 1| d\lambda \leq |x| \int_0^1 (1 - \lambda) \lambda d\lambda = \frac{1}{6} |x| ,$$

et on a aussi l'estimation grossière

$$\int_0^1 (1 - \lambda) |e^{j \lambda x} - 1| d\lambda \leq 2 \int_0^1 (1 - \lambda) d\lambda = 1 ,$$

de sorte que

$$\int_0^1 (1 - \lambda) |e^{j \lambda x} - 1| d\lambda = \min(\frac{1}{6} |x|, 1) .$$

D'après la formule de Taylor avec reste intégral

$$e^{j x} = 1 + j x - \int_0^1 (1 - \lambda) x^2 e^{j \lambda x} d\lambda = 1 + j x - \frac{1}{2} x^2 - \int_0^1 (1 - \lambda) x^2 [e^{j \lambda x} - 1] d\lambda ,$$

il vient

$$\mathbb{E}[\exp\{j u X\}] = 1 - \frac{1}{2} u^2 s^2 - u^2 \int_0^1 (1 - \lambda) \mathbb{E}[|X|^2 [\exp\{j \lambda u X\} - 1]] d\lambda ,$$

de sorte que

$$\begin{aligned} |\mathbb{E}[\exp\{j u X\}] - (1 - \frac{1}{2} u^2 s^2)| &\leq u^2 \int_0^1 (1 - \lambda) \mathbb{E}[|X|^2 | \exp\{j \lambda u X\} - 1|] d\lambda \\ &= u^2 \mathbb{E}[|X|^2 \int_0^1 (1 - \lambda) | \exp\{j \lambda u X\} - 1| d\lambda] \\ &\leq u^2 \mathbb{E}[|X|^2 \min(\frac{1}{6} |u X|, 1)] . \quad \square \end{aligned}$$

Remarque C.6 La majoration

$$\frac{1}{u^2} |\mathbb{E}[\exp\{j u X\}] - (1 - \frac{1}{2} u^2 s^2)| \leq \mathbb{E}[|X|^2 \min(\frac{1}{6} |u X|, 1)] ,$$

fournit une autre preuve du Lemme C.4. On définit

$$Z(u) = |X|^2 \min(\frac{1}{6} |u X|, 1) \leq |X|^2 ,$$

pour tout réel u , de sorte que la famille $(Z(u), u \in \mathbb{R})$ est uniformément intégrable, et on vérifie que $Z(u)$ converge vers 0 presque sûrement quand $u \rightarrow 0$. Il suffit alors d'appliquer le théorème de convergence dominée de Lebesgue pour conclure.

C.1 Variables aléatoires indépendantes identiquement distribuées

Théorème C.7 Soit $(X_1, \dots, X_N, \dots)$ une suite de variables aléatoires i.i.d. centrées et de variance s^2 . Alors

$$\frac{1}{\sqrt{N}} \sum_{i=1}^N X_i \Longrightarrow \mathcal{N}(0, s^2) ,$$

en distribution quand $N \uparrow \infty$.

PREUVE. D'après l'hypothèse d'indépendance, on a

$$\mathbb{E}[\exp\{j u \sum_{i=1}^N X_i\}] = \prod_{i=1}^N \mathbb{E}[\exp\{j u X_i\}] = (\mathbb{E}[\exp\{j u X\}])^N ,$$

où la variable aléatoire X est distribuée comme chacune des variables aléatoires $(X_1, \dots, X_N)$. D'après la majoration classique rappelée dans le Lemme C.3–(i) et en utilisant la notation introduite dans l'énoncé du Lemme C.4, on a

$$|\mathbb{E}[\exp\{j u X\}] - (1 - \frac{1}{2} u^2 s^2)| = R(u) u^2 ,$$

et

$$|\exp\{-\frac{1}{2} u^2 s^2\} - (1 - \frac{1}{2} u^2 s^2)| \leq \frac{1}{8} u^4 s^4 ,$$

et d'après l'inégalité triangulaire, on a

$$|\mathbb{E}[\exp\{j u X\}] - \exp\{-\frac{1}{2} u^2 s^2\}| \leq R(u) u^2 + \frac{1}{8} s^4 u^4 .$$

En utilisant la majoration

$$|a^N - b^N| \leq N |a - b| ,$$

valide pour tous nombres complexes a et b de module inférieur ou égal à 1, et en particulier valide pour

$$a = \mathbb{E}[\exp\{j u X\}] \quad \text{et} \quad b = \exp\{-\frac{1}{2} u^2 s^2\} ,$$

on obtient

$$\begin{aligned}
|\mathbb{E}[\exp\{j u \sum_{i=1}^N X_i\}] - \exp\{-\frac{1}{2} N u^2 s^2\}| &= |(\mathbb{E}[\exp\{j u X\}])^N - (\exp\{-\frac{1}{2} u^2 s^2\})^N| \\
&\leq N |\mathbb{E}[\exp\{j u X\}] - \exp\{-\frac{1}{2} u^2 s^2\}| \\
&\leq N R(u) u^2 + \frac{1}{8} N s^4 u^4,
\end{aligned}$$

et en posant $u = \frac{v}{\sqrt{N}}$ on obtient

$$|\mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^N X_i\}] - \exp\{-\frac{1}{2} v^2 s^2\}| \leq R(\frac{v}{\sqrt{N}}) v^2 + \frac{1}{8} \frac{s^4 v^4}{N}.$$

En utilisant le résultat du Lemme C.4, on en déduit que

$$\mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^N X_i\}] \longrightarrow \exp\{-\frac{1}{2} v^2 s^2\},$$

quand $N \uparrow \infty$. □

C.2 Suites triangulaires de variables aléatoires indépendantes

On considère ici le cas plus général d'un *tableau triangulaire* ou d'une *suite triangulaire* de variables indépendantes. Pour tout entier $N \geq 1$, c'est-à-dire pour toute ligne du tableau, les variables aléatoires $(X_{N,1}, \dots, X_{N,K_N})$ où $K_N \rightarrow \infty$ quand $N \rightarrow \infty$ sont indépendantes mais pas nécessairement identiquement distribuées. En outre, les variables figurant sur deux lignes différentes du tableau ne sont pas nécessairement indépendantes, ni nécessairement définies sur le même espace de probabilité, c'est-à-dire qu'il peut y avoir un espace de probabilité différent pour chaque ligne du tableau.

Théorème C.8 *Soit $(X_{N,1}, \dots, X_{N,K_N})$ une suite triangulaire de variables aléatoires indépendantes et centrées. On pose*

$$s_{N,i}^2 = \mathbb{E}|X_{N,i}|^2 \quad \text{et pour tout } c > 0 \quad F_{N,i}(c) = \mathbb{E}[1_{(|X_{N,i}| > c)} |X_{N,i}|^2],$$

pour tout $i = 1, \dots, K_N$. Si

$$s_N^2 = \frac{1}{N} \sum_{i=1}^{K_N} s_{N,i}^2 \longrightarrow s^2,$$

quand $N \uparrow \infty$, et si pour tout $\varepsilon > 0$

$$F_N(\varepsilon) = \frac{1}{N} \sum_{i=1}^{K_N} F_{N,i}(\varepsilon \sqrt{N}) = \sum_{i=1}^{K_N} \mathbb{E}[1_{(|\frac{X_{N,i}}{\sqrt{N}}| > \varepsilon)} |\frac{X_{N,i}}{\sqrt{N}}|^2] \longrightarrow 0, \quad (\text{C.1})$$

quand $N \uparrow \infty$, alors

$$\frac{1}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i} \Longrightarrow \mathcal{N}(0, s^2) ,$$

en distribution quand $N \uparrow \infty$.

PREUVE. D'après l'hypothèse d'indépendance, on a

$$\mathbb{E}[\exp\{j u \sum_{i=1}^{K_N} X_{N,i}\}] = \prod_{i=1}^{K_N} \mathbb{E}[\exp\{j u X_{N,i}\}] .$$

D'après les majorations classiques rappelées dans les Lemmes C.5 et C.3-(i), on a

$$|\mathbb{E}[\exp\{j u X_{N,i}\}] - (1 - \frac{1}{2} u^2 s_{N,i}^2)| \leq \frac{1}{6} c s_{N,i}^2 |u|^3 + \mathbb{E}[1_{(|X_{N,i}| > c)} |X_{N,i}|^2] u^2 ,$$

et

$$|\exp\{-\frac{1}{2} u^2 s_{N,i}^2\} - (1 - \frac{1}{2} u^2 s_{N,i}^2)| \leq \frac{1}{8} u^4 s_{N,i}^4 ,$$

et d'après l'inégalité triangulaire, on a

$$|\mathbb{E}[\exp\{j u X_{N,i}\}] - \exp\{-\frac{1}{2} u^2 s_{N,i}^2\}| \leq \frac{1}{6} c s_{N,i}^2 |u|^3 + F_{N,i}(c) u^2 + \frac{1}{8} s_{N,i}^4 u^4 ,$$

pour tout $i = 1, \dots, K_N$. En utilisant la majoration

$$|a_1 \cdots a_{K_N} - b_1 \cdots b_{K_N}| = |\sum_{i=1}^{K_N} a_1 \cdots a_{i-1} (a_i - b_i) b_{i+1} \cdots b_{K_N}| \leq \sum_{i=1}^{K_N} |a_i - b_i| ,$$

valide pour tous nombres complexes $a_1, \dots, a_{K_N}$ et $b_1, \dots, b_{K_N}$ de module inférieur ou égal à 1, et en particulier valide pour

$$a_i = \mathbb{E}[\exp\{j u X_{N,i}\}] \quad \text{et} \quad b_i = \exp\{-\frac{1}{2} u^2 s_{N,i}^2\} ,$$

pour tout $i = 1, \dots, K_N$, on obtient

$$\begin{aligned} & |\mathbb{E}[\exp\{j u \sum_{i=1}^{K_N} X_{N,i}\}] - \exp\{-\frac{1}{2} N u^2 s_N^2\}| \\ &= |\prod_{i=1}^{K_N} \mathbb{E}[\exp\{j u X_{N,i}\}] - \prod_{i=1}^{K_N} \exp\{-\frac{1}{2} u^2 s_{N,i}^2\}| \\ &\leq \sum_{i=1}^{K_N} |\mathbb{E}[\exp\{j u X_{N,i}\}] - \exp\{-\frac{1}{2} u^2 s_{N,i}^2\}| \\ &\leq \frac{1}{6} c \sum_{i=1}^{K_N} s_{N,i}^2 |u|^3 + \sum_{i=1}^{K_N} F_{N,i}(c) u^2 + \frac{1}{8} \sum_{i=1}^{K_N} s_{N,i}^4 u^4 . \end{aligned}$$

On remarque que

$$s_{N,i}^2 = \mathbb{E}[1(|X_{N,i}| \leq c) |X_{N,i}|^2] + \mathbb{E}[1(|X_{N,i}| > c) |X_{N,i}|^2] \leq c^2 + F_{N,i}(c) \leq c^2 + \sum_{i=1}^{K_N} F_{N,i}(c) ,$$

pour tout $i = 1, \dots, K_N$, et on en déduit que

$$\sum_{i=1}^{K_N} s_{N,i}^4 \leq (c^2 + \sum_{i=1}^{K_N} F_{N,i}(c)) \sum_{i=1}^{K_N} s_{N,i}^2 .$$

On obtient ainsi

$$\begin{aligned} & | \mathbb{E}[\exp\{j u \sum_{i=1}^{K_N} X_{N,i}\}] - \exp\{-\frac{1}{2} N u^2 s_N^2\} | \\ & \leq \frac{1}{6} c N s_N^2 |u|^3 + \sum_{i=1}^{K_N} F_{N,i}(c) u^2 + \frac{1}{8} (c^2 + \sum_{i=1}^{K_N} F_{N,i}(c)) N s_N^2 u^4 , \end{aligned}$$

et en posant $u = \frac{v}{\sqrt{N}}$ et $c = \varepsilon \sqrt{N}$ on obtient

$$\begin{aligned} & | \mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\}] - \exp\{-\frac{1}{2} v^2 s_N^2\} | \\ & \leq \frac{1}{6} \varepsilon s_N^2 |v|^3 + F_N(\varepsilon) v^2 + \frac{1}{8} (\varepsilon^2 + F_N(\varepsilon)) s_N^2 v^4 . \end{aligned} \tag{C.2}$$

D'après la majoration classique rappelée dans le Lemme C.3-(iii), on a

$$| \exp\{-\frac{1}{2} v^2 s_N^2\} - \exp\{-\frac{1}{2} v^2 s^2\} | \leq \frac{1}{2} v^2 |s_N^2 - s^2| ,$$

et d'après l'inégalité triangulaire, on a

$$\begin{aligned} & | \mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\}] - \exp\{-\frac{1}{2} v^2 s^2\} | \\ & \leq \frac{1}{6} \varepsilon s_N^2 |v|^3 + F_N(\varepsilon) v^2 + \frac{1}{8} (\varepsilon^2 + F_N(\varepsilon)) s_N^2 v^4 + \frac{1}{2} v^2 |s_N^2 - s^2| . \end{aligned}$$

Il résulte des hypothèses, et en particulier de l'hypothèse de Lindeberg (C.1), que

$$\limsup_{N \uparrow \infty} | \mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\}] - \exp\{-\frac{1}{2} v^2 s^2\} | \leq \frac{1}{6} \varepsilon s^2 |v|^3 + \frac{1}{8} \varepsilon^2 s^2 v^4 ,$$

et comme $\varepsilon > 0$ peut être choisi arbitrairement petit, on en déduit que

$$\mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\}] \longrightarrow \exp\{-\frac{1}{2} v^2 s^2\} ,$$

quand $N \uparrow \infty$. □

C.3 Version conditionnelle

Théorème C.9 *On suppose que conditionnellement par rapport à $\mathcal{F}_N$, les variables aléatoires $(X_{N,1}, \dots, X_{N,K_N})$ sont indépendantes et centrées, et on pose*

$$s_{N,i}^2 = \mathbb{E}[|X_{N,i}|^2 \mid \mathcal{F}_N] \quad \text{et pour tout } c > 0 \quad F_{N,i}(c) = \mathbb{E}[1_{(|X_{N,i}| > c)} |X_{N,i}|^2 \mid \mathcal{F}_N] ,$$

pour tout $i = 1, \dots, K_N$. Si

$$s_N^2 = \frac{1}{N} \sum_{i=1}^{K_N} s_{N,i}^2 \longrightarrow s^2 ,$$

en probabilité quand $N \uparrow \infty$, et si pour tout $\varepsilon > 0$

$$F_N(\varepsilon) = \frac{1}{N} \sum_{i=1}^{K_N} F_{N,i}(\varepsilon \sqrt{N}) = \sum_{i=1}^N \mathbb{E}[1_{(|\frac{X_{N,i}}{\sqrt{N}}| > \varepsilon)} |\frac{X_{N,i}}{\sqrt{N}}|^2 \mid \mathcal{F}_N] \longrightarrow 0 , \quad (\text{C.3})$$

en probabilité quand $N \uparrow \infty$, alors pour tout réel v

$$\mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] \longrightarrow \exp\{-\frac{1}{2} v^2 s^2\} , \quad (\text{C.4})$$

en probabilité quand $N \uparrow \infty$.

PREUVE. D'après l'hypothèse d'indépendance conditionnelle, on a

$$\mathbb{E}[\exp\{j u \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] = \prod_{i=1}^{K_N} \mathbb{E}[\exp\{j u X_{N,i}\} \mid \mathcal{F}_N] .$$

En suivant les étapes de la preuve du Théorème C.8, et en utilisant la majoration (C.2), on obtient

$$\begin{aligned} & | \mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] - \exp\{-\frac{1}{2} v^2 s_N^2\} | \\ & \leq \frac{1}{6} \varepsilon s_N^2 |v|^3 + F_N(\varepsilon) v^2 + \frac{1}{8} (\varepsilon^2 + F_N(\varepsilon)) s_N^2 v^4 . \end{aligned}$$

D'après la majoration classique rappelée dans le Lemme C.3-(iii), on a

$$| \exp\{-\frac{1}{2} v^2 s_N^2\} - \exp\{-\frac{1}{2} v^2 s^2\} | \leq \frac{1}{2} v^2 |s_N^2 - s^2| ,$$

et d'après l'inégalité triangulaire, on a

$$\begin{aligned} & | \mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] - \exp\{-\frac{1}{2} v^2 s^2\} | \\ & \leq \frac{1}{6} \varepsilon s_N^2 |v|^3 + F_N(\varepsilon) v^2 + \frac{1}{8} (\varepsilon^2 + F_N(\varepsilon)) s_N^2 v^4 + \frac{1}{2} v^2 |s_N^2 - s^2| . \end{aligned}$$

Il résulte des hypothèses, et en particulier de l'hypothèse de Lindeberg conditionnelle (C.3), que pour tout $\varepsilon > 0$

$$\begin{aligned} \Delta_N(\varepsilon) &= \frac{1}{6} \varepsilon s_N^2 |v|^3 + F_N(\varepsilon) v^2 + \frac{1}{8} (\varepsilon^2 + F_N(\varepsilon)) s_N^2 v^4 + \frac{1}{2} v^2 |s_N^2 - s^2| \\ &\longrightarrow \Delta(\varepsilon) = \frac{1}{6} \varepsilon s^2 |v|^3 + \frac{1}{8} \varepsilon^2 s^2 v^4, \end{aligned}$$

en probabilité quand $N \uparrow \infty$. Soit $\eta > 0$ fixé. On rappelle que le réel v est aussi fixé. Il existe alors $\varepsilon = \varepsilon(\eta) > 0$ tel que

$$\Delta(\varepsilon) = \frac{1}{6} \varepsilon s^2 |v|^3 + \frac{1}{8} \varepsilon^2 s^2 v^4 < \frac{1}{2} \eta.$$

Avec ce choix pour $\varepsilon > 0$, on a

$$\begin{aligned} &| \mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] - \exp\{-\frac{1}{2} v^2 s^2\} | \\ &\leq \Delta_N(\varepsilon) \leq \Delta(\varepsilon) + |\Delta_N(\varepsilon) - \Delta(\varepsilon)| \leq \frac{1}{2} \eta + |\Delta_N(\varepsilon) - \Delta(\varepsilon)|. \end{aligned}$$

On en déduit que

$$\mathbb{P}[| \mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] - \exp\{-\frac{1}{2} v^2 s^2\} | > \eta] \leq \mathbb{P}[|\Delta_N(\varepsilon) - \Delta(\varepsilon)| > \frac{1}{2} \eta],$$

de sorte que

$$\mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] \longrightarrow \exp\{-\frac{1}{2} v^2 s^2\},$$

en probabilité quand $N \uparrow \infty$. □

Remarque C.10 Si les variables aléatoires $(X_{N,1}, \dots, X_{N,K_N})$ vérifient la condition de Lyapunov conditionnelle : pour un certain $\delta > 0$

$$\sum_{i=1}^{K_N} \mathbb{E}[|\frac{X_{N,i}}{\sqrt{N}}|^{2+\delta} \mid \mathcal{F}_N] \longrightarrow 0, \quad (\text{C.5})$$

en probabilité quand $N \uparrow \infty$, et compte tenu que

$$|x|^{2+\delta} \geq |x|^{2+\delta} 1_{(|x| > \varepsilon)} \geq \varepsilon^\delta |x|^2 1_{(|x| > \varepsilon)},$$

pour tout réel x et pour tout $\varepsilon > 0$, alors

$$F_N(\varepsilon) = \sum_{i=1}^{K_N} \mathbb{E}[1_{(|\frac{X_{N,i}}{\sqrt{N}}| > \varepsilon)} |\frac{X_{N,i}}{\sqrt{N}}|^2 \mid \mathcal{F}_N] \leq \frac{1}{\varepsilon^\delta} \sum_{i=1}^{K_N} \mathbb{E}[|\frac{X_{N,i}}{\sqrt{N}}|^{2+\delta} \mid \mathcal{F}_N] \longrightarrow 0,$$

en probabilité quand $N \uparrow \infty$, c'est-à-dire que la condition de Lindeberg conditionnelle (C.3) est vérifiée. On peut alors appliquer le Théorème C.9, et dans le cas particulier où la condition de Lyapunov conditionnelle (C.5) est vérifiée pour $\delta = 1$, c'est-à-dire où

$$\sum_{i=1}^{K_N} \mathbb{E} \left[\left| \frac{X_{N,i}}{\sqrt{N}} \right|^3 \mid \mathcal{F}_N \right] \longrightarrow 0 ,$$

en probabilité quand $N \uparrow \infty$, il est facile de montrer directement le résultat (C.4), sans devoir passer par l'intermédiaire du Théorème C.9.

Remarque C.11 Si les variables aléatoires $(X_{N,1}, \dots, X_{N,K_N})$ sont bornées, i.e. si $|X_{N,i}| \leq c$ pour tout $i = 1, \dots, K_N$, alors

$$F_N(\varepsilon) = \sum_{i=1}^{K_N} \mathbb{E} \left[1_{\left(\left| \frac{X_{N,i}}{\sqrt{N}} \right| > \varepsilon \right)} \left| \frac{X_{N,i}}{\sqrt{N}} \right|^2 \mid \mathcal{F}_N \right] \leq \frac{c^2}{N} \sum_{i=1}^{K_N} \mathbb{P} \left[\left| \frac{X_{N,i}}{\sqrt{N}} \right| > \varepsilon \mid \mathcal{F}_N \right] ,$$

et on remarque que si $N \geq \frac{c^2}{\varepsilon^2}$, alors

$$\mathbb{P} \left[\left| \frac{X_{N,i}}{\sqrt{N}} \right| > \varepsilon \mid \mathcal{F}_N \right] \leq \mathbb{P} \left[|X_{N,i}| > c \mid \mathcal{F}_N \right] = 0 ,$$

pour tout $i = 1, \dots, K_N$, de sorte que

$$F_N(\varepsilon) \leq \varepsilon^2 \sum_{i=1}^{K_N} \mathbb{P} \left[|X_{N,i}| > c \mid \mathcal{F}_N \right] = 0 ,$$

c'est-à-dire que la condition de Lindeberg conditionnelle (C.3) est vérifiée. On peut alors appliquer le Théorème C.9, même si dans ce cas particulier il est facile de démontrer directement le résultat (C.4), sans devoir passer par l'intermédiaire du Théorème C.9.

De même

$$\sum_{i=1}^{K_N} \mathbb{E} \left[\left| \frac{X_{N,i}}{\sqrt{N}} \right|^{2+\delta} \mid \mathcal{F}_N \right] \leq c^{2+\delta} \left(\frac{1}{\sqrt{N}} \right)^\delta \frac{K_N}{N} ,$$

c'est-à-dire que la condition de Lyapunov conditionnelle (C.5) est vérifiée si $\limsup_{N \uparrow \infty} \frac{K_N}{N} < \infty$.

Théorème C.12 On suppose que conditionnellement par rapport à $\mathcal{F}_N$, les variables aléatoires $(X_{N,1}, \dots, X_{N,K_N})$ sont indépendantes, centrées et bornées, et on pose

$$s_{N,i}^2 = \mathbb{E} \left[|X_{N,i}|^2 \mid \mathcal{F}_N \right] \quad \text{et} \quad |X_{N,i}| \leq c ,$$

pour tout $i = 1, \dots, K_N$. Si

$$s_N^2 = \frac{1}{N} \sum_{i=1}^{K_N} s_{N,i}^2 \longrightarrow s^2 ,$$

en probabilité quand $N \uparrow \infty$, alors

$$\mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] \longrightarrow \exp\{-\frac{1}{2} v^2 s^2\} ,$$

en probabilité quand $N \uparrow \infty$.

PREUVE. D'après l'hypothèse d'indépendance conditionnelle, on a

$$\mathbb{E}[\exp\{j u \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] = \prod_{i=1}^{K_N} \mathbb{E}[\exp\{j u X_{N,i}\} \mid \mathcal{F}_N] .$$

D'après les majorations classiques

$$| \mathbb{E}[\exp\{j u X_{N,i}\} \mid \mathcal{F}_N] - (1 - \frac{1}{2} u^2 s_{N,i}^2) | \leq \frac{1}{6} \mathbb{E}[|u X_{N,i}|^3 \mid \mathcal{F}_N] \leq \frac{1}{6} c s_{N,i}^2 |u|^3 ,$$

et

$$| \exp\{-\frac{1}{2} u^2 s_{N,i}^2\} - (1 - \frac{1}{2} u^2 s_{N,i}^2) | \leq \frac{1}{8} u^4 s_{N,i}^4 \leq \frac{1}{8} c^2 u^4 s_{N,i}^2 ,$$

et d'après l'inégalité triangulaire, on a

$$| \mathbb{E}[\exp\{j u X_{N,i}\} \mid \mathcal{F}_N] - \exp\{-\frac{1}{2} u^2 s_{N,i}^2\} | \leq \frac{1}{6} c s_{N,i}^2 |u|^3 + \frac{1}{8} c^2 s_{N,i}^2 u^4 .$$

En utilisant la majoration

$$|a_1 \cdots a_{K_N} - b_1 \cdots b_{K_N}| = | \sum_{i=1}^{K_N} a_1 \cdots a_{i-1} (a_i - b_i) b_{i+1} \cdots b_{K_N} | \leq \sum_{i=1}^{K_N} |a_i - b_i| ,$$

valide pour tous nombres complexes $a_1, \dots, a_{K_N}$ et $b_1, \dots, b_{K_N}$ de module inférieur ou égal à 1, et en particulier valide pour

$$a_i = \mathbb{E}[\exp\{j u X_{N,i}\} \mid \mathcal{F}_N] \quad \text{et} \quad b_i = \exp\{-\frac{1}{2} u^2 s_{N,i}^2\} ,$$

pour tout $i = 1, \dots, K_N$, on obtient

$$\begin{aligned} & | \mathbb{E}[\exp\{j u \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] - \exp\{-\frac{1}{2} N u^2 s_N^2\} | \\ &= | \prod_{i=1}^{K_N} \mathbb{E}[\exp\{j u X_{N,i}\} \mid \mathcal{F}_N] - \prod_{i=1}^{K_N} \exp\{-\frac{1}{2} u^2 s_{N,i}^2\} | \\ &\leq \sum_{i=1}^{K_N} | \mathbb{E}[\exp\{j u X_{N,i}\} \mid \mathcal{F}_N] - \exp\{-\frac{1}{2} u^2 s_{N,i}^2\} | \\ &\leq \frac{1}{6} c \sum_{i=1}^{K_N} s_{N,i}^2 |u|^3 + \frac{1}{8} c^2 \sum_{i=1}^{K_N} s_{N,i}^2 u^4 \\ &\leq \frac{1}{6} c N s_N^2 |u|^3 + \frac{1}{8} c^2 N s_N^2 u^4 , \end{aligned}$$

et en posant $u = \frac{v}{\sqrt{N}}$ on obtient

$$\begin{aligned} & | \mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\} \mid \mathcal{F}_N] - \exp\{-\frac{1}{2} v^2 s_N^2\} | \\ & \leq \frac{1}{6} \frac{c s_N^2}{\sqrt{N}} |v|^3 + \frac{1}{8} \frac{c^2 s_N^2}{N} v^4 , \end{aligned}$$

D'après la majoration classique rappelée dans le Lemme C.3-(iii), on a

$$| \exp\{-\frac{1}{2} v^2 s_N^2\} - \exp\{-\frac{1}{2} v^2 s^2\} | \leq \frac{1}{2} v^2 |s_N^2 - s^2| ,$$

et d'après l'inégalité triangulaire, on a

$$\begin{aligned} & | \mathbb{E}[\exp\{j \frac{v}{\sqrt{N}} \sum_{i=1}^{K_N} X_{N,i}\}] - \exp\{-\frac{1}{2} v^2 s^2\} | \\ & \leq \frac{1}{6} \frac{c s_N^2}{\sqrt{N}} |v|^3 + \frac{1}{8} \frac{c^2 s_N^2}{N} v^4 + \frac{1}{2} v^2 |s_N^2 - s^2| \longrightarrow 0 , \end{aligned}$$

en probabilité quand $N \uparrow \infty$.

□

Bibliographie

- [1] Brian D. O. Anderson and John B. Moore. *Optimal filtering*. Prentice–Hall Information and System Sciences Series. Prentice–Hall, Englewood Cliffs, NJ, 1979.
- [2] M. Sanjeev Arulampalam, Simon Maskell, Neil J. Gordon, and Tim Clapp. A tutorial on particle filters for online nonlinear / non–Gaussian Bayesian tracking. *IEEE Transactions on Signal Processing*, SP–50(2 (Special issue on Monte Carlo Methods for Statistical Signal Processing)) :174–188, February 2002.
- [3] Nathalie Bartoli and Pierre Del Moral. *Simulation et algorithmes stochastiques*. Cépaduès, Toulouse, 2001.
- [4] Niclas Bergman. Posterior Cramér–Rao bounds for sequential estimation. In Arnaud Doucet, Nando de Freitas, and Neil Gordon, editors, *Sequential Monte Carlo methods in practice*, Statistics for Engineering and Information Science, chapter 15, pages 321–338. Springer–Verlag, New York, 2001.
- [5] Olivier Cappé, Simon J. Godsill, and Éric Moulines. An overview of existing methods and recent advances in sequential Monte Carlo. *Proceedings of the IEEE*, 95(5 (Special issue on Large–Scale Dynamic Systems)) :899–924, May 2007.
- [6] Olivier Cappé, Éric Moulines, and Tobias Rydén. *Inference in hidden Markov models*. Springer Series in Statistics. Springer–Verlag, New York, 2005.
- [7] Nicolas Chopin and Omiros Papaspiliopoulos. *An introduction to sequential Monte Carlo*. Springer Series in Statistics. Springer–Verlag, 2020.
- [8] Dan Crisan and Arnaud Doucet. A survey of convergence results on particle filtering methods for practitioners. *IEEE Transactions on Signal Processing*, 50(3) :736–746, March 2002.
- [9] Pierre Del Moral. *Feynman–Kac formulae. Genealogical and interacting particle systems with applications*. Probability and its Applications. Springer–Verlag, New York, 2004.
- [10] Luc Devroye. *Non–uniform random variate generation*. Springer–Verlag, New York, 1986.
- [11] Randal Douc, Olivier Cappé, and Éric Moulines. Comparison of resampling schemes for particle filtering. In *Proceedings of the 4th Symposium on Image and Signal Processing and Analysis, Zagreb 2005*, pages 64–69. IEEE–SPS, September 2005.

- [12] Randal Douc and Éric Moulines. Limit theorems for weighted samples with applications to sequential Monte Carlo methods. *The Annals of Statistics*, 36(5) :2344–2376, October 2008.
- [13] Randal Douc, Éric Moulines, and David S. Stoffer. *Nonlinear time series : Theory, methods and applications with R examples*. Texts in Statistical Science. Chapman & Hall / CRC Press, Boca Raton, 2014.
- [14] Arnaud Doucet and Christophe Andrieu. Particle filters for partially observed Gaussian state space models. *Journal of the Royal Statistical Society, Series B*, 64(4) :827–836, December 2002.
- [15] Arnaud Doucet, Nando de Freitas, and Neil Gordon, editors. *Sequential Monte Carlo methods in practice*. Statistics for Engineering and Information Science. Springer–Verlag, New York, 2001.
- [16] Arnaud Doucet, Simon J. Godsill, and Christophe Andrieu. On sequential Monte Carlo sampling methods for Bayesian filtering. *Statistics and Computing*, 10(3) :197–208, July 2000.
- [17] Fredrik Gustafsson, Fredrik Gunnarsson, Niclas Bergman, Urban Forssell, Jonas Jansson, Rickard Karlsson, and Per-Johan Nordlund. Particle filters for positioning, navigation, and tracking. *IEEE Transactions on Signal Processing*, SP–50(2 (Special issue on Monte Carlo Methods for Statistical Signal Processing)) :425–437, February 2002.
- [18] Allan Gut. *Probability : A graduate course*. Springer Texts in Statistics. Springer–Verlag, New York, 2005.
- [19] Hans R. Künsch. Recursive Monte Carlo filters : Algorithms and theoretical analysis. *The Annals of Statistics*, 33(5) :1983–2021, October 2005.
- [20] Jun S. Liu. *Monte Carlo strategies in scientific computing*. Springer Series in Statistics. Springer–Verlag, New York, 2001.
- [21] Patrick Pérez, Carine Hue, Jaco Vermaak, and Michel Gangnet. Color-based probabilistic tracking. In Anders Heyden, Gunnar Sparr, Mads Nielsen, and Peter Johansen, editors, *Proceedings of the 7th European Conference on Computer Vision (ECCV’02), Copenhagen 2002*, volume 2350 of *Lecture Notes in Computer Science*, pages 661–675. Springer–Verlag, Berlin, June 2002.
- [22] Dinh-Tuan Pham. Stochastic methods for sequential data assimilation in strongly nonlinear systems. *Monthly Weather Review*, 129(5) :1194–1207, May 2001.
- [23] Branko Ristić, M. Sanjeev Arulampalam, and Neil J. Gordon. *Beyond the Kalman filter : Particle filters for tracking applications*. Artech House, Boston, 2004.
- [24] Christian P. Robert and George Casella. *Monte Carlo statistical methods*. Springer Texts in Statistics. Springer–Verlag, New York, 2nd edition, 2004.

- [25] Thomas B. Schön, Fredrik Gustafsson, and Per-Johan Nordlund. Marginalized particle filters for mixed linear / nonlinear state-space models. *IEEE Transactions on Signal Processing*, SP-53(7) :2279–2289, July 2005.
- [26] Sebastian Thrun, Wolfram Burgard, and Dieter Fox. *Probabilistic robotics*. Intelligent Robotics and Autonomous Agents. The MIT Press, Cambridge, MA, 2005.
- [27] Petr Tichavský, Carlos H. Muravchik, and Arye Nehorai. Posterior Cramér–Rao bounds for discrete-time nonlinear filtering. *IEEE Transactions on Signal Processing*, SP-46(5) :1386–1396, May 1998.
- [28] Miroslav Šimandl, Jakub Královec, and Petr Tichavský. Filtering, predictive and smoothing Cramér–Rao bounds for discrete-time nonlinear dynamic systems. *Automatica*, 37(11) :1703–1716, November 2001.