

Premières réflexions sur l'analyse de l'erreur du krigeage

Analyse de l'erreur de krigeage

Majoration de l'erreur sur RKHS

$$|f(x) - \tilde{f}(x)| \leq \|f\|_{\mathcal{H}} \sqrt{K(x, x) - u(x)^T \Sigma^{-1} u(x)}$$

avec

$$u(x) = [K(x^1, x), \dots, K(x^n, x)]^T \text{ et } \Sigma_{i,j} = K(x^i, x^j)$$

Caractérisation de l'erreur

$$|e(x)| \leq \max_{x' \in \Omega} \sqrt{K(x, x) - u(x)^T \Sigma_{\Omega}^{-1} u(x)}$$

Domaine clustérisé (MeanShift)

$$e_{\text{cluster}}(x) = \sqrt{K(x, x) - u_c(x)^T \Sigma_{\Omega_c}^{-1} u_c(x)}$$

Enveloppe de Minkowski

$$e_{\text{Minkowski}}(x) = \sqrt{K(x, x) - u_{\epsilon}(x)^T \Sigma_{\Omega_{\epsilon}}^{-1} u_{\epsilon}(x)}$$

Caractérisation de l'erreur

Ratio des bornes :

$$R(x) = \frac{e_{\text{Minkowski}}(x)}{e_{\text{cluster}}(x)}$$

On a 3 cas intéressants :

- $R(x) \approx 1$: si les points proches dominant (haute densité locale) ;
- $R(x) < 1$: si les points lointains sont importants ;
- $R(x) \ll 1$: si les points proches sont clairsemés (clusters inefficaces).

Caractérisation de l'erreur

Ratio en fonction du covering number :

Par définition, on a

$$e(x) \leq C(K) \varepsilon \sqrt{\frac{1}{N_\varepsilon}}$$

En substituant dans les formules précédentes, on obtient alors :

$$R(x) = \sqrt{\frac{N_\varepsilon(\Omega_c)}{N_\varepsilon(\mathcal{M}_\varepsilon)}}$$

$N_\varepsilon(\mathcal{M}_\varepsilon) > N_\varepsilon(\Omega_c)$ (Minkowski englobe l'ensemble du domaine)

Caractérisation de l'erreur

Par définition, on a

$$N_{\epsilon}(\mathcal{M}_{\epsilon}) \propto (1/\epsilon)^d \text{ et } N_{\epsilon}(\Omega_c) \propto (1/\epsilon)^{d'}$$

Le ratio s'écrit alors sous la forme suivante :

$$R(x) \propto \sqrt{\left(\frac{1}{\epsilon}\right)^{d'-d}} = \frac{1}{\epsilon^{(d'-d)/2}}$$

Si d' est plus petit que d dans les faibles dimensions (clusters concentrés dans des sous espaces), $R(x) < 1$