

Algorithmes de Navigation par Champ Magnétique Terrestre pour des Véhicules Aérospatiaux

Avancement des travaux de recherche - Première année

Bastien HUBERT^{1, 2} - doctorant

Audrey GIREMUS² - directrice de thèse

Karim DAHIA¹ - co-directeur de thèse

Nicolas MERLINGE¹ - encadrant de thèse

¹ONERA, DTIS, IGNC ²Université de Bordeaux, CNRS, IMS

ONERA, 14 juin 2024

Thèse commencée le 6 novembre 2023

Contexte de la thèse

Enjeux de la navigation inertielle

- Fonctionne par intégration de mesures issues des accéléromètres et gyromètres d'une centrale inertielle
- Autonome et fiable sur des missions courtes
- Mais basé sur des mesures imparfaites (biais, facteurs d'échelle, bruits, ...)
- Engendre une solution qui dérive dans le temps

Fusion de données

- Utiliser des données issues d'autres capteurs aide à réduire la dérive
- Souvent par GNSS, mais données potentiellement bruitées ou indisponibles
- Sinon, recalage par champs (altimétrique, magnétique, gravitationnel, ...)
- Comparaison entre une mesure d'environnement et une carte embarquée

Travaux de première année : Navigation par recalage altimétrique




Corrélation de terrain (TAN)

- Mesure de l'élévation du terrain sous le véhicule
- Comparaison à une carte altimétrique

Défis

- Incertitude sur la position initiale grande
- Absence de modèle analytique
- Champ potentiellement bruité et peu résolu, ou carte trop lourde à embarquer



Filtrage bayésien

Représentation dans l'espace d'état

- $$\begin{cases} x_k = f_k(x_{k-1}, u_k, w_k) & \text{modèle d'évolution} \\ z_k = h_k(x_k, n_k) & \text{modèle d'observation} \end{cases}$$

Filtrage bayésien optimal

- But : estimer $\hat{x}_k = \mathbb{E}(x_k | z_{1:k}) = \int x_k p(x_k | z_{1:k}) dx_k$
- Prédiction avec l'équation de Chapman-Kolmogorov :

$$p(x_k | z_{1:k-1}) = \int p(x_k | x_{k-1}) p(x_{k-1} | z_{1:k-1}) dx_{k-1}$$


- Correction par théorème de Bayes :

$$p(x_k | z_{1:k}) = \frac{p(z_k | x_k) p(x_k | z_{1:k-1})}{\int p(z_k | x_k) p(x_k | z_{1:k-1}) dx_k}$$

Filtrage analytique

Filtre de Kalman

- Estimation analytique optimale sous hypothèses fortes :
- Équations linéaires et bruits gaussiens
- Peut être étendu au cas non-linéaire



Limites

- Perte d'optimalité en cas de non-linéarités
 - Gère mal les ambiguïtés et les multimodalités
- ⇒ Filtres stochastiques meilleurs dans ces cas

Filtrage stochastique (1/2)

Filtrage particulaire standard

- Asymptotiquement optimal et hypothèses très faibles : f_k et h_k connues
- Échantillonnage préférentiel : extension des méthodes de Monte-Carlo
- Approximation de la loi a posteriori par une mixture de Dirac :

$$p(x_k | z_{1:k}) \approx \sum_{i=1}^{N_p} w_k^{(i)} \delta(x_k - x_k^{(i)})$$


- Prédiction : $x_k^{(i)} \sim q(\cdot | x_{k-1}^{(i)}, z_k)$
- Correction : $w_k^{(i)} \propto w_{k-1}^{(i)} \frac{p(z_k | x_k^{(i)}) p(x_k^{(i)} | x_{k-1}^{(i)})}{q(x_k^{(i)} | x_{k-1}^{(i)}, z_k)}$
- Usuellement, on prend $q(x_k^{(i)} | x_{k-1}^{(i)}, z_k) = p(x_k^{(i)} | x_{k-1}^{(i)})$

Filtrage stochastique (2/2)


Filtrage particulaire régularisé

- Dégénérescence des poids à cause du choix de $q \rightarrow$ rééchantillonnage
- Perte de la diversité particulaire due à la duplication $\rightarrow$ régularisation
- L'estimateur de l'état du véhicule devient alors :

$$p(x_k | z_{1:k}) \approx \sum_{i=1}^{N_p} w_k^{(i)} \mathcal{K}_h(x_k - x_k^{(i)})$$



Krigeage




Processus gaussien

- Parfois, l'environnement est mal connu
- Donc correction bayésienne impossible
- Champ trop complexe pour une simple interpolation multi-linéaire
- Processus gaussien pour saisir les corrélations spatiales du champs

Régression par processus gaussien

- z et $\tilde{z}$ suivent le même processus gaussien
- $z|\tilde{z}$ suit une loi normale connue
- Réécriture du modèle d'observation avec la moyenne et la covariance conditionnelles

Krigeage adaptatif



Estimation du modèle


- Hyper-paramètres du processus inconnus
- Estimation par maximum de vraisemblance sur les données d'apprentissage

Sélection des données

- Champ de recalage non-stationnaire
- On souhaite caractériser le champ local
- Entraînement sur un sous-ensemble des données d'apprentissage
- Fenêtrage autour de l'estimée prédite

Architecture envisagée

SLAM magnétique par krigeage



Résultats numériques

Comparaison entre l'AK-RPF et l'état de l'art

Résolution	RPF		AK-RPF	
	Convergence	RMSE final	Convergence	RMSE final
0.40km	92%	0.97km	/	/
0.70km	34%	1.31km	/	/
0.78km	21%	1.61km	/	/
0.88km	3%	3.91km	97%	0.43km
1.00km	0%	N/A	81%	1.08km
1.17km	0%	N/A	72%	1.15km
1.40km	/	/	55%	1.19km
1.75km	/	/	26%	2.35km
2.33km	/	/	1%	2.24km

- Article accepté pour la conférence internationale IEEE FUSION 2024

Bibliographie

Références principales

- ① M. S. Arulampalam, S. Maskell, N. Gordon and T. Clapp, "A tutorial on particle filters for online nonlinear/non-Gaussian Bayesian tracking". In: IEEE Transactions on Signal Processing, vol. 50, no. 2, pp. 174-188, Feb. 2002.
- ② C. Musso, N. Oudjane and F. Le Gland. "Improving regularized particle filters". In: Sequential Monte Carlo methods in practice, Springer, pp. 247-271, 2001.
- ③ C. E. Rasmussen and C. K. I. Williams, "Gaussian Processes for Machine Learning". The MIT Press, 2006.
- ④ C. Palmier, A. Giremus, P. Minvielle, C. Vacar, G. Bourmaud, "Terrain-Aided SLAM with Limited-Size Reference Maps Using Gaussian Processes". In: IEEE 22th International Conference on Information Fusion (FUSION), pp. 1-8, 2019
- ⑤ A. Solin, and S. Särkkä, "Hilbert space methods for reduced-rank Gaussian process regression". Stat Comput 30, 419-446, 2020.
- ⑥ A. Murangira, C. Musso, K. Dahia and J. -M. Allard, "Robust regularized particle filter for terrain navigation". In: IEEE 14th International Conference on Information Fusion, Chicago, IL, USA, pp. 1-8, 2011.

Annexes

Équations du filtre de Kalman

- Représentation dans l'espace d'état :

- $x_k = F_k x_{k-1} + B_k u_k + w_k$
 - $z_k = H_k x_k + n_k$

modèle d'évolution
modèle d'observation

- Prédiction :

- $\hat{x}_{k|k-1} = F_k \hat{x}_{k-1|k-1} + B_k u_k$
 - $P_{k|k-1} = F_k P_{k-1|k-1} F_k^T + Q_k$

estimateur de l'état prédit
covariance de l'état prédit

- Correction :

- $\tilde{y}_k = z_k - H_k \hat{x}_{k|k-1}$
 - $S_k = H_k P_{k|k-1} H_k^T + R_k$
 - $K_k = P_{k|k-1} H_k^T S_k^{-1}$
 - $\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \tilde{y}_k$
 - $P_{k|k} = (I - K_k H_k) P_{k|k-1}$

innovation
covariance de l'innovation
gain de Kalman
estimateur de l'état corrigé
covariance de l'état corrigé

Annexes

Équations du krigeage

- 2 jeux de données qui suivent $\mathcal{H}(\cdot) \sim \mathcal{GP}(\mu(\cdot), \mathcal{K}(\cdot, \cdot))$ bruité :

$$\begin{cases} \forall i \in \llbracket 1, n \rrbracket, & z^i = \mathcal{H}(x^i) + \eta^i & \eta^i \sim (0, R) \\ \forall j \in \llbracket 1, \tilde{n} \rrbracket, & \tilde{z}^j = \mathcal{H}(\tilde{x}^j) + \tilde{\eta}^j & \tilde{\eta}^j \sim (0, \tilde{R}) \end{cases}$$

- Loi jointe de z et $\tilde{z}$:

$$\begin{bmatrix} z \\ \tilde{z} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu(x) \\ \mu(\tilde{x}) \end{bmatrix}, \begin{bmatrix} \mathcal{K}(x, x) + I_n \otimes R & \mathcal{K}(x, \tilde{x}) \\ \mathcal{K}(x, \tilde{x})^T & \mathcal{K}(\tilde{x}, \tilde{x}) + I_{\tilde{n}} \otimes \tilde{R} \end{bmatrix} \right)$$

- Loi de z conditionnelle à $\tilde{z}$:

$$\begin{aligned} & \sim \mathcal{N}(\mu^*(x, \tilde{x}, \tilde{z}), R^*(x, \tilde{x})) \\ & \begin{cases} A(x, \tilde{x}) = \mathcal{K}(x, \tilde{x}) \left(\mathcal{K}(\tilde{x}, \tilde{x}) + I_{\tilde{n}} \otimes \tilde{R} \right)^{-1} \\ \mu^*(x, \tilde{x}, \tilde{z}) = \mu(x) + A(x, \tilde{x}) (\tilde{z} - \mu(\tilde{x})) \\ R^*(x, \tilde{x}) = \mathcal{K}(x, x) + I_n \otimes R - A(x, \tilde{x}) \mathcal{K}(x, \tilde{x})^T \end{cases} \end{aligned}$$

Annexes

Pseudo-code de l'AK-RPF

- Tirage des particules selon la loi de transition (prédiction)
- Calcul de la fenêtre de krigeage
- Extraction des données dans la fenêtre
- Maximisation de la vraisemblance du processus gaussien
- Calcul de la vraisemblance des particules
- Calcul des poids des particules (correction)
- Estimation de l'état corrigé et de sa covariance
- Si dégénérescence des particules
 - Rééchantillonnage des particules
 - Régularisation des particules
 - Estimation de l'état corrigé et de sa covariance

Annexes

Paramètres de simulation

- Mouvement rectiligne uniforme
- 6 composantes : 3 positions et 3 vitesses linéaires
- 100 simulations par filtre

Paramètre de simulation	Valeur
Nombre d'itérations	600
Pas de temps	0.5 s
Surface de la carte	$40 \times 100 \text{ km}^2$
Covariance de l'état initial	$\text{diag}([2000, 2000, 100, 2, 2, 1])^2 \text{ SI}$
Covariance d'évolution	$\text{diag}([40, 40, 2, 0.4, 0.4, .05])^2 \text{ SI}$
Covariance d'évolution	15^2 m^2
Nombre de données d'entraînement	$\in \{20^2, 30^2, \dots, 80^2\}$
Covariance des données d'entraînement	15^2 m^2
AK-RPF	Value
Nombre de particules	5000
Facteur de rééchantillonnage	0.5
Facteur de régularisation	0.3
Échantillons de krigeage minimum	10
Facteur de fenêtrage	2