

Algorithmes de Navigation par Champ Magnétique Terrestre pour des Véhicules Aérospatiaux

Bastien HUBERT^{1, 2} - Doctorant de 2ème année

Audrey GIREMUS² - Directrice de thèse

Karim DAHIA¹ - Codirecteur de thèse

Nicolas MERLINGE¹ - Encadrant de thèse

¹ONERA, DTIS, IGNC ²Université de Bordeaux, CNRS, IMS

ONERA, 3 février 2025

Contexte de la thèse

Enjeux de la navigation inertielle

- Fonctionne par intégration de mesures issues des accéléromètres et gyromètres d'une centrale inertielle
 - Autonome et fiable sur des missions courtes
 - Mais basée sur des mesures imparfaites (biais, facteurs d'échelle, bruits, ...)
- ⇒ Engendre une solution qui dérive dans le temps

Fusion de données

- Utiliser des données issues d'autres capteurs aide à réduire la dérive
 - Souvent par GNSS, mais données potentiellement bruitées ou indisponibles
- ⇒ Recalage par champ (altimétrique, magnétique, gravitationnel, ...)
- Comparaison entre une mesure d'environnement et une carte embarquée

Navigation par anomalies du champ magnétique terrestre

Anomalies du champ magnétique


- Mesure du champ local par un magnétomètre
- Décomposition et extraction de l'anomalie magnétique :

$$\mathcal{B}_{total} = \mathcal{B}_{noyau} + \boxed{\mathcal{B}_{croûte}} + \mathcal{B}_{véhicule} + \mathcal{B}_{externe}$$

- Comparaison avec une carte embarquée géoréférencée

Défis

- Champ observé à décomposer
- Incertitude sur l'état initial élevée
- Modèle de l'environnement ambigu
- Champ potentiellement bruité et peu résolu, ou carte trop lourde à embarquer



Estimation bayésienne

Représentation dans l'espace d'état discret

- $$\begin{cases} x_k = \mathcal{F}_k(x_{k-1}, \nu_k) & \text{évolution récursive} \\ z_k = \mathcal{H}_k(x_k) + \eta_k & \text{équation d'observation} \end{cases}$$

Filtrage bayésien

- But : calculer $p(x_k | z_{1:k})$ la densité de probabilité *a posteriori*
- Estimation de l'état courant :

$$\hat{x}_k^{EAP} = \mathbb{E}(x_k | z_{1:k}) = \int x_k p(x_k | z_{1:k}) dx_k$$

- Matrice de covariance de l'erreur :

$$P_k^{EAP} \triangleq \mathbb{V}(\hat{x}_k^{EAP}) = \int (x_k - \hat{x}_k^{EAP})(x_k - \hat{x}_k^{EAP})^T p(x_k | z_{1:k}) dx_k$$

Filtrage bayésien

Limites des filtres usuels

- Filtre optimal : pas de solution analytique en général
- Filtre de Kalman : suppose des équations linéaires à bruits gaussiens, et ne gère pas les ambiguïtés et les multi-modalités

Filtre particulaire standard

- Asymptotiquement optimal en connaissant $\mathcal{F}_k$, $\mathcal{H}_k$ et les lois des bruits
- Approximation de la densité *a posteriori* par une mixture de Dirac :

$$p(x_k | z_{1:k}) \approx \sum_{i=1}^{N_p} w_k^{(i)} \delta(x_k - x_k^{(i)})$$

- Propagation : $x_k^{(i)} \sim q(\cdot | x_{k-1}^{(i)}, z_k)$
- Correction : $w_k^{(i)} \propto w_{k-1}^{(i)} \frac{p(z_k | x_k^{(i)}) p(x_k^{(i)} | x_{k-1}^{(i)})}{q(x_k^{(i)} | x_{k-1}^{(i)}, z_k)}$


Filtre particulaire régularisé

Filtre particulaire régularisé

- Dégénérescence des particules lors de la correction → rééchantillonnage
- Appauvrissement particulaire à cause de la duplication → régularisation
- Estimation de la densité *a posteriori* par noyaux :

$$p(x_k | z_{1:k}) \approx \sum_{i=1}^{N_p} w_k^{(i)} \mathcal{K}_h(x_k - x_k^{(i)})$$


- Autres filtres envisageables (filtre particulaire auxiliaire, ...)



Krigeage

Régression par processus gaussien


- Environnement mal connu → correction bayésienne impossible
 - Champ trop complexe pour une simple interpolation multilinéaire
- ⇒ Krigeage : donne une expression analytique de $\mathcal{H}_k$ et de son incertitude
- Correspond à une réécriture du modèle d'observation avec la loi conditionnelle à certains échantillons d'apprentissage



Krigeage adaptatif

Apprentissage du modèle

- Choix du PG : $\mu : x \mapsto \mu_0$ et $\mathcal{K} : x, x' \mapsto \sigma_f^2 \exp \left(-\frac{1}{2} \frac{(x-x')^T (x-x')}{l^2} \right)$
- Calcul des hyperparamètres par estimation du maximum de vraisemblance




Sélection des échantillons

- Non-stationnarité du champ d'observation
 - Nécessite la sélection dynamique des échantillons de régression
- ⇒ Sélection par fenêtrage de l'état prédit : *Adaptive Kriging Particle Filter and its Application to Terrain-Aided Navigation*, B. Hubert et al., IEEE FUSION, 2024
- Autres sélections en étude

Architecture algorithmique

SLAM magnétique par krigeage



Simulation

Paramètres de simulations

- Mouvement rectiligne uniforme
- 100 simulations de Monte-Carlo par filtre

Paramètre de simulation	Valeur
Nombre d'itérations	600
Surface de la carte	$40 \times 100 \text{ km}^2$
Covariance de l'état initial	$\text{diag}([2000, 2000, 100, 2, 2, 1])^2 \text{ SI}$
Covariance d'évolution	$\text{diag}([40, 40, 2, 0.4, 0.4, .05])^2 \text{ SI}$
Covariance d'observation	15^2 m^2
Nombre d'échantillons	$\in \{20^2, 30^2, \dots, 80^2\}$
Covariance des échantillons	15^2 m^2
AK-RPF	Value
Nombre de particules	5000
Facteur de rééchantillonnage	0.5
Facteur de régularisation	0.3
Échantillons de krigeage minimum	10
Facteur de fenêtrage	2

Résultats numériques

Comparaison à l'état de l'art

Résolution de la carte	RPF		AK-RPF	
	Convergence	RMSE final	Convergence	RMSE final
0.40km	92%	0.97km	/	/
0.70km	34%	1.31km	/	/
0.78km	21%	1.61km	/	/
0.88km	3%	3.91km	97%	0.43km
1.00km	0%	N/A	81%	1.08km
1.17km	0%	N/A	72%	1.15km
1.40km	/	/	55%	1.19km
1.75km	/	/	26%	2.35km
2.33km	/	/	1%	2.24km

Travaux en cours et perspectives

Publication

- B. Hubert, K. Dahia, N. Merlinge and A. Giremus, "Adaptive Kriging Particle Filter and its Application to Terrain-Aided Navigation". 27th International Conference on Information Fusion, 2024

Travaux en cours et perspectives

- Caractérisations théoriques des méthodes de sélection d'échantillons en se basant sur les RKHS
- Étude d'autres filtres : filtre Rao-Blackwellisé, Kalman d'ensemble, ...
- Formalisme SLAM