

THÈSE

présentée

DEVANT L'UNIVERSITÉ DE RENNES 1

pour obtenir

le grade de : ***DOCTEUR DE L'UNIVERSITÉ DE RENNES 1***

Mention : Mathématiques et applications

PAR

Nadia OUDJANE

Équipe d'accueil : ONERA, Châtillon

École Doctorale : MATISSE

Composante universitaire : S.P.M.

STABILITÉ ET APPROXIMATIONS PARTICULAIRES EN FILTRAGE NON LINÉAIRE APPLICATION AU PISTAGE

SOUTENUE LE 18 décembre 2000 devant la commission d'examen :

COMPOSITION DU JURY :

Jean JACOD	Rapporteurs
Etienne PARDOUX	
François LE GLAND	Directeur de thèse
Pierre DEL MORAL	Examineurs
Bernard DELYON	
Christian MUSSO	

Remerciements

Je remercie vivement Jean Jacod et Etienne Pardoux pour avoir accepté d'être rapporteurs de cette thèse. Leurs remarques m'ont permis de corriger et de finaliser au mieux ce travail.

Mes remerciements s'adressent aussi à Bernard Delyon pour sa participation au jury.

Je remercie tout particulièrement Pierre Del Moral pour l'intérêt constant qu'il a porté à mon travail. Je lui suis profondément reconnaissante de nombreuses discussions scientifiques qui m'ont guidée et encouragée dans mes recherches. Je le remercie également d'être parmi les membres du jury.

Je tiens à exprimer ma profonde gratitude à François Le Gland, le directeur de cette thèse, pour sa disponibilité à répondre à mes questions. Ses conseils et ses encouragements me furent très précieux tout au long de ce travail.

Je voudrais réserver une attention particulière à Christian Musso à qui j'adresse toute ma reconnaissance pour les idées et les conseils qu'il m'a apportés durant ce travail. Ses compétences, son enthousiasme et sa bonne humeur ont été des ingrédients indispensables à la réalisation de cette thèse.

Je tiens par ailleurs à remercier vivement Manuel Samuelides, Professeur à Supaéro, qui à différents titres m'a soutenue par sa confiance, en me donnant notamment l'occasion d'enseigner à Supaéro pendant ma thèse.

Je remercie également les membres de l'ONERA de l'équipe STD Palaiseau et de DTIM Châtillon qui ont été mes collègues durant ce travail. Leur soutien et leur bonne humeur m'ont permis d'effectuer cette thèse dans d'excellentes conditions.

J'aimerais enfin exprimer toute ma gratitude à mes amis et à ma famille dont les encouragements et le soutien n'ont jamais fait défaut.

Table des matières

Introduction	9
1 Filtre optimal et filtres approchés	15
1.1 Description du problème de filtrage	15
1.1.1 Motivations	15
1.1.2 Modèle général d'état et d'observation considéré	17
1.1.3 Evolution du filtre optimal	19
1.2 Méthodes d'approximation	23
1.2.1 Méthodes analytiques	23
1.2.2 Méthodes numériques	26
1.2.3 Méthodes de Monte Carlo	26
Conclusion	32
2 Stabilité du filtre optimal	33
2.1 Choix de la métrique	35
2.1.1 Distance moyenne faible	35
2.1.2 Variation totale	38
2.1.3 Distance de Kullback–Leibler	41
2.1.4 Métrique de Hilbert	42
2.1.5 Conclusion	47
2.2 Résultats de stabilité	48
2.2.1 Au sens de la métrique de Hilbert	50
2.2.2 Au sens de la Variation Totale	52
2.2.3 Au sens faible	55
2.2.4 Conclusion	59
2.3 Exemples et applications	60
2.3.1 Noyaux pseudo-mélangeants	60
2.3.2 Discrétisation de l'équation d'état en temps	70
Conclusion	75
3 Filtres particuliers classiques	77
3.1 Filtre de Monte Carlo pondéré	78
3.1.1 Filtre sans oubli	78
3.1.2 Filtre à mémoire limitée	81
3.1.3 Filtre à oubli exponentiel	84

3.1.4	Conclusion	90
3.2	Filtre particulaire avec interaction	91
3.2.1	Analyse générale	91
3.2.2	Algorithme avec nombre aléatoire de particules	95
3.2.3	Cas du noyau mélangeant	100
3.2.4	Points faibles et variantes	102
	Conclusion	106
4	Régularisation par estimation de densité par noyaux	107
4.1	Contexte général	108
4.1.1	Rappels sur le produit de convolution	108
4.1.2	Description du problème	111
4.2	Estimation d'erreurs	113
4.2.1	Résultats principaux	114
4.2.2	Majoration du biais	119
4.2.3	Majoration de la variance	122
4.3	Choix des paramètres	130
4.3.1	Choix optimal	130
4.3.2	Choix empirique	131
4.3.3	Le cas d'une densité corrigée	133
	Conclusion	134
5	Filtres particuliers régularisés	135
5.1	Analyse générale	136
5.1.1	Filtre particulaire pré-régularisé	136
5.1.2	Filtre particulaire post-régularisé	143
5.2	Cas du noyau mélangeant	154
5.2.1	Filtre particulaire pré-régularisé	154
5.2.2	Filtre particulaire post-régularisé	157
5.3	Remarques sur les hypothèses	159
5.3.1	Le facteur de dilatation	159
5.3.2	L'Hypothèse $[Q_I]$	159
5.3.3	Les Hypothèses $[Q']$ et $[Q'']$	160
5.3.4	L'Hypothèse $[Q\Psi]$	161
5.3.5	L'Hypothèse $[Q_d]$	162
5.4	Régularisation et robustification	162
5.4.1	Le problème de robustesse en filtrage	163
5.4.2	La procédure d'augmentation de bruit	164
5.4.3	L'approximation particulaire	165
5.4.4	Robustification	165
5.5	Amélioration par des heuristiques	166
5.5.1	Analyse de deux méthodes approchées de correction	167
5.5.2	Principe de la correction progressive	168
5.5.3	Choix adaptatif de la décomposition	169
5.5.4	Conclusion	172
	Conclusion	173

6	Application au pistage	175
6.1	Modèle d'état et estimation des performances	176
6.1.1	Modèle d'état	176
6.1.2	Estimation des performances	176
6.2	Comparaison RPF / IPF	177
6.2.1	Pistage radar	177
6.2.2	Simulations	177
6.3	Comparaison RPF / EKF	180
6.3.1	Pistage de précision par mesure de distance	180
6.3.2	Pistage par mesure d'angle seul	181
6.4	Comparaison RPF / IMM	184
6.4.1	Modèle de cible manœuvrante et IMM	184
6.4.2	Simulations	184
6.5	Correction progressive	188
6.5.1	Post-RPF avec ou sans correction progressive	188
6.5.2	Post-RPF avec correction progressive / EKF	189
	Conclusion	191
	Conclusion	193
	Annexe A : Notations	197
	Annexe B : Hypothèses	199
	Annexe C : Principaux algorithmes particuliers	203
	Annexe D : Coût de calcul de l'algorithme de rejet	209
	Bibliographie	220

Introduction

Le problème du filtrage consiste à estimer l'état d'un système dynamique au vu d'observations bruitées des états passés du système. Ce problème est suffisamment général pour trouver de nombreuses applications variées telles que le pistage de cible, la commande optimale, ou l'évaluation de risque en finance. C'est ce contexte applicatif riche qui motive pour l'essentiel la recherche dans ce domaine. Dans ce travail de thèse, nous avons choisi de considérer le cas particulier du filtrage en temps discret. Ce choix est naturellement justifié par le caractère nécessairement échantillonné des observations délivrées par l'instrument de mesure. Précisément, nous cherchons à estimer, à chaque instant d'observation, la valeur d'un processus aléatoire markovien, $(X_t)_{t \geq 0}$ à valeurs dans $\mathbb{R}^d$ de transitions connues, appelé signal ou processus état, indirectement lié à un processus observation $(Y_n)_{n \geq 1}$ dont on connaît une réalisation. Le but est alors de calculer (de manière approchée), à chaque instant d'observation t_n , la distribution de probabilité conditionnelle π_n de l'état à l'instant courant sachant les observations passées,

$$X_0 \sim \pi_0, \quad \text{et pour } n \geq 1, \quad \pi_n(dx) = \mathbb{P}[X_{t_n} \in dx \mid Y_1, Y_2, \dots, Y_n].$$

La suite $(\pi_n)_{n \geq 0}$ de mesures de probabilité ainsi formée est appelée filtre optimal. Elle évolue dans le temps par une alternance d'étapes de prédiction et de correction. À chaque instant d'observation t_n , la prédiction consiste à faire évoluer π_{n-1} à travers le noyau de transition du signal entre les instants t_{n-1} et t_n . Puis, l'étape de correction met à jour la probabilité ainsi prédite au vu de l'observation courante Y_n , par simple application de la formule de Bayes. En filtrage, on recherche un algorithme permettant d'effectuer le calcul du filtre optimal qui satisfasse en outre des contraintes de temps réel. Concrètement, le temps de calcul d'une estimée doit être de l'ordre de la période d'observation qui peut être très courte (de l'ordre du centième de seconde en pistage). Pour satisfaire cette contrainte et économiser la mémoire de l'ordinateur, on recherche de préférence un algorithme récursif. Ainsi, le calcul de l'estimée à l'instant courant ne doit dépendre que de l'observation courante et de l'estimée précédente : les observations passées n'étant pas réutilisées. Ces contraintes sont primordiales et caractérisent, pour une précision d'estimation donnée, l'efficacité de l'algorithme proposé.

En 1961 Kalman et Bucy [59, 60] révolutionnent la théorie de l'estimation en fournissant le premier algorithme de filtrage récursif. Le filtre de Kalman–Bucy permet en effet le calcul exact et rapide du filtre optimal lorsque les modèles d'état et d'observation ne font intervenir que des fonctions linéaires et des bruits additifs gaussiens. On montre, en fait, que dans ce cas la loi conditionnelle recherchée est gaussienne. Il suffit alors de propager sa moyenne et sa variance : le problème est de dimension finie. Mais, en toute généralité, le problème du filtrage non linéaire n'admet pas de solution de dimension finie [20, 85]. En pratique, on continue à utiliser, dans ce cas, des versions dérivées du filtre de Kalman–Bucy, comme le filtre de Kalman

étendu qui linéarise le modèle autour de l'estimée courante. Bien que cet algorithme soit depuis une trentaine d'années le filtre non linéaire le plus utilisé, il n'a été justifié rigoureusement que très récemment grâce en particulier aux travaux de Picard [93] qui montre son efficacité dans certains cas d'observations très précises. Hors de ces cas, l'erreur commise par le filtre de Kalman étendu n'est en général pas connue. On observe d'ailleurs des résultats mauvais lorsque le système est trop non linéaire ou lorsque le filtre est mal initialisé. Une autre approche plus rigoureuse propose de calculer la solution des équations du filtrage par des techniques de maillage de l'espace d'état [18, 67]. Cependant la complexité de ces méthodes numériques augmentant fortement avec la dimension de l'espace les rend inutilisables en temps réel, à partir de la dimension trois. Plus récemment, les méthodes de Monte Carlo ont été proposées comme une alternative attrayante [49, 39, 62]. Connues pour leur quasi-insensibilité à la dimension de l'espace et aux non linéarités du système, leur utilisation semble particulièrement adaptée au filtrage non linéaire. Les méthodes particulières proposent d'approcher la loi conditionnelle recherchée par une mesure empirique chargeant les points d'un système de particules aléatoires évoluant avec le signal et les observations. Cependant, les algorithmes particuliers développés jusqu'ici montrent un comportement instable en dehors de certaines hypothèses. On observe ainsi couramment la divergence de ces méthodes dans le cas de systèmes faiblement bruités.

Le but de cette thèse est justement de proposer de nouveaux algorithmes particuliers présentant un comportement plus stable dans le temps que les méthodes particulières classiques. Bien que la thèse ait pour but central le développement et l'analyse d'une nouvelle version de filtres particuliers, d'autres thèmes a priori sans relation sont abordés : la stabilité du filtre optimal au Chapitre 2 et l'estimation de densité au Chapitre 4. Notre contribution se trouve par conséquent disséminée dans plusieurs chapitres organisés autour de ces deux thèmes. Des résultats originaux développés dans le Chapitre 2 permettent d'apporter quelques résultats nouveaux dans l'analyse des filtres particuliers classiques au Chapitre 3. La combinaison des résultats du Chapitre 2 et du Chapitre 4 permet le développement et la justification théorique des méthodes particulières régularisées au Chapitre 5. Ainsi, l'apport de cette thèse consiste autant dans l'amélioration de certains résultats dans des domaines établis que dans la mise en correspondance de domaines différents pour la mise en œuvre de filtres approchés performants.

La démarche que nous avons adoptée pour la recherche d'un filtre approché est ainsi basée sur deux idées fondamentales. La première souligne la relation forte liant les propriétés de stabilité du filtre optimal et la qualité des filtres approchés. Cette relation a été en premier utilisée par Del Moral et Guionnet [33] qui étudient les propriétés de stabilité du filtre optimal pour en déduire la convergence uniforme en temps des méthodes particulières avec interaction, sous des conditions de mélange sur le signal. Nous reprenons ici cette démarche, mais nous l'exploitons plus à fond pour obtenir des résultats plus généraux quand aux schémas d'approximation considérés. On verra, en outre, que l'approche que nous adoptons pour l'étude de stabilité est différente de celle utilisée dans [33]. La plupart des méthodes proposées pour calculer le filtre consistent à perturber son évolution pour la rendre calculable. L'étude de la stabilité du filtre i.e. de sa sensibilité aux perturbations locales fournit ainsi un cadre solide dans la recherche d'un nouveau filtre approché. Le problème de la stabilité du filtre optimal a fait l'objet de nombreux travaux, mais les auteurs se sont limités à l'étude de la sensibilité du filtre à une mauvaise initialisation. Précisément, ils considèrent un processus à valeurs mesures, $(\pi'_n)_{n \geq 0}$ obtenu par la même succession d'étapes de prédiction et de correction que le filtre optimal $(\pi_n)_{n \geq 0}$, mais initialisé avec la fausse condition initiale $\pi'_0 \neq \pi_0$. Le but est

alors d'étudier dans quelle mesure la distance (par exemple en variation totale) entre le filtre optimal π_n et le filtre mal initialisé π'_n tend vers 0 avec le temps.

Dans le contexte du filtrage non linéaire, la plupart des résultats sont obtenus dans le cas d'un signal ergodique. Les premiers travaux réalisés dans ce domaine commencent avec Kunita [65] qui s'intéresse à l'existence d'une mesure invariante pour le filtre optimal. Il montre, dans le cadre d'un espace d'état compact, que si le signal est une chaîne de Markov Feller alors le processus à valeurs mesures constitué par le filtre optimal est lui aussi une chaîne de Markov Feller. En outre, il montre sous certaines conditions techniques, que l'existence d'une unique mesure invariante pour le signal entraîne aussi l'existence d'une unique mesure invariante pour le filtre optimal. En d'autres termes, lorsque le signal converge en loi vers une mesure invariante indépendante de la condition initiale, le filtre optimal converge aussi en loi vers une mesure invariante définie sur l'espace des probabilités qui est indépendante de la loi initiale du filtre. Ce résultat a ensuite été étendu par Kunita [66] et Stettner [100] au cas d'un espace localement compact. Ces articles mettent en évidence l'existence d'un lien entre les propriétés ergodiques du signal et du filtre optimal, mais aucun véritable résultat de stabilité n'est encore prouvé. On commence à s'intéresser au comportement en temps long du filtre mal initialisé avec Stettner [101]. Il s'avère que contrairement au filtre optimal, $(\pi'_n)_{n \geq 0}$ ne constitue pas une chaîne de Markov. Cependant l'auteur montre que le couple $(\pi'_n, X_n)_{n \geq 0}$ est une chaîne de Markov et il fournit des conditions pour lesquelles ce processus est ergodique, dans le cadre d'un espace d'état discret.

Les premiers résultats obtenus concernant l'oubli de la condition initiale par le filtre optimal sont dus à Delyon et Zeitouni [41] puis Ocone et Pardoux [86]. Delyon et Zeitouni [41] montrent la stabilité exponentielle du filtre lorsque le processus état est à valeurs dans un espace fini et que les observations sont suffisamment précises. Ocone et Pardoux [86] montrent un résultat plus général mais moins précis. En s'appuyant sur les travaux de Stettner [100], ils prouvent sous la même condition d'ergodicité du signal (que Kunita [66] et Stettner [100]) que le filtre oublie sa condition initiale au sens L^p . Mais leur preuve ne permet pas de fournir des vitesses de convergence. De plus la convergence est obtenue en moyenne sur les observations et n'est ainsi pas vérifiée pour chaque réalisation des observations.

Une nouvelle approche basée sur la métrique projective de Hilbert a récemment été proposée par Da Prato, Fuhman et Malliavin [25, 26] et indépendamment par Atar et Zeitouni [4]. L'introduction de la métrique de Hilbert en filtrage simplifie grandement l'étude de stabilité. La propriété de projectivité de cette métrique permet de passer de l'étude du filtre optimal dont l'évolution est non linéaire (du fait de la correction) à l'étude du processus dénormalisé dont l'évolution est linéaire. Les nombreux travaux dus en particulier à Birkhoff [12] et Hopf [54] sur les propriétés de contraction des opérateurs linéaires sous la métrique de Hilbert permettent ensuite de déterminer des conditions suffisantes à la stabilité exponentielle du filtre optimal (voir [4]).

Parallèlement, Del Moral et Guionnet [33] ont développé une autre approche utilisant des techniques de semi-groupe et le coefficient d'ergodicité de Dobrushin. L'évolution du filtre dans le temps est vue comme la composition d'opérateurs markovien non homogène et dépendant des observations agissant sur une mesure de probabilité qui elle aussi dépend des observations et du temps. Les résultats de stabilité sont ensuite obtenus en recherchant les conditions qui assurent la contraction de ces opérateurs sous la variation totale. Ils montrent ainsi que la condition de mélange sur le signal entraîne la stabilité exponentielle du filtre.

L'originalité de notre travail consiste en partie à étendre cette étude à l'analyse de la stabilité du filtre par rapport à des perturbations locales intervenant à chaque instant d'observation. Les perturbations locales auxquelles nous nous intéressons ne se limitent pas aux types de celles rencontrées en filtrage particulaire classique. Nous considérons différents types de perturbations selon qu'elles induisent une erreur contrôlée au sens de la métrique de Hilbert, de la variation totale ou bien au sens faible. Nous mettons ensuite en évidence une idée centrale soulignant l'importance du choix de la métrique pour le contrôle de la propagation des erreurs locales. Les résultats que nous obtenons sont alors applicables à des problèmes variés tels que

- la robustesse du filtre par rapport à des erreurs de modèles.
- la discrétisation en temps du signal lorsqu'il est solution d'une équation différentielle stochastique.
- l'approximation du filtre optimal par des méthodes particulières.

Pour développer cette analyse nous reprenons l'approche par la métrique de Hilbert et nous commençons par améliorer le résultat de stabilité exponentielle obtenu dans [4]. Ensuite, nous nous attaquons à l'étude des perturbations locales. On verra dans ce cas, que l'approche hilbertienne permet de retrouver ou d'améliorer des résultats de [33] et aussi d'en amener de nouveaux.

Cette étude de stabilité nous donnant une vision plus claire de la manière dont se propagent les erreurs, nous conduira vers la deuxième idée directrice qui consiste à utiliser les techniques d'estimation de densité par noyaux pour le développement de nouveaux filtres particuliers. L'estimation de densité permet d'approcher de façon non paramétrique la densité sous-jacente à un échantillon donné. L'idée est d'approcher cette densité par une somme de noyaux (densités "régulières") concentrés autour des points de l'échantillon. La théorie déjà développée dans ce domaine permet d'estimer précisément les erreurs commises avec cette méthode, au sens de différents critères. En 1985, Devroye et Györfi [45] regroupent et améliorent l'essentiel des résultats obtenus au sens du critère L^1 , pour le cas de l'estimation d'une densité monodimensionnelle. Plus tard, en 1992, Holmström et Klemelä [53] étendent ces résultats au cas multidimensionnel. L'étude réalisée pour le critère L^2 est résumée dans l'ouvrage de Silverman [99] de 1986. En outre, cette théorie fournit le choix optimal (minimisant l'erreur commise) des paramètres intervenant dans la méthode. Nous profiterons de ces résultats, mais pour permettre le développement des filtres particuliers régularisés, il nous faudra encore étendre le contexte classique de l'estimation de densité au contexte plus général rencontré en filtrage de l'estimation de la densité sous-jacente à un échantillon pondéré. De plus, nous développerons des majorations de l'erreur commise pour d'autres critères tels que les critères L^p lorsque $p > 2$.

Le mémoire s'organise de la façon suivante. Dans le premier chapitre introductif, est présentée la problématique générale du filtrage non linéaire. Nous rappelons les enjeux applicatifs du filtrage qui motivent notre travail. Puis nous décrivons le contexte précis de notre étude. Les différentes approches adoptées pour traiter ce problème sont brièvement décrites. Ce premier chapitre nous permet d'évoquer d'emblée les principales difficultés liées au filtrage non linéaire que nous retrouverons tout au long du mémoire.

Le deuxième chapitre a pour objet l'étude de la stabilité du filtre optimal. Nous soulignons d'abord l'importance du choix de la métrique dans cette étude. Cette idée centrale dans la thèse, nous guidera dans la compréhension de la propagation des erreurs d'approximation et dans la recherche d'un filtre approché. Nous étendons ensuite l'utilisation de la métrique de Hilbert à l'étude des propriétés de stabilité du filtre optimal par rapport à une grande classe de perturbations locales. Les résultats assez généraux (quand aux types de perturbations considérées) obtenus permettent de retrouver (par d'autres moyens) ou même d'améliorer certains résultats déjà connus ainsi que d'en amener de nouveaux. Ce chapitre est essentiel pour l'étude (réalisée dans la suite) du comportement en temps long des approximations particulières.

Le troisième chapitre est consacré aux deux types de méthodes particulières originellement développées : les méthodes de Monte Carlo pondéré et les méthodes particulières avec interaction. Nous rappelons d'abord pour chacune de ces méthodes quelques résultats bien connus. Nous montrons ensuite, toujours par l'approche hilbertienne, la convergence uniforme en temps de certaines versions de ces deux familles d'algorithmes. De plus, une amélioration du filtre particulière avec interaction utilisant un nombre aléatoire de particules est proposée et analysée. Il s'avère qu'en dehors d'hypothèses assez restrictives, les résultats obtenus ne permettent pas d'assurer le bon comportement en temps long de ces approximations. En outre, on observe couramment, en simulations, la divergence de ces algorithmes, dans le cas de systèmes faiblement bruités.

Pour nous affranchir des faiblesses de ces méthodes, nous proposons d'ajouter une étape de régularisation dans l'algorithme du filtre particulière avec interaction. Le principe de régularisation est décrit et analysé au Chapitre 4. Nous nous basons sur la théorie de l'estimation de densité par noyaux pour proposer une perturbation locale du filtre optimal, en un sens, plus fine que celle utilisée par le filtre particulière avec interaction. Nous développons alors quelques majorations d'erreur qui sortent du cadre général rencontré en estimation de densité, mais qui sont nécessaires pour le développement des filtres particuliers régularisés qui est réalisé dans le chapitre suivant.

Dans le Chapitre 5, deux types d'algorithmes sont proposés : le filtre pré-régularisé ou post-régularisé selon l'instant où intervient l'étape de régularisation dans l'algorithme. Le comportement de ces nouveaux algorithmes est étudié pour des systèmes assez généraux puis pour des systèmes vérifiant de fortes conditions d'ergodicité. Les preuves de convergence de ces algorithmes sont obtenues grâce aux résultats du Chapitre 2 et du Chapitre 4. Outre cette étude théorique nous proposons une heuristique spécialement développée pour traiter le problème du faible bruit d'observation.

Dans le Chapitre 6, nous étudions les performances simulées des principaux filtres proposés sur des problèmes concrets de pistage. Nous comparons, dans un premier temps, les filtres particuliers régularisés au filtre particulière avec interaction. Puis, nous montrons l'apport des méthodes régularisées par rapport aux méthodes de filtrage classiquement utilisées par les ingénieurs, dans le cadre de trois problèmes classiques de pistage.

Pour faciliter la lecture nous avons regroupé, en annexe, à la fin du mémoire, les principales notations et hypothèses utilisées dans la thèse ainsi que les algorithmes des méthodes particulières étudiées.

Chapitre 1

Filtre optimal et filtres approchés

Dans la première section de ce chapitre, nous commençons par rappeler la portée vaste du problème de filtrage, en nous appuyant sur trois applications dans des domaines différents. Puis, nous décrivons le contexte plus général de notre étude. Nous considérons ici le modèle de filtrage à observations en temps discret. Le filtre optimal est ensuite défini comme un processus à valeurs mesures dont nous décrivons l'évolution dans le temps. La seconde section de ce chapitre rappelle les différentes approches adoptées pour résoudre le problème de filtrage. Le filtre de Kalman étendu est l'outil communément utilisé par les ingénieurs. Il est présenté en détails car il servira à comparer les performances des méthodes particulières, dans les simulations du Chapitre 6. Le principe et les limites des méthodes numériques de maillage sont ensuite rapidement décrits. Enfin, après avoir rappelé le principe de base des méthodes de Monte Carlo, nous présentons les principales méthodes particulières proposées en filtrage.

1.1 Description du problème de filtrage

1.1.1 Motivations

La recherche en filtrage est motivée par de nombreuses applications dans des domaines variés. Ce problème est en effet assez général puisqu'il s'agit d'estimer l'état d'un système dynamique à partir d'observations bruitées. Nous décrivons ici brièvement le contexte applicatif du filtrage.

Les systèmes physiques ou économiques sont souvent sujets à des perturbations aléatoires. La modélisation de l'évolution dans le temps des états $(X_t)_{t \geq 0}$ du système considéré s'écrit alors sous la forme d'un terme d'évolution déterministe et d'un terme aléatoire,

$$X_t = X_0 + \int_0^t f(s, X_s) ds + \int_0^t b(X_s) dW_s, \quad X_0 \text{ de loi donnée},$$

où f est une fonction connue caractérisant la part déterministe de la dynamique et $(W_t)_{t \geq 0}$ le processus de Wiener standard modélisant les perturbations aléatoires de la dynamique et l'incertitude sur le choix de la fonction f . Cette équation de dynamique traduit la connaissance a priori que l'on a du système. Dans le but de déterminer l'état précis du système (pour des applications en contrôle, commande optimale ...), on élabore une procédure d'observation permettant de recueillir, à des instants discrets t_n , des mesures des états du système.

Ces observations sont, en général, entachées d'erreurs dues à l'imperfection de l'instrument de mesure. La suite des observations $(Y_n)_{n \geq 1}$ est modélisée par l'équation suivante, reliant l'observation Y_n à l'état courant X_{t_n} ,

$$Y_n = h_n(X_{t_n}) + V_n ,$$

où h_n est la fonction d'observation connue et $(V_n)_{n \geq 1}$ une suite de variables aléatoires (v.a.) de statistique connue modélisant l'imperfection des observations.

Le problème consistant à déterminer l'état du système, X_{t_n} , à partir d'observations bruitées $(Y_1, \dots, Y_k)$ est appelé estimation :

- si $k > n$, on parle plus précisément de lissage,
- si $k = n$, on parle de filtrage,
- si $k < n$, on parle de prédiction.

Le choix du critère qualifiant la précision de l'estimée n'est pas unique. Si l'on choisit la distance moyenne quadratique, il est bien connu que l'estimée optimale de X_{t_n} , au vu des observations $(Y_1, \dots, Y_n)$, est l'espérance conditionnelle,

$$\mathbb{E}[X_{t_n} \mid Y_1, \dots, Y_n] .$$

Cependant, cet estimateur n'est pas toujours approprié. Typiquement, lorsque la loi conditionnelle de X_{t_n} sachant les observations $(Y_1, \dots, Y_n)$ est fortement multimodale, on lui préfère le maximum a posteriori (maximisant la loi conditionnelle $\mathcal{L}(X_{t_n} \mid Y_1, \dots, Y_n)$). Dans tous les cas, l'information la plus riche disponible au vu des observations $(Y_1, \dots, Y_n)$ est contenue dans la loi conditionnelle de X_{t_n} sachant les observations passées. Avec la donnée de cette loi, on est libre dans le choix de l'estimateur. Le problème de filtrage consistera donc à calculer (de manière exacte ou approchée) cette mesure de probabilité conditionnelle. En toute généralité, nous avons à faire à un problème de dimension infinie. Nous nuancions d'emblée cet objectif ambitieux en notant que dans les applications (voir ci-dessous) on ne demande jamais à approcher la densité du filtre optimal en tout point de l'espace, seuls quelques moments (typiquement la moyenne et la variance) et la localisation des modes (lorsque la densité est multimodale) ne sont vraiment requis.

Dans notre travail réalisé à l'ONERA, nous nous sommes particulièrement intéressés à l'application pistage du filtrage non linéaire (voir Chapitre 6). Il est néanmoins intéressant de citer aussi d'autres exemples d'applications pour souligner la portée générale de ce problème.

Pistage de cible

En pistage le système considéré est un mobile (par exemple un navire ou un avion) dont on cherche à estimer, à chaque instant t_n , l'état X_{t_n} , constitué par sa position et sa vitesse. Si le navire n'est pas en phase de manœuvre, il est raisonnable de choisir un modèle de dynamique a priori rectiligne uniforme. Un radar fournit des mesures bruitées $(Y_n)_{n \geq 1}$ de sa distance au navire et de l'angle formé par un axe de référence et son axe de visée. La difficulté particulière de cette application est la contrainte de temps réel, c'est-à-dire que le temps de calcul de l'estimée fournie par le filtre doit être de l'ordre de la période de mesure $t_{n+1} - t_n$ (au plus fin de l'ordre du centième de seconde).

Identification du modèle canal radio

En communication radio, un problème important consiste à modéliser les perturbations du canal radio responsables de la détérioration des signaux émis. On suppose alors que ces perturbations sont modélisables par une fonction h connue agissant sur le signal émis et paramétrée par un vecteur X_n inconnu variant lentement dans le temps. Le but est alors d'estimer le paramètre X_n de la perturbation. La suite des observations, $(Y_1, \dots, Y_n, \dots)$, est obtenue en recueillant les réponses du canal radio à une série de signaux tests émis, $(u_1, \dots, u_n, \dots)$ (connus). On obtient alors le modèle classique de filtrage suivant,

$$\begin{aligned} X_{n+1} &= X_n + W_n & X_0 \text{ de loi donnée ,} \\ Y_n &= h(X_n, u_n) + V_n , \end{aligned}$$

où $(W_n)_{n \geq 1}$ et $(V_n)_{n \geq 1}$ sont des séquences de bruits indépendantes représentant respectivement, l'évolution lente de X_n dans le temps et l'incertitude sur le modèle de perturbation donné par la fonction h . Ce problème est, en général, traité dans le cadre du filtrage linéaire adaptatif (h est choisie linéaire en fonction de X_n) car l'étude est dans ce cas simple. Cependant on pourrait imaginer un modèle plus général où h dépendrait non linéairement de X_n , on serait alors confronté à un problème (plus difficile) de filtrage non linéaire.

Estimation de la volatilité pour les modèles financiers

Un modèle de données financières classiquement utilisé pour généraliser la formule de Black-Scholes utilise un modèle aléatoire d'évolution de la volatilité X_t ,

$$X_t = X_0 + \int_0^t f(X_s) ds + \int_0^t b(X_s) dW_s , \quad X_0 \text{ de loi donnée ,}$$

où $(W_t)_{t \geq 0}$ est le processus de Wiener standard. La variation quadratique du prix du marché évaluée à des instants discrets, fournit des mesures de la volatilité,

$$Y_n = \exp\left(\frac{X_{t_n}}{2}\right) V_n ,$$

où $(V_n)_{n \geq 0}$ est une suite de v.a gaussiennes indépendantes et identiquement distribuées (i.i.d.). En opérant une transformation logarithmique sur l'équation d'observation, on obtient,

$$\log Y_n^2 = X_{t_n} + \log V_n^2 .$$

Finalement, on retrouve un problème de filtrage non linéaire et non gaussien.

Ces différents exemples montrent que des problématiques variées peuvent se formuler comme des problèmes de filtrage non linéaire. Nous pouvons maintenant décrire plus en détail le cadre de notre étude.

1.1.2 Modèle général d'état et d'observation considéré

Nous introduisons d'abord quelques notations et définitions qui serviront tout au long du mémoire.

- L'ensemble des mesures positives et des distributions de probabilité sur E sont notés respectivement $\mathcal{M}^+(E)$ et $\mathcal{P}(E) = \mathcal{M}_1^+(E)$.

- A tout noyau positif K défini sur E , est associé l'opérateur intégral, lui aussi noté K , agissant sur $\mathcal{M}^+(E)$ de la manière suivante,

$$K \mu(dx') = \int_E \mu(dx) K(x, dx') ,$$

pour tout $\mu \in \mathcal{M}^+(E)$. L'opérateur adjoint K^* agit sur les fonctions de la manière suivante,

$$K^* \phi(x) = \int_E K(x, dx') \phi(x') ,$$

pour toute fonction ϕ mesurable définie sur E .

- A toute mesure $\mu \in \mathcal{M}^+(E)$, non nulle i.e. telle que $\mu(E) \neq 0$, est associée la mesure positive normalisée (i.e. la mesure de probabilité)

$$\bar{\mu} = \mu / \mu(E) \in \mathcal{P}(E) .$$

- A tout noyau positif K défini sur E , est associé l'opérateur non linéaire $\bar{K}$ (appelé opérateur normalisé associé à K) sur $\mathcal{M}^+(E)$ à valeurs dans $\mathcal{P}(E)$, défini par

$$\bar{K}(\mu) = K \mu / (K \mu)(E) = K \bar{\mu} / (K \bar{\mu})(E) = \bar{K}(\bar{\mu}) ,$$

pour toute mesure $\mu \in \mathcal{M}^+(E)$ telle que $K \mu(E) \neq 0$, et $\bar{K}(\mu) = 0$ si $\mu \equiv 0$.

- $\|\cdot\|$ désigne, selon les cas, la norme en variation totale sur l'espace des mesures signées, ou bien la norme sup sur l'espace des fonctions mesurables et bornées sur E .
- Soit $(u_1, u_2, \dots, u_n)$ un n -uplet dans E^n , on usera souvent de la notation abrégée $u_{1:n} = (u_1, u_2, \dots, u_n)$.

Nous considérons deux suites de variables aléatoires $(X_n)_{n \geq 0}$ et $(Y_n)_{n \geq 1}$, définies sur l'espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$ et à valeurs (respectivement) dans $E = \mathbb{R}^d$ et $F = \mathbb{R}^q$. $(X_n)_{n \geq 0}$ est appelé signal ou processus état, et $(Y_n)_{n \geq 1}$ processus observation.

- Le processus état $(X_n)_{n \geq 0}$ est une chaîne de Markov inhomogène, avec pour noyaux de transition Q_n , i.e. pour tout entier $n \geq 1$

$$\mathbb{P}[X_n \in dx \mid X_{0:n-1} = x_{0:n-1}] = \mathbb{P}[X_n \in dx \mid X_{n-1} = x_{n-1}] = Q_n(x_{n-1}, dx) ,$$

et pour distribution de probabilité initiale p_0 . La distribution de probabilité conjointe de $X_{0:n}$ est notée $p_{0:n}$, nous avons donc

$$p_{0:n}(dx_{0:n}) = \mathbb{P}(X_{0:n} \in dx_{0:n}) = p_0(dx_0) Q_1(x_0, dx_1) \cdots Q_n(x_{n-1}, dx_n) ,$$

pour tout $x_{0:n} = (x_0, \dots, x_n) \in E^{n+1} = \mathbb{R}^{(n+1)d}$. Par exemple, $(X_n)_{n \geq 0}$ peut être défini par une équation du type

$$X_n = f_n(X_{n-1}, W_n) ,$$

où $(W_n)_{n \geq 0}$ est une suite de variables aléatoires indépendantes, pas nécessairement gaussiennes et indépendantes de l'état initial X_0 .

- Le processus observation $(Y_n)_{n \geq 1}$ est lié au processus état de la manière suivante, pour tout entier $n \geq 1$,

$$Y_n = h_n(X_n, V_n) ,$$

où $(V_n)_{n \geq 1}$ est une suite de variables aléatoires (pas nécessairement gaussiennes) et indépendantes du processus état $(X_n)_{n \geq 0}$. Nous supposons que pour chaque entier $n \geq 1$ la distribution de probabilité $\mathbb{P}[Y_n \in dy \mid X_n = x]$ sur F , paramétrée par $x \in E$, est dominée, i.e.

$$\mathbb{P}[Y_n \in dy \mid X_n = x] = g_n(x, y) \lambda_n(dy) ,$$

pour une mesure positive λ_n sur F (typiquement la mesure de Lebesgue). On définit alors Ψ_n , la fonction de vraisemblance associée,

$$\Psi_n(x) = g_n(x, Y_n) ,$$

pour tout $x \in E$. Notons que Ψ_n dépend implicitement de l'observation Y_n . Comme de plus les observations $\{Y_k, k \geq 1\}$ sont mutuellement indépendantes, conditionnellement à $\{X_k, k \geq 0\}$, la distribution de probabilité $\mathbb{P}[Y_{1:n} \in dy_{1:n} \mid X_{1:n} = x_{1:n}]$ sur F^n est dominée et possède la densité $g_{1:n}(x_{1:n}, \cdot)$, telle que

$$\begin{aligned} \mathbb{P}[Y_{1:n} \in dy_{1:n} \mid X_{1:n} = x_{1:n}] &= g_{1:n}(x_{1:n}, y_{1:n}) \lambda_{1:n}(dy_{1:n}) \\ &= g_1(x_1, y_1) \lambda_1(dy_1) \cdots g_n(x_n, y_n) \lambda_n(dy_n) , \end{aligned}$$

où $dy_{1:n} = dy_1 \times \cdots \times dy_n$ désigne l'hypercube élémentaire de $F^n = \mathbb{R}^{nq}$. Nous pouvons alors définir la vraisemblance conjointe qui s'écrit comme le produit des vraisemblances marginales, i.e.

$$\Psi_{1:n}(x_{1:n}) = g_{1:n}(x_{1:n}, Y_{1:n}) = \Psi_1(x_1) \cdots \Psi_n(x_n) ,$$

pour tout $x_{1:n} \in E^n$.

1.1.3 Evolution du filtre optimal

Le problème de filtrage non linéaire est de calculer à chaque pas de temps la loi conditionnelle π_n de l'état X_n , sachant une réalisation des observations $Y_{1:n} = (Y_1, \dots, Y_n)$ jusqu'à l'instant courant n , i.e.

$$\pi_n(dx) = \mathbb{P}[X_n \in dx \mid Y_{1:n}] .$$

La suite de probabilités conditionnelles $(\pi_n)_{n \geq 0}$, avec la convention $\pi_0 = p_0$, est appelée filtre optimal. De plus, l'algorithme proposé pour réaliser ce calcul doit satisfaire des contraintes de temps réel. Pour cette raison, on souhaite obtenir un algorithme récursif de calcul de π_n , i.e. tel que le calcul de π_n ne soit fonction que de la dernière observation Y_n et de la loi conditionnelle précédente π_{n-1} , sans avoir à réutiliser les observations entre les instants $t = 1$ et $t = n - 1$.

Tandis que le calcul du filtre optimal est en général un problème difficile, l'évolution du filtre dans le temps est en revanche facile à décrire. Le passage de π_{n-1} à π_n fait intervenir

la loi conditionnelle $\pi_{n|n-1}$ de l'état X_n sachant une réalisation des observations $Y_{1:n-1} = (Y_1, \dots, Y_{n-1})$ jusqu'à l'instant précédent $n-1$, i.e.

$$\pi_{n|n-1}(dx) = \mathbb{P}[X_n \in dx \mid Y_{1:n-1}] .$$

La suite de probabilités $(\pi_{n|n-1})_{n \geq 0}$, où $\pi_{0|-1} = p_0$, est appelée filtre de prédiction. L'évolution du filtre optimal se décompose en deux étapes.

Prédiction : La première étape d'évolution du filtre optimal utilise la connaissance a priori du système, à travers le noyau de transition Q_n , en réalisant la transition de π_{n-1} à $\pi_{n|n-1}$ de la manière suivante,

$$\pi_{n|n-1}(dx) = \int_E \pi_{n-1}(dx') Q_n(x', dx) = (Q_n \pi_{n-1})(dx) . \quad (1.1)$$

L'étape de prédiction est donc linéaire.

Correction : La deuxième étape utilise la connaissance a posteriori fournie par l'observation Y_n à travers la fonction de vraisemblance Ψ_n . Elle réalise la transition de $\pi_{n|n-1}$ à π_n , par application de la formule de Bayes, sachant que les observations $\{Y_k, k \geq 1\}$ sont mutuellement indépendantes, conditionnellement à $\{X_k, k \geq 0\}$.

$$\pi_n(dx) = \frac{\Psi_n(x) \pi_{n|n-1}(dx)}{\int_E \Psi_n(x') \pi_{n|n-1}(dx')} = \frac{\Psi_n(x) \pi_{n|n-1}(dx)}{\langle \pi_{n|n-1}, \Psi_n \rangle} = (\Psi_n \cdot \pi_{n|n-1})(dx) , \quad (1.2)$$

où $\cdot$ désigne le produit projectif. L'étape de correction est donc non linéaire.

Nous notons, par la suite,

$$\bar{m}_k = \langle \pi_{k|k-1}, \Psi_k \rangle , \quad M_k = \sup_{x \in E} \Psi_k(x) , \quad \text{et} \quad \bar{\gamma}_k = \frac{M_k}{\bar{m}_k} .$$

Si $n > m \geq 1$ nous notons le produit $\bar{\gamma}_n \cdots \bar{\gamma}_m = \bar{\gamma}_{n:m}$ et par convention, $\bar{\gamma}_{n:n} = \bar{\gamma}_n$ et




FIG. 1.1: Fonction de vraisemblance et densité prédite pour une observation précise (a) ou incohérente (b) par rapport à la prédiction, (dans le cas d'un état directement observé i.e. $Y_n = X_n + V_n$)

$\bar{\gamma}_{n+1:n} = 1$. Remarquons que le coefficient $\bar{\gamma}_k \geq 1$ a une interprétation pratique intéressante. Il caractérise,

- la précision de l'observation par rapport à la mesure prédite : $\bar{\gamma}_k$ est d'autant plus grand que la variance du bruit d'observation est faible. La Figure 1.1(a) représente la fonction de vraisemblance Ψ_k et la densité de la mesure prédite $\pi_{k|k-1}$ dans le cas d'une observation Y_k très précise. On observe effectivement que dans ce cas l'intégrale du produit de ces fonctions qui est inversement proportionnel à $\bar{\gamma}_k$ est faible.
- la cohérence entre l'observation courante et la mesure prédite : $\bar{\gamma}_k$ est d'autant plus grand que l'observation est incohérente avec la prédiction (voir Figure 1.1(b)). De la même manière que précédemment, on observe sur la Figure 1.1(b) que dans ce cas l'intégrale du produit de la fonction de vraisemblance et de la densité de la mesure prédite est faible.

Globalement, $\bar{\gamma}_k$ est grand lorsque l'observation est riche au sens où elle modifie (par la correction) sensiblement la mesure prédite.

Par la suite, nous faisons toujours l'hypothèse implicite suivante.

Hypothèse $[\Psi]$ (vraisemblance bornée) :

$$0 < \bar{m}_k = \langle \pi_{k|k-1}, \Psi_k \rangle, \quad \text{et} \quad M_k = \sup_{x \in E} \Psi_k(x) < \infty.$$

$$\text{Nous avons alors } \bar{\gamma}_k = \frac{M_k}{\bar{m}_k} < \infty.$$

Remarque 1.1. L'hypothèse de l'existence du majorant M_k est une hypothèse faible, largement vérifiée dans les cas pratiques. Si par exemple, le bruit d'observation est additif, il suffit que la densité du bruit soit bornée pour que l'hypothèse soit vérifiée.

D'autre part, on note que $\bar{m}_k$ est une v.a. positive presque sûrement non nulle. Dans l'Hypothèse $[\Psi]$, la condition sur $\bar{m}_k$ est ainsi presque sûrement réalisée. En effet,

$$\bar{m}_k = \int_E g_k(x, Y_k) \mathbb{P}[X_k \in dx | Y_{1:k-1}],$$

où par définition

$$g_k(x, y) \lambda_k(dy) = \mathbb{P}[Y_k \in dy | X_k = x].$$

Ainsi,

$$\bar{m}_k = l_k(Y_k),$$

où l_k est la densité conditionnelle de Y_k , sachant les observations précédentes, $Y_{1:k-1}$, par rapport à la mesure de référence λ_k , i.e.

$$l_k(y) \lambda_k(dy) = \mathbb{P}[Y_k \in dy | Y_{1:k-1}].$$

$$\mathbb{P}[\bar{m}_k = 0 | Y_{1:k-1}] = \mathbb{P}[l_k(Y_k) = 0 | Y_{1:k-1}] = \int_F \mathbf{1}_{l_k(y)=0} l_k(y) \lambda_k(dy) = 0,$$

ainsi, $\bar{m}_k = l_k(Y_k) > 0$ $\mathbb{P}$ -p.s..

Finalement, l'évolution du filtre optimal se résume par le schéma suivant,

$$\pi_{n-1} \xrightarrow[\text{Prédiction}]{(1)} \pi_{n|n-1} = Q_n \pi_{n-1} \xrightarrow[\text{Correction}]{(2)} \pi_n = \Psi_n \cdot \pi_{n|n-1} . \quad (1.3)$$

On sera aussi amené, par la suite, à considérer la distribution de probabilité conditionnelle conjointe de $X_{0:n} = (X_0, \dots, X_n)$ sachant $Y_{1:n} = (Y_1, \dots, Y_n)$ que l'on note $\pi_{0:n}$, telle que

$$\pi_{0:n}(dx_{0:n}) = \mathbb{P}[X_{0:n} \in dx_{0:n} \mid Y_{1:n}] .$$

On a par la formule de Bayes,

$$\pi_{0:n}(dx_{0:n}) = \frac{\Psi_{1:n}(x_{1:n}) p_{0:n}(dx_{0:n})}{\int_E \Psi_{1:n}(x_{1:n}) p_{0:n}(dx_{0:n})} = \frac{\Psi_{1:n}(x_{1:n}) p_{0:n}(dx_{0:n})}{\langle p_{0:n}, \Psi_{1:n} \rangle} = (\Psi_{1:n} \cdot p_{0:n})(dx_{0:n}) . \quad (1.4)$$

Notons que

$$\frac{\Psi_{1:n}(x_{1:n})}{\langle p_{0:n}, \Psi_{1:n} \rangle} = \frac{\Psi_1(x_1)}{\langle \pi_{1|0}, \Psi_1 \rangle} \cdots \frac{\Psi_n(x_n)}{\langle \pi_{n|n-1}, \Psi_n \rangle} ,$$

pour tout $x_{1:n} = (x_1, \dots, x_n) \in E^n = \mathbb{R}^{(n)d}$. Ainsi

$$\sup_{x_{1:n} \in E^n} \frac{\Psi_{1:n}(x_{1:n})}{\langle p_{0:n}, \Psi_{1:n} \rangle} = \bar{\gamma}_1 \cdots \bar{\gamma}_n = \bar{\gamma}_{n:1} .$$

Il sera utile par la suite d'écrire les transitions du filtre optimal grâce à l'opérateur d'évolution dénormalisé $R_n = \Psi_n Q_n$ associé au noyau positif

$$R_n(x, dx') = \Psi_n(x') Q_n(x, dx') ,$$

et agissant sur $\mathcal{M}^+(E)$ de la manière suivante,

$$(R_n \mu)(dx') = \int_E \Psi_n(x') \mu(dx) Q_n(x, dx') ,$$

pour toute mesure $\mu \in \mathcal{M}^+(E)$. Notons que R_n dépend de l'observation Y_n à travers la fonction de vraisemblance Ψ_n . Avec ces définitions, l'évolution du filtre optimal décrite par les équations (1.1) et (1.2) peut s'écrire

$$\pi_n = \frac{R_n \pi_{n-1}}{(R_n \pi_{n-1})(E)} = \bar{R}_n(\pi_{n-1}) = \Psi_n \cdot (Q_n \pi_{n-1}) , \quad (1.5)$$

où $\cdot$ désigne le produit projectif. Par récurrence, nous obtenons,

$$\pi_n = \bar{R}_n(\pi_{n-1}) = \bar{R}_n \circ \cdots \circ \bar{R}_m(\pi_{m-1}) = \bar{R}_{n:m}(\pi_{m-1}) .$$

Remarque 1.2. L'équation (1.5) montre clairement que la non linéarité de l'évolution du filtre optimal est essentiellement due au terme de normalisation résultant de l'application de la formule de Bayes lors de la correction (1.2). Au Chapitre 2, nous introduisons une métrique projective à la suite de [25, 26, 4] précisément dans le but de se débarrasser de ce terme de normalisation et de se ramener ainsi à l'étude d'un processus linéaire sur $\mathcal{M}^+(E)$.

1.2 Méthodes d'approximation

Dans cette section, nous présentons les principales méthodes proposées pour résoudre le problème de filtrage. Nous les avons regroupées en trois classes : les méthodes analytiques, les méthodes numériques et les méthodes de Monte Carlo.

1.2.1 Méthodes analytiques

On s'intéresse particulièrement aux filtres de Kalman–Bucy et de Kalman étendu. Ce sont les outils les plus communément utilisés par les ingénieurs pour résoudre les problèmes de filtrage linéaire et non linéaire. La présentation se veut brève mais néanmoins précise car nous retrouvons ces méthodes au Chapitre 6, où nous les comparons, en simulations, aux méthodes particulières.

Filtre de Kalman–Bucy (KF)

Le filtre de Kalman–Bucy développé à l'origine par Kalman [59] en 1960 pour le temps discret puis repris en 1961 par Kalman et Bucy [60] pour le temps continu permet de résoudre le problème de filtrage linéaire lorsque les bruits sont additifs et gaussiens. Une étude détaillée du filtre de Kalman–Bucy est développée dans [58]. On pourra trouver une introduction claire et concise dans [69]. On considère ici le modèle linéaire gaussien, où le processus état suit une évolution linéaire avec un bruit additif gaussien et où l'observation est une fonction linéaire de l'état entachée d'un bruit additif gaussien, i.e.,

$$\begin{cases} X_n = F_n X_{n-1} + c_n + G_n W_n , \\ Y_n = H_n X_n + d_n + V_n , \end{cases} \quad (1.6)$$

On suppose, de plus que :

- les coefficients F_n , c_n , G_n , H_n , et d_n à valeurs respectivement dans $\mathbb{R}^{d \times d}$, $\mathbb{R}^d$, $\mathbb{R}^{d \times k}$, $\mathbb{R}^{d \times q}$, et $\mathbb{R}^q$ sont déterministes,
- les bruits d'état et d'observation W_n et V_n à valeurs respectivement dans $\mathbb{R}^k$ et $\mathbb{R}^q$ sont des bruits blancs gaussiens de covariances respectives Q_n et R_n mutuellement indépendants et indépendants de la condition initiale X_0 ,
- la condition initiale X_0 est gaussienne de moyenne $\mathbb{E}[X_0] = \bar{X}_0$ et de covariance Q_0 .

On montre dans ce cas que le processus $(X_n, Y_n)_{n \geq 1}$ est gaussien et que par conséquent les lois conditionnelles π_n sont elles aussi gaussiennes. Le problème est alors de dimension finie, il suffit de calculer l'espérance notée $\hat{X}_n$ et la matrice de covariance notée P_n de π_n . Ces deux quantités sont calculées récursivement et exactement par le filtre de Kalman–Bucy. Les conditions initiales du filtre sont données par

$$\begin{cases} \hat{X}_0 = \bar{X}_0 \\ P_0 = Q_0 . \end{cases}$$

Puis $\hat{X}_n$ et P_n sont calculés par les étapes de prédiction et correction suivant les équation :

– Equations de prédiction

$$\begin{cases} \hat{X}_{n|n-1} = F_n \hat{X}_{n-1} + c_n \\ P_{n|n-1} = F_n P_{n-1} + G_n Q_n G_n^* . \end{cases} \quad (1.7)$$

– Equations de correction

$$\begin{cases} \hat{X}_n = \hat{X}_{n|n-1} + K_n [Y_n - (H_n \hat{X}_{n|n-1} + d_n)] \\ P_n = [I - K_n H_n] P_{n|n-1} \\ K_n = P_{n|n-1} H_n^* [H_n P_{n|n-1} H_n^* + R_n]^{-1} . \end{cases} \quad (1.8)$$

K_n est appelé le gain de Kalman. On note que les suites des matrices de covariances $(P_n)_{n \geq 0}$, $(P_{n|n-1})_{n \geq 0}$ (solution de l'équation de Ricatti) et des gains $(K_n)_{n \geq 0}$ ne dépendent pas des observations $(Y_n)_{n \geq 1}$. Il est ainsi possible de les précalculer et de diminuer sensiblement la quantité de calculs à effectuer en temps réel.

Il y a au moins trois approches différentes conduisant aux équations du filtre de Kalman–Bucy. Une première approche bayésienne consiste à calculer explicitement les deux étapes de prédiction et de correction. Une deuxième approche par projection, développée notamment par Anderson et Moore [2] ainsi que Chui et Chen [21], consiste à montrer que les innovations $[Y_n - (H_n \hat{X}_{n|n-1} + d_n)]$ constituent une suites de v.a. indépendantes et de projeter le processus état sur la base orthonormale associée. Une troisième est de noter que le problème du filtrage linéaire gaussien est équivalent au problème des moindres carrés récursifs. Il peut donc se résoudre en optimisant un critère (correspondant aux vraisemblances des observations) sous une contrainte (correspondant à la connaissance a priori de l'état).

Si on relâche l'hypothèse de bruits gaussiens, tout en restant dans le cadre de systèmes dynamiques linéaires, on montre que le filtre de Kalman–Bucy fournit toujours l'estimée linéaire à variance minimale de l'état du système, i.e. qu'il fournit la suite de gains optimale $(K_n)_{n \geq 0}$ minimisant l'erreur quadratique de tout estimée $\hat{X}_n$ de la forme

$$\begin{cases} \hat{X}_{n|n-1} = F_n \hat{X}_{n-1} + c_n \\ \hat{X}_n = \hat{X}_{n|n-1} + K_n [Y_n - (H_n \hat{X}_{n|n-1} + d_n)] . \end{cases}$$

C'est notamment pour cette raison qu'il est le filtre le plus répandu. On note qu'ici $\hat{X}_n$ ne désigne plus l'espérance conditionnelle, mais son estimée par le filtre de Kalman–Bucy (sous optimal, dans ce cas).

Le filtre de Kalman–Bucy, s'étend au cas “conditionnellement gaussien”, découvert par Liptser et Shirayev [74]. Dans ce cas les coefficients F_{n+1} , c_{n+1} , G_{n+1} et H_n et d_n dépendent des observations passées $Y_{1:n-1}$. Le couple $(X_n, Y_n)_{n \geq 1}$ n'est plus un processus gaussien mais la loi conditionnelle π_n reste gaussienne et le filtre de Kalman–Bucy (1.7) et (1.8) fournit toujours la moyenne et la covariance de π_n .

Filtre de Kalman Étendu (EKF)

On considère cette fois-ci un système dynamique non linéaire, avec toujours des bruits blancs gaussiens additifs, indépendants entre eux et indépendants de la condition initiale.

$$\begin{cases} X_n = f_n(X_{n-1}) + g_n(W_n) , \\ Y_n = h_n(X_n) + V_n , \end{cases} \quad (1.9)$$

On suppose que les fonctions f_n et g_n sont dérivables. Le filtre optimal associé à ce système n'est plus gaussien. Une idée naturelle est alors de linéariser le système autour d'une estimée M_n de X_n mesurable par rapport aux observations passées $Y_{1:n-1}$.

$$f_n(x) \approx F_n x + c_n , \quad \text{avec } F_n = \nabla f_n(M_{n-1}) , \quad \text{et } c_n = f_n(M_{n-1}) - F_n M_{n-1}$$

$$g_n(x) \approx G_n , \quad \text{avec } G_n = g_n(M_{n-1})$$

$$h_n(x) \approx H_n x + d_n , \quad \text{avec } H_n = \nabla h_n(M_n) , \quad \text{et } d_n = h_n(M_n) - H_n M_n$$

Le système non linéaire (1.9) est alors approché par le système linéaire (1.6),

$$\begin{cases} X_n = F_n X_{n-1} + c_n + G_n W_n , \\ Y_n = H_n X_n + d_n + V_n , \end{cases}$$

On reconnaît ici un problème (localement) conditionnellement gaussien, auquel on applique les deux étapes du filtre de Kalman (1.7) et (1.8). Le filtre de Kalman étendu utilise comme estimée M_n la prédiction $\hat{X}_{n|n-1}$ de l'estimée précédente $\hat{X}_{n-1}$. On note qu'ici les matrices de covariance et les gains ne peuvent plus être précalculés puisque H_n et F_{n+1} sont fonctions de $\hat{X}_n$.

Le filtre de Kalman étendu est le seul filtre non linéaire récursif utilisé dans la pratique par les ingénieurs. Il est rapide peu coûteux en temps de calcul et performant pour beaucoup de problèmes non linéaires. Mais dès que les non-linéarités deviennent trop fortes ou si le problème est mal initialisé, l'EKF peut fournir des résultats mauvais. Bien qu'il soit utilisé depuis une trentaine d'années, des études théoriques permettant de le justifier n'ont été développées que très récemment, essentiellement grâce aux travaux de Picard, notamment [91, 92, 93]. Ces travaux réalisés pour le modèle état en temps continu / observation en temps continu justifient l'utilisation d'algorithmes du type EKF lorsque l'observation est très bonne. Plus précisément, Picard montre que lorsque l'état est totalement observé (h_n injective) avec une variance du bruit d'observation paramétrée par un réel ε tendant vers zéro, alors la variance de la loi conditionnelle est d'ordre ε tandis que l'erreur quadratique moyenne entre l'espérance conditionnelle et l'estimée fournie par l'EKF est d'ordre ε^2 . Ainsi les erreurs commises par l'EKF sont-elles négligeables par rapport à la précision du filtre optimal. Ces résultats ont été étendus par Gegout-Petit [47] à certains cas où l'observation est partiellement très bonne, typiquement lorsqu'une coordonnée est totalement observée. Pour une étude du modèle état en temps continu / observation en temps discret, toujours dans le contexte asymptotique en bruit d'observation faible, on peut se reporter aux travaux de Milheiro [78]. Hors de ces cas

très particuliers aucun résultat théorique ne permet à notre connaissance de justifier l'utilisation du filtre de Kalman étendu. Notamment, l'EKF ne pouvant fournir qu'une approximation gaussienne de la loi conditionnelle n'est pas du tout capable de gérer les cas de multimodalité. L'heuristique classiquement utilisée dans ces cas, est d'approcher la loi conditionnelle par un mélange de gaussiennes dont chaque composante est estimée par un EKF. Mais l'efficacité de cette technique est aléatoire.

L'EKF peut aussi être vu comme un filtre paramétrique. On suppose que la densité du filtre appartient à une famille paramétrique de probabilités : les lois normales. Sous cette hypothèse, l'EKF cherche à estimer les paramètres de la densité du filtre (la moyenne et la variance). Mais en toute généralité, Chaleyat–Maurel et Michel [20] et indépendamment Ocone et Pardoux [85] montrent qu'il n'existe pas de solution de dimension finie au problème de filtrage, d'où les difficultés d'approximation rencontrées en pratique.

1.2.2 Méthodes numériques

Une autre approche est de considérer le filtre optimal comme la solution (à une constante multiplicative près) d'une équation aux dérivées partielles (EDP), l'équation de Zakai. On peut se reporter au cours de Pardoux [89] qui explique bien le lien entre filtrage non linéaire et EDP stochastiques. On cherche alors à approcher le filtre en discrétisant l'équation de Zakai par des méthodes de maillage de l'espace [67, 18]. Les méthodes de maillage fixe ne permettent pas de traiter le cas où le signal évolue dans un domaine non borné. De plus elles ne prennent pas en compte le fait que les fonctions à estimer sont des densités de probabilité et peuvent ainsi couvrir des parties de l'espace de masse nulle pour la loi à estimer. Les techniques de maillage adaptatif [18] ont l'avantage de raffiner le pas du maillage dans les zones de forte probabilité, on exploite ainsi mieux la puissance de calcul. En dimension 1 ou 2 ces techniques fournissent des approximations très précises de la densité à approcher en des temps raisonnables. Mais la quantité de calcul requise pour une précision donnée augmentant exponentiellement avec la dimension, ces méthodes sont inutilisables en temps réel, au delà de la dimension 3. En outre ces techniques sont souvent difficiles à mettre en œuvre.

Cependant, il faut noter que les méthodes numériques de maillage cherchent à approcher la densité du filtre optimal : il s'agit d'un problème difficile pour lequel on ne peut espérer trouver une solution simple en grande dimension. Dans les applications du filtrage, on ne requiert que l'approximation de quelques moments et la localisation des modes de la densité du filtre. Dans ce contexte moins ambitieux, les méthodes de Monte Carlo semblent une alternative intéressante pour traiter le problème de filtrage.

1.2.3 Méthodes de Monte Carlo

On appelle méthode de Monte Carlo toute méthode basée sur la simulation d'un grand nombre de variables aléatoires. Leur utilisation est justifiée par la loi des grands nombres qui permet d'approcher une mesure de probabilité lorsqu'on en connaît un échantillon. Dans toute la suite, pour toute mesure de probabilité μ nous notons $S^N(\mu)$ la mesure empirique de taille N chargeant les points d'un N -échantillon issu de μ , i.e.

$$S^N(\mu) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi^i} \quad \text{où} \quad (\xi^1, \dots, \xi^N) \text{ i.i.d. } \sim \mu.$$

La loi des grands nombres assure que $S^N(\mu)$ constitue une approximation de μ au sens où

$$\sup_{\|\phi\|=1} \mathbb{E}|\langle S^N(\mu) - \mu, \phi \rangle| \leq \frac{1}{\sqrt{N}} . \quad (1.10)$$

Nous introduisons maintenant la méthode d'échantillonnage pondéré et l'algorithme d'acceptation / rejet qui serviront dans le cadre des méthodes particulières. On renvoie à l'ouvrage de Robert [96] pour une présentation plus détaillée de ces deux méthodes.

Echantillonnage pondéré et Algorithme d'acceptation / rejet

Considérons le problème classique suivant.

- On cherche à approcher une mesure ν difficile à simuler directement, par inversion de la fonction de répartition.
- On sait simuler une mesure de probabilité, μ dominant ν telle que la densité de ν par rapport à μ , notée m , soit évaluable en tout point et bornée par une constante positive γ i.e.,

$$\nu(dx) = m(x) \mu(dx) \quad \text{avec} \quad m(x) \leq \gamma ,$$

pour tout $x \in E$.

Pour résoudre ce problème, au moins deux méthodes concurrentes sont à notre disposition : la méthode d'échantillonnage pondéré, “importance sampling” en anglais et la méthode d'acceptation / rejet. Nous omettons volontairement les méthodes de Monte Carlo par chaîne de Markov (algorithme de Metropolis–Hasting, échantillonneur de Gibbs, ...) car nous ne les utiliserons pas, dans la suite.

Définition 1.3 (Echantillonnage pondéré). *On appelle échantillonnage pondéré la technique qui consiste à approcher ν de manière empirique à l'aide d'un échantillon $(\xi^1, \dots, \xi^N)$ i.i.d. $\sim \mu$ par l'approximation*

$$\nu = m \mu \approx m S^N(\mu) = \frac{1}{N} \sum_{i=1}^N m(\xi^i) \delta_{\xi^i} . \quad (1.11)$$

μ est appelé probabilité d'importance ou loi instrumentale.

En filtrage particulière, on est confronté à la situation plus complexe, où la densité m n'est connue qu'à une constante multiplicative près. Précisément,

$$m(x) = \frac{\Psi(x)}{\langle \mu, \Psi \rangle} \leq \frac{\|\Psi\|}{\langle \mu, \Psi \rangle} = \gamma ,$$

pour tout $x \in E$, où Ψ est une fonction positive bornée sur E évaluable en tout point. On utilise, dans ce cas, une deuxième fois l'échantillonnage pondéré pour approcher la constante de normalisation $\langle \mu, \Psi \rangle$, ce qui donne finalement l'approximation

$$\Psi \cdot \mu \approx \Psi \cdot S^N(\mu) = \sum_{i=1}^N \omega^i \delta_{\xi^i} , \quad \text{avec} \quad \omega^i = \frac{\Psi(\xi^i)}{\sum_{j=1}^N \Psi(\xi^j)} . \quad (1.12)$$

Contrairement à (1.11), l'estimateur (1.12) est cette fois-ci biaisé, mais asymptotiquement ($N \rightarrow \infty$) sans biais. On obtient l'estimation d'erreur suivante (voir l'inégalité (2.6) au Chapitre 2).

$$\sup_{\|\phi\|=1} \mathbb{E}|\langle \nu - \Psi \cdot S^N(\mu), \phi \rangle| \leq 2\gamma \frac{1}{\sqrt{N}}. \quad (1.13)$$

On comprend que l'approximation est d'autant meilleur que la probabilité d'importance μ est proche de la probabilité à simuler ν (γ proche de un). Dans le cas contraire, les v.a. générées suivant μ ne fournissent pas d'information pertinente sur ν (et sont par conséquent faiblement pondérées par m). Le temps de calcul requis, pour obtenir la précision (1.13), noté T_{EP} , est constant, $T_{EP} = Nc_\mu$, où c_μ est le temps de génération d'une v.a. suivant μ supposé constant.

Définition 1.4 (Algorithme d'acceptation / rejet). *On appelle méthode d'acceptation / rejet la méthode de génération de v.a. qui consiste à générer des v.a. suivant ν en acceptant ou rejetant des v.a. générées suivant μ , grâce à l'algorithme,*

(i) Générer $\tilde{\xi} \sim \mu$ et U uniforme dans $[0, 1]$.

(ii) Si $U \leq \frac{m(\tilde{\xi})}{\gamma}$ alors $\xi = \tilde{\xi}$, sinon retourner en (i).

Cette technique est a priori frustrante puisqu'un certain nombre de v.a. générées suivant μ ne sont pas directement exploitées puisque rejetées.

Dans le cas rencontré en filtrage, ($m = \Psi / \langle \mu, \Psi \rangle$) la quantité

$$\frac{m(x)}{\gamma} = \frac{\Psi(x)}{\|\Psi\|}$$

est facilement calculable, dès que Ψ est évaluable et que l'on en connaît un majorant (si $\|\Psi\|$ n'est pas connu, on peut utiliser un majorant de Ψ moins fin). Le temps de calcul de cet algorithme pour la génération de N v.a. suivant ν , noté T_{AR} , est aléatoire avec en moyenne $\mathbb{E}[T_{AR}] = \gamma N c_\mu \geq T_{EP}$ qui est souvent prohibitif (voir annexe). Cependant l'erreur d'estimation est plus petite que pour l'échantillonnage pondéré. Elle est majorée directement par la loi des grands nombres.

$$\sup_{\|\phi\|=1} \mathbb{E}|\langle \nu - S^N(\Psi \cdot \mu), \phi \rangle| \leq \frac{1}{\sqrt{N}}.$$

La constante γ n'intervient plus dans l'erreur. En fait, on voit que pour une précision équivalente, l'échantillonnage pondéré requiert en moyenne un temps de calcul 4γ fois supérieur à celui de l'acceptation / rejet.

Remarque 1.5. Casella et Robert [19] comparent, plus en détail, les performances de ces deux méthodes lorsque l'échantillonnage pondéré utilise autant de générations de v.a. que l'algorithme d'acceptation / rejet. Il s'avère que la supériorité d'une méthode par rapport à l'autre n'est, dans ce cas, pas évidente et dépend essentiellement du contexte. Bien qu'en toute généralité, la méthode de rejet soit plus efficace que l'échantillonnage pondéré, Casella et Robert [19] fournissent des exemples où l'échantillonnage pondéré est plus précis que la méthode d'acceptation / rejet, pour un temps de calcul équivalent.

Filtrage particulière

Les méthodes particulières sont basées sur le principe de Monte Carlo. L'idée est d'approcher la loi conditionnelle de l'état sachant les observations à l'aide d'une mesure discrète pondérée chargeant les points d'un échantillon appelé système de particules. Ces méthodes consistent à faire évoluer, dans le temps, le système de particules en fonction de la dynamique du processus état et des observations. Les conditions de base nécessaires à l'implémentation de tout algorithme particulière sont les suivantes. Pour tout entier $n \geq 1$, il faut savoir

- simuler la loi initiale $\pi_0 = p_0$,
- simuler les lois de transitions $Q_n(x, \cdot)$ pour tout $x \in E$,
- évaluer les fonctions de vraisemblance Ψ_n en tout point de l'espace d'état.

L'application directe du principe de Monte Carlo au problème du filtrage consiste à approcher la loi conditionnelle π_n par une mesure empirique associée, $S^N(\pi_n)$. On obtiendrait ainsi une approximation du filtre uniforme en temps en $O(1/\sqrt{N})$. Dans ce contexte, deux questions se posent :

- Comment générer à chaque instant un échantillon $(\xi_n^1, \dots, \xi_n^N)$ i.i.d. suivant π_n ?
- Quels sont la précision et le coût de calcul de la méthode ?

Supposons que l'on dispose d'un échantillon de taille N_{n-1} , $(\xi_{n-1}^1, \dots, \xi_{n-1}^{N_{n-1}})$ i.i.d. suivant π_{n-1} . On peut alors générer $(\xi_n^1, \dots, \xi_n^{N_n})$ i.i.d. suivant $\pi_n = \Psi_n \cdot (Q_n \pi_{n-1})$ en utilisant l'algorithme d'acceptation / rejet suivant.

Initialiser : $i = 1$, et $j = 1$

- (i) Générer $\tilde{\xi}_n \sim Q_n(\xi_{n-1}^i, \cdot)$, poser $i = i + 1$.
- (ii) Générer U uniforme dans $[0, 1]$, si $\Psi_n(\tilde{\xi}_n) > U \|\Psi_n\|$, poser $\xi_n^j = \tilde{\xi}_n$, et $j = j + 1$.
- (iii) Si $i < N_{n-1}$ retourner en (i). Sinon, poser $N_n = j - 1$ et arrêter.

Cet algorithme fournit, en sortie, un échantillon $(\xi_n^1, \dots, \xi_n^{N_n})$ i.i.d. suivant π_n de taille aléatoire $N_n \leq N_{n-1}$, avec en moyenne, $\mathbb{E}[N_n | N_{n-1}] = N_{n-1} / \bar{\gamma}_n$, du fait du taux de rejet de l'algorithme. Ainsi, si le nombre de particules initiales (générées suivant π_0) est fixé au début de l'algorithme (ce qui est nécessaire pour assurer la récursivité de l'algorithme), alors le nombre de particules décroît exponentiellement (en moyenne) avec le temps ainsi que la précision de l'approximation. Inversement, si l'on désire assurer une précision uniforme d'ordre $1/\sqrt{N}$ à chaque itération, alors le nombre moyen de générations suivant π_0 doit croître exponentiellement avec le temps ce qui donne lieu à un algorithme non récursif et très coûteux en temps de calcul, (se reporter à l'annexe pour une étude plus précise du coût de calcul des algorithmes d'acceptation / rejet utilisés séquentiellement). Cette méthode est donc impraticable.

Néanmoins, on devine avec cet exemple naïf qu'il est a priori difficile de trouver une approximation de type Monte Carlo à nombre de particules constant avec une erreur uniforme en temps. En outre, on voit déjà que le coefficient $\bar{\gamma}_n$ influe sensiblement sur la précision de l'approximation. Pour une approximation uniforme, le nombre de particules initiales devrait croître dans le temps comme le produit $\bar{\gamma}_{n:1}$. Intuitivement, cela suggère la nécessité d'une

cohérence entre la précision de l'approximation (donnée par le nombre de particules) et la précision de l'information accumulée par les observations (donnée par $\bar{\gamma}_{n:1}$, voir Figure 1.1). Contrairement à ce qu'on pourrait penser a priori, le problème est d'autant plus difficile (exigeant en nombre de particules) que les observations sont précises et nombreuses ($\bar{\gamma}_{n:1}$ grand). Au cours de cette étude, on sera plusieurs fois amené à constater ce point délicat.

Intéressons nous maintenant aux filtres particuliers réellement envisagés. Que l'on considère le modèle d'évolution de la loi marginale (1.3) ou l'écriture de la loi conjointe (1.4), la difficulté numérique de l'approximation réside dans le calcul des intégrales intervenant dans chacune des équations. Tous les filtres récursifs basés sur le principe de Monte Carlo (filtres particuliers) se réduisent en fait à une application séquentielle de la méthode d'échantillonnage pondéré qui permet de changer ces intégrales en sommes discrètes, voir (1.12).

Le premier type de filtre particulière apparu dans la littérature est le filtre de Monte Carlo pondéré ("Weighted Monte Carlo Filter" ou "Sequential Importance Sampling algorithm" en anglais). L'échantillonnage pondéré est appliqué, à chaque pas de temps sur l'équation (1.4). Cette approche est décrite en détail dans la Section 3.1 du Chapitre 3. Elle a été proposée indépendamment dans [28, 40, 68, 61]. La méthode consiste à approcher la loi conditionnelle conjointe $\pi_{0:n} = \Psi_{1:n} \cdot p_{0:n}$ par une mesure empirique pondérée chargeant les points d'un échantillon issu de $p_{0:n}$ avec des poids proportionnels à la vraisemblance $\Psi_{1:n}$ évaluée en ces points :

$$\Psi_{1:n} \cdot p_{0:n} \approx \Psi_{1:n} \cdot S^N(p_{0:n}) = \sum_{i=1}^N \omega_{1:n}^i \delta_{\xi_{0:n}^i}, \quad \text{avec}$$

$$(\xi_{0:n}^1, \dots, \xi_{0:n}^N) \text{ i.i.d. } \sim p_{0:n}, \quad \text{et} \quad \omega_{1:n}^i = \frac{\Psi_{1:n}(\xi_{1:n}^i)}{\sum_{j=1}^N \Psi_{1:n}(\xi_{1:n}^j)}.$$

Cette méthode est très simple à implémenter elle suppose simplement de savoir évaluer les fonctions de vraisemblance (condition (ii)) et de générer récursivement des trajectoires i.i.d. suivant $p_{0:n}$ ce qui est trivial étant donnée la nature markovienne du processus état et la condition (i). D'un point de vue calculatoire, cette méthode est attrayante, le traitement indépendant de N trajectoires suivant $p_{0:n}$ étant naturellement parallélisable. Malheureusement, on observe un comportement instable de cet algorithme en temps long puisque les poids décroissent vers 0 pour toutes les trajectoires simulées sauf une qui concentre toute la masse. Ce phénomène appelé *dégénérescence des pondérations* provoque la divergence de l'algorithme. Différentes méthodes de régularisation des poids ont alors été proposées. La première méthode donnant lieu au filtre de Monte Carlo à mémoire limitée propose de ne prendre en compte que les p derniers poids calculés ce qui de facto empêche l'accumulation des poids. Del Moral [31] montre la convergence uniforme en temps de cet algorithme sous certaines conditions d'ergodicité du processus état. Une deuxième méthode consiste à introduire un facteur d'oubli exponentiel diminuant l'influence des poids passés. Nous montrons, dans la Section 3.1.3, la convergence uniforme en temps de cet algorithme sous des conditions de mélange des transitions du processus état.

Malgré ces procédures de régularisation, les comportements simulés de ces algorithmes ne sont en général pas très satisfaisants. On note en particulier que le coût de calcul dépensé pour

la prédiction et la correction d'une trajectoire est identique quelle que soit la vraisemblance de la trajectoire. Pour optimiser l'utilisation de la puissance de calcul et améliorer l'exploration de l'espace d'état par les particules, l'idée de privilégier les particules de forte vraisemblance a été introduite indépendamment par Del Moral, Rigal, Salut [39] (filtre particulaire avec interaction), Gordon, Salmond et Smith [49], ("bootstrap filter" ou "Sampling Importance Resampling") et Kitagawa [62] ("Monte Carlo filter"). Dans ce second type de filtre particulaire, présenté en détails dans la Section 3.2 du Chapitre 3, une étape d'échantillonnage d'importance est introduite dans l'évolution de la loi marginale (1.3). Ce qui conduit au schéma d'évolution modifiée suivant,

$$\pi_{n-1}^N \xrightarrow[\substack{\text{Prédiction} \\ \text{échantillonnée}}]{(1)} \pi_{n|n-1}^N = S^N(Q_n \pi_{n-1}^N) \xrightarrow[\text{Correction}]{(2)} \pi_n^N = \Psi_n \cdot \pi_{n|n-1}^N .$$

A chaque pas de temps, le rééchantillonnage multiplie les particules de forte vraisemblance et élimine les autres. Cet algorithme correspond en fait à la méthode d'échantillonnage séquentielle, SIR (Sampling Importance Resampling), déjà proposée par Rubin [97] en 1988. Les principaux résultats théoriques concernant ces algorithmes sont pour l'essentiel résumés dans [38]. Néanmoins, nous présentons dans la Section 3.2 une nouvelle preuve du résultat de convergence uniforme en temps du filtre approché vers le filtre optimal, dans le cas où les noyaux de transition du processus état sont mélangeants. De plus, nous proposons d'utiliser un nombre aléatoire de particules et montrons que cette procédure permet d'améliorer la stabilité de l'algorithme.

Malheureusement, le filtre particulaire avec interaction présente lui aussi, souvent un comportement instable en simulations. En effet, dans le cas de bruit de dynamique faible ou nul, la diversité du système de particules s'appauvrit dangereusement du fait de la succession des étapes d'échantillonnages à chaque pas de temps, si bien que le système de particules finit par se concentrer en un seul point de l'espace. Ce phénomène appelé *dégénérescence des particules* provoque la divergence du filtre. Nous avons alors proposé d'ajouter une étape à cet algorithme permettant d'assurer la diversité du système de particules au cours du temps. Les filtres résultant sont appelés filtres particuliers régularisés ("Regularized Particle Filters", en anglais). La procédure de régularisation est présentée et analysée au Chapitre 4 puis appliquée aux algorithmes de filtrage au Chapitre 5.

Conclusion du Chapitre 1

Dans ce chapitre nous nous sommes attachés à rappeler les enjeux pratiques et théoriques associés au problème du filtrage non linéaire. Nous avons d'abord souligné, à partir de trois exemples simples, les domaines applicatifs nombreux et variés qui motivent la recherche en filtrage non linéaire. Nous avons ensuite décrit le cadre théorique de notre travail. En particulier, nous limitons notre étude aux systèmes à observations en temps discret. Pour une analyse des méthodes particulières, dans le cadre de systèmes à observations en temps continu, on peut se reporter aux travaux de Crisan et Lyons [24] et Del Moral et Miclo [38].

Enfin, nous avons rappelé les principales méthodes utilisées pour résoudre le problème de filtrage. Parmi les méthodes analytiques, nous nous sommes particulièrement attachés à décrire le filtre de Kalman étendu car il s'agit de la méthode couramment utilisée par les ingénieurs. Elle fournit des résultats rapides et satisfaisants dans le cadres de systèmes peu non linéaires, mais hors de ce cas les performances de l'EKF peuvent être très mauvaises. Les méthodes numériques fournissent une solution précise au problème de filtrage non linéaire, mais le temps de calcul augmentant exponentiellement avec la dimension de l'espace d'état les rend impraticables à partir de la dimension trois. Les méthodes de Monte Carlo étant par nature peu sensibles à la dimension de l'espace ou au caractère non linéaire et non gaussien du système, semblent, a priori, une approche particulièrement adaptée au problème de filtrage non linéaire. Nous avons donc présenté brièvement les principales méthodes de Monte Carlo utilisées en filtrage que nous étudierons plus en détails, dans la suite de ce mémoire.

Chapitre 2

Stabilité du filtre optimal

L'étude de stabilité menée dans ce chapitre est essentielle pour l'analyse de la convergence des méthodes particulières, et plus généralement d'une grande classe de méthodes d'approximation du filtre optimal. Les méthodes d'approximation présentées dans la Section 1.2 consistent toutes à introduire une perturbation locale, entre deux instants d'observation $n - 1$ et n , de sorte à rendre l'évolution du filtre calculable. Mais, le contrôle de cette erreur locale n'est pas suffisant pour assurer un bon comportement du filtre, notamment en temps long. L'erreur globale induite par ces approximations successives se décompose en une somme d'erreurs locales transportées par une suite d'opérateurs d'évolution du filtre optimal comme le montre, plus loin, la décomposition (2.36). Ainsi, l'analyse des erreurs des filtres approchés consiste en l'étude des points suivants,

- (i) contrôle des erreurs locales induites,
- (ii) contrôle de la propagation des erreurs locales.

On verra que la réalisation de ces deux points est malheureusement le plus souvent difficile : une méthode peut assurer des erreurs locales faibles au sens d'une certaine métrique tout en ayant une propagation d'erreur à travers le filtre très mauvaise pour cette métrique. Proposer une bonne méthode d'approximation du filtre consiste donc à trouver un compromis entre ces deux aspects de l'erreur globale. Pour le moment, on se propose d'étudier en détail le second point en analysant la propagation de l'erreur d'initialisation, lorsque l'erreur initiale est contrôlée au sens d'une certaine métrique (le point (i) est supposé déjà traité). On cherchera particulièrement à faire ressortir l'influence de la métrique sur la qualité de la propagation d'erreur. Précisément, on appelle π_n le filtre bien initialisé avec la vraie condition initiale π_0 , et π'_n le filtre mal initialisé avec la fausse condition initiale π'_0 , les processus définis respectivement, par

$$\pi_n = \bar{R}_{n:1}(\pi_0) \quad (\text{filtre optimal}) \quad \text{et} \quad \pi'_n = \bar{R}_{n:1}(\pi'_0) \quad (\text{filtre mal initialisé}).$$

On s'intéresse à l'erreur globale entre π_n et π'_n induite par une erreur initiale contrôlée entre π_0 et π'_0 .

Le problème de stabilité du filtre optimal n'est pas nouveau et a déjà initié de nombreux travaux. Dans le contexte linéaire gaussien, l'étude de la stabilité du filtre de Kalman fût très

tôt développée [2, 58] pour analyser les propriétés de robustesse du filtre par rapport à d'éventuelles erreurs de modèle. Les résultats obtenus montrent que le filtre est asymptotiquement exponentiellement stable sous de simples hypothèses de détectabilité et contrôlabilité du système (voir [58]). Les résultats de convergence presque sûre du filtre linéaire mal initialisé avec une loi non nécessairement gaussienne, vers le filtre bien initialisé ont été le sujet de travaux plus récents. Pour le modèle état en temps discret / observation en temps discret, on peut citer les travaux de Makowski et Sowers [76], pour le modèle état en temps continu / observation en temps continu on peut se référer aux travaux de Delyon et Zeitouni [41] et d'Ocone et Pardoux [86]. Dans tous les cas, on note que la stabilité asymptotique pour les systèmes linéaires gaussiens ne demande aucune hypothèse d'ergodicité du processus état. Ce type de résultats n'a, en général, pas pu être étendu aux systèmes non linéaires.

Dans le contexte non linéaire, le premier résultat assez général de stabilité est obtenu par Ocone et Pardoux [86] qui montrent en s'appuyant sur les travaux de Stettner [100] et Kunita [66], que le filtre optimal oublie sa condition initiale au sens L^p , lorsque le processus état lui-même est ergodique. Mais leur preuve ne permet pas de fournir des vitesses de convergence. Une nouvelle approche basée sur la métrique projective de Hilbert a récemment été proposée par Da Prato, Fuhman et Malliavin [25, 26]. Indépendamment, Atar et Zeitouni [4] montrent par ces méthodes, des résultats de stabilité exponentielle du filtre par rapport à sa condition initiale. Dans le cadre de chaîne de Markov cachée, Le Gland et Mevel [72] montrent, sous certaines conditions, que le filtre de prediction oublie sa condition initiale à une vitesse exponentielle. Parallèlement, Del Moral et Guionnet [32] ont développé une autre approche utilisant des techniques de semi-groupe et le coefficient d'ergodicité de Dobrushin. Ils obtiennent ainsi des résultats de stabilité du filtre qui leur permettent de prouver la convergence uniforme en temps des méthodes particulières, sous des conditions de mélange du noyau de transition.

Dans ce chapitre, nous présentons plusieurs majorations d'erreurs induites soit par une mauvaise initialisation, soit par la présence de perturbations locales, dans l'évolution du filtre. Des majorations uniformes en temps sont obtenues, en reprenant l'approche par la métrique de Hilbert. Les hypothèses requises sur les transitions du processus état sont alors en général contraignantes. Des majorations non uniformes en temps sont obtenues pour des modèles plus généraux, par une approche directe.

Nous commençons, dans une première section, par exposer les propriétés utiles ou gênantes de différentes métriques pour l'étude de la stabilité du filtre. Cette section mettra en évidence une idée centrale de cette thèse sur l'importance du choix de la métrique pour l'étude du filtre optimal. Cette idée permettra de justifier notre choix de travailler sous telle ou telle autre métrique suivant la nature des perturbations induites sur le filtre. Dans la deuxième section, nous montrons quelques nouveaux résultats de stabilité du filtre par rapport à sa condition initiale et au modèle, lorsque l'erreur locale est contrôlée au sens de la métrique de Hilbert, puis au sens de la variation totale et enfin au sens de la distance faible. Finalement, dans la troisième section, ces résultats sont illustrés d'exemples et légèrement étendus puis utilisés pour l'étude des erreurs induites sur le filtre par la discrétisation en temps du processus état, lorsque celui-ci est solution d'une équation différentielle stochastique.

2.1 Choix de la métrique

Dans cette section, on étudie la propagation d'une erreur à travers l'étape de prédiction (action d'un noyau markovien Q), et l'étape de correction (produit projectif par une fonction positive Ψ).

On considère, Q , Ψ , μ , μ' , qui désigneront, dans cette section, sauf indication spéciale :

- Q un noyau markovien sur E ,
- Ψ une fonction positive définie sur E ,
- μ et μ' deux mesures de probabilité sur E telles que

$$1 \leq \gamma = \frac{\|\Psi\|}{\langle \mu, \Psi \rangle} < \infty, \quad \text{et} \quad 1 \leq \gamma' = \frac{\|\Psi\|}{\langle \mu', \Psi \rangle} < \infty.$$

On cherche des relations lipschitziennes caractérisant le transport d'erreur à travers la prédiction et la correction pour différentes distances ou pseudo-distances, i.e. des inégalités du type

$$d(Q\mu, Q\mu') \leq a d(\mu, \mu'),$$

$$d(\Psi \cdot \mu, \Psi \cdot \mu') \leq b d(\mu, \mu').$$

On verra que les coûts de transport a et b varient de manière significative avec le choix de la distance d . La métrique la plus fine pour l'analyse de l'erreur propagée étant celle pour laquelle le coût de transport ab est le mieux contrôlé pour tout Q , Ψ , μ et μ' . L'intérêt de cette section est maintenant clair, elle nous guidera vers le choix de la métrique la plus fine pour le type d'erreurs considérées.

2.1.1 Distance moyenne faible

Dans la suite de ce mémoire, on s'intéresse plus précisément aux méthodes particulières qui comme on l'a vu dans la Section 1.2, proposent d'approcher la loi conditionnelle recherchée par une mesure empirique. Le type d'erreurs locales introduites est alors directement contrôlé par la loi des grands nombres (1.10). La distance au sens faible est donc, dans ce cas, naturellement utilisée.

Définition 2.1 (Distance moyenne faible). *Pour toutes mesures signées μ et $\mu' \in \mathcal{M}(E)$, éventuellement aléatoires, nous appelons distance moyenne faible entre μ et μ' , le réel*

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle \mu - \mu', \phi \rangle|,$$

où le sup est pris parmi les fonctions ϕ mesurables sur E et de norme unité dans $\mathbb{R}$.

Nous introduisons en même temps la distance en variation totale.

Définition 2.2 (Variation totale). *Pour toutes mesures signées μ et $\mu' \in \mathcal{M}(E)$, nous appelons variation totale entre μ et μ' , le réel*

$$\|\mu - \mu'\| = 2 \sup_A |\mu(A) - \mu'(A)| ,$$

où le sup est pris parmi tous les boréliens A de E .

Notons que si μ et μ' sont absolument continues par rapport à une mesure de référence λ (par exemple $\lambda = \mu + \mu'$), avec les densités respectives α et α' alors on a l'égalité,

$$\|\mu - \mu'\| = 2 \sup_A |\mu(A) - \mu'(A)| = \int_E |\alpha(x) - \alpha'(x)| \lambda(dx) . \quad (2.1)$$

On note que lorsque les mesures sont déterministes, la distance moyenne faible s'identifie à la variation totale.

Nous définissons ici le taux de contraction d'un opérateur markovien sous la variation totale.

Définition 2.3 (Taux de contraction sous la variation totale). *Soit K un noyau markovien défini sur E . Nous appelons taux de contraction de K pour la variation totale et notons $\beta(K)$, le réel compris entre 0 et 1 tel que*

$$\beta(K) = \sup_{\mu(E)=0} \frac{\|K\mu\|}{\|\mu\|} , \quad (2.2)$$

où le sup est pris parmi les mesures finies signées non nulles.

On note, en particulier que

$$\beta(K) = \frac{1}{2} \sup_{x, x'} \|K(x, \cdot) - K(x', \cdot)\| .$$

Dans la suite, pour tout entier $m \leq n$, le taux de contraction du noyau markovien Q_n du processus état est noté $\beta(Q_n) = \beta_n$, le produit $\beta_n \cdots \beta_m = \beta_{n:m}$ et par convention $\beta_{n:n+1} = \beta_{m-1:m} = 1$ et $\beta_{n:n} = \beta_n$.

Le lemme suivant nous sera utile pour majorer la distance faible entre deux mesures normalisées (probabilités) en fonction de la distance entre deux mesures non normalisées associées.

Lemme 2.4. *Pour toutes mesures μ et $\mu' \in \mathcal{M}^+(E)$, éventuellement aléatoires, et pour tout entier $p \geq 1$,*

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle \bar{\mu} - \bar{\mu}', \phi \rangle| \leq 2 \sup_{\|\phi\|=1} \mathbb{E} \left[\frac{|\langle \mu - \mu', \phi \rangle|}{\mu(E)} \right] . \quad (2.3)$$

La preuve de l'inégalité (2.3) est une conséquence directe de la décomposition,

$$\bar{\mu} - \bar{\mu}' = \frac{1}{\mu(E)} [\mu - \mu' - (\mu(E) - \mu'(E)) \bar{\mu}] . \quad (2.4)$$

La propagation d'une erreur au sens faible à travers l'étape de prédiction puis l'étape de correction est contrôlée par la proposition suivante.

Proposition 2.5. *Pour toutes mesures de probabilité μ et $\mu' \in \mathcal{P}(E)$, éventuellement aléatoires,*

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle Q\mu - Q\mu', \phi \rangle| \leq \beta(Q) \sup_{\|\phi\|=1} \mathbb{E} |\langle \mu - \mu', \phi \rangle|. \quad (2.5)$$

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle \Psi \cdot \mu - \Psi \cdot \mu', \phi \rangle| \leq 2 \sup_{\|\phi\|=1} \mathbb{E} [\min(\gamma, \gamma') |\langle \mu - \mu', \phi \rangle|]. \quad (2.6)$$

La Proposition 2.5 montre que dans tous les cas l'étape de prédiction contracte les erreurs commises précédemment alors que l'étape de correction risque de les accroître considérablement.

Remarque 2.6. Si l'on considère, pour simplifier des mesures de probabilité μ et μ' déterministes, l'inégalité (2.6) se traduit alors

$$\|\Psi \cdot \mu - \Psi \cdot \mu'\| \leq 2 \min(\gamma, \gamma') \|\mu - \mu'\|. \quad (2.7)$$

Les cas de mauvais transport d'erreur, suggérés par cette inégalité correspondent aux cas où les coefficients

$$\gamma = \frac{\|\Psi\|}{\langle \mu, \Psi \rangle} \geq 1, \quad \text{et} \quad \gamma' = \frac{\|\Psi\|}{\langle \mu', \Psi \rangle} \geq 1$$

sont très grands, i.e. lorsque la fonction de vraisemblance se concentre dans une zone de l'espace d'état faiblement chargée par les deux mesures. Or, même si μ et μ' sont très proches au sens faible, il est possible que sur une zone de mesure moindre ces deux distributions diffèrent sensiblement. Si, Ψ se concentre dans cette région de l'espace (γ et γ' grands) alors ces erreurs a priori négligeables deviennent prépondérantes après la correction. En fait, ces cas difficiles correspondent le plus souvent aux cas pratiques d'observations très précises ou encore d'observations incohérentes avec la mesure a priori (voir Figure 1.1). Pour fixer les idées, considérons l'exemple simple où nous disposons d'une observation bruitée, Y , de la variable aléatoire réelle, X telle que

$$Y = X + V, \quad \text{avec}$$

- V une v.a. indépendante de X suivant une loi gaussienne centrée d'écart-type σ_2 . La fonction de vraisemblance Ψ est alors telle que pour tout $x \in \mathbb{R}$,

$$\Psi(x) = \frac{1}{\sqrt{2\pi} \sigma_2} \exp\left[-\frac{1}{2} \frac{(x - Y)^2}{\sigma_2^2}\right].$$

- X une v.a. réelle gaussienne centrée d'écart-type σ_1 , de densité f , telle que pour tout $x \in \mathbb{R}$,

$$f(x) = \frac{1}{\sqrt{2\pi} \sigma_1} \exp\left[-\frac{1}{2} \frac{x^2}{\sigma_1^2}\right].$$

La mesure a priori vérifie alors $\mu(dx) = f(x) dx$, pour tout $x \in \mathbb{R}$.

Dans ce cas, si nous notons $\alpha = \sigma_2/\sigma_1$, le calcul du coefficient de coût donne

$$\gamma = \frac{\|\Psi\|}{\langle \mu, \Psi \rangle} = \frac{\|\Psi\|}{\int \Psi f} = \frac{\sqrt{1+\alpha^2}}{\alpha} \exp\left[\frac{1}{2} \left(\frac{Y}{\sigma_2}\right)^2 \left(1 + \frac{\alpha^2}{1+\alpha^2}\right)\right],$$

avec $\mathbb{E}\left[\left(\frac{Y}{\sigma_2}\right)^2\right] = 1 + 1/\alpha^2$. Ainsi, nous voyons que si l'observation est précise par rapport à l'information a priori (α petit), alors γ est grand. De même, si l'observation est aberrante i.e. non cohérente avec la prédiction ($|Y| \gg \sigma_2$, i.e. $|Y|$ grand devant σ_2), alors γ est grand, sans nécessairement que l'observation soit précise.

PREUVE DE LA PROPOSITION 2.5. L'inégalité (2.6) concernant le transport de l'erreur par la correction est une simple application du Lemme 2.4. L'inégalité (2.5) résulte des majorations suivantes.

$$\mathbb{E}|\langle Q\mu - Q\mu', \phi \rangle| = \mathbb{E}|\langle \mu - \mu', Q^*\phi \rangle| = \mathbb{E}|\langle \mu - \mu', \Phi \rangle|,$$

où Φ est une fonction sur E définie par $\Phi(x) = Q^*\phi(x) - \langle \mu', Q^*\phi \rangle$ pour tout $x \in E$. Il suffit maintenant de noter que

$$\begin{aligned} |\Phi(x)| &= \left| \int_E \int_E [Q(x, du) - Q(x', du)] \phi(u) \mu'(dx') \right| \\ &\leq \frac{1}{2} \|\phi\| \int_E \|Q(x, \cdot) - Q(x', \cdot)\| \mu'(dx') \\ &\leq \|\phi\| \beta(Q). \end{aligned}$$

□

Il semble donc que la distance faible ne soit pas vraiment adaptée à l'étude la propagation des erreurs, dans l'évolution du filtre optimal : l'information apportée par la distance faible étant trop pauvre pour garantir, en général, un bon contrôle de l'erreur à travers la correction.

2.1.2 Variation totale

On verra au Chapitre 5 que les filtres particuliers régularisés induisent une erreur locale contrôlable sous la variation totale. Il est donc utile, pour la suite, d'étudier ici la manière dont l'erreur se propage pour cette distance. Dans la suite de la section, Ψ_n désigne la fonction de vraisemblance associée au filtre optimal π_n donné.

Nous énonçons d'abord deux lemmes qui nous seront utiles.

Lemme 2.7. *Pour tout $x \in E$*

$$\mathbb{E}\left[\frac{\Psi_n(x)}{\langle \pi_n|_{n-1}, \Psi_n \rangle} \mid Y_{1:n-1}\right] = 1.$$

PREUVE DU LEMME 2.7. Rappelons que

$$\mathbb{P}[Y_n \in dy \mid X_n = x] = g_n(x, y) \lambda_n(dy),$$

par définition,

$$\mathbb{P}[Y_n \in dy \mid Y_{1:n-1}] = \left[\int_E g_n(x, y) \pi_n|_{n-1}(dx) \right] \lambda_n(dy).$$

Pour toute fonction test ψ définie sur F

$$\begin{aligned} \mathbb{E}\left[\frac{\psi(Y_n)}{\langle \pi_{n|n-1}, \Psi_n \rangle} \mid Y_{1:n-1}\right] &= \mathbb{E}\left[\frac{\psi(Y_n)}{\int_E g_n(x, Y_n) \pi_{n|n-1}(dx)} \mid Y_{1:n-1}\right] \\ &= \int_F \frac{\psi(y)}{\int_E g_n(x, y) \pi_{n|n-1}(dx)} \left[\int_E g_n(x, y) \pi_{n|n-1}(dx) \right] \lambda_n(dy) \\ &= \int_F \psi(y) \lambda_n(dy) . \end{aligned}$$

En particulier, si $\psi(y) = g_n(x, y)$, alors $\psi(Y_n) = \Psi_n(x)$ et

$$\mathbb{E}\left[\frac{\Psi_n(x)}{\langle \pi_{n|n-1}, \Psi_n \rangle} \mid Y_{1:n-1}\right] = \int_F g_n(x, y) \lambda_n(dy) = 1 .$$

□

Le lemme suivant nous servira à majorer la distance, en variation totale, entre deux mesures normalisées en fonction de la distance entre deux mesures non normalisées associées.

Lemme 2.8. *Pour toutes mesures non nulles μ et $\mu' \in \mathcal{M}^+(E)$, éventuellement aléatoires,*

$$\|\bar{\mu} - \bar{\mu}'\| \leq 2 \frac{\|\mu - \mu'\|}{\mu(E)} . \quad (2.8)$$

Pour toute fonction positive Ψ bornée sur E , et toutes mesures de probabilité μ et $\mu' \in \mathcal{P}(E)$ telles que $\langle \mu, \Psi \rangle > 0$ et $\langle \mu', \Psi \rangle > 0$,

$$\|\Psi \cdot \mu - \Psi \cdot \mu'\| \leq \min(\gamma, \gamma') \|\mu - \mu'\| . \quad (2.9)$$

Cette dernière inégalité (2.9) due à Hürzeler [55] est atteinte (voir [55, pp. 99–100]). Si de plus $\Psi = \Psi_n$ et les mesures positives μ et $\mu' \in \mathcal{M}^+(E)$ sont mesurables par rapport à $Y_{1:n-1}$, alors

$$\mathbb{E}[\|\Psi_n \cdot \mu - \Psi_n \cdot \mu'\| \mid Y_{1:n-1}] \leq 2 \int_E \mathbb{E}\left[\frac{\Psi_n(x)}{\langle \mu, \Psi_n \rangle} \mid Y_{1:n-1}\right] |\mu - \mu'| (dx) . \quad (2.10)$$

PREUVE DU LEMME 2.8. La preuve de l'inégalité (2.8) est une conséquence directe de la décomposition (2.4).

Considérons l'inégalité (2.9). Nous notons $\lambda = \mu + \mu'$, $\alpha = \frac{d\mu}{d\lambda}$ et $\alpha' = \frac{d\mu'}{d\lambda}$.

$$\begin{aligned} \|\Psi \cdot \mu - \Psi \cdot \mu'\| &= \left\| \frac{\Psi \mu}{\langle \mu, \Psi \rangle} - \frac{\Psi \mu'}{\langle \mu', \Psi \rangle} \right\| , \\ &= \left\| \frac{\Psi}{\langle \mu, \Psi \rangle} \left(\mu - \frac{\langle \mu, \Psi \rangle}{\langle \mu', \Psi \rangle} \mu' \right) \right\| . \end{aligned}$$

D'après le théorème de Scheffe,

$$\|\Psi \cdot \mu - \Psi \cdot \mu'\| = 2 \int_E \frac{\Psi(x)}{\langle \mu, \Psi \rangle} (\alpha(x) - \frac{\langle \mu, \Psi \rangle}{\langle \mu', \Psi \rangle} \alpha'(x))^+ \lambda(dx) \quad (2.11)$$

$$= 2 \int_E \frac{\Psi(x)}{\langle \mu, \Psi \rangle} (\alpha(x) - \frac{\langle \mu, \Psi \rangle}{\langle \mu', \Psi \rangle} \alpha'(x))^- \lambda(dx) . \quad (2.12)$$

Si $\langle \mu, \Psi \rangle \geq \langle \mu', \Psi \rangle$, nous utilisons la majoration (2.11), par la partie positive,

$$\|\Psi \cdot \mu - \Psi \cdot \mu'\| \leq 2 \int_E \frac{\Psi(x)}{\langle \mu, \Psi \rangle} (\alpha(x) - \alpha'(x))^+ \lambda(dx) \quad (2.13)$$

$$\begin{aligned} &\leq 2 \frac{\|\Psi\|}{\langle \mu, \Psi \rangle} \int_E (\alpha(x) - \alpha'(x))^+ \lambda(dx) \\ &= \frac{\|\Psi\|}{\langle \mu, \Psi \rangle} \|\mu - \mu'\| . \end{aligned} \quad (2.14)$$

Si $\langle \mu, \Psi \rangle \leq \langle \mu', \Psi \rangle$, nous utilisons la majoration (2.12), par la partie négative

$$\|\Psi \cdot \mu - \Psi \cdot \mu'\| \leq 2 \int_E \frac{\Psi(x)}{\langle \mu, \Psi \rangle} (\alpha(x) - \alpha'(x))^- \lambda(dx) , \quad (2.15)$$

ce qui conduit aussi à l'inégalité (2.14). Puis en intervertissant les rôles de μ et μ' nous avons aussi,

$$\|\Psi \cdot \mu - \Psi \cdot \mu'\| \leq \frac{\|\Psi\|}{\langle \mu', \Psi \rangle} \|\mu - \mu'\| .$$

Considérons enfin l'inégalité (2.10). D'après (2.13) et (2.15), nous avons l'inégalité

$$\|\Psi_n \cdot \mu - \Psi_n \cdot \mu'\| \leq 2 \int_E \frac{\Psi_n(x)}{\langle \mu, \Psi_n \rangle} |\alpha(x) - \alpha'(x)| \lambda(dx) , \quad (2.16)$$

valable même si μ et μ' ne sont pas de même masse. Puis, en prenant l'espérance conditionnellement aux observations passées, nous avons

$$\mathbb{E}[\|\Psi_n \cdot \mu - \Psi_n \cdot \mu'\| \mid Y_{1:n-1}] \leq 2 \int_E \mathbb{E}[\frac{\Psi_n(x)}{\langle \mu, \Psi_n \rangle} \mid Y_{1:n-1}] |\mu - \mu'| \lambda(dx) .$$

□

Nous pouvons maintenant énoncer la proposition suivante comme conséquence directe des deux lemmes précédents.

Proposition 2.9. *Pour toutes mesures de probabilité μ et $\mu' \in \mathcal{P}(E)$,*

$$\|Q\mu - Q\mu'\| \leq \beta(Q) \|\mu - \mu'\| . \quad (2.17)$$

$$\|\Psi \cdot \mu - \Psi \cdot \mu'\| \leq \min(\gamma, \gamma') \|\mu - \mu'\| . \quad (2.18)$$

Soit $\pi'_{n|n-1}$ une mesure de probabilité éventuellement aléatoire et mesurable par rapport à $Y_{1:n-1}$,

$$\mathbb{E}[\|\Psi_n \cdot \pi_{n|n-1} - \Psi_n \cdot \pi'_{n|n-1}\| \mid Y_{1:n-1}] \leq 2 \|\pi_{n|n-1} - \pi'_{n|n-1}\| . \quad (2.19)$$

On voit ici que les qualités de stabilité de la variation totale sont déjà meilleures que celles de la distance faible, le coût de transport à travers l'étape de correction étant deux fois moins grand (2.18). L'inégalité (2.19) nous garantit, de plus, que l'erreur est au plus doublée en moyenne avec la correction. Cependant, la Remarque 2.6 faite pour la distance faible est toujours valable pour la variation totale (sans le facteur 2 dans l'inégalité (2.7)). L'erreur en variation totale avant correction peut s'accroître considérablement après la correction si la vraisemblance se localise dans une zone faiblement chargée par μ et μ' . Ainsi, il reste impossible de contrôler correctement la propagation de l'erreur, même si celle-ci reste, a priori, nettement meilleure qu'avec la distance faible.

2.1.3 Distance de Kullback–Leibler

Clark, Ocone et Coumarbatch [22] ont montré que l'entropie relative entre deux filtres initialisés différemment constitue une supermartingale, son espérance ne peut donc que décroître avec le temps. Ce résultat a été obtenu pour un modèle assez général, où le processus formé par le couple état / observation est une chaîne de Markov à temps continu. Nous rappelons, dans cette sous-section, le résultat de Le Gland [70] pour le modèle état en temps continu / observation en temps discret.

Définition 2.10 (Distance de Kullback–Leibler). *Pour toutes mesures μ et $\mu' \in \mathcal{P}(E)$, telles que $\mu \ll \mu'$ (i.e. μ absolument continue par rapport à μ') et de densités respectives f et f' par rapport à une mesure positive de référence λ , nous appelons distance de Kullback–Leibler ou entropie relative entre μ et μ' , le réel*

$$k(\mu, \mu') = k(f, f') = \int_E \log\left(\frac{f}{f'}(x)\right) \mu(dx) .$$

La distance de Kullback–Leibler ne constitue pas une véritable distance puisqu'elle n'est pas symétrique en μ et μ' . Cette pseudo-distance est particulièrement utile pour traiter les lois conjointes de v.a. indépendantes car

$$k(f^{\otimes n}, f'^{\otimes n}) = n k(f, f') ,$$

ce qui permet de simplifier largement les calculs. De plus, K est invariant par changement de variable, i.e. si Φ est un difféomorphisme de E alors

$$k(\mu \circ \Phi^{-1}, \mu' \circ \Phi^{-1}) = k(\mu, \mu') .$$

On note tout de même que $k(\mu, \mu')$ peut être infini alors que $\mu \ll \mu'$. L'inégalité suivante (voir [43, p. 10]) permet de relier la distance de Kullback–Leibler à la distance en variation totale, plus classiquement utilisée.

$$\|\mu - \mu'\| \leq \sqrt{2 k(\mu, \mu')} . \quad (2.20)$$

Le transport d'erreur à travers la prédiction et la correction est caractérisée par la proposition suivante.

Proposition 2.11. *Pour toutes mesures de probabilité μ et $\mu' \in \mathcal{P}(E)$,*

$$k(Q\mu, Q\mu') \leq k(\mu, \mu') . \quad (2.21)$$

Soit $\pi'_{n|n-1} \in \mathcal{P}(E)$, une mesure de probabilité sur E mesurable par rapport à $Y_{1:n-1}$, et telle que $\pi_{n|n-1} \ll \pi'_{n|n-1}$,

$$\mathbb{E}[k(\Psi_n \cdot \pi_{n|n-1}, \Psi_n \cdot \pi'_{n|n-1}) \mid Y_{1:n-1}] \leq k(\pi_{n|n-1}, \pi'_{n|n-1}) . \quad (2.22)$$

Ce résultat montre que la distance de Kullback–Leibler est a priori mieux adaptée à l'étude du filtre que les métriques précédemment introduites puisqu'en moyenne l'erreur au sens de Kullback n'augmente pas après la correction. Malheureusement, les erreurs locales introduites par les filtres approchés que l'on considère ici sont difficilement contrôlables au sens de Kullback. De plus, la pseudo-distance de Kullback ne vérifie pas l'inégalité triangulaire et est pour cette raison, difficilement manipulable pour l'étude de la propagation d'erreurs locales intervenant à d'autres instants que l'instant initial.

PREUVE DE LA PROPOSITION 2.11. Nous ne reportons ici que la preuve de l'inégalité (2.22), voir Le Gland [70], pour la preuve de l'inégalité (2.21).

On note $f_{n|n-1}$ et $f'_{n|n-1}$ les densités respectives de $\pi_{n|n-1}$ et $\pi'_{n|n-1}$ par rapport à une mesure de référence λ_n éventuellement aléatoire. D'après le Lemme 2.7,

$$\begin{aligned} \mathbb{E}[k(\Psi_n \cdot \pi_{n|n-1}, \Psi_n \cdot \pi'_{n|n-1}) \mid Y_{1:n-1}] &= \mathbb{E}\left[\int_E \log\left(\frac{f_{n|n-1}}{f'_{n|n-1}}(x)\right) \Psi_n \cdot \pi_{n|n-1}(dx) \mid Y_{1:n-1}\right] \\ &\quad + \mathbb{E}\left[\int_E \log\left(\frac{\langle \pi'_{n|n-1}, \Psi_n \rangle}{\langle \pi_{n|n-1}, \Psi_n \rangle}\right) \Psi_n \cdot \pi_{n|n-1}(dx) \mid Y_{1:n-1}\right] \\ &= \int_E \log\left(\frac{f_{n|n-1}}{f'_{n|n-1}}(x)\right) \pi_{n|n-1}(dx) \\ &\quad + \mathbb{E}\left[\log\left(\frac{\langle \pi'_{n|n-1}, \Psi_n \rangle}{\langle \pi_{n|n-1}, \Psi_n \rangle}\right) \mid Y_{1:n-1}\right] . \end{aligned}$$

En utilisant de nouveau le Lemme 2.7 et l'inégalité de Jensen,

$$\mathbb{E}\left[\log\left(\frac{\langle \pi'_{n|n-1}, \Psi_n \rangle}{\langle \pi_{n|n-1}, \Psi_n \rangle}\right) \mid Y_{1:n-1}\right] \leq \log \mathbb{E}\frac{\langle \pi'_{n|n-1}, \Psi_n \rangle}{\langle \pi_{n|n-1}, \Psi_n \rangle} = 0 ,$$

ce qui termine la preuve. $\square$

2.1.4 Métrique de Hilbert

Comme nous l'avons annoncé, l'intérêt des métriques projectives est de faire disparaître le terme de normalisation de l'équation (1.5) résultant de l'application de la formule de Bayes, et ainsi de ramener l'étude du filtre optimal à celle d'un processus linéaire. Ces métriques usuellement utilisées en géométrie hyperbolique ont été introduites en filtrage par Da Prato, Fuhman et Malliavin [25, 26] et indépendamment par Atar et Zeitouni [4] pour l'étude de la stabilité du filtre optimal par rapport à sa condition initiale. Dans cette section, nous définissons la métrique de Hilbert et énonçons quelques unes de ses propriétés qui nous serviront par la suite.

Définition 2.12. Deux mesures positives μ et $\mu' \in \mathcal{M}^+(E)$ sont dites comparables, s'il existe des constantes strictement positives $0 < a \leq b$, telles que

$$a \mu'(A) \leq \mu(A) \leq b \mu'(A) , \quad (2.23)$$

pour tout borelien $A \subset E$.

Définition 2.13 (Propriété de mélange). *Le noyau positif K défini sur E est dit mélangeant, s'il existe une constante $0 < \varepsilon \leq 1$ (constante de mélange), et une mesure positive non nulle, $\lambda \in \mathcal{M}^+(E)$, telles que*

$$\varepsilon \lambda \leq K(x, \cdot) \leq \frac{1}{\varepsilon} \lambda ,$$

pour tout $x \in E$, i.e.

$$\varepsilon \lambda(A) \leq K(x, A) \leq \frac{1}{\varepsilon} \lambda(A) ,$$

pour tout $x \in E$, et tout borelien $A \subset E$.

La propriété de mélange est associée à un opérateur très peu dépendant de l'état de départ x . Un cas particulier où K est mélangeant est le cas extrême où $K(x, \cdot) = \lambda$ indépendant de x , dans ce cas $\varepsilon = 1$.

Définition 2.14 (Métrique de Hilbert). *La métrique de Hilbert sur $\mathcal{M}^+(E)$ est définie par*

$$h(\mu, \mu') = \begin{cases} \log \frac{\sup_{A: \mu'(A) > 0} \frac{\mu(A)}{\mu'(A)}}{\inf_{A: \mu'(A) > 0} \frac{\mu(A)}{\mu'(A)}} , & \text{si } \mu \text{ et } \mu' \text{ sont deux mesures non nulles et comparables,} \\ 0 , & \text{si } \mu = \mu' \equiv 0, \\ +\infty , & \text{dans les autres cas.} \end{cases} \quad (2.24)$$

Notons que les deux mesures positives μ et μ' sont comparables si et seulement si μ et μ' sont équivalentes avec des dérivées de Radon–Nikodym $\frac{d\mu}{d\mu'}$ et $\frac{d\mu'}{d\mu}$ bornées. Dans ce cas, l'égalité suivante est vérifiée

$$h(\mu, \mu') = \log \left[\sup_{A: \mu'(A) > 0} \frac{\mu(A)}{\mu'(A)} \sup_{A: \mu(A) > 0} \frac{\mu'(A)}{\mu(A)} \right] = \log \left(\left\| \frac{d\mu}{d\mu'} \right\| \left\| \frac{d\mu'}{d\mu} \right\| \right) . \quad (2.25)$$

Notons de plus que h est une métrique projective, i.e. qu'elle est invariante par multiplication par des réels positifs, ainsi $h(\mu, \mu') = h(\bar{\mu}, \bar{\mu}')$, pour toutes mesures μ et $\mu' \in \mathcal{M}^+(E)$. (En fait h est une pseudo métrique puisque $h(\mu, \mu') = 0$ n'implique pas $\mu \equiv \mu'$, pour avoir une véritable métrique il suffit de se restreindre à l'ensemble des probabilités comparables à une mesure donnée). Dans le contexte du filtrage non linéaire, cette propriété projective nous permettra de considérer la transformation linéaire $\mu \mapsto R_n \mu$ au lieu de la transformation non linéaire $\pi \mapsto \bar{R}_n(\pi) = R_n \pi / (R_n \pi)(E)$.

Le lemme suivant nous donne deux relations entre la métrique de Hilbert et la variation totale. La première inégalité due à Atar et Zeitouni [4] permet de majorer les erreurs en

variation totale par des erreurs au sens de la métrique de Hilbert. Nous avons développé la seconde inégalité pour permettre la majoration inverse.

Lemme 2.15. *Pour toutes mesures non nulles μ et $\mu' \in \mathcal{M}^+(E)$*

$$\|\bar{\mu} - \bar{\mu}'\| \leq \frac{2}{\log 3} h(\mu, \mu') . \quad (2.26)$$

Si de plus le noyau positif K défini sur E est mélangeant, avec pour constante de mélange $\varepsilon > 0$, alors

$$h(K\mu, K\mu') \leq \frac{1}{\varepsilon^2} \|\bar{\mu} - \bar{\mu}'\| . \quad (2.27)$$

PREUVE DU LEMME 2.15. La preuve de l'inégalité (2.26) est donnée dans [4].

Pour montrer la seconde inégalité, notons d'abord que pour toutes mesures non nulles μ et $\mu' \in \mathcal{M}^+(E)$,

$$\begin{aligned} h(\mu, \mu') &= \log \sup_{A: \mu'(A) > 0} \frac{\mu(A)}{\mu'(A)} + \log \sup_{A: \mu(A) > 0} \frac{\mu'(A)}{\mu(A)} \\ &\leq \sup_{A: \mu'(A) > 0} \frac{|\mu(A) - \mu'(A)|}{\mu'(A)} + \sup_{A: \mu(A) > 0} \frac{|\mu(A) - \mu'(A)|}{\mu(A)} , \end{aligned}$$

puisque $\log(1+x) \leq |x|$. Nous utilisons cette inégalité pour majorer $h(K\mu, K\mu') = h(K\bar{\mu}, K\bar{\mu}')$, nous introduisons

$$\Delta(A) = \frac{K\bar{\mu}(A) - K\bar{\mu}'(A)}{K\bar{\mu}'(A)} = \frac{\int_E (\bar{\mu} - \bar{\mu}')(dx) K(x, A)}{\int_E \bar{\mu}'(dx) K(x, A)} = \int_E (\bar{\mu} - \bar{\mu}')(dx) \Phi(x, A) ,$$

où pour tout $x \in E$ et tout borelien $A \subset E$, nous avons

$$\Phi(x, A) = \frac{K(x, A)}{\int_E \bar{\mu}'(dx) K(x, A)} \leq \frac{1}{\varepsilon^2} ,$$

d'après l'hypothèse de mélange de K . Par le théorème de Scheffe,

$$\int_E (\bar{\mu} - \bar{\mu}')^+(dx) = \int_E (\bar{\mu} - \bar{\mu}')^-(dx) = \frac{1}{2} \|\bar{\mu} - \bar{\mu}'\| ,$$

donc si $\Delta(A)$ est positif,

$$|\Delta(A)| \leq \int_E (\bar{\mu} - \bar{\mu}')^+(dx) \Phi(x, A) \leq \frac{1}{2\varepsilon^2} \|\bar{\mu} - \bar{\mu}'\| ,$$

de même, si $\Delta(A)$ est négatif,

$$|\Delta(A)| \leq \int_E (\bar{\mu} - \bar{\mu}')^-(dx) \Phi(x, A) \leq \frac{1}{2\varepsilon^2} \|\bar{\mu} - \bar{\mu}'\| .$$

□

On s'intéresse maintenant à la propriété de contraction des opérateurs linéaires sous la métrique de Hilbert.

Lemme 2.16 (Birkhoff [12] et Hopf [54]). *Soit K l'opérateur linéaire positif sur $\mathcal{M}^+(E)$ associé au noyau positif K défini sur E . K est une contraction sous la métrique de Hilbert, et*

$$\tau(K) = \sup_{0 < h(\mu, \mu') < \infty} \frac{h(K\mu, K\mu')}{h(\mu, \mu')} = \tanh\left[\frac{1}{4} H(K)\right], \quad (2.28)$$

où $H(K)$ est défini par

$$H(K) = \sup_{\mu, \mu'} h(K\mu, K\mu'),$$

où le sup est pris parmi les mesures μ et μ' positives et non nulles. $\tau(K)$ est appelée le taux de contraction de Birkhoff.

Nous voyons donc que $H(K) < \infty$ implique $\tau(K) < 1$. Un opérateur linéaire est contractant sous la métrique de Hilbert s'il envoie toute mesure positive dans un ensemble de mesures mutuellement équivalentes avec des densités dont les rapports mutuels sont uniformément bornés.

Le lemme précédent et la propriété projective de la métrique de Hilbert entraînent la proposition suivante, (à comparer aux Propositions 2.5, 2.9 et 2.11), caractérisant la propagation d'erreur à travers le filtre, sous la métrique de Hilbert.

Proposition 2.17. *Soit Q un noyau markovien, Ψ une fonction positive sur E . Pour toutes mesures μ et $\mu' \in \mathcal{M}^+(E)$ comparables,*

$$h(Q\mu, Q\mu') \leq \tau(Q) h(\mu, \mu'). \quad (2.29)$$

$$h(\Psi \cdot \mu, \Psi \cdot \mu') \leq h(\mu, \mu'). \quad (2.30)$$

Notons que le taux de contraction en variation totale est majoré par le taux de contraction sous la métrique de Hilbert, $\beta(Q) \leq \tau(Q)$, dans le cas particulier d'un espace d'état fini où Q est une matrice (voir [71]). C'est sous la métrique de Hilbert que la propagation d'erreur est la meilleure : la qualité projective de cette métrique rendant la correction contractante, contrairement aux métriques considérées précédemment.

Dans l'analyse de la stabilité du filtre développée sous la métrique de Hilbert, dans la Section 2.2, nous ne distinguons plus les étapes de prédiction et correction, car nous considérons globalement l'action de l'opérateur d'évolution du filtre optimal $\bar{R}_n$. Le lemme suivant permet de relier les propriétés de contraction de l'opérateur d'évolution à ses propriétés de mélange.

Lemme 2.18. *L'opérateur linéaire positif $R_n = \Psi_n Q_n$ défini sur $\mathcal{M}^+(E)$ est une contraction sous la métrique de Hilbert, avec pour taux de contraction de Birkhoff $\tau_n := \tau(R_n) \leq 1$. De plus*

(i) *Si R_n est mélangeant, avec la constante de mélange ε_n (éventuellement aléatoire), alors*

$$\tau_n \leq \frac{1 - \varepsilon_n^2}{1 + \varepsilon_n^2} < 1.$$

(ii) Si Q_n est mélangeant, avec la constante de mélange ε_n (déterministe) alors R_n est aussi mélangeant avec la même constante de mélange ε_n , et

$$\tau_n \leq \tau(Q_n) \leq \frac{1 - \varepsilon_n^2}{1 + \varepsilon_n^2} < 1 .$$

PREUVE DU LEMME 2.18. Par application directe du Lemme 2.16, R_n est une contraction sous la métrique de Hilbert comme opérateur linéaire positif sur $\mathcal{M}^+(E)$. Si R_n est mélangeant, il existe une constante $0 < \varepsilon_n \leq 1$, et une mesure positive $\lambda_n \in \mathcal{M}^+(E)$, telles que pour toutes mesures non nulles μ et $\mu' \in \mathcal{M}^+(E)$,

$$\varepsilon_n^2 \frac{\mu(E)}{\mu'(E)} R_n \mu' \leq \varepsilon_n \mu(E) \lambda_n \leq R_n \mu \leq \frac{1}{\varepsilon_n} \mu(E) \lambda_n \leq \frac{1}{\varepsilon_n^2} \frac{\mu(E)}{\mu'(E)} R_n \mu' ,$$

ainsi $R_n \mu$ et $R_n \mu'$ sont comparables. D'après l'équation (2.25),

$$H(R_n) = \sup_{\mu, \mu'} h(R_n \mu, R_n \mu') = \sup_{\mu, \mu'} \log \left(\left\| \frac{d(R_n \mu)}{d(R_n \mu')} \right\| \left\| \frac{d(R_n \mu')}{d(R_n \mu)} \right\| \right) \leq \log \frac{1}{\varepsilon_n^4} ,$$

où le sup est pris parmi les mesures positives non nulles. D'après le Lemme 2.16,

$$\tau_n = \tau(R_n) = \tanh\left[\frac{1}{4} H(R_n)\right] \leq \tanh\left(\log \frac{1}{\varepsilon_n}\right) = \frac{1 - \varepsilon_n^2}{1 + \varepsilon_n^2} < 1 ,$$

ce qui achève la preuve de (i).

Si Q_n est mélangeant, alors $R_n = \Psi_n Q_n$ l'est aussi, puisqu'alors

$$\varepsilon_n \Psi_n \lambda_n \leq R_n(x, \cdot) \leq \frac{1}{\varepsilon_n} \Psi_n \lambda_n ,$$

pour tout $x \in E$. On vérifie bien que $\Psi_n \lambda_n$ est une mesure finie non nulle puisque

$$0 < \langle \pi_{n|n-1}, \Psi_n \rangle \leq (\Psi_n \lambda_n)(E) \leq \|\Psi_n\| \lambda_n(E) < \infty .$$

Ainsi $R_n \mu$ et $R_n \mu'$ sont comparables pour toutes mesures non nulles μ et $\mu' \in \mathcal{M}^+(E)$, et leurs dérivées de Radon–Nikodym vérifient

$$\frac{d(R_n \mu)}{d(R_n \mu')} = \frac{d(Q_n \mu)}{d(Q_n \mu')} \mathbf{1}_{\{\Psi_n > 0\}} \leq \frac{d(Q_n \mu)}{d(Q_n \mu')} ,$$

de même en échangeant les rôles de μ et μ' . Par conséquent,

$$H(R_n) \leq \sup_{\mu, \mu'} \log \left(\left\| \frac{d(Q_n \mu)}{d(Q_n \mu')} \right\| \left\| \frac{d(Q_n \mu')}{d(Q_n \mu)} \right\| \right) = H(Q_n) \leq \log \frac{1}{\varepsilon_n^4} ,$$

où le sup est pris parmi les mesures positives non nulles. Puis, en utilisant de nouveau le Lemme 2.16, nous obtenons $\tau_n = \tau(R_n) \leq \tau(Q_n)$. $\square$

Remarque 2.19. Notons qu'il y a équivalence entre la propriété de mélange d'un noyau markovien Q et sa propriété de contraction stricte sous la métrique de Hilbert. En effet, nous savons déjà que Q mélangeant entraîne Q strictement contractant (Lemme 2.18). Supposons

que Q soit une contraction stricte sous la métrique de Hilbert, alors $H(Q) < \infty$. Ainsi, pour tout x et $x' \in E$, $Q(x, \cdot)$ et $Q(x', \cdot)$ sont équivalents et leurs dérivées de Radon–Nikodym mutuelles sont bornées, i.e.

$$\left\| \frac{dQ(x, \cdot)}{dQ(x', \cdot)} \right\| < \infty, \quad \left\| \frac{dQ(x', \cdot)}{dQ(x, \cdot)} \right\| < \infty.$$

Il existe donc une constante $\varepsilon > 0$ et une fonction positive a sur E^2 telles que

$$a(x, x') Q(x', \cdot) \leq Q(x, \cdot) \leq \frac{1}{\varepsilon} a(x, x') Q(x', \cdot).$$

En intégrant sur E , il vient

$$\varepsilon \leq a(x, x') \leq 1.$$

Nous obtenons alors l'inégalité de mélange,

$$\varepsilon Q(x', \cdot) \leq Q(x, \cdot) \leq \frac{1}{\varepsilon} Q(x', \cdot).$$

Plus généralement, un opérateur intégral positif R non identiquement nul est contractant si et seulement si pour tout x et $x' \in E$,

$$\varepsilon \frac{R(x', \cdot)}{R(x', E)} \leq \frac{R(x, \cdot)}{R(x, E)} \leq \frac{1}{\varepsilon} \frac{R(x', \cdot)}{R(x', E)},$$

ce qui est équivalent au mélange dans le cas où il existe deux constantes positives $0 < a \leq b$ telles que

$$a \leq \frac{R(x, E)}{R(x', E)} \leq b.$$

Remarque 2.20. D'après la preuve du Lemme 2.18, nous observons que $\tau(R_n) = \tau(Q_n)$ si par exemple Ψ_n possède pour support l'espace E tout entier. Ainsi, si Q_n n'est pas mélangeant, i.e. $\tau(Q_n) = 1$, il faut nécessairement que la fonction Ψ_n s'annule en au moins un point de l'espace pour avoir $\tau(R_n) < 1$ et a fortiori pour avoir R_n mélangeant. Cela montre la force de la contrainte imposée par la condition de mélange de R_n .

Dans la suite, pour tout entier $m \leq n$, on note le produit des taux de contraction $\tau_n \cdots \tau_m = \tau_{n:m}$, et par convention $\tau_{n:n+1} = \tau_{m-1:m} = 1$. On utilisera communément la majoration suivante du taux de contraction du produit $R_{n:m} = R_n \cdots R_m$,

$$\tau(R_{n:m}) \leq \tau_n \cdots \tau_m = \tau_{n:m}.$$

2.1.5 Conclusion

Cette dernière section montre que le choix de la métrique est déterminant pour le contrôle de l'erreur commise par le filtre approché. L'évolution du filtre se fait en deux étapes : une étape de prédiction linéaire et une étape de correction non linéaire. Nous avons observé que pour les quatre distances (ou pseudo-distances) considérées (faible, variation totale, Kullback, Hilbert) l'étape de prédiction contracte l'erreur. Par contre l'étape de correction est plus difficile à contrôler, elle a de fortes chances d'augmenter largement l'erreur pour la distance

faible, un peu moins pour la variation totale, alors qu'elle contracte l'erreur en moyenne pour la distance de Kullback et presque sûrement pour la distance de Hilbert.

Il est alors intéressant de développer l'étude de stabilité sous une métrique choisie pour ses qualités de propagation d'erreur (Hilbert, Kullback) même si le but final est de majorer l'erreur sous un autre critère (variation totale, distance faible). Dans ce cas, les majorations (2.26), (2.27) et (2.20) permettent de passer d'une métrique à l'autre. Ce préliminaire sur le choix des métriques permet de dégager les deux idées suivantes.

- Pour analyser précisément les erreurs commises par une méthode donnée d'approximation du filtre optimal il faut choisir une métrique permettant à la fois, un bon contrôle des erreurs locales et une bonne propagation de ces erreurs.
- Inversement, si l'on désire proposer une nouvelle méthode d'approximation du filtre optimal basée sur des perturbations locales, il vaut mieux choisir des perturbations locales qui soient contrôlées par une métrique stable à travers l'évolution du filtre optimal.

Nous appliquerons la première idée dans l'étude de stabilité de la section suivante, et la seconde idée, au Chapitre 5 pour le développement des filtres particuliers régularisés.

2.2 Résultats de stabilité

D'un point de vue pratique, l'étude de la sensibilité du filtre optimal aux erreurs de modèle est largement justifiée car dans les applications réelles, les utilisateurs ont rarement accès aux véritables caractéristiques du système. En particulier la loi initiale du filtre est inconnue. Dans cette section, nous étudions dans un premier temps la sensibilité du filtre à sa condition initiale en utilisant l'approche hilbertienne. Nous obtenons dans ce cas un résultat qui améliore sensiblement celui obtenu par Atar et Zeitouni [4]. L'originalité de cette section réside surtout dans le fait que nous nous intéressons, dans un deuxième temps, à l'étude de la sensibilité du filtre à une grande classe de perturbations locales. Une telle étude dans un cadre aussi général que celui abordé ici (quand aux types de perturbations considérées) ne figure pas à notre connaissance dans la littérature.

Considérons π_n le filtre bien initialisé avec la vraie condition initiale π_0 , et π'_n le filtre mal initialisé avec la fausse condition initiale π'_0 , i.e. $\pi_n = \bar{R}_{n:1}(\pi_0)$ et $\pi'_n = \bar{R}_{n:1}(\pi'_0)$. On s'intéresse à l'erreur en variation totale à l'instant n induite par l'erreur initiale.

Théorème 2.21. *Sans aucune hypothèse sur les noyaux positifs, les inégalités suivantes sont vérifiées*

$$\|\pi_n - \pi'_n\| \leq \frac{2}{\log 3} \tau_{n:m} h(\pi_{m-1}, \pi'_{m-1}) . \quad (2.31)$$

Si de plus le noyau R_m est mélangeant, avec la constante de mélange $\varepsilon_m > 0$, alors

$$\|\pi_n - \pi'_n\| \leq \frac{2}{\log 3} \tau_{n:m+1} \frac{1}{\varepsilon_m^2} \|\pi_{m-1} - \pi'_{m-1}\| . \quad (2.32)$$

Nous introduisons ici l'Hypothèse **[R]** de mélange.

Hypothèse [R] : l'opérateur intégral R_k est mélangeant, i.e. il existe une constante positive ε_k et une mesure positive λ_k telles que

$$\varepsilon_k \lambda_k \leq R_k(x, \cdot) \leq \frac{1}{\varepsilon_k} \lambda_k ,$$

pour tout $x \in E$.

Notons qu'en toute généralité ε_k et λ_k dependent de l'observation Y_k et sont donc des variables aléatoires.

Corollaire 2.22. *Si pour tout entier $k \geq 1$, l'Hypothèse **[R]** est vérifiée, avec $\varepsilon_k \geq \varepsilon > 0$, alors*

$$\|\pi_n - \pi'_n\| \leq \frac{2}{\varepsilon^2 \log 3} \tau^{n-m} \|\pi_{m-1} - \pi'_{m-1}\| \quad \text{avec} \quad \tau := \frac{1 - \varepsilon^2}{1 + \varepsilon^2} .$$

Ce corollaire améliore le résultat d'Atar et Zeitouni [4] puisque leur condition forte sur la vraisemblance (vraisemblance bornée inférieurement) est ici relâchée. De plus, dans [4], on se contente d'une inégalité du type (2.31), l'erreur en variation totale à l'instant n n'est pas donnée de façon lipschitzienne en fonction de l'erreur en variation totale à l'instant initial. Cependant, les conditions de mélange sur le noyau de transition sont conservées, pour montrer que le filtre optimal est asymptotiquement exponentiellement stable. Par une autre approche, Del Moral et Guionnet [33] montrent aussi l'oubli exponentiel de la condition initiale par le filtre optimal toujours sous l'hypothèse de mélange. Cependant leur résultat ne fournit pas de relation lipschitzienne entre l'erreur à l'instant n et l'erreur initiale. Le caractère lipschitzien de l'erreur donnée par le Théorème 2.21 permettra, dans la suite, de mener facilement l'étude de la sensibilité du filtre à des perturbations locales.

PREUVE DU THÉORÈME 2.21. D'après l'inégalité (2.26), et la définition (2.28) du taux de contraction de Birkhoff, nous avons

$$\|\bar{R}_{n:m}(\pi) - \bar{R}_{n:m}(\pi')\| \leq \frac{2}{\log 3} h(R_{n:m} \pi, R_{n:m} \pi') \leq \frac{2}{\log 3} \tau_{n:m} h(\pi, \pi') , \quad (2.33)$$

pour toutes mesures de probabilité π et $\pi' \in \mathcal{P}(E)$. Si le noyau R_m est mélangeant, d'après (2.27), on a

$$\begin{aligned} \|\bar{R}_{n:m}(\pi) - \bar{R}_{n:m}(\pi')\| &\leq \frac{2}{\log 3} h(R_{n:m+1} R_m \pi, R_{n:m+1} R_m \pi') \\ &\leq \frac{2}{\log 3} \tau_{n:m+1} h(R_m \pi, R_m \pi') \leq \frac{2}{\log 3} \tau_{n:m+1} \frac{1}{\varepsilon_m^2} \|\pi - \pi'\| . \end{aligned} \quad (2.34)$$

En prenant $\pi = \pi_m$ et $\pi' = \pi'_m$ nous obtenons directement la preuve du théorème. $\square$

Ces résultats de stabilité par rapport à la condition initiale vont nous être utiles pour l'étude de la stabilité par rapport au modèle. Pour traiter le problème du filtrage non linéaire, on doit disposer d'un modèle décrivant le système état / observation, $(X_n, Y_n)_{n \geq 0}$, comme cela a été décrit au premier chapitre. Le modèle général de Markov caché est constitué de

la condition initiale π_0 , du noyau de transition Q_n et de la fonction de vraisemblance Ψ_n , ce qui permet de définir l'opérateur d'évolution R_n du filtre optimal π_n . Mais, comme pour la condition initiale, en pratique, on a rarement accès au véritable modèle. En particulier, la dynamique a priori de l'état est en général inconnue, et le choix de Q_n est approximatif. Le choix d'un modèle pour le bruit d'observation est lui aussi difficile. Ainsi, au lieu d'utiliser le vrai modèle il est courant qu'on utilise un mauvais modèle constitué d'un mauvais noyau de transition Q'_n et d'une mauvaise fonction de vraisemblance Ψ'_n , ce qui finalement produit un mauvais opérateur d'évolution R'_n pour un mauvais filtre π'_n .

Par ailleurs, dans le cas où l'opérateur d'évolution R_n est connu, il n'est en général pas pour autant facile à calculer. Comme nous l'avons déjà évoqué au début de ce chapitre, une démarche classique est alors de construire un filtre approché π'_n (par exemple un filtre particulière) tel que l'évolution $\pi'_{n-1} \mapsto \pi'_n$ est facile à calculer tout en restant proche de la véritable évolution du filtre optimal, $\pi'_{n-1} \mapsto \bar{R}_n(\pi'_{n-1})$. On introduit, cette fois, volontairement des perturbations locales dans l'évolution du filtre optimal qui peuvent s'identifier à des erreurs de modèle.

On s'intéresse ici à majorer l'erreur globale entre π'_n et π_n induite par les erreurs locales introduites volontairement ou non, à chaque pas de temps. On suppose que $\pi_0 = \pi'_0$, puisque l'influence d'une mauvaise initialisation a déjà été étudiée. En toute généralité, nous supposons que $(\pi'_k)_{k \geq 0}$ est une suite à valeurs dans $\mathcal{P}(E)$, satisfaisant la propriété : pour tout $n \geq k \geq 0$ et pour toute fonction mesurable et bornée F définie sur $\mathcal{P}(E)$

$$\mathbb{E}[F(\pi'_k) \mid Y_{1:n}] = \mathbb{E}[F(\pi'_k) \mid Y_{1:k}]. \quad (2.35)$$

Les résultats énoncés plus bas sont basés sur la décomposition suivante de l'erreur globale en somme d'erreurs locales transportées par une suite d'opérateurs d'évolution non linéaires (du fait de la normalisation) $\bar{R}_n$,

$$\pi'_n - \pi_n = \sum_{k=1}^n [\bar{R}_{n:k+1}(\pi'_k) - \bar{R}_{n:k}(\pi'_{k-1})] = \sum_{k=1}^n [\bar{R}_{n:k+1}(\pi'_k) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi'_{k-1})]. \quad (2.36)$$

Cette équation montre clairement le lien entre stabilité par rapport à la condition initiale et stabilité par rapport au modèle.

2.2.1 Au sens de la métrique de Hilbert

Considérons, dans un premier temps, le cas où les erreurs locales sont contrôlées au sens de la distance de Hilbert.

Hypothèse [H] (erreur locale bornée sous la métrique de Hilbert) :

$$\delta_k^H = \mathbb{E}[h(\pi'_k, \bar{R}_k(\pi'_{k-1})) \mid Y_{1:k}] < \infty.$$

Notons que si le mauvais filtre π'_k suit une évolution déterministe (conditionnellement aux observations) telle que

$$\pi'_k(dx') = \int \pi'_{k-1}(dx) R'_k(x, dx') = \int \pi'_{k-1}(dx) \Psi'_k(x') Q'_k(x, dx'),$$

avec de plus $Q_k(x, dx') = q_k(x, x') \lambda_k(dx')$ et $Q'_k(x, dx') = q'_k(x, x') \lambda_k(dx')$, alors une condition suffisante pour que l'Hypothèse **[H]** soit vérifiée est que pour tout entier $k > 0$ il existe des constantes $d_k \geq 0$ et $a_k > 0$ vérifiant

$$a_k \leq \frac{\Psi_k(x') q_k(x, x')}{\Psi'_k(x') q'_k(x, x')} \leq a_k \exp(d_k) , \quad (2.37)$$

pour tout $x, x' \in E$. Dans ce cas, $\delta_k^H \leq d_k$.

Remarque 2.23. Cette métrique est particulièrement adaptée à l'étude de la robustesse du filtre par rapport à d'éventuelles erreurs de modèle sur la puissance des bruits d'observation ou d'état. Par exemple, considérons le cas suivant, d'observations réelles telles que

$$Y_k = h(X_k) + V_k ,$$

avec $(V_n)_{n \geq 1}$ i.i.d. suivant la loi gaussienne centrée de variance σ^2 et h une fonction bornée sur $\mathbb{R}$, par la constante M . On s'intéresse au filtre construit avec une fausse variance des bruits d'observation, σ'^2 , mais avec les bonnes densités q_k des noyaux de transitions. En utilisant la condition suffisante (2.37), on obtient la majoration

$$\delta_k^H \leq 2 (2 M^2 + V_k^2) |\sigma^{-2} - \sigma'^{-2}| .$$

L'erreur locale au sens de la métrique de Hilbert est donc contrôlée en moyenne par la majoration,

$$\mathbb{E}(\delta_k^H) \leq 2 (2 M^2 + \sigma^2) |\sigma^{-2} - \sigma'^{-2}| ,$$

qui tend donc vers zéro, lorsque σ tend vers σ' .

Le théorème suivant permet de majorer l'erreur globale au sens de la variation totale, lorsque l'erreur locale est contrôlée sous la métrique de Hilbert.

Théorème 2.24. *Si pour tout entier $k \geq 1$, l'Hypothèse **[H]** est vérifiée, alors*

$$\mathbb{E}[\|\pi'_n - \pi_n\| \mid Y_{1:n}] \leq \frac{2}{\log 3} \sum_{k=1}^n \tau_{n:k+1} \delta_k^H . \quad (2.38)$$

Sans aucune hypothèse sur les noyaux de transition ou sur les vraisemblances, nous obtenons une majoration d'erreur tout à fait satisfaisante (croissance au pire linéaire avec le temps). Les erreurs locales, δ_k^H , se propagent bien à travers le filtre puisqu'elles sont progressivement oubliées ($\tau_{n:k+1} \delta_k$). On retrouve donc ce que l'on avait annoncé dans la section précédente: les erreurs locales contrôlables sous la métrique de Hilbert (Hypothèse **[H]**) ont une bonne qualité de propagation à travers le filtre. L'intérêt de ce théorème est réel pour l'étude de robustesse par rapport à des erreurs d'évaluation des puissances des bruits (voir Remarque 2.23). Notons par ailleurs que ce résultat ne pouvait pas être obtenu si l'étude de stabilité avait été menée sous la variation totale (encore moins au sens faible) puisqu'il fallait ici exploiter le contrôle au sens de la métrique de Hilbert de l'erreur initiale.

Le corollaire suivant fournit une majoration de l'erreur globale uniforme en temps, sous l'hypothèse de mélange.

Corollaire 2.25. *Si pour tout entier $k \geq 1$, les Hypothèses **[H]****[R]** sont vérifiées, avec $\delta_k^H \leq \delta^H$ et $\varepsilon_k \geq \varepsilon > 0$, alors*

$$\mathbb{E}[\|\pi_n - \pi'_n\| \mid Y_{1:n}] \leq \frac{2}{\varepsilon^2 \log 3} \delta^H . \quad (2.39)$$

En effet

$$\sum_{k=1}^n \tau^{n-k} = \frac{1 - \tau^n}{1 - \tau} \leq \frac{1}{1 - \tau} = \frac{1 + \varepsilon^2}{2\varepsilon^2} \leq \frac{1}{\varepsilon^2} .$$

PREUVE DU THÉORÈME 2.24. En utilisant l'inégalité triangulaire, puis l'estimée (2.33) dans la décomposition (2.36), nous obtenons

$$\|\pi'_n - \pi_n\| \leq \sum_{k=1}^n \|\bar{R}_{n:k+1}(\pi'_k) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi'_{k-1})\| \leq \frac{2}{\log 3} \sum_{k=1}^n \tau_{n:k+1} h(\pi'_k, \bar{R}_k(\pi'_{k-1})) . \quad (2.40)$$

Si l'Hypothèse **[H]** est vérifiée, d'après la propriété (2.35), nous avons

$$\mathbb{E}[h(\pi'_k, \bar{R}_k(\pi'_{k-1})) \mid Y_{1:n}] = \mathbb{E}[h(\pi'_k, \bar{R}_k(\pi'_{k-1})) \mid Y_{1:k}] \leq \delta_k^H ,$$

ainsi, en prenant l'espérance conditionnelle par rapport aux observations, dans (2.40), nous obtenons (2.38). $\square$

Malheureusement, on se retrouve le plus souvent confronté à des erreurs locales qui ne sont pas contrôlables sous la métrique de Hilbert. On verra par la suite, que les méthodes particulières classiques et régularisées induisent des erreurs locales contrôlées respectivement au sens faible et au sens de la variation totale.

2.2.2 Au sens de la Variation Totale

Considérons maintenant le cas où l'erreur locale est contrôlée au sens de la variation totale. On note

$$\delta_k^{VT} = \mathbb{E}[\|\pi'_k - \bar{R}_k(\pi'_{k-1})\| \mid Y_{1:k}] \leq 2 .$$

Théorème 2.26. *Si pour tout entier $k \geq 1$, l'Hypothèse **[R]** est vérifiée, avec la constante de mélange $\varepsilon_k > 0$, alors*

$$\mathbb{E}[\|\pi_n - \pi'_n\| \mid Y_{1:n}] \leq \delta_n^{VT} + \frac{2}{\log 3} \sum_{k=1}^{n-1} \tau_{n:k+2} \frac{\delta_k^{VT}}{\varepsilon_{k+1}^2} . \quad (2.41)$$

L'hypothèse de mélange est ici nécessaire pour assurer une bonne propagation d'erreur. On note que lorsque l'erreur locale est contrôlée au sens de la métrique de Hilbert (Théorème 2.24), cette hypothèse n'est pas nécessaire pour assurer un contrôle de l'erreur globale linéaire en temps. L'introduction de l'hypothèse supplémentaire de mélange permet de compenser la moindre information sur l'erreur fournie par la variation totale par rapport à la métrique de Hilbert (voir l'inégalité (2.26)).

Corollaire 2.27. *Si pour tout entier $k \geq 1$, l'Hypothèse **[R]** est vérifiée avec $\delta_k^{VT} \leq \delta^{VT}$ et $\varepsilon_k \geq \varepsilon > 0$, alors*

$$\mathbb{E}[\|\pi_n - \pi'_n\| \mid Y_{1:n}] \leq (1 + \frac{2}{\varepsilon^4 \log 3}) \delta^{VT} . \quad (2.42)$$

PREUVE DU THÉORÈME 2.26. La décomposition (2.36) s'écrit

$$\pi'_n - \pi_n = [\pi'_n - \bar{R}_n \pi'_{n-1}] + \sum_{k=1}^{n-1} [\bar{R}_{n:k+1}(\pi'_k) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi'_{k-1})] , \quad (2.43)$$

par l'inégalité triangulaire, et d'après l'estimée (2.34), nous avons

$$\begin{aligned} \|\pi'_n - \pi_n\| &\leq \|\pi'_n - \bar{R}_n \pi'_{n-1}\| + \sum_{k=1}^{n-1} \|\bar{R}_{n:k+1}(\pi'_k) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi'_{k-1})\| \\ &\leq \|\pi'_n - \bar{R}_n(\pi'_{n-1})\| + \frac{2}{\log 3} \sum_{k=1}^{n-1} \tau_{n:k+2} \frac{1}{\varepsilon_{k+1}^2} \|\pi'_k - \bar{R}_k(\pi'_{k-1})\| . \end{aligned}$$

En prenant l'espérance conditionnelle par rapport aux observations, nous obtenons

$$\mathbb{E}[\|\pi'_n - \pi_n\| \mid Y_{1:n}] \leq \delta_n^{\text{VT}} + \frac{2}{\log 3} \sum_{k=1}^{n-1} \tau_{n:k+2} \frac{\delta_k^{\text{VT}}}{\varepsilon_{k+1}^2} .$$

□

Dans le cas plus général où aucune hypothèse de mélange n'est faite, nous pouvons toujours majorer l'erreur, mais la majoration obtenue n'est plus uniforme en temps. Nous introduisons d'abord une hypothèse supplémentaire sur l'existence d'une borne inférieure uniforme des moyennes de la fonction de vraisemblance Ψ_n contre les transitions $Q_n(x, \cdot)$.

Hypothèse [QΨ] :

$$0 < m_k = \inf_{x \in E} \langle Q_k(x, \cdot), \Psi_k \rangle .$$

Nous notons alors $\gamma_k = \frac{M_k}{m_k}$, et si $n \geq m \geq 1$ nous notons le produit $\gamma_n \cdots \gamma_m = \gamma_{n:m}$.

Remarque 2.28. L'hypothèse de l'existence d'un minorant $m_k > 0$ est forte. Dans le cas d'une dynamique déterministe (noyau dégénéré) et d'un bruit d'observation additif, si la densité g_k du bruit est non nulle sur tout compact de F , l'hypothèse sera vérifiée si la fonction de dynamique de l'état f_k est bornée (ce qui n'est pas souvent le cas). On note, de plus, les points suivants.

– On a toujours

$$\bar{\gamma}_k = \frac{M_k}{\langle Q_k \pi_{k-1}, \Psi_k \rangle} \leq \gamma_k .$$

– Si la fonction de vraisemblance est bornée supérieurement et inférieurement, i.e.

$$0 < \inf_{x \in E} \Psi_k(x) , \quad \text{et} \quad M_k = \sup_{x \in E} \Psi_k(x) < \infty ,$$

alors $\gamma_k < \infty$ puisque

$$0 < \inf_{x \in E} \Psi_k(x) \leq \inf_{x \in E} \langle Q_k(x, \cdot), \Psi_k \rangle .$$

- Si la fonction de vraisemblance est bornée supérieurement et R_k est mélangeant alors

$$\gamma_k \leq \bar{\gamma}_k / \varepsilon_k^2 < \infty .$$

En effet, dans ce cas

$$\varepsilon_k^2 \langle Q_k \pi_{k-1}, \Psi_k \rangle \leq \langle Q_k(x, \cdot), \Psi_k \rangle ,$$

pour tout $x \in E$.

Nous énonçons le résultat de stabilité sans les hypothèses de mélange ni $[\mathbf{Q}\Psi]$.

Proposition 2.29. *Sans aucune hypothèse,*

$$\mathbb{E}[\|\pi_n - \pi'_n\| \mid Y_{1:n}] \leq \sum_{k=1}^n \beta_{n:k+1} \bar{\gamma}_{n:k+1} \delta_k^{VT} , \quad (2.44)$$

en notant le produit $\bar{\gamma}_{n:k+1} = \bar{\gamma}_n \cdots \bar{\gamma}_{k+1}$.

Si on relâche l'hypothèse de mélange, le contrôle de l'erreur est automatiquement moins bon. Les erreurs locales commises sont d'un côté, atténuées par les propriétés d'oubli des noyaux de transition Q_k (produit des taux de contraction $\beta_{n:k+1}$), mais elles sont d'un autre côté, amplifiées à travers les corrections successives (produit des coefficients de transport $\bar{\gamma}_{n:k+1}$). On peut néanmoins considérer que cette majoration d'erreur reste raisonnable. Même si les coefficients de transport $\bar{\gamma}_{n:k+1}$ ne sont pas contrôlables, ils ont une interprétation assez claire (liée à la cohérence et la précision des observations par rapport à la prédiction) qui permet de donner un sens aux majorations d'erreur. Ainsi, il semblerait que plus les informations apportées par les observations sont riches (au sens où elles sont précises ou bien différentes par rapport à ce qu'on pouvait prédire) plus les erreurs locales commises se ressentent fortement dans l'erreur globale.

PREUVE DE LA PROPOSITION 2.29. On utilise une décomposition de l'erreur différente de (2.36) puis l'inégalité (2.9) du Lemme 2.8 pour la dénormalisation,

$$\begin{aligned} \mathbb{E}[\|\pi'_n - \pi_n\| \mid Y_{1:n}] &\leq \mathbb{E}[\|\bar{R}_n(\pi_{n-1}) - \bar{R}_n(\pi'_{n-1})\| \mid Y_{1:n}] + \mathbb{E}[\|\bar{R}_n(\pi'_{n-1}) - \pi'_n\| \mid Y_{1:n}] \\ &\leq \beta_n \bar{\gamma}_n \mathbb{E}[\|\pi'_{n-1} - \pi_{n-1}\| \mid Y_{1:n-1}] + \delta_n^{VT} , \end{aligned}$$

où $\beta_k = \beta(Q_k)$ désigne le taux de contraction de Q_k pour la variation totale. Cela entraîne par récurrence,

$$\mathbb{E}[\|\pi'_n - \pi_n\| \mid Y_{1:n}] \leq \sum_{k=1}^n \beta_{n:k+1} \bar{\gamma}_{n:k+1} \delta_k^{VT} ,$$

□

Remarque 2.30. On aurait pu utiliser de nouveau la décomposition (2.36), mais cela conduit au résultat moins précis, et plus contraignant (valable uniquement sous l'Hypothèse $[\mathbf{Q}\Psi]$) suivant :

$$\mathbb{E}[\|\pi_n - \pi'_n\| \mid Y_{1:n}] \leq 2 \sum_{k=1}^n \beta_{n:k+1} \gamma_{n:k+1} \delta_k^{VT} , \quad (2.45)$$

en notant que le produit $\gamma_{n:k+1} = \gamma_n \cdots \gamma_{k+1} \geq \bar{\gamma}_{n:k+1}$. En effet,

$$\|\pi'_n - \pi_n\| \leq \sum_{k=1}^n \|\bar{R}_{n:k+1}(\pi'_k) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi'_{k-1})\|.$$

D'après l'inégalité (2.8) pour la dénormalisation, on a

$$\|\pi'_n - \pi_n\| \leq \sum_{k=1}^n \frac{2}{R_{n:k+1}(\pi'_k)(E)} \|R_{n:k+1}[\pi'_k - \bar{R}_k(\pi'_{k-1})]\|.$$

En remarquant que le terme de normalisation s'écrit comme le produit,

$$R_{n:k+1}(\pi'_k)(E) = \langle Q_n \bar{R}_{n-1:k+1}(\pi'_k), \Psi_n \rangle \cdots \langle Q_{k+2} \bar{R}_{k+1}(\pi'_k), \Psi_{k+2} \rangle \langle Q_{k+1} \pi'_k, \Psi_{k+1} \rangle \geq m_{n:k+1}.$$

On obtient finalement,

$$\|\pi'_n - \pi_n\| \leq 2 \sum_{k=1}^n \beta_{n:k+1} \gamma_{n:k+1} \|\pi'_k - \bar{R}_k(\pi'_{k-1})\|. \quad (2.46)$$

2.2.3 Au sens faible

Finalement, on considère le cas où on ne peut contrôler l'erreur locale qu'au sens faible. On note

$$\delta_k^F = \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi'_k - \bar{R}_k(\pi'_{k-1}), \phi \rangle| \mid Y_{1:k}] \leq 2.$$

Par exemple si l'estimée π'_k est une mesure empirique associée à $\bar{R}_k(\pi'_{k-1})$, le contrôle de l'erreur se fait par application de la loi des grands nombres qui ne peut nous fournir qu'une estimée au sens faible de l'erreur. Néanmoins le lemme suivant montre que sous certaines conditions de régularité du noyau R_k , on peut toujours majorer en variation totale l'erreur locale lorsqu'elle est transportée par un opérateur d'évolution.

Lemme 2.31. *Si le noyau positif K défini sur E est dominé, i.e. s'il existe une constante $c > 0$, et une mesure de probabilité $\nu \in \mathcal{P}(E)$, telles que*

$$K(x, \cdot) \leq c \nu, \quad (2.47)$$

pour tout $x \in E$, alors

$$\mathbb{E} \|K \mu - K \mu'\| \leq c \sup_{\|\phi\|=1} \mathbb{E} |\langle \mu - \mu', \phi \rangle|, \quad (2.48)$$

pour toutes mesures μ et $\mu' \in \mathcal{M}^+(E)$, éventuellement aléatoires.

Remarque 2.32. Si le noyau positif K est mélangeant au sens de la Définition 2.13, alors il est dominé, par la mesure de probabilité $\bar{\lambda} = \lambda/\lambda(E) \in \mathcal{P}(E)$, avec la constante $c = \lambda(E)/\varepsilon$. D'autre part, d'après la preuve, l'estimée (2.48) reste vraie avec des espérances conditionnelles pourvu que λ soit mesurable par rapport à la condition.

PREUVE DU LEMME 2.31. Par définition, si K est dominé, alors $K(x, \cdot)$ est absolument continu par rapport à ν , avec une dérivée de Radon–Nikodym $k(x, \cdot)$ bornée par c . Ainsi la distance en variation totale $\|K\mu - K\mu'\|$ peut s'écrire

$$\|K\mu - K\mu'\| = \int_E \left| \int_E (\mu - \mu')(dx) k(x, x') \right| \nu(dx'),$$

puis en prenant l'espérance, nous avons

$$\begin{aligned} \mathbb{E} \|K\mu - K\mu'\| &= \int_E \mathbb{E} \left| \int_E (\mu - \mu')(dx) k(x, x') \right| \nu(dx') \\ &\leq \sup_{\|\phi\|=1} \mathbb{E} |\langle \mu - \mu', \phi \rangle| \int_E \left[\sup_{x \in E} k(x, x') \right] \nu(dx'). \end{aligned}$$

□

Nous énonçons ici les résultats de stabilité du filtre sous l'hypothèse de mélange.

Théorème 2.33. *Si pour tout entier $k \geq 1$, l'Hypothèse **[R]** est vérifiée, alors*

$$\sup_{\|\phi\|=1} \mathbb{E} [|\langle \pi_n - \pi'_n, \phi \rangle| \mid Y_{1:n}] \leq \delta_n^F + 2 \frac{\delta_{n-1}^F}{\varepsilon_n^2} + \frac{4}{\log 3} \sum_{k=1}^{n-2} \tau_{n:k+3} \frac{\delta_k^F}{\varepsilon_{k+2}^2 \varepsilon_{k+1}^2}. \quad (2.49)$$

Corollaire 2.34. *Si pour tout entier $k \geq 1$, les Hypothèses **[R]** est vérifiée, avec $\delta_k^F \leq \delta^F$ et la constante de mélange $\varepsilon_k \geq \varepsilon > 0$, alors*

$$\sup_{\|\phi\|=1} \mathbb{E} [|\langle \pi_n - \pi'_n, \phi \rangle| \mid Y_{1:n}] \leq \left(1 + \frac{2}{\varepsilon^2} + \frac{4}{\varepsilon^6 \log 3}\right) \delta^F. \quad (2.50)$$

La majoration est un peu moins bonne que sous la variation totale, mais l'hypothèse de mélange permet toujours de compenser la maigre information sur l'erreur locale (contrôle faible de l'erreur). Ainsi, si l'erreur locale n'est pas directement contrôlable sous une métrique bien adaptée, on peut exploiter la régularité de l'évolution du filtre pour se placer sous une métrique plus adaptée.

PREUVE DU THÉORÈME 2.33. En utilisant l'inégalité triangulaire dans la décomposition (2.43), nous obtenons

$$|\langle \pi'_n - \pi_n, \phi \rangle| \leq |\langle \pi'_n - \bar{R}_n(\pi'_{n-1}), \phi \rangle| + \|\phi\| \sum_{k=1}^{n-1} \|\bar{R}_{n:k+1}(\pi'_k) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi'_{k-1})\|.$$

Pour tout entier $1 \leq k \leq n-2$, l'estimée (2.34) donne

$$\begin{aligned} \|\bar{R}_{n:k+1}(\pi'_k) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi'_{k-1})\| &= \|\bar{R}_{n:k+2} \circ \bar{R}_{k+1}(\pi'_k) - \bar{R}_{n:k+2} \circ \bar{R}_{k+1} \circ \bar{R}_k(\pi'_{k-1})\| \\ &\leq \frac{2}{\log 3} \tau_{n:k+3} \frac{1}{\varepsilon_{k+2}^2} \|\bar{R}_{k+1}(\pi'_k) - \bar{R}_{k+1} \circ \bar{R}_k(\pi'_{k-1})\|. \end{aligned}$$

Pour tout entier $1 \leq k \leq n-1$, en prenant l'espérance conditionnelle par rapport aux observations, et en utilisant l'estimée (2.8), nous avons

$$\mathbb{E} [\|\bar{R}_{k+1}(\pi'_k) - \bar{R}_{k+1} \circ \bar{R}_k(\pi'_{k-1})\| \mid Y_{1:n}] \leq 2 \mathbb{E} \left[\frac{\|R_{k+1}(\pi'_k - \bar{R}_k(\pi'_{k-1}))\|}{(R_{k+1} \pi'_k)(E)} \mid Y_{1:n} \right].$$

La propriété de mélange donne

$$(R_{k+1} \pi'_k)(E) \geq \varepsilon_{k+1} \lambda_{k+1}(E) .$$

La propriété de mélange entraîne que R_{k+1} est dominé par la mesure de probabilité $\bar{\lambda}_{k+1} = \lambda_{k+1}/\lambda_{k+1}(E)$ avec la constante de domination $\lambda_{k+1}(E)/\varepsilon_{k+1}$ donc d'après l'inégalité (2.48) du Lemme 2.31, on a

$$\begin{aligned} \mathbb{E}[\|R_{k+1}(\pi'_k - \bar{R}_k(\pi'_{k-1}))\| \mid Y_{1:n}] &\leq \frac{\lambda_{k+1}(E)}{\varepsilon_{k+1}} \sup_{\|\phi\|=1} \mathbb{E}[\langle \pi'_k - \bar{R}_k(\pi'_{k-1}), \phi \rangle \mid Y_{1:n}] \\ &= \frac{\lambda_{k+1}(E)}{\varepsilon_{k+1}} \delta_k^F . \end{aligned}$$

En combinant ces deux inégalités, nous obtenons

$$\mathbb{E}[\|\bar{R}_{k+1}(\pi'_k) - \bar{R}_{k+1} \circ \bar{R}_k(\pi'_{k-1})\| \mid Y_{1:n}] \leq 2 \frac{\delta_k^F}{\varepsilon_{k+1}^2} .$$

Finalement, en prenant l'espérance conditionnelle par rapport aux observations, nous obtenons

$$\sup_{\|\phi\|=1} \mathbb{E}[\langle \pi'_n - \pi_n, \phi \rangle \mid Y_{1:n}] \leq \delta_n^F + 2 \frac{\delta_{n-1}^F}{\varepsilon_n^2} + \frac{4}{\log 3} \sum_{k=1}^{n-2} \tau_{n:k+3} \frac{\delta_k^F}{\varepsilon_{k+2}^2 \varepsilon_{k+1}^2} .$$

□

Si l'hypothèse de mélange est relâchée, on obtient une majoration non uniforme en temps. En introduisant l'hypothèse de noyau dominé on peut néanmoins améliorer les résultats de convergence obtenus en toute généralité.

Hypothèse [Q_d] (noyau dominé) : Il existe une constante $c_k > 0$, et une mesure de probabilité $\nu_k \in \mathcal{P}(E)$, telles que

$$Q_k(x, \cdot) \leq c_k \nu_k ,$$

On remarque que cette hypothèse est intermédiaire au mélange, elle ne concerne que la majoration du noyau de transition.

Nous énonçons ici les résultats de stabilité du filtre sans hypothèse de mélange.

Proposition 2.35. *Si pour tout entier $k \geq 1$, l'Hypothèse [QΨ] est satisfaite, alors*

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi'_n, \phi \rangle| \mid Y_{1:n}] \leq 2 \sum_{k=1}^n \beta_{n:k+1} \gamma_{n:k+1} \delta_k^F . \quad (2.51)$$

Si, pour tout entier $k \geq 1$, l'Hypothèse [Q_d] est satisfaite, alors

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi'_n, \phi \rangle| \mid Y_{1:n}] \leq \delta_n^F + 2 \sum_{k=2}^n \beta_{n:k+1} \bar{\gamma}_{n:k} c_k \delta_{k-1}^F . \quad (2.52)$$

Sans aucune hypothèse,

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi'_n, \phi \rangle| \mid Y_{1:n}] \leq \sum_{k=1}^n 2^{n-k} \beta_{n:k+1} \bar{\gamma}_{n:k+1} \delta_k^F , \quad (2.53)$$

Cette proposition est à comparer à la Proposition 2.29. Lorsque l'erreur n'est contrôlée qu'au sens faible, la propagation de l'erreur est très coûteuse (voir (2.53)) sauf sous des hypothèses assez contraignantes ($[\mathbf{Q}\Psi]$ ou $[\mathbf{Q}_d]$, voir (2.51), et (2.52)). Par contre, le contrôle de l'erreur sous la variation totale assure une propagation plus raisonnable sans aucune hypothèse, voir (2.44) dans la Proposition 2.29. En contrepartie, le contrôle de l'erreur locale sous la variation totale est plus difficile à obtenir. On verra dans le cadre des méthodes particulières, que pour obtenir un tel contrôle, il faudra alors supposer des hypothèses supplémentaires de régularités du filtre optimal. On comprend mieux maintenant l'idée du compromis entre contrôle de l'erreur locale et contrôle de la propagation d'erreur annoncée dans l'introduction de ce chapitre. Par ailleurs, on observe que la "régularité" des opérateurs d'évolution du filtre optimal peut compenser un faible contrôle de l'erreur locale. Ainsi, l'Hypothèse $[\mathbf{Q}_d]$ entraîne une certaine régularité du filtre optimal qui permet de traiter l'erreur sous la variation totale (voir Lemme 2.31) et ainsi de mieux contrôler le coût de transport des erreurs locales (voir Proposition 2.9). L'hypothèse extrême étant le mélange des opérateurs R_k qui permet de se placer sous la métrique de Hilbert et ainsi de faire disparaître les termes de vraisemblance dans la majoration d'erreur (voir Théorème 2.33).

PREUVE DE LA PROPOSITION 2.35. La preuve de l'inégalité (2.51) est exactement semblable à la première partie de la preuve de la Proposition 2.29. Nous majorons l'erreur par la décomposition (2.36), puis nous utilisons l'inégalité (2.3) pour obtenir des termes dénormalisés. Enfin l'inégalité (2.5) permet de faire apparaître le taux de contraction de Q_n . Nous obtenons ainsi,

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi'_n - \pi_n, \phi \rangle| \mid Y_{1:n}] &\leq \sum_{k=1}^n \sup_{\|\phi\|=1} \mathbb{E}[|\langle \bar{R}_{n:k+1}(\pi'_k) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi'_{k-1}), \phi \rangle| \mid Y_{1:n}] , \\ &\leq 2 \sum_{k=1}^n \frac{M_n}{m_{n:k+1}} \beta_n \\ &\quad \sup_{\|\phi\|=1} \mathbb{E}[|\langle R_{n-1:k+1} \pi'_k - R_{n-1:k+1} \circ \bar{R}_k(\pi'_{k-1}), \phi \rangle| \mid Y_{1:k}] , \end{aligned}$$

ce qui donne par récurrence

$$\sup_{\|\phi\|=1} |\langle \pi'_n - \pi_n, \phi \rangle| \leq 2 \sum_{k=1}^n \beta_{n:k+1} \gamma_{n:k+1} \delta_k^F .$$

Considérons maintenant l'inégalité (2.52).

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi'_n - \pi_n, \phi \rangle| \mid Y_{1:n}] &\leq \sup_{\|\phi\|=1} \mathbb{E}[|\langle \bar{R}_n(\pi_{n-1}) - \bar{R}_n(\pi'_{n-1}), \phi \rangle| \mid Y_{1:n}] \\ &\quad + \sup_{\|\phi\|=1} \mathbb{E}[|\langle \bar{R}_n(\pi'_{n-1}) - \pi'_n, \phi \rangle| \mid Y_{1:n}] \quad (2.54) \\ &\leq \delta_n^F + 2\gamma_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle Q_n \pi_{n-1} - Q_n \pi'_{n-1}, \phi \rangle| \mid Y_{1:n-1}] \quad (2.55) \end{aligned}$$

On majore le second terme du membre de droite de la manière suivante,

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle Q_n \pi_{n-1} - Q_n \pi'_{n-1}, \phi \rangle| \mid Y_{1:n-1}] \leq \mathbb{E}[\|Q_n \pi_{n-1} - Q_n \pi'_{n-1}\| \mid Y_{1:n-1}] .$$

Ce qui permet de se ramener sous la variation totale, et ainsi d'utiliser l'inégalité (2.9) du Lemme 2.8 pour opérer une dénormalisation précise sans faire apparaître de facteur deux. De plus, comme le noyau Q_n est dominé, l'erreur locale transportée par Q_n sous la variation totale est majorée par l'erreur faible grâce au Lemme 2.31. Nous avons donc

$$\begin{aligned} \mathbb{E}[\|Q_n \pi_{n-1} - Q_n \pi'_{n-1}\| \mid Y_{1:n-1}] &\leq \mathbb{E}[\|Q_n \pi'_{n-1} - Q_n \bar{R}_{n-1}(\pi'_{n-2})\| \mid Y_{1:n-1}] \\ &\quad + \mathbb{E}[\|Q_n \bar{R}_{n-1}(\pi'_{n-2}) - Q_n \bar{R}_{n-1}(\pi_{n-2})\| \mid Y_{1:n-1}] \\ &\leq c_n \delta_{n-1} + \beta_n \bar{\gamma}_{n-1} \mathbb{E}[\|Q_{n-1} \pi'_{n-2} - Q_{n-1} \pi_{n-2}\| \mid Y_{1:n-2}] . \end{aligned}$$

Par récurrence,

$$\mathbb{E}[\|Q_n \pi_{n-1} - Q_n \pi'_{n-1}\| \mid Y_{1:n}] \leq c_n \delta_{n-1}^F + \sum_{k=2}^{n-1} \beta_{n:k+1} \bar{\gamma}_{n-1:k} c_k \delta_{k-1}^F .$$

En injectant cette dernière majoration dans (2.55), nous obtenons le résultat énoncé dans la proposition.

Considérons enfin l'inégalité (2.53). La décomposition d'erreur (2.54) utilisée, avec la variation totale ne permet plus de majorer l'erreur aussi finement en distance faible. En effet, l'inégalité (2.9) du Lemme 2.8 n'est plus utilisable ici, pour la dénormalisation. Nous devons donc utiliser l'inégalité (2.3) pour opérer la dénormalisation ce qui fait apparaître un facteur 2, à chaque décomposition.

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi'_n, \phi \rangle| \mid Y_{1:n}] \leq 2 \beta_n \bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_{n-1} - \pi'_{n-1}, \phi \rangle| \mid Y_{1:n-1}] + \delta_n^F .$$

Ce qui entraîne par récurrence,

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi'_n, \phi \rangle| \mid Y_{1:n}] \leq \sum_{k=1}^n 2^{n-k} \beta_{n:k+1} \bar{\gamma}_{n:k+1} \delta_k^F ,$$

Cette majoration est beaucoup moins bonne que (2.51). □

2.2.4 Conclusion

Nous avons montré dans cette section l'oubli exponentiel de la condition initiale par le filtre optimal sous la seule hypothèse de mélange des opérateurs d'évolution du filtre, améliorant ainsi le résultat de [4]. En nous appuyant sur ce résultat, nous avons recherché des conditions assurant une majoration uniforme en temps de l'erreur globale induite par plusieurs types de perturbations locales intervenant à chaque instant d'observation dans l'évolution du filtre. La démarche que nous avons adoptée utilise les techniques hilbertiennes et se résume en trois temps :

- (i) Décomposition de l'erreur globale en somme d'erreurs locales transportées par une composition d'opérateurs d'évolution du filtre.

- (ii) Passage de l'étude au sens faible ou au sens de la variation totale à l'étude au sens de la métrique de Hilbert, grâce à l'inégalité (2.26) prouvée dans [4].
- (iii)
 - Si l'erreur locale est bien contrôlée au sens de la variation totale : retour de l'étude sous la métrique de Hilbert à l'étude sous la variation totale grâce à l'inégalité (2.27) que nous avons montrée sous l'hypothèse de mélange.
 - Si l'erreur locale est bien contrôlée au sens faible : passage de l'étude sous la métrique de Hilbert à l'étude sous la variation totale comme ci-dessus. Puis retour de l'étude sous la variation totale à l'étude au sens faible par l'inégalité (2.48) que nous avons montrée sous la condition de transition dominée.

Cette démarche montre clairement l'influence duale sur le contrôle de l'erreur globale exercée par les perturbations locales (selon qu'elles sont contrôlées sous la métrique de Hilbert, sous la variation totale ou bien au sens faible) et la régularité des opérateurs d'évolution du filtre optimal (selon qu'ils sont dominés ou mélangeants).

2.3 Exemples et applications

Dans cette section, nous présentons quelques extensions et applications des résultats de stabilité présentés précédemment. Nous introduisons d'abord la notion de noyau pseudo-mélangeant qui permettra d'exhiber quelques exemples simples de noyaux mélangeants et de relâcher, dans certains cas, l'hypothèse de mélange pour obtenir la stabilité du filtre. On note qu'il existe déjà dans la littérature, quelques résultats de stabilité exponentielle du filtre optimal sans condition d'ergodicité du signal. On peut citer en particulier les travaux de Budhiraja et Ocone [16, 17] qui montrent la stabilité exponentielle, dans des cas particulier où l'observation est "suffisamment bonne". Dans la seconde sous-section, nous appliquons les résultats de stabilité de la Section 2.2 pour étudier les erreurs induites sur le filtre, par la discrétisation en temps du processus état solution d'une équation différentielle stochastique.

2.3.1 Noyaux pseudo-mélangeants

L'hypothèse de noyau mélangeant est une hypothèse forte. Ces études qualitatives sur ce cas extrême nous permettent néanmoins de mieux comprendre le comportement, en temps long, du filtre perturbé. Nous introduisons ici la propriété de pseudo-mélange qui nous permettra d'affaiblir, dans certains cas, la condition de mélange.

Exemples de noyaux mélangeants

Dans ce paragraphe, nous donnons quelques exemples de noyaux mélangeants, construits à partir de noyaux pseudo-mélangeants, dans le cas simple où l'espace de départ est restreint par un artifice à un compact.

Définition 2.36 (Propriété de pseudo-mélange). *Le noyau positif K défini sur E est dit pseudo-mélangeant, si pour tout compact C de diamètre Δ , il existe une constante $0 < \varepsilon(\Delta) \leq 1$ (constante de mélange), et une mesure positive non nulle, $\lambda_C \in \mathcal{M}^+(E)$, telles que*

$$\varepsilon(\Delta) \lambda_C \leq K(x, \cdot) \leq \frac{1}{\varepsilon(\Delta)} \lambda_C, \quad (2.56)$$

pour tout $x \in C$, où $\varepsilon(\Delta)$ ne dépend que du diamètre Δ du compact C .

On peut, par exemple, citer les noyaux pseudo-mélangeants, de la forme

$$Q_i(x, dx') = q_i(x' - x) dx' , \quad \text{avec}$$

$$q_1(x) = \frac{p-1}{2p} \left(1 + \frac{|x|}{p}\right)^{-p} , \quad \text{pour } p \geq 2 ,$$

$$q_2(x) = \frac{1}{2} \exp(-|x|) , \quad \text{densité de Laplace ,}$$

$$q_3(x) = \frac{1}{2} \frac{1}{2 + \exp(|x|) + \exp(-|x|)} , \quad \text{densité logistique .}$$

On vérifie en effet facilement que si $|x| \leq \Delta$, alors les inégalités de mélange suivantes sont vérifiées,

$$q_1(\Delta) \lambda(dx') \leq Q_1(x, dx') \leq \frac{1}{q_1(\Delta)} \lambda(dx') , \quad \text{avec}$$

$$\lambda(dx') = q_1(x') \mathbf{1}_{|x'| > \Delta}(x') dx' + \mathbf{1}_{|x'| \leq \Delta}(x') dx' ,$$

$$q_2(\Delta) q_2(x') dx' \leq Q_2(x, dx') \leq q_2(0) q_2(x') dx' ,$$

$$\exp(-\Delta) q_3(x') dx' \leq Q_3(x, dx') \leq \exp(\Delta) q_3(x') dx' .$$

A partir de ces noyaux pseudo-mélangeants, on peut ensuite facilement construire des noyaux mélangeants, de la forme,

$$Q(x, dx') = q(f(x) - x') dx' ,$$

pour tout x et $x' \in E$, pourvu que f soit une fonction, à valeurs dans E , bornée par Δ , i.e. $|f(x)| \leq \Delta$ pour tout $x \in E$.

Remarque 2.37. En fait, si

$$q(x) = l(|x|) ,$$

pour tout $x \in E$, avec l une fonction positive définie sur $\mathbb{R}^+$ décroissante et nulle à l'infini, telle qu'il existe une constante positive a vérifiant

$$l(u+v) \geq a l(u) l(v) , \quad (2.57)$$

pour tout réels positifs u et v , alors $q(x' - x) dx'$ est pseudo-mélangeant. Précisément, pour tout compact C de diamètre Δ , on a

$$\frac{1}{a q(\Delta)} q(x' - z) \geq q(x' - x) \geq a q(\Delta) q(x' - z) ,$$

pour tout $z \in C$.

En effet, si $z, x \in C$ et $x' \in E$,

$$|x - x'| \leq |x - z| + |z - x'| \leq \Delta + |z - x'| .$$

$$l(|x - x'|) \geq l(\Delta + |z - x'|) \geq a l(\Delta) l(|z - x'|) .$$

D'autre part,

$$\begin{aligned} |z - x'| &\leq |z - x| + |x - x'| \leq \Delta + |x - x'| . \\ l(|z - x'|) &\geq l(\Delta + |x - x'|) \geq a l(\Delta) l(|x - x'|) \end{aligned}$$

On note malheureusement que la propriété (2.57) n'est pas vérifiée pour la fonction $x \mapsto \exp(-x^2)$ car la gaussienne tend trop vite vers zéro à l'infini.

Remarque 2.38. Considérons un noyau pseudo-mélangeant $Q(x, dx')$, on note que si f est une fonction lipschitzienne de E dans E alors $Q(f(x), dx')$ est encore pseudo-mélangeant. En effet, soit C un compact de E . Notons $f(C)$ l'image du compact C par f et a la constante de Lipschitz de f i.e.

$$f(C) = \{x' = f(x) \mid x \in C\} \quad \text{et} \quad |f(x) - f(x')| \leq a|x - x'| ,$$

pour tout $x, x' \in E$. Comme $Q(x, dx')$ vérifie la propriété de pseudo-mélange (2.56), on a immédiatement,

$$\varepsilon(a\Delta) \lambda_{f(C)} \leq Q(f(x), \cdot) \leq \frac{1}{\varepsilon(a\Delta)} \lambda_{f(C)} ,$$

Cette remarque permet d'étendre les exemples simples de noyaux pseudo-mélangeants donnés précédemment aux cas de dynamiques du type

$$X_{n+1} = f(X_n) + W_n ,$$

où $(W_n)_{n \geq 0}$ est une séquence i.i.d. de loi commune q (donnée dans les exemple) et f une fonction lipschitzienne de E dans E .

Vraisemblance à support compact

Revenons maintenant au contexte du filtrage. Avec la proposition suivante, nous donnons un exemple, où le noyau de transition du processus état n'est pas mélangeant alors que le filtre optimal oublie exponentiellement sa condition initiale.

Proposition 2.39. *Considérons le filtre optimal π_n tel que*

- (i) *la distribution initiale, $p_0 = \pi_0$, est à support compact C_0 de diamètre Δ ,*
- (ii) *le noyau de transition homogène Q est pseudo-mélangeant,*
- (iii) *pour tout $n \geq 1$, la fonction de vraisemblance Ψ_n est à support compact C_n de diamètre Δ ,*

alors le filtre π_n est exponentiellement stable.

Notons que cette proposition n'est qu'un cas particulier du résultat de Budhiraja et Ocone [16] qui montrent la stabilité exponentielle du filtre optimal, lorsque les bruits d'observation additifs sont bornés, sans condition de pseudo-mélange sur les transitions du signal.

PREUVE DE LA PROPOSITION 2.39. Pour tout $n \geq 1$, nous notons C_n le support de Ψ_n et C_0 le support de π_0 . Nous définissons l'opérateur intégral R'_n tel que

$$R'_n(x, dx') = \mathbf{1}_{C_{n-1}}(x) Q(x, dx') \Psi_n(x') + \mathbf{1}_{C_{n-1}^c}(x) \Psi_n(x') \lambda_n(dx') ,$$

où λ_n est la mesure de mélange de $\mathbf{1}_{C_{n-1}} Q$. Alors, pour toute mesure $\mu \in \mathcal{M}^+(C_{n-1})$, $R'_n \mu = R_n \mu$. Comme $\pi_0 \in \mathcal{P}(C_0)$, nous avons par récurrence $\pi'_n = \bar{R}'_{n:1} \pi_0 = \bar{R}_{n:1} \pi_0 = \pi_n$. D'après la propriété de pseudo-mélange de Q et la définition de R'_n , nous obtenons l'inégalité de mélange, pour tout $n \geq 1$,

$$\varepsilon(\Delta) \Psi_n \lambda_n \leq R'_n(x, \cdot) \leq \frac{1}{\varepsilon(\Delta)} \Psi_n \lambda_n ,$$

Ce qui montre que R'_n est mélangeant avec la même constante de mélange $\varepsilon(\Delta)$ que $\mathbf{1}_{C_{n-1}}(x) Q(x, dx')$ qui ne dépend que du diamètre Δ de C_{n-1} . Notons que $\Psi_n \lambda_n$ est bien une mesure non nulle tant que $(R_{n:1} \pi_0)(E)$ est non nul. $\square$

Remarque 2.40. Cette proposition illustre la Remarque 2.20 de la Sous-section 2.1.4 puisqu'elle fournit un exemple où Q n'est pas mélangeant alors que l'opérateur d'évolution du filtre, R'_k est mélangeant.

Vraisemblance à “décroissance assez rapide”

Nous considérons maintenant le cas où les fonctions de vraisemblance ne sont plus à support compact mais “assez rapidement” décroissantes à l'infini. Dans ce cas, nous montrons que si le noyau de transition est pseudo-mélangeant alors on peut approcher le filtre optimal uniformément en temps, par un filtre exponentiellement stable et que le filtre optimal lui-même oublie sa condition initiale à une vitesse qui sera précisée.

On s'intéresse au système état / observation suivant,

$$\begin{cases} (X_n)_{n \geq 0} \sim (p_0, Q) \\ Y_n = h(X_n) + V_n , \end{cases} \quad (2.58)$$

vérifiant les conditions suivantes :

- la loi initiale de X_0 , $p_0 = \pi_0$, est à support compact C_0 .
- le noyau de transition Q de la chaîne de Markov homogène $(X_n)_{n \geq 0}$ est pseudo-mélangeant. On note alors $\varepsilon(\Delta)$ la constante de mélange de $\mathbf{1}_C(x) Q(x, dx')$, pour tout compact C de diamètre Δ .
- $(V_n)_{n \geq 1}$ est une suite de v.a. i.i.d. indépendantes de X_0 de densité commune g . On note

$$\alpha(\Delta) = \int_{|u| > \Delta} g(u) du .$$

- h est une fonction injective de E dans F vérifiant la propriété lipschitzienne suivante

$$|x - x'| \leq b |h(x) - h(x')| ,$$

pour tous x et $x' \in \mathbb{R}^d$, où b est une constante positive.

Nous notons $(\pi_n)_{n \geq 0}$ le filtre optimal associé au modèle ci-dessus. Nous avons toujours,

$$\pi_n = \bar{R}_n(\pi_{n-1}) = \bar{R}_{n:1}(\pi_0) ,$$

avec pour tout entier $k \geq 1$,

$$R_k(x, dx') = Q(x, dx') \Psi_k(x') = Q(x, dx') g(Y_k - h(x')) ,$$

pour tout x et $x' \in E$. Nous introduisons comme dans la Proposition 2.39, l'opérateur R_k^Δ défini par

$$R_k^\Delta(x, dx') = \mathbf{1}_{C_{k-1}}(x) Q(x, dx') \Psi_k(x') \mathbf{1}_{C_k}(x') + \mathbf{1}_{C_{k-1}^c}(x) \Psi_k(x') \mathbf{1}_{C_k}(x') \lambda_k(dx') .$$

où C_k et λ_k sont définis comme suit :

- C_k est un compact de $\mathbb{R}^d$ de diamètre Δ_k , défini par

$$C_k = \{x \mid |Y_k - h(x)| \leq \Delta\} ,$$

avec Δ une constante positive donnée.

- λ_k est la mesure de mélange de $\mathbf{1}_{C_{k-1}}(x) Q(x, dx')$.

On note $(\pi_n^\Delta)_{n \geq 0}$, le processus résultant de la récurrence

$$\pi_n^\Delta = \bar{R}_n^\Delta(\pi_{n-1}^\Delta) = \bar{R}_{n,1}^\Delta(\pi_0) .$$

La proposition suivante montre que le processus $(\pi_n^\Delta)_{n \geq 0}$ exponentiellement stable constitue une approximation du filtre optimal $(\pi_n)_{n \geq 0}$, uniforme dans le temps, pourvu que les vraisemblances décroissent assez vite à l'infini.

Proposition 2.41. *Soient π_n et π_n^Δ définis ci-dessus. Si pour tout entier $k \geq 1$, la mesure de mélange λ_k est telle que $\lambda_k(E) \leq 1$, alors pour tout entier $n \geq 1$,*

$$\mathbb{E} \|\pi_n^\Delta - \pi_n\| \leq 6 \left(1 + \frac{2}{\varepsilon^4 (2b\Delta) \log 3}\right) \alpha(\Delta) . \quad (2.59)$$

Dans le cas où

$$\lim_{\Delta \rightarrow \infty} \frac{\alpha(\Delta)}{\varepsilon^4 (2b\Delta)} = 0 ,$$

nous concluons que π_n est, en moyenne, approchable uniformément en temps par un filtre asymptotiquement exponentiellement stable.

Remarque 2.42. Si la condition portant sur la masse de la mesure de mélange, $\lambda_k(E) \leq 1$ n'est pas vérifiée, la proposition reste vraie si λ_k est finie i.e. $\lambda_k(E) < \infty$, en remplaçant la mesure de mélange par $\lambda'_k = \lambda_k / \lambda_k(E)$ et la constante de mélange par $\varepsilon'_k = \varepsilon_k \lambda_k(E)$.

Le résultat de cette proposition sera appliqué plus bas pour montrer que, dans certains cas de signaux non ergodiques, le filtre optimal oublie sa condition initiale. Par ailleurs, ce résultat sera utilisé dans le cadre des filtres particuliers, au Chapitre 3, pour fournir une approximation uniforme en temps du filtre optimal lorsque l'hypothèse de mélange n'est pas vérifiée.

Considérons à titre d'exemple le système suivant où $E = F = \mathbb{R}$,

$$\begin{cases} X_{n+1} = f(X_n) + W_n & X_0 \sim p_0 \\ Y_n = h(X_n) + V_n, \end{cases} \quad (2.60)$$

où les bruits d'état et de mesure suivent une densité de Laplace de variances respectives σ et s . Plus précisément,

- $(W_n)_{n \geq 0}$ est une suite de v.a. i.i.d. indépendante de X_0 de densité commune q telle que,

$$q(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x|}{\sigma}\right),$$

- $(V_n)_{n \geq 1}$ est une suite de v.a. i.i.d. indépendante de X_0 de densité commune g telle que

$$g(x) = \frac{1}{2s} \exp\left(-\frac{|x|}{s}\right),$$

- la loi initiale de X_0 , $p_0 = \pi_0$, est à support compact C_0 ,
- f est une fonction lipschitzienne de E dans E telle que,

$$|f(x) - f(x')| \leq a |x - x'|,$$

pour tout x et $x' \in \mathbb{R}^d$, où a est une constante positive.

- h est une fonction injective de E dans F dont l'inverse vérifie la propriété lipschitzienne suivante

$$|x - x'| \leq b |h(x) - h(x')|,$$

pour tout x et $x' \in \mathbb{R}^d$, où b est une constante positive.

Dans ce cas les mesures de mélange λ_k vérifient bien $\lambda_k(E) \leq 1$. En effet, pour tout entier $k \geq 1$, λ_k est la mesure de probabilité de densité q . De plus, on vérifie que

$$\varepsilon^4(2ab\Delta) \geq \frac{1}{16\sigma^4} \exp\left(-8 \frac{ab\Delta}{\sigma}\right), \quad \text{et} \quad \alpha(\Delta) = \frac{1}{2} \exp\left(-\frac{\Delta}{s}\right).$$

Ainsi, dès que la variance du bruit d'état est assez grande par rapport à celle du bruit de mesure ($\sigma > 8abs$), nous avons, grâce à la Proposition 2.41, une approximation exponentiellement stable de π_n .

Remarque 2.43. Ce résultat rejoint l'idée selon laquelle le filtre optimal conserverait des propriétés de stabilité asymptotique lorsque le signal n'est pas ergodique, à condition que les observations soient suffisamment bonnes (comme en filtrage linéaire où les seules hypothèses requises pour la stabilité exponentielle portent sur l'observabilité et la contrôlabilité du système). Budhiraja et Ocone [17] montrent, en effet, la stabilité exponentielle d'un système non linéaire particulier lorsque la variance du bruit d'observation (gaussien et additif) est suffisamment petite. Cependant, leur résultat utilisant une somme ergodique de 0 à l'instant courant pour contrôler la propagation de l'erreur initiale n'est pas exploitable pour prouver la stabilité du filtre par rapport à des erreurs de modèle intervenant à chaque instant d'observation. Un intérêt de la Proposition 2.41 sera justement de permettre ce type de résultat et ainsi de construire une approximation du filtre optimal uniforme en temps (voir Chapitre 3).

PREUVE DE LA PROPOSITION 2.41. Comme Q est pseudo-mélangeant, pour tout $k \geq 1$, l'opérateur R_k^Δ vérifie la propriété de mélange,

$$\varepsilon(\Delta_{k-1}) \Psi_k(x') \mathbf{1}_{C_k}(x') \lambda_k(dx') \leq R_k^\Delta(x, dx') \leq \frac{1}{\varepsilon(\Delta_{k-1})} \Psi_k(x') \mathbf{1}_{C_k}(x') \lambda_k(dx') ,$$

où $\varepsilon(\Delta_{k-1})$ et λ_k sont respectivement la constante de mélange et la mesure de mélange associés à l'opérateur $\mathbf{1}_{C_{k-1}}(x) Q(x, dx')$. On vérifie facilement que le diamètre Δ_{k-1} du compact C_{k-1} et la constante de mélange $\varepsilon(\Delta_{k-1})$ sont majorés comme suit,

$$\Delta_{k-1} \leq 2b\Delta \quad \text{donc} \quad \varepsilon(2b\Delta) \leq \varepsilon(\Delta_{k-1})$$

La propriété de mélange étant satisfaite par R_k^Δ , nous pouvons appliquer le Corollaire 2.27 qui donne

$$\mathbb{E} \|\pi_n^\Delta - \pi_n\| \leq (1 + \frac{2}{\varepsilon^4(2b\Delta) \log 3}) \delta , \quad (2.61)$$

où δ est une constante positive telle que, pour tout entier $1 \leq k \leq n$,

$$\mathbb{E}[\delta_k] = \mathbb{E} \|\bar{R}_k(\pi_{k-1}) - \bar{R}_k^\Delta(\pi_{k-1})\| \leq \delta .$$

Considérons maintenant, la majoration de l'erreur locale, δ_k , pour $k \geq 1$. On rappelle que d'après l'inégalité (2.16) on a pour toutes mesures positives μ et $\mu' \in \mathcal{M}^+(E)$, et pour toute fonction positive Ψ telle que $\langle \mu, \Psi \rangle > 0$,

$$\|\Psi \cdot \mu - \Psi \cdot \mu'\| \leq 2 \int_E \frac{\Psi(x)}{\langle \mu, \Psi \rangle} |\mu - \mu'| (dx) .$$

En utilisant directement cette inégalité, avec $\Psi = \Psi_k$ et

$$\mu = Q\pi_{k-1} = \mathbf{1}_{C_k} Q(\mathbf{1}_{C_{k-1}} \pi_{k-1}) + \mathbf{1}_{C_k} Q(\mathbf{1}_{C_{k-1}^c} \pi_{k-1}) + \mathbf{1}_{C_k^c} Q\pi_{k-1} ,$$

$$\mu' = \mathbf{1}_{C_k} Q(\mathbf{1}_{C_{k-1}} \pi_{k-1}) + \pi_{k-1}(C_{k-1}^c) \lambda_k \mathbf{1}_{C_k} ,$$

on obtient la majoration suivante de l'erreur locale,

$$\delta_k \leq 2 \int_E \frac{\Psi_k(x')}{\langle Q\pi_{k-1}, \Psi_k \rangle} | \mathbf{1}_{C_k} Q(\mathbf{1}_{C_{k-1}^c} \pi_{k-1}) + \mathbf{1}_{C_k^c} Q\pi_{k-1} - \pi_{k-1}(C_{k-1}^c) \lambda_k \mathbf{1}_{C_k} | (dx') . \quad (2.62)$$

En reprenant exactement le raisonnement de la preuve du Lemme 2.7, on obtient l'égalité suivante,

$$\mathbb{E} \left[\frac{\Psi_k(x') \mathbf{1}_{C_k^c}(x')}{\langle Q\pi_{k-1}, \Psi_k \rangle} \mid Y_{1:k-1} \right] = \int_F g(y - h(x)) \mathbf{1}_{|y-h(x)| > \Delta} dy = \int_{|u| > \Delta} g(u) du = \alpha(\Delta) .$$

De la même manière on a l'inégalité,

$$\mathbb{E} \left[\frac{\Psi_k(x') \mathbf{1}_{C_k}(x')}{\langle Q\pi_{k-1}, \Psi_k \rangle} \mid Y_{1:k-1} \right] \leq \mathbb{E} \left[\frac{\Psi_k(x')}{\langle Q\pi_{k-1}, \Psi_k \rangle} \mid Y_{1:k-1} \right] = 1 .$$

Nous pouvons, maintenant, majorer, en moyenne, chacun des termes majorant δ_k , dans l'inégalité (2.62). Le premier terme du membre de droite est majoré de la manière suivante,

$$\begin{aligned}
a_k &= \mathbb{E} \left[\int_E \frac{\Psi_k(x') \mathbf{1}_{C_k}(x')}{\langle \pi_{k|k-1}, \Psi_k \rangle} Q(\mathbf{1}_{C_{k-1}^c} \pi_{k-1})(dx') \right] \\
&= \mathbb{E} \left[\int_E \mathbb{E} \left[\frac{\Psi_k(x') \mathbf{1}_{C_k}(x')}{\langle \pi_{k|k-1}, \Psi_k \rangle} \mid Y_{1:k-1} \right] Q(\mathbf{1}_{C_{k-1}^c} \pi_{k-1})(dx') \right] \\
&\leq \mathbb{E} \left[\int_E \int_E \mathbf{1}_{C_{k-1}^c}(x) \pi_{k-1}(dx) Q(x, dx') \right] \\
&= \mathbb{E} \left[\int_E \mathbb{E} \left[\frac{\Psi_{k-1}(x) \mathbf{1}_{C_{k-1}^c}(x)}{\langle \pi_{k-1|k-2}, \Psi_{k-1} \rangle} \mid Y_{1:k-2} \right] \pi_{k-1|k-2}(dx) \right] \\
&= \alpha(\Delta) .
\end{aligned} \tag{2.63}$$

Le second terme se majore ainsi,

$$\begin{aligned}
b_k &= \mathbb{E} \left[\int_E \frac{\Psi_k(x') \mathbf{1}_{C_k}(x')}{\langle \pi_{k|k-1}, \Psi_k \rangle} \pi_{k|k-1}(dx') \right] \\
&= \mathbb{E} \left[\int_E \mathbb{E} \left[\frac{\Psi_k(x') \mathbf{1}_{C_k}(x')}{\langle \pi_{k|k-1}, \Psi_k \rangle} \mid Y_{1:k-1} \right] \pi_{k|k-1}(dx') \right] \\
&= \alpha(\Delta) .
\end{aligned} \tag{2.64}$$

Le dernier terme est majoré, en moyenne, comme suit,

$$\begin{aligned}
c_k &= \mathbb{E} \left[\int_E \frac{\Psi_k(x') \mathbf{1}_{C_k}(x')}{\langle \pi_{k|k-1}, \Psi_k \rangle} \pi_{k-1}(C_{k-1}^c) \lambda_k(dx') \right] \\
&= \mathbb{E} \left[\int_E \mathbb{E} \left[\frac{\Psi_k(x') \mathbf{1}_{C_k}(x')}{\langle \pi_{k|k-1}, \Psi_k \rangle} \mid Y_{1:k-1} \right] \pi_{k-1}(C_{k-1}^c) \lambda_k(dx') \right] \\
&\leq \mathbb{E}[\pi_{k-1}(C_{k-1}^c)] \\
&= \mathbb{E} \left[\int_E \mathbb{E} \left[\frac{\Psi_{k-1}(x) \mathbf{1}_{C_{k-1}^c}(x)}{\langle \pi_{k-1|k-2}, \Psi_{k-1} \rangle} \mid Y_{1:k-2} \right] \pi_{k-1|k-2}(dx) \right] \\
&= \alpha(\Delta) .
\end{aligned} \tag{2.65}$$

Les majorations (2.63), (2.64) et (2.65) insérées dans l'inégalité (2.62), nous donnent finalement,

$$\mathbb{E}[\delta_k] \leq 6 \alpha(\Delta) = \delta .$$

Nous finissons la preuve en utilisant cette majoration de l'erreur locale moyenne dans la majoration (2.61),

$$\mathbb{E} \|\pi_n^\Delta - \pi_n\| \leq 6 \left(1 + \frac{2}{\varepsilon^4 (2b\Delta) \log 3} \right) \alpha(\Delta) ,$$

□

Ce résultat nous permet, comme annoncé, de montrer la stabilité du filtre optimal par rapport à sa condition initiale.

Proposition 2.44. *Considérons le système (2.58). Soient π_n le filtre optimal (initialisé avec π_0) et π'_n le filtre mal initialisé avec la mesure de probabilité π'_0 , telle que π'_0 et π_0 soient comparables, i.e.*

$$h(\pi_0, \pi'_0) = c_0 < \infty .$$

Si pour tout entier $k \geq 1$, la mesure de mélange λ_k (introduite pour la Proposition 2.41) est telle que $\lambda_k(E) \leq 1$, alors pour tout réel $\Delta > 0$ et pour tout entier $n \geq 1$,

$$\mathbb{E} \|\pi_n - \pi'_n\| \leq 6 d_0 \left(1 + \frac{2}{\varepsilon^4 (2b\Delta) \log 3}\right) \alpha(\Delta) + \frac{2}{\log 3} c_0 (1 - \varepsilon^2(\Delta))^n , \quad (2.66)$$

où $d_0 = 1 + \exp(4c_0)$. Dans le cas où

$$\lim_{\Delta \rightarrow \infty} \frac{\alpha(\Delta)}{\varepsilon^4 (2b\Delta)} = 0 ,$$

nous concluons que π_n oublie sa condition initiale.

Notons que cette proposition nous fournit des vitesses d'oubli de la condition initiale. Ainsi, si on considère l'exemple du système (2.60), on obtient, par cette proposition,

$$\|\pi_n - \pi'_n\| \leq \frac{A}{n^{2\beta\alpha}} ,$$

pour tout $0 \leq \alpha < 1$, avec A une constante positive indépendante de n et $\beta = \sigma/8abs - 1 > 0$ où σ et s désignent respectivement l'écart-type du bruit d'état et d'observation. Ainsi, dans ce cas, si la dynamique est suffisamment bruitée par rapport à la précision des observations, alors le filtre oublie sa condition initiale.

PREUVE DE LA PROPOSITION 2.44. L'erreur est d'abord décomposée en trois termes, faisant intervenir la mesure π_n^Δ introduite dans la Proposition 2.44, et la mesure $\pi_n^{\Delta'}$ suivant la même évolution que π_n^Δ mais partant de la mauvaise condition initiale, i.e.

$$\pi_n^{\Delta'} = \bar{R}_{n:1}^\Delta(\pi'_0) .$$

On a

$$\mathbb{E} \|\pi_n - \pi'_n\| \leq \mathbb{E} \|\pi_n - \pi_n^\Delta\| + \mathbb{E} \|\pi_n^\Delta - \pi_n^{\Delta'}\| + \mathbb{E} \|\pi_n^{\Delta'} - \pi'_n\| .$$

Le premier terme du membre de droite est traité directement par la Proposition 2.41. Le second terme est contrôlé grâce à la propriété de mélange des opérateurs dévolution de $(\pi_n^\Delta)_{n \geq 0}$, (R_k^Δ) . On a ainsi les majorations,

$$\mathbb{E} \|\pi_n - \pi_n^\Delta\| \leq 6 \left(1 + \frac{2}{\varepsilon^4 (2b\Delta) \log 3}\right) \alpha(\Delta) \quad \text{et} \quad \mathbb{E} \|\pi_n^\Delta - \pi_n^{\Delta'}\| \leq \frac{2}{\log 3} (1 - \varepsilon^2(2b\Delta))^n c_0 .$$

La majoration du dernier terme est exactement semblable à celle du premier suivant la preuve de la Proposition 2.41. La propriété de mélange étant satisfaite par R_k^Δ , nous pouvons appliquer le Corollaire 2.27 qui donne

$$\mathbb{E} \|\pi_n^{\Delta'} - \pi'_n\| \leq \left(1 + \frac{2}{\varepsilon^4 (2b\Delta) \log 3}\right) \delta' ,$$

où δ' est une constante positive telle que, pour tout entier $1 \leq k \leq n$,

$$\mathbb{E}[\delta'_k] = \mathbb{E}\|\bar{R}_k(\pi'_{k-1}) - \bar{R}_k^\Delta(\pi'_{k-1})\| \leq \delta'.$$

On obtient la majoration suivante de l'erreur locale,

$$\delta'_k \leq 2 \int_E \frac{\Psi_k(x')}{\langle Q\pi'_{k-1}, \Psi_k \rangle} | \mathbf{1}_{C_k} Q(\mathbf{1}_{C_{k-1}^c} \pi'_{k-1}) + \mathbf{1}_{C_k^c} Q\pi'_{k-1} - \pi'_{k-1}(C_{k-1}^c) \lambda_k \mathbf{1}_{C_k} | (dx') . \quad (2.67)$$

qui n'est autre que l'inégalité (2.62) dans laquelle on a remplacé π_{k-1} par π'_{k-1} . Il suffit maintenant de noter la majoration suivante, valable pour tout entier $k \geq 1$,

$$\frac{\Psi_k(x')}{\langle Q\pi'_{k-1}, \Psi_k \rangle} = \frac{\Psi_k(x')}{\langle Q\pi_{k-1}, \Psi_k \rangle} \frac{\langle Q\pi_{k-1}, \Psi_k \rangle}{\langle Q\pi'_{k-1}, \Psi_k \rangle} \leq \frac{\Psi_k(x')}{\langle Q\pi_{k-1}, \Psi_k \rangle} \exp(c_0) . \quad (2.68)$$

En effet, pour cela il suffit de noter que

$$\begin{aligned} \frac{\langle Q\pi_{k-1}, \Psi_k \rangle}{\langle Q\pi'_{k-1}, \Psi_k \rangle} &= \frac{(R_{k:1}\pi_0)(E)}{(R_{k-1:1}\pi_0)(E)} \frac{(R_{k-1:1}\pi'_0)(E)}{(R_{k:1}\pi'_0)(E)} \\ &\leq \sup_A \frac{(R_{k:1}\pi_0)(A)}{(R_{k:1}\pi'_0)(A)} \sup_B \frac{(R_{k-1:1}\pi'_0)(B)}{(R_{k-1:1}\pi_0)(B)} , \end{aligned}$$

où le sup est pris parmi les boréliens A tels que $(R_{k:1}\pi_0)(A) > 0$ et les boréliens B tels que $(R_{k-1:1}\pi_0)(B) > 0$. Par définition de la métrique de Hilbert, on a alors

$$\frac{\langle Q\pi_{k-1}, \Psi_k \rangle}{\langle Q\pi'_{k-1}, \Psi_k \rangle} \leq \exp(h(R_{k:1}\pi_0, R_{k:1}\pi'_0)) \exp(h(R_{k-1:1}\pi_0, R_{k-1:1}\pi'_0)) .$$

D'après la propriété de contraction des opérateurs linéaires positifs sous la métrique de Hilbert, on obtient finalement,

$$\frac{\langle Q\pi_{k-1}, \Psi_k \rangle}{\langle Q\pi'_{k-1}, \Psi_k \rangle} \leq \exp(h(\pi_0, \pi'_0)) \exp(h(\pi_0, \pi'_0)) = \exp(2c_0) .$$

Il suffit maintenant, comme dans la preuve de la Proposition 2.41, de majorer chacun des termes du membre de droite de l'inégalité (2.67), à l'aide cette fois-ci de l'inégalité (2.68). Le premier terme du membre de droite de l'inégalité (2.67) est majoré de la manière suivante,

$$\mathbb{E} \left[\int_E \frac{\Psi_k(x') \mathbf{1}_{C_k}(x')}{\langle \pi'_{k|k-1}, \Psi_k \rangle} Q(\mathbf{1}_{C_{k-1}^c} \pi'_{k-1})(dx') \right] \leq \exp(4c_0) \alpha(\Delta) . \quad (2.69)$$

Le second terme se majore ainsi,

$$\mathbb{E} \left[\int_E \frac{\Psi_k(x') \mathbf{1}_{C_k^c}(x')}{\langle \pi'_{k|k-1}, \Psi_k \rangle} \pi'_{k|k-1}(dx') \right] \leq \exp(2c_0) \alpha(\Delta) . \quad (2.70)$$

Le dernier terme est majoré, en moyenne, comme suit,

$$\mathbb{E} \left[\int_E \frac{\Psi_k(x') \mathbf{1}_{C_k}(x')}{\langle \pi'_{k|k-1}, \Psi_k \rangle} \pi'_{k-1}(C_{k-1}^c) \lambda_k(dx') \right] \leq \exp(4c_0) \alpha(\Delta) . \quad (2.71)$$

Les majorations (2.69), (2.70) et (2.71) insérées dans l'inégalité (2.67), nous donnent finalement,

$$\mathbb{E}[\delta'_k] \leq 6 \exp(4c_0) \alpha(\Delta) = \delta .$$

□

2.3.2 Discrétisation de l'équation d'état en temps

Nous considérons ici le modèle état continu / observations en temps discret. Le signal $(X_t)_{t \geq 0}$ est un processus à temps continu donné comme solution de l'équation différentielle stochastique (EDS),

$$dX_t = a(X_t) dt + b(X_t) dW_t, \quad X_0 \sim p_0, \quad (2.72)$$

avec $(W_t)_{t \geq 0}$ le processus de Wiener standard. Nous supposons de plus, que les coefficients a et b de l'EDS (2.72) vérifient les hypothèses de régularité (UH) et (C) introduites par Bally et Talay [5]. Les observations sont disponibles à des instants discrets t_n et constituent ainsi une suite à temps discret définie par,

$$Y_n = h_n(X_{t_n}, V_n),$$

où $(V_n)_{n \geq 0}$ est une suite de variables aléatoires indépendantes et indépendantes de X_0 et de $(W_t)_{t \geq 0}$.

Nous associons à l'EDS (2.72), l'opérateur aux dérivées partielles d'ordre deux,

$$L = \sum_{i=1}^m a^i(\cdot) \frac{\partial}{\partial x_i} + \frac{1}{2} \sum_{i,j=1}^m \beta^{i,j}(\cdot) \frac{\partial^2}{\partial x_i \partial x_j},$$

avec $\beta = (\beta^{i,j}) = bb^*$. Nous notons $(P_t)_{t \geq 0}$ le semi-groupe de Markov associé, i.e.

$$P_t \phi(x) = \mathbb{E}[\phi(X_{t+s}) | X_s = x],$$

pour toute fonction ϕ définie sur $E = \mathbb{R}^d$, et tout instant $s \geq 0$. Nous posons $t_0 = 0$, et pour tout $n \geq 1$, $Q_n = P_{t_n - t_{n-1}}$ le noyau de transition de la chaîne de Markov inhomogène $(X_{t_n})_{n \geq 0}$, i.e.

$$Q_n \phi(x) = \mathbb{E}[\phi(X_{t_n}) | X_{t_{n-1}} = x],$$

pour toute fonction test ϕ définie sur $\mathbb{R}^d$.

Dans les cas considérés jusqu'ici, on supposait que les transitions du processus état, entre deux instants d'observation, étaient explicitement connues. Dans le cas présent, l'équation (2.72) ne peut être résolue de manière explicite, mais nous pouvons en approcher une solution par des approximations numériques. Le problème de cette section est d'étudier comment se répercute cette approximation de l'équation d'état sur le filtre optimal. Notons que ce sujet est aussi abordé dans [36, 35]. Dans un premier temps, nous considérons l'approximation d'Euler puis l'approximation de Romberg. En filtrage, on cherche à approcher une mesure de probabilité, nous n'utilisons donc ici que des résultats faibles de convergence des schémas d'approximations numériques des EDS.

Schémas d'Euler

Dans cette partie, nous utilisons le schéma d'Euler pour approcher la solution de l'équation (2.72). Pour tout $\delta > 0$, tout x et $w \in \mathbb{R}^d$ nous posons,

$$F_\delta(x, w) = x + a(x)\delta + b(x)\sqrt{\delta}w.$$

On note $\Gamma_\delta(x, \cdot)$ la distribution gaussienne de moyenne, le vecteur

$$m_\delta(x) = x + a(x)\delta ,$$

et de matrice de covariance,

$$\Sigma_\delta(x) = \beta(x)\delta .$$

En général le temps entre deux observations $t_n - t_{n-1}$ est trop grand pour être utilisé comme temps de discrétisation dans le schéma d'Euler. Nous introduisons donc une subdivision $t_{n-1} = \tau_{n,0} < \tau_{n,1} < \dots < \tau_{n,l_n} = t_n$ de l'intervalle de temps $[t_{n-1}, t_n]$, en notant le pas de temps $\delta_{n,l} = \tau_{n,l} - \tau_{n,l-1}$. Nous choisissons les subdivisions de telle sorte que, pour tout entier n et tout $1 \leq l \leq l_n$, nous ayons $\delta_{n,l} \leq \delta$, une constante positive fixée. Une approximation de la solution de (2.72) à l'instant $\tau_{n,l}$ est fournie par $X_{n,l}^\delta$ défini par

$$X_{n,l}^\delta = F_{\delta_{n,l}}(X_{n,l-1}^\delta, \bar{w}_{n,l}) , \quad 1 \leq l \leq l_n ,$$

où les $(\bar{w}_{n,1}, \dots, \bar{w}_{n,l_n})$ sont des variables aléatoires i.i.d. suivant la loi gaussienne centrée réduite. X_0 est supposé donné. Nous observons que pour tout $x \in \mathbb{R}^d$,

$$\mathbb{P}[X_{n,l}^\delta \in dx' | X_{n,l-1}^\delta = x] = \Gamma_{\delta_{n,l}}(x, dx') ,$$

pour tout $1 \leq l \leq l_n$. Nous notons, Q_n^δ , le noyau de transition associé au schéma d'Euler tel que

$$Q_n^\delta(x, dx') = \mathbb{P}[X_{t_n}^\delta \in dx' | X_{t_{n-1}}^\delta = x] = (\Gamma_{\delta_{n,1}} \cdots \Gamma_{\delta_{n,l_n}})(x, dx') ,$$

pour tout x et $x' \in E$. Q_n^δ constitue une approximation de Q_n au sens de la proposition suivante.

Lemme 2.45. *Sous les hypothèses de régularité (UH) et (C) introduites par Bally et Talay [5], pour toute mesure de probabilité $\mu \in \mathcal{P}(E)$, pour tout entier $n \geq 1$,*

$$\|Q_n^\delta \mu - Q_n \mu\| \leq G_n \delta , \quad (2.73)$$

où $G_n = G(t_n - t_{n-1})$ avec G une fonction croissante et indépendante de δ .

Ce résultat est une conséquence directe du Théorème 3.1 de Bally et Talay [5]. On peut aussi se reporter à l'ouvrage de Kloeden et Platen [63].

Nous déduisons des théorèmes de stabilités de la Section 2.2 le corollaire suivant.

Corollaire 2.46. *Soit $(\pi_n^\delta)_{n \geq 0}$ le processus obtenu en remplaçant Q_n par Q_n^δ dans l'évolution du filtre optimal $(\pi_n)_{n \geq 0}$.*

(i) *Si l'Hypothèse [QΨ] est vérifiée, sans condition de mélange, nous avons*

$$\|\pi_n^\delta - \pi_n\| \leq A_n \delta , \quad \text{avec} \quad A_n = \sum_{k=1}^n \beta_{n:k+1} \bar{\gamma}_{n:k+1} \gamma_k G_k , \quad (2.74)$$

où $\beta_k = \beta(Q_k)$ est le taux de contraction de Q_k pour la variation totale.

(ii) Si, pour tout entier $k \geq 1$, l'Hypothèse **[R]** est vérifiée, avec $\varepsilon_k \geq \varepsilon > 0$, alors

$$\|\pi_n^\delta - \pi_n\| \leq B_n \delta, \quad \text{avec} \quad B_n = \left(1 + \frac{2}{\varepsilon^4 \log 3}\right) \max_{1 \leq k \leq n} \{\gamma_k G_k\}. \quad (2.75)$$

On rappelle que sous l'hypothèse de mélange $\gamma_k \leq \bar{\gamma}_k / \varepsilon^2 < \infty$, (voir Remarque 2.28).

PREUVE DU COROLLAIRE 2.46. L'erreur locale en variation totale est majorée en appliquant l'inégalité (2.9) du Lemme 2.8 puis le Lemme 2.45,

$$\|\pi_k^\delta - \bar{R}_k(\pi_{k-1}^\delta)\| = \|\Psi_k \cdot Q_k^\delta \pi_{k-1}^\delta - \Psi_k \cdot Q_k \pi_{k-1}^\delta\| \leq \frac{M_k}{m_k} G_k \delta = \gamma_k G_k \delta. \quad (2.76)$$

En appliquant le Corollaire 2.27, nous obtenons donc la majoration (2.75).

Dans le cas plus général où aucune hypothèse de mélange n'est faite, nous appliquons directement la Proposition 2.29. $\square$

Schémas de Romberg

Nous utilisons, ici, un schéma de discrétisation de l'EDS (2.72) plus fin que le schéma d'Euler. Le schéma de Romberg bien connu dans le cadre déterministe consiste à combiner linéairement deux approximations d'Euler à des pas δ et $\delta/2$, de sorte à éliminer le terme de premier ordre dans le développement de l'erreur. Talay et Tubaro [102] ont proposé d'étendre cette idée pour l'approximation des EDS. Le lemme suivant découle du développement de l'erreur du schéma d'Euler toujours fournie par le Théorème 3.1 de Bally et Talay [5].

Lemme 2.47. *Sous les hypothèses de régularité (UH) et (C) introduites par Bally et Talay [5], pour toute mesure de probabilité $\mu \in \mathcal{P}(E)$, pour tout entier $n \geq 1$,*

$$\|2Q_n^{\frac{\delta}{2}}\mu - Q_n^\delta\mu - Q_n\mu\| \leq H_n \delta^2, \quad (2.77)$$

où $H_n = H(t_n - t_{n-1})$ avec H une fonction croissante et indépendante de δ .

Pour plus de précisions sur les méthodes d'extrapolation pour la discrétisation des EDS, on peut aussi se reporter à Kloeden et Platen [63, pp 491–495].

Le lemme suivant permettra de contrôler l'approximation de Romberg après transport à travers l'étape de correction.

Lemme 2.48. *Soit trois mesures de probabilité μ et μ' et $\mu'' \in \mathcal{P}(E)$, et Ψ une fonction définie sur E positive et bornée. Alors*

$$\|2\Psi \cdot \mu'' - \Psi \cdot \mu' - \Psi \cdot \mu\| \leq 2 \frac{\|\Psi\|}{\langle \mu'', \Psi \rangle} [\|2\mu'' - \mu' - \mu\| + \frac{\|\Psi\|}{4 \langle \mu, \Psi \rangle} \|\mu - \mu'\|^2]. \quad (2.78)$$

La preuve découle directement de l'égalité,

$$\begin{aligned} 2\Psi \cdot \mu'' - \Psi \cdot \mu' - \Psi \cdot \mu &= \frac{1}{2 \langle \mu'', \Psi \rangle} [2\Psi (2\mu'' - \mu' - \mu) + \langle \mu - \mu', \Psi \rangle (\Psi \cdot \mu - \Psi \cdot \mu') \\ &\quad + \langle 2\mu'' - \mu' - \mu, \Psi \rangle (\Psi \cdot \mu + \Psi \cdot \mu')] . \end{aligned}$$

□

On peut maintenant énoncer le corollaire suivant.

Corollaire 2.49. *Soit $(\pi_n^\delta)_{n \geq 0}$ et $(\pi_n^{\frac{\delta}{2}})_{n \geq 0}$ les processus obtenus respectivement en remplaçant Q_n par Q_n^δ et $Q_n^{\frac{\delta}{2}}$ dans l'évolution du filtre optimal $(\pi_n)_{n \geq 0}$. Si l'Hypothèse $[\mathbf{Q}\Psi]$ est vérifiée, sans condition de mélange, nous avons*

$$\|2 \pi_n^{\frac{\delta}{2}} - \pi_n^\delta - \pi_n\| \leq B_n \delta^2, \quad (2.79)$$

$$\text{avec } B_n = \sum_{k=1}^n 2^{n-k} \gamma_{n:k+1} [\gamma_k^2 (A_{k-1}^2 + G_k^2) + 2 \gamma_k (H_k + \frac{3}{2} G_{k-1} A_{k-1})],$$

où A_k , G_k et H_k sont donnés respectivement dans le Corollaire 2.46, le Lemme 2.45 et le Lemme 2.47.

PREUVE DU COROLLAIRE 2.49. Pour tout entier $n \geq 1$, on note

$$e_n = \|2 \pi_n^{\frac{\delta}{2}} - \pi_n^\delta - \pi_n\|.$$

D'après le Lemme 2.48, on a la majoration suivante,

$$\begin{aligned} e_n &\leq 2 \gamma_n \|2 Q_n^{\frac{\delta}{2}} \pi_{n-1}^{\frac{\delta}{2}} - Q_n^\delta \pi_{n-1}^\delta - Q_n \pi_{n-1}\| \\ &\quad + \frac{1}{2} \gamma_n^2 \|Q_n^\delta \pi_{n-1}^\delta - Q_n \pi_{n-1}\|^2. \end{aligned}$$

Le second terme du membre de droite de l'inégalité ci-dessus est majoré grâce au Corollaire 2.46 et au Lemme 2.45,

$$\begin{aligned} \|Q_n^\delta \pi_{n-1}^\delta - Q_n \pi_{n-1}\|^2 &\leq 2 \|Q_n^\delta \pi_{n-1}^\delta - Q_n^\delta \pi_{n-1}\|^2 + 2 \|Q_n^\delta \pi_{n-1} - Q_n \pi_{n-1}\|^2 \\ &\leq 2 A_{n-1}^2 \delta^2 + 2 G_n^2 \delta^2 \end{aligned} \quad (2.80)$$

Le premier terme du membre de droite se majore ainsi,

$$\begin{aligned} \|2 Q_n^{\frac{\delta}{2}} \pi_{n-1}^{\frac{\delta}{2}} - Q_n^\delta \pi_{n-1}^\delta - Q_n \pi_{n-1}\| &\leq \|2 Q_n^{\frac{\delta}{2}} \pi_{n-1} - Q_n^\delta \pi_{n-1} - Q_n \pi_{n-1}\| \\ &\quad + \|Q_n^{\frac{\delta}{2}} (2 \pi_{n-1}^{\frac{\delta}{2}} - \pi_{n-1}^\delta - \pi_{n-1})\| \\ &\quad + \|Q_n^{\frac{\delta}{2}} (\pi_{n-1}^\delta - \pi_{n-1}) - Q_n^\delta (\pi_{n-1}^\delta - \pi_{n-1})\| \end{aligned}$$

D'après le Lemme 2.47, on a

$$\|2 Q_n^{\frac{\delta}{2}} \pi_{n-1} - Q_n^\delta \pi_{n-1} - Q_n \pi_{n-1}\| \leq H_n \delta^2.$$

En utilisant le Lemme 2.45 et le Corollaire 2.46, on a la majoration,

$$\begin{aligned}
\|Q_n^{\frac{\delta}{2}}(2\pi_{n-1}^{\frac{\delta}{2}} - \pi_{n-1}^{\delta} - \pi_{n-1})\| &\leq \sup_{x \in E} \|Q_n^{\frac{\delta}{2}}(x, \cdot) - Q_n^{\delta}(x, \cdot)\| \|\pi_{n-1}^{\delta} - \pi_{n-1}\| \\
&\leq \|Q_n(x, \cdot) - Q_n^{\frac{\delta}{2}}(x, \cdot)\| \|Q_n(x, \cdot) - Q_n^{\delta}(x, \cdot)\| \|\pi_{n-1}^{\delta} - \pi_{n-1}\| \\
&\leq \frac{3}{2} G_{n-1} A_{n-1} \delta^2
\end{aligned}$$

On a donc

$$\|2 Q_n^{\frac{\delta}{2}} \pi_{n-1}^{\frac{\delta}{2}} - Q_n^{\delta} \pi_{n-1}^{\delta} - Q_n \pi_{n-1}\| \leq H_n \delta^2 + e_{n-1} + \frac{3}{2} G_{n-1} A_{n-1} \delta^2 . \quad (2.81)$$

Finalement, en regroupant les majorations (2.80) et (2.81), on obtient la récurrence suivante,

$$e_n \leq \gamma_n^2 [A_{n-1}^2 + G_n] \delta^2 + 2 \gamma_n [H_n + \frac{3}{2} G_{n-1} A_{n-1}] \delta^2 + 2 \gamma_n e_{n-1} .$$

Ce qui conduit à l'inégalité du corollaire. $\square$

Conclusion du Chapitre 2

Nous avons mené cette étude de stabilité dans l'optique d'analyser les erreurs commises par certains filtres approchés. Plusieurs points essentiels pour la suite ressortent de cette étude.

Nous avons d'abord mis en évidence l'influence du choix de la métrique pour l'étude de la stabilité. On a ainsi pu constater que la métrique de Hilbert est particulièrement adaptée à cette étude. Malheureusement, dans les cas qui nous intéressent les perturbations locales induites ne sont, en général, pas contrôlables au sens de cette métrique sauf sous l'hypothèse contraignante de mélange. Cette condition nous a en effet permis de montrer la stabilité exponentielle du filtre, dans le cas de dynamiques mélangeantes, retrouvant ainsi par des moyens différents un résultat proche de Del Moral et Guionnet [33]. L'originalité de cette section réside dans l'étude par des techniques hilbertiennes de la sensibilité du filtre à une grande classe de perturbations locales. Les résultats obtenus sont applicables directement pour l'étude de la robustesse du filtre ou de la qualité d'un filtre approché, comme nous le verrons aux Chapitres 3 et 5 pour l'analyse de certains filtres particuliers.

Hors de cette hypothèse contraignante, les résultats que nous obtenons sont beaucoup moins forts. La propagation de l'erreur fait intervenir à chaque pas de temps le coefficient de transport produit $\beta_n \bar{\gamma}_n$ caractérisant l'information apportée au filtre entre les instants $n-1$ et n , dans le sens précisé ci-dessous.

- β_n est associé à l'étape de prédiction. Si $\beta_n \ll 1$ le filtre perd de l'information durant la prédiction.
- $\bar{\gamma}_n$ est associé à l'étape de correction. Si $\bar{\gamma}_n = 1$ aucune information n'est fournie par l'observation Y_n . Si $\bar{\gamma}_n \gg 1$: soit l'information apportée par Y_n est très précise par rapport à la prédiction $\pi_{n|n-1}$, soit elle est incohérente avec $\pi_{n|n-1}$. Dans les deux cas, Y_n fournit une information importante dans le sens où elle modifie sensiblement $\pi_{n|n-1}$.

On peut ainsi intuitivement qualifier de riche (en information) toute transition du filtre optimal associée à un petit coefficient $1/\beta_n \bar{\gamma}_n$. Les majorations d'erreur obtenues suggèrent que l'erreur induite sur le filtre à l'instant $n > k$, par une erreur locale δ_k commise à l'instant k est bien contrôlée si δ_k est négligeable devant le coefficient $1/\beta_{n:k+1} \bar{\gamma}_{n:k+1}$, caractérisant la précision accumulée par le filtre entre les instants k et n . Cette remarque suggère qu'il faut équilibrer l'erreur locale induite avec la précision du filtre à approcher. Malheureusement, la contrainte de récursivité empêche de diminuer δ_k avec n . Une alternative est alors de perturber judicieusement le filtre optimal, de sorte à introduire de l'oubli dans son évolution tout en contrôlant l'erreur induite. Cette idée est classique en filtrage et est exploitée dans le chapitre suivant pour stabiliser le filtre de Monte Carlo pondéré.

Notre étude sur le choix de la métrique montre que les erreurs locales contrôlées sous la variation totale se propagent a priori mieux dans le temps que les erreurs contrôlées au sens faible. Ce point nous incite, par la suite, à rechercher des approximations du filtre optimal induisant des erreurs locales contrôlées sous la variation totale. Dans cette optique, nous proposons au Chapitre 5 les méthodes particulières régularisées. L'extension des résultats de stabilité aux noyaux pseudo-mélangeants (Proposition 2.41), suggère une nouvelle approche pour l'approximation du filtre lorsque celui-ci n'est pas exponentiellement stable. L'idée est de rechercher un processus à valeurs mesures exponentiellement stable qui approche le filtre optimal uniformément en temps. L'existence d'un tel processus permettra, dans la suite, de construire, une approximation particulière du filtre optimal uniforme en temps, dans un cas où le signal n'est pas ergodique. L'étude de stabilité développée dans ce chapitre a donc permis de dégager les idées principales autour desquelles s'articulera la suite de notre travail.

Chapitre 3

Filtres particulaires classiques

La première méthode de Monte Carlo proposée pour traiter le problème de filtrage non linéaire est la méthode de Monte Carlo pondéré. Elle consiste à faire évoluer N trajectoires indépendantes suivant la loi du processus état et à les pondérer à chaque instant suivant la vraisemblance de l'observation courante. Cette idée est relativement ancienne. Elle apparaît dans plusieurs publications, dès le début des années 70 [1, 52]. Il faut pourtant attendre les années 80, et le développement des moyens informatiques pour que cette idée soit reconsidérée sérieusement [28, 40, 68, 61]. On note d'emblée que les filtres de Monte Carlo pondérés ont été abandonnés avec l'apparition du filtre particulaire avec interaction. Cependant, leur étude n'est pas pour autant sans intérêt. D'une part, elle permet de mieux comprendre la propagation des erreurs d'échantillonnage dans le filtre. D'autre part, on verra que le filtre particulaire avec interaction lui-même peut être vu comme une version améliorée du filtre de Monte Carlo pondéré classique.

Dans le filtre particulaire avec interaction ("Interacting Particle Filter", IPF), les particules simulées ne suivent plus des évolutions indépendantes, comme dans le filtre de Monte Carlo pondéré. Elles interagissent aux instants d'observations (pas nécessairement tous) de sorte à multiplier les particules les plus probables et éliminer les autres. Le système de particules tient compte, dans son évolution, de la dynamique du processus et des observations. Dans le contexte d'observations à temps discrets, les méthodes de particules en interactions ont été développées indépendamment par Del Moral, Rigal, Salut [39] (filtre particulaire avec interaction), Gordon, Salmond et Smith [49] (Bootstrap filter ou Sampling Importance Resampling (SIR) filter) et Kitagawa [62] (Monte Carlo filter). Dans le cadre d'observations en temps continu, Crisan et Lyons [24] ont développé indépendamment le filtre particulaire avec branchement (Branching Particle Filter). Cette approche procédant d'abord par une discrétisation en temps, donne lieu à un algorithme en temps discret très voisin du filtre particulaire avec interaction. L'étude théorique des systèmes de particules en interaction est essentiellement due aux travaux de Del Moral [30] pour l'étude de la convergence, Del Moral et Guionnet [33, 32, 34] pour l'étude des grandes déviations, de la stabilité du filtre et des théorèmes central limite, Del Moral et Jacod [36, 35] pour la preuve de théorèmes central limite, Del Moral et Ledoux [37] pour l'étude du processus empirique. Enfin on pourra se reporter au cours de Del Moral et Miclo [38] qui résume les principaux résultats sur le sujet et réalise une extension de ces travaux au cas d'observations en temps continu.

La première section de ce chapitre, est consacrée au filtre de Monte Carlo pondéré. Cet

algorithme est décrit dans la première sous-section ainsi que le phénomène de dégénérescence des pondérations qui la rend inefficace. L'idée classique permettant d'éviter ce phénomène est d'oublier brutalement ou progressivement les observations passées. L'oubli brutal, réalisé par le filtre à mémoire limitée, fait l'objet de la deuxième sous-section. On y reporte brièvement le résultat de convergence uniforme en temps, lorsque la mémoire augmente, obtenu par Del Moral [31]. L'oubli progressif est présenté dans la troisième sous-section, avec le filtre à oubli exponentiel. On fournit une preuve originale de la convergence uniforme de ce filtre avec une estimation de la vitesse de convergence. La seconde section de ce chapitre, est consacrée au filtre particulaire avec interaction. Cet algorithme est d'abord décrit et analysé pour des systèmes assez généraux, dans la première sous-section : quelques résultats connus sont rappelés et un nouveau résultat est prouvé. Un nouveau schéma de rééchantillonnage avec nombre aléatoire de particules est présenté et analysé dans la deuxième sous-section. Le cas de systèmes à évolution mélangeante est ensuite étudié, dans la troisième sous-section, en utilisant l'approche par les techniques hilbertiennes développée au Chapitre 2. Une approche basée sur la métrique de Hilbert nous permet de montrer la convergence uniforme de l'algorithme. La quatrième sous-section souligne enfin les points faibles de cet algorithme et présente rapidement quelques variantes proposées dans littérature.

3.1 Filtre de Monte Carlo pondéré

Nous considérons, dans cette section le filtre de Monte Carlo pondéré et quelques unes de ses variantes : filtre à mémoire limitée et filtre à oubli exponentiel. Un résultat de convergence uniforme original est prouvé pour le filtre à oubli exponentiel, lorsque la dynamique est mélangeante.

3.1.1 Filtre sans oubli

Description et majoration de l'erreur

L'idée de la méthode de Monte Carlo pondérée est d'approcher la loi conditionnelle conjointe $\pi_{0:n}$ par la technique de l'échantillonnage pondéré. Dans l'équation (1.4), la loi a priori conjointe $p_{0:n}$ est remplacée par la mesure empirique

$$S^N(p_{0:n}) = \frac{1}{N} \sum_{i=1}^N \xi_{0:n}^i, \quad \text{avec} \quad (\xi_{0:n}^1, \dots, \xi_{0:n}^N) \text{ i.i.d. } \sim p_{0:n},$$

ce qui fournit la mesure empirique pondérée,

$$\pi_{0:n}^N = \Psi_{1:n} \cdot S^N(p_{0:n}),$$

telle que

$$\pi_{0:n}^N = \sum_{i=1}^N \omega_{0:n}^i \delta_{\xi_{0:n}^i} \quad \text{avec} \quad \omega_{0:n}^i = \frac{\Psi_{1:n}(\xi_{1:n}^i)}{\sum_{j=1}^N \Psi_{1:n}(\xi_{1:n}^j)}, \quad \text{i.e.} \quad \langle \pi_{0:n}^N, \phi \rangle = \sum_{i=1}^N \omega_{0:n}^i \phi(\xi_{0:n}^i),$$

pour toute fonction ϕ mesurable bornée sur E^{n+1} .

Le filtre de Monte Carlo pondéré est initialisé à la valeur

$$\pi_0^N = S^N(p_0) = \sum_{i=1}^N \omega_0^i \xi_0^i \quad \text{avec} \quad (\xi_0^1, \dots, \xi_0^N) \text{ i.i.d. } \sim p_0 \quad \text{et} \quad \omega_0^i = \frac{1}{N} \quad 1 \leq i \leq N.$$

Puis $\pi_{0:n}^N$ et sa marginale notée π_n^N s'obtiennent récursivement par l'algorithme suivant.

- (i) Evolution : indépendamment pour chaque i , générer $\xi_n^i \sim Q_n(\xi_{n-1}^i, \cdot)$. Poser $\xi_{0:n}^i = (\xi_{0:n-1}^i, \xi_n^i)$.
- (ii) Correction : pour tout i , calculer les poids

$$\omega_{0:n}^i = \frac{\Psi_n(\xi_n^i) \omega_{0:n-1}^i}{\sum_{j=1}^N \Psi_n(\xi_n^j) \omega_{0:n-1}^j}, \quad \text{et} \quad \omega_n^i = \frac{\Psi_n(\xi_n^i) \omega_{n-1}^i}{\sum_{j=1}^N \Psi_n(\xi_n^j) \omega_{n-1}^j}.$$

Puis poser

$$\pi_{0:n}^N = \sum_{i=1}^N \omega_{0:n}^i \delta_{\xi_{0:n}^i}, \quad \text{et} \quad \pi_n^N = \sum_{i=1}^N \omega_n^i \delta_{\xi_n^i}$$

Sur le plan pratique, la mise en œuvre de cet algorithme est aisée. De plus, les trajectoires simulées étant mutuellement indépendantes, l'algorithme est parallélisable, pourvu que la normalisation des vraisemblances ne soit pas effectuée à chaque itération, mais seulement lorsque le calcul d'une estimée est exigé. Cependant, il est conseillé de normaliser les vraisemblances au moins périodiquement, car leurs multiplications successives peut conduire à des nombres dépassant la capacité de l'ordinateur. La majoration de l'erreur s'obtient par simple application de la loi des grands nombres (voir [40]).

Théorème 3.1.

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_{0:n} - \pi_{0:n}^N, \phi \rangle| \mid Y_{1:n}] \leq 2 \frac{\bar{\gamma}_{n:1}}{\sqrt{N}},$$

le sup étant pris parmi les fonctions ϕ de norme unité mesurable sur E^{n+1} à valeurs dans $\mathbb{R}$, avec la notation du produit $\bar{\gamma}_{n:1} = \bar{\gamma}_n \cdots \bar{\gamma}_1$.

L'inégalité du théorème concerne l'approximation de $\pi_{0:n}$, elle est donc a fortiori vérifiée pour l'approximation de la loi marginale π_n en prenant des fonctions tests sur E .

PREUVE DU THÉORÈME 3.1. Par application de l'inégalité (2.3), nous avons

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_{0:n} - \pi_n^N, \phi \rangle| \mid Y_{1:n}] &= \sup_{\|\phi\|=1} \mathbb{E}[|\langle \frac{p_{0:n}}{\langle p_{1:n}, \Psi_{1:n} \rangle} - \frac{S^N(p_{0:n})}{\langle S^N(p_{1:n}), \Psi_{1:n} \rangle}, \Psi_{1:n} \phi \rangle| \mid Y_{1:n}] , \\ &\leq \frac{2}{\langle p_{0:n}, \Psi_{1:n} \rangle} \sup_{\|\phi\|=1} \mathbb{E}[|\langle p_{0:n} - S^N(p_{0:n}), \Psi_{1:n} \phi \rangle| \mid Y_{1:n}] . \end{aligned}$$

Il suffit maintenant de noter que

$$\|\Psi_{1:n}\| = \|\Psi_1\| \cdots \|\Psi_n\| = M_{n:1} , \quad \text{et} \quad \langle p_{0:n}, \Psi_{1:n} \rangle = \langle \pi_1, \Psi_1 \rangle \cdots \langle \pi_n, \Psi_n \rangle = \bar{m}_{n:1} .$$

□

Avec cet algorithme, la qualité de l'approximation est indépendante de la nature des non linéarités intervenant dans le modèle, ainsi que de la dimension de l'espace d'état. Cependant, il faut noter que le temps de calcul est fonction de la complexité de simulation des noyaux de transition, de même qu'en général le coût de génération d'une v.a. augmente avec la dimension (voir [42, p. 561]). Malgré ces remarques, les méthodes de Monte Carlo restent globalement avantageuses.

Points faibles et variantes

Les performances de cet algorithme ne sont malheureusement pas satisfaisantes. En pratique, on observe que l'accumulation des pondérations entraîne le regroupement de l'essentiel de la masse sur une seule particule, les autres particules ayant des poids presque nuls. Une grande puissance de calcul est donc gâchée au traitement (prédiction et pondération) de trajectoires peu probables, dont la contribution à l'estimée est négligeable. Ce phénomène appelé *dégénérescence des pondérations* provoque à terme la divergence de l'algorithme.

Du point de vue théorique, le caractère instable de l'algorithme est suggéré par la majoration d'erreur fournie par le Théorème 3.1 qui peut croître très vite avec le temps. On retrouve ici les points difficiles annoncés dans la Section 1.2.3 : à nombre de particules constant, l'approximation n'est pas uniforme en temps, et elle est d'autant plus mauvaise que les coefficients de transport $\bar{\gamma}_n$ sont importants et nombreux.

Dans l'algorithme présenté, on applique l'échantillonnage pondéré avec comme probabilité d'importance $p_{0:n}$. Ainsi, lorsque la loi a priori $p_{0:n}$ est très différente de la loi a posteriori $\pi_{0:n}$, les particules n'explorent pas les zones intéressantes de l'espace d'état et la dégénérescence des pondérations est d'autant plus prononcée. Pour éviter cela, une idée présentée dans [46] et utilisée dans [94] consiste à choisir une probabilité d'importance minimisant la variance des poids des trajectoires. Soit $p'_{0:n}$, une mesure de probabilité sur E^{n+1} dominant $p_{0:n}$. On note $f_{0:n}$, la densité de $p_{0:n}$ par rapport $p'_{0:n}$, i.e.

$$f_{0:n}(x_{0:n}) = \frac{dp_{0:n}}{dp'_{0:n}}(x_{0:n}) ,$$

pour tout $x_{0:n} \in E^{n+1}$. On a alors

$$\pi_{0:n} = \Psi_{1:n} \cdot p_{0:n} = (\Psi_{1:n} f_{0:n}) \cdot p'_{0:n} .$$

L'algorithme proposé consiste dans le calcul séquentiel de

$$\pi'_{0:n} = (\Psi_{1:n} f_{0:n}) \cdot S^N(p'_{0:n}) .$$

Pour cela, il faut savoir simuler $p'_{0:n}$ et évaluer la fonction produit $(\Psi_{1:n} f_{0:n})$ (à une constante multiplicative près), le tout récursivement. On présente ici le choix de la probabilité d'importance $p'_{0:n}$ proposé dans [46]. Pour chaque entier $n \geq 1$, on note Ψ'_n la fonction positive sur E définie par

$$\Psi'_n(x) = \int_E \Psi_n(x') Q_n(x, dx') = \langle Q_n(x, \cdot), \Psi_n \rangle ,$$

pour tout $x \in E$. On définit le noyau de transition modifié

$$Q'_n(x, dx') = \frac{Q_n(x, dx') \Psi_n(x')}{\langle Q_n(x, \cdot), \Psi_n \rangle} = \frac{\Psi_n(x')}{\Psi'_n(x)} Q_n(x, dx') ,$$

pour tout $x, x' \in E$. La probabilité d'importance, $p'_{0:n}$ est choisie telle que

$$p'_0 = p_0 , \quad \text{et pour } n \geq 1 \quad p'_{0:n}(dx_{0:n}) = p_0(dx_0) Q'_1(x_0, dx_1) \cdots Q'_n(x_{n-1}, dx_n) ,$$

pour tout $x_{0:n} \in E^{n+1}$. On a avec ce choix

$$f_{0:n}(x_{0:n}) = \frac{dp_{0:n}}{dp'_{0:n}}(x_{0:n}) = \frac{\Psi'_0(x_0) \cdots \Psi'_n(x_n)}{\Psi_{1:n}(x_{1:n})} = \frac{\Psi'_{0:n}(x_{0:n})}{\Psi_{1:n}(x_{1:n})} ,$$

pour tout $x_{0:n} \in E^{n+1}$. La probabilité conditionnelle $\pi_{0:n} = \Psi'_{0:n} \cdot p'_{0:n}$ est alors approchée par la mesure empirique $\pi'_{0:n} = \Psi'_{0:n} \cdot S^N(p'_{0:n})$. La génération d'une v.a. $\xi'_{0:n} = (\xi'_0, \dots, \xi'_n)$ suivant $p'_{0:n}$ est réalisée en générant ξ'_0 suivant $p'_0 = p_0$ puis ξ'_k suivant $Q'_k(\xi'_{k-1}, \cdot)$. Malheureusement, il est le plus souvent difficile de simuler les noyaux $Q'_k(\xi'_{k-1}, \cdot)$, et d'évaluer les fonctions Ψ'_k . Ces opérations sont alors réalisées de manière approchée en utilisant une fois de plus l'échantillonnage pondéré. Pour chaque particule ξ'_{k-1} , on génère M évolutions $(\xi'_{k|k-1,1}, \dots, \xi'_{k|k-1,M})$ suivant $Q_k(\xi'_{k-1}, \cdot)$. Ce système de particules intermédiaire permet les approximations suivantes

$$Q'_k(\xi'_{k-1}, \cdot) \approx \sum_{j=1}^M \frac{\Psi_k(\xi'_{k|k-1,j})}{\Psi'_k(\xi'_{k-1})} \delta_{\xi'_{k|k-1,j}} , \quad \text{et} \quad \Psi'_k(\xi'_{k-1}) \approx \frac{1}{M} \sum_{j=1}^M \Psi_k(\xi'_{k|k-1,j}) .$$

Cette procédure permet d'améliorer sensiblement le comportement du filtre. L'étape d'évolution est réalisée conditionnellement à l'observation courante. Ainsi, l'exploration de l'espace d'état par les particules n'est plus aveugle, mais dirigée dans les zones de forte vraisemblance. Cependant, cette méthode est très exigeante en temps de calcul. Cette idée d'évolutions conditionnelles est aussi exploitée, dans le cadre des systèmes de particules en interactions (voir [38, pp. 60–63]). Nous présenterons cette application succinctement dans la section suivante.

D'autres idées, moins coûteuses, ont été proposées pour éviter la dégénérescence des pondérations. Elles consistent à oublier complètement ou partiellement les observations les plus anciennes. Nous présentons, dans les sous-sections suivantes deux de ces techniques.

3.1.2 Filtre à mémoire limitée

L'idée du filtre à mémoire limitée consiste à ne tenir compte que des p observations les plus récentes de manière à éviter l'accumulation des pondérations responsable de la divergence avec le temps du filtre de Monte Carlo pondéré. On se contente donc d'approcher le filtre optimal par la loi conditionnelle aux observations les plus récentes. Le filtre à mémoire limitée aux p dernières observations est noté $(\pi_{n,p})_{n \geq 0}$,

$$\pi_{n,p}(dx) = \mathbb{P}[X_n \in dx | Y_{1:n}] \quad \text{si } n \leq p , \quad \text{et} \quad \pi_{n,p}(dx) = \mathbb{P}[X_n \in dx | Y_{n:n-p+1}] \quad \text{si } n \geq p+1 .$$

L'idée de limiter la mémoire du filtre brutalement (filtre à mémoire limitée) ou progressivement (filtre à oubli exponentiel, section suivante) est très répandue dans le domaine du filtrage. Elle

est apparue très tôt, dans le développement du filtre de Kalman [58], pour éviter les problèmes de divergence observés lorsque le modèle d'état ou d'observation est mal connu. Cette idée est aussi classiquement utilisée en filtrage adaptatif, dans les cas de systèmes lentement variables, où elle donne lieu aux algorithmes des moindres carrés récurrents à mémoire limitée et à oubli exponentiel. Dans les deux cas, il s'agit de traiter le problème de robustesse aux erreurs éventuelles de modèle, auquel on peut identifier, par analogie (comme au Chapitre 2), le problème plus général de stabilité du filtre par rapport aux perturbations locales. De ce point de vue, l'utilisation du filtre à mémoire limitée en filtrage particulaire paraît une extension naturelle.

Cependant, cette technique semble a priori frustrante, puisqu'on s'empêche volontairement de tirer parti de toutes les observations. En fait, elle consiste à équilibrer la précision des informations accumulées avec la précision de l'approximation, comme cela a été suggéré dans la conclusion du Chapitre 2. Intuitivement, lorsque le filtre approché est moins précis que les observations, il est incapable d'exploiter proprement ces données. Il risque même de mal les utiliser et de diverger. Dans ce cas, on comprend qu'il est préférable de se limiter à une interprétation partielle mais juste des observations les plus récentes. La taille de la mémoire doit correspondre à la durée pendant laquelle le filtre approché constitue une approximation satisfaisante du filtre optimal. En filtrage particulaire, l'erreur d'échantillonnage introduite s'accumule avec le temps. La taille de la mémoire doit donc dépendre des erreurs locales (fonction du nombre de particules) mais aussi de la manière dont elles se propagent. Nous verrons, en effet, dans la suite, que les résultats de convergence uniforme obtenus sont réalisés pour une mémoire augmentant avec le nombre de particules, mais sous des conditions de bonne propagation de l'erreur (assurées par l'ergodicité du noyau de transition).

Le filtre de Monte Carlo pondéré à mémoire limitée aux p dernières observations est noté $(\pi_{n,p}^N)_{n \geq 0}$. Il est défini par

$$\langle \pi_{n,p}^N, \phi \rangle = \frac{\langle S^N(p_{1:n}), \Psi_{1:n} \phi \rangle}{\langle S^N(p_{1:n}), \Psi_{1:n} \rangle} \quad \text{si } n \leq p, \quad \langle \pi_{n,p}^N, \phi \rangle = \frac{\langle S^N(p_{p:n}), \Psi_{p:n} \phi \rangle}{\langle S^N(p_{p:n}), \Psi_{p:n} \rangle} \quad \text{si } n \geq p+1,$$

pour toute fonction test, ϕ , mesurable et bornée ne dépendant que de la n -ième variable. Il est initialisé à la valeur $\pi_{0,p}^N = S^N(p_0)$ avec les poids $\omega_0^i = \frac{1}{N}$ pour $1 \leq i \leq N$. Puis le passage de $\pi_{n-1,p}^N$ à $\pi_{n,p}^N$ est décrit par l'algorithme,

(i) Evolution : indépendamment pour chaque i , générer $\xi_n^i \sim Q_n(\xi_{n-1}^i, \cdot)$.

(ii) Correction : pour tout i , calculer les poids

$$\omega_n^i = \frac{\Psi_n(\xi_n^i) \omega_{n-1}^i}{\sum_{j=1}^N \Psi_n(\xi_n^j) \omega_{n-1}^j} \quad \text{si } n \leq p, \quad \omega_n^i = \frac{\frac{\Psi_n(\xi_n^i)}{\Psi_{n-p}(\xi_{n-p}^i)} \omega_{n-1}^i}{\sum_{j=1}^N \frac{\Psi_n(\xi_n^j)}{\Psi_{n-p}(\xi_{n-p}^j)} \omega_{n-1}^j} \quad \text{si } n \geq p+1.$$

Puis poser

$$\pi_{n,p}^N = \sum_{i=1}^N \omega_n^i \delta_{\xi_n^i}$$

Del Moral [31] montre que sous certaines conditions d'ergodicité du signal, le filtre de Monte Carlo pondéré à mémoire limitée fournit une approximation uniforme en temps du filtre optimal. On rapporte ici brièvement ce résultat de convergence uniforme et l'idée de sa preuve.

Théorème 3.2 (Del Moral [31]). *On considère un modèle de filtrage homogène, i.e. pour tout entier $n \geq 1$, $Q_n = Q$, $h_n = h$ avec une séquence de bruits $(V_n)_{n \geq 1}$ i.i.d.. Supposons que les deux conditions suivantes soient satisfaites :*

- (i) *Le noyau de transition Q possède une unique mesure invariante μ telle que pour toute fonction ϕ mesurable bornée sur E , et toute mesure de probabilité $\nu \in \mathcal{P}(E)$,*

$$\lim_{n \rightarrow \infty} |\langle Q^n \nu - \mu, \phi \rangle| = 0, \quad \text{et} \quad \limsup_{n \rightarrow \infty} \langle \mu, \Phi_n \rangle = 0,$$

où Φ_n est la fonction positive sur E définie par

$$\Phi_n(x) = |\langle Q^n \delta_x - \mu, \phi \rangle|,$$

pour tout $x \in E$.

- (ii) *La fonction d'observation h est telle que*

$$\sup_{n \geq 0} [\langle p_n, h^2 \rangle - \langle p_n, h \rangle^2] < \infty, \quad \text{i.e.} \quad \text{Var}(h(X_n)) < \infty.$$

Alors il existe une fonction croissante $p : \mathbb{N} \rightarrow \mathbb{N}$ telle que

$$\lim_{N \rightarrow \infty} \sup_{n \geq 0} \mathbb{E} |\langle \pi_{n,p(N)}^N - \pi_n, \phi \rangle| = 0. \quad (3.1)$$

Ce théorème ne fournit pas de vitesse de convergence, car sa preuve utilise le lemme suivant.

Lemme 3.3 (Ocone et Pardoux [86]). *Si le noyau de transition Q satisfait la condition d'ergodicité (i) du Théorème 3.2 alors pour toute fonction ϕ mesurable bornée sur E ,*

$$\limsup_{n \geq p} \mathbb{E} |\langle \pi_{n,p}^N - \pi_n, \phi \rangle| = 0. \quad (3.2)$$

Ce lemme utilise l'homogénéité du système et le résultat de Stettner [100] assurant l'ergodicité de $(\pi_n)_{n \geq 0}$. Il apporte déjà une première information rassurante, à savoir que le filtre à mémoire limitée converge uniformément dans le temps vers le filtre optimal.

La preuve du Théorème 3.2 est basée sur la décomposition suivante de l'erreur,

$$\mathbb{E} |\langle \pi_{n,p(N)}^N - \pi_n, \phi \rangle| \leq \mathbb{E} |\langle \pi_{n,p(N)}^N - \pi_{n,p(N)}, \phi \rangle| + \mathbb{E} |\langle \pi_{n,p(N)} - \pi_n, \phi \rangle|.$$

Le second terme du membre de droite est directement traité par le Lemme 3.3. La majoration du premier terme consiste à choisir une taille de mémoire adéquate en fonction du nombre de particules assurant une erreur globale uniformément bornée dans le temps. Ce choix consiste à équilibrer le coût de transport de l'erreur (fonction de la taille de la mémoire) et l'erreur locale (fonction du nombre de particules). Nous ne détaillons pas plus en détails ces manipulations

car nous réutiliserons la même idée pour le filtre à oubli exponentiel, dans la preuve du Corollaire 3.6 de la section suivante.

Malheureusement, avec cette approche, on perd le caractère récursif de l'algorithme puisque le calcul de $\pi_{n,p}^N$ exige de stocker les p dernières observations pour pouvoir supprimer à chaque instant l'influence de la p ième observation passée. La méthode d'oubli progressif analysée, dans la section suivante a l'avantage de conserver le caractère récursif du filtre.

3.1.3 Filtre à oubli exponentiel

Parallèlement à l'idée d'oublier brutalement les anciennes observations s'est développée l'idée d'un oubli progressif paramétré par un facteur d'oubli α . On verra que cette méthode possède elle aussi des propriétés de convergence uniforme sous des conditions (plus fortes) de mélange de l'opérateur d'évolution. Il existe déjà des résultats théoriques justifiant son utilisation pour l'algorithme des moindres carrés récursifs (qui s'identifie au filtre de Kalman dans le cas d'un état déterministe). Guo, Ljung et Priouret [50] montrent, en effet, que l'erreur d'estimation commise par cet algorithme est d'ordre $O(\sqrt{1-\alpha} + \varepsilon/\sqrt{1-\alpha})$, lorsque le processus état est simplement perturbé par un bruit additif de puissance inconnue paramétrée par ε . Ce qui montre, dans ce cas particulier d'estimation linéaire, que la mémoire doit être d'autant plus grande ($\alpha \rightarrow 1$) que l'erreur sur le modèle est petite ($\varepsilon \rightarrow 0$). Dans le cadre du filtrage non linéaire, notre approche permet d'obtenir des résultats similaires, pour les systèmes à dynamique mélangeante.

Nous présentons, dans un premier temps, le filtre à oubli exponentiel sans approximation particulière, pour lequel nous montrons des résultats de convergence uniforme précis vers le filtre optimal lorsque la mémoire augmente ($\alpha \rightarrow 1$). Puis ces résultats sont appliqués au filtre particulier à oubli exponentiel.

Filtre à oubli exponentiel

Description Nous définissons la vraisemblance conjointe exponentiellement modifiée, $\Psi_{1:n}^{(\alpha)}$, par un facteur d'oubli $0 \leq \alpha \leq 1$, de la manière suivante,

$$\Psi_1^{(\alpha)} = \Psi_1, \quad \text{et pour } n \geq 2, \quad \Psi_{1:n}^{(\alpha)}(x_{1:n}) = (\Psi_1)^{\alpha^{n-1}}(x_1) \cdots (\Psi_k)^{\alpha^{n-k}}(x_k) \cdots \Psi_n(x_n),$$

pour tout $x_{1:n} \in E^n$. Notons que la modification exponentielle consiste à privilégier l'importance des observations les plus récentes par rapport aux premières observations. Par exemple, dans le cas d'un bruit d'observation additif et gaussien de matrice de covariance Σ , cela revient exactement à augmenter artificiellement la variance des bruits sur les observations passées, en effet dans ce cas

$$(\Psi_k)^{\alpha^{n-k}}(x) = C \exp\left\{-\frac{1}{2} (Y_k - h_k(x))^T \Sigma_k^{-1} (Y_k - h_k(x))\right\}, \quad \text{avec } \Sigma_k = (1/\alpha^{n-k}) \Sigma.$$

Dans cette partie, nous nous intéressons au filtre à oubli exponentiel $(\pi_n^{(\alpha)})_{n \geq 0}$ paramétré par le facteur d'oubli $0 \leq \alpha \leq 1$, et défini de la même manière que le filtre optimal, en remplaçant, dans (1.4), la vraisemblance conjointe $\Psi_{1:n}$ par la vraisemblance conjointe exponentiellement

modifiée $\Psi_{1:n}^{(\alpha)}$,

$$\pi_n^{(\alpha)} = \Psi_{1:n}^{(\alpha)} \cdot p_{0:n}, \quad \text{i.e.} \quad \langle \pi_n^{(\alpha)}, \phi \rangle = \frac{\langle p_{0:n}, \Psi_{1:n}^{(\alpha)} \phi \rangle}{\langle p_{0:n}, \Psi_{1:n}^{(\alpha)} \rangle}, \quad (3.3)$$

pour toute fonction ϕ mesurable et bornée ne dépendant que de la n -ième variable. Nous observons que lorsque le facteur d'oubli vaut un, le filtre à oubli exponentiel se confond avec le filtre optimal, (il n'y a pas d'oubli). Au contraire, lorsque le facteur d'oubli vaut zéro, le filtre à oubli exponentiel se confond avec la suite des lois a priori $(p_n)_{n \geq 0}$, aucune observation n'est prise en compte (tout est oublié). Notre but est de prouver que, sous des conditions de mélange de l'opérateur d'évolution, le filtre à oubli exponentiel constitue une approximation uniforme en temps du filtre optimal (lorsque le facteur d'oubli tend vers 1). Pour cela, on se placera, de nouveau sous la métrique de Hilbert, pour se ramener à l'étude des processus dénormalisés (à valeurs mesures) $(\mu_n)_{n \geq 0}$ et $(\mu_n^{(\alpha)})_{n \geq 0}$ définis comme suit.

$$\mu_0 = p_0, \quad \text{et pour } n \geq 1, \quad \langle \mu_n, \phi \rangle = \langle p_{1:n}, \Psi_{1:n} \phi \rangle,$$

pour toute fonction ϕ mesurable et bornée. Ou de manière équivalente,

$$\mu_n = R_{n:1} \mu_0 = \Psi_n Q_n \Psi_{n-1} Q_{n-1} \cdots \Psi_1 Q_1 \mu_0.$$

Le filtre optimal π_n s'obtient simplement par normalisation de μ_n , $\pi_n = \bar{\mu}_n = \mu_n / \mu_n(E)$.

$$\mu_0^{(\alpha)} = \mu_0, \quad \text{et pour } n \geq 1, \quad \langle \mu_n^{(\alpha)}, \phi \rangle = \langle p_{1:n}, \Psi_{1:n}^{(\alpha)} \phi \rangle,$$

pour toute fonction ϕ mesurable et bornée. Ou de manière équivalente,

$$\mu_n^{(\alpha)} = \Psi_n Q_n (\Psi_{n-1})^\alpha Q_{n-1} \cdots (\Psi_1)^{\alpha^{n-1}} Q_1 \mu_0.$$

Le filtre exponentiellement modifié $\pi_n^{(\alpha)}$ s'obtient simplement par normalisation de $\mu_n^{(\alpha)}$, $\pi_n^{(\alpha)} = \mu_n^{(\alpha)} / \mu_n^{(\alpha)}(E)$.

Pour décrire l'évolution du processus $(\mu_n^{(\alpha)})_{n \geq 0}$, il nous faut introduire un dernier processus intermédiaire, $(\nu_n^{\alpha,k})_{n \geq 0}$, défini pour tout entier $k \geq 0$ par

$$\nu_n^{\alpha,k} = (\Psi_{1:n}^{(\alpha)})^{\alpha^k} p_{1:n} \quad \text{i.e.} \quad \langle \nu_n^{\alpha,k}, \phi \rangle = \langle p_{1:n}, (\Psi_{1:n}^{(\alpha)})^{\alpha^k} \phi \rangle,$$

pour toute fonction ϕ mesurable et bornée. Nous observons que pour $k = 0$, $\nu_n^{\alpha,0}$ se réduit à $\mu_n^{(\alpha)}$, et que pour $k \geq 1$, $\nu_n^{\alpha,k}$ s'obtient à partir de $\mu_{n-1}^{(\alpha)}$ par atténuation de l'influence de la vraisemblance conjointe $\Psi_{1:n}^{(\alpha)}$ en l'élevant à la puissance α^k .

La transition de $\mu_{n-1}^{(\alpha)}$ à $\mu_n^{(\alpha)}$ se déroule en deux étapes,

$$\mu_{n-1}^{(\alpha)} \longrightarrow \nu_{n-1}^{\alpha,1} \longrightarrow \mu_n^{(\alpha)} = \Psi_n Q_n \nu_{n-1}^{\alpha,1} = R_n \nu_{n-1}^{\alpha,1}.$$

Résultat de convergence Dans cette partie, nous montrons que le filtre à oubli exponentiel converge uniformément vers la filtre optimal à une vitesse $(1 - \alpha)$ lorsque α tend vers 1. Nous énonçons d'abord le lemme suivant.

Lemme 3.4. *Soient μ et μ' deux mesures signées finies et comparables, et Ψ et Ψ' deux fonctions positives, pour lesquelles il existe des constantes $a, b > 0$, telles que $a\Psi \leq \Psi' \leq b\Psi$. Alors,*

$$h(\Psi\mu, \Psi'\nu) \leq h(\Psi, \Psi') + h(\mu, \nu) , \quad (3.4)$$

avec la notation, $h(\Psi, \Psi') = \log \left(\left\| \frac{\Psi}{\Psi'} \right\| \left\| \frac{\Psi'}{\Psi} \right\| \right)$.

PREUVE DU LEMME 3.4. La preuve est directe puisque $\Psi\mu$ et $\Psi'\nu$ sont deux mesures équivalentes dont les dérivées de Radon–Nikodym vérifient

$$\frac{d\Psi\mu}{d\Psi'\nu} = \frac{\Psi}{\Psi'} \frac{d\mu}{d\nu} , \quad \text{et} \quad \frac{d\Psi'\nu}{d\Psi\mu} = \frac{\Psi'}{\Psi} \frac{d\nu}{d\mu} ,$$

ce qui implique, d'après l'égalité (2.25),

$$\begin{aligned} h(\Psi\mu, \Psi'\nu) &= \log \left(\left\| \frac{\Psi}{\Psi'} \frac{d\mu}{d\nu} \right\| \left\| \frac{\Psi'}{\Psi} \frac{d\nu}{d\mu} \right\| \right) \\ &\leq \log \left(\left\| \frac{\Psi}{\Psi'} \right\| \left\| \frac{\Psi'}{\Psi} \right\| \right) + \log \left(\left\| \frac{d\mu}{d\nu} \right\| \left\| \frac{d\nu}{d\mu} \right\| \right) \\ &= h(\Psi, \Psi') + h(\mu, \nu) . \end{aligned}$$

□

Nous introduisons une hypothèse supplémentaire sur l'existence de minorants et majorants strictement positifs pour la fonction de vraisemblance.

Hypothèse $[\tilde{\Psi}]$: Il existe des constantes $0 < \tilde{m}_k \leq M_k$, éventuellement fonctions de Y_k , telles que

$$0 < \tilde{m}_k \leq \Psi_k(x) \leq M_k < \infty ,$$

pour tout $x \in E$. Nous notons alors $\tilde{\gamma}_k = \frac{M_k}{\tilde{m}_k}$.

On observe que $\tilde{\gamma}_k \leq \gamma_k \leq \tilde{\gamma}_k$. Nous pouvons maintenant énoncer le résultat suivant qui montre la convergence uniforme du filtre à oubli exponentiel vers le filtre optimal.

Théorème 3.5. *Si pour tout entier $k \geq 1$ les Hypothèses $[\mathbf{R}][\tilde{\Psi}]$ sont vérifiées pour des constantes de mélange $\varepsilon_k \geq \varepsilon > 0$, si de plus, il existe une constante $C > 0$ telle que $\mathbb{E}[\log(\tilde{\gamma}_k)] \leq C$, alors pour tout facteur d'oubli $1 \geq \alpha \geq 0$, on a*

$$\mathbb{E} \|\pi_n^{(\alpha)} - \pi_n\| \leq C_1(1 - \alpha) , \quad \text{avec} \quad C_1 = \frac{2}{\log 3} \frac{C}{\varepsilon^4} . \quad (3.5)$$

PREUVE DU THÉORÈME 3.5. D'après le Lemme 2.15,

$$\|\pi_n^{(\alpha)} - \pi_n\| \leq \frac{2}{\log 3} h(\pi_n^{(\alpha)}, \pi_n) = \frac{2}{\log 3} h(\mu_n^{(\alpha)}, \mu_n) . \quad (3.6)$$

en utilisant le Lemme 2.18, et l'hypothèse de mélange, on sait que R_k est une contraction sous la métrique de Hilbert, avec un taux de contraction $\tau_k \leq \tau = \frac{1-\varepsilon^2}{1+\varepsilon^2}$. Sachant que $\mu_n^{(\alpha)} = R_n \nu_{n-1}^{\alpha,1}$ et $\mu_n = R_n \mu_{n-1}$, nous obtenons par l'inégalité triangulaire,

$$\begin{aligned} h(\mu_n^{(\alpha)}, \mu_n) &\leq \sum_{k=1}^n h(R_{n:k} \nu_{k-1}^{\alpha,1}, R_{n:k} \mu_{k-1}^{(\alpha)}) \\ &\leq \sum_{k=1}^n \tau^{n+1-k} h(\nu_{k-1}^{\alpha,0}, \nu_{k-1}^{\alpha,1}) . \end{aligned} \quad (3.7)$$

Considérons maintenant le terme $h(\nu_{k-1}^{\alpha,0}, \nu_{k-1}^{\alpha,1})$. Rappelons que

$$\begin{aligned} \nu_{k-1}^{\alpha,0} &= \mu_{k-1}^{(\alpha)} = \Psi_{k-1} Q_{k-1} (\Psi_{k-2})^\alpha Q_{k-2} \cdots (\Psi_1)^{\alpha^{k-2}} Q_1 \mu_0 = R_{k-1} \nu_{k-2}^{\alpha,1} , \\ \nu_{k-1}^{\alpha,1} &= (\Psi_{k-1})^\alpha Q_{k-1} (\Psi_{k-2})^{\alpha^2} Q_{k-2} \cdots (\Psi_1)^{\alpha^{k-1}} Q_1 \mu_0 = (\Psi_{k-1})^{\alpha-1} R_{k-1} \nu_{k-2}^{\alpha,2} . \end{aligned}$$

Nous obtenons donc

$$h(\nu_{k-1}^{\alpha,0}, \nu_{k-1}^{\alpha,1}) = h(R_{k-1} \nu_{k-2}^{\alpha,1}, (\Psi_{k-1})^{\alpha-1} R_{k-1} \nu_{k-2}^{\alpha,2}) .$$

Comme les fonctions de vraisemblance Ψ_k sont minorées et majorées par des réels strictement positifs et que de plus $R_{k-1} \nu_{k-2}^{\alpha,1}$ et $R_{k-1} \nu_{k-2}^{\alpha,2}$ sont comparables (puisque R_{k-1} est mélangeant), nous pouvons appliquer l'inégalité du Lemme 3.4, qui entraîne

$$\begin{aligned} h(\nu_{k-1}^{\alpha,0}, \nu_{k-1}^{\alpha,1}) &\leq h(\Psi_{k-1}^{\alpha-1}, 1) + h(R_{k-1} \nu_{k-2}^{\alpha,1}, R_{k-1} \nu_{k-2}^{\alpha,2}) , \\ &\leq h(\Psi_{k-1}^{\alpha-1}, 1) + \tau h(\nu_{k-2}^{\alpha,1}, \nu_{k-2}^{\alpha,2}) . \end{aligned}$$

De même pour tous les entiers $1 \leq i \leq k-1 \leq n-1$, nous avons

$$\begin{aligned} h(\nu_{k-i}^{\alpha,i-1}, \nu_{k-i}^{\alpha,i}) &= h((\Psi_{k-i})^{\alpha^{i-1}-1} R_{k-i} \nu_{k-i-1}^{\alpha,i}, (\Psi_{k-i})^{\alpha^i-1} R_{k-i} \nu_{k-i-1}^{\alpha,i+1}) , \\ &\leq h((\Psi_{k-i})^{\alpha^{i-1}-1}, (\Psi_{k-i})^{\alpha^i-1}) + \tau h(\nu_{k-i-1}^{\alpha,i}, \nu_{k-i-1}^{\alpha,i+1}) . \end{aligned}$$

Nous obtenons ainsi la majoration suivante, pour tout entier $1 \leq k \leq n$,

$$\begin{aligned} h(\nu_{k-1}^{\alpha,0}, \nu_{k-1}^{\alpha,1}) &\leq \sum_{i=0}^{k-2} \tau^i h((\Psi_{k-1-i})^{\alpha^{i+1}-1}, (\Psi_{k-1-i})^{\alpha^i-1}) , \\ &= \sum_{i=0}^{k-2} \tau^i \log(\|(\Psi_{k-1-i})^{\alpha^{i+1}-1}\| \|(\Psi_{k-1-i})^{\alpha^i-1}\|) . \end{aligned}$$

Les fonctions de vraisemblance Ψ_k étant minorées et majorées respectivement par $\tilde{m}_k$ et M_k , nous avons,

$$\mathbb{E}[h(\nu_{k-1}^{\alpha,0}, \nu_{k-1}^{\alpha,1})] \leq \mathbb{E} \sum_{i=0}^{k-2} \tau^i \alpha^i (1-\alpha) \log(\tilde{\gamma}_{k-1-i}) \leq \sum_{i=0}^{k-2} (\tau\alpha)^i (1-\alpha) C \leq \frac{1-\alpha}{1-\tau\alpha} C. \quad (3.8)$$

La combinaison des équations (3.6), (3.7) et (3.8) nous conduit à l'équation (3.5). $\square$

Filtre de Monte Carlo pondéré à oubli exponentiel

Dans cette partie, le but est de prouver la convergence uniforme dans le temps du filtre de Monte Carlo à oubli exponentiel vers le filtre optimal. La preuve du résultat énoncé ci-dessous s'inspire de [31].

Description Nous définissons le filtre de Monte Carlo pondéré à oubli exponentiel $\pi_n^{(\alpha),N}$, de la manière suivante,

$$\pi_n^{(\alpha),N} = \Psi_{1:n}^{(\alpha)} \cdot S^N(p_{0:n}) \quad \text{i.e.} \quad \langle \pi_n^{(\alpha),N}, \phi \rangle = \frac{\langle S^N(p_{0:n}), \Psi_{1:n}^{(\alpha)} \phi \rangle}{\langle S^N(p_{0:n}), \Psi_{1:n}^{(\alpha)} \rangle},$$

pour toute fonction ϕ mesurable et bornée. Nous rappelons que $S^N(p_{0:n})$ désigne la mesure empirique de taille N associée à $p_{0:n}$, i.e.

$$S^N(p_{0:n}) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_{0:n}^i} \quad \text{avec } (\xi_{0:n}^1, \dots, \xi_{0:n}^N) \text{ i.i.d. } \sim p_{0:n}.$$

Le filtre de Monte Carlo à oubli exponentiel est initialisé à la valeur $\pi_0^{(\alpha),N} = S^N(p_0)$ et les poids $\omega_0^i = \frac{1}{N}$ pour $1 \leq i \leq N$. Puis le passage de $\pi_{n-1}^{(\alpha),N}$ à $\pi_n^{(\alpha),N}$ est décrit par l'algorithme suivant,

- (i) Evolution : indépendamment pour chaque i , générer $\xi_n^i \sim Q_n(\xi_{n-1}^i, \cdot)$.
- (ii) Correction : pour chaque i , calculer les poids

$$\omega_n^i = \frac{\Psi_n(\xi_n^i) (\omega_{n-1}^i)^\alpha}{\sum_{j=1}^N \Psi_n(\xi_n^j) (\omega_{n-1}^j)^\alpha}.$$

Puis poser

$$\pi_n^N = \sum_{i=1}^N \omega_n^i \delta_{\xi_n^i}$$

Dans cette partie nous choisissons le facteur d'oubli $1 > \alpha \geq 0$ comme une fonction du nombre de particules N de sorte que $\alpha(N) \xrightarrow{N \rightarrow \infty} 1$. Le corollaire suivant montre qu'il est possible de trouver une fonction α de N (et en exhibe une) telle que $\pi_n^{(\alpha(N)),N}$ converge vers π_n uniformément en temps, avec le nombre de particules.

Résultat de convergence Une grande faiblesse du filtre de Monte Carlo pondéré est que chaque particule simulée ξ_n^i est condamnée à porter éternellement le poids de son passé : si ξ_k est très faiblement pondérée, il y a de bonnes chances pour que ξ_n^i ($n \geq k$) le soit aussi. Ce poids du passé est totalement justifié lorsque le filtre dépend fortement de sa condition initiale. Par contre, un filtre à évolution mélangeante oublie son passé à une vitesse exponentielle. Les propriétés de mélange font qu'une particule ξ_k peu vraisemblable, à l'instant k , peut redevenir très vraisemblable à l'instant $n > k$. L'idée du filtre à oubli exponentiel est de prendre en compte cette possibilité et d'exploiter au maximum toutes les particules en empêchant qu'elles soient excessivement pénalisées par leur passé. Le corollaire suivant justifie cette idée.

Corollaire 3.6. *Si pour tout entier $0 \leq k \leq n$ les Hypothèses $[\mathbf{R}][\tilde{\Psi}]$ sont vérifiées pour des constantes de mélange $\varepsilon_k \geq \varepsilon > 0$, si de plus, il existe une constante $C > 0$ telle que $\mathbb{E}[\log(\tilde{\gamma}_k)] \leq C$, alors,*

$$\sup_{\|\phi\|=1} \mathbb{E}|\langle \pi_n^{(\alpha(N)),N} - \pi_n, \phi \rangle| \leq \frac{C_2}{(\log N)^{1/2}} + \frac{2}{N^{1/4}}, \quad \text{avec } C_2 = \frac{4}{\log 3} \frac{C}{\varepsilon^4} + 8C, \quad (3.9)$$

$$\text{et } \alpha(N) = 1 - \frac{1}{\log(N)^{1/2}}, \quad (3.10)$$

pour toute fonction ϕ mesurable de norme unité.

Notons que dans la majoration (3.9), l'espérance est prise par rapport aux observations $(Y_1, \dots, Y_n)$ et aux variables aléatoires simulées $(\xi_{0:n}^1, \dots, \xi_{0:n}^N)$. D'autre part, on observe que par rapport au filtre à mémoire limitée nous avons dû renforcer l'hypothèse sur le noyau de transition. En contrepartie, le résultat du Corollaire 3.6 est valable pour les systèmes non homogènes et fournit une vitesse de convergence.

PREUVE DU COROLLAIRE 3.6. Soit ϕ une fonction mesurable de norme unité, nous pouvons majorer l'erreur comme suit

$$\mathbb{E}|\langle \pi_n^{(\alpha),N} - \pi_n \phi \rangle| \leq \mathbb{E}|\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle| + \mathbb{E}|\langle \pi_n^{(\alpha)} - \pi_n, \phi \rangle|. \quad (3.11)$$

Le second terme à droite de l'inégalité est déjà majoré par le Théorème 3.5. Décomposons le premier terme de la manière suivante,

$$\mathbb{E}|\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle| \leq \mathbb{E}|\mathbb{E}[\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle \mid Y_{1:n}] \mathbf{1}_B| + \mathbb{E}|\mathbb{E}[\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle \mid Y_{1:n}] \mathbf{1}_{B^c}|, \quad (3.12)$$

où B est un événement aléatoire mesurable par rapport aux observations.

Le premier terme à droite de l'inégalité (3.12) est majoré ainsi

$$\mathbb{E}|\mathbb{E}[\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle \mid Y_{1:n}] \mathbf{1}_B| \mathbb{P}(B) \leq 2 \|\Phi\| \mathbb{P}(B) \leq 2 \mathbb{P}(B), \quad (3.13)$$

puisque ϕ est de norme unité. Par application du Lemme 2.8 au second terme de la décomposition (3.12), nous obtenons

$$|\mathbb{E}[\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle \mid Y_{1:n}]| = |\mathbb{E}[\langle \frac{S^N(p_{0:n})}{\langle S^N(p_{0:n}), \Psi_{1:n}^{(\alpha)} \rangle} - \frac{p_{0:n}}{\langle p_{0:n}, \Psi_{1:n}^{(\alpha)} \rangle}, \Psi_{1:n}^{(\alpha)} \phi \rangle]| \leq \frac{2a(\Psi_{1:n}^{(\alpha)})}{\sqrt{N}},$$

où $a(\Psi_{1:n}^{(\alpha)}) = \prod_{k=1}^n \tilde{\gamma}_k^{\alpha^{n-k}}$. En prenant l'espérance par rapport aux observations, nous obtenons

$$\mathbb{E}|\mathbb{E}[\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle \mid Y_{1:n}] \mathbf{1}_{B^c}| \leq \frac{2}{\sqrt{N}} \mathbb{E}[a(\Psi_{1:n}^{(\alpha)}) \mathbf{1}_{B^c}]. \quad (3.14)$$

En injectant les équations (3.13) et (3.14) dans (3.12) nous avons,

$$\mathbb{E}|\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle| \leq 2 \mathbb{P}(B) + \frac{2}{\sqrt{N}} \mathbb{E}[a(\Psi_{1:n}^{(\alpha)}) \mathbf{1}_{B^c}]. \quad (3.15)$$

D'après les hypothèses du corollaire,

$$\mathbb{E} \log a(\Psi_{1:n}^{(\alpha)}) \leq \sum_{k=1}^n \alpha^{n-k} \mathbb{E} \log \tilde{\gamma}_k \leq \frac{C}{1-\alpha}.$$

Par application de l'inégalité de Markov, pour toute constante positive g , nous pouvons écrire

$$\mathbb{P}(\log a(\Psi_{1:n}^{(\alpha)}) > g) \leq \frac{C}{1-\alpha} \frac{1}{g},$$

Ainsi pour toute fonction, G strictement positive, définie sur $[0; 1]$ et tout $0 \leq \alpha < 1$, nous avons

$$\mathbb{P}(B(\alpha, n)) < \frac{C}{(1-\alpha)} \frac{1}{G(\alpha)} \quad \text{avec,} \quad B(\alpha, n) = \left\{ \omega \in \Omega \mid a(\Psi_{1:n}^{(\alpha)}) > \exp(G(\alpha)) \right\}. \quad (3.16)$$

Nous appliquons l'inégalité (3.16) à l'inégalité (3.15) avec $B = B(\alpha, n)$ et nous obtenons,

$$\mathbb{E}|\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle| \leq \frac{2C}{1-\alpha} \frac{1}{G(\alpha)} + \exp(G(\alpha)) \frac{2}{\sqrt{N}}.$$

Nous choisissons $G(\alpha)$ et α , de la manière suivante,

$$G(\alpha) = \frac{1}{4} \log N, \quad \text{et} \quad \alpha = 1 - \frac{1}{(\log N)^{1/2}}, \quad (3.17)$$

que nous injectons dans l'équation (3.11), ce qui conduit finalement à l'inégalité

$$E|\langle \pi_n^{(\alpha),N} - \pi_n^{(\alpha)}, \phi \rangle| \leq \frac{2}{\log 3} \frac{C}{(1-\tau)^2 (\log N)^{1/2} + \tau(1-\tau)} + \frac{8C}{(\log N)^{1/2}} + \frac{2}{N^{1/4}},$$

et termine la preuve du corollaire. $\square$

3.1.4 Conclusion

Dans cette section, nous avons présenté les différents types de filtres de Monte Carlo pondéré proposés dans la littérature. Nous avons vu que l'introduction d'oubli dans l'évolution du filtre au travers des observations permet parfois de le rendre plus stable par rapport aux erreurs locales d'approximation. A la suite du résultat de Del Moral [31] pour le filtre de Monte Carlo pondéré à mémoire limitée, nous avons prouvé sous des conditions de mélange la convergence uniforme en temps du filtre de Monte Carlo pondéré à oubli exponentiel. Les

conditions de validité de notre résultat sont certes plus contraignantes que dans [31] pour le filtre à mémoire limitée, mais notre résultat gagne en précision puisque nous obtenons des vitesses de convergence. L'approche adoptée est elle aussi différente. Elle est basée sur des techniques hilbertiennes, mais n'utilise pas les résultats de stabilité du Chapitre 2. Les théorèmes du Chapitre 2 serviront dans la suite pour d'autres types de schémas particuliers.

Cependant, lorsque l'on sort du cadre strict des hypothèses fortes sur les vraisemblances et les noyaux de transitions, ces méthodes d'oubli ne permettent pas d'améliorer suffisamment les performances du filtre de Monte Carlo pondéré. Les zones explorées par les particules sont déterminées a priori suivant la dynamique du processus état, sans tenir compte des observations. Ce point est relativement gênant car on aimerait diriger les particules dans les zones de forte vraisemblance. Pour améliorer la qualité d'exploration de l'espace par les particules, sans trop augmenter le coût de calcul, une idée est de rééchantillonner périodiquement le système de particules. La procédure consiste à multiplier les trajectoires fortement pondérées et éliminer les autres, de sorte à concentrer les particules dans les zones de forte probabilité. En outre, à chaque échantillonnage, les poids sont réinitialisés à $1/N$, ce qui empêche automatiquement la dégénérescence des pondérations. Cette procédure donne lieu aux méthodes particulières avec interaction qui sont présentées dans la section suivante.

3.2 Filtre particulaire avec interaction

Dans cette section, nous nous intéressons au filtre particulaire avec interaction ("Interacting Particle Filter", IPF). L'IPF est d'abord décrit et analysé pour des systèmes assez généraux. Nous proposons ensuite un nouveau schéma de rééchantillonnage avec nombre aléatoire de particules. Puis, un résultat de convergence uniforme est prouvé, dans le cadre particulier de dynamique mélangeante. Enfin, nous mettons en évidence les points faibles de l'IPF et présentons quelques variantes proposées dans littérature.

3.2.1 Analyse générale

Description

Le filtre particulaire avec interaction est noté π_n^N . Il est initialisé à la valeur $\pi_0^N = \pi_0$, puis la transition de π_{n-1}^N à π_n^N s'effectue en deux étapes,

$$\pi_{n-1}^N \xrightarrow[\substack{\text{Prédiction} \\ \text{échantillonnée}}]{(1)} \pi_{n|n-1}^N = S^N(Q_n \pi_{n-1}^N) \xrightarrow[\text{Correction}]{(2)} \pi_n^N = \Psi_n \cdot \pi_{n|n-1}^N. \quad (3.18)$$

Dans la pratique ces deux étapes s'implémentent de la manière suivante

(i) Prédiction échantillonnée

- Echantillonnage : générer $(\xi_{n-1}^1, \dots, \xi_{n-1}^N)$ i.i.d. $\sim \pi_{n-1}^N$.
- Evolution : indépendamment pour chaque i , générer $\xi_{n|n-1}^i \sim Q_n(\xi_{n-1}^i, \cdot)$.

Puis poser

$$\pi_{n|n-1}^N = S^N(Q_n \pi_{n-1}^N) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_{n|n-1}^i} \quad \text{i.e.} \quad \langle \pi_{n|n-1}^N, \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(\xi_{n|n-1}^i),$$

pour toute fonction ϕ mesurable bornée définie sur E .

(ii) Correction : pour tout i , calculer le poids

$$\omega_n^i = \frac{\Psi_n(\xi_{n|n-1}^i)}{\sum_{j=1}^N \Psi_n(\xi_{n|n-1}^j)}.$$

Puis poser

$$\pi_n^N = \sum_{i=1}^N \omega_n^i \delta_{\xi_{n|n-1}^i} \quad \text{i.e.} \quad \langle \pi_n^N, \phi \rangle = \sum_{i=1}^N \omega_n^i \phi(\xi_{n|n-1}^i),$$

pour toute fonction ϕ mesurable bornée définie sur E .

L'étape de correction consiste à pondérer chaque particule suivant sa vraisemblance : les particules les plus vraisemblables se voient attribuer les poids les plus forts. Puis, l'échantillonnage (première étape de la prédiction échantillonnée) consiste à générer N v.a. suivant

la somme de Diracs pondérées $\pi_{n-1}^N = \sum_{i=1}^N \omega_{n-1}^i \delta_{\xi_{n-1|n-2}^i}$. Concrètement, il s'agit de sélectionner

N particules parmi $(\xi_{n-1|n-2}^1, \dots, \xi_{n-1|n-2}^N)$, avec la probabilité ω_{n-1}^i de choisir $\xi_{n-1|n-2}^i$. Les particules les plus vraisemblables sont sélectionnées, si bien que le système de particules se concentre naturellement dans les régions les plus intéressantes de l'espace d'état. L'exploration de l'espace par les particules est ici guidée par les observations et ainsi beaucoup plus efficace qu'avec les méthodes de Monte Carlo pondéré.

Remarque 3.7. L'échantillonnage revient à générer le vecteur aléatoire $(N_n^1, \dots, N_n^N)$ représentant le nombre d'occurrences de chaque particule dans le nouveau système. Ce vecteur aléatoire suit une loi multinomiale de paramètres $(N, N, (\omega_{n-1}^i)_{1 \leq i \leq N})$ et peut être rapidement généré, en $O(N)$ pas, de la manière suivante :

(i) Générer directement des variables uniformes ordonnées $u^1 \leq \dots \leq u^N$, (voir le théorème de Malmquist dans [42, p. 212]).

(ii) Pour tout i , poser $p^i = \sum_{j=1}^i \omega_{n-1}^j$, et calculer le nombre N_n^i de variables u^j comprises dans l'intervalle $[p^i, p^{i+1})$.

Remarque 3.8. Si les fonctions de vraisemblance Ψ_k ne sont pas strictement positives, il est possible qu'après l'étape de correction toutes les particules aient un poids nul. Pour simplifier l'exposer, nous évitons d'avoir à traiter ce cas marginal, en supposant pour tout ce qui concerne

le filtre particulaire avec interaction (et les filtres particuliers régularisés) que les fonctions de vraisemblance Ψ_k ne s'annulent jamais. Les résultats obtenus dans ce cas, s'étendent au cas général, en reprenant la démarche de Del Moral et Jacod [35]. Dans le cas critique où toutes les particules se voient attribuer un poids nul, les auteurs proposent de concentrer le système de particules en un point arbitraire de l'espace. Les preuves des théorèmes doivent alors prendre en compte cet événement de faible probabilité.

Majoration de l'erreur

On vérifie, avant tout, que le filtre particulaire avec interaction vérifie bien la propriété (2.35), i.e. que pour toute fonction mesurable et bornée F définie sur $\mathcal{P}(E)$,

$$\mathbb{E}[F(\pi_k^N) \mid Y_{1:n}] = \mathbb{E}[F(\pi_k^N) \mid Y_{1:k}] ,$$

de sorte à pouvoir appliquer les résultats de stabilité du Chapitre 2. Nous énonçons maintenant un lemme qui permettra la majoration des moments d'ordre p de l'erreur au sens faible.

Lemme 3.9 (Inégalité de Marcinkiewicz–Zygmund–Whittle [77, 103]). *Soient des variables aléatoires réelles $(\xi^1, \dots, \xi^N)$ intégrables indépendantes et centrées, alors pour tout $p \geq 1$, il existe des constantes A_p et B_p indépendantes des (ξ^i) telles que*

$$A_p \mathbb{E} \left[\left| \sum_{i=1}^N \frac{|\xi^i|^2}{N^2} \right|^{\frac{p}{2}} \right] \leq \mathbb{E} \left[\left| \sum_{i=1}^N \frac{\xi^i}{N} \right|^p \right] \leq B_p \mathbb{E} \left[\left| \sum_{i=1}^N \frac{|\xi^i|^2}{N^2} \right|^{\frac{p}{2}} \right] . \quad (3.19)$$

Grâce à Whittle [103], nous avons une valeur de la constante B_p ,

$$B_p = \frac{1}{\sqrt{\pi}} 8^{\frac{p}{2}} \Gamma\left(\frac{p+1}{2}\right) . \quad (3.20)$$

Classiquement après l'inégalité de Marcinkiewicz–Zygmund nous utilisons Jensen pour $p \geq 2$ ce qui donne finalement une majoration de l'erreur moyenne à la puissance p ,

$$\mathbb{E} \left[\left| \sum_{i=1}^N \frac{\xi^i}{N} \right|^p \right] \leq B_p \mathbb{E} \left[\frac{|\xi^1|^p}{N^{\frac{p}{2}}} \right] . \quad (3.21)$$

Le théorème suivant énonce les principaux résultats de convergence du filtre particulaire avec interaction. Le premier résultat de convergence pour cet algorithme est obtenu dans [30]. Les inégalités (3.22), (3.23) et (3.24) du théorème suivant sont des résultats connus qu'on trouvera par exemple dans [38]. Nous avons développé la nouvelle majoration (3.25) pour mettre en évidence l'influence de la régularité des transitions du filtre sur la qualité de propagation des erreurs locales.

Théorème 3.10.

$$\sup_{\|\phi\|=1} \mathbb{E} [|\langle \pi_n - \pi_n^N, \phi \rangle| \mid Y_{1:n}] \leq \frac{1}{\sqrt{N}} \sum_{k=1}^n 2^{n+1-k} \beta_{n:k+1} \bar{\gamma}_{n:k} . \quad (3.22)$$

Si pour tout entier $k \geq 1$, l'Hypothèse $[\mathbf{Q}\Psi]$ est vérifiée, alors les inégalités suivantes sont satisfaites

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi_n^N, \phi \rangle| | Y_{1:n}] \leq \frac{2}{\sqrt{N}} \sum_{k=1}^n \beta_{n:k+1} \gamma_{n:k} . \quad (3.23)$$

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi_n^N, \phi \rangle|^p | Y_{1:n}]^{\frac{1}{p}} \leq \frac{C_p}{\sqrt{N}} \sum_{k=1}^n \gamma_{n:k} . \quad (3.24)$$

où $C_p = 2B_p^{\frac{1}{p}}$ (voir (3.20)). Si pour tout entier $k \geq 1$, les Hypothèses $[\mathbf{Q}\Psi][\mathbf{Q}_d]$ sont vérifiées, avec la constante de domination c_k , alors

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi_n^N, \phi \rangle| | Y_{1:n}] \leq 2 \frac{\gamma_n}{\sqrt{N}} + \frac{4}{\sqrt{N}} \sum_{k=2}^n \beta_{n:k+1} \bar{\gamma}_{n:k} \gamma_{k-1} c_k . \quad (3.25)$$

La majoration (3.22) valable sans aucune hypothèse n'est pas très satisfaisante puisque le majorant croît exponentiellement avec le temps. Il faut supposer la condition $[\mathbf{Q}\Psi]$ assez contraignante pour obtenir un majorant d'erreur plus raisonnable (3.23). Dans l'inégalité (3.25), l'Hypothèse $[\mathbf{Q}_d]$ permet une meilleure propagation de l'erreur ($\bar{\gamma}_{n:k} \leq \gamma_{n:k}$). Cependant, l'Hypothèse $[\mathbf{Q}\Psi]$ est toujours nécessaire pour le contrôle de l'erreur locale. Nous proposons dans la section suivante, une procédure permettant de relâcher cette dernière hypothèse et d'obtenir ainsi une majoration d'erreur raisonnable sous la seule hypothèse de noyau dominé.

PREUVE DU THÉORÈME 3.10.

La preuve de l'inégalité (3.22) s'obtient de manière analogue à l'inégalité (2.53) de la Proposition 2.35.

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n^N - \pi_n, \phi \rangle| | Y_{1:n}] &= \sup_{\|\phi\|=1} \mathbb{E}[|\langle \Psi_n \cdot S^N(Q_n \pi_{n-1}^N) - \Psi_n \cdot (Q_n \pi_{n-1}), \phi \rangle| | Y_{1:n}] \\ &\leq 2 \bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle S^N(Q_n \pi_{n-1}^N) - (Q_n \pi_{n-1}), \phi \rangle| | Y_{1:n}] \\ &\leq 2 \bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle S^N(Q_n \pi_{n-1}^N) - (Q_n \pi_{n-1}^N), \phi \rangle| | Y_{1:n}] \\ &\quad + 2 \bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle Q_n \pi_{n-1}^N - Q_n \pi_{n-1}, \phi \rangle| | Y_{1:n}] \\ &\leq 2 \frac{\bar{\gamma}_n}{\sqrt{N}} + 2 \bar{\gamma}_n \beta_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_{n-1}^N - \pi_{n-1}, \phi \rangle| | Y_{1:n}] . \end{aligned}$$

La preuve de l'inégalité (3.23) s'obtient comme celle de l'inégalité (2.51) de la Proposition 2.35. En dénormalisant suivant le Lemme 2.8 et en utilisant la loi des grands nombres,

nous avons

$$\begin{aligned}
\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n^N - \pi_n, \phi \rangle| \mid Y_{1:n}] &\leq \sum_{k=1}^n \sup_{\|\phi\|=1} \mathbb{E}[|\langle \bar{R}_{n:k+1}(\pi_k^N) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi_{k-1}^N), \phi \rangle| \mid Y_{1:n}] \\
&\leq 2 \sum_{k=1}^n \beta_{n:k+1} \frac{M_{n:k}}{m_{n:k}} \sup_{\|\phi\|=1} \mathbb{E}[|\langle S^N(Q_k \pi_{k-1}^N) - Q_k \pi_{k-1}^N, \phi \rangle| \mid Y_{1:k-1}] \\
&\leq \frac{2}{\sqrt{N}} \sum_{k=1}^n \beta_{n:k+1} \gamma_{n:k} .
\end{aligned}$$

On conclue ensuite par récurrence.

L'inégalité (3.24) s'obtient de la même manière, en utilisant l'inégalité de Marcinkiewicz–Zygmund (3.19) pour majorer les moments d'ordre p des erreurs locales,

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle S^N(Q_k \pi_{k-1}^N) - Q_k \pi_{k-1}^N, \phi \rangle|^p \mid Y_{1:k-1}] \leq \frac{B_p}{N^{\frac{p}{2}}} .$$

Enfin, l'inégalité (3.25) s'obtient par simple application de l'inégalité (2.52) de la Proposition 2.35, avec la majoration suivante des erreurs locales

$$\begin{aligned}
\delta_k &= \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_k^N - \bar{R}_k(\pi_{k-1}^N), \phi \rangle| \mid Y_{1:k}] \\
&\leq 2 \sup_{\|\phi\|=1} \mathbb{E}\left[\frac{|\langle S^N(Q_k \pi_{k-1}^N) - Q_k \pi_{k-1}^N, \phi \Psi_k \rangle|}{\langle Q_k \pi_{k-1}^N, \Psi_k \rangle} \mid Y_{1:k} \right] \\
&\leq 2 \frac{\gamma_k}{\sqrt{N}} .
\end{aligned} \tag{3.26}$$

□

3.2.2 Algorithme avec nombre aléatoire de particules

Dans la preuve du Théorème 3.10, dans l'inégalité (3.26) majorant l'erreur locale, nous aurions pu choisir $\langle S^N(Q_k \pi_{k-1}^N), \Psi_k \rangle$ comme dénominateur au lieu de $\langle Q_k \pi_{k-1}^N, \Psi_k \rangle$. Nous voyons ainsi que l'erreur locale commise est d'autant plus petite que la moyenne des valeurs de la vraisemblance sur les particules est grande. Par ailleurs, on observe communément lors des simulations la divergence de l'IPF, dans le cas contraire où la moyenne des valeurs de la vraisemblance sur les particules est petite. La moyenne empirique

$$\langle S^N(Q_k \pi_{k-1}^N), \Psi_k \rangle = \frac{1}{N} \sum_{i=1}^N \Psi(\xi_{k|k-1}^i)$$

apparaît ainsi déterminante pour le comportement du filtre particulaire. C'est pourquoi nous nous proposons de la contrôler, en faisant varier le nombre de particules. Pour assurer une erreur locale δ , uniforme dans le temps, indépendante de la vraisemblance, nous proposons d'utiliser, à chaque instant k , un nombre aléatoire de particules noté, N_k , tel que

$$N_k = \inf\{N \mid \delta^2 \sum_{i=1}^{N_k} \Psi_k(\xi_{k|k-1}^i) \geq M_k\} . \tag{3.27}$$

où Ψ_k est supposée bornée par M_k . Le lemme suivant montre que ce choix permet, en effet, de contrôler l'erreur locale, indépendamment de la fonction de vraisemblance.

Lemme 3.11. *Soit $\mu \in \mathcal{P}(E)$ une mesure de probabilité et Ψ une fonction positive définie sur E bornée par M telle que $\langle \mu, \Psi \rangle > 0$. A tout réel positif H , on associe le temps d'arrêt T_H défini par*

$$T_H = \inf\{N \mid \sum_{i=1}^N \Psi(\xi^i) \geq H\} \quad \text{avec} \quad (\xi^1, \dots, \xi^N) \text{ i.i.d. } \sim \mu .$$

Soit δ une constante positive, si $H(\delta) = M/\delta^2$ alors

$$\sup_{\|\phi\|=1} \mathbb{E}|\langle \Psi \cdot S^{T_H(\delta)}(\mu) - \Psi \cdot \mu, \phi \rangle| \leq 2\delta\sqrt{1+\delta^2} . \quad (3.28)$$

En outre, le nombre moyen de particules requis pour obtenir une approximation de précision δ est $\mathbb{E}[T_{H(\delta)}]$, avec

$$\frac{\gamma}{\delta^2} \leq \mathbb{E}[T_{H(\delta)}] \leq \gamma(1 + \frac{1}{\delta^2}) , \quad (3.29)$$

où $\gamma = M/\langle \mu, \Psi \rangle$.

Ce lemme propose, en fait, une méthode d'approximation de la mesure corrigée $\Psi \cdot \mu$ à mi-chemin entre l'échantillonnage pondéré classique (à nombre de v.a. simulées fixe) et la méthode d'acceptation / rejet, toutes deux présentées, dans la Section 1.2. Le nombre de v.a. simulées suivant μ est ici aléatoire, comme pour la méthode d'acceptation / rejet. Mais, comme pour l'échantillonnage pondéré classique, toutes les v.a. simulées sont pondérées et apparaissent dans l'approximation. Pour fournir une approximation de même précision δ que la méthode d'acceptation / rejet, la méthode d'échantillonnage pondéré, avec nombre aléatoire de v.a. simulées, utilise en moyenne un nombre équivalent de simulations, $\gamma(1 + 1/\delta^2)$. Par contre, pour une même précision δ , l'échantillonnage pondéré classique requiert, en moyenne, plus de $4\gamma/(1+\delta^2)$ fois plus de simulations. Cette méthode permet donc en moyenne de réduire considérablement le coût de calcul de l'algorithme.

PREUVE DU LEMME 3.11. On vérifie d'abord que pour toute constante positive H , le temps d'arrêt T_H est presque sûrement fini puisque

$$\frac{1}{N} \sum_{i=1}^N \Psi(\xi^i) \xrightarrow[N \rightarrow \infty]{} \langle \mu, \Psi \rangle > 0 \quad \mathbb{P}\text{-p.s.} .$$

Soit ϕ , une fonction test mesurable bornée sur E , on note R_N , le rapport défini par

$$R_N = \frac{\langle S^N(\mu) - \mu, \Psi\phi \rangle}{\langle S^N(\mu), \Psi \rangle} ,$$

où l'on rappelle que

$$S^N(\mu) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi^i} \quad \text{avec} \quad (\xi^1, \dots, \xi^N) \text{ i.i.d. } \sim \mu .$$

Par dénormalisation suivant l'inégalité (2.6) de la Proposition 2.5,

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle \Psi \cdot S^N(\mu) - \Psi \cdot \mu, \phi \rangle| \leq 2 \sup_{\|\phi\|=1} R_N ,$$

On pose

$$R_N = \frac{S_N}{U_N} ,$$

avec

$$S_N = \sum_{i=1}^N [\Psi(\xi^i) \phi(\xi^i) - \langle \mu, \Psi \phi \rangle] \quad \text{et} \quad U_N = \sum_{i=1}^N \Psi(\xi^i) .$$

La suite $(S_N)_{N \geq 1}$ est une martingale. On écrit la décomposition de Doob de la sous-martingale $(S_N^2)_{N \geq 1}$: $S_N^2 = V_N + S'_N$, où $(S'_N)_{N \geq 1}$ est une martingale et

$$V_N = \sum_{i=1}^N \mathbb{E}[(\Delta S_i)^2 | \mathcal{F}_{i-1}] = N [\langle \mu, \Psi^2 \phi^2 \rangle - \langle \mu, \Psi \phi \rangle^2] \leq N \|\phi\|^2 M \langle \mu, \Psi \rangle ,$$

où $\mathcal{F}_i = \sigma(\xi^1, \dots, \xi^i)$. Par définition du temps d'arrêt T_H , on a

$$H \leq U_{T_H} = U_{T_H-1} + \Psi(\xi^{T_H}) \leq H + M , \quad (3.30)$$

ce qui entraîne

$$|R_{T_H}| \leq \frac{1}{H} |S_{T_H}| .$$

D'après Cauchy-Schwartz,

$$\mathbb{E}|R_{T_H}| \leq \frac{1}{H} \mathbb{E}|S_{T_H}| \leq \frac{1}{H} (\mathbb{E}[S_{T_H}^2])^{1/2} = \frac{1}{H} (\mathbb{E}[V_{T_H}] + \mathbb{E}[S'_{T_H}])^{1/2} .$$

D'après le théorème d'arrêt,

$$\mathbb{E}[S'_{T_H}] = 0 , \quad \text{et} \quad \mathbb{E}[V_{T_H}] \leq \|\phi\|^2 M \langle \mu, \Psi \rangle \mathbb{E}[T_H] .$$

En appliquant l'identité de Wald, on obtient

$$\langle \mu, \Psi \rangle \mathbb{E}[T_H] = \mathbb{E}[U_{T_H}] \leq H + M , \quad (3.31)$$

ce qui entraîne

$$\mathbb{E}|R_{T_H}| \leq \frac{1}{H} \|\phi\| \sqrt{M} \sqrt{H + M} . \quad (3.32)$$

En prenant $H = M/\delta^2$, on conclut que

$$\sup_{\|\phi\|=1} \mathbb{E}|R_{T_{M/\delta^2}}| \leq \delta \sqrt{1 + \delta^2} .$$

D'après les inégalités (3.30) et (3.31), on a

$$\frac{H}{\langle \mu, \Psi \rangle} \leq \mathbb{E}[T_H] \leq \frac{H + M}{\langle \mu, \Psi \rangle} .$$

Pour obtenir une approximation de précision δ , on choisit $H = M/\delta^2$ ce qui requiert, en moyenne, $\mathbb{E}[T_{M/\delta^2}]$ particules, avec

$$\frac{\gamma}{\delta^2} \leq \mathbb{E}[T_{M/\delta^2}] \leq \gamma(1 + \frac{1}{\delta^2}) .$$

□

On peut maintenant énoncer le corollaire suivant.

Corollaire 3.12. *Si pour tout entier $k \geq 1$, l'Hypothèse $[\mathbf{Q_d}]$ est vérifiée et si le nombre de particules N_k , à l'instant k , est défini comme le temps d'arrêt (3.27), pour une constante positive donnée δ alors l'inégalité suivante est vérifiée,*

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi_n^{N_n}, \phi \rangle| \mid Y_{1:n}] \leq 2 \left[1 + 2 \sum_{k=2}^n \beta_{n:k+1} \bar{\gamma}_{n:k} c_k \right] \delta \sqrt{1 + \delta^2} . \quad (3.33)$$

Le nouveau schéma de rééchantillonnage avec nombre aléatoire de particules ne permet d'éliminer l'Hypothèse $[\mathbf{Q\Psi}]$ que dans le cadre de noyaux de transition dominés. La variation du nombre de particules n'influe, en effet, que sur le coefficient γ_k intervenant dans le terme d'erreur locale et non sur les autres coefficients de transport d'erreur $(\gamma_n, \dots, \gamma_{k+1})$.

PREUVE DU COROLLAIRE 3.12. Il suffit de reprendre la preuve de l'inégalité (3.25) en majorant, cette fois, l'erreur locale comme suit

$$\begin{aligned} \delta_k &= \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_k^{N_k} - \bar{R}_k(\pi_{k-1}^{N_{k-1}}), \phi \rangle| \mid Y_{1:k}] \\ &= \sup_{\|\phi\|=1} \mathbb{E}[|\langle \Psi_k \cdot S^{N_k}(Q_k \pi_{k-1}^{N_{k-1}}) - \Psi_k \cdot Q_k \pi_{k-1}^{N_{k-1}}, \phi \rangle| \mid Y_{1:k}] . \end{aligned}$$

Comme Ψ_k est supposée toujours strictement positive, $\langle Q_k \pi_{k-1}^{N_{k-1}}, \Psi_k \rangle > 0$. Nous pouvons donc appliquer le Lemme 3.11 avec $\Psi = \Psi_k$, $\mu = Q_k \pi_{k-1}^{N_{k-1}}$, et $\mathcal{F} = \sigma(Y_{1:k}, \pi_{k-1}^{N_{k-1}})$. Ce qui entraîne

$$\delta_k \leq \delta \sqrt{1 + \delta^2} .$$

□

On peut ici appliquer la Proposition 2.41 pour construire une approximation uniforme en temps du filtre optimal sans hypothèse de mélange. Considérons de nouveau le système état / observation (2.58) décrit dans la Section 2.3. On note toujours π_n^Δ le processus à valeurs mesures tel que

$$\pi_n^\Delta = R_{n:1}^\Delta \pi_0 ,$$

où

$$R_k^\Delta(x, dx') = \mathbf{1}_{C_{k-1}}(x) Q(x, dx') \Psi_k(x') \mathbf{1}_{C_k}(x') + \mathbf{1}_{C_{k-1}^c}(x) \Psi_k(x') \mathbf{1}_{C_k}(x') \lambda_k(dx') ,$$

avec C_k le compact de $\mathbb{R}^d$ de diamètre Δ_k , défini par

$$C_k = \{x \mid |Y_k - h(x)| \leq \Delta\} ,$$

et λ_k la mesure de mélange de $\mathbf{1}_{C_k-1}(x) Q(x, dx')$. On construit une approximation particulière du processus $(\pi_n^\Delta)_{n \geq 0}$, notée $(\pi_n^{\Delta N_n})_{n \geq 0}$. $(\pi_n^{\Delta N_n})_{n \geq 0}$ est simplement obtenu par application de l'algorithme de l'IPF à nombre aléatoire de particules sur $(\pi_n^\Delta)_{n \geq 0}$. Le filtre $(\pi_n^{\Delta N_n})_{n \geq 0}$ se calcule récursivement exactement comme $\pi_n^{\Delta N_n}$ sauf que les fonctions de vraisemblance Ψ_k sont remplacées par les fonctions à support compact $\Psi_k \mathbf{1}_{C_k}$. Concrètement, la différence réside dans le fait que dans le calcul de $\pi_n^{\Delta N_n}$ les particules peu vraisemblables (extérieures à C_k) sont systématiquement éliminées. D'après le corollaire suivant, $(\pi_n^{\Delta N_n})_{n \geq 0}$ constitue une approximation uniforme en temps du filtre optimal.

Corollaire 3.13. *Soit un réel $\Delta > 0$. On considère le système état / observation (2.58). Si pour tout entier $k \geq 1$, le nombre de particules N_k , à l'instant k , est défini comme le temps d'arrêt (3.27) associé à la constante positive $\delta = \varepsilon^2(2b\Delta)\alpha(\Delta)$ et si de plus, la mesure de mélange λ_k de l'opérateur $\mathbf{1}_{C_k-1}(x) Q(x, dx')$ est telle que $\lambda_k(E) \leq 1$, alors pour tout entier $n \geq 1$,*

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle \pi_n - \pi_n^{\Delta N_n}, \phi \rangle| \leq 50 \frac{\alpha(\Delta)}{\varepsilon^4(2b\Delta)}. \quad (3.34)$$

Dans le cas où

$$\lim_{\Delta \rightarrow \infty} \frac{\alpha(\Delta)}{\varepsilon^4(2b\Delta)} = 0,$$

nous concluons que $\pi_n^{\Delta N_n}$ constitue une approximation uniforme en temps de π_n .

Ce corollaire suggère une démarche en deux temps pour l'approximation du filtre optimal. D'abord, rechercher un filtre exponentiellement stable approchant le filtre optimal de façon uniforme dans le temps. Puis construire une approximation particulière à partir de ce filtre intermédiaire. On obtient, au final, une approximation du filtre optimal uniforme dans le temps, sans que le signal soit nécessairement ergodique.

À titre d'illustration, on peut reprendre l'exemple du système état / observation (2.60) présenté dans la Section 2.3. Si on suppose $\beta = 1 - 8abs/\sigma > 0$, on obtient la majoration d'erreur,

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle \pi_n - \pi_n^{\Delta N_n}, \phi \rangle| \leq 400 \sigma^4 \exp(-\beta \frac{\Delta}{s}).$$

Ainsi, si $\beta > 0$ i.e. si la puissance σ du bruit de dynamique est suffisamment forte par rapport à la puissance s du bruit d'observation, on sait construire une approximation uniforme en temps du filtre optimal.

PREUVE DU COROLLAIRE 3.13. L'erreur est décomposée en deux termes,

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle \pi_n - \pi_n^{\Delta N_n}, \phi \rangle| \leq \mathbb{E} \|\pi_n - \pi_n^\Delta\| + \sup_{\|\phi\|=1} \mathbb{E} |\langle \pi_n^\Delta - \pi_n^{\Delta N_n}, \phi \rangle|.$$

Le premier terme du membre de droite est majoré directement par la Proposition 2.41. Le second terme est majoré par le Corollaire 2.34, sachant que l'opérateur R_k^Δ est mélangeant. On a ainsi les majorations

$$\mathbb{E} \|\pi_n^\Delta - \pi_n\| \leq 6 \left(1 + \frac{2}{\varepsilon^4(2b\Delta) \log 3}\right) \alpha(\Delta), \quad (3.35)$$

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle \pi_n^\Delta - \pi_n^{\Delta N_n}, \phi \rangle| \leq \left(1 + \frac{2}{\varepsilon^2(2b\Delta)} + \frac{4}{\varepsilon^6(2b\Delta) \log 3}\right) \delta(\Delta), \quad (3.36)$$

où $\delta(\Delta)$ est un réel positif tel que pour tout entier $k \geq 1$,

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \bar{R}_k^\Delta(\pi_{k-1}^{\Delta N_{k-1}}) - \pi_k^{\Delta N_k}, \phi \rangle|] \leq \delta(\Delta) .$$

D'après le mélange de R_k^Δ , on a

$$0 < \varepsilon^2(2b\Delta)g(\Delta)\mathbf{1}_{C_{k-1}}Q(x, C_k) \leq \varepsilon(2b\Delta)\langle \lambda_k, \Psi_k \mathbf{1}_{C_k} \rangle \leq \langle Q\pi_{k-1}^{\Delta N_{k-1}}, \Psi_k \mathbf{1}_{C_k} \rangle .$$

On peut alors appliquer le Lemme 3.11, ce qui entraîne la majoration suivante de l'erreur locale moyenne, $\delta(\Delta)$,

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[|\langle \bar{R}_k^\Delta(\pi_{k-1}^{\Delta N_{k-1}}) - \pi_k^{\Delta N_k}, \phi \rangle|] &= \sup_{\|\phi\|=1} \mathbb{E}[|\langle \Psi_k \mathbf{1}_{C_k} \cdot (Q\pi_{k-1}^{\Delta N_{k-1}}) - \Psi_k \mathbf{1}_{C_k} \cdot S^{N_k}(Q\pi_{k-1}^{\Delta N_{k-1}}), \phi \rangle|] \\ &\leq 2\varepsilon^2(2b\Delta)\alpha(\Delta)\sqrt{1 + (\varepsilon^2(2b\Delta)\alpha(\Delta))^2} . \end{aligned}$$

Le reste de la preuve est simplement calculatoire. □

3.2.3 Cas du noyau mélangeant

Dans cette sous-section, nous présentons des résultats de convergence uniforme en temps du filtre particulaire avec interaction. Ces résultats sont basés sur l'étude de stabilité utilisant la métrique de Hilbert développée au Chapitre 2. Ils ne sont valables que sous l'hypothèse forte de mélange, mais permettent néanmoins de mieux cerner le comportement de l'approximation particulaire en temps long.

Théorème 3.14. *Si pour tout entier $k \geq 1$, l'Hypothèse [R] est vérifiée, alors*

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi_n^N, \phi \rangle| | Y_{1:n}] \leq \delta_n + 2 \frac{\delta_{n-1}}{\varepsilon_n^2} + \frac{4}{\log 3} \sum_{k=1}^{n-2} \tau_{n:k+3} \frac{\delta_k}{\varepsilon_{k+2}^2 \varepsilon_{k+1}^2} ,$$

avec $\delta_k \leq \frac{2}{\sqrt{N}} \gamma_k$.

On rappelle que lorsque R_k est mélangeant $\gamma_k \leq \bar{\gamma}_k / \varepsilon_k^2 < \infty$, en effet

$$\varepsilon_k^2 \langle Q_k \pi_{k|k-1}, \Psi_k \rangle \leq \langle Q_k(x, \cdot), \Psi_k \rangle ,$$

pour tout $x \in E$.

Corollaire 3.15. *Si pour tout entier $k \geq 1$, l'Hypothèse [R] est vérifiée, avec $\varepsilon_k \geq \varepsilon > 0$, et $\mathbb{E}[\gamma_k] \leq \frac{1}{2}\gamma$ alors la convergence est uniforme en temps, avec une vitesse en $1/\sqrt{N}$, i.e.*

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi_n^N, \phi \rangle|] \leq \frac{1}{\sqrt{N}} \left(1 + \frac{2}{\varepsilon^2} + \frac{4}{\varepsilon^6 \log 3} \right) \gamma .$$

Des résultats comparables ont été obtenus par Del Moral et Guionnet [33]. Cependant, les deux approches sont différentes et conduisent à des énoncés proches mais distincts. Nous avons utilisé les résultats du Chapitre 2, basés sur les techniques hilbertiennes et faisant apparaître le taux de contraction de Birkhoff de l'opérateur intégrale R_k tandis que dans [33], les auteurs utilisent plutôt le coefficient d'ergodicité de Dobrushin d'un semi-groupe associé au filtre optimal. De plus, le cadre de notre résultat est lui aussi différent puisque d'un côté, notre hypothèse de mélange est un cas particulier de stabilité exponentiel du filtre et de l'autre côté, l'hypothèse de vraisemblance bornée inférieurement posée dans [33] est dans notre cas relâchée. Enfin, la vitesse de convergence que nous obtenons est plus précise (en $1/\sqrt{N}$ à comparer à $1/N^{\frac{\alpha}{2}}$ avec $\alpha \leq 1$ obtenue dans [33]).

Remarque 3.16. Ce résultat de convergence faible peut être utilisé pour prouver la convergence en variation totale du filtre particulaire de prédiction, en utilisant la régularité des noyaux de transition Q_k . Au lieu de considérer le filtre optimal, $\pi_n(dx) = \mathbb{P}[X_n \in dx \mid Y_{1:n}]$, nous considérons le filtre de prédiction, $\pi_{n|n-1}(dx) = \mathbb{P}[X_n \in dx \mid Y_{1:n-1}]$, et nous voulons majorer l'erreur entre $\pi_{n|n-1} = Q_n \pi_{n-1}$ et $Q_n \pi_{n-1}^N$. Sous les hypothèses du Corollaire 3.15, le Lemme 2.31 implique directement,

$$\mathbb{E} \|\pi_{n|n-1} - Q_n \pi_{n-1}^N\| \leq \frac{1}{\sqrt{\varepsilon N}} \left(1 + \frac{2}{\varepsilon^2} + \frac{4}{\varepsilon^6 \log 3}\right) \frac{\gamma}{\varepsilon}. \quad (3.37)$$

PREUVE DU THÉORÈME 3.14. Il nous suffit de majorer l'erreur locale au sens faible, puis d'appliquer le Théorème 2.33. Considérons l'erreur faible entre π_k^N et $\bar{R}_k(\pi_{k-1}^N)$ pour une fonction ϕ mesurable bornée. D'après le Lemme 2.8, nous avons

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E} [|\langle \bar{R}_k(\pi_{k-1}^N) - \pi_k^N, \phi \rangle| \mid Y_{1:n}] &= \sup_{\|\phi\|=1} \mathbb{E} [|\langle \bar{R}_k(\pi_{k-1}^N) - \pi_k^N, \phi \rangle| \mid Y_{1:k}] \\ &= \sup_{\|\phi\|=1} \mathbb{E} [|\langle \Psi_k \cdot (Q_k \pi_{k-1}^N) - \Psi_k \cdot (S^N(Q_k \pi_{k-1}^N)), \phi \rangle| \mid Y_{1:k}] \\ &\leq 2 \sup_{\|\phi\|=1} \mathbb{E} \left[\frac{|\langle Q_k \pi_{k-1}^N - S^N(Q_k \pi_{k-1}^N), \Psi_k \phi \rangle|}{\langle Q_k \pi_{k-1}^N, \Psi_k \rangle} \mid Y_{1:k} \right] \end{aligned} \quad (3.38)$$

Par ailleurs, d'après la loi des grands nombres,

$$\mathbb{E} [|\langle Q_k \pi_{k-1}^N - S^N(Q_k \pi_{k-1}^N), \Psi_k \phi \rangle| \mid Y_{1:k} \vee \pi_{k-1}^N] \leq \frac{1}{\sqrt{N}} M_k \|\phi\|,$$

ce qui termine la preuve. $\square$

Si l'on désire obtenir une majoration de l'erreur indépendante de la vraisemblance, il suffit d'utiliser un nombre de particules variable comme au Corollaire 3.12. Nous obtenons alors le corollaire suivant.

Corollaire 3.17. *Si pour tout entier $k \geq 1$, l'Hypothèse [R] est vérifiée, avec $\varepsilon_k \geq \varepsilon > 0$, et si le nombre de particules N_k à l'instant k satisfait la condition (3.27) pour une constante positive donnée, δ , alors l'inégalité suivante est vérifiée,*

$$\sup_{\|\phi\|=1} \mathbb{E} [|\langle \pi_n - \pi_n^{N_n}, \phi \rangle| \mid Y_{1:n}] \leq 2 \left(1 + \frac{2}{\varepsilon^2} + \frac{4}{\varepsilon^6 \log 3}\right) \delta \sqrt{1 + \delta^2}.$$

Exactement comme dans la preuve du Corollaire 3.12, ce résultat s'obtient par majoration de l'erreur locale grâce au Lemme 3.11 :

$$\delta_k = \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_k^{N_k} - \bar{R}_k(\pi_{k-1}^{N_{k-1}}), \phi \rangle| \mid Y_{1:k}] \leq 2\delta \sqrt{1 + \delta^2}.$$

3.2.4 Points faibles et variantes

Dégénérescence des particules

Bien que l'IPF converge uniformément en temps sous la condition de mélange, on observe qu'en dehors de cette hypothèse son comportement est très instable. En effet, après chaque rééchantillonnage, on obtient un nouveau système, dans lequel plusieurs particules peuvent avoir la même position. Dans le cas particulier d'un bruit d'état faible ou nul, la diversité du système de particules s'appauvrit dangereusement, du fait de la succession des étapes de rééchantillonnage, si bien que le système de particules finit par se concentrer en un seul point de l'espace. L'algorithme perd alors toute capacité d'exploration de l'espace. Ce phénomène appelé *dégénérescence des particules* provoque la divergence du filtre. En fait, nous allons voir que l'on rencontre ce comportement instable de l'algorithme non seulement dans le cas critique du faible bruit d'état, mais aussi dans le cas du faible bruit d'observation.

Faible bruit d'état La Figure 3.2.4 représente l'évolution d'un système de quatre particules entre trois instants d'observation, suivant l'algorithme de l'IPF. Au temps $T = 0$, une première




FIG. 3.1: *Dégénérescence des particules : faible bruit d'état*

observation est prise en compte. Chaque particule est pondérée suivant sa vraisemblance puis sélectionnée ou abandonnée. Ensuite, les particules sélectionnées suivent une évolution suivant le noyau de transition. A chaque instant d'observation suivant, on réitère la même procédure. On observe, sur la figure, qu'au temps $T = 3$, toutes les particules du système sont issues de la même particule initiale. On comprend donc que si l'étape d'évolution est déterministe ou faiblement bruitée, les particules finissent par se concentrer en un seul point ou dans une région très restreinte de l'espace. A partir de là, l'algorithme a très peu de chances de retrouver l'état, si celui-ci est à l'extérieur de la petite zone couverte par les particules. On voit donc

d'une part, que la capacité exploratoire de l'algorithme est limitée par le système de particules initial, mais aussi qu'elle ne peut que s'appauvrir avec les rééchantillonnages successifs.

Faible bruit d'observation Le second cas critique provoquant la dégénérescence des particules correspond au cas du faible bruit d'observation, ou plus généralement, à un coefficient de transport $\bar{\gamma}_n$ élevé. La Figure 3.2.4 représente la fonction de vraisemblance associée à un bruit d'observation V_n additif et gaussien de variance faible, lorsque l'état est totalement observé i.e.,

$$Y_n = X_n + V_n .$$

La précision de l'observation induit une vraisemblance très localisée dans l'espace d'état, si




FIG. 3.2: *Dégénérescence des particules : faible bruit d'observation*

bien que la vraisemblance se concentre dans une petite zone dépourvue de particules. L'exploration de l'espace d'état se limitant au support des particules, il est, dans ce cas, impossible d'exploiter efficacement l'information apportée par l'observation. A l'étape de rééchantillonnage seules seront sélectionnées les quelques particules les plus vraisemblables. Le nouveau système de particules sera ainsi composé de plusieurs copies des rares particules choisies. On voit ainsi que d'une part, la diversité des particules est mise en danger et que d'autre part, l'observation est mal exploitée (absence de particules dans la zone de forte vraisemblance).

Ces deux cas extrêmes montrent que la nature discrète de l'approximation particulaire limite largement la capacité d'exploration de l'algorithme.

Variantes

D'autres versions de filtres particulaires avec interaction ont été proposées dans la littérature. Nous en présentons ici brièvement trois grande classes.

Echantillonnage périodique Pour limiter les effets néfastes du rééchantillonnage, une idée est de ne pas le réaliser à chaque pas de l'algorithme. Entre chaque rééchantillonnage les poids se cumulent alors comme dans le filtre de Monte Carlo pondéré. Différentes méthodes ont été proposées pour choisir le moment de la redistribution. Nous en présentons, ici, trois très succinctement, mais il existe certainement d'autres techniques proposées dans la littérature.

Le schéma d'interactions périodiques introduit par Del Moral et Guionnet [33] est basé sur l'étude du comportement en temps long du filtre particulaire. La période d'interaction est fonction des propriétés de stabilité du filtre optimal et du nombre de particules. En un sens, l'algorithme attend que l'information accumulée soit suffisamment riche pour l'exploiter au cours de l'interaction (échantillonnage). Les résultats classiques de convergence de l'IPF se généralisent facilement à cette version de méthode particulaire.

Kong et Liu [64] proposent un choix de l'instant de rééchantillonnage basé sur un critère lié à la variance des pondérations. Partant de l'algorithme du filtre de Monte Carlo pondéré, l'idée est d'y introduire des étapes de rééchantillonnage, à des instants choisis, de sorte à éviter la dégénérescence des pondérations. Ils introduisent le paramètre

$$\tilde{N}_k = \frac{1}{\sum_{i=1}^N \omega_k^i{}^2} ,$$

qui est une approximation du nombre de particules issues directement de la loi conditionnelle π_k suffisant pour fournir une estimation empirique de π_k de précision équivalente à celle fournie par le filtre particulaire. $\tilde{N}_k$ est un indicateur du phénomène de dégénérescence des pondérations. Typiquement, si le paramètre $\tilde{N}_k$ est faible, la variance des poids des particules est élevée et la précision du filtre particulaire est mauvaise. L'utilisateur fixe alors une valeur minimale de $\tilde{N}_k$, notée, $\tilde{N}_{\text{lim}}$, directement liée à la précision minimale souhaitée. La procédure de rééchantillonnage est exécutée, à chaque fois que $\tilde{N}_{\text{lim}}$ est atteint.

Un autre indicateur de l'instant de rééchantillonnage est proposé par Pham [90]. Il est basé sur un critère d'entropie mesurant la dispersion des pondérations,

$$k(\omega_k^1, \dots, \omega_k^N) = \log(N) + \sum_{i=1}^N \omega_k^i \log \omega_k^i .$$

Cette quantité est toujours positive et n'est nulle que si tous les poids sont égaux à $1/N$. L'étape de rééchantillonnage n'est effectuée que si l'entropie $k(\omega_k^1, \dots, \omega_k^N)$ dépasse un seuil fixé par l'utilisateur.

Évolutions conditionnelles Pour mieux exploiter l'observation dans l'exploration de l'espace d'état par les particules, l'idée des évolutions conditionnelles aux observations présentée dans la Sous-section 3.1.1 pour le filtre de Monte Carlo pondéré peut être appliquée à l'IPF. Cette idée est présentée dans [38, pp. 60–63]. L'étape d'évolution “aveugle”, suivant le noyau de transition Q_n , est remplacée par une évolution “guidée”, suivant un noyau Q'_n dépendant de l'observation courante. Il suffit de noter que, pour tout $n \geq 1$,

$$\pi_n = \Psi'_n \cdot (Q'_n \pi_{n-1}) ,$$

avec

$$\Psi'_n(x) = \int_E \Psi_n(x') Q_n(x, dx') = \langle Q_n(x, \cdot), \Psi_n \rangle , \quad \text{et} \quad Q'_n(x, dx') = \frac{\Psi_n(x')}{\Psi'_n(x)} Q_n(x, dx')(dx') ,$$

On construit alors le filtre particulaire $(\pi_n'^N)_{n \geq 0}$, suivant le schéma,

$$\pi_{n-1}'^N \xrightarrow[\substack{\text{Prédiction} \\ \text{échantillonnée}}]{(1)} \pi_{n|n-1}'^N = S^N(Q'_n \pi_{n-1}'^N) \xrightarrow[\text{Correction}]{(2)} \pi_n'^N = \Psi'_n \cdot \pi_{n|n-1}'^N .$$

La simulation de $Q'_n(x, \cdot)$ et l'évaluation de Ψ'_n sont réalisées de manière approchée, par échantillonnage pondéré, comme cela a été décrit à la Section 3.1.1. Malheureusement, ces approximations réalisées à chaque instant d'observation sont relativement coûteuses en temps de calcul et rendent cette idée peu attrayante.

Filtres particuliers avec branchement Etant donnée l'approximation particulière à l'instant $n - 1$,

$$\pi_{n-1}^N = \sum_{i=1}^N \omega_{n-1}^i \delta_{\xi_{n-1|n-2}^i} ,$$

l'étape d'interaction classique de l'IPF consistait à générer un vecteur aléatoire multinomial, $(N_n^1, \dots, N_n^N)$, représentant le nombre d'occurrences de chaque particule dans le nouveau système. D'autres schémas de selection ont été proposés produisant un vecteur aléatoire $(N_n^1, \dots, N_n^N)$ dont les composantes N_n^i sont, cette fois, mutuellement indépendantes conditionnellement aux aléas passés, mais dont la somme $N_n = \sum_{i=1}^{N_{n-1}} N_n^i$ n'est plus constante mais aléatoire. Ces techniques de selection appelées branchement sont essentiellement motivées par leur apport en termes de temps de calcul ou de minimisation de l'erreur quadratique entre la mesure empirique pondérée,

$$\pi_{n-1}^{N_{n-1}} = \sum_{i=1}^{N_{n-1}} \omega_{n-1}^i \delta_{\xi_{n-1|n-2}^i} ,$$

et la mesure empirique obtenue après branchement,

$$\frac{1}{N_{n-1}} \sum_{i=1}^{N_{n-1}} N_n^i \delta_{\xi_{n-1|n-2}^i} .$$

Dans les filtres particuliers avec branchement, l'étape d'interaction est simplement remplacée par une étape de branchement, les autres étapes de l'algorithme de l'IPF restant inchangées.

On peut, à titre d'exemple, citer la méthode de branchement selon la loi de Bernoulli introduite par Crisan et Lyons [24]. Les nombres de descendants $(N_n^1, \dots, N_n^N)$ sont des variables aléatoires, conditionnellement indépendantes, suivant chacune la loi de Bernoulli,

$$\mathbb{P}[N_n^i = [N_{n-1} \omega_{n-1}^i]] = 1 - (N_{n-1} \omega_{n-1}^i - [N_{n-1} \omega_{n-1}^i]) ,$$

$$\mathbb{P}[N_n^i = [N_{n-1} \omega_{n-1}^i] + 1] = N_{n-1} \omega_{n-1}^i - [N_{n-1} \omega_{n-1}^i] ,$$

où $[a]$ désigne la partie entière du réel a .

Les autres techniques de branchement sont répertoriées dans [38, pp. 64–69] et étudiées en détails dans [23]. Il faut néanmoins noter que les algorithmes particuliers avec branchement ont quelques inconvénients. D'une part, le nombre de particules étant aléatoire, il peut dégénérer et atteindre la valeur critique zéro. D'autre part, ces méthodes sont, en général, plus difficiles à analyser. En particulier, le résultat de convergence uniforme obtenu pour le filtre particulier avec interaction n'est a priori pas valable pour les filtres particuliers avec branchement.

Conclusion du Chapitre 3

Dans ce chapitre nous avons considéré les deux types d'approximations particulières initialement proposés pour le filtrage : le filtre de Monte Carlo pondéré et le filtre particulaire avec interaction.

L'idée d'introduire de l'oubli dans le filtre optimal suggérée dans la conclusion du Chapitre 2 a été utilisée pour stabiliser le filtre de Monte Carlo pondéré. On a vu grâce au résultat de Del Moral [31] que sous certaines conditions d'ergodicité du signal, l'oubli brutal des observations passées permettait un contrôle uniforme en temps des erreurs commises par le filtre de Monte Carlo pondéré. A la suite de ce résultat, nous avons montré que sous des conditions de mélange, l'oubli progressif des observations passées conduisait aussi à une approximation uniforme en temps. Dans ces deux cas, l'oubli a été introduit au travers des observations. Toujours dans l'optique de stabiliser l'approximation particulaire dans le temps, on peut aussi imaginer introduire de l'oubli en perturbant la dynamique du signal. Cette idée sera en un sens exploitée au Chapitre 5 pour le développement des filtres particuliers régularisés.

Le bref rappel de quelques résultats de convergence du filtre particulaire avec interaction a mis en évidence la force des hypothèses requises pour un bon contrôle de l'erreur. Ces hypothèses sont nécessaires pour compenser la maigre information disponible sur l'erreur locale qui n'est contrôlable qu'au sens faible. Nous avons en particulier montré que lorsque le noyau est dominé, l'erreur globale est mieux contrôlée. On a vu en effet, au Chapitre 2 que ce type de perturbations locales se propageait mal dans l'évolution du filtre. Pour améliorer les performances de cet algorithme nous avons proposé d'utiliser un nombre aléatoire de particules s'adaptant automatiquement à la précision souhaitée. L'intérêt de cette procédure est qu'elle permet d'obtenir une erreur locale donnée pour un temps de calcul sensiblement inférieur à la méthode classique. Cependant, cette modification n'est pas suffisante pour assurer un bon comportement du filtre en temps long. Seuls des hypothèses supplémentaires sur la régularité des transitions permet d'obtenir des majorations satisfaisantes (noyau dominé). Néanmoins, l'IPF avec nombre aléatoire de particules, permet dans certains cas où les transitions sont pseudo-mélangeantes de construire une approximation uniforme en temps du filtre optimal. Le filtre approché proposé utilise des fonctions de vraisemblance modifiées à support compact suivant la Proposition 2.41 du Chapitre 2.

Dans le cas extrême de transitions mélangeantes, nous avons montré la convergence uniforme de l'IPF par simple application des résultats de stabilité du Chapitre 2, améliorant ainsi la vitesse de convergence obtenue par Del Moral et Guionnet [33].

Plusieurs variantes de l'IPF ont été proposées dans la littérature pour améliorer le comportement de l'algorithme dans des contextes plus réalistes. Malheureusement, toutes ces procédures ne sont, en général, pas suffisantes pour éviter le phénomène de dégénérescence des particules. Pour assurer la diversité du système de particules au cours du temps, des heuristiques consistant à bruite artificiellement les particules [48] ont été proposées. Mais aucune méthode systématique n'a été développée. En nous basant sur la théorie de l'estimation de densité par noyaux, nous développons au Chapitre 4 une procédure formalisant, en un sens, l'idée du bruitage artificiel. Les filtres particuliers résultant sont appelés filtres particuliers régularisés. Ils sont présentés et analysés dans le Chapitre 5.

Chapitre 4

Régularisation par estimation de densité par noyaux

On a vu que la nature discrète de l'approximation fournie par l'IPF peut provoquer des résultats très mauvais, dans certains cas de bruits d'état ou d'observation faible. Dans ce chapitre, nous décrivons deux méthodes permettant d'approcher par une mesure à densité une mesure de probabilité corrigée assez régulière lorsqu'on ne connaît qu'une approximation empirique discrète de la mesure avant correction. Ces méthodes permettront de développer les filtres particuliers régularisés, dans le chapitre suivant. Considérons dans un premier temps une version particulière de ce problème. Etant donné un échantillon $(\xi^1, \dots, \xi^N)$ issu d'une probabilité de densité f sur E , nous cherchons une estimation $f^{N,h}$ de f ne dépendant que de l'échantillon (h étant un paramètre à déterminer). L'estimation non paramétrique de densité par noyaux propose une solution à ce problème. Cette technique classiquement utilisée en analyse de données est aujourd'hui presque aussi répandue que l'histogramme. L'idée est d'étendre l'influence de chaque point de l'échantillon à une petite zone environnante, en plaçant un noyau ("densité lisse") centré en chacun des points. L'approximation obtenue prend alors la forme d'un mélange de noyaux.

Ce domaine de recherche est en plein essor. Nous ne citons pas ici, la multitude des travaux réalisés. Les résultats principaux concernant l'étude au sens L^1 pour le cas monodimensionnel sont développés dans les ouvrages de base de Devroye et Györfi [45] (1985) et Devroye [43] (1987). L'article d'Holmström et Klemelä [53] (1992) étend ces résultats au cas multidimensionnel. Pour ce qui concerne les travaux réalisés pour l'étude au sens L^2 , ils sont rapportés pour l'essentiel, dans l'ouvrage de Silverman [99] (1986).

Dans la première section de ce chapitre, nous décrivons le cadre de notre étude. Le problème considéré est une extension de celui rencontré en estimation classique de densité. On cherche ici à estimer une densité corrigée $\nu = \Psi \cdot \mu$ lorsque sont connus la fonction positive Ψ et un échantillon issu de μ . La deuxième section est consacrée à l'analyse des erreurs des estimées. Nous présentons des résultats classiques de la théorie de l'estimation de densité par noyaux. Ces résultats sont étendus au cadre plus général de notre étude, pour l'estimation d'une densité corrigée. De plus, nous développons de nouvelles estimations d'erreur au sens L^p pour $p > 2$ qui serviront essentiellement à prouver la convergence p.s. des filtres particuliers régularisés. Dans la troisième section, on considère l'optimisation du choix des paramètres de régularisation de sorte à minimiser l'erreur commise. Cette section servira essentiellement

pour la détermination des paramètres utilisés dans les simulations du Chapitre 6.

4.1 Contexte général

Nous ne considérons, dans ce chapitre, que des mesures sur $E = \mathbb{R}^d$ absolument continues (a.c.) par rapport à la mesure de Lebesgue. Nous notons simplement L^p l'espace $L^p(\mathbb{R}^d, \mathbb{R}, dx)$ des fonctions définies sur $\mathbb{R}^d$ à valeurs dans $\mathbb{R}$ dont la puissance p -ième est intégrable par rapport à la mesure de Lebesgue.

4.1.1 Rappels sur le produit de convolution

Soient f et K deux fonctions de E dans $\mathbb{R}$, où $f \in L^1$ et $K \in L^p$, le produit de convolution de f par K est la fonction $K * f$ telle que pour tout $x \in E$,

$$(K * f)(x) = \int_E K(x - u)f(u) du = \int_E f(x - u)K(u) du .$$

Cette définition s'étend naturellement aux mesures. Soit μ une mesure signée finie sur E et $K \in L^p$ une fonction de E dans $\mathbb{R}$, le produit de convolution de μ par K est la mesure $K * \mu$ a.c. par rapport à la mesure de Lebesgue, telle que

$$(K * \mu)(dx) = \left\{ \int_E K(x - u)\mu(du) \right\} dx .$$

Si μ a pour densité f , alors $K * \mu$ a pour densité $K * f$. Ces définitions sont justifiées par le lemme suivant dans lequel nous énonçons quelques propriétés utiles et bien connues de l'opérateur de convolution.

Lemme 4.1. *Soient f et K deux fonctions respectivement dans L^p et L^1 , pour un réel $p \geq 1$ alors $K * f$ est dans L^p et*

$$\|K * f\|_p \leq \|f\|_p \|K\|_1 . \quad (4.1)$$

*Si K est une fonction dans L^1 et ϕ une fonction bornée sur $\mathbb{R}$, alors $K * \phi$ est aussi bornée et*

$$\|K * \phi\| \leq \|\phi\| \|K\|_1 . \quad (4.2)$$

Toute fonction K dans L^1 telle que $\int_E K(x) dx = 1$ est une unité approchée i.e.

$$\lim_{h \rightarrow 0} \|K_h * f - f\|_1 = 0 , \quad (4.3)$$

pour toute fonction f dans L^1 , où K_h désigne le noyau dilaté associé au réel $h > 0$ i.e., pour tout $x \in E$,

$$K_h(x) = \frac{1}{h^d} K\left(\frac{x}{h}\right) .$$

On peut se reporter à Brezis [15] pour la preuve de ce lemme.

Nous rappelons quelques notations classiques.

- $W^{r,p}$ désigne l'espace de Sobolev des fonctions mesurables définies sur $E = \mathbb{R}^d$ dont les dérivées jusqu'à l'ordre r (au sens des distributions) sont dans L^p .

- Pour tout d-uplet $\alpha = (\alpha_1, \dots, \alpha_d) \in \{1, 2, \dots, r\}^d$ nous notons $|\alpha| = \sum_{i=1}^d \alpha_i$, et $\alpha! = \alpha_1! \cdots \alpha_d!$.
- Pour tout $x = (x_1, \dots, x_d) \in \mathbb{R}^d$, nous notons x^α le réel $x_1^{\alpha_1} \cdots x_d^{\alpha_d}$.
- Pour toute fonction $f \in W^{r,p}$, et tout d-uplet α tel que $|\alpha| \leq r$ nous notons

$$(D_i^{\alpha_i} f)(x) = \frac{\partial^{\alpha_i} f}{\partial x_i^{\alpha_i}}(x), \quad (D^\alpha f)(x) = D_1^{\alpha_1} D_2^{\alpha_2} \cdots D_d^{\alpha_d} f(x), \quad (\nabla^2 f)(x) = \sum_{i=1}^d D_i^2 f(x).$$

- La norme $\|\cdot\|_{r,p}$ et la semi-norme $|\cdot|_{r,p}$ sont définies par

$$\|f\|_{r,p} = \left\{ \sum_{|\alpha| \leq r} \int_{\mathbb{R}^d} |D^\alpha f(x)|^p dx \right\}^{\frac{1}{p}}, \quad |f|_{r,p} = \left\{ \sum_{|\alpha|=r} \int_{\mathbb{R}^d} |D^\alpha f(x)|^p dx \right\}^{\frac{1}{p}}.$$

Soit μ une mesure signée finie sur E de densité f par rapport à la mesure de Lebesgue, nous introduisons les notations suivantes,

- pour tout $p \geq 1$, $\|\mu\|_p = \|f\|_p = [\int_E |f(x)|^p dx]^{\frac{1}{p}}$,
- $b(f) = \|f\|_2$,
- $I(\mu) = I(f) = \int_E |x|^{d+1} |f(x)| dx$,
- $J(\mu) = J(f) = \int_E \sqrt{|f(x)|} dx$,
- $a(\mu) = a(f) = \int_E |x|^2 |f(x)| dx$,
- pour tout entier $s \geq 1$, $a_s(\mu) = a_s(f) = s! \max_{|\alpha|=s} \int_E |x^\alpha| |f(x)| dx$,

lorsque ces quantités existent. Notons que $I(f)$ fini implique $J(f)$ fini, cela est en effet une conséquence de l'inégalité de Carlson énoncée dans le lemme suivant.

Lemme 4.2 (Inégalité de Carlson multidimensionnelle). *Soit f une densité de probabilité sur $\mathbb{R}^d$ telle que $I(f) < \infty$ alors*

$$J(f) \leq A_d I(f)^{\frac{d}{2(d+1)}} \quad \text{où} \quad A_d = \left(\frac{(2\pi)^{\frac{d+1}{2}}}{\Gamma(\frac{d+1}{2})} \right)^{1/2}. \quad (4.4)$$

On trouvera une inégalité plus précise dans [53]. Cette inégalité permet de rattacher $J(\mu)$ à l'épaisseur des queues de distribution : si $J(\mu)$ est grand alors μ concentre sa masse en queues de distribution.

PREUVE DU LEMME 4.2. Rappelons que la densité de Cauchy sur $\mathbb{R}^d$ est donnée par

$$c(x) = \frac{c_d}{(1 + |x|^2)^{\frac{d+1}{2}}}, \quad \text{où} \quad c_d = \frac{\Gamma(\frac{d+1}{2})}{\pi^{\frac{d+1}{2}}}.$$

Soit $r > 0$, en appliquant successivement l'inégalité de Cauchy-Schwarz puis l'inégalité de Minkowski nous obtenons

$$\begin{aligned}
J(f) &= \int_E \left[\frac{(1 + r^2|x|^2)^{\frac{d+1}{2}}}{(1 + r^2|x|^2)^{\frac{d+1}{2}}} f(x) \right]^{1/2} dx \\
&\leq \left[\int_E \frac{dx}{(1 + r^2|x|^2)^{\frac{d+1}{2}}} \int_E (1 + r^2|x|^2)^{\frac{d+1}{2}} f(x) dx \right]^{1/2} \\
&\leq \left(\frac{1}{r^d c_d} \right)^{1/2} \left[\int_E (1 + r^2|x|^2)^{\frac{d+1}{2}} f(x) dx \right]^{1/2} \\
&\leq \left(\frac{1}{r^d c_d} \right)^{1/2} \left[\left(\int_E 1^{\frac{d+1}{2}} f(x) dx \right)^{\frac{2}{d+1}} + \left(\int_E (r^2|x|^2)^{\frac{d+1}{2}} f(x) dx \right)^{\frac{2}{d+1}} \right]^{\frac{d+1}{4}}.
\end{aligned}$$

Comme l'intégrale de f vaut un, le réel $c > 0$, minimisant le majorant de l'inégalité ci-dessus est $r = (1/I(f))^{\frac{1}{d+1}}$, nous avons donc finalement

$$J(f) = \int_E \sqrt{f(x)} dx \leq \left(\frac{1}{c_d} \right)^{1/2} \left(\frac{1}{r^{d+1}} \right)^{\frac{d}{2(d+1)}} (1 + 1)^{\frac{d+1}{4}} \leq \left(\frac{(2\pi)^{\frac{d+1}{2}}}{\Gamma(\frac{d+1}{2})} \right)^{1/2} I(f)^{\frac{d}{2(d+1)}},$$

ce qui termine la preuve du lemme. $\square$

Définition 4.3 (Noyau de régularisation et facteur de dilatation). Soit un entier $s \geq 1$. Une fonction mesurable K sur $E = \mathbb{R}^d$ à valeurs dans $\mathbb{R}$ est appelée noyau de régularisation d'ordre s si elle vérifie les conditions suivantes,

- (i) K est symétrique, i.e. $K(-x) = K(x)$ pour tout $x \in \mathbb{R}^d$,
- (ii) $\int_E K(x) dx = 1$,
- (iii) $\int_E x^\alpha K(x) dx = 0$, pour tout d -uplet α tel que $1 \leq |\alpha| \leq s - 1$,
- (iv) $\int_E |x^\alpha| |K(x)| dx < \infty$ pour tout d -uplet α tel que $|\alpha| = s$, nous notons alors $a_s(K) = \max_{|\alpha|=s} \int_E |x^\alpha| |K(x)| dx$.

Nous appelons facteur de dilatation tout réel $h > 0$, associé au noyau dilaté K_h tel que

$$K_h(x) = \frac{1}{h^d} K\left(\frac{x}{h}\right),$$

pour tout $x \in E$. Pour toute mesure finie μ sur E , la mesure $K_h * \mu$ est appelée la régularisation de la mesure μ par le noyau K_h .

Remarque 4.4. On note que le noyau de régularisation K peut éventuellement prendre des valeurs négatives. Il ne s'agit donc pas toujours d'une densité de probabilité. En particulier, tout noyau d'ordre supérieur ou égal à trois doit nécessairement prendre des valeurs négatives pour que le point (iii) puisse être vérifié. Dans ce cas la mesure régularisée est une mesure signée qu'il faut approcher au mieux par une mesure de probabilité. Cette projection est, en général, coûteuse en temps de calcul. Elle exige, en effet, de déterminer les zones de positivité de l'estimée signée. Cette remarque justifie le traitement spécial que nous réservons dans la suite aux noyaux positifs d'ordre deux.

Considérons, par exemple, le cas où $\mu = \sum_{i=1}^N \omega^i \delta_{\xi^i}$ avec pour tout $i \in \{1, \dots, N\}$, $\xi^i \in E$ et $\omega^i \in \mathbb{R}$. La mesure régularisée a alors pour densité,

$$\frac{d(K_h * \mu)}{dx}(x) = \frac{1}{h^d} \sum_{i=1}^N \omega^i K\left(\frac{1}{h}(x - \xi^i)\right) = \sum_{i=1}^N \omega^i K_h(x - \xi^i), \quad (4.5)$$

voir Figure 4.1.1.




FIG. 4.1: Régularisation d'une mesure empirique

Remarque 4.5. On note qu'il est facile de simuler le mélange (4.5). La génération de ξ suivant (4.5) est en effet réalisée suivant la procédure :

- (i) Générer $I \in \{1, \dots, N\}$, avec $\mathbb{P}(I = i) = \omega^i$.
- (ii) Générer $\varepsilon \sim K$.
- (iii) Poser $\xi = \xi^I + h \varepsilon$.

Cette remarque est essentielle car dans de nombreuses applications, l'estimation de densité a justement pour but d'augmenter la taille de l'échantillon initial en générant des v.a. suivant la densité estimée. Le nouvel échantillon ainsi obtenu n'est évidemment pas i.i.d. suivant μ , mais on montre que son comportement en est asymptotiquement ($N \rightarrow \infty$) proche (voir [42, pp. 759–767]). Par ailleurs, dans l'application que nous ferons de l'estimation de densité en filtrage particulière, on sera aussi amené à générer un échantillon suivant l'estimée obtenue. Les contraintes de temps de calcul étant essentielles en filtrage, il est crucial de savoir simuler rapidement cette densité.

4.1.2 Description du problème

Pré-régularisation et post-régularisation

En estimation de densité classique, on dispose d'un échantillon $(\xi^1, \dots, \xi^N)$ issu d'une mesure de probabilité μ . Le but est d'approcher μ par $\mu^{N,h} = K_h * S^N(\mu)$ la régularisa-

tion de la mesure empirique $S^N(\mu) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi^i}$ associée à l'échantillon. Comme on l'a vu, l'approximation prend alors la forme d'un mélange de noyaux équipondérés,

$$\mu^{N,h} = [K_h * S^N(\mu)](dx) = \frac{1}{N} \sum_{i=1}^N K_h(x - \xi^i) dx .$$

Dans ce chapitre, nous considérons une version plus générale de ce problème. Nous disposons toujours d'un échantillon $(\xi^1, \dots, \xi^N)$ issu de μ mais, cette fois, nous cherchons une approximation régulière de la mesure corrigée $\Psi \cdot \mu$ où Ψ est une fonction positive connue. Lorsque Ψ est constante, on retrouve le problème classique d'estimation de densité puisqu'alors $\Psi \cdot \mu = \mu$. Nous proposons deux solutions à ce problème.

Pré-régularisation : Une première idée est d'appliquer directement les techniques d'estimation de densité en approchant μ par $K_h * S^N(\mu)$ puis $\Psi \cdot \mu$ par $\Psi \cdot (K_h * S^N(\mu))$:

$$S^N(\mu) \xrightarrow[\text{Régularisation}]{(1)} K_h * S^N(\mu) \xrightarrow[\text{Correction}]{(2)} \Psi \cdot (K_h * S^N(\mu)) . \quad (4.6)$$

Cette technique a l'avantage d'exploiter la connaissance de Ψ sur tout le support de la densité $K_h * S^N(\mu)$. Cependant, la mesure obtenue est difficile à simuler. Il faut en effet implémenter un algorithme d'acceptation / rejet en simulant un nombre aléatoire de v.a. suivant le mélange $K_h * S^N(\mu)$.

Post-régularisation : Une autre idée consiste à approcher $\Psi \cdot \mu$ par $K_h * (\Psi \cdot S^N(\mu))$ la régularisation de la mesure empirique pondérée $\Psi \cdot S^N(\mu) = \sum_{i=1}^N \omega_i \delta_{\xi^i}$ avec $\omega_i = \frac{\Psi(\xi^i)}{\sum_{j=1}^N \Psi(\xi^j)}$:

$$S^N(\mu) \xrightarrow[\text{Correction}]{(1)} \Psi \cdot S^N(\mu) \xrightarrow[\text{Régularisation}]{(2)} K_h * (\Psi \cdot S^N(\mu)) . \quad (4.7)$$

L'approximation ainsi obtenue est un mélange de noyaux et donc facilement simulable (voir Remarque 4.5).

$$\mu^{N,h}(dx) = [K_h * (\Psi \cdot S^N(\mu))](dx) = \sum_{i=1}^N \omega^i K_h(x - \xi^i) dx .$$

Mais, ici la fonction Ψ est loin d'être parfaitement exploitée, puisqu'elle n'est évaluée que pour les points de l'échantillon.

Dans les deux cas, le problème se résume à trouver le facteur de dilatation h et le noyau de régularisation K tels que l'erreur entre la vraie mesure μ de densité f et l'approximation $\mu^{N,h}$ de densité $f^{N,h}$ soit minimale. Dans la section suivante nous étudions les erreurs commises par ces deux méthodes d'estimation pour des paramètres N et h donnés. Pour ce qui concerne l'erreur de pré-régularisation, nous nous contenterons d'étudier l'erreur induite par la première étape, la régularisation qui correspond à l'erreur classiquement considérée en estimation de densité.

Choix du critère

Il nous faut avant tout choisir un critère mesurant la précision de l'approximation. Dans le cadre classique de l'estimation de densité, le critère le plus répandu dans la littérature est celui de la moyenne quadratique intégrée, i.e.

$$\int_E \mathbb{E} |f^{N,h}(x) - f(x)|^2 dx = \mathbb{E} \|f^{N,h} - f\|_2^2 = \mathbb{E} \|\mu^{N,h} - \mu\|_2^2 .$$

L'emploi de ce critère est naturel en statistique lorsqu'on s'intéresse à la qualité d'un estimateur, car il s'interprète comme la somme d'un terme de biais et d'un terme de variance,

$$\mathbb{E} [f^{N,h}(x) - f(x)]^2 = \mathbb{E} [f^{N,h}(x) - K_h * f(x)]^2 + [K_h * f(x) - f(x)]^2 . \quad (4.8)$$

On note effectivement qu'en estimation de densité $f^{N,h}$ est un estimateur biaisé de f puisque

$$\mathbb{E} [f^{N,h}(x)] = \frac{1}{N} \sum_{i=1}^N \int_E K_h(x - u^i) f(u^i) du^i = K_h * f(x) .$$

De plus, nous verrons avec le Théorème 4.6 que ce critère permet de développer des estimations d'erreur particulièrement précises et simples. Parallèlement, une autre approche privilégie la distance moyenne au sens L^1 i.e.

$$\mathbb{E} \int_E |f^{N,h}(x) - f(x)| dx = \mathbb{E} \|f^{N,h} - f\|_1 = \mathbb{E} \|\mu^{N,h} - \mu\|_1 .$$

Cette distance présente, en effet, certains avantages. Elle est invariante par changement de variable, et constitue ainsi une mesure universelle de la distance entre $f^{N,h}$ et f . De plus, la distance L^1 entre les densités coïncide avec la distance en variation totale entre les mesures,

$$\|f^{N,h} - f\|_1 = \|\mu^{N,h} - \mu\|_1 = 2 \sup_A |\mu^{N,h}(A) - \mu(A)| = \|\mu^{N,h} - \mu\| ,$$

où le sup est pris parmi tous les boréliens de $E = \mathbb{R}^d$. Elle constitue donc une mesure naturelle de la distance entre les densités de probabilité. Malheureusement, nous verrons au Théorème 4.6 qu'avec ce critère, les majorations d'erreurs sont difficiles et demandent des hypothèses supplémentaires de régularité de la densité sous-jacente. Enfin, dans ce chapitre nous développons aussi des majorations de l'erreur moyenne au sens L^p qui permettront de prouver la convergence p.s. des méthodes particulières régularisées.

$$\int_E \mathbb{E} |f^{N,h}(x) - f(x)|^p dx = \mathbb{E} \|f^{N,h} - f\|_p^p = \mathbb{E} \|\mu^{N,h} - \mu\|_p^p ,$$

4.2 Estimation d'erreurs

Cette section a pour objet l'analyse des erreurs commises par les méthodes d'estimation de densité par noyaux et par la post-régularisation. Nous n'abordons pas ici le choix optimal du facteur de dilatation h en fonction de l'échantillon. Nous considérons les paramètres de régularisation h et K comme donnés et déterministes. Les estimation d'erreur classique en estimation de densité sont ici rappelées. Puis nous fournissons de nouvelles majorations d'erreurs

pour les critères L^p ($p > 2$). Nous étudions ensuite les erreurs dues à la post-régularisation. Enfin, nous terminons par la preuve d'un nouveau résultat de convergence p.s. en estimation de densité.

Pour alléger les notations, lorsque nous considérons, par la suite, un noyau de régularisation K , les notations $a(K) = \int_E |x|^2 |K(x)| dx$, $a_s(K) = s! \sup_{|\alpha|=s} \int_E |x^\alpha| |K(x)| dx$ et $b(K) = \|K\|_2$ sont respectivement remplacées par a , a_s et b , lorsque ces quantités existent.

4.2.1 Résultats principaux

Convergence au sens L^p

Nous présentons d'abord des résultats classiques en estimation de densité fournissant des estimations précises des erreurs de régularisation aux sens L^1 et L^2 . Ces estimations serviront à optimiser le choix des paramètres de régularisation utilisés dans les applications. Par souci de clarté, nous ne reportons ces résultats que dans le cas d'un noyau de régularisation radialement symétrique (invariant par rotation). Cette restriction se justifie, en pratique, par la simplicité de simulation de ces noyaux (voir Devroye [42, pp. 225–245]).

Théorème 4.6. *Soit μ une mesure de probabilité sur E de densité $f = \frac{d\mu}{dx}$ par rapport à la mesure de Lebesgue, et K un noyau de régularisation positif d'ordre deux radialement symétrique.*

(i) *Si $f \in W^{2,1}$ avec $I(\mu)$ fini et $K \in L^2$ avec $I(K^2)$ fini, alors*

$$\mathbb{E}\|K_h * S^N(\mu) - \mu\| \leq h^2 \frac{a}{2} \|\nabla^2 f\|_1 + \frac{J(\mu)b}{\sqrt{N}h^d} + \frac{\omega(h)}{\sqrt{N}h^d}, \quad (4.9)$$

où $\omega(h)$ converge vers zéro quand h tend vers zéro.

(ii) *Si $f \in W^{2,2}$ et $K \in L^2$, alors*

$$\mathbb{E}\|K_h * S^N(\mu) - \mu\|_2^2 = h^4 \frac{a^2}{4} \|\nabla^2 f\|_2^2 + \frac{b^2}{N h^d} + o(h^4) + O\left(\frac{1}{N}\right). \quad (4.10)$$

Les inégalités se généralisent facilement à un noyau K d'ordre s non radialement symétrique et prenant éventuellement des valeurs négatives (voir [43, 53]). Nous observons, comme nous l'avons annoncé que l'estimation d'erreur la plus précise est obtenue pour le critère L^2 , sous la seule hypothèse, $\|\nabla^2 f\|_2 < \infty$, qui suppose que f n'oscille pas trop. Par contre, le critère L^1 requiert en plus $J(\mu) < \infty$ qui sous entend que les queues de distribution de μ ne sont pas trop épaisses. On peut noter que Devroye et Györfi [43, p. 79] (pour le cas monodimensionnel) et Holmström et Klemelä [53, p. 257] (pour le cas multidimensionnel) fournissent des minoration asymptotiques de l'erreur L^1 qui sont du même ordre de grandeur que la majoration (4.9) à une constante multiplicative près. Cela donne une idée des performances limites de l'estimation par noyaux. Pour obtenir une estimation plus précise, on peut avoir recours à une méthode d'estimation paramétrique pour une classe de densités particulière. En contrepartie, l'estimée fournie peut s'avérer très mauvaise si la densité recherchée n'appartient pas à la classe considérée.

Nous présentons maintenant des majorations plus grossières des erreurs de régularisation que nous avons développées pour les sens faible, L^1 et L^p pour $p \geq 2$. Ces majorations permettront l'analyse des filtres particulières régularisés.

Théorème 4.7. *Soit μ une mesure de probabilité sur E de densité $f = \frac{d\mu}{dx}$ par rapport à la mesure de Lebesgue, et K un noyau de régularisation d'ordre deux.*

(i) *Si $f \in W^{2,1}$, alors*

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle K_h * S^N(\mu) - \mu, \phi \rangle| \leq a_2 h^2 |f|_{2,1} + \frac{1}{\sqrt{N}}. \quad (4.11)$$

(ii) *Si $f \in W^{2,1}$ avec $I(\mu)$ fini et $K \in L^2$ avec $I(K^2)$ fini, alors*

$$\mathbb{E} \|K_h * S^N(\mu) - \mu\| \leq a_2 h^2 |f|_{2,1} + A'_d \frac{(1 + I(\mu)) b}{\sqrt{N} h^d}, \quad (4.12)$$

où $A'_d = 2^{\frac{d}{2}} A_d$ ne dépend que de la dimension d (voir (4.4)).

(iii) *Si pour un réel $p \geq 2$, $f \in W^{2,p}$ et $K \in L^p$, alors*

$$(\mathbb{E} \|K_h * S^N(\mu) - \mu\|_p^p)^{\frac{1}{p}} \leq a_2 h^2 |f|_{2,p} + C_p \frac{\|K\|_p}{N^{\frac{1}{2}} h^{\frac{p-1}{p}d}}, \quad (4.13)$$

où $C_p = 2B_p^{\frac{1}{p}}$ ne dépend que de p (voir (3.20)).

(iv) *Si $f \in W^{2,1}$ avec $I(\mu)$ fini et pour un réel $p \geq 2$, $K \in L^p$ avec $I(K)$ fini, alors*

$$(\mathbb{E} \|K_h * S^N(\mu) - \mu\|_p^p)^{\frac{1}{p}} \leq a_2 h^2 |f|_{2,1} + C_{p,d} \frac{(1 + I(\mu)) \|K\|_p^{\frac{1}{2}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p}d}}, \quad (4.14)$$

où $C_{p,d} = 2^{\frac{d+3}{2}} B_p^{\frac{1}{2p}} A_d$ ne dépend que de p et d (voir (3.20) et (4.4)).

On note que la vitesse de convergence obtenue pour le sens faible est en $O(1/\sqrt{N})$, comme la loi des grands nombres, si h est choisi en $O(1/N^{1/4})$. Par contre, en variation totale, la vitesse de convergence est moins bonne et dépend de la dimension (elle est en $O(1/N^{2/d+4})$, si h est en $O(1/N^{1/d+4})$).

Les inégalités se généralisent facilement à un noyau K d'ordre s . Seul le terme de biais en h^2 est modifié suivant l'inégalité (4.26) de la Proposition 4.12 (plus bas), le terme de variance étant indépendant de l'ordre ou du signe du noyau de régularisation (voir Proposition 4.16). Notons que l'inégalité (4.13) n'est valable que pour $p \geq 2$, en effet dans la preuve nous utilisons l'inégalité de Jensen qui exige $p/2 \geq 1$. Cela justifie le traitement spécial réservé au cas $p = 1$.

La preuve du Théorème 4.7 consiste, dans un premier temps, à décomposer l'erreur en termes de variance et de biais, pour tout $p \geq 1$,

$$(\mathbb{E} \|K_h * S^N(\mu) - \mu\|_p^p)^{\frac{1}{p}} \leq (\mathbb{E} \|K_h * S^N(\mu) - K_h * \mu\|_p^p)^{\frac{1}{p}} + \|K_h * \mu - \mu\|_p. \quad (4.15)$$

Heureusement, cette première majoration n'est pas trop grossière. En effet, en reprenant l'argument de Devroye [43, p. 31], nous notons qu'une minoration du même ordre est satisfaite :

$$\frac{1}{4} (\mathbb{E} \|K_h * S^N(\mu) - K_h * \mu\|_p^p)^{\frac{1}{p}} + \frac{1}{2} \|K_h * \mu - \mu\|_p \leq (\mathbb{E} \|K_h * S^N(\mu) - \mu\|_p^p)^{\frac{1}{p}}.$$

Car, d'après Jensen, le second terme du membre de gauche est majoré comme suit

$$\|K_h * \mu - \mu\|_p \leq (\mathbb{E} \|K_h * S^N(\mu) - \mu\|_p^p)^{\frac{1}{p}},$$

et le premier terme du membre de gauche est majoré ainsi

$$(\mathbb{E} \|K_h * S^N(\mu) - K_h * \mu\|_p^p)^{\frac{1}{p}} \leq (\mathbb{E} \|K_h * S^N(\mu) - \mu\|_p^p)^{\frac{1}{p}} + \|K_h * \mu - \mu\|_p \leq 2 (\mathbb{E} \|K_h * S^N(\mu) - \mu\|_p^p)^{\frac{1}{p}}.$$

Dans le cas particulier de la norme L^2 , nous avons déjà vu avec l'équation (4.8) que la décomposition est plus précise, l'inégalité étant remplacée par une égalité,

$$\mathbb{E} \|K_h * S^N(\mu) - \mu\|_2^2 = \mathbb{E} \|K_h * S^N(\mu) - K_h * \mu\|_2^2 + \|K_h * \mu - \mu\|_2^2. \quad (4.16)$$

C'est notamment cette spécificité qui peut faire préférer le critère L^2 .

La majoration du terme de biais fera l'objet de la Section 4.2.2 tandis que la Section 4.2.3 sera consacrée au terme de variance.

Nous présentons maintenant le résultat concernant l'estimation d'une mesure corrigée.

Théorème 4.8. *Soit μ une mesure de probabilité sur E de densité $f = \frac{d\mu}{dx}$ par rapport à la mesure de Lebesgue, K un noyau de régularisation positif d'ordre deux, et Ψ une fonction positive bornée sur E , deux fois dérivable telle que $\langle \mu, \Psi \rangle > 0$ et telle qu'il existe une constante positive M' vérifiant*

$$M' = \max\{\|\Psi\|, 2 \sum_{i=1}^d \|D_i \Psi\|, \sum_{i,j=1}^d \|D_i D_j \Psi\|\} < \infty.$$

On note $\gamma' = M' / \langle \mu, \Psi \rangle$.

(i) Si $f \in W^{2,1}$, alors

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle K_h * (\Psi \cdot S^N(\mu)) - \Psi \cdot \mu, \phi \rangle| \leq \gamma' \left[a_2 h^2 \|f\|_{2,1} + \frac{2}{\sqrt{N}} \right]. \quad (4.17)$$

(ii) Si $f \in W^{2,1}$ avec $I(\mu)$ fini et $K \in L^2$ avec $I(K^2)$ fini, alors

$$\mathbb{E} \|K_h * (\Psi \cdot S^N(\mu)) - \Psi \cdot \mu\| \leq \gamma' \left[a_2 h^2 \|f\|_{2,1} + 2 A'_d \frac{(1 + I(\mu)) b}{\sqrt{N} h^d} \right], \quad (4.18)$$

où $A'_d = 2^{\frac{d}{2}} A_d$ ne dépend que de d (voir (4.4)).

(iii) Si pour un réel $p \geq 2$, $f \in W^{2,p}$ et $K \in L^p$, alors

$$(\mathbb{E} \|K_h * (\Psi \cdot S^N(\mu)) - \Psi \cdot \mu\|_p^p)^{\frac{1}{p}} \leq \gamma' \left[a_2 h^2 \|f\|_{2,p} + C'_p \frac{\|K\|_p}{N^{\frac{1}{2}} h^{\frac{p-1}{p}d}} \right], \quad (4.19)$$

où $C'_p = 3B_p^{\frac{1}{p}}$ ne dépend que de p (voir (3.20)).

(iv) Si $f \in W^{2,1}$ avec $I(\mu)$ fini et pour un réel $p \geq 2$, $K \in L^p$ avec $I(K)$ fini, alors

$$(\mathbb{E}\|K_h * (\Psi \cdot S^N(\mu)) - \Psi \cdot \mu\|_p^p)^{\frac{1}{p}} \leq \gamma' \left[a_2 h^2 \|f\|_{2,1} + C'_{p,d} \frac{(1 + I(\mu)) \|K\|_p^{\frac{1}{2}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p}d}} \right], \quad (4.20)$$

où $C'_{p,d} = 2^{\frac{d+2}{2}} \sqrt{3} B_p^{\frac{1}{2p}} A_d$ ne dépend que de p et d (voir (3.20) et (4.4)).

Ici aussi, la preuve consiste d'abord à décomposer l'erreur en un terme de biais et un terme de variance,

$$\begin{aligned} (\mathbb{E}\|K_h * (\Psi \cdot S^N(\mu)) - \Psi \cdot \mu\|_p^p)^{\frac{1}{p}} &\leq (\mathbb{E}\|K_h * (\Psi \cdot S^N(\mu)) - K_h * (\Psi \cdot \mu)\|_p^p)^{\frac{1}{p}} \\ &\quad + \|K_h * (\Psi \cdot \mu) - \Psi \cdot \mu\|_p. \end{aligned} \quad (4.21)$$

On note que le terme de biais, $\|K_h * (\Psi \cdot \mu) - \Psi \cdot \mu\|_p$, correspond en fait au biais asymptotique lorsque $N \rightarrow \infty$. En réalité pour N fini l'échantillonnage pondéré ajoute un biais supplémentaire. Pour cette raison, l'égalité (4.16) n'a pas d'équivalent simple ici. Du fait de l'étape de dénormalisation, nous perdons la précision des majorations d'erreur que nous pouvions obtenir en estimation de densité classique avec le Théorème 4.6, avec l'apparition du coefficient $\gamma' \geq 1$. Là encore les inégalités se généralisent facilement au cas d'un noyau d'ordre s .

Remarque 4.9. On précise que les inégalités (4.9) du Théorème 4.6 et les inégalités (4.18) du Théorème 4.8 ne sont rigoureusement valables que pour $h \leq (1 + I(K^2)/b^2)^{\frac{1}{d+1}}$. Cette condition implicite n'est pas essentielle, elle permet seulement d'alléger les majorations. Sans elle, il suffit de remplacer, dans les inégalités, le terme $(1 + I(\mu))$ par $(1/\sqrt{2}) [I(\mu)^{\frac{d}{d+1}} + h^d (I(K^2)/b^2)^{\frac{d}{d+1}}]^{\frac{1}{2}}$ (voir les majorations (4.31) et (4.32) de la preuve du Lemme 4.14). Pour la même raison, l'inégalité (4.14) du Théorème 4.6 et l'inégalité (4.20) du Théorème 4.8 ne sont valables que pour $h \leq (1 + I(K))^{\frac{1}{d+1}}$. Dans la suite, ces deux conditions seront implicites.

Convergence presque sûre

Pour ce qui concerne les résultats de convergence p.s. de mesures empiriques régularisées vers la vraie mesure sous-jacente à l'échantillon, nous pouvons nous reporter à plusieurs résultats de Devroye [42, 43]. Notamment le Théorème 3.1 dans [43, p. 30], montre que les conditions

$$(i) \lim_{N \rightarrow \infty} h = 0$$

$$(ii) \lim_{N \rightarrow \infty} N h^d = \infty$$

sont nécessaires et suffisantes pour que $\lim_{N \rightarrow \infty} \|f^{N,h} - f\|_1 = 0$ p.s.. Plus loin dans le même ouvrage p. 163, des vitesses de convergence p.s. sont fournies par le Corollaire 9.3 du Théorème 9.1 qui établit l'égalité,

$$\sqrt{N} |\|f^{N,h} - f\|_1 - \mathbb{E}\|f^{N,h} - f\|_1| = o(\log(N)), \quad \mathbb{P}\text{-p.s.},$$

pour toute densité de probabilité f pourvu que K soit à support compact. Ainsi, si de plus $f \in W^{2,1}$ et $I(f)$ est fini, nous obtenons, grâce à l'inégalité (4.12) du Théorème 4.7,

$$\|f^{N,h} - f\|_1 \leq \varepsilon(N) \frac{\log(N)}{\sqrt{N}} + a_2 h^2 |f|_{2,1} + A'_d \frac{(1 + I(f))b}{\sqrt{N}h^d}, \quad \mathbb{P}\text{-p.s.}, \quad (4.22)$$

où $(\varepsilon(N))_{N \geq 0}$ est une suite aléatoire positive convergeant p.s. vers zéro. Il résulte le corollaire suivant.

Corollaire 4.10. *Soit $f \in W^{2,1}$ avec $I(f)$ fini et K un noyau de régularisation d'ordre deux à support compact. Si h est choisi de manière à optimiser la vitesse de convergence, (en $O(1/N^{1/(d+4)})$), alors*

$$\lim_{N \rightarrow \infty} N^\alpha \|f^{N,h} - f\|_1 = 0, \quad \mathbb{P}\text{-p.s.}, \quad \text{pour tout} \quad \alpha < \frac{2}{d+4}. \quad (4.23)$$

Dans les algorithmes de filtrage particulaire régularisé, nous opérons à chaque instant d'observation, avant ou après l'étape de correction, la régularisation de la mesure empirique associée au système de particules courant. Pour l'étude de la convergence en temps long de ces algorithmes, l'inégalité (4.22) n'est pas exploitable car on ne peut garantir la convergence uniforme de toutes les suites $(\varepsilon(N))_{N \geq 0}$ associées aux erreurs de régularisation commises à chaque instant. Nous nous appuyerons alors sur les majorations de l'erreur moyenne d'ordre p au sens L^1 des inégalités (4.14) et (4.20) pour obtenir la convergence p.s. en utilisant le lemme de Borel Cantelli comme dans le corollaire suivant.

Corollaire 4.11. *Soit $f \in W^{2,1}$ avec $I(f)$ fini et K un noyau de régularisation d'ordre deux tel que pour un réel $p \geq 2$, $K \in L^p$ et $I(K)$ est fini. Si le facteur de dilatation h est choisi tel que*

$$h = O\left(\frac{1}{N^{\frac{p}{2[(d+4)p-d]}}}\right),$$

alors,

$$\lim_{N \rightarrow \infty} N^\alpha \|f^{N,h} - f\|_1 = 0 \quad \mathbb{P}\text{-p.s.}, \quad \text{pour tout} \quad \alpha < \frac{p}{(d+4)p-d} - \frac{1}{p}. \quad (4.24)$$

Ce choix de h est naturel puisqu'il permet d'optimiser la vitesse de convergence moyenne d'ordre p au sens L^1 suggérée par l'inégalité (4.14). Il conduit alors à une erreur d'ordre $O\left(\frac{1}{N^{\frac{1}{(d+4)p-d}}}\right)$.

Le Corollaire 4.11 est plus général que le Corollaire 4.10 puisqu'il est aussi valable pour les noyaux à support infini. Cependant, dans le cas particulier d'un noyau K à support compact, l'inégalité (4.24) du Corollaire 4.11 est moins précise que l'inégalité (4.23) du Corollaire 4.10, puisqu'elle fournit le résultat :

$$\lim_{N \rightarrow \infty} N^\alpha \|f^{N,h} - f\|_1 = 0, \quad \mathbb{P}\text{-p.s.}, \quad \text{pour tout} \quad \alpha < \frac{1}{d+4}.$$

PREUVE DU COROLLAIRE 4.11. D'après l'inégalité (4.14), et l'inégalité de Markov, nous avons

$$\mathbb{P}[N^{\alpha p} \|f^{N,h} - f\|^p \geq \varepsilon] \leq \frac{Cte}{\varepsilon N^{\frac{p^2}{(d+4)p-d} - \alpha p}},$$

puis nous terminons la preuve en utilisant le Lemme de Borel–Cantelli. $\square$

4.2.2 Majoration du biais

Dans cette section, on considère les termes de biais des décompositions (4.15) et (4.21).

Nous reprenons les notations introduites dans [53]. Nous associons à tout noyau de régularisation K d'ordre $s \geq 1$ et à tout multi-indice α tel que $|\alpha| = s$ la fonction L^α définie par

$$L^\alpha(x) = (-1)^{|\alpha|} \int_1^\infty \frac{(t-1)^{|\alpha|-1}}{(|\alpha|-1)!} t^{d-1} x^\alpha K(tx) dt ,$$

pour tout $x \in E$. Nous vérifions que

$$\|L^\alpha\|_1 = \int_E |L^\alpha(x)| dx \leq \frac{1}{|\alpha|!} \int_E |x^\alpha| |K(x)| dx \leq \frac{a_s}{|\alpha|!} \leq \frac{a_s}{s!} .$$

$K_h * \mu$ approche μ au sens des inégalités de la proposition suivante.

Proposition 4.12. *Soit un réel $p \geq 1$ et une mesure de probabilité μ sur E de densité $f = \frac{d\mu}{dx} \in W^{s,p}$ par rapport à la mesure de Lebesgue, et K un noyau de régularisation d'ordre $s \geq 1$. Alors*

$$\|K_h * \mu - \mu\|_p = \|K_h * f - f\|_p \leq a_s h^s \sum_{|\alpha|=s} \frac{1}{\alpha!} \|D^\alpha f\|_p . \quad (4.25)$$

$$\|K_h * \mu - \mu\|_p = \|K_h * f - f\|_p = h^s \left\| \sum_{|\alpha|=s} \frac{s!}{\alpha!} D^\alpha f \int_E L^\alpha \right\|_p + o(h^s) , \quad (4.26)$$

Dans le cas particulier où $f \in W^{2,p}$ avec un noyau d'ordre deux nous avons

$$\|K_h * \mu - \mu\|_p = \|K_h * f - f\|_p \leq a_2 h^2 \|f\|_{2,p} . \quad (4.27)$$

Si de plus le noyau est positif et radialement symétrique nous avons

$$\|K_h * \mu - \mu\|_p = \|K_h * f - f\|_p = h^2 \frac{a}{2} \|\nabla^2 f\|_p + o(h^2) . \quad (4.28)$$

Si $f \in W^{r,p}$, avec $r > s$, et que le noyau K est d'ordre s , le biais reste toujours d'ordre s . Ainsi quelle que soit la régularité de f , les irrégularités du noyau limitent les performances d'estimation. Les noyaux d'ordre infini, appelés “superkernel” en anglais, s'adaptent à la régularité de f de sorte à produire un biais d'ordre minimal pour tout f . Malheureusement, comme on l'a vu avec la Remarque 4.4, dès que l'ordre du noyau dépasse trois, celui-ci n'est plus une densité de probabilité et l'estimée fournie non plus. En outre, on verra dans la section suivante que le coefficient $b = b(K)$ intervenant dans l'estimation asymptotique de la variance augmente avec l'ordre du noyau. L'emploi de ce type de noyaux n'est donc pas toujours indiqué.

Pour le traitement du terme de biais de la décomposition (4.21) correspondant au Théorème 4.8 (cas d'une mesure corrigée), nous étendons aux fonctions la définition du produit

projectif déjà introduit pour les mesures. Pour toutes fonctions f et g de E dans $\mathbb{R}$ nous notons $f \cdot g$ la fonction de E dans $\mathbb{R}$ telle que

$$(f \cdot g)(x) = \begin{cases} \frac{f(x)g(x)}{\int_E f(x)g(x)dx} & \text{si } \int_E f g \neq 0, \\ 0 & \text{si } \int_E f g = 0, \end{cases}$$

pour tout $x \in E$. Le terme de biais $\|\Psi \cdot f - K_h * (\Psi \cdot f)\|_p$ est toujours majoré par la Proposition 4.12, en remplaçant dans les inégalités f par $\Psi \cdot f$ et en notant que

$$M' = \max\{\|\Psi\|, 2 \sum_{i=1}^d \|D_i \Psi\|, \sum_{i,j=1}^d \|D_i D_j \Psi\|\} < \infty,$$

entraîne pour tout $p \geq 1$

$$\begin{aligned} \|\Psi \cdot f\|_{2,p} &= \frac{1}{\langle \mu, \Psi \rangle} \left[\int_E \left| \sum_{i,j=1}^d (D_i D_j \Psi)(x) f(x) + 2 \sum_{i,j=1}^d (D_i \Psi)(x) (D_j f)(x) \right. \right. \\ &\quad \left. \left. + \sum_{i,j=1}^d \Psi(x) (D_i D_j f)(x) \right|^p dx \right]^{\frac{1}{p}} \\ &\leq \frac{1}{\langle \mu, \Psi \rangle} \left[\sum_{i,j=1}^d \|D_i D_j \Psi\| \|f\|_p + 2 \sum_{i,j=1}^d \|D_i \Psi\| \|f\|_{1,p} + \|\Psi\| \|f\|_{2,p} \right] \leq \frac{M'}{\langle \mu, \Psi \rangle} \|f\|_{2,p}. \end{aligned}$$

PREUVE DE LA PROPOSITION 4.12. On peut trouver la preuve de la Proposition 4.12 en dimension 1 pour $p = 1$ dans [43]. Pour le cas multidimensionnel avec $p = 1$, on peut se reporter à [95] ou [53]. La preuve développée ici est une extension facile de la preuve de [53] aux réels $p \geq 1$. Nous considérons d'abord les inégalités grossières (4.25) et (4.27). D'après la Proposition 3 de [53] nous avons

$$K_h * f(x) - f(x) = \sum_{|\alpha|=s} \frac{s!}{\alpha!} L_h^\alpha * D^\alpha f(x).$$

$$\begin{aligned} \|K_h * f - f\|_p &\leq \sum_{|\alpha|=s} \frac{s!}{\alpha!} \|L_h^\alpha * D^\alpha f\|_p \\ &\leq \sum_{|\alpha|=s} \frac{s!}{\alpha!} \|D^\alpha f\|_p \|L_h^\alpha\|_1 \\ &= h^s \sum_{|\alpha|=s} \frac{s!}{\alpha!} \|D^\alpha f\|_p \|L^\alpha\|_1 \\ &\leq h^s \sum_{|\alpha|=s} \frac{1}{\alpha!} \|D^\alpha f\|_p a_s. \end{aligned}$$

Pour un noyau d'ordre deux,

$$\|K_h * f - f\|_p \leq a_2 h^2 |f|_{2,p} .$$

Nous considérons maintenant les inégalités fines (4.26) et (4.28). Pour simplifier l'exposé nous ne traitons que le cas de l'inégalité (4.28) d'un noyau positif d'ordre deux radialement symétrique, pour le cas général (4.26) la généralisation de [53] (où $p = 1$), se fait de manière analogue. Pour tous entiers $1 \leq i < j \leq d$, nous notons $a_{i,j}$ le d -uplet $(0 \cdots 0, 1, 0 \cdots 0, 1, 0 \cdots 0) \in \{0, 1\}^d$ où les 1 occupent les i -ième et j -ième places, et $a_{i,i}$ le d -uplet $(0 \cdots 0, 2, 0 \cdots 0) \in \{0, 2\}^d$ où le 2 occupe la i -ème place. La fonction $L^{a_{i,j}}$ associée à K s'écrit

$$L^{a_{i,j}}(x) = x_i x_j \int_0^1 \frac{1-t}{t^2} K_t(x) dt = \int_1^\infty (t-1) t^{d-1} x_i x_j K(tx) dt .$$

Du fait de la symétrie radiale de K , $\int L^{a_{i,j}} = 0$ si $i \neq j$ et $\int L^{a_{i,i}} = \frac{a}{2}$ pour tout $1 \leq i \leq d$. Par le développement de Lagrange de f à l'ordre deux, nous avons

$$f(x+y) = f(x) + \sum_{i=1}^d (D_i f)(x) y_i + \sum_{i,j} \int_0^1 (1-t) D_i D_j f(x+ty) y_i y_j dt .$$

En intégrant cette expression contre le noyau K_h par rapport à y et en utilisant la propriété de symétrie de K , nous obtenons

$$\begin{aligned} (K_h * f)(x) - f(x) &= \int_E [f(x-y) - f(x)] K_h(y) dy \\ &= \sum_{i,j} \int_E \int_0^1 (1-t) D_i D_j f(x-ty) y_i y_j dt K_h(y) dy \\ &= h^2 \sum_{i,j} \int_E D_i D_j f(x-u) \frac{u_i u_j}{h^2} \int_0^1 \frac{1-t}{t^2} K_{th}(u) dt du \\ &= h^2 \sum_{i,j} L_h^{a_{i,j}} * (D_i D_j f)(x) \\ h^{-2} [(K_h * f)(x) - f(x)] &= \sum_{i,j} L_h^{a_{i,j}} * (D_i D_j f)(x) \end{aligned}$$

D'après l'inégalité de Minkowski,

$$\begin{aligned} |h^{-2} \|K_h * f - f\|_p - \frac{a}{2} \|\nabla^2 f\|_p| &\leq \|h^{-2} [K_h * f - f] - \frac{a}{2} \nabla^2 f\|_p \\ &= \left\| \sum_{i,j} L_h^{a_{i,j}} * (D_i D_j f) - \frac{a}{2} \nabla^2 f \right\|_p \\ &\leq \sum_i \|L_h^{a_{i,i}} * (D_i^2 f) - \frac{a}{2} \nabla^2 f\|_p + \sum_{i \neq j} \|L_h^{a_{i,j}} * (D_i D_j f)\|_p . \end{aligned}$$

Nous rappelons que $\int L^{a_i,i} = \frac{a}{2}$ et nous posons $\lambda_{i,j} = \int (L^{a_i,j})^- = \int (L^{a_i,j})^+$. Nous avons alors

$$\begin{aligned} |h^{-2} \|K_h * f - f\|_p - \frac{a}{2} \|\nabla^2 f\|_p| &\leq \frac{a}{2} \sum_i \left\| \frac{L_h^i}{\int L^i} * D_i^2 f - D_i^2 f \right\|_p \\ &\quad + \sum_{i \neq j} \lambda_{i,j} \left\| \frac{(L_h^{a_i,j})^+}{\int (L^{a_i,j})^+} * D_i D_j f - \frac{(L_h^{a_i,j})^-}{\int (L^{a_i,j})^-} * D_i D_j f \right\|_p, \end{aligned}$$

Nous terminons la preuve en utilisant la propriété d'unité approchée de l'inégalité (4.3) du Lemme 4.1 pour montrer que chacun des termes de droite tend vers zéro lorsque h tend vers zéro.

La preuve pour le cas général d'un noyau d'ordre s est complètement semblable, avec un développement de Taylor jusqu'à l'ordre s . $\square$

4.2.3 Majoration de la variance

On s'intéresse maintenant aux termes de variance des décompositions (4.15) et (4.21). Nous énonçons tout d'abord trois lemmes qui nous seront utiles.

Lemme 4.13. *Soient G et f deux densités de probabilité telles que $I(G)$ et $I(f)$ sont finis. Alors*

$$\lim_{h \rightarrow 0} \int_E |G_h * f - f|^{1/2}(x) dx = \lim_{h \rightarrow 0} J(G_h * f - f) = 0. \quad (4.29)$$

La preuve utilise l'inégalité de Carlson multidimensionnelle. Elle est développée dans [53] et conduit plus précisément à la majoration

$$J(G_h * f - f) \leq A_d \|G_h * f - f\|_1^{\frac{1}{2(d+1)}} [(1 + 2^d)I(f) + 2^d h^{d+1} I(G)]^{\frac{d}{2(d+1)}},$$

où A_d est une constante positive ne dépendant que de la dimension d donnée par (4.4).

Lemme 4.14. *Soient G une densité de probabilité et μ une mesure de probabilité telles que $I(G)$ et $I(\mu)$ sont finis. Alors pour tout $h \leq (1/I(G))^{\frac{1}{d+1}}$,*

$$J(G_h * \mu) \leq 2^{\frac{d}{2}} A_d [1 + I(\mu)]. \quad (4.30)$$

On note que la condition de majoration du facteur de dilatation, $h \leq (1/I(G))^{\frac{1}{d+1}}$, ne sert que pour alléger la majoration. Sans cette condition, on peut se contenter de l'inégalité (4.31) de la preuve. Pour la clarté de l'exposé, cette condition sera, par la suite, implicite.

PREUVE DU LEMME 4.14. D'après l'inégalité de Carlson (4.4), on a

$$J(G_h * \mu) \leq A_d I(G_h * \mu)^{\frac{d}{2(d+1)}}.$$

Après changement de variable nous utilisons l'inégalité de Minkowski par rapport à la mesure $G dx \times \mu$ sur E^2 et nous obtenons

$$\begin{aligned}
 I(G_h * \mu)^{\frac{1}{d+1}} &= \left[\int_E \int_E |x|^{d+1} G_h(x-y) \mu(dy) dx \right]^{\frac{1}{d+1}} \\
 &= \left[\int_E \int_E |y+uh|^{d+1} G(u) \mu(dy) du \right]^{\frac{1}{d+1}} \\
 &\leq I(\mu)^{\frac{1}{d+1}} + h I(G)^{\frac{1}{d+1}} \\
 I(G_h * \mu)^{\frac{d}{2(d+1)}} &\leq 2^{\frac{d-1}{2}} [I(\mu)^{\frac{d}{d+1}} + h^d I(G)^{\frac{d}{d+1}}]^{\frac{1}{2}}.
 \end{aligned} \tag{4.31}$$

Ainsi, dès que $h \leq (1/I(G))^{\frac{1}{d+1}}$ nous avons

$$I(G_h * \mu)^{\frac{d}{2(d+1)}} \leq 2^{\frac{d}{2}} [1 + I(\mu)] . \tag{4.32}$$

□

Le lemme suivant, permet de majorer l'erreur L^1 entre deux densités par l'erreur L^p .

Lemme 4.15. *Soient f et g deux densités de probabilité avec $J(f)$ fini. Si pour un réel $p \geq 2$, $f \in L^p$, alors*

$$\|f - g\|_1 \leq 2 J(f)^{\frac{p-1}{p}} \|f - g\|_p^{\frac{1}{2}} . \tag{4.33}$$

PREUVE DU LEMME 4.15.

$$\begin{aligned}
 \|f - g\|_1 &= 2 \int (f - g)^+{}^{\frac{1}{2}} (f - g)^+{}^{\frac{1}{2}} \\
 &\leq 2 \left(\int (f - g)^+{}^p \right)^{\frac{1}{2p}} \left(\int (f - g)^+{}^{\frac{p}{2p-1}} \right)^{\frac{2p-1}{2p}} .
 \end{aligned}$$

Rappelons (voir [15, p. 57]) que pour tous réels positifs $0 < r < q < s$, q s'écrit $\alpha r + \beta s$ avec $\alpha + \beta = 1$, et donc

$$\|f\|_q^q \leq \|f\|_r^{r\alpha} \|f\|_s^{s\beta} .$$

Nous utilisons cette inégalité pour les réels $1/2 < p/(2p-1) < 1$ ($p \geq 2$) et $\alpha = (2p-2)/(2p-1)$, ce qui nous donne

$$\left(\int (f - g)^+{}^{\frac{p}{2p-1}} \right)^{\frac{2p-1}{2p}} \leq \left(\int (f - g)^+{}^{\frac{1}{2}} \right)^{\frac{p-1}{p}} \left(\int (f - g)^+ \right)^{\frac{1}{2p}} .$$

En notant que $(f - g)^+ \leq f$ on a

$$\left(\int (f - g)^+{}^{\frac{p}{2p-1}} \right)^{\frac{2p-1}{2p}} \leq \left(\int f^{\frac{1}{2}} \right)^{\frac{p-1}{p}} \left(\int f \right)^{\frac{1}{2p}} \leq J(f)^{\frac{p-1}{p}} .$$

Finalement, nous obtenons

$$\|f - g\|_1 \leq 2 J(f)^{\frac{p-1}{p}} \|f - g\|_p^{\frac{1}{2}} .$$

□

Nous pouvons maintenant énoncer la première proposition de la section permettant de majorer la variance dans le cadre de l'estimation de densité classique correspondant aux Théorèmes 4.6 et 4.7.

Proposition 4.16. *Soit μ une mesure de probabilité sur E et K un noyau de régularisation d'ordre $s \geq 1$.*

(i)

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle K_h * S^N(\mu) - K_h * \mu, \phi \rangle| \leq \frac{1}{\sqrt{N}} . \quad (4.34)$$

(ii) Si $I(\mu)$ est fini et $K \in L^2$ avec $I(K^2)$ fini, alors

$$\mathbb{E} \|K_h * S^N(\mu) - K_h * \mu\| \leq A'_d \frac{(1 + I(\mu)) b}{\sqrt{N h^d}} , \quad (4.35)$$

où $A'_d = 2^{\frac{d}{2}} A_d$ ne dépend que de la dimension d (voir (4.4)). Si de plus μ est a.c. par rapport à la mesure de Lebesgue, alors on a la majoration plus précise

$$\mathbb{E} \|K_h * S^N(\mu) - K_h * \mu\| \leq \frac{J(\mu) b}{\sqrt{N h^d}} + \frac{\omega(h)}{\sqrt{N h^d}} , \quad (4.36)$$

où $\omega(h)$ converge vers zéro quand h tend vers zéro.

(iii) Si $K \in L^2$, alors

$$\mathbb{E} \|K_h * S^N(\mu) - K_h * \mu\|_2^2 = \frac{b^2}{N h^d} + O\left(\frac{1}{N}\right) \leq \frac{b^2}{N h^d} . \quad (4.37)$$

(iv) Si pour un réel $p \geq 2$, $K \in L^p$

$$(\mathbb{E} \|K_h * S^N(\mu) - K_h * \mu\|_p^p)^{\frac{1}{p}} \leq C_p \frac{\|K\|_p}{N^{\frac{1}{2}} h^{\frac{p-1}{p} d}} , \quad (4.38)$$

où $C_p = 2 B_p^{\frac{1}{p}}$ ne dépend que de p (voir (3.20)).

(v) Si $I(\mu)$ est fini avec pour un réel $p \geq 2$, $K \in L^p$ et $I(K)$ fini, alors

$$(\mathbb{E} \|K_h * S^N(\mu) - K_h * \mu\|^p)^{\frac{1}{p}} \leq C_{p,d} \frac{(1 + I(\mu)) \|K\|_p^{\frac{1}{2}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p} d}} , \quad (4.39)$$

où $C_{p,d} = 2^{\frac{d+3}{2}} B_p^{\frac{1}{2p}} A_d$ ne dépend que de p et d (voir (3.20) et (4.4)).

On peut noter que seule l'inégalité (4.36) requiert l'existence d'une densité pour μ . En estimation de densité, l'existence d'une densité est exigée surtout pour la majoration du terme de biais. D'autre part, on a vu au paragraphe précédent que le terme de biais est d'autant plus petit que f est régulière et que K est d'ordre grand (K oscille beaucoup). Malheureusement, les noyaux d'ordre grand ont tendance à osciller ce qui implique de grandes valeurs de b . On voit donc que la minimisation des erreurs de biais et de variance nécessite un compromis.

PREUVE DE LA PROPOSITION 4.16. L'inégalité (4.34) s'obtient directement par la loi des grands nombres et l'inégalité (4.2) du Lemme 4.1,

$$\mathbb{E}|\langle K_h * S^N(\mu) - K_h * \mu, \phi \rangle| = \mathbb{E}|\langle S^N(\mu) - \mu, K_h * \phi \rangle| \leq \frac{\|K_h * \phi\|}{\sqrt{N}} \leq \frac{1}{\sqrt{N}}.$$

Considérons maintenant l'inégalité (4.37). On note $f^{N,h}$ la densité de $K_h * S^N(\mu)$, et f^h la densité $K_h * \mu$, on a alors

$$f^{N,h}(x) = \frac{1}{N} \sum_{i=1}^N K_h(x - \xi^i), \quad \text{et} \quad f^h(x) = \int_E K_h(x - x') \mu(dx'),$$

$$\mathbb{E}[f^{N,h}(x)] = \frac{f^h(x)}{N}, \quad \text{et} \quad \mathbb{E}[f^{N,h}(x)]^2 = \frac{1}{N} \frac{d[(K_h)^2 * \mu]}{dx}(x).$$

Ainsi,

$$\begin{aligned} \mathbb{E}|f^{N,h} - f^h|^2(x) &= \frac{1}{N} \left[\frac{d[(K_h)^2 * \mu]}{dx}(x) - (f^h)^2(x) \right] \\ &= \frac{b^2}{Nh^d} \frac{d[G_h * \mu]}{dx}(x) - \frac{1}{N} (f^h)^2(x), \end{aligned} \quad (4.40)$$

où $G = \frac{K^2}{b^2}$, est une densité de probabilité. Nous obtenons alors par intégration,

$$\mathbb{E}\|f^{N,h} - f^h\|_2^2 = \frac{b^2}{Nh^d} - \frac{1}{N} \|f^h\|_2^2 = \frac{b^2}{Nh^d} + O\left(\frac{1}{N}\right) \leq \frac{b^2}{Nh^d},$$

car $\|f^h\|_2^2 \leq 2(\|K_h * f - f\|_2^2 + \|f\|_2^2) < \infty$, ce qui termine la preuve de l'inégalité (4.37).

Considérons l'inégalité (4.36). Nous supposons ici que $I(K^2)$ est fini ainsi $I(G)$ l'est aussi. Cauchy-Schwarz dans (4.40), entraîne

$$\mathbb{E}|f^{N,h} - f^h|(x) \leq \frac{b}{\sqrt{Nh^d}} \sqrt{\frac{d[G_h * \mu]}{dx}(x)}. \quad (4.41)$$

Après intégration, nous utilisons l'inégalité (4.30) du Lemme 4.14,

$$\mathbb{E}\|f^{N,h} - f^h\|_1 \leq \frac{b}{\sqrt{Nh^d}} J(G_h * \mu) \leq 2^{\frac{d}{2}} A_d \frac{b}{\sqrt{Nh^d}} [1 + I(\mu)],$$

dès que $h < (1/I(G))^{\frac{1}{d+1}}$. Pour obtenir une majoration plus précise dans le cas où μ possède la densité f , nous majorons $J(G_h * \mu) = J(G_h * f)$ par l'inégalité triangulaire, puis par

application du Lemme 4.13 nous avons

$$\begin{aligned} \mathbb{E}\|f^{N,h} - f^h\|_1 &\leq \frac{b}{\sqrt{N}h^d} [J(G_h * f - f) + J(f)] \\ &\leq \frac{b}{\sqrt{N}h^d} [J(f) + \omega(h)] , \end{aligned}$$

avec $\omega(h)$ qui tend vers zéro lorsque h tend vers zéro.

Considérons l'inégalité (4.38). Nous avons, pour tout $x \in E$,

$$\mathbb{E}|f^{N,h} - f^h|^p(x) = \mathbb{E} \left| \frac{1}{N} \sum_{i=1}^N [K_h(\xi^i - x) - f^h(x)] \right|^p .$$

D'après l'inégalité de Marcinkiewicz-Zygmund puis l'inégalité de Jensen ($\frac{p}{2} \geq 1$), nous obtenons

$$\begin{aligned} \mathbb{E}|f^{N,h} - f^h|^p(x) &\leq \frac{B_p}{N^{\frac{p}{2}}} \mathbb{E}|K_h(\xi^1 - x) - f^h(x)|^p \\ &\leq 2^{p-1} \frac{B_p}{N^{\frac{p}{2}}} [\mathbb{E}|K_h(\xi^1 - x)|^p + \mathbb{E}^p |K_h(\xi^1 - x)|] \\ &\leq 2^p \frac{B_p}{N^{\frac{p}{2}}} \frac{d[|K_h|^p * \mu]}{dx}(x) \\ \mathbb{E}\|f^{N,h} - f^h\|_p^p &\leq 2^p \frac{B_p}{N^{\frac{p}{2}}} \int_E \frac{d[|K_h|^p * \mu]}{dx}(x) dx \\ &= 2^p \frac{B_p}{N^{\frac{p}{2}} h^{(p-1)d}} \int_E |K|^p(x) dx , \end{aligned}$$

ce qui termine la preuve de l'inégalité (4.38).

Considérons enfin l'inégalité (4.39). Par simple application du Lemme 4.15 nous avons

$$(\mathbb{E}\|f^{N,h} - f^h\|_1^p)^{\frac{1}{p}} \leq 2 J(K_h * \mu)^{\frac{p-1}{p}} (\mathbb{E}\|f^{N,h} - f^h\|_p^{\frac{p}{2}})^{\frac{1}{p}} .$$

L'inégalité (4.30) du Lemme 4.14 implique que pour tout $h \leq (1/I(K))^{\frac{1}{d+1}}$,

$$(\mathbb{E}\|f^{N,h} - f^h\|_1^p)^{\frac{1}{p}} \leq 2(2^{\frac{d}{2}} A_d [1 + I(\mu)])^{\frac{p-1}{p}} (\mathbb{E}\|f^{N,h} - f^h\|_p^{\frac{p}{2}})^{\frac{1}{2p}} .$$

Enfin, l'inégalité (4.38) nous donne

$$(\mathbb{E}\|f^{N,h} - f^h\|_1^p)^{\frac{1}{p}} \leq 2^{\frac{d+2}{2}} A_d [1 + I(\mu)] \left[C_p \frac{\|K\|_p}{N^{\frac{1}{2}} h^{\frac{p-1}{p}d}} \right]^{\frac{1}{2}} .$$

□

Nous énonçons maintenant la proposition permettant de majorer le terme de variance correspondant au cas de l'estimation d'une densité corrigée du Théorème 4.8.

Proposition 4.17. *Soit μ une mesure de probabilité sur E , K un noyau de régularisation d'ordre $s \geq 1$, et Ψ une fonction positive sur E , bornée par une constante positive M , et telle que $\langle \mu, \Psi \rangle > 0$. On note $\gamma = M/\langle \mu, \Psi \rangle$.*

(i)

$$\sup_{\|\phi\|=1} \mathbb{E} |\langle K_h * (\Psi \cdot S^N(\mu)) - K_h * (\Psi \cdot \mu), \phi \rangle| \leq \frac{2}{\sqrt{N}} \gamma . \quad (4.42)$$

(ii) Si $I(\mu)$ est fini avec $K \in L^2$ et $I(K^2)$ fini, alors

$$\mathbb{E} \|K_h * (\Psi \cdot S^N(\mu)) - K_h * (\Psi \cdot \mu)\| \leq 2 A'_d \frac{(1 + I(\mu)) b}{\sqrt{N} h^d} \gamma , \quad (4.43)$$

où $A'_d = 2^{\frac{d}{2}} A_d$ ne dépend que de la dimension d (voir (4.4)).

(iii) Si $K \in L^2$, alors

$$\mathbb{E} \|K_h * (\Psi \cdot S^N(\mu)) - K_h * (\Psi \cdot \mu)\|_2^2 \leq 4 \frac{b^2}{N h^d} \frac{\langle \mu, \Psi^2 \rangle}{\langle \mu, \Psi \rangle^2} . \quad (4.44)$$

(iv) Si pour un réel $p \geq 2$, $K \in L^p$

$$(\mathbb{E} \|K_h * (\Psi \cdot S^N(\mu)) - K_h * (\Psi \cdot \mu)\|_p^p)^{\frac{1}{p}} \leq C'_p \frac{\|K\|_p}{N^{\frac{1}{2}} h^{\frac{p-1}{p} d}} \gamma^{\frac{p-1}{p}} , \quad (4.45)$$

où $C'_p = 3B_p^{\frac{1}{p}}$ ne dépend que de p (voir (3.20)).

(v) Si $I(\mu)$ est fini avec pour un réel $p \geq 2$, $K \in L^p$ et $I(K)$ fini, alors

$$(\mathbb{E} \|K_h * (\Psi \cdot S^N(\mu)) - K_h * (\Psi \cdot \mu)\|^p)^{\frac{1}{p}} \leq C'_{p,d} \frac{(1 + I(\mu)) \|K\|_p^{\frac{1}{2}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p} d}} \gamma^{\frac{p-1}{p}} , \quad (4.46)$$

où $C'_{p,d} = 2^{\frac{d+2}{2}} \sqrt{3} B_p^{\frac{1}{2p}} A_d$ ne dépend que de p et d (voir (3.20) et (4.4)).

PREUVE DE LA PROPOSITION 4.17. La preuve utilise les mêmes outils que celle de la Proposition 4.16, mais ici nous devons en plus gérer les termes de normalisation dus à la correction. La mesure empirique corrigée normalisée $K_h * (\Psi \cdot S^N(\mu))$ et la mesure empirique corrigée non normalisée $K_h * (\Psi S^N(\mu))$ ont pour densités respectives $\bar{g}^{N,h}$ et $g^{N,h}$ telles que

$$\bar{g}^{N,h}(x) = \sum_{i=1}^N K_h(x - \xi^i) \frac{\Psi(\xi^i)}{\sum_{j=1}^N \Psi(\xi^j)} , \quad \text{et} \quad g^{N,h}(x) = \frac{1}{N} \sum_{i=1}^N K_h(x - \xi^i) \Psi(\xi^i) ,$$

pour tout $x \in E$. La mesure corrigée normalisée $K_h * (\Psi \cdot \mu)$ et la mesure corrigée non normalisée $K_h * (\Psi \mu)$ ont pour densités respectives $\bar{g}^h$ et g^h telles que

$$\bar{g}^h(x) = \int_E K_h(x - x') (\Psi \cdot \mu)(dx') , \quad \text{et} \quad g^h(x) = \int_E K_h(x - x') \Psi(x') \mu(dx') ,$$

pour tout $x \in E$. La décomposition (2.4) permet de traiter les mesures non normalisées au lieu des mesures normalisées, et donne

$$(\mathbb{E} \|\bar{g}^{N,h} - \bar{g}^h\|_p^p)^{\frac{1}{p}} \leq \frac{1}{\langle \mu, \Psi \rangle} \left[(\mathbb{E} \|g^{N,h} - g^h\|_p^p)^{\frac{1}{p}} + [\mathbb{E}(|\langle \mu - S^N(\mu), \Psi \rangle|^p \|\bar{g}^{N,h}\|_p^p)]^{\frac{1}{p}} \right]. \quad (4.47)$$

Par l'inégalité de Jensen, nous pouvons déjà majorer le terme aléatoire $\|\bar{g}^{N,h}\|_p^p$ par un terme déterministe

$$\begin{aligned} \|\bar{g}^{N,h}\|_p^p &= \int_E \left| \sum_{i=1}^N K_h(x - \xi^i) \frac{\Psi(\xi^i)}{\sum_{j=1}^N \Psi(\xi^j)} \right|^p dx \\ &\leq \int_E \sum_{i=1}^N |K_h(x - \xi^i)|^p \frac{\Psi(\xi^i)}{\sum_{j=1}^N \Psi(\xi^j)} dx \\ &\leq \frac{\|K\|_p^p}{h^{(p-1)d}}, \end{aligned} \quad (4.48)$$

avec égalité pour $p = 1$ si K est positif. Considérons, dans un premier temps, le cas $p = 2$ correspondant à l'inégalité (4.44). Nous nous intéressons à l'espérance du premier terme du membre de droite de l'inégalité (4.47).

$$\begin{aligned} \mathbb{E}|g^{N,h} - g^h|^2(x) &= \frac{1}{N} \left[\frac{d[(K_h)^2 * (\Psi^2 \mu)]}{dx}(x) - (g^h)^2(x) \right] \\ &= \frac{b^2}{Nh^d} \frac{d[G_h * (\Psi^2 \mu)]}{dx}(x) - \frac{1}{N} (g^h)^2(x) \\ \mathbb{E}\|g^{N,h} - g^h\|_2^2 &\leq \frac{b^2}{Nh^d} \langle \mu, \Psi^2 \rangle. \end{aligned}$$

Pour la majoration de l'espérance du second terme du membre de droite de l'inégalité (4.47), nous utilisons la majoration (4.48), puis par la loi des grands nombres, nous avons

$$\mathbb{E}|\langle \mu - S^N(\mu), \Psi \rangle|^2 \leq \frac{\langle \mu, \Psi^2 \rangle}{N},$$

ce qui termine la preuve de l'inégalité (4.44).

Nous considérons maintenant le cas $p = 1$ correspondant à l'inégalité (4.43). Le premier terme du membre de droite de l'inégalité (4.47) se majore grossièrement ainsi,

$$\mathbb{E}\|g^{N,h} - g^h\|_1 \leq \frac{b}{\sqrt{Nh^d}} J(G_h * (\Psi^2 \mu)) \leq \frac{b}{\sqrt{Nh^d}} M J(G_h * \mu).$$

Puis nous utilisons directement l'inégalité (4.36) de la Proposition 4.16. Pour une majoration plus fine, si la mesure μ possède une densité f par rapport à la mesure de Lebesgue, nous

majorons $J(G_h * (\Psi^2 \mu))$ par inégalité triangulaire,

$$\begin{aligned} \mathbb{E} \|g^{N,h} - g^h\|_1 &= \mathbb{E} \|g^{N,h} - K_h * (\Psi f)\|_1 \\ &\leq \frac{b}{\sqrt{N}h^d} [J(\Psi^2 f) + J(G_h * (\Psi^2 f) - \Psi^2 f)] \\ &\leq \frac{b}{\sqrt{N}h^d} [J(\Psi^2 f) + M \omega(h)] , \end{aligned}$$

où nous retrouvons le même $\omega(h)$ que celui de l'inégalité (4.36) de la Proposition 4.16. Le second terme du membre de droite de l'inégalité (4.47) se majore toujours par la loi des grands nombres,

$$\mathbb{E} |\langle \mu - S^N(\mu), \Psi \rangle| \leq \frac{\langle \mu, \Psi^2 \rangle^{\frac{1}{2}}}{\sqrt{N}} ,$$

ce qui termine la preuve de l'inégalité (4.43).

Considérons le cas $p \geq 2$ correspondant à l'inégalité (4.45). Le premier terme du membre de droite de l'inégalité (4.47) se majore encore en utilisant l'inégalité de Marcinkiewicz–Zygmund,

$$\mathbb{E} \|g^{N,h} - g^h\|_p^p \leq 2^p \frac{B_p}{N^{\frac{p}{2}}} \int_E \frac{d[(K_h)^p * (\Psi^p \mu)](x)}{dx} dx = 2^p \frac{B_p}{N^{\frac{p}{2}} h^{(p-1)d}} \langle \mu, \Psi^p \rangle \|K\|_p^p .$$

Puis, nous majorons le second terme de la même manière,

$$\mathbb{E} |\langle \mu - S^N(\mu), \Psi \rangle|^p \leq \frac{B_p}{N^{\frac{p}{2}}} \langle \mu, \Psi^p \rangle .$$

Il suffit, enfin, de noter que

$$\langle \mu, \Psi^p \rangle \leq \langle \mu, \Psi \rangle M^{p-1} .$$

Considérons enfin l'inégalité (4.46). Par simple application du Lemme 4.15 et de l'inégalité (4.45) nous avons

$$(\mathbb{E} \|\bar{g}^{N,h} - \bar{g}^h\|_1^p)^{\frac{1}{p}} \leq 2 J(\bar{g}^h)^{\frac{p-1}{p}} (\mathbb{E} \|\bar{g}^{N,h} - \bar{g}^h\|_p^p)^{\frac{1}{2p}} .$$

Puis, d'après l'inégalité (4.30) du Lemme 4.14, pour $h \leq (1/I(K))^{\frac{1}{d+1}}$,

$$J(\bar{g}^h) = J(K_h * (\Psi \cdot \mu)) \leq \left[\frac{M}{\langle \mu, \Psi \rangle} \right]^{\frac{1}{2}} J(K_h * \mu) \leq 2^{\frac{d}{2}} A_d \left[\frac{M}{\langle \mu, \Psi \rangle} \right]^{\frac{1}{2}} [1 + I(\mu)] .$$

En combinant ces deux dernières inégalités, nous obtenons finalement

$$(\mathbb{E} \|\bar{g}^{N,h} - \bar{g}^h\|_1^p)^{\frac{1}{p}} \leq 2^{\frac{d+2}{2}} A_d [1 + I(\mu)] \left[C'_p \frac{\|K\|_p}{N^{\frac{1}{2}} h^{\frac{p-1}{p}d}} \right]^{\frac{1}{2}} \left[\frac{M}{\langle \mu, \Psi \rangle} \right]^{\frac{p-1}{p}} .$$

□

4.3 Choix des paramètres

Dans les deux premiers paragraphes de cette section, nous présentons brièvement les méthodes classiques utilisées pour le choix des paramètres de régularisation. Ce problème constitue un point central dans la théorie de l'estimation de densité. Néanmoins, nous ne développons pas cet aspect en détails. L'analyse des méthodes particulières régularisées au Chapitre 5 étant réalisée pour un noyau de régularisation et un facteur de dilatation fixés, non optimisés. Les résultats de cette section serviront, en fait, pour le réglage des paramètres utilisés dans les simulations présentées au Chapitre 6. Le dernier paragraphe propose une idée pour le choix du facteur de dilatation dans le cas de l'estimation d'une densité corrigée.

4.3.1 Choix optimal

Le noyau de régularisation K et le facteur de dilatation h sont choisis de sorte à minimiser l'erreur estimée, au sens du critère choisi. Dans le cadre de l'estimation de densité classique, la minimisation des estimées (4.9) pour le critère L^1 et (4.10) pour le critère L^2 , fournit respectivement

$$h_{\text{opt}}^{(1)} = \left[\frac{d}{2} \frac{b(K)}{a(K)} \frac{J(\mu)}{\|\nabla^2 f\|_1} \right]^{\frac{2}{d+4}} \frac{1}{N^{\frac{1}{d+4}}}, \quad \text{et} \quad h_{\text{opt}}^{(2)} = \left[d \frac{b(K)}{a(K)} \frac{1}{\|\nabla^2 f\|_2} \right]^{\frac{2}{d+4}} \frac{1}{N^{\frac{1}{d+4}}}. \quad (4.49)$$

Dans les deux cas, le h optimal dépend de la densité sous-jacente inconnue ce qui rend son évaluation problématique. Nous avons fait ici le choix du critère L^2 pour l'optimisation des paramètres, car il permet de mener une analyse plus simple et rapide. On note, en effet, que pour le critère L^1 , l'expression du h optimal est plus complexe puisque μ intervient au travers de la quantité $J(\mu)$, en général, difficile à évaluer. Par exemple, dans le cas où la densité sous-jacente est gaussienne de matrice de covariance unité, la quantité $\|\nabla^2 f\|_2$, est facilement calculable (fonction de la variance de f). On obtient ainsi le facteur de dilatation optimal, au sens L^2 ,

$$h_{\text{opt}}^{(2)} = A(K) N^{-\frac{1}{d+4}} \quad \text{avec} \quad A(K) = \left[d \frac{b(K)}{a(K)} \frac{(2\sqrt{\pi})^d}{\frac{d}{2} + \frac{d^2}{4}} \right]^{\frac{1}{d+4}}. \quad (4.50)$$

Le noyau optimal est obtenu par minimisation (par des méthodes de Lagrangien) de l'erreur estimée pour le facteur de dilatation optimal. La théorie de l'estimation classique (voir [99, 43]) fournit le choix optimal, parmi les noyaux radialement symétriques d'ordre deux,

$$K_{\text{opt}}(x) = \begin{cases} \frac{d+2}{2c_d} (1 - |x|^2) & \text{si } |x| < 1 \\ 0 & \text{dans le cas contraire.} \end{cases} \quad (4.51)$$

Le noyau optimal K_{opt} est appelé noyau d'Epanechnikov. On note qu'il est indépendant de la densité sous-jacente. Pour ce choix de noyau, si la densité sous-jacente est gaussienne de matrice de covariance unité, le facteur de dilatation optimal est

$$h_{\text{opt}} = A(K) N^{-\frac{1}{d+4}} \quad \text{avec} \quad A(K) = [8 c_d^{-1} (d+4) (2\sqrt{\pi})^d]^{\frac{1}{d+4}}, \quad (4.52)$$

où c_d est le volume de la sphère unité de $\mathbb{R}^d$. Pour réduire le temps de calcul dû à la simulation du noyau d'Epanechnikov, on peut choisir d'utiliser le noyau gaussien. Dans ce cas, le facteur de dilatation optimal (toujours sous l'hypothèse d'une densité sous-jacente gaussienne de matrice de covariance unité) est

$$h_{\text{opt}} = A(K) N^{-\frac{1}{d+4}} \quad \text{avec} \quad A(K) = (4/(d+2))^{\frac{1}{d+4}}. \quad (4.53)$$

On montre, en fait, que le choix du noyau n'a pas une grande influence sur l'erreur commise. Pour cette raison, il sera plutôt choisi pour sa rapidité de simulation que pour son optimalité. Par contre, le choix de h est déterminant pour le comportement de l'estimée. Un h petit rendra l'estimée irrégulière (à la limite une somme de Dirac) tandis qu'un h trop grand donnera une estimée trop lisse, i.e. trop biaisée pour faire apparaître les irrégularités (comme par exemple le caractère multimodal) de la densité sous-jacente. L'importance du choix du facteur de dilatation justifie les nombreux travaux récents proposant des méthodes plus ou moins sophistiquées fournissant un h fonction de l'échantillon.

4.3.2 Choix empirique

Le but n'est pas ici de proposer de nouvelles méthodes pour le choix du facteur de dilatation. La littérature sur ce sujet est déjà très riche et active. On peut néanmoins distinguer quatre approches dominantes.

- Minimisation non paramétrique de l'erreur estimée (“non parametric plug-in method”). Elle a été initialement proposée pour le critère L^2 , par Woodroffe [104]. Il s'agit d'estimer $\|\nabla^2 f\|_2$, de façon non paramétrique, directement à partir de l'échantillon.
- Minimisation paramétrique de l'erreur estimée (“parametric plug-in method”). Elle a été initialement proposée pour le critère L^2 , par Deheuvels [29]. On suppose que f fait partie d'une certaine famille paramétrique de densités. Puis, sous cette hypothèse paramétrique, on exprime $\|\nabla^2 f\|_2$ en fonction d'un paramètre facile à estimer à partir de l'échantillon (par exemple la variance pour l'hypothèse gaussienne).
- Technique de validation croisée (“ L^2 -cross validation”). Elle a été développée pour le critère L^2 , par Rudemo [98]. On construit un estimateur non biaisé de l'erreur quadratique en fonction de l'échantillon. Puis, h est choisi de sorte à minimiser cet estimateur. Hall [51] montre que ce choix est asymptotiquement ($N \rightarrow \infty$) optimal lorsque la densité sous-jacente est bornée.
- Méthode des deux noyaux (“double kernel method”). Elle a été développée pour le critère L^1 , par Devroye [44]. On construit, à partir de l'échantillon, deux estimations par noyaux, avec le même facteur de dilatation mais des noyaux de régularisation différents. Puis, h est choisi de sorte à minimiser la distance moyenne au sens L^1 entre ces deux densités. Devroye [44] montre que l'estimée obtenue, avec ce facteur de dilatation, converge en moyenne au sens L^1 , vers la densité sous-jacente (sans condition sur celle-ci).

Pour chacune de ces approches, il existe plusieurs variantes. On peut se reporter à l'excellent récapitulatif de Berlinet et Devroye [10], où les différentes méthodes sont comparées du point

de vue théorique et pratique. On note que seules les méthodes de “plug-in” consistent à minimiser les estimations d’erreur au sens L^1 ou L^2 présentées au Théorème 4.6. Les deux autres techniques présentées, méthodes des deux noyaux et de la validation croisée, n’utilisent pas ces bornes d’erreurs, mais leur coût de calcul est rédhibitoire pour les applications en temps réel. Cependant, il faut souligner que ces deux dernières méthodes sont les seules à avoir des justifications théoriques solides.

Pour bien souligner la dépendance du facteur de dilatation à l’échantillon, nous le notons, par la suite, h_{emp} (pour h empirique). Les résultats théoriques obtenus sont, en général, basés sur le théorème de Devroye [43, p. 38] qui montre un résultat assez général de convergence lorsqu’un facteur de dilatation empirique est utilisé :

Théorème 4.18 (Devroye [43]). *Soit K une densité de probabilité. Si le facteur de dilatation empirique, h_{emp} , vérifie*

$$(i) \lim_{N \rightarrow \infty} h_{\text{emp}} = 0 \text{ en probabilité (resp. } \mathbb{P}\text{-p.s.)}$$

$$(ii) \lim_{N \rightarrow \infty} N h_{\text{emp}}^d = \infty \text{ en probabilité (resp. } \mathbb{P}\text{-p.s.)}$$

alors,

$$\lim_{N \rightarrow \infty} \|f^{N, h_{\text{emp}}} - f\|_1 = 0, \quad \text{en probabilité (resp. } \mathbb{P}\text{-p.s.)} . \quad (4.54)$$

Dans les simulations présentées au Chapitre 6, les contraintes de temps réel nous imposent d’utiliser le choix de h le moins coûteux en temps de calcul. Nous utilisons donc la technique de minimisation paramétrique de l’erreur estimée. Dans le cas général d’une densité sous-jacente arbitraire f , deux approximations sont faites pour le calcul du facteur de dilatation (suivant la démarche proposée par Silverman [99]). On suppose que la densité f est gaussienne, et que sa matrice de covariance S , est égale à la matrice de covariance empirique de l’échantillon, $(\xi^1, \dots, \xi^N)$ issu de f . On applique alors une transformation linéaire sur l’échantillon pour se ramener au cas simple d’une densité gaussienne réduite. Cette opération, appelée blanchiment consiste à changer chaque point de l’échantillon, ξ^i , en $A^{-1} \xi^i$, où $AA^T = S$. On obtient ainsi un nouveau système de particules de matrice de covariance unité. Dans ce cas, le facteur de dilatation optimal est donné directement par (4.52) ou (4.53) suivant qu’on utilise le noyau d’Epanechnikov ou le noyau gaussien. Toutes ces manipulations peuvent se résumer à l’utilisation du noyau,

$$x \mapsto \frac{(\det A)^{-1}}{h^d} K\left(\frac{1}{h} A^{-1} x\right) . \quad (4.55)$$

Pour traiter les cas de densités multimodales, Silverman conseille de choisir un facteur de dilatation plus petit $h = h_{\text{opt}}/2$, (voir [99] Figure 3.3).

Remarque 4.19. Pour générer suivant le noyau d’Epanechnikov (4.51) il suffit de générer $\sqrt{\beta}T$, où β suit une loi beta de paramètres $(d/2, 2)$, et T est uniformément distribué sur la sphère unité de $\mathbb{R}^d$, voir [45, pp. 236–237].

4.3.3 Le cas d'une densité corrigée

Pour ce qui concerne l'estimation de densité corrigée, le problème du choix du facteur de dilatation empirique n'ayant pas été abordé dans la littérature, nous proposons une extension simple des idées du paragraphe précédent. Les inégalités (4.28) et (4.44) fournissent l'estimation d'erreur suivante, lorsque le noyau de régularisation est radialement symétrique et d'ordre deux.

$$\mathbb{E}\|K_h * (\Psi \cdot S^N(\mu)) - \Psi \cdot \mu\|_2^2 \leq h^4 \frac{a^2}{4} \|\nabla^2(\Psi \cdot f)\|_2^2 + 4 \frac{b^2}{Nh^d} \frac{\langle \mu, \Psi^2 \rangle}{\langle \mu, \Psi \rangle^2} + o(h^4) . \quad (4.56)$$

Le h optimal obtenu en minimisant cette estimation d'erreur est

$$\tilde{h}_{\text{opt}}^{(2)} = \left[2d \frac{b(K)}{a(K)} \frac{1}{\|\nabla^2(\Psi \cdot f)\|_2} \right]^{\frac{2}{d+4}} \frac{1}{\tilde{N}^{\frac{1}{d+4}}} , \quad \text{avec} \quad \tilde{N} = \frac{\langle \mu, \Psi \rangle^2}{\langle \mu, \Psi^2 \rangle} N . \quad (4.57)$$

Dans le cas de l'estimation classique de densité ($\Psi = Cte$), on obtient $\tilde{h}_{\text{opt}}^{(2)} = 2^{\frac{2}{d+4}} h_{\text{opt}}^{(2)}$ puisqu'alors $\tilde{N} = N$ et $\|\nabla^2(\Psi \cdot f)\|_2 = \|\nabla^2 f\|_2$. Ce choix sous optimal est dû aux erreurs supplémentaires de dénormalisation. Dans le cas où Ψ se concentre dans une zone restreinte de l'espace, $\tilde{N} \ll N$. $\tilde{N}$ s'interprète comme le nombre nécessaire de particules issus de la mesure corrigée $\Psi \cdot \mu$ pour fournir une estimation classique par noyaux $K_h * S^{\tilde{N}}(\Psi \cdot \mu)$ de même précision que l'estimation $K_h * (\Psi \cdot S^N(\mu))$ basée sur un échantillon de taille N de la mesure a priori μ . Un échantillon directement issu de $\Psi \cdot \mu$ est clairement plus efficace qu'un échantillon issu de μ , pour estimer $\Psi \cdot \mu$. Il est donc naturel d'avoir $\tilde{N} \leq N$.

Pour approcher $\tilde{h}_{\text{opt}}^{(2)}$ de manière empirique, on propose de réutiliser le principe proposé dans le cas classique d'estimation de densité. On se ramène au cas classique (4.49) en utilisant l'approximation suivante, dans (4.57).

$$\tilde{N} \approx \frac{1}{\sum_{i=1}^N \omega^{i2}} , \quad \text{avec} \quad \omega^i = \frac{\Psi(\xi^i)}{\sum_{j=1}^N \Psi(\xi^j)} .$$

On suppose que $\Psi \cdot f$ est gaussienne et que sa matrice de covariance S , est égale à la matrice de covariance empirique de la mesure de dirac pondérée, $\sum_{i=1}^N \omega^i \delta_{\xi^i}$. On applique alors une transformation linéaire sur l'échantillon pour se ramener au cas simple d'une densité gaussienne réduite. La suite de la procédure est exactement semblable à celle décrite, dans le cadre de l'estimation de densité classique.

Conclusion du Chapitre 4

On a vu au Chapitre 3 que le caractère instable du filtre particulaire avec interaction était essentiellement dû à la nature discrète de l'approximation fournie. En d'autres termes, cette instabilité était le fait d'un contrôle trop faible de l'erreur locale induite : erreur d'échantillonnage contrôlée par la loi des grands nombres au sens faible. L'objectif de ce chapitre était de fournir une alternative à ce type d'approximations locales faibles qui serait toujours basée sur la donnée d'un échantillon (méthode particulaire) mais qui cette fois-ci permettrait un contrôle de l'erreur au sens fort. Cette idée suppose, il est vrai, quelques hypothèses supplémentaires sur la régularité de la mesure recherchée, mais en réduisant ainsi l'espace de recherche, elle permet de fournir une estimée plus précise de la densité recherchée.

La théorie de l'estimation de densité par noyaux semblait un outil naturel pour le développement d'une telle alternative. Ce chapitre a donc consisté à présenter et à étendre les résultats classiques en estimation de densité dans le but d'utiliser ces techniques en filtrage particulaire.

Nous avons d'abord élargi le contexte classique de l'estimation de densité au cas plus général (rencontré en filtrage) où la densité à estimer est la correction d'une densité dont on connaît un échantillon. Nous avons proposé deux méthodes différentes pour résoudre ce problème.

Pré-régularisation : régulariser la mesure empirique associée à l'échantillon a priori avant d'opérer la correction. Cette méthode donnera lieu au filtre particulaire pré-régularisé présenté au chapitre suivant.

Post-régularisation : régulariser la mesure discrète pondérée obtenue après la correction de l'échantillon. Cette méthode donnera lieu au filtre particulaire post-régularisé présenté aussi au chapitre suivant.

Dans le cadre classique de l'estimation de densité par noyaux, de nouvelles majorations de l'erreur au sens L^p ont été développées. Nous avons ainsi obtenu des vitesses de convergence p.s. de l'estimée régularisée vers la densité recherchée valables pour une plus grande classe de noyaux que le résultat de Devroye énoncé au Corollaire 4.10. Les vitesses obtenues sont en contrepartie moins bonnes.

L'étude réalisée dans le cadre classique a ensuite été étendue au contexte plus général que nous avons défini. Les estimations d'erreur établies seront essentielles pour évaluer les performances des filtres particuliers régularisés qui feront l'objet du chapitre suivant.

Le problème de l'optimisation des paramètres de régularisation a été abordé brièvement dans la dernière section. Bien que ce choix optimal ne soit pas pris en compte dans l'étude des filtres particuliers régularisés réalisée au chapitre suivant, il est clair qu'il constitue un point déterminant pour les performances du filtre. Nous utiliserons donc les suggestions de cette dernière section pour les applications présentées au Chapitre 6.

Il reste maintenant à exploiter les fruits de ce chapitre pour le développement de nouveaux algorithmes de filtrage particulaire.

Chapitre 5

Filtres particuliers régularisés

L'idée essentielle des méthodes particulières régularisées est de changer l'approximation discrète π_n^N fournie par le filtre particulier avec interaction en une approximation continue, de telle sorte que l'étape d'échantillonnage consiste à simuler une loi absolument continue, produisant ainsi, un nouveau système de particules avec N valeurs différentes. Cette approche suppose implicitement que le filtre optimal π_n possède une densité lisse ce qui est le cas dans la plupart des applications (comme par exemple en pistage). D'un point de vue théorique, cette hypothèse supplémentaire permet d'obtenir des approximations du filtre optimal au sens fort (L^p pour $p \geq 1$). De plus, les bornes d'erreurs obtenues sont plus stables dans le temps sous des hypothèses moins contraignantes que celles requises en général pour l'IPF. Du point de vue pratique, cette approche conduit à des filtres dont le comportement (en simulations) est plus stable au cours du temps que l'IPF.

Dans la première section de ce chapitre, nous présentons les filtres particuliers pré-régularisé et post-régularisé obtenus en introduisant la régularisation avant ou après l'étape de correction. Nous analysons ensuite la vitesse de convergence de ces algorithmes pour des systèmes assez généraux. La deuxième section est consacrée plus particulièrement aux systèmes à dynamique mélangeante. Nous montrons dans ce cas, la convergence uniforme des filtres particuliers régularisés. Les hypothèses conditionnant ces résultats sont discutées et relâchées, dans la troisième section. Dans la quatrième section, nous présentons un point de vue plus général sur la régularisation. Les méthodes particulières régularisées sont rattachées à une classe plus large de méthodes d'approximation consistant en une première étape de robustification puis en une seconde étape d'approximation locale des transitions du filtre optimal. Enfin, dans la cinquième section, nous proposons une heuristique appelée correction progressive, pour gérer tout particulièrement le cas difficile du faible bruit d'observation. L'idée est de décomposer la correction en plusieurs étapes de sous-corrrections pour lesquelles la propagation de l'erreur est bien contrôlée. Le système de particules résultant suit une évolution adaptative, où le nombre de sous-corrrections est déterminé par la précision de l'observation.

5.1 Analyse générale

5.1.1 Filtre particulaire pré-régularisé

Une première analyse du filtre particulaire pré-régularisé (pré-RPF) fut développée dans [73]. Nous choisissons ici, d'approcher la mesure corrigée $\Psi \cdot \mu$ par la mesure à densité $\Psi \cdot (K_h * S^N(\mu))$, selon la première méthode proposée dans le Chapitre 4. Le filtre particulaire résultant est noté $\pi_n^{N,h}$ et appelé filtre particulaire pré-régularisé car l'étape de régularisation est réalisée avant l'étape de correction. On note que Hürzeler [55] et Hürzeler et Künsch [56] ont développé un algorithme très voisin indépendamment de notre travail sous le nom de Kernel Filter.

Description du filtre

Le filtre particulaire pré-régularisé est initialisé à la valeur $\pi_0^{N,h} = \pi_0$, puis le passage de $\pi_{n-1}^{N,h}$ à $\pi_n^{N,h}$ se déroule en trois étapes

$$\begin{aligned} \pi_{n-1}^{N,h} &\xrightarrow[\substack{\text{Prédiction} \\ \text{échantillonnée}}]{(1)} \pi_{n|n-1}^{N,h} = S^N(Q_n \pi_{n-1}^{N,h}) \xrightarrow[\text{Régularisation}]{(2)} \nu_{n|n-1}^{N,h} = K_h * \pi_{n|n-1}^{N,h} \\ &\xrightarrow[\text{Correction}]{(3)} \pi_n^{N,h} = \Psi_n \cdot \nu_{n|n-1}^{N,h} . \end{aligned} \quad (5.1)$$

Ici, la phase d'échantillonnage dans l'étape de la prédiction échantillonnée devient, en général, relativement coûteuse à mettre en œuvre puisqu'elle demande l'exécution de l'algorithme d'acceptation / rejet suivant, (voir Annexe) :

indépendamment pour chaque i

- (i) Générer I uniformément dans $\{1, \dots, N\}$.
- (ii) Générer $\varepsilon \sim K$, noyau d'Epanechnikov (4.51) ou gaussien, et U uniformément dans $[0, 1]$.
- (iii) Poser $X = \xi_{n|n-1}^I + h \Gamma_n \varepsilon$, avec $h = h_{\text{opt}}$ donné par (4.52) ou (4.53). Si la technique de blanchiment est utilisée, $\Gamma_n = A_n$ la racine carrée de la matrice de covariance empirique, voir (4.55), sinon $\Gamma_n = I$.
- (iv) Si $\Psi_n(X) > U M_n$, poser $\xi_n^i = X$, sinon retourner à l'étape (i). ($M_n = \|\Psi_n\|$).

Cet algorithme requiert en moyenne $N M_n / \langle Q_n \pi_{n-1}^{N,h}, \Psi_n \rangle \leq N \gamma_n$ itérations pour générer N v.a. suivant $\pi_n^{N,h}$.

Remarque 5.1. Il faut noter que des méthodes efficaces ont été développées pour accélérer le temps d'implémentation du pré-RPF. Notamment le Kernel Filter développé par Hürzeler et Künsch [56] propose d'utiliser un noyau de régularisation à support compact (par exemple le noyau d'Epanechnikov) de sorte à ne plus faire intervenir, dans l'algorithme de rejet, le

maximum global $\|\Psi_n\|$, de la fonction de vraisemblance, mais les maxima locaux c_n^i de la fonction de vraisemblance sur le support du noyau centré en la particule i , i.e.

$$c_n^i = \sup\{ \Psi_n(x) \mid K_h(x - \xi_{n|n-1}^i) > 0 \} .$$

L'algorithme de rejet résultant est le suivant :

indépendamment pour chaque i

- (i) Générer I dans $\{1, \dots, N\}$ avec $\mathbb{P}[I = j] = c_n^j / \sum_{l=1}^N c_n^l$.
- (ii) Générer $\varepsilon \sim K$, noyau d'Epanechnikov (4.51) et U uniformément dans $[0, 1]$.
- (iii) Poser $X = \xi_{n|n-1}^I + h \Gamma_n \varepsilon$, avec $h = h_{\text{opt}}$ donné par (4.52). Si la technique de blanchiment est utilisée, $\Gamma_n = A_n$ la racine carrée de la matrice de covariance empirique, voir (4.55), sinon $\Gamma_n = I$.
- (iv) Si $\Psi_n(X) > U c_n^I$, poser $\xi_n^i = X$, sinon retourner à l'étape (i).

Cette procédure judicieuse permet de réduire sensiblement le temps de calcul, qui est en moyenne $\frac{1}{N} \sum_{i=1}^N c_n^i / \max_{1 \leq k \leq N} c_n^k$ fois moins long que pour le rejet classique.

Une amélioration du Kernel Filter est développée par Musso [82, 81] elle permet encore de diminuer le temps de calcul en réalisant un compromis entre précision et temps de calcul de l'algorithme. L'algorithme obtenu (Local Rejection Particle Filter, L2RPF) est performant et satisfait aux contraintes de temps réel (voir Chapitre 6).

Majoration de l'erreur

On vérifie, avant tout, que le pré-RPF vérifie bien la propriété (2.35), i.e. que pour toute fonction mesurable et bornée F définie sur $\mathcal{P}(E)$,

$$\mathbb{E}[F(\pi_k^{N,h}) \mid Y_{1:n}] = \mathbb{E}[F(\pi_k^{N,h}) \mid Y_{1:k}] ,$$

de sorte à pouvoir appliquer les résultats de stabilité du Chapitre 2.

Nous introduisons quelques notations supplémentaires.

- On note respectivement Q_n^h et R_n^h le noyau perturbé et l'opérateur d'évolution perturbé, définis respectivement, par

$$\begin{aligned} Q_n^h(x, dx') &= \int_E Q_n(x, du) K_h(x' - u) dx' , \quad \text{et} \\ R_n^h(x, dx') &= \int_E Q_n(x, du) K_h(x' - u) \Psi_n(x') dx' , \end{aligned} \tag{5.2}$$

pour tout $x, x' \in E$. L'opérateur intégral associé au noyau Q_n^h agit sur les mesures $\mu \in \mathcal{M}^+(E)$, de la manière suivante,

$$Q_n^h \mu = K_h * (Q_n \mu) .$$

- Lorsque le moment d'ordre $d+1$ de $Q_k \pi_{k-1}^{N,h}$ existe, on note $\bar{I}_k$ sa moyenne conditionnelle aux observations, i.e.

$$\bar{I}_k = \mathbb{E}[I(Q_k \pi_{k-1}^{N,h}) | Y_{1:k-1}] .$$

Nous introduisons des hypothèses de régularité sur le filtre optimal π_k et le noyau de transition Q_k .

Hypothèse $[\Pi']$: $\pi_{k|k-1}$ est a.c. par rapport à la mesure de Lebesgue avec la densité $f_{k|k-1} = \frac{d\pi_{k|k-1}}{dx} \in W^{2,p}$ telle qu'il existe une v.a. $D_k > 0$ mesurable par rapport aux observations $Y_{1:k-1}$ vérifiant

$$|f_{k|k-1}|_{2,p} \leq D_k .$$

Hypothèse $[\mathbf{Q}']$: Pour tout $x \in E$, $Q_k(x, \cdot)$ est a.c. par rapport à la mesure de Lebesgue avec la densité $q_k(x, \cdot) \in W^{2,p}$ telle qu'il existe une constante $D_k > 0$ vérifiant

$$|q_k(x, \cdot)|_{2,p} \leq D_k ,$$

pour tout $x \in E$.

Hypothèse $[\mathbf{Q}_I]$:

$$I_k = \sup_{x \in E} I(Q_k(x, \cdot)) < \infty .$$

pour tout $x \in E$.

Remarque 5.2. Si l'Hypothèse $[\mathbf{Q}']$ est vérifiée pour un réel $p \geq 1$, alors pour toute mesure de probabilité μ , $Q_k \mu$ est a.c. par rapport à la mesure de Lebesgue et

$$|\frac{dQ_k \mu}{dx}|_{2,p} = |\int_E \mu(dx) q_k(x, \cdot)|_{2,p} \leq \sup_{x \in E} |q_k(x, \cdot)|_{2,p} \leq D_k . \quad (5.3)$$

En particulier, l'Hypothèse $[\mathbf{Q}']$ implique l'Hypothèse $[\Pi']$. Dans les Hypothèse $[\mathbf{Q}']$ et $[\Pi']$, la définition de la constante D_k est différente. Dans la suite, toute ambiguïté est levée, car nous précisons à chaque apparition de D_k , l'hypothèse à laquelle la constante est rattachée.

Si le noyau de transition Q_k est mélangeant, et que le moment d'ordre $d+1$ du filtre de prédiction, $I(\pi_{k|k-1})$, est fini alors l'Hypothèse $[\mathbf{Q}_I]$ est automatiquement vérifiée. En effet,

$$I_k \leq \frac{1}{\varepsilon_k} I(\lambda_k) \leq \frac{1}{\varepsilon_k^2} I(\pi_{k|k-1}) . \quad (5.4)$$

Si l'Hypothèse $[\mathbf{Q}_I]$ est vérifiée alors

$$\bar{I}_k = \mathbb{E}[I(Q_k \pi_{k-1}^{N,h}) | Y_{1:k-1}] \leq I_k < \infty .$$

Nous rappelons que pour tout réel $n \geq 1$, $\beta_n = \beta(Q_n)$ le taux de contraction du noyau markovien Q_n pour la variation totale et que pour toute suite de réels $(u_k)_{k \geq 1}$, nous notons $u_n^{\max} = \max_{1 \leq k \leq n} u_k$. Nous énonçons d'abord les résultats de convergence faible du filtre pré-régularisé.

Proposition 5.3. *Soit K un noyau de régularisation d'ordre deux.*

(i) *Si pour tout entier $k \geq 1$, les Hypothèses $[\mathbf{Q}'][\mathbf{Q}\Psi]$ sont vérifiées pour $p = 1$, alors*

$$\sup_{\|\phi\|=1} \mathbb{E}[\langle \pi_n - \pi_n^{N,h}, \phi \rangle | Y_{1:n}] \leq 2 \left[h^2 a_2 D_n^{\max} + \frac{1}{\sqrt{N}} \right] \sum_{k=1}^n \beta_{n:k+1} \gamma_{n:k} . \quad (5.5)$$

(ii) *Si pour tout entier $k \geq 1$, les Hypothèses $[\Pi'][\mathbf{Q}_d][\mathbf{Q}\Psi]$ sont vérifiées pour $p = 1$, alors*

$$\sup_{\|\phi\|=1} \mathbb{E}[\langle \pi_n - \pi_n^{N,h}, \phi \rangle | Y_{1:n}] \leq 2 \left[h^2 a_2 D_n^{\max} + \frac{2}{\sqrt{N}} \right] \sum_{k=2}^{n+1} \beta_{n:k+1} \bar{\gamma}_{n:k} \gamma_{k-1} c_k . \quad (5.6)$$

On retrouve, ici, l'équivalent des estimations d'erreur, au sens faible, (3.23) et (3.25), obtenues pour l'IPF. L'ordre de la vitesse de convergence est optimal, en $O(1/\sqrt{N})$, si $h^2 = O(1/\sqrt{N})$. Malheureusement, comme pour l'IPF, ces résultats ne sont valables que sous l'Hypothèse $[\mathbf{Q}\Psi]$ et si $[\mathbf{Q}_d]$ n'est pas vérifiée, on constate que l'erreur se propage relativement mal, au travers des coefficients produit $\gamma_{n:k} \geq \bar{\gamma}_{n:k}$.

Remarque 5.4. De la même manière que pour l'IPF, lorsque l'Hypothèse $[\mathbf{Q}_d]$ est vérifiée, à l'inégalité (5.6), on peut penser à faire varier le nombre de particules de sorte à se débarrasser de l'Hypothèse $[\mathbf{Q}\Psi]$ sur la vraisemblance. Malheureusement, il ne suffit plus ici d'évaluer pour chaque particule la quantité $\Psi_k(\xi_{k|k-1}^i)$, mais l'intégrale,

$$\int_E K_h(x - \xi_{k|k-1}^i) \Psi_k(x) dx .$$

Ce calcul est, en général, assez coûteux, et rend l'idée du nombre aléatoire de particules inutilisable pour le pré-RPF.

PREUVE DE LA PROPOSITION 5.3. La preuve de l'inégalité (5.5) s'obtient en utilisant le raisonnement de la Proposition 2.35,

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[\langle \pi_n^{N,h} - \pi_n, \phi \rangle | Y_{1:n}] &\leq \sum_{k=1}^n \sup_{\|\phi\|=1} \mathbb{E}[\langle \bar{R}_{n:k+1}(\pi_k^{N,h}) - \bar{R}_{n:k+1} \circ \bar{R}_k(\pi_{k-1}^{N,h}), \phi \rangle | Y_{1:n}] \\ &\leq 2 \sum_{k=1}^n \beta_{n:k+1} \frac{M_{n:k}}{m_{n:k}} d_k \end{aligned}$$

avec l'erreur locale

$$d_k = \sup_{\|\phi\|=1} \mathbb{E}[\langle K_h * S^N(Q_k \pi_{k-1}^{N,h}) - Q_k \pi_{k-1}^{N,h}, \phi \rangle | Y_{1:k-1}]$$

D'après l'inégalité (5.3) de la Remarque 5.2, on a

$$\left| \frac{dQ_k \pi_{k-1}^{N,h}}{dx} \right|_{2,p} \leq D_k .$$

En appliquant l'inégalité (4.11) du Théorème 4.7, on obtient

$$d_k \leq h^2 a_2 D_k + \frac{1}{\sqrt{N}} .$$

Ce qui finalement entraîne

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n^{N,h} - \pi_n, \phi \rangle| | Y_{1:n}] \leq 2 \sum_{k=1}^n \beta_{n,k+1} \gamma_{n,k} [h^2 a_2 D_k + \frac{1}{\sqrt{N}}] .$$

Considérons l'inégalité (5.6). On utilise l'idée de la preuve de l'inégalité (2.52), mais on opère ici une décomposition de l'erreur différente. Nous dénormalisons l'erreur suivant l'inégalité (2.3) du Lemme 2.8, puis nous la décomposons en termes d'erreur locale de régularisation (biais et variance) et d'erreur globale transportée. Nous obtenons

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi_n^{N,h}, \phi \rangle| | Y_{1:n}] &= \sup_{\|\phi\|=1} \mathbb{E}[|\langle \Psi_n \cdot (Q_n \pi_{n-1}) - \Psi_n \cdot (K_h * S^N(Q_n \pi_{n-1}^{N,h})), \phi \rangle| | Y_{1:n}] \\ &\leq 2\bar{\gamma}_n \|Q_n \pi_{n-1} - Q_n^h \pi_{n-1}\| \\ &\quad + 2\bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle Q_n^h \pi_{n-1} - Q_n^h \pi_{n-1}^{N,h}, \phi \rangle| | Y_{1:n-1}] \\ &\quad + 2\bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle Q_n^h \pi_{n-1}^{N,h} - K_h * S^N(Q_n \pi_{n-1}^{N,h}), \phi \rangle| | Y_{1:n-1}] \end{aligned} \tag{5.7}$$

Le terme de variance (dernier terme du membre de droite), est majoré grâce à l'inégalité (4.42) de la Proposition 4.17. Le terme de biais (premier terme du membre de droite), est majoré grâce à l'inégalité (4.27) de la Proposition 4.12, sachant que l'Hypothèse $[\Pi']$ garantit

$$\left| \frac{dQ_n \pi_{n-1}}{dx} \right|_{2,p} \leq D_n .$$

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \pi_n^{N,h}, \phi \rangle| | Y_{1:n}] \leq 2\bar{\gamma}_n [h^2 a_2 D_n + \frac{1}{\sqrt{N}} + \mathbb{E}[\|Q_n^h \pi_{n-1} - Q_n^h \pi_{n-1}^{N,h}\| | Y_{1:n-1}]] . \tag{5.8}$$

Le terme d'erreur en variation totale du membre de droite se majore par récurrence.

$$\begin{aligned} \mathbb{E}[\|Q_n^h \pi_{n-1} - Q_n^h \pi_{n-1}^{N,h}\| | Y_{1:n-1}] &\leq \mathbb{E}[\|Q_n^h \bar{R}_{n-1}(\pi_{n-2}) - Q_n^h \bar{R}_{n-1}(\pi_{n-2}^{N,h})\| | Y_{1:n-1}] \\ &\quad + \mathbb{E}[\|Q_n^h \bar{R}_{n-1}(\pi_{n-2}^{N,h}) - Q_n^h \pi_{n-1}^{N,h}\| | Y_{1:n-1}] . \end{aligned} \tag{5.9}$$

L'intérêt de s'être placé sous la variation totale est de pouvoir utiliser l'inégalité (2.8) du Lemme 2.8 pour dénormaliser le premier terme du membre de droite sans introduire un facteur 2.

$$\begin{aligned} \mathbb{E}[\|Q_n^h \bar{R}_{n-1}(\pi_{n-2}) - Q_n^h \bar{R}_{n-1}^h(\pi_{n-2}^{N,h})\| \mid Y_{1:n-1}] &\leq \beta_n \bar{\gamma}_{n-1} \mathbb{E}[\|Q_{n-1} \pi_{n-2} - Q_{n-1}^h \pi_{n-2}^{N,h}\| \mid Y_{1:n-2}] \\ &\leq \beta_n \bar{\gamma}_{n-1} h^2 a_2 D_{n-1} \\ &\quad + \beta_n \bar{\gamma}_{n-1} \mathbb{E}[\|Q_{n-1}^h \pi_{n-2} - Q_{n-1}^h \pi_{n-2}^{N,h}\| \mid Y_{1:n-2}]. \end{aligned}$$

Pour majorer le second terme du membre de droite de (5.9) nous utilisons le Lemme 2.31 qui permet de majorer l'erreur en variation totale transportée par Q_n (dominé) par l'erreur faible comme suit.

$$\begin{aligned} \mathbb{E}[\|Q_n^h \bar{R}_{n-1}^h(\pi_{n-2}^{N,h}) - Q_n^h \pi_{n-1}^{N,h}\| \mid Y_{1:n-1}] &\leq c_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle \bar{R}_{n-1}^h(\pi_{n-2}^{N,h}) - \pi_{n-1}^{N,h}, \phi \rangle| \mid Y_{1:n-1}] \\ &\leq 2 c_n \frac{\gamma_{n-1}}{\sqrt{N}}. \end{aligned}$$

En injectant les deux majorations précédentes dans (5.9), nous obtenons

$$\begin{aligned} \mathbb{E}[\|Q_n^h \pi_{n-1} - Q_n^h \pi_{n-1}^{N,h}\| \mid Y_{1:n-1}] &\leq \beta_n \bar{\gamma}_{n-1} [h^2 a_2 D_{n-1} + \mathbb{E}[\|Q_{n-1}^h \pi_{n-2} - Q_{n-1}^h \pi_{n-2}^{N,h}\| \mid Y_{1:n-2}]] \\ &\quad + 2 c_n \frac{\gamma_{n-1}}{\sqrt{N}} \\ &\leq 2 \sum_{k=2}^n \beta_{n:k+1} \bar{\gamma}_{n-1:k} \left[\frac{\gamma_{k-1}}{\sqrt{N}} c_k + \frac{1}{2} \bar{\gamma}_{k-1} \beta_k h^2 a_2 D_{k-1} \right]. \end{aligned}$$

Cette dernière inégalité avec (5.8) entraîne l'inégalité (5.6). $\square$

Nous énonçons les résultats principaux de cette section, concernant la convergence en variation totale du filtre pré-régularisé.

Théorème 5.5. *Soit K un noyau de régularisation d'ordre deux.*

- (i) *Si pour tout entier $1 \leq k \leq n$, les Hypothèses $[\mathbf{Q}_I][\Pi']$ sont vérifiées pour $p = 1$ et $K \in L^2$ avec $I(K^2)$ fini, alors*

$$\mathbb{E}[\|\pi_n - \pi_n^{N,h}\| \mid Y_{1:n}] \leq [h^2 a_2 D_n^{max} + A'_d \frac{(1 + I_n^{max}) b}{\sqrt{N} h^d}] \sum_{k=1}^n \beta_{n:k} \bar{\gamma}_{n:k}, \quad (5.10)$$

où A'_d ne dépend que de d .

- (ii) *Si pour tout entier $1 \leq k \leq n$, les Hypothèses $[\mathbf{Q}_I][\Pi']$ sont vérifiées pour $p = 1$, et si pour un réel $p \geq 2$, $K \in L^p$ avec $I(K)$ fini, alors*

$$(\mathbb{E}[\|\pi_n - \pi_n^{N,h}\|^p \mid Y_{1:n}])^{\frac{1}{p}} \leq 2 [h^2 a_2 D_n^{max} + C_{p,d} \frac{(1 + I_n^{max}) \|K\|_p^{\frac{1}{2}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p} d}}] \sum_{k=1}^n \beta_{n:k} \bar{\gamma}_{n:k}, \quad (5.11)$$

où $C_{p,d} = 2^{\frac{d+3}{2}} B_p^{\frac{1}{2p}} A_d$ ne dépend que de p et d (voir (3.20) et (4.4)).

Ce théorème montre que si l'on remplace l'Hypothèse $[\mathbf{Q}\Psi]$ sur la vraisemblance et le noyau par l'Hypothèse $[\mathbf{Q}\mathbf{I}]$ sur le noyau, le pré-RPF a, contrairement à l'IPF, l'avantage de conserver de bonnes propriétés de convergence. Le pré-RPF converge, en effet, au sens de la variation totale, avec une vitesse en $O(1/N^{2/d+4})$ si $h^2 = O(1/N^{2/(d+4)})$. Bien que les critères soient différents, on peut tout de même comparer cette majoration au sens fort avec l'inégalité (5.5) obtenue pour le pré-RPF majorant l'erreur au sens faible, dans la mesure où l'inégalité (5.10) entraîne a fortiori une majoration au sens faible. On constate alors que la régularisation permet de réaliser le compromis que nous évoquions au Chapitre 2, entre les termes d'erreur locale et de propagation d'erreur : avec la régularisation, l'erreur locale dépend de la dimension, mais elle est mieux transportée au travers des coefficients produits $\beta_{n:k} \bar{\gamma}_{n:k}$. Ceci est dû aux meilleures qualités de transport de l'erreur en variation totale à travers la correction. Par ailleurs, on note qu'il est naturel d'obtenir en (5.10) une vitesse de convergence qui dépend de la dimension de l'espace d'état tout comme pour les méthodes numériques de maillage. En effet, il s'agit ici d'une estimation d'erreur au sens fort concernant donc le problème difficile de l'approximation de la densité du filtre optimal. Cependant, on rappelle que pour nos applications, la densité toute entière ne nous intéresse pas. En particulier, en pistage, on se limite classiquement aux critères de moyenne et de variance. On observera d'ailleurs dans les simulations que les performances des filtres régularisés ne semblent pas trop dépendre de la dimension de l'état lorsque l'on se contente d'estimer ces deux paramètres.

Le corollaire suivant fournit des vitesses de convergence p.s. au sens de la variation totale. Il résulte directement de l'inégalité (5.11), grâce à l'inégalité de Markov et au Lemme de Borel–Cantelli, (de la même manière que pour le Corollaire 4.11).

Corollaire 5.6. *Soit K un noyau de régularisation d'ordre deux, tel que pour un réel $p \geq 2$, $K \in L^p$ avec $I(K)$ fini. Si pour tout entier $1 \leq k \leq n$, les Hypothèses $[\mathbf{Q}\mathbf{I}][\Pi']$ sont vérifiées pour $p = 1$, alors pour tout facteur de dilatation h choisi tel que*

$$h = O\left(\frac{1}{N^{\frac{p}{2[(d+4)p-d]}}}\right),$$

on a

$$\lim_{N \rightarrow \infty} N^\alpha \|\pi_n^{N,h} - \pi_n\| = 0 \quad \mathbb{P}\text{-p.s.}, \quad \text{pour tout} \quad \alpha < \frac{p}{(d+4)p-d} - \frac{1}{p}. \quad (5.12)$$

PREUVE DU THÉORÈME 5.5. Considérons l'inégalité (5.10). Nous utilisons l'inégalité (2.8) du Lemme 2.8 qui permet de dénormaliser l'erreur de manière précise (sans introduire un

facteur 2),

$$\begin{aligned}
\mathbb{E}[\|\pi_k - \pi_k^{N,h}\| \mid Y_{1:k}] &= \mathbb{E}[\|\Psi_k \cdot (Q_k \pi_{k-1}) - \Psi_k \cdot (K_h * S^N(Q_k \pi_{k-1}^{N,h}))\| \mid Y_{1:k}] \\
&\leq \frac{M_k}{\bar{m}_k} \mathbb{E}[\|Q_k \pi_{k-1} - K_h * S^N(Q_k \pi_{k-1}^{N,h})\| \mid Y_{1:k-1}] \\
&\leq \bar{\gamma}_k \|\pi_{k|k-1} - K_h * \pi_{k|k-1}\| \\
&\quad + \bar{\gamma}_k \mathbb{E}[\|K_h * (Q_k \pi_{k-1}) - K_h * (Q_k \pi_{k-1}^{N,h})\| \mid Y_{1:k-1}] \\
&\quad + \bar{\gamma}_k \mathbb{E}[\|K_h * (Q_k \pi_{k-1}^{N,h}) - K_h * S^N(Q_k \pi_{k-1}^{N,h})\| \mid Y_{1:k-1}].
\end{aligned}$$

Nous appliquons l'inégalité (4.27) de la Proposition 4.12 pour majorer le premier terme de droite (qui correspond au biais de l'erreur de régularisation), puis l'inégalité (4.36) de la Proposition 4.16 pour majorer le dernier terme de droite (qui correspond à la variance de l'erreur de régularisation), ce qui entraîne

$$\mathbb{E}[\|\pi_k - \pi_k^{N,h}\| \mid Y_{1:k}] \leq \frac{M_k}{\bar{m}_k} \left[h^2 a_2 D_k + A'_d \frac{(1 + \bar{I}_k) b}{\sqrt{N h^d}} + \beta_k \mathbb{E}[\|\pi_{k-1} - \pi_{k-1}^{N,h}\| \mid Y_{1:k-1}] \right].$$

L'Hypothèse **[Q1]** permet, ensuite, la majoration $\bar{I}_k = \mathbb{E}[I(Q_k \pi_{k-1}^{N,h}) \mid Y_{1:k-1}] \leq I_k < \infty$ (voir Remarque 5.2). L'inégalité (5.10) s'obtient par récurrence sur k .

Considérons enfin l'inégalité (5.11), de la même manière que pour l'inégalité (5.10), nous avons

$$\begin{aligned}
(\mathbb{E}[\|\pi_k - \pi_k^{N,h}\|^p \mid Y_{1:k}])^{\frac{1}{p}} &\leq \bar{\gamma}_k \|\pi_{k|k-1} - K_h * \pi_{k|k-1}\| \\
&\quad + \bar{\gamma}_k (\mathbb{E}[\|K_h * (Q_k \pi_{k-1}) - K_h * (Q_k \pi_{k-1}^{N,h})\|^p \mid Y_{1:k-1}])^{\frac{1}{p}} \\
&\quad + \bar{\gamma}_k (\mathbb{E}[\|K_h * (Q_k \pi_{k-1}^{N,h}) - K_h * S^N(Q_k \pi_{k-1}^{N,h})\|^p \mid Y_{1:k-1}])^{\frac{1}{p}}.
\end{aligned}$$

Puis nous appliquons l'inégalité (4.27) de la Proposition 4.12 pour majorer le terme de biais (premier terme du membre de droite), et l'inégalité (4.39) de la Proposition 4.16 pour majorer le terme de variance (dernier terme du membre de droite), ce qui finalement entraîne

$$(\mathbb{E}[\|\pi_k - \pi_k^{N,h}\|^p \mid Y_{1:k}])^{\frac{1}{p}} \leq \frac{M_k}{\bar{m}_k} \left[h^2 a_2 D_k + C_{p,d} \frac{(1 + \bar{I}_k) \|K\|_p^{\frac{1}{2}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p} d}} + \beta_k (\mathbb{E}[\|\pi_{k-1} - \pi_{k-1}^{N,h}\|^p \mid Y_{1:k-1}])^{\frac{1}{p}} \right].$$

La preuve s'obtient alors par récurrence. $\square$

5.1.2 Filtre particulaire post-régularisé

Le filtre particulaire post-régularisé (post-RPF) a été originellement introduit dans [80, 87], où il est comparé à l'IPF sur des problèmes classiques de pistage. Nous choisissons ici d'approcher la mesure corrigée $\Psi \cdot \mu$, par la mesure à densité $K_h * (\Psi \cdot S^N(\mu))$, selon la seconde méthode proposée au Chapitre 4. Le filtre particulaire résultant est noté $\tilde{\pi}_n^{N,h}$ et appelé filtre particulaire post-régularisé (post-RPF) car la régularisation s'opère après la correction.

Description du filtre

Le filtre particulaire post-régularisé est initialisé à la valeur $\tilde{\pi}_0^{N,h} = \pi_0$, puis le passage de $\tilde{\pi}_{n-1}^{N,h}$ à $\tilde{\pi}_n^{N,h}$ se déroule en trois étapes,

$$\tilde{\pi}_{n-1}^{N,h} \xrightarrow[\substack{\text{Prédiction} \\ \text{échantillonnée}}]{(1)} \tilde{\pi}_{n|n-1}^{N,h} = S^N(Q_n \tilde{\pi}_{n-1}^{N,h}) \xrightarrow[\text{Correction}]{(2)} \tilde{\nu}_n^{N,h} = \Psi_n \cdot \tilde{\pi}_{n|n-1}^{N,h} \quad (5.13)$$

$$\xrightarrow[\text{Régularisation}]{(3)} \tilde{\pi}_n^{N,h} = K_h * \tilde{\nu}_n^{N,h} .$$

Du fait de la régularisation (étape (3)), la première phase de la prédiction échantillonnée (étape (1)) est changée par rapport à l'IPF. L'étape de rééchantillonnage du système de particules (fini), est remplacée par un échantillonnage suivant une probabilité à densité lisse selon la procédure :

indépendamment pour chaque i

- (i) Générer $I \in \{1, \dots, N\}$, avec $\mathbb{P}(I = j) = \omega_n^j$.
- (ii) Générer $\varepsilon \sim K$, noyau d'Epanechnikov (4.51) ou gaussien.
- (iii) Calculer $\xi_{n|n-1}^i = \xi_n^I + h \Gamma_n \varepsilon$, avec $h = h_{\text{opt}}$ donné par (4.52) ou (4.53). Si la technique de blanchiment est utilisée, $\Gamma_n = A_n$, la racine carrée de la matrice de covariance empirique, voir (4.55), sinon $\Gamma_n = I$.

Du point de vue de la complexité, cet algorithme est comparable à l'IPF. Il demande seulement N générations de variables aléatoires supplémentaires, suivant le noyau de régularisation, K , à chaque pas de l'algorithme. A ce petit prix supplémentaire, le post-RPF améliore sensiblement les performances de l'IPF, en particulier dans les cas de dynamiques faiblement bruitées, comme on le verra au Chapitre 6.

Majoration de l'erreur

On vérifie, avant tout, que le post-RPF vérifie bien la propriété (2.35), i.e. que pour toute fonction mesurable et bornée F définie sur $\mathcal{P}(E)$,

$$\mathbb{E}[F(\tilde{\pi}_k^{N,h}) \mid Y_{1:n}] = \mathbb{E}[F(\tilde{\pi}_k^{N,h}) \mid Y_{1:k}] ,$$

de sorte à pouvoir appliquer les résultats de stabilité du Chapitre 2.

Nous introduisons quelques notations supplémentaires.

- On note $\tilde{Q}_n^h$ le noyau perturbé défini par

$$\tilde{Q}_n^h(x, dx') = \int_E K_h(x - u) Q_n(u, dx') du , \quad (5.14)$$

pour tout $x, x' \in E$. L'opérateur intégral associé au noyau $\tilde{Q}_n^h$ agit sur les mesures $\mu \in \mathcal{M}^+(E)$, de la manière suivante,

$$\tilde{Q}_n^h \mu = Q_n(K_h * \mu) .$$

- Lorsque le moment d'ordre $d+1$ de $Q_k \tilde{\pi}_{k-1}^{N,h}$ existe, on note $\tilde{I}_k$ sa moyenne conditionnelle aux observations, i.e.

$$\tilde{I}_k = \mathbb{E}[I(Q_k \tilde{\pi}_{k-1}^{N,h}) | Y_{1:k-1}] .$$

Nous introduisons des hypothèses de régularité sur le filtre optimal π_k , le noyau de transition Q_k pour un réel $p \geq 1$ et la fonction de vraisemblance Ψ_k .

Hypothèse $[\Pi'']$: π_k est a.c. par rapport à la mesure de Lebesgue avec la densité $f_k = \frac{d\pi_k}{dx} \in W^{2,p}$ telle qu'il existe une v.a. $D_k > 0$ mesurable par rapport aux observations $Y_{1:k-1}$ vérifiant

$$\|f_k\|_{2,p} \leq D_k .$$

Hypothèse $[\mathbf{Q}']$: Pour tout $x \in E$, $Q_k(x, \cdot)$ est a.c. par rapport à la mesure de Lebesgue avec la densité $q_k(x, \cdot) \in W^{2,p}$ telle qu'il existe une constante $D_k > 0$ vérifiant

$$\|q_k(x, \cdot)\|_{2,p} \leq D_k ,$$

pour tout $x \in E$.

Hypothèse $[\Psi']$:

$$M'_k = \max\{\|\Psi_k\|, 2 \sum_{i=1}^d \|D_i \Psi_k\|, \sum_{i,j=1}^d \|D_i D_j \Psi_k\|\} < \infty .$$

Nous notons alors $\gamma'_k = \frac{M'_k}{m_k}$ et $\bar{\gamma}'_k = \frac{M'_k}{\bar{m}_k}$, lorsque ces quantités sont définies.

Remarque 5.7. Si l'Hypothèse $[\mathbf{Q}']$ est vérifiée pour un réel $p \geq 1$, alors pour toute mesure de probabilité μ , $Q_k \mu$ est a.c. par rapport à la mesure de Lebesgue et

$$\left\| \frac{dQ_k \mu}{dx} \right\|_{2,p} = \left| \int_E \mu(dx') q_k(x, \cdot) \right|_{2,p} \leq \sup_{x \in E} \|q_k(x, \cdot)\|_{2,p} \leq D_k . \quad (5.15)$$

Si les Hypothèses $[\mathbf{Q}'][\Psi']$ sont vérifiées pour un réel $p \geq 1$, alors l'Hypothèse $[\Pi'']$ est vérifiée. En effet,

$$\left\| \frac{d\pi_k}{dx} \right\|_{2,p} \leq \bar{\gamma}'_k \left\| \frac{dQ_k \pi_{k-1}}{dx} \right\|_{2,p} \leq \bar{\gamma}'_k D_k .$$

Nous énonçons d'abord les résultats de convergence faible du post-RPF.

Proposition 5.8. *Soit K un noyau de régularisation d'ordre deux.*

- (i) *Si pour tout entier $1 \leq k \leq n$, les Hypothèses $[\mathbf{Q}'][\Psi'][\mathbf{Q}\Psi]$ sont vérifiées pour $p = 1$, alors*

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \tilde{\pi}_n^{N,h}, \phi \rangle| | Y_{1:n}] \leq 2 \left[h^2 a_2 D_n^{max} + \frac{2}{\sqrt{N}} \right] \sum_{k=1}^n \beta_{n:k+1} \gamma'_{n:k} . \quad (5.16)$$

(ii) Si pour tout entier $1 \leq k \leq n$, les Hypothèses $[\Pi''][\mathbf{Q}\Psi][\mathbf{Q}_d]$ sont vérifiées pour $p = 1$, alors

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \tilde{\pi}_n^{N,h}, \phi \rangle| | Y_{1:n}] \leq 2 \left[h^2 a_2 D_n^{\max} + \frac{2}{\sqrt{N}} \right] \sum_{k=1}^{n+1} \beta_{n:k+1} \bar{\gamma}_{n:k} \gamma_{k-1} c_k . \quad (5.17)$$

Comme pour l'IPF et le pré-RPF, on obtient des vitesses de convergence, au sens faible, en $O(1/\sqrt{N})$, sous l'Hypothèse $[\mathbf{Q}\Psi]$ si $h^2 = O(1/\sqrt{N})$.

PREUVE DE LA PROPOSITION 5.8. La preuve de l'inégalité (5.16) s'obtient par le raisonnement de la Proposition 2.35,

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[|\langle \tilde{\pi}_n^{N,h} - \pi_n, \phi \rangle| | Y_{1:n}] &\leq \sum_{k=1}^n \sup_{\|\phi\|=1} \mathbb{E}[|\langle \bar{R}_{n:k+1}(\tilde{\pi}_k^{N,h}) - \bar{R}_{n:k+1} \circ \bar{R}_k(\tilde{\pi}_{k-1}^{N,h}), \phi \rangle| | Y_{1:n}] \\ &\leq 2 \sum_{k=1}^n \beta_{n:k+1} \frac{M_{n:k+1}}{m_{n:k+1}} d_k , \end{aligned}$$

avec l'erreur locale,

$$d_k = \sup_{\|\phi\|=1} \mathbb{E}[|\langle K_h * (\Psi_k \cdot S^N(Q_k \tilde{\pi}_{k-1}^{N,h})) - \Psi_k \cdot (Q_k \tilde{\pi}_{k-1}^{N,h}), \phi \rangle| | Y_{1:k}] .$$

D'après l'inégalité (5.15) de la Remarque 5.7, on a

$$\left\| \frac{dQ_k \tilde{\pi}_{k-1}^{N,h}}{dx} \right\|_{2,p} \leq D_k .$$

En appliquant l'inégalité (4.17) du Théorème 4.8,

$$d_k \leq h^2 a_2 D_k \frac{M'_k}{m_k} + \frac{2}{\sqrt{N}} \frac{M_k}{m_k} ,$$

ce qui finalement entraîne

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \tilde{\pi}_n^{N,h} - \pi_n, \phi \rangle| | Y_{1:n}] \leq 2 \sum_{k=1}^n \beta_{n:k+1} \frac{M_{n:k+1}}{m_{n:k+1}} \left[h^2 a_2 D_k \frac{M'_k}{m_k} + \frac{2}{\sqrt{N}} \frac{M_k}{m_k} \right] .$$

Considérons l'inégalité (5.17). Nous décomposons l'erreur en terme d'erreur locale de régularisation (biais et variance) et d'erreur globale transportée.

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \tilde{\pi}_n^{N,h}, \phi \rangle| | Y_{1:n}] &= \sup_{\|\phi\|=1} \mathbb{E}[|\langle \Psi_n \cdot (Q_n \pi_{n-1}) - K_h * (\Psi_n \cdot S^N(Q_n \tilde{\pi}_{n-1}^{N,h})), \phi \rangle| | Y_{1:n}] \\ &\leq \|\pi_n - K_h * \pi_n\| \\ &\quad + 2 \bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle Q_n \pi_{n-1} - Q_n \tilde{\pi}_{n-1}^{N,h}, \phi \rangle| | Y_{1:n-1}] \\ &\quad + 2 \bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle Q_n \pi_{n-1}^{N,h} - S^N(Q_n \tilde{\pi}_{n-1}^{N,h}), \phi \rangle| | Y_{1:n-1}] \end{aligned}$$

On rappelle que dans la description de l'évolution du post-RPF, on a introduit, dans le schéma (5.13), le processus intermédiaire $(\tilde{\nu}_n^{N,h})_{n \geq 0}$ tel que

$$\tilde{\pi}_n^{N,h} = K_h * \tilde{\nu}_n^{N,h} \quad \text{et} \quad Q_n \tilde{\pi}_n^{N,h} = \tilde{Q}_n^h \tilde{\nu}_n^{N,h} .$$

On reprend ici cette notation. On majore le premier terme du membre de droite (terme de biais de l'erreur de régularisation), en utilisant l'inégalité (4.27) de la Proposition 4.12, sachant que l'Hypothèse $[\Pi'']$ garantit

$$\left\| \frac{d\pi_n}{dx} \right\|_{2,p} \leq D_n .$$

Le dernier terme du membre de droite est majoré par la loi des grands nombres, sachant que Q_n ne fait que contracter l'erreur.

$$\begin{aligned} \sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \tilde{\pi}_n^{N,h}, \phi \rangle| | Y_{1:n}] &\leq h^2 a_2 D_n + 2 \frac{\bar{\gamma}_n}{\sqrt{N}} + 2 \bar{\gamma}_n \mathbb{E} \|Q_n \pi_{n-1} - \tilde{Q}_n^h \pi_{n-1}\| \\ &\quad + 2 \bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle \tilde{Q}_n^h \pi_{n-1} - \tilde{Q}_n^h \tilde{\nu}_{n-1}^{N,h}, \phi \rangle| | Y_{1:n-1}] \\ &\leq h^2 a_2 D_n + 2 \frac{\bar{\gamma}_n}{\sqrt{N}} + 2 \bar{\gamma}_n h^2 a_2 D_{n-1} \\ &\quad + 2 \bar{\gamma}_n \sup_{\|\phi\|=1} \mathbb{E}[|\langle \tilde{Q}_n^h \pi_{n-1} - \tilde{Q}_n^h \tilde{\nu}_{n-1}^{N,h}, \phi \rangle| | Y_{1:n-1}] \quad (5.18) \end{aligned}$$

Pour majorer le second terme du membre de droite, on note que

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \tilde{Q}_n^h \pi_{n-1} - \tilde{Q}_n^h \tilde{\nu}_{n-1}^{N,h}, \phi \rangle| | Y_{1:n-1}] \leq d_n, \quad \text{avec} \quad d_n = \mathbb{E}[\|\tilde{Q}_n^h \pi_{n-1} - \tilde{Q}_n^h \tilde{\nu}_{n-1}^{N,h}\| | Y_{1:n-1}].$$

Puis nous utilisons le Lemme 2.31 qui permet de majorer l'erreur en variation totale transportée par Q_n (dominé) par l'erreur faible comme suit.

$$\begin{aligned} d_n &\leq \mathbb{E}[\|\tilde{Q}_n^h \Psi_{n-1} \cdot (Q_{n-1} \pi_{n-2}) - \tilde{Q}_n^h \Psi_{n-1} \cdot (\tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N,h})\| | Y_{1:n-1}] \\ &\quad + \mathbb{E}[\|\tilde{Q}_n^h \Psi_{n-1} \cdot (\tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N,h}) - \tilde{Q}_n^h \Psi_{n-1} \cdot S^N(\tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N,h})\| | Y_{1:n-1}] \\ &\leq \beta_n \bar{\gamma}_{n-1} [h^2 a_2 D_{n-2} + \mathbb{E}[\|\tilde{Q}_{n-1}^h \pi_{n-2} - \tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N,h}\| | Y_{1:n-2}]] \\ &\quad + 2 \frac{\gamma_{n-1} c_n}{\sqrt{N}} \\ &\leq 2 \frac{\gamma_{n-1} c_n}{\sqrt{N}} + \sum_{k=2}^{n-1} \beta_{n:k+1} \bar{\gamma}_{n-1:k} [h^2 a_2 D_{k-1} + 2 \frac{\gamma_{k-1} c_k}{\sqrt{N}}] . \quad (5.19) \end{aligned}$$

En insérant cette dernière inégalité dans (5.18), nous obtenons l'inégalité (5.17). $\square$

Nous énonçons, maintenant, le résultat principal de convergence du post-RPF, au sens de la variation totale.

Théorème 5.9. *Soit K un noyau de régularisation d'ordre deux.*

- (i) *Si pour tout entier $1 \leq k \leq n$, les Hypothèses $[\Pi''][\mathbf{Q}\Psi][\mathbf{Q_I}]$ sont vérifiées pour $p = 1$ et $K \in L^2$ avec $I(K^2)$ fini, alors*

$$\mathbb{E}[\|\pi_n - \tilde{\pi}_n^{N,h}\| | Y_{1:n}] \leq [h^2 a_2 D_n^{max} + 2\gamma_n^{max} A'_d \frac{(1 + I_n^{max})b}{\sqrt{N}h^d}] \sum_{k=1}^n \beta_{n:k} \bar{\gamma}_{n:k}, \quad (5.20)$$

où A'_d ne dépend que de d .

- (ii) *Si pour tout entier $1 \leq k \leq n$, les Hypothèses $[\Pi''][\mathbf{Q}\Psi][\mathbf{Q_I}]$ sont vérifiées pour $p = 1$ et pour un réel $p \geq 2$, $K \in L^p$, avec $I(K)$ fini, alors*

$$(\mathbb{E}[\|\pi_n - \tilde{\pi}_n^{N,h}\|^p | Y_{1:n}])^{\frac{1}{p}} \leq [h^2 a_2 D_n^{max} + 2\gamma_n^{max} C'_{p,d} \frac{(1 + I_n^{max})\|K\|_p^{\frac{1}{2}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p}d}}] \sum_{k=1}^n \beta_{n:k} \bar{\gamma}_{n:k}, \quad (5.21)$$

où $C'_{p,d} = 2^{\frac{d+2}{2}} \sqrt{3} B_p^{\frac{1}{2p}} A_d$ ne dépend que de p et d (voir (3.20) et (4.4)).

Ces résultats sont, en général, moins forts que ceux obtenus pour le pré-RPF. En effet, les hypothèses de régularité sur la vraisemblance $[\Psi']$ et sur le filtre optimal $[\Pi'']$ sont légèrement plus fortes que celles requises par le pré-RPF ($[\Psi]$, et $[\Pi']$). De plus, les inégalités (5.20) et (5.21) ne sont valables que sous l'Hypothèse $[\mathbf{Q}\Psi]$, tandis que les inégalités correspondantes pour le pré-RPF (5.10) et (5.11) ne demandent aucune hypothèse sur la vraisemblance. Cette condition est en fait exigée pour le contrôle de l'erreur locale. C'est le caractère discret de l'étape de correction qui induit ce terme d'erreur. En effet, pour le post-RPF, comme pour l'IPF la correction consiste seulement à pondérer l'ensemble discret des particules. Par contre, pour le pré-RPF, la correction utilise l'information fournie par la vraisemblance Ψ_k pour pondérer tous les points du support de la densité de $K_h * S^N(Q_k \pi_{k-1}^{N,h})$. Néanmoins, on observe qu'à la différence de l'IPF, le post-RPF ne fait intervenir le coefficient γ_n qu'une seule fois, le transport de l'erreur s'effectuant à travers les coefficients mieux contrôlés $\bar{\gamma}_k$.

Le corollaire suivant est une conséquence directe de l'inégalité (5.21).

Corollaire 5.10. *Soit K un noyau de régularisation d'ordre deux, tel que pour un réel $p \geq 2$, $K \in L^p$, avec $I(K)$ fini. Si pour tout entier $1 \leq k \leq n$, les Hypothèses $[\Pi''][\mathbf{Q}\Psi][\mathbf{Q_I}]$ sont vérifiées pour $p = 1$, alors pour tout facteur de dilatation h choisi tel que*

$$h = O\left(\frac{1}{N^{\frac{p}{2[(d+4)p-d]}}}\right),$$

on a

$$\lim_{N \rightarrow \infty} N^\alpha \|\tilde{\pi}_n^{N,h} - \pi_n\| = 0 \quad \mathbb{P}\text{-}p.s., \quad \text{pour tout} \quad \alpha < \frac{p}{(d+4)p-d} - \frac{1}{p}. \quad (5.22)$$

PREUVE DU THÉORÈME 5.9. Considérons l'inégalité (5.20).

$$\begin{aligned}
\mathbb{E}[\|\pi_k - \tilde{\pi}_k^{N,h}\| \mid Y_{1:k}] &= \mathbb{E}[\|\Psi_k \cdot (Q_k \pi_{k-1}) - K_h * (\Psi_k \cdot S^N(Q_k \tilde{\pi}_{k-1}^{N,h}))\| \mid Y_{1:k}] \\
&\leq \|\pi_k - K_h * \pi_k\| \\
&\quad + \mathbb{E}[\|K_h * (\Psi_k \cdot (Q_k \pi_{k-1})) - K_h * (\Psi_k \cdot (Q_k \tilde{\pi}_{k-1}^{N,h}))\| \mid Y_{1:k}] \\
&\quad + \mathbb{E}[\|K_h * (\Psi_k \cdot (Q_k \tilde{\pi}_{k-1}^{N,h})) - K_h * (\Psi_k \cdot S^N(Q_k \tilde{\pi}_{k-1}^{N,h}))\| \mid Y_{1:k}] \quad (5.23)
\end{aligned}$$

Le second terme du membre de droite est majoré en utilisant l'inégalité (2.8) du Lemme 2.8 qui permet de dénormaliser l'erreur sans introduire un facteur deux,

$$\begin{aligned}
\mathbb{E}[\|K_h * (\Psi_k \cdot (Q_k \pi_{k-1})) - K_h * (\Psi_k \cdot (Q_k \tilde{\pi}_{k-1}^{N,h}))\| \mid Y_{1:k}] &\leq \frac{M_k}{\tilde{m}_k} \mathbb{E}[\|Q_k \pi_{k-1} - Q_k \tilde{\pi}_{k-1}^{N,h}\| \mid Y_{1:k-1}] \\
&\leq \frac{M_k}{\tilde{m}_k} \beta_k \mathbb{E}[\|\pi_{k-1} - \tilde{\pi}_{k-1}^{N,h}\| \mid Y_{1:k-1}].
\end{aligned}$$

Nous appliquons l'inégalité (4.27) de la Proposition 4.12 pour majorer le terme de biais (premier terme du membre de droite de (5.23)) et l'inégalité (4.43) de la Proposition 4.17 pour majorer le terme de variance (dernier terme du membre de droite de (5.23)). Ce qui finalement entraîne

$$\mathbb{E}[\|\pi_k - \tilde{\pi}_k^{N,h}\| \mid Y_{1:k}] \leq h^2 a_2 D_k + 2 \gamma_k A'_d \frac{(1 + \tilde{I}_k) b}{\sqrt{N h^d}} + \bar{\gamma}_k \beta_k \mathbb{E}[\|\pi_{k-1} - \tilde{\pi}_{k-1}^{N,h}\| \mid Y_{1:k-1}].$$

De la même manière que pour le pré-RPF, on utilise l'Hypothèse **[Q_I]** qui permet la majoration, $\tilde{I}_k = \mathbb{E}[I(Q_k \tilde{\pi}_{k-1}^{N,h}) \mid Y_{1:k-1}] \leq I_k < \infty$. La preuve se termine par récurrence.

Considérons enfin l'inégalité (5.21). L'erreur se décompose comme suit,

$$\begin{aligned}
(\mathbb{E}[\|\pi_k - \tilde{\pi}_k^{N,h}\|^p \mid Y_{1:k}])^{\frac{1}{p}} &\leq \|\pi_k - K_h * \pi_k\| \\
&\quad + (\mathbb{E}[\|K_h * (\Psi_k \cdot Q_k \pi_{k-1}) - K_h * (\Psi_k \cdot (Q_k \tilde{\pi}_{k-1}^{N,h}))\|^p \mid Y_{1:k}])^{\frac{1}{p}} \\
&\quad + (\mathbb{E}[\|K_h * (\Psi_k \cdot (Q_k \tilde{\pi}_{k-1}^{N,h})) - K_h * (\Psi_k \cdot S^N(Q_k \tilde{\pi}_{k-1}^{N,h}))\|^p \mid Y_{1:k}])^{\frac{1}{p}}.
\end{aligned}$$

Puis nous appliquons l'inégalité (4.27) de la Proposition 4.12 pour majorer le terme de biais (premier terme du membre de droite) et l'inégalité (4.46) de la Proposition 4.17 pour majorer le terme de variance (dernier terme du membre de droite). Ce qui finalement entraîne

$$(\mathbb{E}[\|\pi_k - \tilde{\pi}_k^{N,h}\|^p \mid Y_{1:k}])^{\frac{1}{p}} \leq h^2 a_2 D_k + 2 \gamma_k C'_{p,d} \frac{(1 + \tilde{I}_k) \|K\|_p^{\frac{1}{2}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p} d}} + \bar{\gamma}_k \beta_k (\mathbb{E}[\|\pi_{k-1} - \tilde{\pi}_{k-1}^{N,h}\|^p \mid Y_{1:k-1}])^{\frac{1}{p}}.$$

La preuve se termine par récurrence. $\square$

Il est encore possible de se débarrasser de l'Hypothèse $[\mathbf{Q}\Psi]$ nécessaire aux inégalités (5.17) et (5.20), en faisant varier le nombre de particules. Pour assurer une erreur locale δ , au sens de la variation totale, uniforme dans le temps, nous proposons d'utiliser à chaque instant k , un nombre aléatoire de particules, noté N_k , tel que

$$N_k = \inf\{N \mid \delta^2 \sum_{i=1}^N \Psi_k(\xi_{k|k-1}^i) \geq M_k/h^d\} . \quad (5.24)$$

où Ψ_k est supposée bornée par M_k .

Le lemme suivant montre que ce choix permet, en effet, de contrôler l'erreur locale, indépendamment de la fonction de vraisemblance.

Lemme 5.11. *Soit $\mu \in \mathcal{P}(E)$ une mesure de probabilité et Ψ une fonction positive définie sur E bornée par M telle que $\langle \mu, \Psi \rangle > 0$. A tout réel positif H , on associe le temps d'arrêt T_H défini par*

$$T_H = \inf\{N \mid \sum_{i=1}^N \Psi(\xi^i) \geq H\} \quad \text{avec} \quad (\xi^1, \dots, \xi^N) \text{ i.i.d. } \sim \mu .$$

Pour toute constante positive δ , on pose $H(\delta) = M/h^d\delta^2$,

(i) si $I(\Psi \cdot \mu)$ est fini avec $K \in L^2$ et $I(K^2)$ fini alors

$$\mathbb{E}\|K_h * (\Psi \cdot S^{T_{H(\delta)}}(\mu)) - K_h * (\Psi \cdot \mu)\| \leq 2b A'_d (1 + I(\Psi \cdot \mu)) \delta \sqrt{1 + h^d \delta^2} , \quad (5.25)$$

(ii) si $K \in L^2$, alors

$$\mathbb{E}\|K_h * (\Psi \cdot S^{T_{H(\delta)}}(\mu)) - K_h * (\Psi \cdot \mu)\|_2 \leq 2\delta \sqrt{1 + h^d \delta^2} , \quad (5.26)$$

Par la suite, nous ne nous servirons que de l'inégalité (5.25) majorant l'erreur moyenne en variation totale. Nous présentons néanmoins la majoration de l'erreur moyenne au sens L^2 (5.26), pour souligner que, dans ce cas, l'erreur d'estimation ne dépend pas du moment d'ordre $d+1$ de la mesure corrigée $I(\Psi \cdot \mu)$. On montre, ainsi, que pour le critère L^2 , comme pour le sens faible (voir Lemme 3.11), l'échantillonnage pondéré avec nombre aléatoire de simulations fournit une approximation dont les bornes d'erreur sont aussi bonnes que celles obtenues pour la méthode d'acceptation / rejet, avec un temps de calcul équivalent.

PREUVE DU LEMME 5.11. La preuve est calquée sur celle du Lemme 3.11, en introduisant la fonction R_N , définie sur E , telle que

$$R_N(x) = \frac{\langle S^N(\mu) - \mu, \Psi \phi_x \rangle}{\langle S^N(\mu), \Psi \rangle} , \quad \text{avec} \quad \phi_x(x') = K_h(x - x') ,$$

pour tout $x, x' \in E$. Par dénormalisation suivant l'inégalité (2.8) du Lemme 2.8,

$$\begin{aligned} \|K_h * (\Psi \cdot S^N(\mu)) - K_h * (\Psi \cdot \mu)\| &\leq 2 \frac{\|K_h * (\Psi S^N(\mu)) - K_h * (\Psi \mu)\|}{[K_h * (\Psi S^N(\mu))](E)} \\ &= 2 \int_E \left| \frac{\langle S^N(\mu) - \mu, \Psi \phi_x \rangle}{\langle S^N(\mu), \Psi \rangle} \right| dx \\ &= 2 \|R_N\|_1 . \end{aligned}$$

On a donc déjà,

$$\mathbb{E}\|K_h * (\Psi \cdot S^{T_H}(\mu)) - K_h * (\Psi \cdot \mu)\| \leq 2 \mathbb{E}\|R_{T_H}\|_1 . \quad (5.27)$$

L'erreur au sens L^2 est majorée en utilisant de nouveau la décomposition (2.4).

$$\begin{aligned} \|K_h * (\Psi \cdot S^N(\mu)) - K_h * (\Psi \cdot \mu)\|_2 &\leq \frac{1}{\langle S^N(\mu), \Psi \rangle} \left[\|K_h * (\Psi \cdot S^N(\mu)) - K_h * (\Psi \cdot \mu)\|_2 \right. \\ &\quad \left. + |\langle S^N(\mu) - \mu, \Psi \rangle| \|K_h * (\Psi \cdot \mu)\|_2 \right] \\ &= \|R_N\|_2 + \left| \frac{\langle S^N(\mu) - \mu, \Psi \rangle}{\langle S^N(\mu), \Psi \rangle} \right| \|K_h * (\Psi \cdot \mu)\|_2 . \end{aligned}$$

Si on note $b = \|K\|_2$, on a la majoration,

$$\|K_h * (\Psi \cdot \mu)\|_2 \leq \frac{b}{\sqrt{h^d}} .$$

Par ailleurs, l'inégalité (3.32), dans la preuve du Lemme 3.11, nous donne

$$\mathbb{E} \left| \frac{\langle S^{T_H}(\mu) - \mu, \Psi \rangle}{\langle S^{T_H}(\mu), \Psi \rangle} \right| \leq \sqrt{M} \sqrt{H + M} .$$

On a donc déjà,

$$\mathbb{E}\|K_h * (\Psi \cdot S^{T_H}(\mu)) - K_h * (\Psi \cdot \mu)\|_2 \leq \mathbb{E}\|R_{T_H}\|_2 + \frac{b}{\sqrt{h^d}} \sqrt{M} \sqrt{H + M} . \quad (5.28)$$

Pour obtenir les inégalités (5.25) et (5.26) du lemme, il reste maintenant à majorer respectivement, les termes $\mathbb{E}\|R_{T_H}\|_1$ et $\mathbb{E}\|R_{T_H}\|_2$. On pose

$$R_N(x) = \frac{S_N(x)}{U_N} ,$$

avec

$$S_N(x) = \sum_{i=1}^N [\Psi(\xi^i) \phi_x(\xi^i) - \langle \mu, \Psi \phi_x \rangle] \quad \text{et} \quad U_N = \sum_{i=1}^N \Psi(\xi^i) .$$

La suite $(S_N(x))_{N \geq 1}$ est une martingale. On écrit la décomposition de Doob de la sous-martingale $(S_N^2(x))_{N \geq 1}$: $S_N^2(x) = V_N(x) + S'_N(x)$, où $(S'_N(x))_{N \geq 1}$ est une martingale et

$$V_N(x) = N [\langle \mu, \Psi^2 \phi_x^2 \rangle - \langle \mu, \Psi \phi_x \rangle^2] \leq N \frac{b^2}{h^d} M \langle \mu, \Psi \rangle \frac{d[G_h * (\Psi \cdot \mu)]}{dx}(x) ,$$

où G est la densité de probabilité, $G = K^2/b^2$. D'après le théorème d'arrêt,

$$\mathbb{E}[V_{T_H}(x)] \leq \mathbb{E}[T_H] \frac{b^2}{h^d} M \langle \mu, \Psi \rangle \frac{d[G_h * (\Psi \cdot \mu)]}{dx}(x) ,$$

Par définition du temps d'arrêt T_H et par le théorème d'arrêt on a, comme au Lemme 3.11,

$$\frac{H}{\langle \mu, \Psi \rangle} \leq \mathbb{E}[T_H] \leq \frac{H + M}{\langle \mu, \Psi \rangle} ,$$

ce qui entraîne

$$\mathbb{E}[V_{T_H}(x)] \leq \frac{b^2}{h^d} M (H + M) \frac{d[G_h * (\Psi \cdot \mu)]}{dx}(x) ,$$

Comme au Lemme 3.11, on a

$$\mathbb{E}|R_{T_H}(x)| \leq \frac{1}{H} \mathbb{E}|S_{T_H}(x)| \leq \frac{1}{H} (\mathbb{E}[S_{T_H}^2(x)])^{1/2} = \frac{1}{H} (\mathbb{E}[V_{T_H}(x)])^{1/2} ,$$

$$\mathbb{E}|R_{T_H}(x)|^2 \leq \frac{1}{H^2} \mathbb{E}[S_{T_H}^2(x)] = \frac{1}{H^2} \mathbb{E}[V_{T_H}(x)] .$$

On obtient, ainsi, par intégration

$$\mathbb{E} \int_E |R_{T_H}(x)| dx \leq b \sqrt{\frac{M}{Hh^d}} \sqrt{1 + M/H} J(G_h * (\Psi \cdot \mu)) , \quad (5.29)$$

$$\mathbb{E} \int_E |R_{T_H}(x)|^2 dx \leq b \frac{M}{Hh^d} (1 + M/H) . \quad (5.30)$$

Pour le traitement de l'inégalité (5.29), on utilise les hypothèses $I(\Psi \cdot \mu) < \infty$ et $I(K^2) < \infty$ puis on applique l'inégalité (4.30) du Lemme 4.14, ce qui entraîne, pour tout $h \leq (1/I(G))^{\frac{1}{d+1}}$,

$$\mathbb{E} \|R_{T_H}\|_1 \leq 2^{\frac{d}{2}} A_d b (1 + I(\Psi \cdot \mu)) \sqrt{\frac{M}{Hh^d}} \sqrt{1 + M/H} .$$

En prenant $H(\delta) = M/(h^d \delta^2)$, on conclut

$$\mathbb{E} \|R_{T_H}\|_1 \leq 2^{\frac{d}{2}} A_d b \delta \sqrt{1 + h^d \delta^2} (1 + I(\Psi \cdot \mu)) ,$$

ce qui, avec l'inégalité (5.27), termine la preuve de l'inégalité (5.25).

En prenant $H(\delta) = M/(h^d \delta^2)$ dans (5.30), on a

$$\mathbb{E} \|R_{T_{H(\delta)}}\|_2 \leq \delta \sqrt{1 + h^d \delta^2} .$$

La preuve de l'inégalité (5.26) s'obtient en reportant cette dernière inégalité dans l'inégalité (5.28). $\square$

On peut maintenant énoncer le corollaire suivant.

Corollaire 5.12. *Soit K un noyau de régularisation d'ordre deux et δ , une constante positive donnée.*

(i) *Si pour tout entier $1 \leq k \leq n$, les Hypothèses $[\Pi''][\mathbf{Q}_d]$ sont vérifiées pour $p = 1$ et le nombre de particules N_k , à l'instant k , est défini comme le temps d'arrêt (3.27), alors*

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle \pi_n - \tilde{\pi}_n^{N,h}, \phi \rangle| | Y_{1:n}] \leq 2 [h^2 a_2 D_n^{max} + 2\delta \sqrt{1 + \delta^2}] \sum_{k=1}^{n+1} \beta_{n:k+1} \bar{\gamma}_{n:k} c_k , \quad (5.31)$$

(ii) Supposons que le noyau $K \in L^2$ avec $I(K^2)$ fini. Si pour tout entier $1 \leq k \leq n$, l'Hypothèse $[\Pi'']$ est vérifiée pour $p = 1$, $\tilde{I}_{k|k} = \mathbb{E}[I(\Psi_k \cdot Q_k \tilde{\pi}_{k-1}^{N,h}) \mid Y_{1:k}]$ est fini et le nombre de particules N_k , à l'instant k , est défini comme le temps d'arrêt (5.24), alors

$$\mathbb{E}[\|\pi_n - \tilde{\pi}_n^{N,h}\| \mid Y_{1:n}] \leq [h^2 a_2 D_n^{max} + 2b A'_d \delta \sqrt{1 + h^d \delta^2} (1 + \tilde{I}_{n|n}^{max})] \sum_{k=1}^n \beta_{n:k} \bar{\gamma}_{n:k}, \quad (5.32)$$

où A'_d ne dépend que de d .

L'inégalité (5.32) montre que le post-RPF utilisé avec un nombre aléatoire de particules fournit une approximation du filtre optimal comparable au pré-RPF (inégalité (5.10)), l'Hypothèse $[\mathbf{Q}\Psi]$ n'étant plus nécessaire ici. En contrepartie, le temps de calcul est cette fois-ci aléatoire comme pour le pré-RPF.

PREUVE DU COROLLAIRE 5.12. Il suffit de reprendre les preuves des inégalités (5.17) et (5.20) du Théorème 5.9, en majorant, cette fois, l'erreur locale à l'aide des Lemme 3.11 et 5.11. Considérons l'inégalité (5.31). Dans la preuve de l'inégalité (5.17) la majoration (5.19) est changée. On avait

$$\mathbb{E}[\|\tilde{Q}_n^h \pi_{n-1} - \tilde{Q}_n^h \tilde{\nu}_{n-1}^{N_{n-1},h}\| \mid Y_{1:n-1}] \leq A_n + B_n, \quad (5.33)$$

avec

$$A_n = \mathbb{E}[\|\tilde{Q}_n^h \Psi_{n-1} \cdot (Q_{n-1} \pi_{n-2}) - \tilde{Q}_n^h \Psi_{n-1} \cdot (\tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N_{n-2},h})\| \mid Y_{1:n-1}],$$

$$B_n = \mathbb{E}[\|\tilde{Q}_n^h \Psi_{n-1} \cdot (\tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N_{n-2},h}) - \tilde{Q}_n^h \Psi_{n-1} \cdot S^N(\tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N_{n-2},h})\| \mid Y_{1:n-1}].$$

A_n , est toujours majoré de la même façon, i.e.

$$A_n \leq \beta_n \bar{\gamma}_{n-1} [h^2 a_2 D_{n-2} + \mathbb{E}[\|\tilde{Q}_{n-1}^h \pi_{n-2} - \tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N_{n-2},h}\| \mid Y_{1:n-2}]]. \quad (5.34)$$

Par contre, B_n est majoré, en utilisant le Lemme 2.31 pour majorer l'erreur en variation totale transportée par Q_n (dominé) par l'erreur faible, puis le Lemme 3.11 pour majorer l'erreur faible.

$$\begin{aligned} B_n &\leq c_n \sup_{\|\phi\|=1} \mathbb{E}[\|\langle \tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N_{n-2},h} - S^{N_{n-1}}(\tilde{Q}_{n-1}^h \tilde{\nu}_{n-2}^{N_{n-2},h}), \phi \rangle\| \mid Y_{1:n-1}] \\ &\leq 2 c_n \delta \sqrt{1 + \delta^2}. \end{aligned} \quad (5.35)$$

Les inégalités (5.33) et (5.34) injectées dans (5.35) fournissent, par récurrence, la majoration,

$$\mathbb{E}[\|\tilde{Q}_n^h \pi_{n-1} - \tilde{Q}_n^h \tilde{\nu}_{n-1}^{N_{n-1},h}\| \mid Y_{1:n-1}] \leq \sum_{k=2}^{n-1} \beta_{n:k+1} \bar{\gamma}_{n-1:k} [h^2 a_2 D_{k-1} + 2 c_n \delta \sqrt{1 + \delta^2}],$$

qui, elle-même, insérée dans l'inégalité (5.18), fournit l'inégalité (5.31).

Considérons l'inégalité (5.32). Dans la preuve de l'inégalité (5.20), la majoration (5.23) du terme de variance de l'erreur locale de régularisation est changée (dernier terme du membre de droite de (5.23)). En utilisant le Lemme 5.11, on obtient

$$\mathbb{E}[\|K_h * \Psi_k \cdot (Q_k \tilde{\pi}_{k-1}^{N_{k-1},h}) - K_h * \Psi_k \cdot S^{N_{k-1}}(Q_k \tilde{\pi}_{k-1}^{N_{k-1},h})\| \mid Y_{1:k}] \leq 2b A'_d (1 + I(\Psi_k \cdot Q_k \tilde{\pi}_{k-1}^{N,h})) \delta \sqrt{1 + h^d \delta^2}.$$

Cette modification insérée dans (5.23) fournit l'inégalité (5.32). $\square$

5.2 Cas du noyau mélangeant

Dans cette section, nous montrons la convergence uniforme en temps des filtres particulaires régularisés lorsque l'évolution du filtre optimal est mélangeante.

5.2.1 Filtre particulaire pré-régularisé

Le théorème suivant énonce les résultats de convergence uniforme du pré-RPF.

Théorème 5.13. *Soit K un noyau de régularisation d'ordre deux.*

(i) *Si pour tout entier $k \geq 1$, les Hypothèses $[\mathbf{R}][\mathbf{Q}']$ sont vérifiées pour $p = 1$, alors*

$$\sup_{\|\phi\|=1} \mathbb{E}[\langle \pi_n - \pi_n^{N,h}, \phi \rangle \mid Y_{1:n}] \leq \delta_n + 2 \frac{\delta_{n-1}}{\varepsilon_n^2} + \frac{4}{\log 3} \sum_{k=1}^{n-2} \tau_{n:k+3} \frac{\delta_k}{\varepsilon_{k+2}^2 \varepsilon_{k+1}^2}, \quad (5.36)$$

avec

$$\delta_k \leq 2 \gamma_k [h^2 a_2 D_k + \frac{1}{\sqrt{N}}].$$

(ii) *Si pour tout $k \geq 1$, les Hypothèses $[\mathbf{R}][\mathbf{Q}'][\mathbf{Q}_I]$ sont vérifiées pour $p = 1$, et $K \in L^2$ avec $I(K^2)$ fini, alors*

$$\mathbb{E}[\|\pi_n - \pi_n^{N,h}\| \mid Y_{1:n}] \leq \delta_n + \frac{2}{\log 3} \sum_{k=1}^{n-1} \tau_{n:k+2} \frac{\delta_k}{\varepsilon_{k+1}^2}, \quad (5.37)$$

avec

$$\delta_k \leq \gamma_k [h^2 a_2 D_k + A'_d \frac{(1 + I_k) b}{\sqrt{N h^d}}].$$

(iii) *Si pour tout $k \geq 1$, les Hypothèses $[\mathbf{R}][\mathbf{Q}'][\mathbf{Q}_I]$ sont vérifiées pour $p = 1$, et si pour un réel $p \geq 2$, $K \in L^p$ avec $I(K)$ fini, alors*

$$(\mathbb{E}[\|\pi_n - \pi_n^{N,h}\|^p \mid Y_{1:n}])^{\frac{1}{p}} \leq \delta_n + \frac{2}{\log 3} \sum_{k=1}^{n-1} \tau_{n:k+2} \frac{\delta_k}{\varepsilon_{k+1}^2}, \quad (5.38)$$

avec

$$\delta_k \leq \gamma_k [h^2 a_2 D_k + C_{p,d} \frac{(1 + I_k) \|K\|_p^{\frac{1}{2}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p} d}}],$$

où $C_{p,d} = 2^{\frac{d+3}{2}} B_p^{\frac{1}{2p}} A_d$ ne dépend que de p et d (voir (3.20) et (4.4)).

On rappelle que sous l'hypothèse de mélange $\gamma_k \leq \bar{\gamma}_k / \varepsilon_k^2 < \infty$.

Ces résultats sont tout à fait comparables à ceux obtenus au Théorème 3.14 pour l'IPF. Comme on pouvait s'y attendre, l'intérêt de la régularisation semble très limité dans le cadre de dynamiques mélangeantes. Cependant, nous verrons, au Corollaire 5.15 que la pré-régularisation permet toujours un meilleur contrôle de l'erreur locale (indépendant du coefficient γ_k), tout comme nous avons vu, au Corollaire 3.17 qu'un nombre aléatoire de particules permettait un meilleur contrôle de l'erreur locale induite par l'IPF.

L'inégalité (5.38) entraîne le résultat suivant de convergence p.s. uniforme en temps.

Corollaire 5.14. *Soit K un noyau de régularisation d'ordre deux, tel que pour un réel $p \geq 2$, $K \in L^p$ avec $I(K)$ fini. Si pour tout $k \geq 1$, les Hypothèses $[\mathbf{R}][\mathbf{Q}'][\mathbf{Q}_\mathbf{I}]$ sont vérifiées pour $p = 1$ avec $\varepsilon_k \geq \varepsilon > 0$ et $D_k \leq D < \infty$, alors pour tout facteur de dilatation h choisi tel que*

$$h = O\left(\frac{1}{N^{\frac{p}{2[(d+4)p-d]}}}\right),$$

on a

$$\lim_{N \rightarrow \infty} N^\alpha \sup_{n \geq 0} \|\pi_n^{N,h} - \pi_n\| = 0 \quad \mathbb{P}\text{-p.s.}, \quad \text{pour tout} \quad \alpha < \frac{p}{(d+4)p-d} - \frac{1}{p}. \quad (5.39)$$

PREUVE DU THÉORÈME 5.13. Considérons l'erreur locale à l'instant k ,

$$\begin{aligned} \delta_k &= \mathbb{E}[|\langle \pi_k^{N,h} - \bar{R}_k(\pi_{k-1}^{N,h}), \phi \rangle| \mid Y_{1:k}, \pi_{k-1}^{N,h}] \\ &= \mathbb{E}[|\langle \Psi_k \cdot K_h * S^N(Q_k \pi_{k-1}^{N,h}) - \Psi_k \cdot Q_k \pi_{k-1}^{N,h}, \phi \rangle| \mid Y_{1:k}, \pi_{k-1}^{N,h}] \\ &\leq 2 \sup_{\|\phi\|=1} \mathbb{E}\left[\frac{|\langle Q_k \pi_{k-1}^{N,h} - K_h * S^N(Q_k \pi_{k-1}^{N,h}), \Psi_k \phi \rangle|}{\langle Q_k \pi_{k-1}^{N,h}, \Psi_k \rangle} \mid Y_{1:k}, \pi_{k-1}^{N,h}\right]. \end{aligned}$$

Puis d'après l'inégalité (4.11) du Théorème 4.7, nous avons

$$\sup_{\|\phi\|=1} \mathbb{E}[|\langle Q_k \pi_{k-1}^{N,h} - K_h * S^N(Q_k \pi_{k-1}^{N,h}), \Psi_k \phi \rangle| \mid Y_{1:k}, \pi_{k-1}^{N,h}] \leq M_k (h^2 a_2 D_k + \frac{1}{\sqrt{N}}).$$

Pour obtenir les majorations au sens fort, nous opérons d'abord la dénormalisation à l'aide de l'inégalité (2.9) ce qui nous permet d'économiser un facteur 2,

$$\|\Psi_k \cdot Q_k \pi_{k-1}^{N,h} - \Psi_k \cdot K_h * S^N(Q_k \pi_{k-1}^{N,h})\| \leq \frac{M_k}{\langle Q_k \pi_{k-1}^{N,h}, \Psi_k \rangle} \|Q_k \pi_{k-1}^{N,h} - K_h * S^N(Q_k \pi_{k-1}^{N,h})\|.$$

L'Hypothèse $[\mathbf{Q}_\mathbf{I}]$ permet d'assurer que $\bar{I}_k = \mathbb{E}[I(Q_k \pi_{k-1}^{N,h}) \mid Y_{1:k-1}] \leq I_k < \infty$ et d'appliquer l'inégalité (4.9) du Théorème 4.7, ce qui entraîne

$$\mathbb{E}[\|Q_k \pi_{k-1}^{N,h} - K_h * S^N(Q_k \pi_{k-1}^{N,h})\| \mid Y_{1:k-1}] \leq h^2 a_2 D_k + A'_d \frac{(1 + \bar{I}_k) b}{\sqrt{N h^d}}.$$

Enfin, nous achevons la preuve par application du Théorème 2.26. $\square$

On voit qu'avec le filtre pré-régularisé, la correction s'opère sur la densité régularisée, si bien que chaque point du support de la densité est mis à jour lors de la correction. Ainsi, le problème causé par la correction discrète que l'on rencontre avec l'IPF ou le post-RPF devrait disparaître avec le pré-RPF. Pourtant, les estimations d'erreur du Théorème 5.13 dépendent toujours de la vraisemblance (au travers du coefficient γ_k) de la même manière que pour l'IPF ou le post-RPF. En fait, nous allons voir que dans le cas mélangeant, il suffit de considérer

l'erreur moyenne (sur les observations) pour obtenir des bornes d'erreur indépendantes de la vraisemblance.

Corollaire 5.15. *Si pour tout $k \geq 1$, le noyau Q_k est mélangeant, avec la constante de mélange $\varepsilon_k > 0$ et les Hypothèses $[\mathbf{Q}'][\mathbf{Q}_I]$ sont satisfaites pour $p = 1$, avec $\mathbb{E}[D_k] < \infty$ alors l'erreur moyennée sur les observations, $\mathbb{E}\|\pi_n - \pi_n^{N,h}\|$, vérifie l'inégalité (5.37) du Théorème 5.13, avec*

$$\delta_k \leq \frac{2}{\varepsilon_k^2} (h^2 a_2 \mathbb{E}[D_k] + A'_d \frac{(1 + I_k) b}{\sqrt{N h^d}}) .$$

En particulier, si pour tout $k \geq 1$, le noyau Q_k est mélangeant les Hypothèses $[\mathbf{Q}'][\mathbf{Q}_I]$ sont satisfaites pour $p = 1$, avec $\varepsilon_k \geq \varepsilon > 0$, $\mathbb{E}[D_k] \leq D$, et $I_k \leq I$, alors

$$\mathbb{E}\|\pi_n - \pi_n^{N,h}\| \leq (1 + \frac{2}{\varepsilon^4 \log 3}) \delta , \quad \text{avec} \quad \delta \leq \frac{2}{\varepsilon^2} (h^2 a_2 D + A'_d \frac{(1 + I/\varepsilon) b}{\sqrt{N h^d}}) .$$

PREUVE DU COROLLAIRE 5.15. Il suffit de majorer l'erreur locale au sens fort puis d'appliquer l'équation (2.42) du Corollaire 2.27. D'après l'inégalité (2.10) du Lemme 2.8

$$\begin{aligned} \delta_k &= \mathbb{E}[\|\bar{R}_k(\pi_{k-1}^{N,h}) - \pi_k^{N,h}\| \mid Y_{1:k}, \pi_{k-1}^{N,h}] \\ &\leq 2 \int_E \frac{\Psi_k(x)}{\langle Q_k \pi_{k-1}^{N,h}, \Psi_k \rangle} \mathbb{E}[|K_h * S^N(Q_k \pi_{k-1}^{N,h}) - Q_k \pi_{k-1}^{N,h}| \mid Y_{1:k}, \pi_{k-1}^{N,h}](dx) . \end{aligned}$$

En utilisant la propriété de mélange de Q_k avec la constante $\varepsilon_k > 0$ et la mesure de mélange λ_k , on a

$$\varepsilon_k^2 \langle Q_k \pi_{k-1}^{N,h}, \Psi_k \rangle \leq \varepsilon_k \langle \lambda_k, \Psi_k \rangle \leq \langle Q_k \pi_{k-1}^{N,h}, \Psi_k \rangle .$$

où ε_k est déterministe puisque lié à Q_k . On obtient

$$\mathbb{E}[\|\bar{R}_k(\pi_{k-1}^{N,h}) - \pi_k^{N,h}\| \mid Y_{1:k}, \pi_{k-1}^{N,h}] \leq \frac{2}{\varepsilon_k^2} \int_E \frac{\Psi_k(x)}{\langle Q_k \pi_{k-1}^{N,h}, \Psi_k \rangle} A_k(x) dx ,$$

où pour tout $x \in E$, $A_k(x)$ est défini par

$$A_k(x) = \mathbb{E}[|\frac{d K_h * S^N(Q_k \pi_{k-1}^{N,h})}{dx}(x) - \frac{d Q_k \pi_{k-1}^{N,h}}{dx}(x)| \mid Y_{1:k}, \pi_{k-1}^{N,h}] .$$

On décompose $A_k(x)$ en une erreur de biais et de variance,

$$\begin{aligned} A_k(x) &\leq \mathbb{E}[|\frac{d K_h * S^N(Q_k \pi_{k-1}^{N,h})}{dx} - \frac{d K_h * (Q_k \pi_{k-1}^{N,h})}{dx}(x)| \mid Y_{1:k}, \pi_{k-1}^{N,h}] \\ &\quad + |\frac{d K_h * (Q_k \pi_{k-1}^{N,h})}{dx}(x) - \frac{d Q_k \pi_{k-1}^{N,h}}{dx}(x)| . \end{aligned}$$

L'inégalité (4.41) nous fournit une majoration du terme de variance, on obtient

$$A_k(x) \leq \frac{b}{\sqrt{N h^d}} \sqrt{\frac{d G_h * (Q_k \pi_{k-1}^{N,h})}{dx}(x)} + |\frac{d K_h * (Q_k \pi_{k-1}^{N,h})}{dx}(x) - \frac{d Q_k \pi_{k-1}^{N,h}}{dx}(x)| = B_k(x) ,$$

où $G = \frac{K^2}{\int K^2}$ et $b = \sqrt{\int K^2}$. Avec cette nouvelle notation $B_k(x)$, on a

$$\mathbb{E}[\|\bar{R}_k(\pi_{k-1}^{N,h}) - \pi_k^{N,h}\| \mid Y_{1:k}, \pi_{k-1}^{N,h}] \leq \frac{2}{\varepsilon_k^2} \int_E \frac{\Psi_k(x)}{\langle Q_k \pi_{k-1}, \Psi_k \rangle} B_k(x) dx . \quad (5.40)$$

D'après le Lemme 2.7 on rappelle que

$$\mathbb{E}\left[\frac{\Psi_k(x)}{\langle Q_k \pi_{k-1}, \Psi_k \rangle} \mid Y_{1:k-1}, \pi_{k-1}^{N,h}\right] = \mathbb{E}\left[\frac{\Psi_k(x)}{\langle Q_k \pi_{k-1}, \Psi_k \rangle} \mid Y_{1:k-1}\right] = 1 .$$

En prenant l'espérance conditionnelle à $Y_{1:k-1}$ et $\pi_{k-1}^{N,h}$ dans (5.40) on obtient finalement,

$$\begin{aligned} \mathbb{E}[\|\bar{R}_k(\pi_{k-1}^{N,h}) - \pi_k^{N,h}\| \mid Y_{1:k-1}, \pi_{k-1}^{N,h}] &\leq \frac{2}{\varepsilon_k^2} \int_E \mathbb{E}\left[\frac{\Psi_k(x)}{\langle Q_k \pi_{k-1}, \Psi_k \rangle} \mid Y_{1:k-1}, \pi_{k-1}^{N,h}\right] B_k(x) dx \\ &= \frac{2}{\varepsilon_k^2} \int_E B_k(x) dx \\ &\leq \frac{2}{\varepsilon_k^2} (h^2 a_2 D_k + A'_d \frac{(1 + I_k) b}{\sqrt{N h^d}}) . \end{aligned}$$

□

5.2.2 Filtre particulaire post-régularisé

Le théorème suivant énonce les résultats de convergence uniforme du filtre particulaire post-régularisé.

Théorème 5.16. *Soit K un noyau de régularisation d'ordre deux.*

- (i) *Si pour tout entier $k \geq 1$, les Hypothèses $[\mathbf{R}][\mathbf{Q}'][\Psi']$ sont satisfaites pour $p = 1$, alors le post-RPF, $\tilde{\pi}_n^{N,h}$, est une approximation faible du filtre optimal au sens de l'inégalité (5.36) du Théorème 5.13 avec,*

$$\delta_k \leq 2 \gamma'_k [h^2 a_2 D_k + \frac{1}{\sqrt{N}}] .$$

- (ii) *Si pour tout entier $k \geq 1$, les Hypothèses $[\mathbf{R}][\mathbf{Q}'][\Psi'][\mathbf{Q}_I]$ sont satisfaites pour $p = 1$, et $K \in L^2$ avec $I(K^2)$ fini, alors le post-RPF, $\tilde{\pi}_n^{N,h}$ est une approximation forte du filtre optimal au sens de l'inégalité (5.37) du Théorème 5.13, avec*

$$\delta_k \leq 2 \gamma'_k [h^2 a_2 D_k + 2 A'_d \frac{(1 + I_k) b}{\sqrt{N h^d}}] .$$

- (iii) *Si pour tout $k \geq 1$, les Hypothèses $[\mathbf{R}][\mathbf{Q}'][\Psi'][\mathbf{Q}_I]$ sont satisfaites pour $p = 1$, et pour un réel $p \geq 2$, $K \in L^p$ avec $I(K)$ fini, alors le post-RPF, $\tilde{\pi}_n^{N,h}$ est une approximation forte du filtre optimal au sens de l'inégalité (5.38) du Théorème 5.13, avec*

$$\delta_k \leq 2 \gamma'_k [h^2 a_2 D_k + 2 C'_{p,d} \frac{(1 + I_k) \|K\|_p^{\frac{1}{p}}}{N^{\frac{1}{4}} h^{\frac{p-1}{2p} d}}] ,$$

où $C'_{p,d} = 2^{\frac{d+2}{2}} \sqrt{3} B_p^{\frac{1}{2p}} A_d$ ne dépend que de p et d (voir (3.20) et (4.4)).

On rappelle que lorsque R_k est mélangeant, $\gamma'_k \leq M'_k \bar{\gamma}_k / M_k \varepsilon_k^2 < \infty$ et que $I_k \leq I(\pi_{k|k-1}) / \varepsilon_k$.
Le résultat (iii) entraîne la convergence p.s. uniforme en temps du corollaire suivant.

Corollaire 5.17. *Soit K un noyau de régularisation d'ordre deux, tel que pour un réel $p \geq 2$, $K \in L^p$ avec $I(K)$ fini. Si pour tout $k \geq 1$, les Hypothèses $[\mathbf{R}][\mathbf{Q}'''][\Psi'][\mathbf{Q}_t]$ sont vérifiées pour $p = 1$ avec $\varepsilon_k \geq \varepsilon > 0$ et $D_k \leq D < \infty$, alors pour tout facteur de dilatation h choisi tel que*

$$h = O\left(\frac{1}{N^{\frac{p}{2[(d+4)p-d]}}}\right),$$

on a

$$\lim_{N \rightarrow \infty} N^\alpha \sup_{n \geq 0} \|\tilde{\pi}_n^{N,h} - \pi_n\| = 0 \quad \mathbb{P}\text{-p.s.}, \quad \text{pour tout} \quad \alpha < \frac{p}{(d+4)p-d} - \frac{1}{p}. \quad (5.41)$$

PREUVE DU THÉORÈME 5.16. La preuve est semblable à celle du Théorème 5.13 à la différence que nous utilisons le Théorème 4.8 au lieu du Théorème 4.7 pour majorer les erreurs de régularisation. Considérons l'erreur locale à l'instant k ,

$$\mathbb{E}[\langle \tilde{\pi}_k^{N,h} - \bar{R}_k(\tilde{\pi}_{k-1}^{N,h}), \phi \rangle \mid Y_{1:k}, \tilde{\pi}_{k-1}^{N,h}] = \mathbb{E}[\langle K_h * (\Psi_k \cdot S^N(Q_k \tilde{\pi}_{k-1}^{N,h})) - \Psi_k \cdot (Q_k \tilde{\pi}_{k-1}^{N,h}), \phi \rangle \mid Y_{1:k}, \tilde{\pi}_{k-1}^{N,h}].$$

On rappelle que l'Hypothèse $[\mathbf{Q}''']$ assure que

$$\left\| \frac{d Q_k \tilde{\pi}_{k-1}^{N,h}}{dx} \right\|_{2,p} \leq D_k.$$

Pour la majoration au sens faible, il nous suffit d'appliquer directement l'inégalité (4.17) du Théorème 4.8. Pour la majoration au sens fort, nous utilisons l'inégalité (4.18) du Théorème 4.8 qui donne

$$\begin{aligned} \mathbb{E}[\|K_h * \Psi_k \cdot S^N(Q_k \tilde{\pi}_{k-1}^{N,h}) - \Psi_k \cdot (Q_k \tilde{\pi}_{k-1}^{N,h})\| \mid Y_{1:k}, \tilde{\pi}_{k-1}^{N,h}] &\leq h^2 a_2 D_k \frac{M'_k}{\langle Q_k \tilde{\pi}_{k-1}^{N,h}, \Psi_k \rangle} \\ &\quad + 2A'_d \frac{[1 + I(Q_k \tilde{\pi}_{k-1}^{N,h})] b}{\sqrt{N} h^d} \frac{M_k}{\langle Q_k \tilde{\pi}_{k-1}^{N,h}, \Psi_k \rangle}. \end{aligned}$$

Pour terminer la preuve, il reste à noter que $I(Q_k \tilde{\pi}_{k-1}^{N,h}) \leq I_k$. $\square$

Rappelons pour finir qu'il n'y a pas de réel intérêt pratique à la régularisation lorsque la dynamique est mélangeante puisque la propagation de l'erreur est déjà très bien contrôlée. Seule la pré-régularisation permet effectivement un meilleur contrôle de l'erreur locale (en moyenne indépendante du coefficient γ_k , voir Corollaire 5.15). Mais le post-RPF ou l'IPF utilisés avec un nombre aléatoire de particules fournissent des résultats comparables. L'intérêt de la régularisation est par contre réel, dans le cas plus général, où les transitions ne sont pas assez "régulières" pour assurer un bon transport de l'erreur. Dans ce cas, une erreur contrôlable au sens de la variation totale aura de bonnes chances d'être mieux propagée qu'une erreur au sens faible.

5.3 Remarques sur les hypothèses

Par souci de clarté, dans les énoncés des théorèmes et propositions précédents, les hypothèses utilisées sont souvent simplifiées. Nous allons voir qu'elles peuvent en général être relâchées. Dans cette section, pour chaque hypothèse considérée, nous donnons des exemples simples pour lesquels l'hypothèse est vérifiée et nous précisons si elle peut être relâchée. Dans les exemples donnés, nous nous référons au système état / observation suivant,

$$\begin{cases} X_{n+1} = f(X_n) + W_n \\ Y_n = h(X_n) + V_n \end{cases} \quad (5.42)$$

où $(W_n)_{n \geq 0}$ et $(V_n)_{n \geq 0}$ sont des suites de v.a. i.i.d. indépendantes de $(X_n)_{n \geq 0}$ et de densités respectives q et g . Le noyau de transition et la fonction de vraisemblance associés sont définis pour tout $x \in E$ par,

$$\Psi_k(x) = g(Y_k - h(x)) \ , \quad Q_k(x, dx') = q(x' - f(x)) dx' \ .$$

5.3.1 Le facteur de dilatation

Dans tout ce qui précède, le facteur de dilatation h peut varier avec le temps. Les résultats des propositions et théorèmes s'étendent facilement à ce cas tant que les h_k restent déterministes, en remplaçant, dans les preuves, h par h_k . Par contre, si les h_k sont choisis de manière empirique comme conseillé dans la Section 4.3, les résultats énoncés ne sont plus valables. Chaque facteur de dilatation est une variable aléatoire dépendant de l'échantillon courant. Il faut se reporter au Théorème 4.18 dû à Devroye pour une étude de l'erreur induite par le choix d'un facteur de dilatation empirique.

5.3.2 L'Hypothèse [Q_I]

L'Hypothèse [Q_I] demande que les moments d'ordre $d+1$ de $Q_k(x, \cdot)$ soient uniformément bornés en x , ce qui moralement suppose dans le cas du système (5.42), que la fonction de dynamique f soit bornée par M , i.e.

$$\sup_{x \in E} |f(x)| \leq M \ .$$

En effet, supposons que cela soit le cas et que de plus, la densité du bruit d'état q possède un moment d'ordre $d+1$, i.e.

$$I(q) = \int_{x \in E} |x|^{d+1} q(x) dx < \infty \ ,$$

alors

$$\begin{aligned} I(Q_k(x, \cdot)) &= \int_E |x'|^{d+1} q(x' - f(x)) \\ &= \int_E |u + f(x)|^{d+1} q(u) du \\ &\leq 2^{d+2} (M^{d+1} + I(q)) < \infty \ , \end{aligned}$$

ce qui montre bien que l'Hypothèse $[\mathbf{Q_I}]$ est vérifiée.

On note que l'Hypothèse $[\mathbf{Q_d}]$ de noyau dominé entraîne l'Hypothèse $[\mathbf{Q_I}]$ pourvu que la mesure dominante possède un moment d'ordre $d + 1$ fini. En effet, si

$$Q_k(x, \cdot) \leq c_k \nu_k ,$$

alors pour tout $x \in E$,

$$I(Q_k(x, \cdot)) = \int_E |x'|^{d+1} Q_k(x, dx') \leq c_k \int_E |x'|^{d+1} \nu_k(dx') = c_k I(\nu_k) .$$

A fortiori, (comme cela a déjà été remarqué) l'hypothèse de mélange entraîne l'Hypothèse $[\mathbf{Q_I}]$ pourvu que la mesure de mélange possède un moment d'ordre $d + 1$ fini.

En fait, dans tous les résultats énoncés, l'Hypothèse $[\mathbf{Q_I}]$ peut être remplacée par l'existence de la moyenne conditionnelle aux observations du moment d'ordre $d + 1$ de $Q_k \pi_{k-1}^{N,h}$, pour le pré-RPF et de $Q_k \tilde{\pi}_{k-1}^{N,h}$, pour le post-RPF. Ce qui correspond aux Hypothèses $[\tilde{\mathbf{I}}]$ et $[\tilde{\mathbf{I}}]$ suivantes,

Hypothèse $[\tilde{\mathbf{I}}]$:

$$\bar{I}_k = \mathbb{E}[I(Q_k \pi_{k-1}^{N,h}) | Y_{1:k-1}] < \infty .$$

Hypothèse $[\tilde{\mathbf{I}}]$:

$$\tilde{I}_k = \mathbb{E}[I(Q_k \tilde{\pi}_{k-1}^{N,h}) | Y_{1:k-1}] < \infty .$$

Dans ce cas, il suffit de remplacer, dans les estimations d'erreur des théorèmes, la constante I_k par $\bar{I}_k$, pour le pré-RPF et $\tilde{I}_k$, pour le post-RPF.

Il faut noter que bien que les conditions $[\tilde{\mathbf{I}}]$ et $[\tilde{\mathbf{I}}]$ soient nettement moins fortes que la condition $[\mathbf{Q_I}]$, elles ont l'inconvénient non négligeable de dépendre des approximations particulières que l'on ne sait justement pas contrôler.

5.3.3 Les Hypothèses $[\mathbf{Q'}]$ et $[\mathbf{Q''}]$

Les Hypothèses $[\mathbf{Q'}]$ et $[\mathbf{Q''}]$ ne sont pas des hypothèses trop contraignantes tant que le noyau de transition n'est pas dégénéré (rappelons que ces hypothèses ne sont utilisées que sous la condition de mélange). Elles sont par exemple satisfaites pour le noyau gaussien défini sur $\mathbb{R}$,

$$Q(x, dx') = q(x' - x) dx' , \quad \text{avec} \quad q(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2} x^2\right) .$$

Dans ce cas, on a pour tout $x \in E$,

$$\int_E |q'(x' - x)| dx' \leq \sigma , \quad \text{et} \quad \int_E |q''(x' - x)| dx' \leq 1 + \sigma^2 .$$

Comme pour l'Hypothèse $[\mathbf{Q_I}]$, on note que les Hypothèses $[\mathbf{Q'}]$ et $[\mathbf{Q''}]$ peuvent être relâchées et remplacées par les conditions $[\tilde{\mathbf{I}}']$ et $[\tilde{\mathbf{I}}'']$ suivantes de régularité sur les estimées fournies respectivement par le pré-RPF et le post-RPF.

Hypothèse $[\tilde{\mathbf{I}}']$: $Q_k \pi_{k-1}^{N,h}$ est a.c. par rapport à la mesure de Lebesgue, avec la densité

$\frac{dQ_k \pi_{k-1}^{N,h}}{dx} \in W^{2,p}$ telle qu'il existe une v.a. $D_k > 0$ mesurable par rapport aux observations $Y_{1:k-1}$ vérifiant

$$\mathbb{E} \left[\left\| \frac{dQ_k \pi_{k-1}^{N,h}}{dx} \right\|_{2,p} \mid Y_{1:k-1} \right] \leq D_k .$$

Hypothèse $[\tilde{\Pi}'']$: $Q_k \tilde{\pi}_{k-1}^{N,h}$ est a.c. par rapport à la mesure de Lebesgue, avec la densité $\frac{dQ_k \tilde{\pi}_{k-1}^{N,h}}{dx} \in W^{2,p}$ telle qu'il existe une v.a. $D_k > 0$ mesurable par rapport aux observations $Y_{1:k-1}$ vérifiant

$$\mathbb{E} \left[\left\| \frac{dQ_k \tilde{\pi}_{k-1}^{N,h}}{dx} \right\|_{2,p} \mid Y_{1:k-1} \right] \leq D_k .$$

On note ici encore que ces conditions ne sont a priori pas vérifiables, puisqu'elles dépendent des approximations particulières que l'on ne contrôle pas.

5.3.4 L'Hypothèse $[\mathbf{Q}\Psi]$

Considérons le système (5.42). Nous présentons deux cas simples pour lesquels l'Hypothèse $[\mathbf{Q}\Psi]$ est vérifiée :

- (i) Supposons que la densité du bruit d'observation g ne soit jamais nulle. Alors

$$\int_E q(x' - z) \Psi_k(x') dx' > 0 ,$$

pour tout $z \in E$. Supposons de plus que f soit bornée. On note alors $f(E) = \{f(x) \mid x \in E\}$, le compact contenant toutes les images de f . On a alors,

$$m_k = \inf_{x \in E} \langle Q_k(x, \cdot), \Psi_k \rangle = \inf_{z \in f(E)} \int_E q(x' - z) \Psi(x') dx' > 0 ,$$

ce qui correspond bien à l'Hypothèse $[\mathbf{Q}\Psi]$.

- (ii) De la même manière, nous supposons que la fonction d'observation h est bornée, i.e.

$$\sup_{x \in E} |h(x)| \leq H .$$

Nous supposons, en outre, que la densité du bruit de mesure s'écrit

$$g(x) = l(|x|) ,$$

pour tout $x \in E$, où l est une fonction strictement positive et décroissante définie sur $\mathbb{R}^+$. Alors,

$$\Psi_k(x) = g(h(X_k) - h(x) + V_k) \leq l(2H + |V_k|) > 0 \quad \mathbb{P}\text{-p.s.} .$$

Cette minoration entraîne directement l'Hypothèse $[\mathbf{Q}\Psi]$.

5.3.5 L'Hypothèse $[\mathbf{Q}_d]$

L'Hypothèse $[\mathbf{Q}_d]$ peut être remplacée par l'Hypothèse $[\mathbf{Q}_d^h]$, pour le pré-RPF et par l'Hypothèse $[\tilde{\mathbf{Q}}_d^h]$, pour le post-RPF :

Hypothèse $[\mathbf{Q}_d^h]$: Il existe une constante $c_k > 0$, et une mesure de probabilité $\nu_k \in \mathcal{P}(E)$, telles que

$$Q_k^h(x, \cdot) \leq c_k \nu_k .$$

Hypothèse $[\tilde{\mathbf{Q}}_d^h]$: Il existe une constante $c_k > 0$, et une mesure de probabilité $\nu_k \in \mathcal{P}(E)$, telles que

$$\tilde{Q}_k^h(x, \cdot) \leq c_k \nu_k .$$

Ces hypothèses sont légèrement moins fortes que $[\mathbf{Q}_d]$. En effet, si l'Hypothèse $[\mathbf{Q}_d]$ est vérifiée pour un entier k , alors les Hypothèses $[\mathbf{Q}_d^h]$ et $[\tilde{\mathbf{Q}}_d^h]$ sont vérifiées, du fait des inégalités suivantes,

$$Q_k^h(x, dx') = \int_E Q_k(x, du) K_h(x' - u) dx' \leq \int_E c_k \nu_k(du) K_h(x' - u) dx' = c_k (K_h * \nu_k)(x') dx' .$$

$$\tilde{Q}_k^h(x, dx') = \int_E K_h(x - u) Q_k(u, dx') du \leq c_k \nu_k(dx') .$$

Remarque 5.18. On a vu que les Hypothèses $[\mathbf{Q}_I]$, et $[\mathbf{Q}\Psi]$ exigeaient, en général, une fonction de dynamique bornée pour être vérifiées. Un moyen simple de se ramener à une dynamique bornée est d'opérer un changement d'état, Considérons le système (5.42), sans bruit de dynamique ($W_n = 0$). On rappelle que l'étape de régularisation est particulièrement nécessaire dans ce cas. On note Φ l'homéomorphisme de $\mathbb{R}^d$ dans la boule unité de $\mathbb{R}^d$ défini par

$$\Phi(x) = \frac{x}{1 + |x|} ,$$

pour tout $x \in \mathbb{R}^d$. On opère le changement d'état $X'_n = \Phi(X_n)$ qui conduit au système suivant équivalent à (5.42)

$$\begin{cases} X'_0 = \Phi(X_0) , \\ X'_{n+1} = f'(X'_n) & \text{avec} & f' = \Phi \circ f \circ \Phi^{-1} \\ Y_n = h'(X'_n) + V_n & \text{avec} & h' = h \circ \Phi^{-1} . \end{cases} \quad (5.43)$$

On est ainsi ramené à l'étude d'un système où la fonction de dynamique f' est bornée dans la boule unité.

5.4 Régularisation et robustification

La régularisation a été initialement développée pour éviter les problèmes de divergence de l'IPF rencontrés essentiellement lorsque le bruit d'état ou d'observation est faible. L'étude de la stabilité du filtre au Chapitre 2 suggère effectivement que les difficultés d'approximation

sont accrues lorsque la vraisemblance est localisée (faible bruit d'observation), tandis que les propriétés d'oubli du noyau de transition (fort bruit d'état) atténuent l'erreur locale commise. La robustesse du filtre optimal dans le contexte de systèmes faiblement bruités est en réalité identifiée depuis longtemps comme un problème difficile. Dans le cadre du filtrage linéaire, quelques solutions heuristiques ont été proposées dont certaines sont aujourd'hui appliquées par les ingénieurs. Il est intéressant de les rappeler ici, car la régularisation développée pour les approximations particulières peut être interprétée comme l'une d'elle.

5.4.1 Le problème de robustesse en filtrage

Le problème de la divergence du filtre lorsque le modèle est faux s'explique intuitivement par le fait que le filtre a trop confiance en son estimée. Ce phénomène est d'autant plus marqué que les bruits de dynamique ou d'observation sont faibles. On observe, dans ces cas, en filtrage linéaire, que la covariance de l'erreur estimée par le filtre de Kalman est très petite alors que la covariance réelle de l'erreur commise est très grande. Or le modèle utilisé par le filtre est différent du véritable modèle si bien que l'estimée diverge. Jazwinski [58], cite le problème concret de la détermination d'orbite, où les mesures fournies par les radars sont si précises qu'on se trouve classiquement confronté à des problèmes de divergence. Une pratique courante est alors d'augmenter artificiellement la covariance estimée de l'erreur de sorte à compenser les erreurs de modèle. En un sens, les erreurs de modèle ajoutent une incertitude qui doit se traduire par une augmentation de la matrice de covariance.

Deux points de vue sont alors adoptés. L'un est de privilégier les observations les plus récentes de sorte à oublier les informations passées et ainsi à n'exploiter le modèle (faux) que sur une période de courte durée. Cette idée donne lieu au filtre à mémoire limitée ou à oubli exponentiel déjà exploité en filtrage particulière, dans la Section 3.1, pour régulariser les poids du filtre de Monte Carlo pondéré. L'autre est d'augmenter le bruit d'état de sorte à prendre en considération, dans le modèle d'état, l'incertitude sur le modèle. Dans le contexte de l'approximation particulière, cette procédure suggère que l'erreur d'échantillonnage introduite (identifiée à une erreur de modèle) doit être du même ordre que les bruits d'état intervenant dans le modèle. Si cela n'est pas possible (pour un système faiblement bruité cela exigerait un trop grand nombre de particules), il faut alors introduire un bruit artificiel de l'ordre de l'erreur d'échantillonnage. Cela va dans le sens de l'intuition puisqu'il est naturel de penser que la précision de l'approximation doit être au moins aussi bonne que la précision du modèle. Dans les deux points de vue proposés, l'idée est d'introduire artificiellement de l'oubli dans le filtre. La difficulté de la méthode d'augmentation du bruit d'état consiste évidemment dans le choix de la nature et de la puissance du bruit à ajouter, pour minimiser l'erreur introduite. Plusieurs méthodes intuitives sont proposées par Jazwinski [58], mais il n'y a pas réellement de méthode systématique. Dans ce contexte, nous allons voir que la régularisation peut aussi être vue comme une méthode d'estimation adaptative des bruits d'état à ajouter pour robustifier le filtre.

5.4.2 La procédure d'augmentation de bruit

La procédure d'augmentation de bruit peut consister à remplacer le noyau de transition Q_n , par le noyau perturbé Q_n^h déjà introduit en (5.2) tel que pour tout $x, x' \in E$

$$Q_n^h(x, dx') = \int_E Q_n(x, du) K_h(x' - u) dx' ,$$

où K_h est une densité de probabilité paramétrée par le facteur de dilatation h réglant la force du bruit ajouté. En effet, si le modèle d'état est donné par

$$X_n = f_n(X_{n-1}, W_n) , \quad (5.44)$$

ce changement de noyau consiste à le remplacer par

$$X_n^h = f_n(X_{n-1}^h, W_n) + h\varepsilon_n ,$$

où $(\varepsilon_n)_{n \geq 0}$ constitue une suite de v.a. i.i.d. suivant K . On note π_n^h le filtre résultant de ce changement de modèle (i.e. utilisant Q_n^h au lieu de Q_n) et défini par la récurrence,

$$\begin{cases} \pi_0^h = \pi_0 \\ \pi_n^h = \Psi_n \cdot (Q_n^h \pi_{n-1}^h) = \Psi_n \cdot (K_h * (Q_n \pi_{n-1}^h)) = \bar{R}_n^h(\pi_{n-1}^h) , \end{cases} \quad (5.45)$$

où R_n^h est l'opérateur intégral $R_n^h = \Psi_n Q_n^h$. L'évolution de π_n^h est décrite par les deux étapes suivantes,

$$\pi_{n-1}^h \xrightarrow[\text{Prédiction perturbée}]{(1)} \pi_{n|n-1}^h = K_h * (Q_n \pi_{n-1}^h) \xrightarrow[\text{Correction}]{(2)} \pi_n^h = \Psi_n \cdot \pi_{n|n-1}^h .$$

Une autre possibilité est d'ajouter le bruit avant le transport par Q_n , i.e. de remplacer Q_n par le noyau perturbé $\tilde{Q}_n^h$ déjà introduit en (5.14) tel que pour tout $x, x' \in E$,

$$\tilde{Q}_n^h(x, dx') = \int_E K_h(x - u) Q_n(u, dx') du .$$

Ce qui revient à changer le modèle d'état (5.44) en

$$\tilde{X}_n^h = f_n(\tilde{X}_{n-1}^h, W_n + h\varepsilon_n) ,$$

où $(\varepsilon_n)_{n \geq 0}$ constitue une suite de v.a. i.i.d. suivant K . On note $\tilde{\nu}_n^h$ le filtre résultant de ce changement de modèle défini par la récurrence,

$$\begin{cases} \tilde{\nu}_0^h = \pi_0 \\ \tilde{\nu}_n^h = \Psi_n \cdot (\tilde{Q}_n^h \tilde{\nu}_{n-1}^h) = \Psi_n \cdot (Q_n(K_h * \tilde{\nu}_{n-1}^h)) = \bar{R}_n^h(\tilde{\nu}_{n-1}^h) , \end{cases} \quad (5.46)$$

où $\tilde{R}_n^h$ est l'opérateur intégral $\tilde{R}_n^h = \Psi_n \tilde{Q}_n^h$. L'évolution de $\tilde{\nu}_n^h$ est décrite par les deux étapes suivantes,

$$\tilde{\nu}_{n-1}^h \xrightarrow[\text{Prédiction perturbée}]{(1)} \tilde{\nu}_{n|n-1}^h = Q_n(K_h * \tilde{\nu}_{n-1}^h) \xrightarrow[\text{Correction}]{(2)} \tilde{\nu}_n^h = \Psi_n \cdot \tilde{\nu}_{n|n-1}^h .$$

On voit dans les deux cas que la procédure d'augmentation du bruit s'est traduite par l'insertion d'une étape de régularisation (convolution par le noyau K_h) dans l'évolution du filtre optimal.

5.4.3 L'approximation particulière

Les filtres particuliers régularisés s'obtiennent ensuite en appliquant l'algorithme de l'IPF sur les processus $(\pi_n^h)_{n \geq 0}$ et $(\tilde{\nu}_n^h)_{n \geq 0}$ correspondant aux modèles perturbés.

Le filtre particulier pré-régularisé s'obtient, en introduisant une étape d'échantillonnage, dans la récurrence (5.45), juste avant la régularisation :

$$\pi_n^{N,h} = \Psi_n \cdot (K_h * S^N(Q_n \pi_{n-1}^{N,h})) .$$

En reprenant les notations du schéma (5.1), on obtient le schéma d'évolution équivalent :

$$\pi_{n-1}^{N,h} \xrightarrow[\substack{\text{Prédiction perturbée} \\ \text{et échantillonnée}}]{(1)} \nu_{n|n-1}^{N,h} = K_h * S^N(Q_n \pi_{n-1}^{N,h}) \xrightarrow[\text{Correction}]{(2)} \pi_n^{N,h} = \Psi_n \cdot \nu_{n|n-1}^{N,h} .$$

Le filtre particulier post-régularisé s'obtient en introduisant dans (5.46) l'étape d'échantillonnage après l'action du noyau $\tilde{Q}_n^h$:

$$\tilde{\nu}_n^{N,h} = \Psi_n \cdot (S^N(Q_n K_h * \tilde{\nu}_{n-1}^{N,h})) .$$

En reprenant les notations du schéma (5.13), on obtient le schéma d'évolution équivalent :

$$\tilde{\nu}_{n-1}^{N,h} \xrightarrow[\substack{\text{Prédiction perturbée} \\ \text{et échantillonnée}}]{(1)} \tilde{\pi}_{n|n-1}^{N,h} = S^N(Q_n K_h * \tilde{\nu}_{n-1}^{N,h}) \xrightarrow[\text{Correction}]{(2)} \tilde{\nu}_n^{N,h} = \Psi_n \cdot \tilde{\pi}_{n|n-1}^{N,h} .$$

On note que $\tilde{\nu}_n^{N,h}$ ne correspond pas exactement à $\tilde{\pi}_n^{N,h}$ mais lui est étroitement lié par la relation $\tilde{\pi}_n^{N,h} = K_h * \tilde{\nu}_n^{N,h}$.

On peut remarquer qu'il y a d'autres possibilités d'intercaler l'étape d'échantillonnage, mais elles n'apportent rien de plus que les deux présentées. En effet, on pourrait opérer l'échantillonnage après la régularisation dans (5.45). Mais cela donne lieu à un algorithme semblable au post-RPF. Parallèlement, opérer l'échantillonnage juste après la régularisation dans (5.46) obligerait à utiliser un algorithme d'acceptation / rejet exigeant un nombre aléatoire de simulations suivant les transitions Q_n . Le coût de ces simulations pouvant être grand, on a préféré ne pas exploiter cette possibilité.

5.4.4 Robustification

L'interprétation de la régularisation comme une étape de robustification découle directement de l'étude de stabilité du Chapitre 2. Considérons par exemple le filtre pré-régularisé (le cas du post-RPF étant semblable). L'erreur globale commise peut se décomposer comme suit

$$\begin{aligned} \|\pi_n - \pi_n^{N,h}\| &\leq \|\pi_n - \pi_n^h\| + \|\pi_n^h - \pi_n^{N,h}\| \\ &\leq \sum_{k=1}^n \|\bar{R}_{n:k+1}^h \circ \bar{R}_k(\pi_{k-1}) - \bar{R}_{n:k+1}^h \circ \bar{R}_k^h(\pi_{k-1})\| \\ &\quad + \sum_{k=1}^n \|\bar{R}_{n:k+1}^h \circ \bar{R}_k^h(\pi_{k-1}^{N,h}) - \bar{R}_{n:k+1}^h(\pi_k^{N,h})\| . \end{aligned}$$

On voit apparaître les erreurs locales d'échantillonnage et de régularisation aisément contrôlables par les résultats du Chapitre 4,

$$\|\bar{R}_k(\pi_{k-1}) - \bar{R}_k^h(\pi_{k-1})\| \quad \text{et} \quad \|\bar{R}_k^h(\pi_{k-1}^{N,h}) - \pi_k^{N,h}\|.$$

L'avantage que l'on gagne avec la régularisation, par rapport à l'IPF, réside dans le fait que l'erreur locale est ici transportée par les opérateurs $\bar{R}_n^h$ qui ont a priori de meilleures propriétés d'oubli que les opérateurs $\bar{R}_n$. En un sens, l'approximation particulière étant réalisée sur le filtre robustifié π_n^h , on peut espérer une propagation de l'erreur d'échantillonnage légèrement meilleure que si elle avait été réalisée directement sur le véritable filtre π_n .

Plus généralement, on peut choisir n'importe quelle perturbation de Q_n permettant une meilleure propagation de l'erreur d'échantillonnage sans trop s'éloigner du filtre optimal. Par exemple, on peut choisir de remplacer Q_n par le noyau composé $Q'_n = Q_n K_n$ où K_n a pour mesure invariante π_{n-1} . Si on note R'_n l'opérateur intégral $R'_n = \Psi_n Q_n K_n$, on a avec ce choix

$$\pi_n = \bar{R}'_{n:1}(\pi_0) = \bar{R}_{n:1}(\pi_0).$$

Ainsi, la perturbation choisie n'a pas changé l'évolution du filtre, elle n'introduit aucune erreur (elle est en ce sens optimale). Pourtant la propagation de l'erreur à travers R'_n est probablement meilleure puisque les propriétés d'oubli du noyau composé Q'_n sont meilleures :

$$\beta(Q'_n) \leq \beta(Q_n) \beta(K_n) \leq \beta(Q_n).$$

L'idéal étant évidemment de trouver un noyau Q'_n mélangeant. Malheureusement, la connaissance d'un noyau K_n ayant pour mesure invariante π_{n-1} suppose quasiment la connaissance de π_{n-1} . Cette idée est donc en partie formelle, et n'est pas directement applicable. On peut trouver néanmoins dans la littérature des approches basées sur cette idée qui proposent d'utiliser des méthodes de Monte Carlo par chaîne de Markov (du type algorithme de Métropolis, échantillonneur de Gibbs, ...) pour générer des transitions suivant un noyau ayant pour mesure invariante, l'approximation particulière de π_{n-1} (à défaut de π_{n-1}) qui elle est donnée par le filtre approché. Nous ne discutons pas ici le détail de ce type de méthodes, pour plus d'informations on peut se reporter aux articles [3, 11, 46, 94]. Cependant on observe que, dans beaucoup d'algorithmes proposés, la méthode consiste d'abord à robustifier le filtre par rapport aux perturbations locales puis à introduire l'étape d'échantillonnage permettant le calcul du filtre, en espérant ainsi un meilleur contrôle de l'erreur induite.

5.5 Amélioration par des heuristiques

Dans cette section nous proposons des méthodes d'approximation permettant de contrôler l'étape de correction entre les instants $n-1$ et n en terme d'erreur et de temps de calcul. Ces méthodes ont été présentées dans [82, 88]. Nous rappelons que pour toutes mesures de probabilité sur $\mathbb{R}^d$, μ et μ' si Q est un noyau markovien et Ψ une fonction positive bornée sur $\mathbb{R}^d$ telle que $\langle \mu, \Psi \rangle > 0$, alors les inégalités suivantes sont vérifiées.

$$\|Q\mu - Q\mu'\| \leq \|\mu - \mu'\|, \quad (5.47)$$

$$\|\Psi \cdot \mu - \Psi \cdot \mu'\| \leq \gamma \|\mu - \mu'\|, \quad (5.48)$$

avec $\gamma = \|\Psi\|/\langle\mu, \Psi\rangle \geq 1$. L'inégalité (5.48) est atteinte (voir [55, pp. 99–100]), et montre que l'étape de correction peut induire des erreurs considérables lorsque γ est grand (ce qui arrive typiquement lorsque le bruit de mesure est faible ou bien lorsque l'observation est abhérante, i.e. lorsqu'elle n'est pas cohérente avec la mesure a priori). Par contre, l'étape de prédiction est toujours une contraction, comme le montre l'inégalité (5.47). C'est pour cette raison que nous nous intéressons particulièrement à l'étape de correction. Dans la suite, le but est de développer une méthode pour approcher la distribution a posteriori $\Psi \cdot \mu$. γ est appelé ici coefficient de coût de la correction. Rappelons que dans le contexte du filtrage, la distribution de probabilité μ à corriger est la loi prédite. Pour alléger les notations, nous oublions volontairement, dans cette section, de préciser la dépendance en fonction du temps. Nous travaillons à un instant donné $n \geq 1$, pour lequel la fonction de vraisemblance Ψ_n , l'observation courante Y_n et la loi prédite $\pi_{n|n-1}$ sont notées respectivement Ψ , Y et μ .

5.5.1 Analyse de deux méthodes approchées de correction

En filtrage particulière, la difficulté essentielle réside dans l'étape de correction. Deux types d'approximation ont été proposées au travers des méthodes particulières post-régularisées et pré-régularisées.

Correction par pondération $\mu \rightarrow \Psi \cdot S^N(\mu) \rightarrow K_h * (\Psi \cdot S^N(\mu))$

Comme le montre le schéma (5.13), cette méthode de correction est celle utilisée par le post-RPF. L'étape de correction consiste seulement à pondérer les particules i.i.d. suivant μ . La vraisemblance des autres points de l'espace n'est pas prise en compte. Dans le cas typique, où les observations sont très précises, la fonction de vraisemblance se concentre dans une petite région de l'espace d'état qui peut être si réduite qu'elle ne contient que peu ou pas de particules. Dans ces cas, nous observons communément, en simulation, la divergence du post-RPF, comme le suggère l'inégalité (5.48). Néanmoins, le temps de calcul reste raisonnable et indépendant de γ .

Correction par rejet $\mu \rightarrow K_h * S^N(\mu) \rightarrow \Psi \cdot (K_h * S^N(\mu))$

Comme le montre le schéma (5.1), cette méthode est celle utilisée par le pré-RPF. Ici, la correction est appliquée sur la régularisation de la mesure empirique. Ainsi, chaque point du support de la densité est remis à jour par la vraisemblance, l'information fournie par l'observation est mieux exploitée, et le problème de divergence rencontré avec la correction par pondération disparaît. Malheureusement, si nous voulons ensuite produire un N -échantillon i.i.d. suivant la mesure résultante, nous devons implémenter un algorithme d'acceptation / rejet. Cette méthode exige de générer suivant μ , un nombre aléatoire de variables aléatoires qui suit une binomiale négative (loi de Pascal) de paramètre $(N, 1/\gamma)$, et de moyenne $N\gamma$ (comme somme de N variables aléatoires indépendantes géométriquement distribuées de paramètre $1/\gamma$, voir annexe). Cela entraîne que lorsque γ est grand, nous observons une augmentation importante du temps de calcul. Cependant, nous n'avons jamais observé la divergence du filtre, lors des simulations réalisées.

Quelque soit la méthode choisie pour approcher la correction, le cas où γ est grand semble être difficile à traiter. Il se traduit soit par une augmentation d'erreur, soit par une augmen-

tation du temps de calcul. Le but de la correction progressive est justement de contrôler ces deux paramètres.

5.5.2 Principe de la correction progressive

L'idée principale de la correction progressive vient de l'observation élémentaire suivante. Si μ est une mesure de probabilité sur $\mathbb{R}^d$, et si Ψ , $\Psi^{(1)}$ et $\Psi^{(2)}$ sont trois fonctions positives définies sur $\mathbb{R}^d$, telles que $\Psi = \Psi^{(1)} \Psi^{(2)}$, alors il est équivalent de corriger μ par Ψ , ou de corriger successivement μ par $\Psi^{(1)}$ puis la mesure obtenue par $\Psi^{(2)}$. En d'autres termes,

$$\Psi \cdot \mu = \Psi^{(2)} \cdot (\Psi^{(1)} \cdot \mu) . \quad (5.49)$$

La correction progressive propose de diviser l'étape de correction en plusieurs étapes de sous-corrrection pour lesquelles le coefficient γ est bien contrôlé. Pour cela, il nous faut choisir une décomposition $(\Psi^{(1)}, \dots, \Psi^{(L)})$ de la fonction de vraisemblance Ψ . Ce problème sera traité dans la Section 5.5.3. Pour le moment, supposons que cette décomposition est donnée. Soit $\nu_l = \Psi^{(l)} \cdot \nu_{l-1}$ la distribution résultant des l premières sous-corrrections, $1 \leq l \leq L$, avec $\nu_0 = \mu$. Soit γ_l le coefficient de coût correspondant à la l -ième sous-corrrection, i.e.,

$$\gamma_l = \frac{\|\Psi^{(l)}\|}{\langle \nu_{l-1}, \Psi^{(l)} \rangle} .$$

On vérifie facilement que le coefficient de coût total est égal au produit des sous-coefficients γ_l , $1 \leq l \leq L$, i.e.

$$\gamma = \gamma_1 \cdots \gamma_L ,$$

pourvu que les fausses fonctions de vraisemblance $\Psi^{(l)}$ atteignent leur maximum pour le même point de l'espace d'état.

Correction progressive par pondération

Soit $\tilde{\nu}_l$ l'approximation de ν_l obtenue par l'application d'une succession de sous-corrrections par pondération i.e. $\tilde{\nu}_0 = \mu$ et,

$$\tilde{\nu}_l = K_h * (\Psi^{(l)} \cdot S^N(\tilde{\nu}_{l-1})) , \quad 1 \leq l \leq L .$$

De manière analogue à γ_l , nous définissons

$$\tilde{\gamma}_l = \frac{\|\Psi^{(l)}\|}{\langle \tilde{\nu}_{l-1}, \Psi^{(l)} \rangle} .$$

Soit $\tilde{\mathcal{S}}_l$ la tribu engendrée par l'observation Y et les variables aléatoires simulées lors du passage de $\tilde{\nu}_0$ à $\tilde{\nu}_l$. D'après l'inégalité (5.48) et les majorations d'erreur du Chapitre 4, nous avons

Proposition 5.19. *Si ν_{l-1} est a.c. par rapport à la mesure de Lebesgue, avec la densité $\frac{d\nu_{l-1}}{dx} \in W^{2,1}$, alors l'erreur locale moyenne due à la correction progressive par pondération vérifie*

$$\mathbb{E}[\|\tilde{\nu}_l - \nu_l\| \mid \tilde{\mathcal{S}}_{l-1}] \leq \tilde{\alpha}_l h^2 + \tilde{\gamma}_l \frac{\tilde{\beta}_l}{\sqrt{N} h^p} + \min(\tilde{\gamma}_l, \gamma_l)[\|\tilde{\nu}_{l-1} - \nu_{l-1}\|] , \quad (5.50)$$

avec $\tilde{\alpha}_l = a_2(K) \|\Psi^{(l)} \cdot \frac{d\nu_{l-1}}{dx}\|_{2,1}$, et $\tilde{\beta}_l = 2 A'_d [1 + I(\tilde{\nu}_{l-1})] b(K)$.

Correction progressive par rejet

Soit $\bar{\nu}_l$ l'approximation de ν_l obtenue par l'application d'une succession de sous-corrrections par rejet, i.e. $\bar{\nu}_0 = \mu$ et

$$\bar{\nu}_l = \Psi^{(l)} \cdot (K_h * S^N(\bar{\nu}_{l-1})) , \quad 1 \leq l \leq L .$$

De manière analogue à $\tilde{\gamma}_l$, nous définissons

$$\tilde{\gamma}_l = \frac{\|\Psi^{(l)}\|}{\langle K_h * S^N(\bar{\nu}_{l-1}), \Psi^{(l)} \rangle} .$$

Soit $\bar{\mathcal{S}}_l$ la tribu engendrée par l'observation Y et les variables aléatoires simulées lors du passage de $\bar{\nu}_0$ à $\bar{\nu}_l$. D'après l'inégalité (5.48) et les résultats classiques d'estimation de densité (voir Chapitre 4), nous avons

Proposition 5.20. *Si ν_{l-1} est a.c. par rapport à la mesure de Lebesgue, avec la densité $\frac{d\nu_{l-1}}{dx} \in W^{2,1}$, alors l'erreur local moyenne due à la correction progressive par rejet vérifie*

$$\mathbb{E}[\|\bar{\nu}_l - \nu_l\| \mid \bar{\mathcal{S}}_{l-1}] \leq \min(\tilde{\gamma}_l, \gamma_l) [\tilde{\alpha}_l h^2 + \frac{\tilde{\beta}_l}{\sqrt{N} h^d} + \|\bar{\nu}_{l-1} - \nu_{l-1}\|] , \quad (5.51)$$

avec $\tilde{\alpha}_l = a_2(K) \mid \frac{d\nu_{l-1}}{dx} \mid_{2,1}$, et $\tilde{\beta}_l = A'_d [1 + I(\bar{\nu}_{l-1})] b(K)$.

De plus, le nombre de générations de variables aléatoires requises pour générer un N -échantillon i.i.d. suivant $\bar{\nu}_L$ (pour une décomposition $(\Psi^{(1)}, \dots, \Psi^{(L)})$ donnée) est une variable aléatoire de moyenne $N(\tilde{\gamma}_1 + \dots + \tilde{\gamma}_L)$. Nous rappelons que le nombre de simulations requises pour générer un N -échantillon i.i.d. suivant ν_L est en moyenne $N\gamma = N(\gamma_1 \dots \gamma_L)$. Nous voyons donc que la correction progressive permet, au prix d'une erreur de correction donnée par (5.51), de changer le produit $(\gamma_1 \dots \gamma_L)$ en la somme $(\tilde{\gamma}_1 + \dots + \tilde{\gamma}_L)$, ce qui en général réduit considérablement le coût de calcul.

Les inégalités (5.50) et (5.51) montrent que l'erreur commise à l'itération l se compose d'une erreur due à la sous-corrrection courante et d'un terme d'erreur transportée à travers la sous-corrrection. Ainsi, la correction progressive permet de réduire le coût de transport de l'erreur (le coefficient de coût γ_l est remplacée par $\min(\tilde{\gamma}_l, \gamma_l)$) en induisant une erreur à chaque sous-corrrection.

Il nous faut maintenant choisir $\Psi^{(l)}$ tel que $\tilde{\gamma}_l$ (ou γ_l) soit bien contrôlé.

5.5.3 Choix adaptatif de la décomposition

Nous décrivons une méthode adaptative de choix de la décomposition $(\Psi^{(1)}, \dots, \Psi^{(L)})$, dans le cas général d'un bruit d'observation additif pas nécessairement gaussien.

Supposons que la décomposition $(\Psi^{(1)}, \dots, \Psi^{(l-1)})$ soit déjà donnée jusqu'au pas $l-1 < L$, et que les $(l-1)$ premières sous-corrrections soient déjà réalisées. Nous avons alors à notre disposition $\bar{\nu}_{l-1}$, dans le cas de la correction par pondération et $\bar{\nu}_{l-1}$, dans le cas de la correction par rejet. Le but est de trouver $\Psi^{(l)}$ tel que $\tilde{\gamma}_l \leq \gamma_{\max}$ (ou $\tilde{\gamma}_l \leq \gamma_{\max}$), où $\gamma_{\max} > 1$ est un

paramètre de contrôle choisi par l'utilisateur et déterminant le coefficient de coût maximal autorisé à chaque étape de sous-correction. Rappelons que

$$\begin{aligned}\frac{d\tilde{\nu}_l}{dx}(x) &= \frac{d(K_h * (\Psi^{(l)} \cdot S^N(\tilde{\nu}_{l-1})))}{dx}(x) = \sum_{i=1}^N \tilde{\omega}_l^i K_h(x - \tilde{x}_{l-1}^i), \\ \frac{d\bar{\nu}_l}{dx}(x) &= \frac{d(\Psi^{(l)} \cdot (K_h * S^N(\bar{\nu}_{l-1})))}{dx}(x) \propto \sum_{i=1}^N \Psi^{(l)}(x) K_h(x - \bar{x}_{l-1}^i),\end{aligned}$$

avec $(\tilde{x}_{l-1}^1, \dots, \tilde{x}_{l-1}^N)$ i.i.d. $\sim \tilde{\nu}_{l-1}$, et $(\bar{x}_{l-1}^1, \dots, \bar{x}_{l-1}^N)$ i.i.d. $\sim \bar{\nu}_{l-1}$ et où $\propto$ signifie que les quantités de par et d'autre du symbol sont proportionnelles. Notons que nous recherchons $\Psi^{(l)}$ ou toute autre fonction proportionnelle (du fait de la normalisation). Nous recherchons $\Psi^{(l)}$ parmi les fonctions de la famille paramétrée,

$$\Psi^{(l)}(x) = [\Psi(x)]^{1/\lambda_l} = [g(Y - h(x))]^{1/\lambda_l}, \quad (5.52)$$

où Y est la mesure courante, h la fonction d'observation, g la densité du bruit d'observation additif et $\lambda_l > 0$ est un paramètre à déterminer. Il nous est facile d'approcher $\tilde{\gamma}_l$ et $\bar{\gamma}_l$ par les approximations de Monte Carlo suivantes,

$$\tilde{\gamma}_l = \frac{\|\Psi^{(l)}\|}{\langle \tilde{\nu}_{l-1}, \Psi^{(l)} \rangle} \approx N \frac{\|\Psi^{(l)}\|}{\sum_{i=1}^N \Psi^{(l)}(\tilde{x}_{l-1}^i)}, \quad \bar{\gamma}_l = \frac{\|\Psi^{(l)}\|}{\langle K_h * S^N(\bar{\nu}_{l-1}), \Psi^{(l)} \rangle} \approx N \frac{\|\Psi^{(l)}\|}{\sum_{i=1}^N \Psi^{(l)}(\bar{x}_{l-1}^i)}.$$

Dorénavant, les cas de la correction par pondération et par rejet étant complètement similaires nous ne considérons que l'un des deux. Le choix de λ_l est déterminé par l'équation suivante,

$$\min_{1 \leq i \leq N} \Psi^{(l)}(\tilde{x}_{l-1}^i) = \|\Psi^{(l)}\|/\gamma_{\max}. \quad (5.53)$$

La condition (5.53) est choisie parce qu'elle entraîne approximativement $\tilde{\gamma}_l \leq \gamma_{\max}$ et qu'elle est suffisante pour déterminer λ_l . En effet, d'après (5.53),

$$\lambda_l = \frac{\max_{1 \leq i \leq N} [-\log g(Y - h(\tilde{x}_{l-1}^i))]}{\log(\gamma_{\max}) - \log(\|\Psi^{(l)}\|)}.$$

Nous observons que la suite $(\lambda_1, \dots, \lambda_{l-1}, \dots)$ est décroissante. En effet, à chaque étape de sous-correction, les particules se concentrent de plus en plus autour du véritable état, entraînant ainsi la décroissance de $\max_{1 \leq i \leq N} [-\log g(Y - h(\tilde{x}_{l-1}^i))]$. Pour assurer que le produit $(\Psi^{(1)} \dots \Psi^{(L)}) = \Psi$, nous définissons la procédure d'arrêt de l'algorithme suivante: si $\sum_{i=1}^l 1/\lambda_i > 1$, poser $l = L$, et la dernière itération de l'algorithme est réalisée avec $\Psi^{(L)} = \Psi/(\Psi^{(1)} \dots \Psi^{(L-1)})$. Si aucune autre condition n'est ajoutée, la taille L de la décomposition est a priori inconnue et déterminée pendant l'implémentation de l'algorithme puisque la condition d'arrêt de l'algorithme est alors aléatoire. Dans ce cas, le temps de calcul ainsi que l'erreur induite par les étapes de sous-correction ne sont pas contrôlés. Pour remédier à cela, nous

associations au paramètre, $\gamma_{\max}$, un nombre maximal de sous-corrrections, $L_{\max}$ qui assure un temps maximal d'exécution et limite l'erreur de sous-corrrection. Le choix de $\gamma_{\max}$ et de $L_{\max}$ permet ainsi de réaliser un compromis entre l'erreur de transport et l'erreur de sous-corrrection. Le calcul de $\Psi^{(l)}$ à chaque étape de sous-corrrection est finalement réalisé par les deux étapes suivantes,

(i) Calculer

$$\lambda_l = \frac{\max_{1 \leq i \leq N} [-\log g(Y - H(\tilde{x}_{l-1}^i))]}{\log(\gamma_{\max})} .$$

(ii) Si $\sum_{i=1}^l 1/\lambda_i \leq 1$, et $l \leq L_{\max}$, calculer $\Psi^{(l)}$ par (5.52), sinon poser $L = l$, et $\Psi^{(L)} = \Psi / (\Psi^{(1)} \dots \Psi^{(l-1)})$.

Remarque 5.21. Dans le cas particulier où le bruit d'observation est additif et gaussien de matrice de covariance Σ la correction progressive s'implémente de la manière suivante,

$$\Psi^{(l)}(x) = C \exp\left\{-\frac{1}{2\lambda_l} (Y - h(x))^T \Sigma^{-1} (Y - h(x))\right\} ,$$

où Y est l'observation courante, et $\lambda_l > 0$ est un paramètre à déterminer. Le choix de λ_l est déterminé par (5.53), ce qui entraîne

$$\lambda_l = \frac{\max_{1 \leq i \leq N} (Y - h(\tilde{x}_{l-1}^i))^T \Sigma^{-1} (Y - h(\tilde{x}_{l-1}^i))}{2 \log(\gamma_{\max})} .$$

Dans ce cas particulier, la correction progressive est basée sur l'idée qu'une observation précise peut être remplacée, de manière équivalente, par plusieurs observations moins précises (dont les matrices de covariances de bruits $(\lambda_1 \Sigma, \dots, \lambda_{l-1} \Sigma, \dots)$ sont décroissantes).

Remarque 5.22. On peut aussi voir la correction progressive comme une technique de relaxation du type recuit simulé utilisé le plus souvent pour résoudre des problèmes d'optimisation. Dans les deux cas, le but est d'obtenir un échantillon issu d'une distribution de probabilité μ_0 , et cela est réalisé par génération successive d'échantillons approximativement distribués suivant une suite de probabilités $(\mu_{T_1}, \mu_{T_2}, \dots, \mu_{T_l}, \dots)$ indexées par un paramètre de température décroissant. Quand T_l tend vers zéro, μ_{T_l} tend vers μ_0 , si bien que l'échantillon est asymptotiquement distribué suivant μ_0 . Dans la correction progressive, l'idée est semblable avec $1/T_l = \sum_{i=1}^l 1/\lambda_i$ à la différence que l'algorithme est arrêté avant que la température soit nulle.

Remarque 5.23. En fait, le principe de la correction progressive n'est qu'une extension naturelle de l'idée des filtres pré-régularisés et post-régularisés utilisés dans le cas d'un signal immobile. En effet, considérons le système état / observation,

$$\begin{cases} X_{l+1} = X_l \\ Y_l = h(X_l) + V_l \end{cases} , \quad (5.54)$$

où les v.a. V_l sont indépendantes de densité proportionnelle à g^{1/λ_l} avec $\lambda_l > 0$. La fonction de vraisemblance Ψ_l vérifie alors

$$\Psi_l(x) \propto g^{1/\lambda_l} (Y_l - h(x)) ,$$

pour tout $x \in E$. Comme l'état X_n est immobile, le filtre optimal suit l'évolution,

$$\pi_l = \Psi_l \cdot \pi_{l-1} = \Psi_l \cdot (\Psi_{l-1} \cdot \pi_{l-2}) .$$

D'après l'égalité (5.49), on a donc

$$\pi_l = (\Psi_l \Psi_{l-1} \cdots \Psi_1) \cdot \pi_0 .$$

Le post-RPF (respectivement le pré-RPF) appliqué à ce système conduit à un algorithme semblable à la correction progressive par pondération (respectivement par rejet) utilisé pour réaliser une correction suivant $\Psi = \Psi^{(L)} \cdots \Psi^{(1)}$. La différence réside dans le fait qu'avec la correction progressive les pseudo-fonctions de vraisemblance dépendent toutes de la même observation Y , i.e.

$$\Psi^{(l)}(x) = g^{1/\lambda_l} (Y - h(x)) \neq \Psi_l(x) ,$$

comme si on avait obtenu la même observation $Y_l = Y$ à chaque instant d'observation. On peut donc dire que la correction progressive revient à utiliser un filtre particulaire régularisé après avoir remplacé l'observation précise Y par plusieurs observations moins précises $Y^{(1)} = Y^{(2)} = \cdots = Y^{(L)} = Y$ de mêmes valeurs mesurant le même état immobile $X^{(1)} = X^{(2)} = \cdots = X^{(L)} = X$.

5.5.4 Conclusion

Cette méthode suit une règle de bon sens naturelle : lorsque les observations sont très précises, il vaut mieux privilégier, lors de la correction l'information apportée par l'observation par rapport à l'approximation de la loi prédite dont on dispose. En effet, dans ce cas, les erreurs d'approximations accumulées (dues, en particulier, aux échantillonnages successifs réalisés à chaque instant d'observation) sont souvent d'un ordre largement supérieur à la précision de l'observation. Le cas extrême serait de ne pas du tout prendre en compte l'approximation de la loi prédite et d'approcher la loi corrigée par la mesure chargeant les points de l'espace d'état maximisant la fonction de vraisemblance. La correction progressive est moins brutale. Elle modifie la loi a priori de sorte à la rapprocher de la fonction de vraisemblance, sans pour autant oublier complètement l'a priori. On observera dans les simulations du chapitre suivant l'apport de cette heuristique.

Conclusion du Chapitre 5

Dans ce chapitre consacré aux méthodes particulières régularisées, nous avons présenté et analysé deux nouveaux types de filtres particuliers.

Dans le cas de systèmes assez généraux, les résultats de convergence obtenus pour le sens faible sont du même ordre que pour l'IPF : les hypothèses exigées pour que l'erreur n'explose pas de façon exponentielle avec le temps, sont assez contraignantes. Par contre, nous montrons des résultats de convergence au sens de la variation totale relativement satisfaisants, dans le sens où les majorations d'erreurs obtenues sont plus stables dans le temps. Notons que les majorations d'erreurs pour le filtre pré-régularisé sont valables sous des hypothèses plus générales que celles obtenues pour le filtre post-régularisé. Cependant, l'utilisation d'un nombre aléatoire de particules permet de rendre le post-RPF aussi performant que le pré-RPF, en terme de majoration d'erreur. Cela semble naturel dans la mesure où l'acceptation / rejet et l'échantillonnage pondéré avec nombre aléatoire de v.a. simulées sont deux méthodes de performances comparables. Dans le cas de systèmes à dynamique mélangeante, l'application des résultats de stabilité du Chapitre 2 permet d'obtenir la convergence uniforme en temps des méthodes particulières régularisées.

Nous avons vu que l'étape de régularisation basée sur la théorie de l'estimation de densité par noyaux, peut être aussi perçue comme une étape de robustification du filtre optimal avant l'introduction des erreurs locales d'échantillonnage permettant le calcul du filtre. On peut finalement récapituler les différentes justifications plus ou moins intuitives des méthodes particulières régularisées :

- Elles permettent d'éviter la dégénérescence des particules, en assurant à chaque échantillonnage, la diversité du système de particules.
- Elles induisent une erreur locale contrôlée sous la variation totale. Or on sait d'après la Section 2.1 du Chapitre 2 qu'une erreur en variation totale se transporte mieux à travers le filtre qu'une erreur moyenne au sens faible. On obtient ainsi une approximation plus stable que celle fournie par l'IPF.
- Elles consistent à remplacer les transitions du processus état par des transitions "plus mélangeantes". Le filtre résultant est alors plus robuste par rapport aux perturbations locales. L'erreur d'échantillonnage induite est mieux transportée.
- En d'autres termes, elles introduisent de l'oubli sur la dynamique du système. La propagation de l'erreur locale est alors mieux contrôlée tandis que la précision du filtre est détériorée. Cela a pour effet d'équilibrer l'erreur (globale) d'approximation avec la précision du filtre perturbé.

Enfin, nous avons proposé une méthode heuristique permettant de traiter le cas difficile du faible bruit d'observation. L'idée consiste, en un sens, à remplacer l'observation précise par une suite d'observations moins précises pour lesquelles l'étape de correction est facile à réaliser (en terme d'erreur commise ou de temps de calcul).

Ce chapitre aura permis de présenter et de justifier en théorie l'intérêt des nouvelles méthodes particulières développées. Il est aussi intéressant d'étudier le comportement en simulations de ces algorithmes. Dans le chapitre suivant, nous comparons les performances simulées des méthodes particulières régularisées à celles d'autres algorithmes. Cela permettra de mettre en évidence l'intérêt pratique des filtres régularisés.

Chapitre 6

Application au pistage

Le problème du pistage ou de la poursuite de cibles consiste à estimer les paramètres cinématiques d'un mobile (position, vitesse, accélération ...) au vu de mesures bruitées fonctions de ces paramètres fournies par un capteur (radar, sonar, capteur optique ...). On possède en général un modèle de dynamique décrivant l'évolution de l'état de la cible dans le temps découlant de la connaissance a priori que l'on a du système. Les modèles de dynamique choisis sont souvent linéaires,

$$X_n = F_n X_{n-1} + W_n .$$

Par contre, l'équation d'observation liant la mesure à l'état est très souvent non linéaire : elle dépend évidemment du capteur utilisé. La mesure de l'état X_n fournie par le capteur est modélisée par une équation du type,

$$Y_n = h_n(X_n) + V_n .$$

On retrouve exactement l'énoncé d'un problème de filtrage classique.

Dans ce chapitre, nous nous intéressons aux comportements simulés des méthodes particulières régularisées sur des problèmes concrets de pistage. Nous avons fait le choix d'applications réalistes, par conséquent les hypothèses requises pour la convergence uniforme des filtres approchés dans les théorèmes et propositions du Chapitre 5 ne sont en général pas satisfaites dans les applications considérées. Ce chapitre présente néanmoins un intérêt pratique certain en montrant l'apport des méthodes particulières régularisées face aux méthodes particulières classiques et surtout en proposant des solutions simples à des problèmes difficiles de pistage, pour lesquels les méthodes classiques telles que l'EKF sont parfois mises en défaut.

Dans la première section de ce chapitre, nous comparons les performances de l'IPF et du RPF sur le problème de pistage par mesure de distance et d'angle. On s'intéresse particulièrement à l'évolution des performances de chacun des algorithmes en fonction des puissances du bruit d'état. Dans la deuxième section, nous soulignons l'intérêt pratique du RPF en comparant ses performances à celles de l'EKF. Nous considérons pour cela deux problèmes de pistage difficiles : le pistage par mesure d'angle seul et le pistage de précision par mesures de distance et d'angle. La troisième section est consacrée au problème complexe du pistage de cible manœuvrante. Dans ce cas, la cible est capable de suivre différents modèles de dynamique. Nous verrons que la solution particulière de ce problème est simple et efficace comparée à l'algorithme classiquement utilisé pour résoudre ce problème. Enfin, nous illustrons dans la

quatrième section l'intérêt de la correction progressive au travers de l'exemple du pistage par mesure de distance et d'angle lorsque la mesure de distance est très précise.

6.1 Modèle d'état et estimation des performances

6.1.1 Modèle d'état

On considère le problème de pistage d'un mobile se déplaçant dans un plan munis d'un repère cartésien de référence. L'évolution du mobile est ainsi décrite par l'évolution de ses coordonnées $(x(t), y(t))$. Si on note $\vec{F}_t$ la somme des forces agissant à l'instant t sur le mobile de masse m , alors on obtient, par les lois de la mécanique, une relation liant l'accélération du mobile à la force $\vec{F}_t$:

$$m \begin{bmatrix} \ddot{x}(t) \\ \ddot{y}(t) \end{bmatrix} = \vec{F}_t. \quad (6.1)$$

La force $\vec{F}_t$ se réduit aux frottements de l'air ou à d'autres perturbations extérieures lorsque le mobile n'est pas en phase de manœuvre (i.e. lorsque qu'il n'accélère pas). Dans ce cas, on dit que le mobile est en mouvement rectiligne uniforme bruité. Lorsque le mobile opère une accélération volontaire (produite par la poussée des moteurs), la force $\vec{F}_t$ résulte en plus de cette accélération. Dans ce cas on dit que le mobile est en phase de manœuvre. On fait l'hypothèse du modèle d'état discret [6, p. 86] i.e. qu'entre deux instants de discrétisation t_n et t_{n+1} , l'accélération $\vec{F}_t/m$ est supposée constante et égale à $[w_n^1, w_n^2]$ où les accélérations $([w_k^1, w_k^2])_{k \geq 0}$ sont indépendantes entre deux intervalles de discrétisation. Avec cette hypothèse, en intégrant par deux fois l'équation (6.1), entre t_n et t_{n+1} , on obtient

$$\begin{bmatrix} x(t_{n+1}) \\ \dot{x}(t_{n+1}) \\ y(t_{n+1}) \\ \dot{y}(t_{n+1}) \end{bmatrix} = \begin{bmatrix} 1 & T & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & T \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x(t_n) \\ \dot{x}(t_n) \\ y(t_n) \\ \dot{y}(t_n) \end{bmatrix} + \begin{bmatrix} T^2/2 & 0 \\ T & 0 \\ 0 & T^2/2 \\ 0 & T \end{bmatrix} \begin{bmatrix} w_n^1 \\ w_n^2 \end{bmatrix}, \quad (6.2)$$

où $T = t_{n+1} - t_n$ est la période de discrétisation du modèle. Pour tout entier $n \geq 0$, on note

$$X_n = \begin{bmatrix} x_{1,n} \\ x_{2,n} \\ x_{3,n} \\ x_{4,n} \end{bmatrix} = \begin{bmatrix} x(t_n) \\ \dot{x}(t_n) \\ y(t_n) \\ \dot{y}(t_n) \end{bmatrix}.$$

X_n constitue l'état du mobile à l'instant t_n , i.e. sa position et sa vitesse suivant chacune des coordonnées. L'équation (6.2) décrivant l'évolution de X_n dans le temps est appelée équation d'état. Le but du pistage est d'estimer la valeur de X_n , il s'agit donc ici d'un problème de dimension 4.

6.1.2 Estimation des performances

Dans la suite, nous présentons des problèmes de pistage dans le plan auxquels différentes versions de filtres particuliers sont appliquées. L'erreur commise en chacune des coordonnées

j de l'état, est estimée à partir de M tirages Monte Carlo

$$\{\mathbb{E}[\hat{x}_{j,n} - \mathbb{E}(\hat{x}_{j,n})]^2\}^{1/2} \approx \left\{ \frac{1}{M} \sum_{k=1}^M [\hat{x}_{j,n}^{(k)} - \frac{1}{M} \sum_{k=1}^M \hat{x}_{j,n}^{(k)}]^2 \right\}^{1/2} \quad [\text{écart-type}]$$

$$\mathbb{E}(\hat{x}_{j,n}) - \mathbb{E}(x_{j,n}) \approx \frac{1}{M} \sum_{k=1}^M [\hat{x}_{j,n}^{(k)} - x_{j,n}] \quad [\text{biais}]$$

où $x_{j,n}$ est la j -ème coordonnée du véritable état X_n du mobile, et $\hat{x}_{j,n}^{(k)}$ est la j -ème coordonnée de l'estimée fournie par le filtre approché au k -ième tirage Monte Carlo. Le nombre de tirages Monte Carlo est $M = 50$. Les filtres approchés sont initialisés avec la loi normale de moyenne un faux état $\hat{X}_0$ généré suivant la loi normale centrée en X_0 (le véritable état) et de matrice de covariance P_0 qui sera précisée dans chaque cas. Nous considérons en général des problèmes de pistage sans bruit de dynamique, nous pouvons alors facilement calculer la borne de Cramer Rao (BCR) qui fournit une borne inférieure de l'écart-type de tout estimateur sans biais (voir [9]). Elle nous permettra d'évaluer les performances des algorithmes simulés.

6.2 Comparaison RPF / IPF

6.2.1 Pistage radar

Nous rappelons brièvement le principe de mesure d'un radar de poursuite décrit en détails dans [27]. Le radar envoie un signal très bref ou impulsion dans une direction donnée. Ce signal se propage à la vitesse de la lumière, dans toutes les directions : il forme une onde sphérique. Au bout d'un intervalle de temps ΔT , le signal atteint la cible, ce temps est proportionnel à la distance radar-cible. Une partie du signal est réfléchiée par la cible et au bout du même intervalle de temps ΔT , l'onde réfléchiée atteint après atténuation et effet doppler à nouveau le radar. Celui-ci, après avoir traité le signal reçu (amplification, filtrage, détection, corrélation ...), fournit une estimation de la distance entre le radar et la cible et de l'angle formé par l'axe de visée du radar et un axe de référence. L'utilisation d'un tel radar de poursuite conduit au problème de pistage par mesure de distance et d'angle.

Remarque 6.1. Dans le cas général, la matrice de covariance du bruit de mesure est fonction du rapport signal / bruit qui est lui-même fonction de la distance radar-cible. Afin de faciliter les calculs, dans les applications considérées, nous avons négligé cette contrainte. La matrice de covariance du bruit de mesure est considérée fixée.

6.2.2 Simulations

Dans les simulations effectuées, le mobile suit un mouvement rectiligne uniforme (MRU). Le radar fournit des mesures bruitées de la distance entre l'observateur et le mobile, ainsi que de l'angle formé par l'axe vertical et la ligne de visée, i.e.,

$$h_n(X) = \begin{pmatrix} \sqrt{x_1^2 + x_3^2} \\ \arctan(x_3/x_1) \end{pmatrix},$$

où $X = (x_1, x_2, x_3, x_4)$ désigne dans l'ordre, la position et la vitesse en abscisse et la position et la vitesse en ordonnée du mobile dont l'état est X .

Nous considérons le problème suivant de pistage par mesure de distance et d'angle.

- L'état initial est $X_0 = (5\text{km}, -20\text{m/s}, 5\text{km}, 20\text{m/s})$ avec comme matrice de covariance $P_0 = [\text{diag}(2\text{km}, 20\text{m/s}, 2\text{km}, 20\text{m/s})]^2$. La dynamique de la cible est bruitée selon l'équation (6.2) avec un bruit sur l'accélération $w^1 = w^2 = c$ variable.
- Le temps de poursuite est $T = 200\text{s}$ avec une période de mesures $\Delta = 1\text{s}$.
- L'écart-type des bruits de mesure sur la distance et l'angle sont respectivement de 50m et 1 degré.




FIG. 6.1: Trajectoires réelles et simulées pour (a) $c = 2 \text{ m/s}^2$ et (b) $c = 1.5 \text{ m/s}^2$.

Nous avons observé l'influence du bruit d'état sur les performances de l'IPF et du post-RPF, tous deux fonctionnant avec $N = 3000$ particules. Pour cela, nous avons fait varier l'écart-type du bruit d'accélération en x et en y , ($w^1 = w^2 = c$) entre $c = 0.4 \text{ m/s}^2$ et $c = 3 \text{ m/s}^2$. Lorsque $c = 1.5 \text{ m/s}^2$, Figure 6.1(b), on observe que l'estimée fournie par l'IPF se dégrade, mais elle reste acceptable sur la fin de la trajectoire. La Figure 6.2, pour $c = 1 \text{ m/s}^2$, met clairement en évidence le phénomène de dégénérescence des particules. Les quelques nuages de particules représentés sont, en effet, concentrés dans une trop petite zone de l'espace pour contenir le véritable état : l'IPF diverge. Par contre, on observe que le post-RPF fournit toujours une estimée acceptable de la trajectoire. Les résultats des simulations montrent que le post-RPF est insensible aux variations de puissance du bruit d'état, contrairement à l'IPF dont les performances se dégradent nettement lorsque le bruit diminue. Cependant, lorsque la dynamique est suffisamment bruitée i.e. $c \geq 2$, voir Figure 6.1(a), les performances des deux filtres semblent comparables. Il apparaît que l'étape de régularisation n'apporte rien dès lors que le bruit de dynamique est assez fort.

Sur la Figure 6.3, nous avons représenté le nombre de particules nécessaire à l'IPF pour fournir des performances équivalentes au post-RPF avec 3000 particules, lorsque la puissance du bruit de dynamique varie. On observe naturellement que le nombre de particules augmente lorsque la puissance du bruit diminue. Mais il est intéressant de noter que cette croissance

est très rapide, apparemment exponentielle. On voit donc que le coût de calcul de l'IPF est rédhibitoire en-dessous d'un certain seuil de bruit d'état. Or, dans beaucoup d'applications considérées, le bruit d'état est faible ou inexistant (notons que dans le cas $c = 2m/s^2$ la trajectoire observée sur la Figure 6.1(a) est trop chahutée pour être réaliste). Ajouter du bruit artificiellement permettrait effectivement d'empêcher la divergence de l'IPF, mais cela au prix de gâcher la précision du modèle d'état dont on dispose.

Notons qu'en terme de temps de calculs, pour un même nombre de particules le post-RPF coûte en moyenne 1.5 fois plus cher que l'IPF. Nous avons préféré néanmoins comparer les performances à nombre de particules égal (et non à temps de calcul égal) car cette quantité est plus significative, dans le sens où l'on observe que pour un bruit d'état assez grand les deux filtres ont des performances équivalentes.




FIG. 6.2: *Trajectoires réelles et simulées pour $c=1 m/s^2$.*




FIG. 6.3: *Nombre de particules en fonction du bruit de dynamique.*

6.3 Comparaison RPF / EKF

6.3.1 Pistage de précision par mesure de distance

Nous comparons ici les performances du L2RPF (Local Rejection Regularized Particle Filter) et de l'EKF sur un problème de pistage par mesure de distance et d'angle. Nous rappelons que le L2RPF développé par Musso [81] est une version de filtre pré-régularisé permettant de contrôler le coût de calcul de l'algorithme initialement prohibitif du fait de l'implémentation d'un algorithme de rejet. Le principe de cet algorithme est basé sur le Kernel Filter développé par Hürzeler et Künsch [56] (voir Remarque 5.1). Nous ne détaillons pas ici l'algorithme du L2RPF, pour plus de détails, on pourra se reporter aux articles déjà cités.

Nous considérons le problème suivant de pistage de précision par mesure de distance et d'angle.

- L'état initial est $X_0 = (5\text{km}, -20\text{m/s}, 5\text{km}, -20\text{m/s})$ avec comme matrice de covariance $P_0 = [\text{diag}(0.5\text{km}, 50\text{m/s}, 0.5\text{km}, 50\text{m/s})]^2$.
- Le temps de poursuite est $T = 200\text{s}$ avec une période de mesures $\Delta = 1\text{s}$.
- L'écart-type des bruits de mesure sur la distance et l'angle sont respectivement de 1m (cas de mesure précise) et 1 degré.

Le nombre de particules utilisées par le L2RPF est $N = 1000$ particules.

Nous soulignons que les conditions de [93] garantissant le bon comportement de l'EKF ne sont pas vérifiées même si les mesures sont très précises puisque la fonction de mesure n'est pas injective. Pour le problème considéré (mesure de distance très précise), nous n'observons pas la divergence de l'EKF, mais nous notons clairement le caractère sous-optimal de l'EKF.





FIG. 6.4: *Biais sur la position et la vitesse estimées selon X.*

On observe sur la Figure 6.4 que le biais des deux filtres atteint rapidement la valeur 0. Cependant, la Figure 6.5 montre que contrairement à l'EKF, le L2RPF atteint très tôt la BCR. Ainsi, pour un coût de calcul environ 30 fois celui de l'EKF, le L2RPF fournit une estimation sensiblement plus précise.

FIG. 6.5: *Ecart-type sur la position et la vitesse estimées selon X.*

6.3.2 Pistage par mesure d'angle seul

Le problème de pistage par mesure d'angle seul est aussi appelé trajectographie passive [83] car dans ce cas, pour des raisons de discrétion, le capteur est passif, dans le sens où il n'envoie pas de signal mais se contente d'écouter les signaux produits par la cible appelée bruiteur. Typiquement, un sonar est utilisé pour écouter les vibrations acoustiques produites par l'hélice d'un sous-marin. Si cette technique de pistage à l'avantage de la discrétion elle ne permet qu'une observation partielle des paramètres cinématiques de la cible. En effet, lorsque le capteur et le bruiteur sont en mouvement rectiligne uniforme, la seule connaissance d'une suite de mesures d'angle (même non bruitées) ne permet pas de retrouver l'état de la cible. Seule une famille de trajectoires du bruiteur engendrant un même défilement d'angles est calculable. On dit que le problème n'est pas observable voir [83]. Cependant on peut le rendre observable si l'observateur effectue une manœuvre, la cible étant toujours supposée animée d'un mouvement rectiligne uniforme. Le plus souvent, la manœuvre choisie consiste en un changement de cap : le porteur est à vitesse constante et change de direction.

Nous considérons le problème de trajectographie passive suivant.

- Le mobile suit une trajectoire rectiligne uniforme initialisée à $X_0 = (10\text{km}, 15\text{m/s}, 10\text{km}, 15\text{m/s})$, avec la matrice de covariance initiale $P_0 = [\text{diag}(10\text{km}, 15\text{m/s}, 10\text{km}, 15\text{m/s})]^2$.
- L'observateur est initialement placé à l'origine en mouvement rectiligne uniforme de vitesse $v_1 = (50\text{m/s}, 0\text{m/s})$, puis opère une manœuvre à l'instant $t = 100\text{s}$ pour suivre un autre mouvement rectiligne uniforme de vitesse $v_2 = (-50\text{m/s}, 50\text{m/s})$ jusqu'à l'instant $T = 200\text{s}$.
- L'observateur mesure tout les $\Delta = 1\text{s}$ l'angle formé par l'axe vertical et la ligne de visée, i.e.,

$$h_n(X) = \arctan(x_3/x_1) ,$$

avec un bruit de mesure d'écart-type 0.5 degrés.

Rappelons que ce problème n'est pas observable tant que l'observateur n'a pas manœuvré (i.e. jusqu'à l'instant $t = 100s$). Cette difficulté provoque la divergence de l'EKF 5 fois sur 50, ce qui explique pourquoi nous ne reportons pas ici les résultats de l'EKF. Précisément, seuls 3 paramètres sur 4 sont observables avant la manœuvre : l'angle, la vitesse angulaire et la vitesse radiale relative. Durant cette phase, aucune information n'est apportée sur la distance. En observant, la BCR sur les Figures 6.9 et 6.10, on voit effectivement qu'elle ne décroît quasiment pas avant la manœuvre.







FIG. 6.6: Densités estimées aux instants $t=99s$ et $t=110s$


Par ailleurs, on observe sur la Figure 6.6 les densités de probabilité du filtre optimal sur le plan (x, y) estimées par le post-RPF aux instants $t = 99s$, juste avant la manœuvre, et $t = 110s$, 10s après la manœuvre. La première observation est qu'aux deux instants considérés la densité se concentre le long de l'axe de visée ce qui résulte naturellement de la prise en compte de la succession des mesures d'angle. Pour ce qui est de la distance, on voit clairement qu'avant la manœuvre, l'information est moindre puisque la densité s'étale sur l'axe de visée sur une distance de plus de $47km$. Puis, en l'espace de 10s après la manœuvre, on observe une nette concentration de la densité en distance, elle ne s'étant plus que sur à peine $7km$.

On devine que d'autres manœuvres de l'observateur permettraient encore d'améliorer la précision du filtre optimal, ce qui conduirait à une meilleure estimation de l'état de la cible. Ce point constitue un sujet de recherche en soit, on peut se reporter à la thèse [79] pour plus de détails sur le choix de la manœuvre optimale.

Les performances du post-RPF sont satisfaisantes, nous n'avons observé aucune divergence. De plus, les courbes d'erreurs en biais des Figures 6.7 et 6.8 montrent que rapidement après la manœuvre l'erreur décroît vers 0. De même, les courbes d'écart-types sur les Figures 6.9 et 6.10 atteignent vite la BCR après la manœuvre. Notons qu'avant la manœuvre, l'existence d'un biais non négligeable rend possible celle d'un écart-type inférieur à la BCR.

On souligne qu'il existe d'autres approches plus performantes que l'EKF au problème de trajectographie passive. Les plus efficaces sont des méthodes globales traitant les mesures par blocs comme le maximum de vraisemblance [57]. Mais ces méthodes sont plus lourdes en temps de calcul et ne vérifient pas la propriété de récursivité.

FIG. 6.7: *Biais de la position et de la vitesse estimées selon X.*FIG. 6.8: *Biais de la position et de la vitesse estimées selon Y.*FIG. 6.9: *Ecart-type de la position et de la vitesse estimées selon X.*

FIG. 6.10: *Ecart-type de la position et de la vitesse estimées selon Y.*

6.4 Comparaison RPF / IMM

6.4.1 Modèle de cible manœuvrante et IMM

Nous avons considéré jusqu'ici des mobiles animés d'un mouvement rectiligne uniforme éventuellement légèrement bruité. Il s'agissait là de cibles non manœuvrantes, dans le sens où l'accélération nulle ou faible n'était pas due à la poussée des moteurs du mobile. Une cible manœuvrante opère une accélération qui lui permet typiquement de passer d'un mouvement rectiligne uniforme à un mouvement de rotation (ou virage). Dans ce cas, le problème de pistage est de dimension plus grande puisqu'il faut estimer en plus la dynamique de la cible (phase de manœuvre ou non) l'intensité de l'accélération. La poursuite d'une cible manœuvrante est en fait un problème difficile qui a fait l'objet de nombreux travaux. Plusieurs algorithmes ont été développés pour résoudre ce problème. On peut par exemple citer l'article de Blair [13] qui propose d'utiliser deux filtres de Kalman en parallèles, l'un utilisant un modèle de dynamique rectiligne uniforme et l'autre un modèle de dynamique accélérée modélisant la phase de manœuvre. L'estimée de l'état de la cible est alors obtenue en combinant linéairement les estimées de chacun des filtres. Bar-Shalom, Chang et Blom [7] proposent l'algorithme à modèles multiples interactifs (Interacting Multiple Model, IMM). Dans cet algorithme, on utilise comme dans celui de Blair [13] plusieurs filtres associés aux modèles de dynamique potentiels de la cible. Mais, ici, les filtres ne sont plus indépendants, ils interagissent à chaque instant de mesure pour corriger leur estimé aux vues de celles des autres filtres. Nous ne décrivons pas ici l'algorithme de l'IMM, pour plus de détails, on peut se reporter à l'article de Bar-Shalom, Chang et Blom [7] ou bien à Blom [14]. Notons seulement que parmi tous les algorithmes récursifs proposés pour la poursuite d'une cible manœuvrante, l'IMM est de loin le plus performant et donc le plus couramment utilisé.

6.4.2 Simulations

Nous reprenons ici le formalisme classique utilisé par Blom [14], pour le traitement de systèmes avec modèles de dynamiques multiples. Le modèle de dynamique du mobile est es-

timé parmi un ensemble fini de modèles donnés (mouvement rectiligne uniforme, mouvement rectiligne accéléré, mouvement de rotation, ...). On suppose que la suite des modèles $(\theta_n)_{n \geq 0}$ constitue une chaîne de Markov à espace d'état fini S de matrice de transition $p = (p(k, \ell))_{k, \ell \in S}$ connue. Typiquement, on suppose connue la probabilité que le mobile passe d'un mouvement rectiligne uniforme à un mouvement de rotation et inversement. Nous pouvons alors directement appliquer les algorithmes de filtrage particulaire en considérant l'état augmenté (X_n, θ_n) . Nous supposons que θ_n est indépendant de X_{n-1} , sachant θ_{n-1} , et nous définissons le noyau de transition

$$\mathbb{P}(X_n \in dx' \mid \theta_n = \ell, X_{n-1} = x) = Q_n(\ell, x, dx') ,$$

l'étape de prédiction est donnée par

$$\mathbb{P}(X_n \in dx', \theta_n = \ell \mid Y_{1:n-1}) = \sum_{k \in S} p(k, \ell) \int Q_n(\ell, X, dx') \mathbb{P}(X_{n-1} \in dx, \theta_{n-1} = k \mid Y_{1:n-1}) . \quad (6.3)$$

Si on connaît un échantillon $(\xi_{n-1}^1, \theta_{n-1}^1, \dots, \xi_{n-1}^N, \theta_{n-1}^N)$, suivant la loi conditionnelle $\mathcal{L}(X_{n-1}, \theta_n \mid Y_{1:n-1})$, la procédure suivante permet de générer un échantillon suivant la prédiction (6.3) : indépendamment pour chaque i

- (i) Générer $\theta_n^i \in S$, avec $\mathbb{P}[\theta_n^i = \ell] = p(\theta_{n-1}^i, \ell)$.
- (ii) Générer $\xi_{n|n-1}^i \sim Q_n(\theta_n^i, \xi_{n-1}^i, \cdot)$.




FIG. 6.11: Trajectoires réelle et estimées. (Les nuages de particules sont dilatés 10 fois)

Dans les simulations effectuées, le mobile peut suivre deux types de modèle de dynamique : un mouvement rectiligne uniforme ou un virage à vitesse angulaire constante $\Omega = 0.0262$ rad/s

(rotation). La Figure 6.11 donne la configuration considérée avec la trajectoire réelle dans le plan ainsi que les trajectoires estimées par l'IMM et le post-RPF.

- L'observateur est placé à l'origine et mesure toutes les secondes l'angle de visée avec un écart-type sur le bruit de mesure de 1 degré et sa distance au mobile avec un écart-type sur le bruit de mesure de 30m.
- Le mobile suit un mouvement rectiligne uniforme pendant 180s, puis un virage à droite à la vitesse constante $\Omega = 0.0262$ rad/s, pendant 180s, et revient finalement en mouvement rectiligne uniforme jusqu'à l'instant final de pistage $T = 540$ s. L'état est initialisé à $X_0 = (20\text{km}, 0\text{m/s}, 20\text{km}, 300\text{m/s})$ avec une matrice de covariance $P_{0|0} = [\text{diag}(1\text{km}, 100\text{m/s}, 1\text{km}, 100\text{m/s})]^2$.
- La probabilité initiale du modèle de dynamique rectiligne uniforme est $\mathbb{P}(\theta_0 = 1) = 0.99$, et la matrice de transition d'un modèle de dynamique à un autre est $\begin{pmatrix} 0.98 & 0.02 \\ 0.02 & 0.98 \end{pmatrix}$.

Nous comparons les performances de l'IMM et du post-RPF. Notons que la version d'IMM que nous utilisons estime difficilement la vitesse de rotation pendant le virage, cette vitesse lui est donc donnée. Par contre, le post-RPF estime la vitesse angulaire de rotation pendant le virage ce qui nous ramène à un problème de dimension 5 pendant la phase de rotation. On initialise cette vitesse angulaire pour le post-RPF, selon une loi normale d'écart-type $\sigma_\Omega = 0.04\text{rad/s}$ et de moyenne, une v.a. générée suivant la loi normale d'écart-type σ_Ω centrée en la vraie valeur $\Omega = 0.0262\text{rad/s}$. Dans ces conditions, l'IMM fournira des estimées de référence a priori de bonne qualité puisque la vitesse du virage lui est connue.






FIG. 6.12: *Biais et écart-type sur la vitesse estimée selon X*

Nous observons que malgré le handicap du post-RPF (ignorance de la vitesse de rotation pendant le virage), les performances des deux filtres sont comparables. La Figure 6.12 montre que la vitesse estimée selon x est de qualité comparable pour le post-RPF et l'IMM. Comme on pouvait s'y attendre on note des pics d'erreurs aux instants 180s et 360s qui correspondent aux instants de manœuvres. La Figure 6.13 montre que les probabilités des différents modèles

FIG. 6.13: *Probabilité estimée que le mobile soit en rotation.*

de dynamique sont bien estimées par le post-RPF. La probabilité que le mobile soit en phase de virage est estimée proche de 1 dans l'intervalle de temps [180s, 360s] qui correspond effectivement à la phase de manœuvre. On note en particulier, que la vitesse de détection des modes de dynamique est relativement rapide. Sur les 50 simulations réalisées, nous observons deux

FIG. 6.14: *Erreur d'estimation en vitesse angulaire*

mauvaises estimations de la vitesse angulaire tandis que le model de dynamique est toujours bien estimé. Pour ne pas fausser les conclusions, nous n'avons pas pris en compte ces deux simulations dans les erreurs (biais et écart-types) reportées sur la Figure 6.14. Ainsi, nous observons hormis deux mauvaises estimations sur 50, que la vitesse angulaire est en général bien estimée pendant le virage, elle est précise et rapide puisque le biais et l'écart-type atteignent zero en à peine 40 secondes.

6.5 Correction progressive

6.5.1 Post-RPF avec ou sans correction progressive

Dans cette section, nous comparons les performances du post-RPF (avec $N = 5000$ particules), avec celles du post-RPF avec correction progressive (PC) (avec $N = 1000$ particules) par rapport à la borne de Cramer Rao, lorsque l'écart-type du bruit sur la mesure de distance varie.

- La durée totale du pistage est $T = 500s$, avec comme intervalle de temps entre deux observations $\Delta = 5s$.
- L'écart-type du bruit sur la mesure d'angles reste constante et vaut un degré.
- Le mobile est initialisé à l'état $X_0 = (50km, 0m/s, 50km, 5m/s)$ avec comme matrice de covariance $P_{0|0} = [\text{diag}(500m, 50m/s, 500m, 50m/s)]^2$.
- Le coefficient coût maximal pour la correction progressive est fixé à la valeur $\gamma_{\max} = 10$, et le nombre maximal de sous-correction par étape est $L_{\max} = 25$.

A chaque écart-type de bruit sur la mesure de distance reporté en abscisse, nous associons les erreurs des estimées de position et de vitesse, moyennées sur la trajectoire entre les instants 20s et 500s.





FIG. 6.15: *Ecart-types sur la position et la vitesse estimées selon Y.*

Sur la Figure 6.15, nous reportons l'écart-type des erreurs des estimées de position et vitesse. Nous observons que la correction progressive améliore considérablement les performances du post-RPF, puisque l'écart-type reste proche de la BCR quelle que soit la valeur du bruit de mesure. Par contre, le post-RPF classique ne fournit des résultats acceptables que pour des puissances de bruit de mesure suffisamment élevées.




Sur le graphe de gauche de la Figure 6.16, nous reportons le coût de calcul du post-RPF avec et sans correction progressive, rapporté au temps de calcul de l'EKF, pour chaque valeur d'écart-type sur le bruit de mesure en distance. Nous remarquons que lorsque la correction

FIG. 6.16: *Evolution du coût de calcul.*

progressive est utilisée, le temps de calcul diminue lorsque le bruit de mesure augmente, passant ainsi d'un temps de calcul 24 fois supérieur à l'EKF à seulement 12. En revanche, le post-RPF sans correction progressive a un coût de calcul constant, en moyenne 28 fois supérieur à l'EKF. De la même façon, nous observons sur le graphe de droite de la Figure 6.16 que le nombre maximal de sous-corrections $L_{\max} = 25$ n'est atteint qu'aux premiers instants d'observation, dans le cas de faible bruit de mesure (écart-type de 0.1m, et 3.3m), pour lesquels il est clair que le coefficient de coût γ est élevé. Ainsi, avec la correction progressive le temps de calcul s'adapte automatiquement à la difficulté du problème.

6.5.2 Post-RPF avec correction progressive / EKF

Nous reprenons ici le problème de pistage de précision par mesure de distance et d'angle déjà introduit dans la Section 6.3. Le post-RPF utilisant la correction progressive avec $N = 1000$ particules est comparé à l'EKF dont on sait qu'il n'est pas optimal dans ce cas (pour avoir été comparé au L2RPF dans la Section 6.3). On observe effectivement sur la Figure 6.18 que le post-RPF atteint la BCR plus tôt que l'EKF. De plus, la Figure 6.19 montre que le nombre de sous-corrections diminue rapidement après quelques instants de mesures pour se contenter finalement d'une simple étape de correction. Comme nous l'avons déjà remarqué, la correction progressive adapte automatiquement le nombre de sous-corrections à la difficulté du problème. Le temps de calcul du post-RPF ainsi utilisé est en moyenne à peine 12 fois celui d'un EKF pour des performances sensiblement meilleurs.

FIG. 6.17: *Biais sur la position et la vitesse estimées selon X.*FIG. 6.18: *Ecart-type sur la position et la vitesse estimées selon X.*FIG. 6.19: *Nombre de sous-corrections par instant.*

Conclusion du chapitre 6

Le but de ce chapitre était d'étudier les performances en simulations des méthodes particulières régularisées, sur des problèmes de pistage en dimensions 4 ou 5 (estimation de la position et de la vitesse d'un mobile dans le plan, avec en plus dans le cas d'une cible manœuvrante, l'estimation du modèle de dynamique pendant toute la poursuite et de la vitesse angulaire pendant le virage). Pour les problèmes considérés le post-RPF utilise 5000 particules (1000 particules avec la correction progressive) et le pré-RPF (sous la forme du L2RPF) utilise en moyenne 1000 particules. Le temps de calcul de ces algorithmes est dans ce cas entre 20 et 30 fois celui d'un Kalman. On a pu observer que le nombre de particules requis par l'algorithme n'augmente que peu avec la dimension de l'espace d'état (voir aussi Musso [81] pour une application du L2RPF au problème en dimension 6 du recalage altimétrique). Ceci vient confirmer l'intuition selon laquelle l'erreur commise par les filtres régularisés sur la simple estimation de quelques moments ne dépend que peu de la dimension contrairement aux estimations d'erreurs obtenues au sens fort (caractérisant l'estimation de toute la densité).

Enfin, nous soulignons que la mise en oeuvre de ces algorithmes est simple et rapide. Cette simplicité algorithmique permet de traiter facilement des problèmes complexes tels que la trajectographie passive ou la poursuite de cibles manœuvrantes. Nous avons vu que dans ces cas, les méthodes particulières régularisées constituent en effet une alternative efficace aux méthodes classiquement utilisées en pistage.

Conclusion

La recherche en filtrage non linéaire est fortement motivée par ses nombreuses applications. Cependant, il s'agit d'un problème difficile qui n'admet pas en général de solution de dimension finie. Entre le filtre de Kalman étendu sensible aux non linéarités du système et les méthodes numériques de maillage fortement dépendantes de la dimension de l'espace, les méthodes particulières semblent a priori une approche spécialement adaptée à ce problème. Néanmoins, on observe que les méthodes particulières classiques présentent elles aussi des faiblesses qui les rendent parfois inefficaces. L'objectif de cette thèse était précisément de parer à ces faiblesses en développant de nouveaux algorithmes particuliers plus performants.

Dans cette optique, nous nous sommes, dans un premier temps, intéressés au comportement du filtre optimal face à la présence de perturbations locales dans son évolution. Notre but était de trouver un type de perturbations locales permettant un calcul rapide du filtre sans trop bouleverser son évolution. L'étude de stabilité que nous avons menée nous a permis de distinguer différentes classes de perturbations locales selon la métrique permettant de les contrôler (distance faible, variation totale, entropie de Kullback et métrique de Hilbert). En particulier nous avons pu constater que les perturbations locales contrôlables sous la métrique de Hilbert ne bouleversent pas trop l'évolution du filtre optimal dans le sens où l'erreur induite croît au pire linéairement dans le temps. De même, nous avons observé que les perturbations locales contrôlables sous la variation totale respectent plus l'évolution du filtre optimal que celles contrôlables sous la distance faible. Symétriquement, on a vu que les "propriétés de régularité" des opérateurs d'évolution du filtre influent aussi sur la qualité de la propagation d'erreur. Typiquement, la propriété de noyau dominé permet de passer d'une étude sous la topologie faible à une étude sous la variation totale et ainsi d'obtenir un meilleur contrôle de la propagation d'erreur. De même, la propriété de noyau mélangeant permet le passage d'une étude au sens faible ou au sens de la variation totale à une étude au sens de la métrique de Hilbert. Ainsi, les propriétés de régularité du noyau permettent de se placer sous une topologie mieux adaptée au problème de filtrage. De cette façon, nous avons pu montrer que sous la condition de mélange le filtre reste uniformément stable dans le temps par rapport à toutes les classes de perturbations considérées. Dans le cas général, ce type de résultats n'est plus valable. La sensibilité du filtre aux perturbations locales est d'autant plus grande que les observations accumulées sont nombreuses et précises. Cette remarque justifie les techniques d'oubli communément utilisées en filtrage pour stabiliser le filtre.

A la lumière de cette étude nous avons pu aborder plus clairement l'analyse des filtres de Monte Carlo pondérés et des filtres particuliers avec interaction. Nous nous sommes d'abord intéressés au filtre de Monte Carlo pondéré dont on a rappelé le caractère instable se traduisant par la dégénérescence des pondérations. Pour parer à cette difficulté, l'idée classique

est d'introduire de l'oubli au travers des observations. Del Moral [31] a montré qu'un oubli brutal des observations les plus anciennes permet effectivement d'obtenir une approximation du filtre optimal uniforme en temps pourvu que le signal soit suffisamment ergodique. Nous avons montré à sa suite, par des méthodes hilbertiennes que l'oubli progressif (exponentiel) des observations passées conduit aussi à une approximation uniforme lorsque les transitions du signal sont mélangeantes. Malheureusement, hors de ces hypothèses contraignantes, ces méthodes d'oubli ne sont pas suffisantes pour compenser la faible capacité exploratoire du système de particules.

Pour mieux exploiter les observations et guider l'évolution des particules dans les zones intéressantes de l'espace, l'idée d'introduire des étapes de rééchantillonnage du système de particules a été proposée indépendamment dans [49, 39, 62]. Avec le filtre particulaire avec interaction, les particules les plus vraisemblables sont régulièrement sélectionnées alors que les autres sont éliminées. Par des méthodes hilbertiennes, nous avons montré la convergence uniforme de ce filtre approché vers le filtre optimal lorsque la dynamique du signal est mélangeante, obtenant ainsi par d'autres méthodes, un résultat moins général mais plus précis que Del Moral et Guionnet [33]. En dehors de cette hypothèse, les majorations d'erreur sont décevantes puisqu'elles croissent exponentiellement avec le temps. Nous avons néanmoins proposé une version de cet algorithme utilisant un nombre aléatoire de particules dont nous montrons qu'elle permet un meilleur contrôle de l'erreur locale induite. Grâce à cet algorithme, nous avons pu construire dans un cas particulier de dynamique pseudo-mélangeante (mais non ergodique) une approximation particulaire uniforme en temps du filtre optimal. Mais dans le cas général, la nature discrète de l'approximation limite fatalement la capacité exploratoire du système de particules.

Pour maintenir la diversité du système de particules et améliorer l'exploitation des observations, nous avons proposé d'ajouter une étape de régularisation dans l'algorithme du filtre particulaire avec interaction. Deux types de filtres particuliers régularisés ont été développés, les filtres pré-régularisés où la régularisation est introduite avant la correction et les filtres post-régularisés où la régularisation intervient après la correction. L'étape de régularisation est basée sur la théorie de l'estimation de densité par noyaux qui fournit une estimation absolument continue d'une mesure à densité dont on connaît un échantillon. Pour construire les outils nécessaires au développement des filtres particuliers régularisés, nous avons dû étendre le cadre classique de l'estimation de densité par noyaux au problème rencontré en filtrage de l'estimation d'une densité corrigée. En outre, il nous a fallu développer de nouvelles estimations d'erreur notamment au sens L^p (pour $p > 2$), dans le but d'obtenir par la suite des vitesses de convergence presque sûre pour les filtres régularisés. Dans le cadre stricte de l'estimation de densité, nous avons ainsi apporté un résultat de convergence presque sûre de la densité estimée plus général mais moins précis que celui obtenu par Devroye (énoncé au Corollaire 4.10). Dans le cadre du filtrage, nous avons ainsi construit une perturbation locale plus fine que celles utilisées par les filtres particuliers classiques puisque contrôlable au sens de la variation totale.

Les majorations d'erreurs obtenues au sens faible pour les filtres particuliers régularisés sont du même ordre que pour l'IPF. Les majorations obtenues au sens fort améliorent les termes de propagation d'erreur tandis que l'erreur locale est dégradée dans la mesure où elle croît avec la dimension. Ce dernier résultat n'est pas surprenant, le problème consistant à approcher une densité dans un espace de grande dimension étant nécessairement difficile.

Cependant, nous soulignons que l'intérêt pratique du filtrage réside seulement dans l'approximation de quelques moments de la densité et non dans l'approximation de la densité dans son ensemble. Les méthodes particulières que nous avons développées ne prétendent pas concurrencer sur ce dernier point, les méthodes de maillage. On observe néanmoins dans les simulations que pour l'estimation de simples moments, l'étape de régularisation permet effectivement de bien stabiliser l'algorithme sans que ses performances ne dépendent fortement de la dimension. Nous proposons deux interprétations duales à ce fait (comme conséquences directes de notre étude de stabilité réalisée au Chapitre 2) :

- La régularisation permet un contrôle fort de l'erreur locale ce qui permet une meilleure propagation d'erreur.
- La régularisation robustifie (ou régularise) les opérateurs d'évolution du filtre améliorant ainsi le transport de l'erreur.

Ce travail de recherche s'est donc articulé autour de trois points principaux :

Stabilité du filtre optimal avec quelques nouveaux résultats de stabilité (notamment par rapport aux perturbations locales) et la mise en évidence de l'importance de la métrique utilisée dans l'étude de stabilité et dans la recherche d'un filtre approché.

Estimation de densité par noyaux avec le développement de quelques nouvelles majorations d'erreur dans un contexte un peu plus général que celui rencontré classiquement en estimation de densité.

Développement de nouveaux algorithmes de filtrage avec une analyse théorique des erreurs commises et la comparaison en simulation à d'autres algorithmes sur des problèmes réalistes de pistage.

Ces trois points ont permis de souligner l'intérêt des nouveaux algorithmes développés mais le travail réalisé reste bien évidemment à approfondir du point de vue théorique comme du point de vue pratique. En ce qui concerne l'étude de stabilité, on devine intuitivement (par analogie au cas linéaire) et on observe en simulation que les résultats de stabilité exponentielle peuvent s'étendre à des cas beaucoup plus généraux que ceux que nous avons considérés. Par ailleurs, dans l'optique de proposer des approximations du filtre optimal stables dans le temps, il serait intéressant d'exploiter plus en détails l'idée consistant à rechercher des processus exponentiellement stables approchant le filtre optimal de façon uniforme en temps. D'autre part, dans l'étude de convergence des méthodes particulières régularisées que nous avons menée, nous nous sommes limités au cas de facteurs de dilatation déterministes. Or les algorithmes implémentés utilisent des facteurs de dilatation dépendant du système de particules courant. Il reste donc à étendre notre étude au cas où les facteurs de dilatation sont aléatoires. Une telle analyse permettrait en outre de mieux mesurer l'influence de ce paramètre et ainsi d'améliorer encore son choix. Il reste aussi à développer une analyse plus précise du comportement asymptotique des méthodes particulières régularisées en étudiant notamment les grandes déviations ou en recherchant des théorèmes central limite. Du point de vue pratique, certains algorithmes proposés n'ont pas été testés en simulations, comme les filtres particuliers utilisant des nombres aléatoires de particules. Il serait en particulier intéressant de comparer les performances de ces algorithmes avec le filtre particulière pré-régularisé dont le temps de calcul est lui aussi aléatoire. Par ailleurs, en pistage, on pourrait envisager des applications plus complexes, comme le pistage dans un environnement multicible, en présence de fausses alarmes, ou encore le pistage de cibles étendues. Il faut enfin rappeler que le champs d'application des méthodes particulières régularisées s'étend bien au delà du pistage et que d'autres domaines d'application sont bien entendu envisageables.

Annexe A

Notations

A.1 Filtres et Filtres approchés

- $(\pi_n)_{n \geq 0}$: filtre optimal $\pi_n(dx) = \mathbb{P}[X_n \in dx \mid Y_{1:n}]$.
- $(\pi_{n|n-1})_{n \geq 0}$: filtre de prédiction, $\pi_{n|n-1}(dx) = \mathbb{P}[X_n \in dx \mid Y_{1:n-1}]$.
- $(\pi_n^N)_{n \geq 0}$: Filtre de Monte Carlo pondéré (Annexe C.1).
- $(\pi_{n,p}^N)_{n \geq 0}$: Filtre de Monte Carlo pondéré à mémoire limitée de taille p (Annexe C.2).
- $(\pi_n^{(\alpha),N})_{n \geq 0}$: Filtre de Monte Carlo pondéré à oubli exponentiel (Annexe C.3).
- $(\pi_n^N)_{n \geq 0}$: Filtre particulière avec interaction ou IPF (Annexe C.4).
- $(\pi_n^{N,h})_{n \geq 0}$: Filtre particulière pré-régularisé ou pré-RPF (Annexe C.5).
- $(\tilde{\pi}_n^{N,h})_{n \geq 0}$: Filtre particulière post-régularisé ou post-RPF (Annexe C.6).

A.2 Fonctions de vraisemblances et constantes associées

- Ψ_n : fonction de vraisemblance, $\Psi_n(x) = g_n(x, Y_n)$.
- $\Psi_{1:n}$: fonction de vraisemblance conjointe, $\Psi_{1:n}(x_{1:n}) = g_{1:n}(x_{1:n}, Y_{1:n}) = \Psi_1(x_1) \cdots \Psi_n(x_n)$.
- M_n : borne supérieure de la fonction de vraisemblance, $M_n = \sup_{x \in E} \Psi_n(x)$
- M'_n : borne supérieure de la fonction de vraisemblance et de ses dérivées,

$$M'_n = \max\{\|\Psi_k\|, 2 \sum_{i=1}^d \|D_i \Psi_n\|, \sum_{i,j=1}^d \|D_i D_j \Psi_n\|\} < \infty.$$

- $\tilde{m}_n$: borne inférieure de la fonction de vraisemblance, $\tilde{m}_n = \inf_{x \in E} \Psi_n(x)$.
- m_n : borne inférieure de la vraisemblance moyennée contre $Q_n(x, \cdot)$, $m_n = \inf_x \langle Q_n(x, \cdot), \Psi_n \rangle$.
- $\bar{m}_n$: vraisemblance moyennée contre $\pi_{n|n-1}$, $\bar{m}_n = \langle \pi_{n|n-1}, \Psi_n \rangle$.
- $\bar{\gamma}_n$: coefficient de transport de la correction, $M_n/\bar{m}_n$.
- $\bar{\gamma}'_n$: $M'_n/\bar{m}_n$.
- γ_n : M_n/m_n .
- γ'_n : M'_n/m_n .

A.3 Opérateurs, opérations et taux de contraction

$\Psi \cdot \mu = \frac{\Psi \cdot \mu}{\langle \mu, \Psi \rangle}$: produit projectif entre une fonction et une mesure,

$(\mathbf{K} * \mathbf{f})(\mathbf{x}) = \int_E K(x - u) f(u) du = \int_E f(x - u) K(u) du$: produit de convolution entre deux fonctions.

$(\mathbf{K} * \mu)(d\mathbf{x}) = \left\{ \int_E K(x - u) \mu(du) \right\} dx$: produit de convolution entre une mesure et une fonction.

$\mathbf{R}_n$: opérateur d'évolution dénormalisé du filtre optimal, $R_n(x, dx') = \Psi_n(x') Q_n(x, dx')$.

$\bar{\mu}$: mesure normalisée (probabilité) associée à la mesure positive μ , $\bar{\mu} = \mu / \mu(E) \in \mathcal{P}(E)$.

$\mathbf{S}^N(\mu)$: mesure empirique chargeant un N -échantillon issu de la mesure de probabilité μ ,

$$S^N(\mu) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi^i} \quad \text{où} \quad (\xi^1, \dots, \xi^N) \text{ i.i.d. } \sim \mu.$$

$\tau(\mathbf{R})$: taux de contraction sous la métrique de Hilbert de l'opérateur intégrale R .

$\beta(\mathbf{Q})$: taux de contraction sous la variation totale du noyau markovien Q .

A.4 Normes ou pseudo-normes

$\|\cdot\|$: norme en variation totale sur l'espace des mesures signées, ou bien norme sup sur l'espace des fonctions mesurables et bornées sur E , selon les cas.

$\mathbf{h}(\cdot, \cdot)$: métrique projective de Hilbert sur l'espace des mesures.

$\mathbf{k}(\cdot, \cdot)$: distance de Kullback sur l'espace des mesures.

$|\cdot|$: norme usuelle sur $\mathbb{R}^d$.

$\mathbf{W}^{r,p}$: espace de Sobolev des fonctions mesurables définies sur $E = \mathbb{R}^d$ dont les dérivées jusqu'à l'ordre r (au sens des distributions) sont dans L^p .

$\|\cdot\|_{r,p}$: norme usuelle sur $W^{r,p}$, $\|f\|_{r,p} = \left\{ \sum_{|\alpha| \leq r} \int_{\mathbb{R}^d} |D^\alpha f(x)|^p dx \right\}^{\frac{1}{p}}$.

$|\cdot|_{r,p}$: semi-norme usuelle sur $W^{r,p}$, $|f|_{r,p} = \left\{ \sum_{|\alpha|=r} \int_{\mathbb{R}^d} |D^\alpha f(x)|^p dx \right\}^{\frac{1}{p}}$.

A.5 Autres notations

Soit μ est une mesure signée finie sur E de densité f par rapport à la mesure de Lebesgue.

$\|\mu\|_p = \|\mathbf{f}\|_p = \left[\int_E |f(x)|^p dx \right]^{\frac{1}{p}}$.

$\mathbf{b}(\mathbf{f}) = \|f\|_2$.

$\mathbf{I}(\mu) = \mathbf{I}(\mathbf{f}) = \int_E |x|^{d+1} |f(x)| dx$.

$\mathbf{J}(\mu) = \mathbf{J}(\mathbf{f}) = \int_E \sqrt{|f(x)|} dx$.

$\mathbf{a}(\mu) = \mathbf{a}(\mathbf{f}) = \int_E |x|^2 |f(x)| dx$.

$\mathbf{a}_s(\mu) = \mathbf{a}_s(\mathbf{f}) = s! \max_{|\alpha|=s} \int_E |x^\alpha| |f(x)| dx$.

Annexe B

Hypothèses

B.1 Sur la vraisemblance

Hypothèse $[\Psi]$ (vraisemblance bornée) :

$$0 < \bar{m}_k = \langle \pi_{k|k-1}, \Psi_k \rangle, \quad \text{et} \quad M_k = \sup_{x \in E} \Psi_k(x) < \infty .$$

Nous avons alors $\bar{\gamma}_k = \frac{M_k}{\bar{m}_k} < \infty$. $[\Psi]$ est toujours supposée vérifiée.

Hypothèse $[\tilde{\Psi}]$ (vraisemblance bornée inférieurement et supérieurement) : Il existe des constantes $0 < \tilde{m}_k \leq M_k$, éventuellement fonctions de Y_k , telles que

$$\tilde{m}_k \leq \Psi_k(x) \leq M_k ,$$

pour tout $x \in E$. Nous notons alors $\tilde{\gamma}_k = \frac{M_k}{\tilde{m}_k}$.

Hypothèse $[\Psi']$ (vraisemblance à dérivées bornées) :

$$M'_k = \max\{\|\Psi_k\|, 2 \sum_{i=1}^d \|D_i \Psi_k\|, \|D_i D_j \Psi_k\|\} < \infty .$$

B.2 Sur le noyau de transition

Hypothèse $[\mathbf{Q}_d]$ (noyau dominé) : Il existe une constante $c_k > 0$, et une mesure de probabilité $\nu_k \in \mathcal{P}(E)$, telles que

$$Q_k(x, \cdot) \leq c_k \nu_k ,$$

Hypothèse $[\mathbf{Q}_I]$ (moments d'ordre $d+1$ uniformément bornés) :

$$I_k = \sup_{x \in E} I(Q_k(x, \cdot)) < \infty .$$

Hypothèse [Q'] : Pour tout $x \in E$, $Q_k(x, \cdot)$ est a.c. par rapport à la mesure de Lebesgue avec la densité $q_k(x, \cdot) \in W^{2,p}$ telle qu'il existe une constante $D_k > 0$ vérifiant

$$|q_k(x, \cdot)|_{2,p} \leq D_k ,$$

pour tout $x \in E$.

Hypothèse [Q''] : Pour tout $x \in E$, $Q_k(x, \cdot)$ est a.c. par rapport à la mesure de Lebesgue avec la densité $q_k(x, \cdot) \in W^{2,p}$ telle qu'il existe une constante $D_k > 0$ vérifiant

$$\|q_k(x, \cdot)\|_{2,p} \leq D_k ,$$

pour tout $x \in E$.

Hypothèse [Q_d^h] : Il existe une constante $c_k > 0$, et une mesure de probabilité $\nu_k \in \mathcal{P}(E)$, telles que

$$Q_k^h(x, \cdot) \leq c_k \nu_k .$$

Hypothèse [$\tilde{Q}_d^h$] : Il existe une constante $c_k > 0$, et une mesure de probabilité $\nu_k \in \mathcal{P}(E)$, telles que

$$\tilde{Q}_k^h(x, \cdot) \leq c_k \nu_k .$$

B.3 Sur la vraisemblance et le noyau de transition

Hypothèse [QΨ] (vraisemblance moyenne bornée inférieurement) :

$$0 < m_k = \inf_{x \in E} \langle Q_k(x, \cdot), \Psi_k \rangle .$$

Nous notons alors $\gamma_k = \frac{M_k}{m_k}$, et si $n \geq m \geq 1$ nous notons le produit $\gamma_n \cdots \gamma_m = \gamma_{n:m}$.

Hypothèse [R] (opérateur d'évolution mélangeant) : L'opérateur intégral R_k est mélangeant, i.e. il existe une constante positive ε_k et une mesure positive λ_k telles que

$$\varepsilon_k \lambda_k \leq R(x, \cdot) \leq \frac{1}{\varepsilon_k} \lambda_k ,$$

pour tout $x \in E$.

B.4 Sur le filtre optimal

Hypothèse [Π'] : $\pi_{k|k-1}$ est a. c. par rapport à la mesure de Lebesgue avec la densité $f_{k|k-1} = \frac{d\pi_{k|k-1}}{dx} \in W^{2,p}$ telle qu'il existe une v.a. $D_k > 0$ mesurable par rapport aux observation $Y_{1:k-1}$ et vérifiant

$$|f_{k|k-1}|_{2,p} \leq D_k .$$

Hypothèse [Π''] : π_k est a. c. par rapport à la mesure de Lebesgue avec la densité $f_k = \frac{d\pi_k}{dx} \in W^{2,p}$ telle qu'il existe une v.a. $D_k > 0$ mesurable par rapport aux observation $Y_{1:k-1}$ et vérifiant

$$\|f_k\|_{2,p} \leq D_k .$$

B.5 Sur les filtres régularisés

Hypothèse $[\bar{\mathbf{I}}]$:

$$\bar{I}_k = \mathbb{E}[I(Q_k \pi_{k-1}^{N,h}) \mid Y_{1:k-1}] < \infty .$$

Hypothèse $[\tilde{\mathbf{I}}]$:

$$\tilde{I}_k = \mathbb{E}[I(Q_k \tilde{\pi}_{k-1}^{N,h}) \mid Y_{1:k-1}] < \infty .$$

Annexe C

Principaux algorithmes particuliers

C.1 Filtre de Monte Carlo pondéré $(\pi_n^N)_{n \geq 0}$

Le filtre de Monte Carlo pondéré est initialisé à la valeur

$$\pi_0^N = S^N(p_0) = \sum_{i=1}^N \omega_0^i \xi_0^i \quad \text{avec} \quad (\xi_0^1, \dots, \xi_0^N) \text{ i.i.d. } \sim p_0 \quad \text{et} \quad \omega_0^i = \frac{1}{N} \quad 1 \leq i \leq N.$$

Puis $\pi_{0:n}^N$ et sa marginale notée π_n^N s'obtiennent récursivement par l'algorithme suivant.

- (i) Evolution : indépendamment pour chaque i , générer $\xi_n^i \sim Q_n(\xi_{n-1}^i, \cdot)$. Poser $\xi_{0:n}^i = (\xi_{0:n-1}^i, \xi_n^i)$.
- (ii) Correction : pour tout i , calculer les poids

$$\omega_{0:n}^i = \frac{\Psi_n(\xi_n^i) \omega_{0:n-1}^i}{\sum_{j=1}^N \Psi_n(\xi_n^j) \omega_{0:n-1}^j}, \quad \text{et} \quad \omega_n^i = \frac{\Psi_n(\xi_n^i) \omega_{n-1}^i}{\sum_{j=1}^N \Psi_n(\xi_n^j) \omega_{n-1}^j}.$$

Puis poser

$$\pi_{0:n}^N = \sum_{i=1}^N \omega_{0:n}^i \delta_{\xi_{0:n}^i}, \quad \text{et} \quad \pi_n^N = \sum_{i=1}^N \omega_n^i \delta_{\xi_n^i}$$

C.2 Filtre de Monte Carlo pondéré à mémoire limitée $(\pi_{n,p}^N)_{n \geq 0}$

Le filtre de Monte Carlo pondéré à mémoire limitée aux p dernières observations est noté $(\pi_{n,p}^N)_{n \geq 0}$. Il est initialisé à la valeur $\pi_{0,p}^N = S^N(p_0)$ avec les poids $\omega_0^i = \frac{1}{N}$ pour $1 \leq i \leq N$. Puis le passage de $\pi_{n-1,p}^N$ à $\pi_{n,p}^N$ est décrit par l'algorithme,

- (i) Evolution : indépendamment pour chaque i , générer $\xi_n^i \sim Q_n(\xi_{n-1}^i, \cdot)$.

(ii) Correction : pour tout i , calculer les poids

$$\omega_n^i = \frac{\Psi_n(\xi_n^i) \omega_{n-1}^i}{\sum_{j=1}^N \Psi_n(\xi_n^j) \omega_{n-1}^j} \quad \text{si } n \leq p, \quad \omega_n^i = \frac{\frac{\Psi_n(\xi_n^i)}{\Psi_{n-p}(\xi_{n-p}^i)} \omega_{n-1}^i}{\sum_{j=1}^N \frac{\Psi_n(\xi_n^j)}{\Psi_{n-p}(\xi_{n-p}^j)} \omega_{n-1}^j} \quad \text{si } n \geq p+1.$$

Puis poser

$$\pi_{n,p}^N = \sum_{i=1}^N \omega_n^i \delta_{\xi_n^i}$$

C.3 Filtre de Monte Carlo pondéré à oubli exponentiel $(\pi_n^{(\alpha),N})_{n \geq 0}$

Le filtre de Monte Carlo à oubli exponentiel est initialisé à la valeur $\pi_0^{(\alpha),N} = S^N(p_0)$ et les poids $\omega_0^i = \frac{1}{N}$ pour $1 \leq i \leq N$. Puis le passage de $\pi_{n-1}^{(\alpha),N}$ à $\pi_n^{(\alpha),N}$ est décrit par l'algorithme suivant.

- (i) Evolution : indépendamment pour chaque i , générer $\xi_n^i \sim Q_n(\xi_{n-1}^i, \cdot)$.
- (ii) Correction : pour chaque i , calculer les poids

$$\omega_n^i = \frac{\Psi_n(\xi_n^i) (\omega_{n-1}^i)^\alpha}{\sum_{j=1}^N \Psi_n(\xi_n^j) (\omega_{n-1}^j)^\alpha}.$$

Puis poser

$$\pi_n^N = \sum_{i=1}^N \omega_n^i \delta_{\xi_n^i}$$

C.4 Filtre particulaire avec interaction $(\pi_n^N)_{n \geq 0}$

Le filtre particulaire avec interaction est noté π_n^N . Il est initialisé à la valeur $\pi_0^N = \pi_0$, puis la transition de π_{n-1}^N à π_n^N s'effectue en deux étapes,

$$\pi_{n-1}^N \xrightarrow[\substack{\text{Prédiction} \\ \text{échantillonnée}}]{(1)} \pi_{n|n-1}^N = S^N(Q_n \pi_{n-1}^N) \xrightarrow[\text{Correction}]{(2)} \pi_n^N = \Psi_n \cdot \pi_{n|n-1}^N.$$

Dans la pratique ces deux étapes s'implémentent de la manière suivante

- (i) Prédiction échantillonnée

Echantillonnage : générer $(\xi_{n-1}^1, \dots, \xi_{n-1}^N)$ i.i.d. $\sim \pi_{n-1}^N$.

Indépendamment pour chaque i ,

- Générer $I \in \{1, \dots, N\}$, avec $\mathbb{P}(I = j) = \omega_{n-1}^j$.

– Poser $\xi_{n-1}^i = \xi_{n-1|n-2}^I$.

Evolution : indépendamment pour chaque i , générer $\xi_{n|n-1}^i \sim Q_n(\xi_{n-1}^i, \cdot)$. Puis poser

$$\pi_{n|n-1}^N = S^N(Q_n \pi_{n-1}^N) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_{n|n-1}^i} \quad \text{i.e.} \quad \langle \pi_{n|n-1}^N, \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(\xi_{n|n-1}^i) ,$$

Pour toute fonction ϕ mesurable bornée définie sur E .

(ii) Correction : pour tout i , calculer le poids

$$\omega_n^i = \frac{\Psi_n(\xi_{n|n-1}^i)}{\sum_{j=1}^N \Psi_n(\xi_{n|n-1}^j)} .$$

Puis poser

$$\pi_n^N = \sum_{i=1}^N \omega_n^i \delta_{\xi_{n|n-1}^i} \quad \text{i.e.} \quad \langle \pi_n^N, \phi \rangle = \sum_{i=1}^N \omega_n^i \phi(\xi_{n|n-1}^i) ,$$

pour toute fonctions ϕ mesurable bornée définie sur E .

C.5 Filtre particulaire pré-régularisé $(\pi_n^{N,h})_{n \geq 0}$

Le filtre particulaire pré-régularisé est initialisé à la valeur $\pi_0^{N,h} = \pi_0$, puis le passage de $\pi_{n-1}^{N,h}$ à $\pi_n^{N,h}$ se déroule en trois étapes

$$\pi_{n-1}^{N,h} \xrightarrow[\substack{\text{Prédiction} \\ \text{échantillonnée}}]{(1)} \pi_{n|n-1}^{N,h} = S^N(Q_n \pi_{n-1}^{N,h}) \xrightarrow[\text{Régularisation}]{(2)} \nu_{n|n-1}^{N,h} = K_h * \pi_{n|n-1}^{N,h}$$

$$\xrightarrow[\text{Correction}]{(3)} \pi_n^{N,h} = \Psi_n \cdot \nu_{n|n-1}^{N,h} .$$

Pour la clarté de la présentation, nous décrivons l'algorithme permettant la transition de $\pi_{n-1|n-2}$ à $\pi_{n|n-1}$. L'algorithme reprend l'étape d'échantillonnage de l'IPF, sauf qu'ici la phase d'échantillonnage demande l'exécution d'un algorithme d'acceptation / rejet.

(i) Echantillonnage (avec régularisation et correction)

indépendamment pour chaque i

- Générer I uniformément dans $\{1, \dots, N\}$.
- Générer $\varepsilon \sim K$, noyau d'Epanechnikov (4.51) ou gaussien, et U uniformément dans $[0, 1]$.
- Poser $X = \xi_{n-1|n-2}^I + h \Gamma_{n-1} \varepsilon$, avec $h = h_{\text{opt}}$ donné par (4.52) ou (4.53). Si la technique de blanchiment est utilisée, $\Gamma_{n-1} = A_{n-1}$ la racine carrée de la matrice de covariance empirique, voir (4.55), sinon $\Gamma_{n-1} = I$.

- Si $\Psi_{n-1}(X) > U \|\Psi_{n-1}\|$, poser $\xi_{n-1}^i = X$, sinon retourner à l'étape (i).
- (ii) Evolution : indépendamment pour chaque i , générer $\xi_{n|n-1}^i \sim Q_n(\xi_{n-1}^i, \cdot)$. Puis poser

$$\pi_{n|n-1}^{N,h} = S^N(Q_n \pi_{n-1}^{N,h}) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_{n|n-1}^i} \quad \text{i.e.} \quad \langle \pi_{n|n-1}^{N,h}, \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(\xi_{n|n-1}^i),$$

Pour toute fonction ϕ mesurable bornée définie sur E .

C.6 Filtre particulaire post-régularisé $(\tilde{\pi}_n^{N,h})_{n \geq 0}$

Le filtre particulaire post-régularisé est initialisé à la valeurs $\tilde{\pi}_0^{N,h} = \pi_0$, puis le passage de $\tilde{\pi}_{n-1}^{N,h}$ à $\tilde{\pi}_n^{N,h}$ se déroule en trois étapes,

$$\begin{aligned} \tilde{\pi}_{n-1}^{N,h} &\xrightarrow[\substack{\text{Prédiction} \\ \text{échantillonnée}}]{(1)} \tilde{\pi}_{n|n-1}^{N,h} = S^N(Q_n \tilde{\pi}_{n-1}^{N,h}) \xrightarrow[\text{Correction}]{(2)} \tilde{\nu}_n^{N,h} = \Psi_n \cdot \tilde{\pi}_{n|n-1}^{N,h} \\ &\xrightarrow[\text{Régularisation}]{(3)} \tilde{\pi}_n^{N,h} = K_h * \tilde{\nu}_n^{N,h}. \end{aligned}$$

Pour simplifier la description, nous présentons l'algorithme de transition de $\tilde{\nu}_{n-1}^{N,h}$ à $\tilde{\nu}_n^{N,h}$. L'algorithme reprend les deux étapes de prédiction échantillonnée et de correction de l'IPF, sauf qu'ici la phase d'échantillonnage dans l'étape de la prédiction échantillonnée est effectuée suivant la procédure :

- (i) Prédiction échantillonnée (avec post-régularisation)

Echantillonnage (avec régularisation) : indépendamment pour chaque i ,

- Générer $I \in \{1, \dots, N\}$, avec $\mathbb{P}(I = j) = \omega_{n-1}^j$.
- Générer $\varepsilon \sim K$, noyau d'Epanechnikov (4.51) ou gaussien.
- Calculer $\xi_{n-1}^i = \xi_{n-1|n-2}^I + h \Gamma_n \varepsilon$, avec $h = h_{\text{opt}}$ donné par (4.52) ou (4.53).
Si la technique de blanchiment est utilisée, $\Gamma_n = A_n$, la racine carrée de la matrice de covariance empirique, voir (4.55), sinon $\Gamma_n = I$.

Evolution : indépendamment pour chaque i , générer $\xi_{n|n-1}^i \sim Q_n(\xi_{n-1}^i, \cdot)$. Puis poser

$$\tilde{\pi}_{n|n-1}^{N,h} = S^N(Q_n \tilde{\pi}_{n-1}^{N,h}) = \frac{1}{N} \sum_{i=1}^N \delta_{\xi_{n|n-1}^i} \quad \text{i.e.} \quad \langle \tilde{\pi}_{n|n-1}^{N,h}, \phi \rangle = \frac{1}{N} \sum_{i=1}^N \phi(\xi_{n|n-1}^i),$$

Pour toute fonction ϕ mesurable bornée définie sur E .

- (ii) Correction : pour tout i , calculer le poids

$$\omega_n^i = \frac{\Psi_n(\xi_{n|n-1}^i)}{\sum_{j=1}^N \Psi_n(\xi_{n|n-1}^j)}.$$

Puis poser

$$\tilde{\nu}_n^{N,h} = \sum_{i=1}^N \omega_n^i \delta_{\xi_{n|n-1}^i} \quad \text{i.e.} \quad \langle \tilde{\nu}_n^{N,h}, \phi \rangle = \sum_{i=1}^N \omega_n^i \phi(\xi_{n|n-1}^i) ,$$

pour toute fonctions ϕ mesurable bornée définie sur E .

Annexe D

Coût de calcul de l'algorithme de rejet

D.1 Algorithme de rejet simple

Soient $\Psi_1, \dots, \Psi_n$ n fonctions positives bornées sur $E = \mathbb{R}^d$, on définit $\Psi = \Psi_1 \Psi_2 \dots \Psi_n$, et $\nu_0, \nu_1, \dots, \nu_n$ des mesures de probabilité sur $E = \mathbb{R}^d$ telles que pour tout $k \geq 1$,

$$\nu_k = \Psi_k \cdot \nu_{k-1} = \frac{\Psi_k \nu_{k-1}}{\langle \Psi_k, \nu_{k-1} \rangle}.$$

Nous voulons générer une variable aléatoire suivant la loi a posteriori $\nu_n = \Psi \cdot \nu_0 = \Psi_n \cdot \nu_{n-1}$ sachant que nous pouvons simuler ν_0 . Supposons, dans un premier temps, que nous sachions simuler ν_k , nous pouvons utiliser l'algorithme de rejet suivant pour générer la variable aléatoire ξ_{k+1} suivant la loi a posteriori $\nu_{k+1} = \Psi_{k+1} \cdot \nu_k$.

- (i) Générer X suivant ν_k
- (ii) Générer U uniformément dans $[0, 1]$.
- (iii) Si $\Psi_{k+1}(X) > U \|\Psi_{k+1}\|$, poser $\xi_{k+1} = X$, sinon retourner à l'étape (i).

Le coût de calcul de cet algorithme est aléatoire. En effet si nous notons a_k le nombre de générations de variables aléatoires suivant ν_k requises pour la génération d'une variable aléatoire suivant ν_{k+1} par l'algorithme de rejet, alors on a le résultat bien connu, (voir Devroye [42]) :

Proposition 6.2. *Pour tout entier $k \geq 0$, a_k suit une loi géométrique de paramètre $1/\gamma_{k+1}$, avec $\gamma_{k+1} = \|\Psi_{k+1}\|/\langle \nu_k, \Psi_{k+1} \rangle$, notée $G(\gamma_{k+1}^{-1})$, i.e. pour tout entier $p \geq 1$,*

$$\mathbb{P}(a_k = p) = (1 - \gamma_{k+1}^{-1})^{p-1} \gamma_{k+1}^{-1}.$$

En particulier, l'espérance, $\mathbb{E}[a_k] = \gamma_{k+1}$, et la variance, $\sigma_{a_k}^2 = \gamma_{k+1}(\gamma_{k+1} - 1)$.

PREUVE DE LA PROPOSITION 6.2. D'après l'algorithme de rejet, pour tout entier $p \geq 1$,

$$\mathbb{P}(a_k = p) = (\mathbb{P}(U \geq \Psi_{k+1}(\xi_k))^{p-1} \mathbb{P}(U < \Psi_{k+1}(\xi_k)))$$

où U est une variable uniformément distribuée dans $[0, 1]$ et ξ_k est distribuée suivant ν_k . Nous avons alors $\mathbb{P}(U < \Psi_{k+1}(\xi_k)) = \gamma_{k+1}^{-1}$. $\square$

D.2 Algorithme de rejet itéré

Nous nous intéressons maintenant au nombre $N_{0,n}$ de générations de variables aléatoires suivant ν_0 requises pour la génération de N variables aléatoires suivant ν_n , en utilisant n algorithmes de rejet successifs. Nous énonçons d'abord le lemme suivant.

Lemme 6.3. *Soit Y une variable aléatoire distribuée suivant $G(m_1)$ (la loi géométrique de paramètre m_1), et $(X^1, X^2, \dots, X^N, \dots)$, des variables aléatoires indépendantes de Y et i.i.d. selon $G(m_2)$. Alors la variable aléatoire $Z = \sum_{i=1}^Y X^i$ suit la loi géométrique $G(m_1 m_2)$.*

PREUVE DU LEMME 6.3. Nous utilisons la caractérisation de la loi de X donnée par la fonction génératrice, $\Phi_X(t) = E[t^X]$. Par définition de la fonction génératrice nous obtenons $\Phi_Z(t) = \Phi_Y(\Phi_X(t))$. Comme X suit la loi $G(m_1)$, nous avons

$$\Phi_X(t) = \frac{m_1 t}{1 - (1 - m_1) t}$$

ainsi,

$$\Phi_Z(t) = \Phi_Y(\Phi_X(t)) = \Phi_Y\left(\frac{m_1 t}{1 - (1 - m_1) t}\right) = \frac{m_2 m_1 t}{1 - (1 - m_2 m_1) t},$$

qui est la fonction génératrice de la loi géométrique $G(m_1 m_2)$. $\square$

Pour générer N variables aléatoires suivant ν_n , nous utilisons n algorithmes de rejet imbriqués. Le temps de calcul aléatoire de cette procédure est déterminé par la proposition suivante.

Proposition 6.4. *Pour tout entier $n \geq 0$, le nombre $N_{0,n}$ de générations suivant ν_0 requises pour générer N variables aléatoires i.i.d. suivant ν_n , suit la loi de Pascal $P(N, \gamma_{1:n}^{-1})$, i.e. $N_{0,n}$ prend les valeurs entières $p = N, N + 1, \dots$ avec les probabilités,*

$$P(N_{0,n} = p) = C_{N-1}^{p-1} (\gamma_{1:n}^{-1})^N (1 - \gamma_{1:n}^{-1})^{p-N} \quad p \geq N,$$

où $\gamma_{1:n}$ désigne le produit $\gamma_1 \cdots \gamma_n$. En particulier, l'espérance $E[N_{0,n}] = N \gamma_{1:n}$ et la variance $\sigma_{N_{0,n}}^2 = N \gamma_{1:n} (\gamma_{1:n} - 1)$.

PREUVE DE LA PROPOSITION 6.4. Pour tout entier $p > k$, nous notons $a_{k,p}$ le nombre de générations de variables aléatoires suivant ν_k requises pour la génération d'une variable aléatoire suivant ν_p . ($a_{k,k+1} = a_k$). Pour toute variable aléatoire X , et tout entier $p \geq 1$, nous notons $X^{(\alpha)}$ avec l'index $\alpha = (i_1, i_2, \dots, i_p) \in \mathbb{N}^p$, des variables aléatoires indépendantes et de même loi que X . Avec cette notation, nous avons

$$N_{0,n} = \sum_{i_1=1}^N a_{0,n}^{i_1} = \sum_{i_1=1}^N \sum_{i_2=1}^{a_n^{i_1}} a_{0,n-1}^{(i_1, i_2)} = \sum_{i_2=1}^{a_n^{i_1}} \cdots \sum_{i_n=1}^{a_1^{(i_1, \dots, i_{n-1})}} a_0^{(i_1, \dots, i_n)}. \quad (6.4)$$

En appliquant la Proposition 6.2 et le Lemme 6.3 successivement $n + 1$ fois, nous obtenons que $a_{0,n}$ suit la loi géométrique $G(\gamma_n^{-1} \cdots \gamma_0^{-1})$, et qu'elle admet ainsi la fonction génératrice

$$\Phi_{a_{0,n}}(t) = \frac{\gamma_n^{-1} \cdots \gamma_1^{-1} t}{1 - (1 - \gamma_n^{-1} \cdots \gamma_1^{-1}) t}.$$

Nous utilisons une nouvelle fois le Lemme 6.3 pour obtenir que la fonction génératrice de $N_{0,n}$ vérifie

$$\Phi_{N_{0,n}}(t) = \left(\frac{\gamma_n^{-1} \cdots \gamma_1^{-1} t}{1 - (1 - \gamma_n^{-1} \cdots \gamma_1^{-1}) t} \right)^N ,$$

que l'on reconnaît comme la fonction génératrice de la loi de Pascal $P(N, \gamma_{1:n}^{-1})$. $\square$

Bibliographie

- [1] H. Akashi, H. Kumamoto, and K. Nose. Application of Monte Carlo Methods to Optimal Control for Linear Systems under Measurement Noise with Markov Dependent Statistical Property. *International Journal on Control*, 22(6):821–836, 1975.
- [2] Brian. D. O. Anderson and John. B. Moore. *Optimal Filtering*. Electrical Engineering. Pentice–Hall, Providence, RI, 1979.
- [3] Christophe Andrieu, J.F.G. De Freitas, and Arnaud Doucet. Sequential MCMC for Bayesian model selection. In *Proceedings of Work. IEEE HOS, Israël*, 1999.
- [4] Rami Atar and Ofer Zeitouni. Exponential stability for nonlinear filtering. *Annales de l'Institut Henri Poincaré, Probabilités et Statistiques*, 33(6):697–725, 1997.
- [5] Vlad Bally and Denis Talay. The law of the Euler scheme for stochastic differential equations. I. *Probability Theory and Related Fields*, 104(1):43–60, 1996.
- [6] Yaakov Bar-Shalom. *Tracking and Data Association*, volume 179 of *Mathematics in science and engineering*. Academic press, 1988.
- [7] Yaakov Bar-Shalom, K. Chang, and H. Blom. Tracking a maneuvering target using input estimation versus the Interacting Multiple Model Algorithm. *IEEE Transactions on Aerospace and Electronic Systems*, AES-25(2):296–300, 1982.
- [8] Vaclav.E. Benes. Exact finite–dimensional filters for certain diffusions with nonlinear drift. *Stochastics*, 5:65–92, 1981.
- [9] Niclas Bergman. Posterior Cramér–Rao bounds for sequential estimation. In A. Doucet, J.F.D. de Freitas, and N.J. Gordon, editors, *Sequential Monte Carlo methods in practice*. 2000.
- [10] Alain Berlinet and Luc Devroye. A comparison of kernel density estimates. *Publication de l'Institut de Statistique de l'Université de Paris*, 38(3):3–59, 1994.
- [11] Carlo Berzuini, N. Best, and C. Larizza. Dynamic conditional independence models and Markov chain Monte Carlo methods. *Journal of the American Statistical Association*, 92:1403–1412, 1997.
- [12] Garrett Birkhoff. *Lattice Theory*, volume XXV of *Colloquium Publications*. AMS, Providence, RI, 3rd edition, 1967.

- [13] W. Blair. Fixed-gain two-stage estimators for tracking maneuvering targets. *IEEE Transactions on Aerospace and Electronic Systems*, AES-29(3):1004–1014, August 1993.
- [14] Henk A. P. Blom and Yaakov Bar-Shalom. The interacting multiple model algorithm for systems with Markovian switching coefficients. *IEEE Transactions on Automatic Control*, AC-33(8):780–783, August 1988.
- [15] Haïm Brézis. *Analyse Fonctionnelle*. Mathématiques Appliquées pour la Maîtrise. Masson, Paris, 1983.
- [16] Amarjit Budhiraja and Daniel L. Ocone. Exponential stability of discrete-time filters for bounded observation noise. *Systems and Control Letters*, 30:185–193, 1997.
- [17] Amarjit Budhiraja and Daniel L. Ocone. Exponential stability of discrete-time filters for non-ergodic signals. *Stochastic Processes and their Applications*, 82:245–257, 1999.
- [18] Zhiqiang Cai, François Le Gland, and Huilong Zhang. An adaptive local grid refinement method for nonlinear filtering. Technical Report 2679, INRIA, 1995.
- [19] George Casella and Christian P. Robert. Post-processing accep-reject samples: recycling and rescaling. Biometrics unit, Cornell University, 1996.
- [20] Mireille Chaleyat-Maurel and Dominique Michel. Des résultats de non existence de filtre de dimension finie. *Stochastics*, 13:83–102, 1984.
- [21] C. K. Chui and G. Chen. *Kalman Filtering with Real-Time applications*. Springer-Verlag, New-York, 3rd edition, 1999.
- [22] J. M. C. Clark, Daniel L. Ocone, and Cyril E. Coumarbatch. Relative entropy and error bounds for filtering of Markov process. *Mathematics of Control, Signals, and Systems*, 12:346–360, 1999.
- [23] Dan Crişan, Pierre Del Moral, and Terry J. Lyons. Nonlinear Filtering using Branching and Interacting Particle Systems. *Markov Processes and Related Fields*, 5(3), 1999.
- [24] Dan Crişan and Terry J. Lyons. Nonlinear filtering and measure-valued processes. *Probability Theory and Related Fields*, 109(2):217–244, 1997.
- [25] Giuseppe Da Prato, Marco Fuhrman, and Paul Malliavin. Asymptotic ergodicity for the Zakai filtering equation. *Comptes Rendus de l'Académie des Sciences, Série I, Mathématique*, 321(5):613–616, 1995.
- [26] Giuseppe Da Prato, Marco Fuhrman, and Paul Malliavin. Asymptotic ergodicity of the process of conditional law in some problem of nonlinear filtering. *Journal of Functional Analysis*, 164(2):356–377, 1999.
- [27] J. Darricau. *Physique et théorie du radar*. Concept de Traitement du Signal. Sodipe, 1994.
- [28] M. Davis. New Approach to Filtering nonlinear Systems. *IEEE Proceedings, Part D*, 128(5):166–172, 1981.

- [29] Paul Deheuvels. Estimation non paramétrique de la densité par histogrammes généralisés. *Revue de Statistique Appliquée*, 25:5–42, 1977.
- [30] Pierre Del Moral. Nonlinear filtering: interacting particle resolution. *Markov Processes and Related Fields*, 2(4):555–580, 1996.
- [31] Pierre Del Moral. A uniform convergence theorem for the numerical solving of the nonlinear filtering problem. *Journal of Applied Probability*, 35(4):873–884, 1998.
- [32] Pierre Del Moral and Alice Guionnet. Large deviation for interacting particle systems. Application to nonlinear filtering problems. *Stochastic Processes and their Applications*, 78(1):69–95, 1998.
- [33] Pierre Del Moral and Alice Guionnet. On the Stability of Measure Valued Processes. Applications to Nonlinear Filtering and Interacting Particle Systems. Publication du Laboratoire de Statistique et Probabilités 03–98, Université Paul Sabatier, Toulouse, 1998.
- [34] Pierre Del Moral and Alice Guionnet. A Central Limit Theorem for Nonlinear Filtering using Interacting Particle Systems. *Advances in Applied Probability*, 9(2):275–297, 1999.
- [35] Pierre Del Moral and Jean Jacod. The Monte–Carlo Method for filtering with discrete time observations. Central Limit Theorems. Publication du Laboratoire de Probabilités 515, Université Paris VI, Paris, 1999.
- [36] Pierre Del Moral, Jean Jacod, and Philip Protter. The Monte–Carlo Method for filtering with discrete time observations. Publication du Laboratoire de Probabilités 435, Université Paris VI, Paris, 1998.
- [37] Pierre Del Moral and Michel Ledoux. On the Convergence and the Applications of Empirical Processes for Interacting Particle Systems and Nonlinear Filtering. *Journal of Theoretical Probability*, 13(1):225–257, 2000.
- [38] Pierre Del Moral and Laurent Miclo. Branching and Interacting Particle Systems Approximations of Feynman–Kac Formulae with Applications to Non–Linear Filtering. In J. Azéma, M. Emery, M. Ledoux, and M. Yor, editors, *Séminaire de Probabilités XXXIV*, volume 1729 of *Lecture Notes in Mathematics*. Springer–Verlag, Berlin, 2000.
- [39] Pierre Del Moral, Gilles Rigal, and Gérard Salut. Estimation et commande optimale non–linéaire. Technical Report 2, Convention D.R.E.T.-DIGILOG-LAAS/CNRS, SM.MCY/685.92/A, 89.34.553.00.470.75.01, mars 1992.
- [40] Pierre Del Moral, Gilles Rigal, and Gérard Salut. Estimation et commande optimale non–linéaire: la résolution particulière en estimation/filtrage - résultats théoriques. Technical Report 3, Convention D.R.E.T. / 89.34.553.00.470.75.01, October 1992.
- [41] Bernard Delyon and Ofer Zeitouni. Lyapounov exponents for filtering problems. In M.H.A. Davis and R.J. Elliot, editors, *Applied Stochastic Analysis*. Gordon and Breach, New–York, 1991.

- [42] Luc Devroye. *Non-Uniform Random Variate Generation*. Springer-Verlag, Berlin, 1986.
- [43] Luc Devroye. *A Course on Density Estimation*, volume 14 of *Progress in Probability and Statistics*. Birkhäuser, Boston, 1987.
- [44] Luc Devroye. The double kernel method in density estimation. *Annales de l'Institut Henri Poincaré, Probabilités et Statistiques*, 25:533–580, 1989.
- [45] Luc Devroye and László Györfi. *Nonparametric Density Estimation: The L_1 View*. Wiley series in Probability and Mathematical Statistics. John Wiley & Sons, New York, 1985.
- [46] Arnaud Doucet. On sequential simulation based methods for Bayesian filtering. CUED/F-INFENG/TR.310 310, Signal Processing Group, Department of Engineering, University of Cambridge, 1998.
- [47] Anne Gegout-Petit. Approximate Filter for the Conditional Law of a Partially Observed Process in Nonlinear filtering. *SIAM Journal on Control and Optimization*, 36(4):1423–1447, 1998.
- [48] Neil J. Gordon. A Hybrid Bootstrap Filter for Target Tracking in Clutter. *IEEE Transactions on Aerospace and Electronic Systems*, 33(1):353–358, 1997.
- [49] Neil J. Gordon, David J. Salmond, and Adrian F. M. Smith. Novel approach to nonlinear/non-Gaussian Bayesian state estimation. *IEE Proceedings, Part F*, 140(2):107–113, April 1993.
- [50] Lei Guo, Lennart Ljung, and Pierre Priouret. Tracking Performance Analysis of the Forgetting Factor RLS Algorithm. In *Proceedings of the 31st Conference on Decision and Control, Tuscon, Arizona*, December 1992.
- [51] Peter Hall. Large-sample optimality of least squares cross-validation in density estimation. *Annals of Statistics*, 11:1156–1174, 1983.
- [52] J.E. Handschin. Monte Carlo Techniques for Prediction and Filtering of Non-Linear Stochastic Processes. *Automatica*, 6:555–563, 1970.
- [53] Lasse Holmström and Jussi Klemelä. Asymptotic bounds for the expected L_1 error of a multivariate kernel density estimator. *Journal of Multivariate Analysis*, 42(2):245–266, 1992.
- [54] Eberhard Hopf. An inequality for positive linear integral operators. *Journal of Mathematics and Mechanics*, 12(5):683–692, 1963.
- [55] Markus Hürzeler. *Statistical Methods for General State-Space Models*. Ph.D. Thesis, Department of Mathematics, ETH Zürich, Zürich, 1998.
- [56] Markus Hürzeler and Hans R. Künsch. Monte Carlo approximations for general state space models. *Journal of Computational and Graphical Statistics*, 7(2):175–193, June 1998.

- [57] Claude Jauffret. *Trajectographie passive, observabilité et prise en compte des fausses alarmes*. PhD thesis, Université de Toulon, Var, 1993.
- [58] Andrew. H. Jazwinski. *Stochastic Process and Filtering Theory*. Colloquium Publications. Academic Press, New-York and London, 1970.
- [59] R. E. Kalman. A New Approach to Linear Filtering and Prediction Problems. *Trans. ASME, Journal of Basic Engineering*, 82:34–45, 1960.
- [60] R. E. Kalman and R. Bucy. A New Approach to Linear Filtering and Prediction Theory. *Trans. ASME, Journal of Basic Engineering*, 83:95–108, 1961.
- [61] G. Kitagawa. Non-Gaussian State-Space Modeling of Nonstationary Time Series. *Journal of the American Statistical Association*, 82(400):1032–1063, 1987.
- [62] G. Kitagawa. Monte Carlo Filter and Smoother for Non-Gaussian Nonlinear State Space Models. *Journal of Computational and Graphical Statistics*, 5(1):1–25, 1996.
- [63] Peter E. Kloeden and Eckhard Platen. *Numerical Solution of Stochastic Differential Equations*. Applications of Mathematics. Springer-Verlag, 1992.
- [64] A. Kong, J. S. Liu, and W. H. Wong. Sequential Imputations and Bayesian Missing Data Problems. *Journal of the American Statistical Association*, 89(425):278–288, 1994.
- [65] Hiroshi Kunita. Asymptotic behavior of the nonlinear filtering errors of Markov processes. *Journal of Multivariate Analysis*, 1:365–393, 1971.
- [66] Hiroshi Kunita. Ergodic properties of nonlinear filtering processes. In K.C. Alexander and J.C. Watkins, editors, *Spatial Stochastic Processes: Festschrift in honor of T.E. Harris*, volume 19 of *Progress in Probability*, pages 233–256. Birkhäuser, Boston, 1991.
- [67] Harold J. Kushner and P. Dupuis. *Numerical Methods for Approximations in Stochastic Control Problems in Continuous Time*, volume 24 of *Applications of Mathematics*. Springer-Verlag, New-York, 1992.
- [68] François Le Gland. Monte-Carlo Methods in nonlinear Filtering. In *Proceedings of the 23rd Conference on Decision and Control, Las Vegas*, pages 31–32, December 1984.
- [69] François Le Gland. Introduction au filtrage en temps discret. Filtre de Kalman—Modèles de Markov cachés. Dea stir, Université de Rennes I, 1995.
- [70] François Le Gland. Stability and Approximation of Nonlinear Filters: an Information Theoretic Approach. In *Proceeding of the IEEE European Workshop on Computer-Intensive Methods in Control and Signal, Phoenix*, pages 1889–1894, December 1999.
- [71] François Le Gland and Laurent Mevel. Basic properties of projective product with application to products of column-allowable nonnegative matrices. *Mathematics of Control, Signals, and Systems*, 13:41–62, 2000.
- [72] François Le Gland and Laurent Mevel. Exponential forgetting and geometric ergodicity in hidden markov models. *Mathematics of Control, Signals, and Systems*, 13:63–93, 2000.

- [73] François Le Gland, Christian Musso, and Nadia Oudjane. An analysis of regularized interacting particle methods for nonlinear filtering. In Jiří Rojíček, Markéta Valečková, Miroslav Kárný, and Kevin Warwick, editors, *Proceedings of the IEEE European Workshop on Computer-Intensive Methods in Control and Data Processing, Prague*, pages 167–174, September 1998.
- [74] Robert S. Liptser and Albert N. Shiryaev. *Statistics of random processes*, volume I, II. Springer, 1977.
- [75] J.S. Liu and R. Chen. Monte Carlo Methods for Dynamic Systems. Technical report, Department of Statistics, Stanford University, 1997.
- [76] A.M. Makowski and Richard B. Sowers. Discrete-time filtering for linear systems with non Gaussian initial conditions: Asymptotic behavior of the difference between the MMSE and the LMSE estimates. *IEEE Transactions on Automatic Control*, 37:114–121, 1992.
- [77] J. Marcinkiewicz and A. Zygmund. Sur les fonctions indépendantes. *Fundamentales de Mathématiques*, 29:60–90, 1937.
- [78] Paula Milheiro de Oliveira. Filtres approchés pour un problème de filtrage non linéaire discret avec petit bruit d’observation. Technical Report 1142, INRIA, 1989.
- [79] Christian Musso. *Méthodes rapides d’estimation en trajectographie par mesures d’azimuts*. PhD thesis, Université Joseph Fourier–Grenoble I, 1993.
- [80] Christian Musso and Nadia Oudjane. Regularisation schemes for branching particle systems as a numerical solving method of the nonlinear filtering problem. In *Proceedings of the Irish Signals Systems Conference, Dublin*, June 1998.
- [81] Christian Musso and Nadia Oudjane. Recent particle filter applied to terrain navigation. In *Proceedings of the 3rd International Conference on Fusion, Paris*, July 2000.
- [82] Christian Musso, Nadia Oudjane, and François Le Gland. Improving regularized particle filters. In A. Doucet, J.F.D. de Freitas, and N.J. Gordon, editors, *Sequential Monte Carlo methods in practice*. 2000.
- [83] Steven C. Nardone and Vincent J. Aidala. Observability criteria for bearings-only target motion analysis. *IEEE Transactions on Aerospace and Electronic Systems*, AES–17(2):162–166, March 1981.
- [84] Daniel L. Ocone. Stochastic calculus of variations for SPDEs. *Journal of Functional Analysis*, 79:288–331, 1986.
- [85] Daniel L. Ocone and Etienne Pardoux. A Lie-algebraic criterion for non existence of finite dimensionally computable filters. In Da Prato and Tubaro, editors, *Stochastic Partial Differential Equations and Applications*, volume 1390 of *Lecture Notes in Mathematics*. Springer, 1989.

-
- [86] Daniel L. Ocone and Etienne Pardoux. Asymptotic stability of the optimal filter with respect to its initial condition. *SIAM Journal on Control and Optimization*, 34(1):226–243, 1996.
 - [87] Nadia Oudjane and Christian Musso. Multiple model particle filter. In *Actes du 17ème Colloque GRETSI, Vannes*, September 1999.
 - [88] Nadia Oudjane and Christian Musso. Progressive correction for regularized particle filters. In *Proceedings of the 3rd International Conference on Fusion, Paris*, July 2000.
 - [89] Etienne Pardoux. Filtrage Non Linéaire et Equations aux Dérivées Partielles Stochastiques Associées. In *Ecole d'été de Probabilités de Saint-Flour XIX*, volume 1464 of *Lecture Notes in Mathematics*. Springer-Verlag, 1989.
 - [90] Dinh Tuan Pham. Stochastic methods for sequential data assimilation in strongly non-linear systems. Technical Report 3597, INRIA, 1998.
 - [91] Jean Picard. Filtrage de diffusions vectorielles faiblement bruitées. In *Analysis and Optimization of Systems*, volume 83 of *Lecture Notes in Control and Information Sciences*. Springer, 1986.
 - [92] Jean Picard. Asymptotic study of estimation problems with small observation noise. In *Stochastic Modelling and Filtering*, volume 91 of *Lecture Notes in Control and Information Sciences*. Springer, 1987.
 - [93] Jean Picard. Efficiency of the Extended Kalman Filter. *SIAM Journal on Applied Mathematics*, 51(3):843–885, 1991.
 - [94] Mike K. Pitt and Neal Shephard. Filtering via simulation: auxiliary particle filters. *Journal of the American Statistical Association*, 94, 1999.
 - [95] Pierre-Arnaud Raviart. An analysis of particle methods. In F. Brezzi, editor, *Numerical Methods in Fluid Dynamics, Como 1983*, volume 1127 of *Lecture Notes in Mathematics*, pages 243–324. Springer-Verlag, Berlin, 1985.
 - [96] Christian P. Robert. *Méthodes de Monte Carlo par Chaîne de Markov*. Statistique mathématique et Probabilité. Economica, Paris, 1996.
 - [97] Donald B. Rubin. Using the SIR algorithm to simulate posterior distributions. In J.M. Bernardo, M.H. DeGroot, D.V. Lindley, and A.F.M. Smith, editors, *Bayesian Statistics 3*, pages 395–402. Oxford University Press, Oxford, 1988.
 - [98] Mats Rudemo. Empirical choice of histograms and kernel density estimators. *Scandinavian Journal of Statistics*, 9:65–78, 1982.
 - [99] Bernard W. Silverman. *Density Estimation for Statistics and Data Analysis*, volume 26 of *Monographs on Statistics and Applied Probability*. Chapman & Hall, London, 1986.
 - [100] Łukasz Stettner. On invariant measures of filtering processes. In *Stochastic Differential Systems*, volume 126 of *Lecture Notes in Control and Information Sciences*. Springer-Verlag, Berlin, 1989.

- [101] Łukasz Stettner. Invariant measures of pair : state, approximate filtering process. *Colloquium Mathematicum*, LXII(2):347–351, 1991.
- [102] Denis Talay and Luciano Tubaro. Expansion of the global error for numerical schemes solving Stochastic Differential Equations. *Stochastic and Applications*, 8(4):483–509, 1990.
- [103] P. Whittle. Bounds for the moments of linear and quadratic forms in independant random variables. *Theory of Probability and its Applications*, 5:302–305, 1960.
- [104] M. Woodroffe. On Choosing a Delta-Sequence. *Annals of Mathematical Statistics*, 41:1665–1671, 1970.

Résumé

Le problème du filtrage non linéaire consiste à calculer de façon approchée la loi conditionnelle d'un processus markovien appelé signal, indirectement lié à un processus observation dont on connaît une réalisation. Le but de cette thèse est de proposer de nouveaux algorithmes particuliers pour la résolution du problème de filtrage non linéaire. La première idée développée ici souligne le lien fort existant entre les propriétés de stabilité du filtre optimal et le comportement en temps long de certains filtres approchés. On étudie la sensibilité du filtre optimal à différents types de perturbations locales intervenant dans son évolution à chaque pas de temps. On met ainsi en évidence le rôle clé de la métrique projective de Hilbert qui permet le contrôle uniforme en temps de l'erreur globale induite dans le filtre perturbé pourvu que le signal vérifie certaines conditions d'ergodicité. Ces résultats permettent en particulier de montrer que sous ces mêmes conditions d'ergodicité, les deux filtres particuliers initialement proposés dans la littérature (filtre de Monte Carlo pondéré et filtre particulier avec interaction) convergent uniformément en temps, vers le filtre optimal. Cependant, une analyse plus générale des méthodes particulières classiques met en évidence leur faiblesse spécialement dans le cas de systèmes faiblement bruités et nous conduit à proposer un nouveau type de filtres particuliers utilisant une perturbation locale plus fine. La régularisation constitue l'étape clé de cette perturbation. Elle est basée sur une extension de la théorie de l'estimation de densité par noyaux et permet de remplacer l'approximation discrète fournie par les filtres particuliers classiques en une approximation lisse. Les deux types de filtres particuliers résultants appelés filtre pré-régularisé et filtre post-régularisé sont analysés. Ils sont ensuite appliqués en simulations à différents problèmes de pistage.

Mots clés : filtrage non linéaire, stabilité, métrique projective, Monte Carlo, méthodes particulières, estimation de densité, pistage de cible.

Abstract

The nonlinear filtering problem consists in computing the conditional distribution of a Markovian process, usually called signal, given noisy observations. In this thesis, the aim is to propose some new particle algorithms to compute the optimal filter. The first point developed here emphasizes the link between the stability properties of the optimal filter and the long time behavior of approximate filters. The sensitivity of the optimal filter with regards to local perturbations occurring at each step of time in its evolution is studied. The Hilbert projective metric appears to be specially adapted to this analysis and allows us to bound uniformly in time the global error induced in the filter, provided that some suitable ergodicity assumptions are satisfied by the signal. These results are then used to prove uniform convergence of the weighted Monte Carlo filter and the interacting particle filter originally developed in particle filtering. However, out of the ergodicity assumption, classical particle filters can behave badly, especially in cases of small observation or dynamical noise. To overcome this problem we propose a new kind of particle filters based on a more accurate local perturbation. The basic idea is based on the regularization step which is a generalization of the kernel density estimation principle used to estimate the underlying density of a given i.i.d. sample. The regularization step allows to change the discrete approximation provided by classical particle filters to a continuous approximation. Two kind of particle filters are then developed: the pre-regularized and post-regularized particle filter. Both are analyzed theoretically and applied to classical tracking problems.

Keywords : nonlinear filtering, stability, projective metric, Monte Carlo, particle methods, density estimation, target tracking.